
Université Paris 1 Panthéon-Sorbonne

École d'Histoire de la Sorbonne

Master 1 — Sciences des Données, Histoire et Culture

Le « barbare » comme objet historiographique

Bibliométrie et analyse lexicale d'un champ
scientifique (1975–2025)

Enora ROY

Sous la direction de

Monsieur LAMASSÉ Stéphane

et

Madame JOYE Sylvie

Année universitaire 2025–2026

Table des matières

1 Le « barbare » comme problème historiographique : pour une lecture distante du champ	17
1.1 Polysémie constitutive et enjeux de définition du « barbare »	17
1.2 Objectiver le champ : bibliométrie, science mapping et distant reading comme instruments d'une appréhension structurale	22
1.2.1 Un sous-champ en cours de cristallisation : la médiévistique du Haut Moyen Âge entre autonomie disciplinaire et perméabilité aux autres champs	22
1.2.2 La publication comme prise de position : trace des luttes dans le champ historiographique	25
1.2.3 « Mesurer la science » LARIVIÈRE et SUGIMOTO 2018 pour la cartographier : le champ comme cadre d'intelligibilité de la bibliométrie	27
1.2.4 Changement de regard et construction de l'objet, le distant reading comme épistémologie du faire	32
1.3 Délimitation du corpus : le « barbare » comme entrée lexicale et les bornes du corpus	34
1.4 Annonce du plan	37
2 Construire l'archive : Worldcat, le format RIS et les conditions épistémologiques d'une bibliométrie de l'historiographie.	39
2.1 Worldcat face à l'historien	40
2.1.1 « Worldcat », une coopérative mondiale : histoire, structure et choix	40
2.1.2 Une organisation à but non-lucratif aux logiques commerciales : ambiguïtés du modèle économique et rapport de force sur les données.	41

2.1.3	De quoi Worldcat est-il l'archive (RYGIEL 2011) ? Statut épistémologique d'une base de données bibliographiques.	44
2.1.4	Des problèmes anciens, sous une autre forme : la trace numérique et l'enquête historique.	47
2.2	Une donnée appauvrie : le RIS	48
2.2.1	Un format conçu pour la citation, et non la description : histoire et logique commerciale du RIS	48
2.2.2	Des silences du RIS aux bruits de la donnée.	51
2.2.3	Bruit, doublons et corruption d'encodage : les imperfections de la donnée comme <i>données</i> sur l'archive.	52
2.3	La redocumentarisation comme geste épistémologique	55
2.3.1	Une stratégie explorée mais impraticable : SPARQL et les limites de l'interopérabilité.	55
2.3.2	Augmenter la donnée sans la trahir : choix des référentiels et arbitrages épistémologiques.	56
3	De la notice à la base de données : protocole, modélisation et construction de l'objet.	63
3.1	IA et protocole : usage, effet, réflexivité	63
3.1.1	L'utilisation de l'Intelligence Artificielle dans ce projet : assistant de protocole et inférence.	63
3.1.2	Le prompt comme pensée structurée et posture de décomposition du problème de recherche	66
3.1.3	<i>Prompt engineering</i> : exemple de prompt utile et bonnes pratiques dans mes usages de l'IA	68
3.1.4	Enjeux éthiques, moraux et intellectuels de l'utilisation des LLM . .	71
3.2	Du <i>scraping</i> à la base : hiérarchisation des stratégies de collecte et retours réflexifs sur un protocole de bibliométrie.	73
3.2.1	Du choix de nos outils	73
3.2.2	Récupérer la donnée, scraper Worldcat	75
3.2.3	Nettoyage, normalisation, uniformisation	89
3.2.4	Enrichissement des données, redocumentarisation	96
3.2.5	Une hiérarchisation des méthodes d'augmentation des données . . .	103

3.2.6	Imputer la donnée : une stratégie envisageable ?	104
3.2.7	Bonnes pratiques, satisfactions et insatisfactions d'un protocole de collecte semi-automatisé	115
3.3	De l'entité au document	116
3.3.1	Les contraintes d'un modèle normalisé : MySQL et l'homogénéité impossible de données bibliographiques hétérogènes	116
3.3.2	Réhabiliter la singularité de la notice : MongoDB et le document . .	119
4	Pour une cartographie du champ : l'objet « barbare » entre structures sociales et régimes discursifs.	123
4.1	Le choix des mots clés : condition d'accès au corpus.	123
4.2	Des mots à la trace	123
4.2.1	Une liste à tendance maximaliste	125
4.2.2	Traduire, c'est trahir ? La question du multilinguisme dans l'histo- riographie	129
4.3	La langue : « structure structurée et structurante » du champ	130
4.3.1	La distribution linguistique du corpus : un indicateur des transfor- mations du champ	131
4.3.2	La structure nationale du corpus	134
4.3.3	La langue, expression de la position d'une nation au sein du champ ?	135
4.4	Qui écrit avec qui ? Topologie et inégalités structurelles du réseau de coautorat	140
4.4.1	Construction et lecture du réseau : méthodologie et épistémologie .	142
4.4.2	Cadrage général et premiers observables statistiques	147
4.4.3	Qui ou quoi est dans la composante principale ? Accès et premières inégalités	150
4.4.4	Les positions dans le réseau : formes de capitaux et logiques d'inégalité	162
4.4.5	Une structure qui se sédimente : dynamiques temporelles et effet d'ancienneté	173
4.4.6	Les apports de la topologie et la nécessité du tournant textuel . . .	178
4.5	Les mots pour le dire	180
4.5.1	Construire le corpus : entre contraintes techniques et choix épisté- mologiques	181
4.5.2	Une première lecture : le corpus délinéarisé	190

4.5.3	Restituer le sens : analyse des cooccurrences de « barbar »	224
4.5.4	Ce que le lexique dit du champ	235
5	Conclusion	239
5.1	Ce que l'enquête a montré.	239
5.2	Retour à la problématique : existe-t-il un champ du Haut Moyen Âge? . .	241
5.3	Portée, limites et perspectives.	241
6	Bibliographie	245
6.1	Ouvrages	245
6.2	Articles de revues	249
6.3	Chapitres d'ouvrages collectifs	257
6.4	Autres	260
7	Annexes	263
7.1	Annexes pour la section 2.3	263
7.2	Annexes pour la section 3.1.3	269
7.3	Annexes pour la section 4.3	271
7.4	Annexes pour la section 4.4	284
7.5	Annexes pour la section 4.5	315
7.5.1	Les Analyses Factorielles des Correspondances	317
7.5.2	La LDA	386

Remerciements

Je tiens à remercier toutes les personnes qui m'ont aidée au cours de ce projet.

Je voudrais d'abord remercier mon directeur de mémoire, M. LAMASSÉ, Maître de conférences (LaMOP) à l'Université Paris 1 Panthéon-Sorbonne, pour son encadrement et le temps qu'il m'a accordé, sa patience et ses précieux conseils.

Je remercie également Mme JOYE, Professeure d'histoire du Moyen Âge (LaMOP) à l'Université Paris 1 Panthéon-Sorbonne, dont l'expertise en histoire médiévale a été un soutien précieux pour ancrer ce travail dans son contexte historiographique.

J'adresse mes sincères remerciements à tous les membres du Pireh (Pôle Informatique de Recherche et d'Enseignement en Histoire), et plus largement aux professeurs et intervenants qui, par leurs cours et leurs échanges avec moi sur mon projet, ont guidé mes réflexions.

Je remercie tout particulièrement les personnes inconnues contactées dans le cadre de ce projet, au détour d'un e-mail, qui ont généreusement transmis les informations demandées à une étudiante qui présentait son projet et sa formation : Matthew TRESKON, pour les références dans la base de données « Project Muse », et un représentant de Paperity¹, qui m'a transmis le lien de l'API (Application Programming Interface) Scholarapi, m'a permis de récupérer automatiquement les références de Paperity, et m'a même proposé des crédits gratuitement.

Enfin, je tiens à exprimer toute ma gratitude pour mes parents, Sophie et Frédéric, et mes frères, Evan et Maël, pour leur soutien inconditionnel tout au long de cette année, et pour avoir toujours été là pour moi. Un immense merci à Pichenette, pour sa présence indéfectible.

1. Souhaitant demeurer anonyme.

Liste des acronymes et des formats de fichier fréquemment cités

Explications

Pour des raisons pratiques autant qu'épistémologiques, je restitue les principales abréviations utilisées ici. Le lecteur aura remarqué la présence de nombreuses expressions anglaises, même lorsqu'une traduction était disponible.

Pratiques, car elles correspondent, pour partie, à mes propres conventions d'écriture dans ma base de données (USA, UK), qui, le plus souvent, sont issues du *scraping* de sites hétérogènes.

Cognitives, car ces anglicismes disent quelque chose de la manière dont j'appréhende moi-même ces outils : par mes lectures, en grande majorité anglophone, par des blogs ou des billets *substack*.

Liste des abréviations

AFC Analyse Factorielle des Correspondances

API *Application Programming Interface* (interface de programmation)

BDD Base De Données

BERT Bidirectional Encoder Representations from Transformers

BnF Bibliothèque nationale de France

CAPTCHA *Completely Automated Public Turing test to tell Computers and Humans Apart* (famille de tests de Turing permettant de différencier de manière automatisée un utilisateur humain d'un ordinateur)

CSV *Comma Separated Values* (valeurs séparées par des virgules)

DOI *Digital Object Identifier* (identifiant numérique d'objet)

GND *Gemeinsame Normdatei* (fichier d'autorités partagé international géré par la Bibliothèque Nationale Allemande)

HDBSCAN *Hierarchical Density-Based Clustering of Applications with Noise*

HTML *Hypertext Markup Language* (langage de balisage conçu pour écrire les pages web)

HTTP *Hypertext Transfer Protocol* (protocole de transfert hypertexte)

IA Intelligence Artificielle

IdRef Identifiants et Référentiels

IEEE *Institute of Electrical and Electronics Engineers* (Institut des ingénieurs électriciens et électroniciens)

IP *Internet Protocol* (Protocole internet)

ISNI *International Standard Name Identifier* (Code international normalisé des noms)

ISSN *International Standard Serial Number* (Numéro international normalisé des publications en série)

JSON JavaScript Object Notation

LLM *Large Language Model* (Grand Modèle de Langue)

LCC *Largest Connected Component* (Composante Connexe Principale)

LDA *Latent Dirichlet Allocation* (Allocation de Dirichlet Latente)

MARC *MAchine-Readable Cataloging* (format d'échange de données bibliographiques informatisées des catalogues de bibliothèques)

MCD Modèle Conceptuel de Données

NLP *Natural Language Processing* (TAL, Traitement Automatique de la Langue)

NoSQL *Not Only Structured Query Language*

OCLC *Online Computer Library Center*

ORCID *Open Researcher and Contributor ID*

OTAN Organisation du Traité de l'Atlantique Nord

PCA *Principal Component Analysis* (Analyse en Composantes Principales)

PDF *Portable Document Format*

RDF *Resource Description Framework*

RIS *Research Information System*

SHS Sciences Humaines et Sociales

SPARQL *SPARQL Protocol and RDF Query Language*

SQL *Structured Query Language*

STC *Short Text Clustering* (regroupement des textes courts)

STEM *Science, Technology, Engineering, and Mathematics* (Science, Technologie, Ingénierie et Mathématiques)

TAL *Traitement Automatique de la Langue*

TF-IDF *Term Frequency - Inverse Document Frequency*

t-SNE *t-distributed Stochastic Neighbor Embedding*

UK *United Kingdom* (Royaume-Uni)

UMAP *Uniform Manifold Approximation and Projection*

URL *Uniform Resource Locator* (localisateur uniforme de ressource)

URI *Uniform Resource Identifier* (identifiant uniforme de ressource)

URSS *Union des Républiques Socialistes Soviétiques*

USA *United States of America* (États-Unis d'Amérique)

UTF-8 *Universal Character Set Transformation Format - 8 bits*

VIAF *Virtual International Authority File* (fichier international d'autorité virtuel)

VPN *Virtual Private Network* (réseau privé virtuel)

WoS *Web of Science*

XML *Extensible Markup Language* (langage de balisage extensible)

Lexique, définitions, utilitaires

Cette courte section a pour objectif d'aider le lecteur peu familier des termes techniques exposés ici, en prodiguant, autant que possible, quelques explications sur leur définition. Sans prétendre à une définition exhaustive et totale de ces termes, dont les aspects sont davantage exposés dans le corps du développement, il s'agit surtout d'une page sur laquelle le lecteur peut revenir au cours de la lecture pour aider la compréhension.

Les principales bibliothèques Python mobilisées

Beautiful Soup Bibliothèque d'analyse syntaxique de documents HTML et XML, utilisée pour extraire automatiquement des données structurées depuis des pages web.

geckodriver Pilote permettant à Selenium de contrôler le navigateur Firefox ; son installation constitue un prérequis à l'utilisation de Selenium avec ce navigateur.

NetworkX Bibliothèque Python pour la création, la manipulation et l'analyse de graphes. Mobilisée ici pour la construction et l'étude du réseau de coautorat : calcul des indicateurs de centralité, détection des composantes connexes et projection unipartie.

pandas Bibliothèque Python de manipulation et d'analyse de données tabulaires, reposant sur la structure de *DataFrame*. Utilisée dans ce travail pour le nettoyage, la normalisation et l'exploration statistique de la base bibliographique.

PyAutoGUI Bibliothèque d'automatisation de l'interface graphique permettant de contrôler la souris et le clavier de manière automatique, utilisée pour automatiser des interactions avec des interfaces ne proposant pas d'API.

requests Bibliothèque Python permettant d'envoyer des requêtes HTTP et de récupérer le contenu de pages web automatiquement.

rispy Bibliothèque Python permettant de lire et d'écrire des fichiers au format RIS, format bibliographique standard notamment utilisé par WorldCat pour l'export de notices.

Selenium Outil d'automatisation de navigateur web permettant de simuler des interactions humaines (navigation, clics, saisies de formulaires), utile pour accéder à des contenus dynamiques inaccessibles par les seules requêtes HTTP.

spaCy Bibliothèque de traitement automatique des langues (TAL) en Python, utilisée

dans ce travail pour la tokenisation, la lemmatisation et l'étiquetage morphosyntaxique des textes du corpus.

Quelques termes, logiciels et anglicismes à expliquer

API (*Application Programming Interface*) Interface permettant à des programmes informatiques de communiquer entre eux. Dans ce travail, les API désignent principalement des points d'accès distants : envoyer une requête à l'adresse d'une API (par exemple celle de Crossref, d'IdRef ou de Wikidata) permet de récupérer automatiquement des métadonnées structurées sans passer par une interface graphique.

Base de données relationnelle vs NoSQL Une base de données *relationnelle* (comme MySQL) organise l'information en tables homogènes reliées par des identifiants communs, supposant une structure fixe et normalisée. Une base *NoSQL* (ici MongoDB) stocke au contraire des documents hétérogènes (au format JSON), sans schéma prédéfini, permettant une plus grande souplesse face à des données de structure variable.

Cloudflare Service de sécurité web déployé pour protéger les sites internet contre les robots et les attaques automatisées ; il peut bloquer ou ralentir les tentatives de collecte automatisée de données.

Clustering Méthode d'analyse automatique consistant à regrouper des éléments (documents, termes, individus) selon leur similarité, sans catégories prédéfinies imposées par le chercheur.

DOI (*Digital Object Identifier*) Identifiant numérique pérenne attribué à une publication scientifique par un organisme centralisateur (Crossref pour la majorité des éditeurs académiques). Il se présente sous la forme 10.XXXX/... et permet de localiser de manière stable un document sur le web, indépendamment des changements d'URL.

Encodage En informatique, système de représentation numérique des caractères. L'encodage UTF-8, par exemple, permet de représenter l'ensemble des caractères Unicode, incluant les caractères accentués et les alphabets non latins. Des problèmes d'encodage surviennent lorsqu'un fichier est interprété selon un standard différent de celui utilisé pour sa création.

Scraping (ou *web scraping*) Collecte automatisée de données depuis des pages web, no-

tamment par le biais de programmes analysant le code HTML des pages pour en extraire le contenu.

TF-IDF (*Term Frequency – Inverse Document Frequency*) Mesure statistique pondérant la fréquence d'un terme dans un document par sa rareté dans l'ensemble du corpus. Un terme fréquent dans un document mais rare ailleurs obtient un score élevé, ce qui en fait un indicateur de spécificité lexicale d'un document par rapport au corpus.

Token En traitement automatique des langues, unité minimale obtenue après segmentation d'un texte : généralement un mot ou un signe de ponctuation. La *tokenisation* est l'opération préalable à l'analyse lexicale ou statistique d'un corpus.

Vectorisation Opération consistant à transformer des données textuelles en représentations numériques (vecteurs), permettant leur traitement mathématique et statistique (pour notamment BERT)

Principaux concepts mathématiques mobilisés

Corrélation de Pearson (r) Mesure de la force et du sens de la relation *linéaire* entre deux variables continues. Elle varie entre -1 (relation linéaire négative parfaite) et $+1$ (relation linéaire positive parfaite), la valeur 0 indiquant l'absence de relation linéaire.

Corrélation de Spearman (ρ) Mesure de la relation *monotone* entre deux variables, fondée sur le rang des observations plutôt que sur leurs valeurs brutes. Plus pertinent que la corrélation de Pearson en présence de valeurs extrêmes ou lorsque la relation n'est pas strictement linéaire.

Test du χ^2 de conformité Test statistique mesurant l'écart entre des fréquences observées et des fréquences théoriques attendues sous l'hypothèse d'indépendance. Un résultat significatif indique que les écarts observés sont peu compatibles avec une distribution aléatoire ; il est toutefois sensible à la taille des effectifs. Pour le propos de ce mémoire, le seuil retenu à partir duquel l'hypothèse nulle n'est pas conforme à nos données est $p = 0,05$.

V de Cramér Mesure de la force d'association entre deux variables catégorielles, dérivée du test du χ^2 . Contrairement à la statistique χ^2 , le V de Cramér est normalisé entre 0 (absence d'association) et 1 (association parfaite), et est peu sensible à la taille de

l'échantillon. Un seuil usuel de $V < 0,10$ indique un effet négligeable, permettant d'interpréter l'absence de conséquence pratique même lorsque le χ^2 est significatif en raison de grands effectifs.

Avant-propos : une @-rudition

Le lecteur attentif à la table des matières, ou ayant parcouru ce mémoire, aura pu noter sa longueur. Plus long qu'un mémoire de première année de Master ne l'est habituellement, les explications autour de cette dimension sont la raison d'être de cet avant-propos, en ce qu'il s'agit aussi de la question des conditions de production du savoir.

Long, car il a entraîné avec lui des coûts temporels, de formation et d'acquisition de compétences qu'il m'était nécessaire de construire, parfois maladroitement, au fil de l'année. Outre dresser l'état de l'art d'un champ historiographique, celui des « barbares » du Haut Moyen Âge, il convenait d'articuler cette démarche bibliographique avec l'approche bibliométrique et lexicométrique, qui, elle aussi, a requis des compétences en programmation que je ne possédais pas en septembre 2025. Ces apprentissages, mêlés les uns aux autres au fil du parcours, expliquent l'inflation de ce travail : il m'a paru nécessaire de restituer la teneur de ces moments, tant pour le lecteur que pour moi même, d'explicitier autant que possible la méthode, les présupposés, les résultats et les précautions, dans une logique de rigueur scientifique et de traçabilité du protocole.

Mon parcours est celui d'une étudiante en humanités numériques, formée avant tout à l'histoire et aux sciences politiques, et au cours duquel il a fallu construire une boîte à outils computationnelle au fur et à mesure de l'avancement du projet : apprendre à comprendre des algorithmes et des méthodes de traitement de données en parallèle d'une érudition sur l'historiographie des « barbares » participent autant de la construction de l'objet.

En effet, un présupposé scientifique est au cœur de ce travail : les outils mobilisés le sont puisqu'ils permettent de dégager du sens sur l'historiographie étudiée comme objet, à la condition qu'il est nécessaire de comprendre ce que l'on construit par cette méthode, ce qu'on mesure, et sur quelles hypothèses tout ceci repose. Et je ne peux prétendre

maîtriser, dans les détails, l'ensemble des algorithmes mobilisés, mais l'exigence de rigueur qui a guidé ce travail m'a imposé d'en saisir les principes et leurs limites. En somme, j'ai, à chaque intuition, souhaité associer un objet observable et vérifiable par l'expérimentation.

Enfin, je tiens à aborder dans cet avant-propos la question du style de citation. Si en histoire, il est d'usage de citer en note de bas de page, j'ai fait le choix de réserver cet espace à des précisions, des renvois ou des développements dont la mention m'a semblée inadaptée dans le corps du texte. Ainsi, les citations sont au format (AUTEUR, date), et je renvoie le lecteur intéressé à la bibliographie.

Ce mémoire ne se limite pas à un objet textuel : je tiens à y joindre un dépôt des programmes discutés, à l'adresse suivante : https://github.com/PirehP1/memoire_e_noraroy.

Chapitre 1

Le « barbare » comme problème historiographique : pour une lecture distante du champ

1.1 Polysémie constitutive et enjeux de définition du « barbare »

L'analyse des similitudes conduite sur un corpus de presse¹ révèle d'emblée toute la polysémie du terme « barbare » dans l'espace médiatique : gravitent autour de lui *empire, romain* et *grec*, mais aussi *ukraine, islamique, hezbollah*, et *conan, film, image* ; et plus largement, dans l'espace social, rendant son appréhension problématique. Le « barbare » renvoie simultanément à des usages médiatiques et médiévalistes, (*Assassin's Creed Valhalla, Conan le Barbare*), à un qualificatif moral pour un comportement jugé *inhumain*²,

1. Le corpus est constitué des cinquante résultats les plus pertinents obtenus par la requête `TEXT=barbare` dans les archives d'Europresse, tous supports et toutes dates confondus en date du 10/05/2026. L'analyse des similitudes a été conduite avec le logiciel IRaMuTeQ, à partir de l'export HTML des résultats.

2. Lévi-Strauss formule à ce sujet un paradoxe : « le barbare, c'est d'abord l'homme qui croit à la barbarie » (LÉVI-STRAUSS 1987). Raymond ARON souligne l'incohérence logique de cette proposition dans « LE PARADOXE DU MÊME ET DE L'AUTRE », remarquant qu'elle conduit l'ethnologue à se poser en « civilisé par excellence », mais son efficacité tient précisément à ce renversement : ce n'est pas le désigné qui révèle la barbarie, c'est l'acte de désignation lui-même. TODOROV prolonge cette intuition en lui donnant une portée normative, puisque seraient barbares non des peuples, mais « ceux qui ne

et à une catégorie savante mobilisée par les historiens pour désigner les peuples du Haut Moyen Âge. Cette ubiquité, qui déborde largement le champ académique, rend le terme difficile à saisir et à définir de manière univoque et invite à se demander comment les historiens, dans leurs publications académiques, ont eux-mêmes investi ce terme.

La difficulté de l'historien à manier le terme renvoie d'abord au fait qu'il s'agit à la fois d'une catégorie mobilisée dans les sources, et une catégorie analytique mobilisée dans l'historiographie, et il convient de préciser son histoire sémantique. En effet, le terme « barbare » a été profondément resémantisé au fil du temps (POL-DROIT 2007)³. Étymologiquement associé à *barbaros*, celui qui produit des sons incompréhensibles, il naît dans le monde grec comme désignation de l'étranger non hellénophone, avant d'être repris par Rome, qui lui superpose l'opposition entre *humanitas* et *feritas* : le « barbare » n'est plus seulement l'étranger linguistique, il est celui qui demeure hors du cadre politico-juridique de la civilisation. Avec la christianisation de l'Empire, la catégorie se charge d'un troisième registre : à partir du VII^e siècle, « barbare » et « païen » tendent à devenir synonymes, si bien que les peuples convertis cessent progressivement d'être ainsi qualifiés, tandis que le terme se déplace vers les marges encore non christianisées. À la Renaissance et chez les Humanistes, il se retourne contre le Moyen Âge lui-même, qualifiant de « barbarie » tout ce qui a détruit ou ignoré la civilisation antique, avant de fusionner, aux Lumières, avec la figure du « sauvage » pour alimenter une philosophie de l'histoire opposant civilisation et arriération (DELON 2007). Montaigne avait pourtant déjà tenté de désamorcer cette logique en retournant la catégorie contre les Européens eux-mêmes : « chacun appelle barbarie ce qui n'est pas de son usage », (*Essais*, 1580), pour déplacer l'usage vers la cruauté et la violence comme comportements, indépendamment de tout groupe (DUMÉZIL 2020).

À la fin du XVIII^e siècle, le terme subit un « coup d'état sémantique » en étant réinvesti au cœur des débats sur la civilisation et la régénération de la société (CHAPPEY, SERNA et NOÛS 2020). La notion de « barbare » sert alors d'outil de stigmatisation politique : entre 1793 et 1794, elle est systématiquement utilisée pour désigner les adversaires de la Révolution, assimilés à des êtres cruels et fanatiques, avant que l'usage ne change de camp

reconnaissent pas la pleine humanité des autres » (TODOROV 2008). La barbarie devient ainsi un concept absolu, non relativiste, désignant une attitude et non un groupe.

3. POL-DROIT (2007) consacre son ouvrage à une généalogie des « barbares ». Le lecteur intéressé par une chronologie précise des multiples définitions du terme pourra s'y référer.

au lendemain de la chute de Robespierre. Cette période voit l'émergence de la figure de « l'homme-tigre », synthèse de la barbarie et de la sauvagerie perçue comme une pathologie politique contagieuse. Parallèlement, le « barbare » retrouve sa racine linguistique : révolutionnaires et contre-révolutionnaires s'accusent mutuellement de « barbariser » la langue française, liant la corruption du langage à la perversion des mœurs et des lois. Cette construction de l'Autre en « barbare » devient ainsi un instrument privilégié pour défendre sa propre domination sociale en criminalisant l'opposant (CHAPPEY, SERNA et NOÛS 2020). Le XIX^e siècle en fait un instrument de hiérarchisation raciale et nationale : les débats sur les « Grandes Invasions » et les origines germaniques des nations européennes chargent le terme d'enjeux politiques liant historiographie et construction des identités nationales (GILLETT 2002). Selon HOBBSBAWN, « ce sont les États et les nationalismes qui font ou inventent les nations » (HOBBSBAWN 1990) : les nations sont des constructions historiques modernes, et non des données naturelles antérieures à l'État ; ANDERSON prolonge ce constat en montrant comment cette construction repose sur une identification collective partagée, la « communauté imaginée », plutôt que sur une expérience directe entre ses membres (ANDERSON 1983). L'argument de Patrick GEARY dans *The Myth of Nations* (P. GEARY 2003) applique cette grille au haut Moyen Âge : les peuples dits « barbares » ont été rétroactivement construits comme ancêtres fondateurs des nations européennes modernes, projetant sur des groupes fluides et hétérogènes la cohérence dont les États-nations avaient besoin pour légitimer leur existence (GILLETT 2002).

La seconde Guerre Mondiale constitue une apogée de la « barbarie », retournée cette fois contre des populations européennes au nom de catégories raciales héritées du XIX^e siècle, et rend désormais impossible de manier le terme sans précaution, au regard des violences que la catégorie avait historiquement permis de légitimer. Comme le note HALSALL, l'historiographie de ce sujet reflète une attitude presque schizophrène de l'Europe vis-à-vis de son passé barbare (HALSALL 2007). Cet aperçu chronologique rend ainsi visible la polysémie héritée du « barbare », appartenant à plusieurs catégories conceptuelles : politique, ethnique, culturel et religieux (MATHISEN 2021).

Ces enjeux sont d'autant plus prépondérants au regard de la charge mémorielle prise par le terme, puisqu'au delà de la question nationale, la mémoire du « barbare » reste active jusqu'à aujourd'hui. Outre les éléments relevant du médiévalisme pouvant nous être contemporains (fêtes médiévales, jeux vidéos, parcs d'attraction et œuvres diverses

étant autant de supports à cet égard), le 1500^e anniversaire du baptême de Clovis en 1996 en constitue un exemple emblématique (controverse baptisée « l'affaire Clovis » dans les médias). D'un côté, le Front National fait de Clovis un symbole : la carte d'adhérent de l'année 1996 est à son effigie, et le « comité Clovis », animé par des membres du parti, y voit « la rencontre de la force franque et de la foi catholique donnant naissance à la France », opposant explicitement la France de Clovis à celle d'une « Europe sans frontières, ouverte comme au IV^e siècle à toutes les invasions » (BOULANGER 2006). De l'autre, les milieux laïques et anticléricaux dénoncent une récupération mémorielle, organisant une manifestation nationale le 22 septembre, date retenue pour la venue du pape à Reims, qui est aussi le jour anniversaire de la proclamation de la Première République (BOULANGER 2006). Derrière la querelle sur la date exacte du baptême ou la personnalité de Clovis se joue une question : « Nos ancêtres les Gaulois ou nos ancêtres les Francs ? », c'est-à-dire quel « barbare » la France choisit-elle d'assumer comme ancêtre fondateur. Le glissement du roi mérovingien au débat sur l'identité nationale, illustre cette perméabilité structurelle du champ de l'histoire aux usages mémoriels et politiques du « barbare » et semble contribuer à en faire un objet d'étude pertinent.

Ces reconfigurations mémorielles ne s'opèrent pas sans les historiens : comme le rappelle LEDOUX, reprenant Jacques REVEL, la discipline historique « mêle inextricablement » une prétention à la connaissance et une « fonction sociale » (LEDOUX 2016), et la frontière entre histoire et mémoire nationale est elle-même une construction. Écrire sur les « barbares », c'est ainsi, à des degrés divers, prendre position dans un débat qui dépasse le seul champ académique.

Les précautions d'emploi, et, entre autres, les guillemets, justifications, remises en cause terminologiques, relèvent en ce sens moins d'une prudence rhétorique qu'une tension épistémologique. JOYE, dans l'introduction de *Les lois barbares. Dire le droit et le pouvoir en Occident après la disparition de l'Empire romain*, en offre un exemple : tout en conservant l'expression pour le titre de l'ouvrage, elle reconnaît explicitement qu'il pose problème et que nombre d'études s'ouvrent précisément par sa remise en cause, la jugeant insatisfaisante, voire trompeuse (JOYE 2025b, pp. 13-21). Elle justifie ce choix par l'absence d'une autre expression efficace et par la longue postérité historiographique du terme, argument que l'on retrouve chez DUMÉZIL, notant que l'historien ne saurait s'affranchir d'une construction dont la prégnance a pesé lourdement sur les mentalités occidentales

(DUMÉZIL 2020). Ce faisant, les deux auteurs soulignent que l'aspect dépréciatif du qualificatif ne peut être écarté, ni lorsqu'il apparaît dans les sources médiévales, ni lorsqu'il est mobilisé par les chercheurs eux-mêmes. Ce maintien, en dépit de sa charge sémantique, montre certes une impuissance lexicale, mais dit aussi quelque chose sur la structure même de l'espace d'écriture historique : comme le souligne DUMÉZIL, la désignation du barbare sert à ériger une norme, celle du groupe qui produit le discours (DUMÉZIL 2020), et elle dit autant du locuteur que de celui qu'elle désigne. Cette observation, transposée à l'historiographie des « barbares », invite à lire les précautions d'emploi comme des indices épistémologiques : la manière dont une communauté savante négocie, visiblement (par le texte), l'héritage d'un terme dont elle ne peut ni se passer ni tout à fait assumer l'usage sans réserve au risque de s'exposer à d'éventuelles critiques.

Ainsi, la polysémie du « barbare » et les enjeux qu'il sous-tend semblent contribuer de sa pertinence heuristique, puisqu'il permet de rendre visible les positions et prises de position des auteurs qui le mobilisent ou l'évitent. Or, l'existence d'un objet ainsi disputé suppose un espace de lutte dont il convient d'analyser la structure : s'interroger sur qui mobilise le « barbare », et depuis quelle position, impose alors de définir le cadre dans lequel s'exercent ces tensions, le champ scientifique de l'historiographie du Haut Moyen Âge.

1.2 Objectiver le champ : bibliométrie, science mapping et distant reading comme instruments d'une appréhension structurale

1.2.1 Un sous-champ en cours de cristallisation : la médiévis-tique du Haut Moyen Âge entre autonomie disciplinaire et perméabilité aux autres champs

Appréhender le « barbare » comme enjeu de prises de positions invite à définir l'espace social et intellectuel où ces dernières s'expriment. Le concept de « champ », tel que théorisé par Pierre BOURDIEU, constitue un cadre épistémologique pour comprendre cette dynamique : espace de concurrence où les agents luttent pour le contrôle des positions

dominantes, il possède des règles du jeu lui étant propres. Cette configuration de relations objectives entre des positions est réglée par les luttes en son sein en fonction de la possession d'un capital spécifique et d'un *habitus*, en tant que système de dispositions incorporées (CHAMPAGNE et CHRISTIN 2012) : en bref, le champ est un « mode d'existence de l'histoire » (CHAMPAGNE et CHRISTIN 2012) où « la définition de l'enjeu de la lutte fait partie des enjeux de la lutte scientifique » (BOURDIEU 1976). Ainsi, le concept de champ repose sur une conception relationnelle : une pratique scientifique, telle que le choix d'employer ou de récuser le terme « barbare », ne prend son sens que relativement à l'ensemble des pratiques du même univers (ROUEFF 2013). Par ailleurs, Bourdieu justifie l'usage de la notion de champ quant à l'appréhension des sciences comme un moyen de comprendre « à quoi on joue » en son sein (BOURDIEU 2001, p. 66). Si Bourdieu souligne l'autonomie *relative* des champs comme propriété générant une frontière entre les « professionnels » et les « profanes » (maîtrise des règles, langage spécifique, capitaux), le champ de l'histoire ne peut totalement être appréhendé sous cet angle (BOURDIEU 1976) : l'histoire balance entre un pôle de recherche scientifique, où les pairs sont les seuls juges, et un pôle commémoratif, plus perméable à la « demande sociale » et aux enjeux de mémoire nationale (BOURDIEU 1995)⁴, qui, dans le cas du « barbare », en est chargée (voir section 1.1).

4. « Elle [l'histoire] balance entre le modernisme d'une science des faits historiques et l'académisme et le conformisme prudents d'une tradition lettrée (visibles notamment dans le rapport aux concepts et à l'écriture), ou, plus précisément, entre une recherche nécessairement critique, puisqu'appliquée à des objets construits contre les représentations ordinaires et totalement ignorés de l'histoire de célébration, et une histoire officielle ou semi-officielle, vouée à la gestion de la mémoire collective à travers sa participation aux commémorations [...] Il s'ensuit que le champ historique tend à s'organiser autour de l'opposition entre deux pôles, différenciés selon leur degré d'autonomie à l'égard de la demande sociale : d'un côté, l'histoire scientifique, qui est affranchie de l'objet strictement national (l'histoire de France au sens traditionnel), au moins par la manière de la construire, et qui est le fait de professionnels produisant pour d'autres professionnels : de l'autre, l'histoire commémorative qui permet à certains des professionnels, souvent les plus consacrés, de s'assurer les prestiges et les profits mondains du livre d'étrennes (grâce notamment aux biographies) et de la littérature de commémoration ou des grandes oeuvres collectives à grand tirage, en jouant de l'ambiguïté pour étendre le marché des travaux de recherche [...]. Je ne puis m'empêcher de craindre que le poids du marché, et du succès mondain, qui se fait sentir de plus en plus, à travers la pression des éditeurs, et de la télévision, instrument de promotion commerciale et aussi de promotion personnelle, ne renforce de plus en plus le pôle de l'histoire commémorative. » (BOURDIEU 1995).

De ce point de vue, le champ de la médiévisique s'est constitué en France sur un socle institutionnel et méthodologique dès la fin du XIX^e siècle. Comme le souligne GRACEFFA (2009), l'ouverture d'une chaire spécifiquement consacrée à l'histoire médiévale à la Sorbonne en 1880 marque le début d'une « haute réputation en matière de formation méthodologique et érudite » ; le même phénomène date de 1882 pour l'Allemagne. Cette autonomie du champ repose aussi sur la maîtrise des sciences auxiliaires (diplomatique, paléographie, numismatique), disciplines largement dominées par les médiévistes et fonctionnant comme des barrières à l'entrée pour les « profanes ». L'apparition de revues spécialisées dès 1888 (*Le Moyen Âge*) consolide la formation de cette communauté scientifique, dotée d'instances de consécration propres où se distribue le capital symbolique (GRACEFFA 2009).

Néanmoins, le champ de la médiévisique n'est pas homogène : en suivant BOURDIEU, sur les dynamiques du champ, notons qu'il se subdivise en sous-champs plus ou moins autonomes. Comme les champs, dont la frontière est relative, les limites des sous-champs sont elles-mêmes des enjeux de lutte permanents (DENORD, SAPIRO, DUVAL, HAUCHECORNE, HEILBRON, POUPEAU, SEILER, LORDON et al. 2020) : pour le champ de l'histoire, les frontières peuvent s'interpréter comme des débats autour de la périodisation, qui, au delà du désaccord technique, sont des luttes de définition. BOURDIEU distingue en effet les champs « cristallisés », où les positions sont faites et les droits d'entrée clairement définis, des champs « décristallisés », où les positions sont encore à construire (DENORD, SAPIRO, DUVAL, HAUCHECORNE, HEILBRON, POUPEAU, SEILER, LORDON et al. 2020)⁵.

Le sous-champ du Haut Moyen Âge semble relever de ce second cas : on observe les prémices d'une cristallisation institutionnelle à travers l'apparition de chaires dédiées à la période, à l'instar de celle de Michel ROUCHE à Paris IV à la fin des années 1990, ou de Régine LE JAN à Paris I en 2002, mais, comme le note GRACEFFA en 2009, ces

5. La distinction entre champ « cristallisé » et « décristallisé » renvoie au degré de stabilisation des relations de force et des frontières disciplinaires. Un champ cristallisé se caractérise par des instances de consécration fortes et des trajectoires de carrière prévisibles, tandis qu'un champ décristallisé (ou en voie de cristallisation) est marqué par une plus grande fluidité des positions et des luttes plus intenses sur la définition même de l'objet de recherche. Dans notre cas, le Haut Moyen Âge illustre cette plasticité : si les institutions sont solides (consolidation), les débats sémantiques sur le « barbare » restent ouverts (décristallisation épistémologique). Voir DENORD, SAPIRO, DUVAL, HAUCHECORNE, HEILBRON, POUPEAU, SEILER, LORDON et al. 2020.

cas relèvent de l'exception plus que de la règle pour le XX^e siècle. S'il peut s'appuyer désormais sur des ancrages institutionnels de plus en plus robuste, notamment depuis le projet *The Transformation of the Roman World (1993-1998)*, le « barbare » relève d'un enjeu de lutte invitant le sous-champ à renégocier ses limites et méthodes.

Dans ce contexte, le « barbare » est un concept de frontière, à la fois chronologique et géographique, et son usage peut s'interpréter plus largement qu'un choix lexical : il constitue alors une prise de position sur ce qu'est le Haut Moyen Âge comme espace disciplinaire, rendue structurellement inévitable par la *doxa*, « ensemble des présupposés que les antagonistes admettent comme allant de soi » (BOURDIEU 1976)⁶.

Cette hypothèse d'autonomisation doit toutefois être confrontée à la trace empirique autorisant à parler de l'historiographie du Haut Moyen Âge comme un espace autonome. Or, si le champ existe et produit des effets, ces effets laissent des traces, et parmi elles, les publications ont une place de choix. En effet, elles semblent être un lieu matériel systématiquement accessible et analysable par des outils historiques et constituent en ce sens un terrain d'enquête des dynamiques du champ. C'est donc par elles, et par les régularités que leur observation permet de dégager, que l'on peut tenter de saisir la structure du sous-champ.

1.2.2 La publication comme prise de position : trace des luttes dans le champ historiographique

Si la lutte pour la définition du champ et du sous-champ traverse une diversité d'espaces (académiques, institutionnels, pédagogiques), la publication scientifique s'appréhende comme un des supports matériels où elle se donne à voir. Il importe toutefois de ne pas confondre la publication avec le champ lui-même, ni même avec la lutte qui s'y déroule. La publication n'est pas le terrain de la compétition mais une des traces matérielles, parmi d'autres (les jurys de thèse, les comités de rédaction, les postes institutionnels, les conférences). Néanmoins, elle semble se distinguer de ces autres formes car outre son caractère écrit, la publication a franchi les instances de reconnaissance du champ. Dans un champ scientifique autonome, comme le rappelle BOURDIEU, « un producteur particulier

6. Ici, en l'occurrence, que le terme *n'est pas* neutre et que l'auteur doit se positionner par rapport à lui.

ne peut attendre la reconnaissance de la valeur de ses produits que des autres producteurs qui, étant aussi ses concurrents, sont les moins enclins à la lui accorder sans discussion ni examen » (BOURDIEU 1976, p. 91). Dans un univers où les producteurs « n'ont généralement pas d'autres clients possibles que leurs concurrents directs » (BOURDIEU 1976, p. 91), la recension, la citation ou la réactualisation bibliographique sont des formes de débat où les pairs détenteurs de capitaux agissent vis-à-vis de la frontière du champ : une publication qui obtient ce crédit malgré la concurrence devient ainsi une prise de position valide, une sorte de définition légitimée.

La recension mérite ici une attention particulière, en ce qu'elle constitue un cas singulier de publication. Comme le soulignent VERBERGT et HAGEN, la recension est peut-être le seul genre savant accessible à des chercheurs de tout rang : un doctorant peut y commenter publiquement le travail d'un professeur consacré (VERBERGT et HAGEN 2025). Loin d'être une formalité, elle est, dans le champ de l'histoire, un espace où se négocient les normes de la bonne science et les frontières de la discipline (« *gatekeeping mechanisms* ») (VERBERGT et HAGEN 2025). En effet, l'acte même de recenser suppose une reconnaissance mutuelle de l'appartenance au champ, puisque commenter publiquement le travail d'un auteur suppose de l'admettre comme un pair, faisant de la critique une lutte pour la reconnaissance (SINGH et HAN 2010). En ce sens, la recension peut s'interpréter comme une prise de position *sur* une prise de position. SINGH et HAN montrent à cet égard que les comptes-rendus de pairs fonctionnent comme des instruments de positionnement dans le champ : ils permettent d'occuper une position, de la contester, ou de la confirmer, selon que le recenseur choisit de valider ou de rejeter la valeur d'un travail (SINGH et HAN 2010), et constitue aussi un espace d'évaluation de la preuve, au sens de la solidité du rapport aux sources.

Si la publication constitue une trace pertinente pour l'appréhension du champ, c'est aussi au regard de ses deux dimensions : une position intellectuelle (choix d'un vocabulaire, usage de « barbare » ou d'un équivalent, rejet ou adoption d'une périodisation) et une position sociale (dans quel réseau on publie, en quelle langue, dans quel support, avec qui) qui lui préexistent et qu'elle contribue à reconfigurer. Ainsi, le corpus des publications sur les « barbares » constitue un support d'objectivation des dynamiques du champ dans ses deux dimensions à la fois, sociale et cognitive, qu'il convient d'approcher par des outils adaptés à ces régularités, et, ici, la bibliométrie.

1.2.3 « Mesurer la science » Larivière et Sugimoto 2018 pour la cartographier : le champ comme cadre d'intelligibilité de la bibliométrie

La bibliométrie se définit comme « l'application de méthodes statistiques ou mathématiques sur des ensembles de références bibliographiques » (ROSTAING 1996), ou plus simplement comme l'étude quantitative de la production savante et des structures de communication scientifique. Son programme est formulé dès les années 1960 par PRICE, qui entend « traiter séparément toutes les analyses scientifiques que l'on peut faire de la science » en lui appliquant ses propres outils : mesurer, généraliser, formuler des hypothèses et en tirer des conclusions (D. J. d. S. PRICE 1963). En ce sens, la science ne différerait pas d'autres phénomènes et activités humaines et pourrait être étudiée avec les mêmes outils et méthodes. Ce modèle suppose que le travail scientifique est représenté par les articles qui le rapportent, et les relations entre travaux par les références qu'ils se font mutuellement. Si ce modèle constitue, comme GARFIELD lui-même l'admet, une simplification du processus scientifique, il en offre néanmoins une image fonctionnelle, à la fois précise et opératoire pour analyser l'organisation de la recherche et ses dynamiques (GARFIELD et MERTON 1979, p. 81) : la publication devient ainsi l'unité d'analyse centrale comme trace d'un travail et noeud dans un réseau de relations entre chercheurs.

La bibliométrie, science de la science, possède deux dimensions : elle vise à la fois à évaluer, mais également cartographier un champ scientifique (LIM et KUMAR 2024), produisant « au système scientifique un excellent moyen de s'observer lui-même » (LARIVIERE et SUGIMOTO 2018).

La première, la *performance analysis*, vise à évaluer les acteurs scientifiques et leur impact à partir de données bibliographiques : comptage de citations, facteur d'impact des revues, indices de productivité des auteurs (PANSU, N. DUBOIS et BEAUVOIS 2014, p. 17). PANSU, N. DUBOIS et BEAUVOIS rappellent que la bibliométrie d'impact ne représente que le « versant évaluatif du traitement statistique des citations des chercheurs les uns par les autres », une facette parmi d'autres d'un ensemble de méthodes plus large. La seconde, le *science mapping*, cherche quant à elle à mettre en lumière les aspects structuraux et dynamiques de la recherche scientifique : non pas évaluer qui produit quoi et avec quel impact, mais représenter comment un champ s'organise, évolue et se structure dans

le temps. Il s'agit d'une scientométrie moins évaluative qui mobilise les mêmes données pour mettre en évidence des « réseaux de chercheurs » ou des « structures thématiques » (PANSU, N. DUBOIS et BEAUVOIS 2014, p. 17-18). GLÄNZEL la décrit comme une *structural scientometrics* dont l'ambition est de « cartographier la structure épistémologique de la science » à partir des techniques de co-citation, de couplage bibliographique et d'analyse lexicale (GLÄNZEL 2003, p. 5).⁷

C'est dans cette seconde inclinaison que s'inscrit la présente recherche : cartographier la structure et l'évolution d'un champ historiographique à travers ses traces documentaires. L'objectif est, comme le formulent LARIVIÈRE et SUGIMOTO, d'exploiter ce « point de vue exceptionnel sur les éléments relationnels et contextuels de la science » que prodigue la bibliométrie, en vue de mieux comprendre les modes de production et de diffusion des connaissances ainsi que leur évolution au fil du temps (LARIVIÈRE et SUGIMOTO 2018).

Toutefois, la bibliométrie appliquée à l'historiographie ne peut être transposée directement depuis ses origines, les sciences naturelles. Dans un chapitre consacré à une bibliométrie pour les humanités, HAMMARFELT montre que les premières études se sont presque exclusivement concentrées sur les défauts de couverture des grandes bases de données,

7. Notre propos ne développe que partiellement les critiques adressées à la bibliométrie d'impact, dans la mesure où celle-ci n'est pas l'objet principal de la présente recherche ; le lecteur intéressé pourra se référer à l'analyse détaillée proposée par PANSU, N. DUBOIS et BEAUVOIS (2014), ou, pour un plus petit ouvrage, GINGRAS 2014. Il n'en demeure pas moins que l'usage de méthodes bibliométriques appelle un effort de réflexivité. Derrière leur apparente objectivité, les indicateurs bibliométriques d'impact ne mesurent pas la qualité scientifique, mais des comptages de citations et des facteurs d'impact dont l'interprétation ne saurait se faire hors contexte : ils mesurent davantage « la participation à un réseau géopolitique de chercheurs » qu'une influence scientifique au sens strict (PANSU, N. DUBOIS et BEAUVOIS 2014, p. 75). Ces indicateurs, construits à partir de bases centrées sur certaines aires géographiques et linguistiques, tendent à refléter des centres de pouvoir académiques et à invisibiliser des recherches périphériques. Ce constat est d'autant plus pertinent pour une historiographie multilingue et largement non-anglophone comme celle des « barbares ». Par ailleurs, PASSAS souligne que les études bibliométriques reposent sur un sous-ensemble de travaux déterminé par les bases et critères retenus, et que « les résultats fournissent une connaissance fragmentée d'un domaine » (PASSAS 2024) ; d'où la nécessité, affirmée tout au long de ce travail, de croiser les résultats quantitatifs avec une interprétation qualitative attentive au contexte historiographique. Enfin, les indicateurs bibliométriques ne se contentent pas de décrire un état de la production scientifique : en redéfinissant ce qui compte comme « visible », ils contribuent à façonner la hiérarchie des objets, des formats et des publics légitimes (LARIVIÈRE et SUGIMOTO 2018, p. 155-156).

avant de tendre vers une interrogation plus fine sur les caractéristiques propres des humanités (HAMMARFELT 2016), pour les appréhender comme des champs avec leurs règles propres par rapport aux sciences naturelles. Plusieurs traits combinés distinguent en effet les humanités des STEM (Science, Technologie, Ingénierie et Mathématique) et rendent fragile toute transposition directe des indicateurs classiques : l'importance structurante des monographies, la diversité et la hiérarchie des publics visés (pairs internationaux, audiences nationales ou régionales, lectorat non académique), l'usage massif des sources primaires, la forte présence des langues autres que l'anglais, et une temporalité longue de la réception (NEDERHOF 2006 ; HAMMARFELT 2016). Cette dernière caractéristique est particulièrement importante, ce que Price qualifiait de « métabolisme humaniste » désigne un processus de « digestion » lente où le chercheur doit assimiler tout ce qui a précédé avant de produire du nouveau (HAMMARFELT 2016, p. 120). TAŞKIN et AKÇA ont ainsi montré, pour l'*American Historical Review*, que la demi-vie agrégée des articles est supérieure à dix ans, ce qui signifie que les publications restent citées sur une décennie au moins (TAŞKIN et AKÇA 2016) : les fenêtres d'évaluation bibliométrique standards de deux à cinq ans sont donc peu adaptées à l'histoire, ce qui justifie une fenêtre d'observation plus importante. GATES et al. (2019) illustre concrètement ces limites : en traitant la citation comme un indicateur d'impact universel, sans distinguer les pratiques disciplinaires il produit une image de « la science » qui est en réalité celle des STEM anglophones⁸.

À ces éléments s'ajoutent la faible couverture, par les outils bibliométriques contemporains comme *Scopus* ou *Web of Science*, des humanités et sciences humaines et sociales, et au delà, même lorsque ces champs sont couverts, la préférence linguistique en faveur de l'anglais. HICKS a ainsi montré la difficulté d'atteindre une couverture complète de la littérature internationale en sciences sociales et humanités dans les grandes bases de données (HICKS 1999). Cette question de la langue est d'autant plus importante que OCHSNER

8. Trois difficultés méritent d'être signalées. D'abord, la citation y est confondue avec l'impact : or citer n'est pas nécessairement reconnaître une influence, et l'inspiration passe en histoire par des voies que le modèle rend structurellement invisibles (NEDERHOF 2006). Ensuite, les catégorisations disciplinaires mobilisées restent implicites : regrouper sous « sciences humaines et sociales » des champs aussi hétérogènes que l'histoire, la sociologie ou la linguistique, là où d'autres domaines se subdivisent finement, produit mécaniquement une dispersion artificielle de leur impact. Enfin, les pratiques de citation ayant elles-mêmes évolué sur la période analysée, appliquer rétrospectivement un indicateur construit sur des normes contemporaines suppose une stabilité qui n'a rien d'évident.

relève que ces différences reflètent des communautés partiellement séparées, où les débats savants, les normes de qualité et les épistémologies varient d’une aire linguistique à l’autre (OCHSNER 2021). MUSTIGMAN a illustré cette limite empiriquement pour l’historiographie du Mouvement national juif : une part considérable de la production en humanités est adressée à un public local, dans sa propre langue, sur des supports nationaux peu indexés par les bases anglophones (MUSTIGMAN 2015) ; son travail justifie alors la création d’une base *ad hoc* pour ses analyses. Ces règles du jeu propres aux humanités sont en ce sens des propriétés du champ, d’un espace social spécifique dont la bibliométrie doit tenir compte pour en restituer la topologie.

Pour développer une bibliométrie appliquée et applicable à l’histoire, HÉRUBEL propose la *historical bibliometrics*, entendue comme l’application des méthodes quantitatives à l’étude de l’évolution intellectuelle d’une discipline dans un cadre spatio-temporel précis, en traitant les données bibliographiques comme des sources primaires à part entière (HÉRUBEL 1999) : les listes de références, les revues et les monographies deviennent des sources permettant d’identifier des communautés intellectuelles, des régimes de publication et des trajectoires disciplinaires. Peu employée en histoire, COLAVIZZA souligne que cette perspective reste largement sous-développée, alors même qu’elle permettrait de suivre le développement de disciplines spécifiques au fil du temps et répond à des questions proprement historiennes (COLAVIZZA 2018). Cette démarche suppose par ailleurs d’adopter une perspective externaliste : les résultats bibliométriques ne sont pas auto-suffisants en ce que les inflexions de croissance d’un champ doivent être corrélées aux forces institutionnelles, politiques ou historiographiques qui l’ont traversé (HÉRUBEL 2006). Cette perspective rejoint alors le cadre de BOURDIEU : les conjonctures de COLAVIZZA sont ces moments où les conditions sociales de production des prises de position se reconfigurent et peuvent laisser des traces mesurables dans la distribution des publications. Ainsi, parmi les travaux mobilisant la *historical bibliometrics*, les résultats peuvent être lu comme des effets de dynamiques des champs dont l’interprétation requiert un retour au contexte historiographique : MUSTIGMAN a systématisé cette exigence en liant les pics de production à des facteurs externes concrets, comme l’ouverture d’archives nationales ou la création de nouveaux départements de recherche (MUSTIGMAN 2015) ; COLAVIZZA propose à cet égard un cadre d’analyse fondé sur l’interaction entre expansion (augmentation du nombre de publications et de chercheurs), traditions (inertie des revues et des

pratiques éditoriales) et conjonctures (chocs méthodologiques comme la micro-histoire, le *cultural turn* ou l'internationalisation) (COLAVIZZA 2018).

C'est dans ce cadre de champ que la bibliométrie peut être rendue intelligible, et cette articulation n'est pas nouvelle. Comme le propose SCHIRONE dans sa recension systématique de la littérature bibliométrique mobilisant BOURDIEU, elle constitue un programme de recherche établi, dont les fondements remontent aux travaux de GINGRAS sur la physique canadienne (SCHIRONE 2023), qui a posé le principe que la topologie sociale du champ se traduit en une topologie des documents, et que les relations entre publications, revues et auteurs peuvent être lues comme des indices de structure sociale. LARIVIÈRE, dont SCHIRONE recense plus de vingt contributions dans ce cadre, a prolongé ce programme en montrant comment les indicateurs bibliométriques (citations, coauthorships, langues de publication) peuvent être lus non comme des mesures d'impact mais comme des indicateurs du capital scientifique au sens bourdieusien (SCHIRONE 2023). Cette approche, l'étude de « l'organisation sociale et intellectuelle des champs de recherche émergents depuis un point de vue bourdieusien » (SCHIRONE 2023), est celle dans laquelle s'inscrit la présente recherche (lire dans les traces documentaires des indices de position dans la lutte pour la définition du champ). L'homologie dressée par SCHIRONE entre espace documentaire et espace social permet de considérer la bibliométrie comme un instantané différé du champ : arrivant *postquem*, après la production des publications, leur catalogage et leur indexation, elle lit dans les traces une structure passée, qui était en vigueur au moment de la publication.

Néanmoins, observer ces traces à l'échelle du corpus suppose de les ériger en objets analysables, et c'est en ce sens que se pose la question épistémologique du *Distant Reading* comme méthode d'objectivation du champ pour appréhender autre chose (MILLIGAN 2012). En effet, les propriétés que l'on souhaite observer n'existent qu'en tant que propriété collectives, et ce n'est donc pas la quantité du corpus qui impose le recours au distant reading mais la *nature* de l'objet : la structure, le système et ses propriétés.

1.2.4 Changement de regard et construction de l'objet, le distant reading comme épistémologie du faire

La distance est une condition de connaissance : les détails semblent moins visibles au profit des relations et des structures (MORETTI 2013). Ce regard distant est indissociable d'un acte de construction technique, par le modèle⁹, les « *Graph, Map, Trees* » (MORETTI 2007), qu'il convient d'explicitier. En ce sens, l'analyse permise par la visibilité du champ au cours d'un acte, la fabrication d'un objet intermédiaire, n'est pas sans conséquences épistémologique puisqu'il peut s'agir d'un point d'émergence de la connaissance sur notre objet. Cette approche rend aussi possible le test d'hypothèses de manière presque expérimentale, au cœur d'un laboratoire, sur cet objet et ses dynamiques, et la distance devient une condition de visibilité de ces phénomènes qu'on ne pourrait saisir autrement. Toutefois, elle suppose un « little pact with the devil », le renoncement, temporaire du moins, à la richesse du texte singulier au profit du concept et du modèle, rendant le système manipulable (MORETTI 2013).

Ce geste de construction n'est pas neutre : « le produit objectivé du travail de codification devient, sous le regard réflexif, la trace immédiatement lisible de l'opération de construction de l'objet » (BOURDIEU 1984, p. 18-19) ; « il n'y a pas d'objet qui n'engage un point de vue » (BOURDIEU 1984, p. 17). Transposé à notre démarche, cela signifie que les choix opérés dans la construction de nos objets (modèle de base de donnée, mots retenus, variables observées, catégories créées) forment une grille mise en œuvre pour produire l'objet d'analyse. Chaque décision de codification est déjà une prise de position sur ce qu'est le champ historiographique des « barbares ». De plus, prendre pour objet un monde social dans lequel on est pris « oblige à rencontrer, sous une forme dramatisée, la difficulté de la rupture avec l'expérience indigène » (BOURDIEU 1984, p. 11). La présente recherche n'échappe pas à cette condition : conduite depuis une université française, dans le cadre d'une formation en histoire, elle est elle-même prise en partie dans le champ qu'elle tente d'observer. Les choix qui l'orientent (l'entrée par le mot « barbare » plutôt que par une période ou un auteur, le recours à Worldcat, la fenêtre 1975-2025) sont aussi,

9. La définition du modèle tentée par DROUIN : « Le modèle est "quelque chose" (objet concret, représentation imagée, système d'équations...) qui se substitue au réel trop complexe, ou inaccessible à l'expérience, et qui permet de comprendre ce réel par un intermédiaire plus connu ou plus accessible à la connaissance. » (DROUIN-HANS 1988).

en un sens, des effets de position. Par conséquent, la transparence sur ce protocole est une exigence scientifique de réflexivité sur nos propres pratiques, et la présentation de notre position par rapport à ce champ en fait partie (BOURDIEU 2001, p. 15)¹⁰.

Ce changement de regard est également à lier avec l'évolution des conditions matérielles de la recherche, marquée par la démocratisation de l'outil informatique et le *digital turn* des années 2000¹¹ : l'ordinateur personnel peut s'envisager comme un outil pour accéder au terrain d'expérience et y tester des hypothèses ; l'omniprésence du web et l'accès en ligne aux notices bibliographiques change notre rapport à la publication scientifique et à la masse scientifique accessible. Ainsi, l'outillage informatique contemporain (logiciels de bases de données, réseaux de neurones, modèles de langue, internet) rendent plus accessible la construction du champ par des modèles, produisant une image intelligible de la structure de l'historiographie que l'on interroge et manipule à des fins de connaissance. La formalisation des protocoles de collecte et d'analyse des données permet d'ancrer ces actes dans des pratiques de construction du savoir, puisque le graphe, la carte, le réseau de coautorat sont des *modèles* du champ, et c'est parce que « les formes sont l'abstrait des relations sociales » (MORETTI 2013) que leur analyse formelle est, en ce sens, une analyse de ces rapports de force que le concept de champ peut nous permettre d'appréhender.

L'usage de la bibliométrie ne saurait donc être réduit à une stratégie de compensation face à l'inflation documentaire, ou encore un tropisme contemporain au regard de l'informatique ; il relève plutôt d'un choix méthodologique et épistémologique de regard sur cet objet, qui souhaite tenter de dégager un espace de position et de prise de position par un geste interrogeant le système des relations entre les publications. Le modèle permet en ce sens d'accéder à d'autres propriétés collectives. L'enjeu n'est donc pas de raconter l'histoire des barbares, ni l'histoire de leur histoire. Il s'agit de décrire comment, entre 1975 et 2025, une communauté savante internationale a produit, en choisissant ses langues et ses thèmes, un savoir sur les barbares du Haut Moyen Âge et comment cet objet historiogra-

10. Suivre Bourdieu jusqu'au bout supposerait d'« ouvrir successivement toutes les boîtes à l'intérieur desquelles le chercheur se trouve enfermé » (BOURDIEU 1984, p. 48) : c'est une ambition que ce travail ne peut qu'esquisser, mais dont il entend au moins poser le principe.

11. La question de ce que cette transformation fait au métier d'historien a fait, entre autres, l'objet d'une réflexion collective dès 2011 : « Le métier d'historien à l'ère numérique : nouveaux outils, nouvelle épistémologie ? », *Revue d'histoire moderne et contemporaine*, 2011/5, n° 58-4bis, Belin (BELIN 2011).

phique a été resémantisé et reconstruit au fil de ses emplois. Ce matériau, ses conditions de production et sa nature, constituent désormais l'objet à construire.

1.3 Délimitation du corpus : le « barbare » comme entrée lexicale et les bornes du corpus

Le cadre conceptuel que nous venons de dresser (le « barbare » comme terme dont l'usage constitue une prise de position dans un champ en cours de reconfiguration, la publication comme trace de ses dynamiques, la bibliométrie historique et le *distant reading* comme modes d'objectivation) suppose maintenant d'être ancré dans un corpus de sources délimité. Si le champ constitue un outillage interprétatif, il s'observe par son objet empirique, le corpus. Il convient ainsi de définir ce qu'on observe, dans quelles bornes temporelles et à partir de quelle source, et, encore une fois, ces choix sont déjà, en un sens, des prises de position sur ce qu'est le champ historiographique des « barbares ».

Le corpus de sources de la présente étude est constitué par les publications évoquant le « barbare » (tant le lemme que le champ lexical associé (Francs, Lombards,...), comme nous le verrons dans le chapitre 4) dans le contexte du Haut Moyen Âge et de l'Antiquité tardive, récupérées par un jeu de mots-clés croisant les équivalents multilingues du terme avec des périodisations médiévales ou tardo-antiques. Ce choix d'une entrée par le mot plutôt que par une période ou une problématique est lui-même à justifier : le terme est suffisamment large et polysémique, comme nous l'avons vu, pour embrasser une diversité de traditions nationales et d'approches méthodologiques. Comprendre ce que recouvre la catégorie de « barbare » implique de replacer son étude dans le cadre des transformations du champ historiographique qui en organise l'élaboration.

Le cadre chronologique de la présente étude s'étend de 1975 à 2025. Ces choix ne désignent pas la naissance du champ médiéviste, constitué depuis la fin du XIX^e siècle : ils correspondent à un moment de reconfiguration de ses enjeux internes, qui fait du « barbare » un concept disputé plutôt qu'une catégorie stabilisée.

La borne basse résulte de la convergence de plusieurs dynamiques, dont la conjonction rend ce moment propice à l'analyse d'un champ médiévistique constitué.

La première est institutionnelle. Les années 1965-1975 correspondent, à l'échelle internationale, à une massification de l'enseignement supérieur et de la recherche. En France, l'héritage de Mai 1968 se traduit par la loi Faure (1968) et l'éclatement de l'Université de Paris en treize universités autonomes, créant autant de nouveaux pôles de recherche et de postes d'enseignants-chercheurs. Aux États-Unis, la dynamique est antérieure : le *Higher Education Act* de 1965, s'inscrivant dans la continuité du GI Bill (1944), élargit l'accès à l'enseignement supérieur par un système de bourses et de prêts fédéraux. Les dépenses pour la recherche et l'enseignement supérieur sont largement revues à la hausse (R. L. GEIGER 2017, p. 198). Cette augmentation quantitative et qualitative se couple du mouvement « College for All » des années 1970 : il en résulte une saturation dans les taux de recrutement au sein des universités dans les années 1960, atteignant son apogée en 1975 (ALTBACH et R. GEIGER 2024). Au sens de BOURDIEU, on ne peut parler de *champ* médiéviste autonome qu'à partir du moment où il existe suffisamment d'agents en aux positions et prises de positions différenciées, et la constitution d'enjeux propres : ces éléments semblent atteints, à l'échelle des nationalités considérées pour notre étude¹²), dans la seconde moitié des années 1970 (BOURDIEU 1995).

De même, le champ académique a connu des transformations globales notamment depuis les années 1980 : « les enjeux économiques y sont devenus omniprésents, quelles que soient les disciplines, et s'accompagnent de transformations morphologiques d'ampleur [...] La population estudiantine continue d'augmenter, mais plus dans certains secteurs de l'espace que dans d'autres : les disciplines « temporelles » semblent bénéficier aujourd'hui de leur lien plus étroit avec le marché du travail, alors que les humanités et les sciences « pures » voient leur attractivité décliner. » (DENORD, SAPIRO, DUVAL, HAUCHECORNE, HEILBRON, POUPEAU, SEILER, LORDON et al. 2020).

La deuxième dynamique est historiographique. GRACEFFA décrit les quatre grandes étapes de l'historiographie altimédiévale, et identifie que « la structuration progressive de la médiévistique à l'Université et la formation d'une communauté de spécialistes reconnus comme tels » constitue une condition première de son développement (GRACEFFA 2009) : une structuration achevée, pour l'essentiel, à la fin du XIX^e siècle, mais dont les effets en termes de volume de production ne se font réellement sentir qu'un siècle plus tard, à mesure que croît le nombre de chercheurs. C'est dans les années 1970-1980 que la

12. Au delà de la France et de l'Allemagne que décrivait GRACEFFA

Troisième Génération des *Annales* (DUBY, LE GOFF, VOVILLE) propose un déplacement du regard vers l'anthropologie historique, l'histoire des mentalités et des représentations (DOSSE 1987, LE GOFF 1988). Ce tournant est particulièrement précoce en médiévistique : comme le note SIRINELLI, « ce sont surtout l'histoire médiévale et l'histoire moderne qui ont d'abord été les sites privilégiés de ce type d'histoire » (SIRINELLI 2005). DOSSE évoque alors une « ethnologisation du discours historique » (DOSSE 1987, p. 165), et SCHMITT et IOGNA-PRAT relèvent que « la plupart des médiévistes français accepteraient aujourd'hui de se placer sous [la] bannière » dressée par le chapitre « Anthropologie et histoire » (Jacques BERLIOZ et Jacques LE GOFF) dans *La Nouvelle histoire*. Dans le même temps, la période dite « romano-barbare » bénéficie d'une nouvelle exploitation des sources pour renouveler la connaissance sur le sujet. L'archéologie préventive, généralisée en France à partir de la fin des années 1970, vient simultanément multiplier les sources disponibles sur le Haut Moyen Âge et enrichir les approches : importance des travaux en histoire de l'art et archéologie dont rendent compte les revues *Cahiers archéologiques* depuis 1946, *Archéologie médiévale* depuis 1970, les colloques d'archéologie chrétienne ou mérovingienne (RICHE et al. 1989 ; GRACEFFA 2009). RICHÉ et al. note également le renouveau des sources épigraphiques, avec la sortie du recueil des inscriptions chrétiennes de la gaule antérieure à la renaissance de MARROU, numismatiques, autour des travaux de LAFaurie, juridiques (FLEURIOT), diplomatiques (VEZIN) et hagiographiques.

La troisième dynamique, moins visible parce qu'elle opère sur le temps long, est sémantique. La Seconde Guerre mondiale constitue une rupture irréversible dans l'usage des catégories raciales et nationales héritées du XIX^e siècle : après l'apogée de la « barbarie » nazie, le vocabulaire des peuples et des ethnies doit être refondé. Cependant, GRACEFFA nuance cette évidence : « les années qui suivent 1945 restent marquées par l'optique antérieure. La véritable rupture s'amorce avec la construction effective d'une dynamique européenne, à partir de la fin des années 1950 : moins historique que culturel, ce nouvel idéal rompt définitivement avec le modèle d'une Europe germanique, barbare ou franque, que l'idéologie national-socialiste a perverti » (GRACEFFA 2009). S'observe ainsi le rejet de la logique raciale et la substitution progressive de termes connotés comme « race » ou « Germains » par celui de « barbares » qui caractérisent les décennies d'après-guerre (GRACEFFA 2009). Ce déplacement est également conceptuel : c'est à partir de la fin des années 1950 que « le succès de la dynamique européenne enlève à la ques-

tion du peuplement sa pertinence politique » et que les problématiques se déplacent vers les modalités d'intégration des cultures, la réalité de l'ethnogenèse et l'importance des cadres institutionnels (GRACEFFA 2009). Cette refondation ne s'accomplit toutefois pas immédiatement : elle implique le délai d'une génération, celle qui, formée dans les années 1960 sous l'influence du structuralisme (LÉVI-STRAUSS, DUMÉZIL) et de l'histoire sociale, publie à partir du milieu des années 1970.

Enfin, il convient de signaler que la borne de 1975 est aussi *empirique*, lisible dans nos données (voir figure 4.1, page 130). Les notices WorldCat relatives au « babare » du Haut Moyen Âge sont quasi absentes avant 1960, et la croissance des publications indexées ne devient véritablement nette qu'aux alentours de 1970, ce qui coïncide avec l'accélération institutionnelle et le renouveau historiographique décrits ci-dessus. Ce démarrage visible dans notre corpus apporte une suggestion par les données de ce que les historiens de l'historiographie décrivent par leurs propres méthodes, et semble légitimer d'autant plus de situer notre seuil d'observation dans cette période. Ainsi, les années 1970 semblent, sur Worldcat aussi, enregistrer quelque chose qui a à voir avec la constitution du champ prise par l'indicateur de la croissance du volume de sa production.

Quant à la borne haute de 2025, elle ne constitue pas une rupture historiographique : elle correspond à la date du *scraping* des données sur WorldCat. Elle est une image parmi d'autres du champ à un instant donné, en intégrant la latence inhérente aux acquisitions bibliothécaires et à la mise à jour des notices sur la base de données considérée. En ce sens, il serait inexact d'y lire une chute de la production : c'est une limite technique et éditoriale, propre à notre source, état figé d'une réalité en évolution. Notre fenêtre d'observation est donc 1975-2025, avec la conscience que sa borne supérieure est une limite d'accès à la source autant qu'un horizon d'analyse.

1.4 Annonce du plan

La présente introduction a établi le cadre dans lequel cette recherche s'inscrit : le « barbare » comme terme dont la définition est elle-même un enjeu de la lutte au sein du sous-champ historiographique du Haut Moyen Âge, la publication comme trace de ces luttes, et la *historical bibliometrics* outillée du *distant reading* comme mode d'objectivation de ce champ. Il s'agit à la fois de questionner le vocabulaire et le champ historiographique

du Haut Moyen Âge, l'investissement d'un terme par les historiens, mais aussi, sur le plan méthodologique, la condition de possibilité d'une historiographie outillée par ordinateur.

Notre propos s'articule en trois axes principaux.

Le chapitre 2 revient sur les conditions épistémologiques de cette observation en interrogeant la source principale de ce travail : Worldcat, en tant que base de données construite, avec ses propres logiques d'indexation, ses biais linguistiques et géographiques qu'il convient d'explicitier pour mieux comprendre ce dont quoi elle est l'archive. En ce sens, il permet d'établir ce que la bibliométrie peut, ou ne peut pas, dire sur notre objet avec les matériaux regroupés.

Si Worldcat constitue le point d'entrée dans cet univers, il fournit des traces brutes qu'il est nécessaire de transformer en données analysables par le biais d'un protocole, ce que décrit le chapitre 3. Loin d'être des dispositifs techniques, ces choix de modélisation et de transformation de nos données contribuent à la construction de notre objet, et doivent donc être explicités.

Enfin, le chapitre 4 constitue l'analyse du champ. Il procède d'abord par les métadonnées (structure sociale du champ : langue, genre, réseau de coautorat), avant d'opérer un retour au texte par la lexicométrie. Cela permet d'analyser la structure sociale du champ et les positions qui y publient, et de donner à voir comment le « barbare » est défini et entouré, révélant ainsi les prises de position des auteurs sur ce qu'est le Haut Moyen Âge comme espace.

Chapitre 2

Construire l'archive : Worldcat, le format RIS et les conditions épistémologiques d'une bibliométrie de l'historiographie.

« Été comme hiver, elle est glacée ; les doigts s'engourdissent à la déchiffrer tandis qu'ils s'encrent de poussière froide au contact de son papier parchemin ou chiffon. Elle est peu lisible à des yeux mal exercés même si elle est parfois habillée d'une écriture minutieuse et régulière. »

Arlette FARGE, *Le goût de l'Archive*, 1989.

L'entrée en archives, telle que décrite par FARGE, constitue un rapport presque charnel au document, au fondement de la pratique historique. Cependant, le matériau sur lequel repose la présente recherche est d'une autre nature : des notices bibliographiques extraites d'une base de données commerciale, sans poussière si ce n'est celle sur notre écran d'ordinateur ou sur le clavier nous permettant de requêter le site, sans archiviste ou aide pour guider dans les fonds, dans un format standardisé conçu pour la citation et non, de prime abord, pour l'enquête.

Dans ce chapitre, je reviens sur ce qu'est Worldcat, son rapport à l'historien et à l'enquête. Je tente de montrer que ce matériau, produit pour la citation et non pour l'analyse, peut devenir une source pour l'historien, à condition d'en interroger les médiations, condi-

tions de production, et enjeux.

2.1 Worldcat, une base de données face à l'historien : histoire, tensions juridiques et statut épistémologique d'une source numérique.

2.1.1 « Worldcat », une coopérative mondiale : histoire, structure et choix

Worldcat est « la plus vaste base de données bibliographiques au monde »¹. Créé en 1971 par l'Online Computer Library Center (OCLC), il s'agit d'une base de données d'union regroupant les catalogues de bibliothèques volontaires à travers le monde « en utilisant une seule boîte de recherche »²).

En 2001, Worldcat comptait déjà 45 millions de notices, couvrant plus de 4000 ans de connaissances enregistrées en 377 langues (PERRAULT 2003, p. 63). La catalogue s'est aussi internationalisé, puisque les données suggèrent que les bibliothèques nationales et les grands établissements de recherche internationaux, qui ont commencé à verser leurs notices dans les années 1990, seraient en grande partie à l'origine de l'augmentation des notices en langues étrangères sur cette période (PERRAULT 2003, p. 68). À cette date, 65% des notices monographiques étaient en anglais et 35% en langues étrangères, les six principaux groupes linguistiques non anglophones (chinois, français, allemand, japonais, russe et espagnol) représentant à eux seuls 67.5% de l'ensemble des notices en langues étrangères (PERRAULT 2003, p. 65).

Le catalogue regroupe aujourd'hui (données d'Octobre/Novembre 2025³) plus de 600 millions de notices bibliographiques, dans 488 langues différentes (et 61% des langues représentées dans les notices sont autres que l'anglais).

Ainsi, cette base de données bibliographiques diffère de Scopus ou Web of Science (WoS), bases plus orientées sur les publications scientifiques, et qui sont, cette fois-ci,

1. Selon la page Wikipédia de Worldcat, consultée le 20/05/2026, disponible à l'adresse <https://fr.wikipedia.org/wiki/WorldCat>.

2. Citation issue de la page « à propos » de Worldcat, , consultée le 20/05/2026, disponible à l'adresse <https://search.worldcat.org/fr/about>.

3. Disponibles à l'adresse suivante : <https://www.oclc.org/en/worldcat/inside-worldcat.html>.

inaccessibles gratuitement à l'utilisateur. En outre, à rebours de Scopus ou WoS, voire même de Google Scholar, Worldcat ne dispose pas d'indicateurs bibliométriques intégrés permettant de mesurer, dans le cadre de la bibliométrie évaluative, le nombre de citations par exemple. Ces outils indexent également peu les monographies, les chapitres d'ouvrages ou les revues non anglophones, qui sont pourtant des formes de publication que l'on ne peut ignorer dans le cadre de l'historiographie (MONGEON et PAUL-HUS 2015, HAMMARFELT 2016) — étant majoritaires en Sciences Humaines et Sociales et en Humanités. Par conséquent, passer par ces bases de données établies est non seulement payant, mais aussi peu adapté pour notre objectif, de cartographier le champ du Haut Moyen Âge (HAMMARFELT 2016, p. 121).

De plus, les objectifs affichés de Worldcat semblent en faire une véritable bibliothèque d'Alexandrie : le catalogue coopératif, la normalisation des métadonnées, le Prêt Entre Bibliothèques (PEB) et le partage des ressources ; bref, mettre en réseau tout le savoir du monde au plan multimédia (du livre audio, ou braille à la musique et aux partitions) face à la multiplicité d'initiatives privées⁴. Néanmoins, derrière cette apparente universalité, Worldcat présente des biais notables d'indexation structurels : seules les bibliothèques volontaires mutualisent leurs notices, et les données sur leur site permettent de suggérer un biais occidental notable, avec 39% des notices étant en anglais (le chinois ne représentant que 3% de leur catalogue) : par exemple, nous pouvons nous questionner quant à la place des notices russes datant d'avant la dissolution de l'URSS dans Worldcat.

2.1.2 Une organisation à but non-lucratif aux logiques commerciales : ambiguïtés du modèle économique et rapport de force sur les données.

La page Wikipédia de Worldcat présente, à qui la consulte en anglais et en français⁵, un premier indice de l'ambiguïté du statut de la donnée sur le site. L'encart de présentation rapide de l'organisation, sur la droite de la page Wikipédia diffère selon la version linguistique retenue : là où la page anglophone indique « no » à la rubrique « commercial », la page francophone répond « oui ». Cette différence peut apparaître anecdotique, mais

4. Objectifs affichés à la page disponible à l'adresse suivante : <https://www.oclc.org/en/worldcat/inside-worldcat.html> (consulté le 20/05/2026).

5. Consulté le 20/05/2026, ainsi que le 08/04/2026.

suggère le flou structurel autour des droits des utilisateurs de Worldcat.

Si l'accès est libre et gratuit pour la consultation individuelle et manuelle, les exports massifs de donnée, voire même le fait de faire plus de 10 requêtes (avec des url différentes) d'affilé sur le site `Worldcat.org` déclenche immédiatement un avertissement rendant impossible toute recherche ultérieure à moins de patienter plus longuement : « Trop de demandes. Veuillez réessayer plus tard ou connectez-vous pour une profiter d'une limite plus élevée. » (message d'avertissement s'affichant sur la page après la 10^{ème} recherche).

Cet avertissement introduit de fait une discrimination quant à l'accès : la consultation approfondie du catalogue est conditionnée à la création d'un compte utilisateur, impliquant de renseigner une adresse électronique valide, d'accepter les conditions d'utilisation et la politique de confidentialité d'OCLC⁶, et d'être âgé d'au moins seize ans. Bien que la création d'un compte soit gratuite, elle implique en retour la collecte de données personnelles susceptibles d'être utilisées à des fins commerciales⁷.

Toutefois, la création d'un compte est une étape requise, mais non suffisante pour consulter les données de manière systématique. En effet, il est possible d'obtenir une clé API, mais celle-ci est sur la base d'un abonnement, qui, semble-t-il, ne soit pas accessible à tous et requiert une authentification institutionnelle⁸ (les bibliothèques membres peuvent en faire la demande, en raison de leur appartenance au catalogue d'union).

Mais alors, de quels droits disposons nous sur les notices qui nous sont accessibles, en tant qu'utilisateur anonyme? Cet élément, laissé largement implicite en dehors de la lecture approfondie des conditions d'utilisations d'OCLC, a été détaillé au cours du

6. Disponibles respectivement aux adresses suivantes : <https://www.oclc.org/content/dam/ext-ref/worldcat-org/terms.html> et <https://policies.oclc.org/fr/privacy/privacy-statement.html>.

7. « Faire du marketing. », sous le titre « De quelle manière utilisons-nous les informations? », suivi de « Dans certains cas, OCLC peut associer les données personnelles que vous nous avez fournies avec les informations que nous collectons par le biais de nos sites Web, et les informations recueillies à partir d'autres sources telles que des sites de réseaux sociaux tiers. Nous traitons ces données pour mettre à jour, développer et analyser nos notices marketing existantes, identifier de nouveaux clients, personnaliser les publicités ou vos expériences sur les sites Web, et envoyer des courriels marketing. », disponible à l'adresse <https://policies.oclc.org/fr/privacy/privacy-statement.html>.

8. Voir à l'adresse : https://help.oclc.org/Librarian_Toolbox/OCLC_APIs/Troubleshooting/How_do_I_request_an_API_WSKey.

procès contre Anna’s Archive (pour une présentation de la plateforme, voir section 2.3.2). De fait, la plateforme avait scrapé des Téraoctets (To)⁹ de données de Worldcat pour les proposer sur sa plateforme, gratuitement, avec pour défense qu’il s’agissait d’un objectif de sauvegarde du savoir ; néanmoins, cela était à l’encontre des politiques de Worldcat¹⁰. OCLC rappelle que lorsqu’un individu cherche sur le site de Worldcat, il donne son accord sur les conditions d’utilisation, comprenant par ailleurs l’interdiction de la reproduction, conservation, distribution des données, ni leur collecte dans des quantités importantes¹¹ à l’aide d’un processus automatisé¹². Le flou sur la question de la quantité de donnée ne permet pas de trancher de la légalité ou de l’illégalité de ma recherche, mais la justice américaine a donné raison à OCLC dans son procès avec le site pirate, donnant lieu à une jurisprudence notable¹³.

« WorldCat also sits at the center of OCLC’s family of products and services. Id. ¶ 63. OCLC’s cataloging, resource sharing, discovery sharing, OCLC publisher, and OCLC data services all benefit from WorldCat records. Id. ¶ 64. By providing WorldCat records for free, Anna’s Archive has undermined the strength of WorldCat in the market and decreased its value to OCLC’s other products and services »¹⁴

Ce flou juridique se retrouve aussi dans les critiques adressées à OCLC directement : « In summary, when OCLC makes money on the deal, it’s called “resource sharing ;” when OCLC doesn’t make money on the deal, it’s called “record nabbing.” » (BEALL 2008). En ce sens, BEALL souligne la revendication par OCLC d’un contrôle sur des notices qui

9. Si Anna’s Archive a récupéré 2.2Tb du catalogue de Worldcat et l’a publié, 35 000 notices ont été récupérées (taille de notre base de données : 36Mo en comptant les enrichissements faits, soit 0.001% de ce qu’Anna’s archive a récupéré. En termes de nombre de notices, cela représente 0.005% des notices du catalogue

10. Selon une source médiatique disponible à l’adresse suivante : <https://torrentfreak.com/annas-archive-worldcat-scrape-lawsuit-drops-5m-claim-pivots-to-takedown-tactic/>.

11. À ce sujet : « material amounts of data » (voir I, B, 58 et 59, accessible à cette adresse <https://torrentfreak.com/annas-archive-worldcat-scrape-lawsuit-drops-5m-claim-pivots-to-takedown-tactic/>).

12. Idem, voir à l’adresse : <https://policies.oclc.org/en/terms/worldcat.org.html>.

13. Notamment relevée par plusieurs médias, dont Ars Technica, site d’actualité sur la technologie numérique : <https://arstechnica.com/tech-policy/2026/01/judge-orders-annas-archive-to-delete-scraped-data-no-one-thinks-it-will-comply/>.

14. Je renvoie le lecteur aux documents déposés sur le Github dans le **Chapitre_1**.

seraient à priori publiques (comme les données bibliographiques de la librairie du Congrès), par ajout d’une propriété de OCLC, le numéro *a minima*. BEALL va même plus loin, en peignant OCLC comme une organisation monopolistique et opaque, et critique notamment le modèle économique d’OCLC, qui, selon lui, est au détriment des bibliothécaires, en ce qu’il achète des données bibliographiques à bas coûts pour les revendre à prix élevés (monétisation des données des bibliothécaires, acquisition d’autres filiales de la chaîne bibliographique).

Ainsi, Worldcat, loin d’être un terrain neutre permettant l’accès à une donnée ouverte, suggère au contraire un rapport de force économique et juridique avec l’utilisateur conditionnant le possible sur la plateforme. De ce fait, si une récupération de données de grande envergure sur Worldcat s’envisage, comme nous le verrons section 3.2, cela a un coût et n’est pas sans conséquence sur notre protocole :

- le temps, comme notre protocole a pu le constater ;
- la loi, comme éprouvé par Anna’s Archive et la perte de son procès ;
- une identification et éventuellement un paiement, pour récupérer une clé d’API et un identifiant.

L’illusion d’un accès neutre, presque universel et exhaustif à la production savante, n’est pas sans rappeler les travaux de MORSEL 2004 et « l’effet de réel » des ensembles documentaires : l’historien, croyant voir dans Worldcat un reflet de la production médiévisque mondiale sur le plan des métadonnées, se trouve *de fait* devant le résultat des pratiques bibliographiques de cette institution et de ses bibliothèques membres.

Les contraintes dégagées ici suggèrent que Worldcat n’a pas été fait pour être interrogé comme une archive : si Worldcat n’est pas un terrain neutre d’accès à la production savante, de quoi est-il réellement la trace ?

2.1.3 De quoi Worldcat est-il l’archive (Rygiel 2011) ? Statut épistémologique d’une base de données bibliographiques.

De prime abord, il est possible de penser que Worldcat est une archive numérique car ce catalogue conserve, recense et donne accès à des notices bibliographiques ; il convient toutefois de démonter cette apparence sur trois plans.

D'abord, une archive suppose un index qui organise l'accès à un catalogue stable. Au contraire, Worldcat se présente comme une interface web, un moteur de recherche, dont les résultats sont classés via un algorithme opaque. Les notices sont quelque part, mais leur accès n'est ni stable, ni garanti, et il devient tout aussi impossible de dire si la donnée est présente ou absente (« rémanence non contrôlée » (MERZEAU 2003)).

Ensuite, sur le plan institutionnel, une archive implique une mission de préservation et de garantie d'accès durable : même Internet Archive, organisation dont le but est d'archiver le web, ne remplit pas ces conditions, en ce qu'elle est exposée aux pressions de tiers ayant obtenu le retrait de contenus (MERZEAU 2003). Pour Worldcat, comme en témoigne le blocage systématique des accès automatisés et la jurisprudence, la donnée bibliographique y est considérée comme un produit commercial : son accès est conditionné, et sa pérennité dépend des arbitrages d'OCLC.

Enfin, du point de vue de la qualité de la donnée, si l'archive offre des documents décrits selon des normes relativement stabilisées, Worldcat agrège des pratiques de catalogage hétérogènes, résultat en des notices lacunaires ou corrompues. En outre, une même description de publication peut exister sous plusieurs formes : une agrégée, lorsque plusieurs bibliothèques se regroupent sous une notice commune, ou sous *des* formes divergentes, à la marge, conséquence d'un catalogue coopératif sans autorité centralisatrice suffisamment incitative pour normaliser les contributions (BEALL 2008).

Ces tensions soulèvent la question du droit applicable à la notice bibliographique, qui, pour l'utilisateur qui consulte Worldcat simplement, ne lui est pas donnée. Le flou juridique sur Worldcat interroge, par extension, la place de l'historien sur la toile. En effet, dans un espace archivistique, le cadre juridique est explicite et médié par l'archiviste : la consultation de données personnelles contemporaines, les conditions de reproduction, les restrictions d'accès sont encadrées par ces professionnels. À l'inverse, sur Worldcat, le droit s'exerce de manière plus ou moins tacite, par des moyens techniques (la limite Cloudflare) ou judiciaires (procès), sans pour autant que la frontière entre le légal et l'illégal ne soit clarifiée pour l'utilisateur ordinaire, tapant sa requête dans la barre de recherche¹⁵.

15. Par ailleurs, cette situation est comparable à Google Books, qui numérise des collections dans l'apparence du service universel pour, au final, en réclamer la propriété.

Si Worldcat n'est *pas* une archive, de quoi est-il l'archive (RYGIEL 2011) ? Cette base de données articule trois objets qu'il convient de ne pas confondre :

- la publication elle-même, décrite par des métadonnées et dont l'emplacement est indiqué sur le site selon les bibliothèques membres ;
- la notice bibliographique, description structurée de la publication produite par un agent ayant des normes professionnelles propres au monde de la documentation ;
- l'export RIS, transformation supplémentaire de la notice, produite automatiquement ¹⁶ pour l'interopérabilité entre les systèmes.

En un sens, Worldcat est l'archive des pratiques de catalogage de la production scientifique, celle des pratiques de description des bibliothécaires, qui ont leur propre histoire sur le plan de leur numérisation. Le passage à l'informatique dans les bibliothèques, qui naît en France dans les années 1980–1990 (LUPOVICI 1991), implique une rétroconversion des catalogues papier vers des formats numériques. Ce processus perd nécessairement quelque chose : la matérialité de la notice, sa mise en forme, certains éléments non prévus dans les balises restreintes du format. Lupovici observe que tout projet d'informatisation est souvent vécu comme une « grande purification », censée « remédier une fois pour toutes aux imperfections des informations manuelles » (LUPOVICI 1991). Toutefois, certaines de ses limites sont visibles dans nos données : des balises HTML encodées en dur dans les titres, des problèmes d'encodage UTF-8/ISO-8859-1 corrompus, des notices qui semblent avoir été copiées-collées directement depuis les systèmes des éditeurs.

Néanmoins, les données bibliographiques peuvent aussi, et doivent, être traitées comme toute autre source primaire, analogues et complémentaires aux archives ou aux données statistiques, soumises aux mêmes exigences de critique et d'analyse que l'imposent les conventions de la recherche historique (HÉRUBEL 1999, p. 383) ¹⁷ : au final, la navigation sur Worldcat est aussi un geste faisant partie de l'enquête.

16. Supposé.

17. Les notices sont aussi, au sens foucauldien, des documents qui portent un discours sur les conditions de leur propre production, ou la domination des modèles bibliographiques occidentaux, des thésaurus et des formats envisagés comme possibles, la neutralité technique du catalogue coopératif dissimulant un rapport de force... Voir FOUCAULT 2014, MORSEL 2021, et sur le pouvoir symbolique, BOURDIEU 1995.

2.1.4 Des problèmes anciens, sous une autre forme : la trace numérique et l'enquête historique.

Les problématiques érigées ci-dessus ne sont pas propres au numérique et à l'historien travaillant sur des sources extraites du web, car la situation décrite s'inscrit dans la continuité épistémologique de la méthode historique, en modifiant le terrain d'enquête, la toile.

En effet, une des caractéristiques de l'observation historique est la connaissance par « traces », les *documenta*, « la marque, perceptible aux sens, qu'a laissée un phénomène en lui-même impossible à saisir » (BLOCH 1949, p. 34). La situation décrite relève de la trace à deux niveaux. Premièrement, notre objet relevant du champ de l'historiographie, il est par définition accessible uniquement via ses effets, dont nous avons montré que les publications peuvent en faire partie (voir sous-section 1.2.2). Ensuite, ces publications elles-mêmes ne sont pas directement accessibles, puisqu'on les approche par les métadonnées disponibles dans les notices sur Worldcat.

Ces traces doivent s'entendre dans le cadre du paradigme indiciaire en tant que principe épistémologique, c'est-à-dire la capacité à remonter, depuis des données apparemment négligeables, vers une réalité complexe non directement observable (GINZBURG 1980, SERRES 2002, p. 7). Le caractère non intentionnel de ces traces fait d'elles des témoins malgré elles, disant quelque chose que les producteurs de ces notices n'avaient pas l'intention de dire (BLOCH 1949) : les pratiques de catalogage, la visibilité numérique différenciée des agents du champ, ou encore les rétroconversions de qualité variables ont en ce sens une valeur indiciaire, puisque les notices, et encore moins les exports RIS, ont été pensés en premier lieu dans cet objectif.

En outre, transformer les traces en sources implique le geste de problématisation. Ainsi, comme le rappelle BLOCH, ce n'est que par la question posée qu'il devient possible de transformer la trace, ici nos notices RIS, en corpus documentaire, matériel de l'historien (formulée par Ricoeur, repris par (SERRES 2002)) : notre question, l'existence et la structure d'un champ historiographique qu'il devient possible d'approcher via le « barbare », transforme les notices RIS en corpus bibliométrique, et le processus de nettoyage et d'enrichissement est, en ce sens, un geste épistémologique. Cette construction du document, par la question qu'on lui pose, implique aussi une « règle universelle de probité » qui, pour notre protocole, se traduit par le code et l'explicitation des scripts de collecte et de

transformation de nos données¹⁸

Ainsi, si la démarche bibliométrique procède par agrégation là où le paradigme indiciaire porte davantage sur des cas individuels, nous reprenons l'épistémologie de la trace : la connaissance historique, objet non inaccessible directement, passe par l'interprétation de ses traces et dont les lacunes sont des informations sur ses conditions de production. Cependant, ces traces nous parviennent sous une forme bien particulière, que constitue l'export RIS, imposant ses propres contraintes au matériau.

2.2 Une donnée appauvrie : le format RIS comme contrainte épistémologique de la bibliométrie des Sciences Humaines et Sociales

2.2.1 Un format conçu pour la citation, et non la description : histoire et logique commerciale du RIS

Le RIS est format informatique de balisage standardisé de données bibliographiques, afin de faciliter l'échange entre des logiciels de gestion bibliographique dans une perspective d'interopérabilité. Intégré à de nombreuses bibliothèques numériques, ou bases de données en ligne, le RIS est stocké sous forme de fichier texte, dont l'architecture le rend lisible par l'humain, et compréhensible à moindre coût. Ce format prodigue des informations bibliographiques dont la nature est identifiée par une balise de deux lettres, suivis de deux espaces, puis d'un tiret. Chaque ligne ne doit contenir qu'une balise, et si l'ordre des balises n'importe pas, il est nécessaire d'avoir le **TY** - (type de document) en premier et **ER** - (end record) en dernier. Si le nombre de balises disponibles a été augmenté au fil du temps, chacune a ses particularités et limites, notamment en nombre de caractères qu'il est possible d'y indiquer¹⁹. De plus, un fichier RIS peut contenir de 1 à N références ;

18. Avec toutefois la réserve que les données brutes issues de Worldcat ne peuvent être publiées sans risque juridique, limite structurelle de la présente recherche. Je m'efforce toutefois de publier le matériel sur lequel je m'appuie, dénué de ce qui relie les notices à Worldcat (RIS, liens, numéro OCLC).

19. Le lecteur intéressé peut se référer à la liste disponible sur Wikipédia, à l'adresse suivante : Le format RIS.

mais ceux fournis par Worldcat n'en contiennent qu'une : chaque fichier RIS correspond à une référence unique pour la plateforme²⁰.

Un exemple de RIS issu de la base de données

Ci-dessous un exemple de fichier RIS récupéré depuis Worldcat pour le document 69825516c835c41957dfce50 :

```
TY  - JOUR
AU  - Sheehan, Michael
RP  -
LA  -
SN  -
T2  - Marriage, family, and law in medieval Europe : collected studies
TA  -
TT  -
SP  - 278-291
VL  -
IS  -
PB  -
M2  - 278
DB  - Wellcome
PY  -
TI  - The bishop of Rome to a barbarian king on the rituals of marriage
DO  -
LK  - https://worldcat.org/title/537727690
UR  -
ER  -
```

Lecture : il s'agit d'un article (type : JOUR) publié dans la base de données *Wellcome*. Cet article, « The bishop of Rome to a barbarian king on the rituals of marriage » est paru dans *Marriage, family, and law in medieval Europe : collected studies* aux pages 278-291 et a été écrit par Michael Sheehan. Pour re-

20. Toutefois, cela n'est pas tout à fait adéquat vis à vis de la réalité, en ce que des références étaient dupliquées, voir partie 3.2.3.

trouver cette ressource dans Worldcat, il faut se rendre à l'adresse suivante :
<https://worldcat.org/title/537727690>.

Bien qu'extensive, cette liste de balises, et l'exemple de ce RIS issu de Worldcat soulève deux problématiques :

- la moindre souplesse du format, qui, contrairement au Bibtex, ne permet pas d'ajouter ses propres balises ;
- la faible quantité d'informations réellement fournies par Worldcat (les RIS les plus fournis étant ceux ayant un doi, à la rigueur un lieu d'édition).

Ces éléments rejoignent l'histoire du RIS en ce qu'il a été originellement développé par Research Information System Incorporated, désormais Institute of Scientific Information, une division de Thomson Reuters-Clarivate ; et qu'il s'agit, dès lors, d'un format créé pour accompagner le logiciel Reference Manager (puis EndNote), puis adopté par des bases de données commerciales. En ce sens, ce format, bien qu'ouvert, reste indissociable d'une pratique commerciale de l'information bibliographique ; et d'une manière de décrire les documents dans un but de standardisation de la production scientifique pour une circulation au sein des logiciels, payants pour certains²¹

De plus, le RIS a été conçu d'abord pour les articles, ce qui invite à questionner sa pertinence pour les formes de publications en Sciences Humaines et Sociales (éditions critiques, archives). Par exemple, la balise TY - ne contient aucun possible pour les recensions, alors même que ces formes de publications sont structurantes en Sciences Humaines et Sociales (SHS). Ce format, conçu pour la citation, ne permet pas de faire les liens entre des documents comme le MARC (MAchine-Readable Cataloging) le permet et, là où le BibTeX permet une structuration hiérarchique via le champ `crossref`, préservant ainsi l'unité entre un chapitre et son ouvrage (LEHMAN, KIME et WEMHEUER s. d., le format RIS impose une architecture plate qui atomise la donnée, rompant les liens relationnels entre les documents. En outre, en contraignant l'information dans des balises prédéfinies, il devient difficile de rendre compte d'autres formes de structuration du savoir²².

21. EndNote requiert un abonnement, de même que d'autres services intégrant les RIS au sein de Clarivate (Web of Science, Journal Citation Reports).

22. Outre les autres disciplines, nous pouvons penser aux autres formes culturelles que celles de l'Occident par exemple, ou celles à venir.

Cette atomisation de la donnée a des conséquences sur le corpus bibliométrique ainsi constitué, puisqu'il filtre une partie de l'information documentaire. La réduction d'une notice de catalogue à la citation génère des manques que nous ne pouvons espérer combler du fait de la nature même de ce format. À cette contrainte technique s'ajoute un appauvrissement pratique : alors que le standard RIS permettrait théoriquement de véhiculer des données plus denses, WorldCat semble privilégier la diffusion de notices minimalistes sur le plan informationnel.

2.2.2 Des silences du RIS aux bruits de la donnée.

Ces silences structurels du format ne sont pas compensés par les pratiques de catalogage des bibliothèques partenaires d'OCLC, puisque les lacunes se redoublent de bruit. Worldcat génère automatiquement les citations à partir des informations dont il dispose sur le document stocké dans sa base de données. Ces citations sont exportables sous différents formats, l'un d'entre eux étant le RIS. La qualité de ces exports dépend donc de celle des notices sources : si les données saisies par les bibliothèques partenaires sont lacunaires ou mal normalisées, le RIS produit en hérite mécaniquement ; produisant une forte hétérogénéité dans la qualité des données. Si l'on constate la présence de « dirty data » pour les notices dont le niveau d'information est inférieur au minimum attendu (BEALL 2008), elles constituent une difficulté supplémentaire à la constitution et l'harmonisation d'un corpus bibliométrique, alors même que l'on pourrait s'attendre à ce que ces notices suivent des normes de catalogages stabilisées.

Au-delà de ce constat, il convient de signaler que le RIS fourni par Worldcat, à disposition gratuitement, est une donnée amoindrie par rapport à la quantité d'information détenue par OCLC : suffisante pour un usage de citation, plus complexe pour une analyse bibliométrique. Un exemple concerne les notices d'autorité : bien qu'OCLC maintienne son propre système de contrôle des identités (numéros OCLC) et soit étroitement associé au VIAF, aucun de ces identifiants n'est transmis dans le RIS, même lorsque l'auteur y est par ailleurs correctement identifié²³. En outre, cet appauvrissement s'étend aussi à la langue de publication, le résumé, les mots clés d'indexation, la mention d'une traduction ou d'une réédition, car si ces informations sont accessibles à l'utilisateur connecté via l'interface web, elles sont absentes de l'export. De même, l'accès aux métadonnées

23. Par exemple, voir cette page : <https://search.worldcat.org/fr/title/257831976>.

enrichies est conditionné à la création d'un compte, voire à des accès par API réservées, suggérant que la gratuité apparente de l'export en est un moyen d'avoir une donnée, mais incomplète²⁴.

2.2.3 Bruit, doublons et corruption d'encodage : les imperfections de la donnée comme *données* sur l'archive.

Au cours de la réflexion autour du protocole de récupération des notices, s'est posée la question de la langue de recherche du « barbare » : comment adopter une vision globale de l'historiographie des « barbares » à l'aide de mots clés de recherche ? Au delà de la langue, il s'agissait aussi de choisir des caractères pour le chercher, puisque, dans le cas des langues dont l'écriture n'est pas latine, les mots sont parfois translittérés dans les notices. Enfin, la question s'est posée à un troisième niveau, celui de l'encodage des caractères.

Ces lacunes s'ajoutent à des dégradations liées aux conditions concrètes de production et de circulation des notices, qui, au delà d'être une difficulté pour le protocole, sont aussi des informations sur l'archive elle-même. D'abord, nous avons rencontré des problèmes d'encodages des caractères et, si le problème est ancien, il demeure difficile de le résoudre. Pour le corpus, la situation est d'autant plus paradoxale que WorldCat déclare utiliser l'UTF-8, et que la plupart des sources liées aux notices font de même : on pourrait donc s'attendre à ce que les transferts s'effectuent sans perte. Néanmoins, au cours du processus, une altération des caractères, des transcodages erronés, apparaissent dont l'origine nous est pour l'instant inconnue. L'encart ci-dessous documente trois catégories d'anomalies rencontrées : l'altération de caractères accentués, le transcodage erroné UTF-8 / ISO-8859-1 produisant des séquences du type `sociÃ©tÃ©s` pour *sociétés*, et la présence de balises HTML non filtrées dans les métadonnées.

Typologie des anomalies de codage et de structuration dans WorldCat

Les notices bibliographiques issues de WorldCat présentent fréquemment des anomalies d'encodage, en particulier sur les caractères accentués ou spéciaux. Les exemples suivants illustrent ces dysfonctionnements ^a.

24. Une sorte de produit d'appel.

Exemple 1 — altération de caractères accentués

Forme observée :

Charms, charmers and charming in Ireland: from the medieval to the modern by Ilona Tuomi, John Carey, Barbara Hillers, Ciar[?]n [?]G[?]albh[?]in (review) ^b

Forme correcte :

Charms, charmers and charming in Ireland : from the medieval to the modern by Ilona Tuomi, John Carey, Barbara Hillers, Ciarán Ó Géalbháin (review)

Exemple 2 — transcodage UTF-8 / ISO-8859-1

Forme observée :

Gil, Marc. Les femmes dans les métiers d'art des Pays-Bas bourguignons au xve siècle. CLIO. Histoire, femmes et sociÃ©tÃ©s. Published online 2011. doi:10.4000/clio.10349 ^c

Forme correcte :

Gil, Marc. Les femmes dans les métiers d'art des Pays-Bas bourguignons au xve siècle. *CLIO. Histoire, femmes et sociétés*. Published online 2011. doi :10.4000/clio.10349

Exemple 3 — perte d'information dans la notice (non lié à l'encodage)

Forme observée :

<i>Anglo-Saxons in a Frankish World, 690-900</i>. (Studies in the Early Middle Ages, number 19.) Turnhout, Belgium: Brepols. 2009. Pp. x, 324. €70.00 ^d

Forme correcte :

Anglo-Saxons in a Frankish World, 690-900. (Studies in the Early Middle Ages, number 19.) Turnhout, Belgium : Brepols. 2009. Pp. x, 324. €70.00

Remarque : ce cas ne relève ni de l'encodage ni de la perte de données, mais de la présence de balises HTML non filtrées dans les métadonnées bibliographiques.

- a. L'utilisation de [?] signale des caractères altérés ou perdus lors de l'interprétation des encodages de caractères (erreurs de décodage ou substitutions Unicode de type U+FFFD).
- b. <https://worldcat.org/fr/title/9893044614?oclcNum=9893044614>
- c. <https://worldcat.org/fr/title/805914162?oclcNum=805914162>. Celui-ci n'est pas visible directement, il faut appuyer sur `citer` pour le voir apparaître.
- d. <https://worldcat.org/fr/title/5496056830?oclcNum=5496056830>

Ensuite, une autre difficulté a été posée par la question de la translittération de noms d'oeuvres ou d'auteurs issus d'alphabets non latins. En effet, lors de la production d'une notice, le même nom peut être transcrit selon des normes différenciées sans pour autant que le choix retenu soit précisé dans le RIS récupéré. Ainsi, un même auteur peut apparaître sous des formes différentes à mes yeux, d'autant plus compte tenu de mon rapport très distancié à ces écritures : par exemple, Botalov Sergey G. possède aussi une écriture cyrillique très différente²⁵. Worldcat ne normalise pas non plus ces variantes, laissant coexister dans les notices des noms différents pour une même personne, sans qu'elle ne soit pour autant reliée à un identifiant unique tel que le ferait une notice d'autorité. Par conséquent, l'identification des doublons sur la base des méthodes que mises en place (similarité sur les chaînes de caractères, voir section 3.2.3) se trouve mise en défaut.

Ainsi, nous avons pu voir que ces anomalies ont des implications massives concernant les processus d'automatisation et d'identification des auteurs, mais également sur les analyses fondées sur les titres des publications (voir section 3.2.6), et plus généralement, toute opération supposant la comparaison de chaînes de caractères. Toutefois, elles semblent aussi être la trace d'autre chose²⁶ : l'instabilité, les lacunes et le bruit structurel de la donnée sur le web en tant qu'attributs structurels de la donnée sur la toile ; ce qui suggère que ces observations sont des traces des conditions de production du document, des difficultés analogues à celles rencontrées par l'historien dans son enquête. Ces transformations successives de la notice, de sa production par le professionnel de la documentation à son export en RIS, s'apparente aux « couches » s'interposant entre l'historien et ses sources,

25. Si l'on croit le site russe http://uralhist.uran.ru/en/394/_aview_b393, qui répertorie sur le même ID ces noms. Aussi, pour des raisons d'encodage, il m'est difficile d'inclure le nom écrit en cyrillique ici, mais j'invite le lecteur à consulter la page web.

26. D'autant qu'il paraît difficile d'envisager que la donnée brute préexiste et que le « nettoyage » que nous opérons ne ferait que révéler un état originel.

où s’opèrent des choix qui ne sont pas toujours explicités et qui conditionnent la manière d’interpréter les archives à l’ère numérique (CLAVERT 2019) : documenter ces couches, les dépasser pour produire un objet à partir d’elles (redocumentarisation), sont alors des impératifs méthodologiques pour ne pas perdre de vue la source au fondement de l’analyse (CLAVERT 2019).

2.3 La redocumentarisation comme geste épistémologique : stratégies d’enrichissement des métadonnées.

La redocumentarisation peut s’envisager comme un processus par lequel les traces observées peuvent devenir des matériaux documentaires pour notre recherche, à l’aide d’opérations d’extraction, de croisement des informations (MERZEAU 2009). Ce geste implique des décisions techniques, que nous détaillerons dans la partie 3.2.4, mais aussi des enjeux épistémologiques : choisir d’utiliser la trace est aussi une acception de ses caractéristiques comme des éléments constitutifs de l’objet d’étude, en tant que condition et que donnée sur elle-même ; mais c’est aussi faire le pari que l’information manquante existe quelque part sur la toile, et qu’il est possible de la trouver au risque d’introduire de nouvelles sources de bruit dans la chaîne de traitement.

2.3.1 Une stratégie explorée mais impraticable : SPARQL et les limites de l’interopérabilité.

L’idée du web sémantique esquissée par RASTIER semblait *a priori* adaptée au besoin de résoudre les manques des notices, en proposant une solution pour interconnecter des données hétérogènes par des standards communs (RDF), en dépit des critiques que l’on peut relever à son sujet (RASTIER 2008)²⁷. En effet, les bases que nous étions invitées à consulter (Wikidata, IdRef) disposent d’un *endpoint* SPARQL (SPARQL Protocol and RDF query language), qui aurait permis de les interroger directement, à l’aide des

27. Le web sémantique repose sur l’idée que les connaissances sont indépendantes de leurs bases sémiotiques, et pose donc que celles-ci sont formalisables dans des ontologies universelles ; ce qui semble peu adapté à la réalité incommensurable des langues et des cultures (RASTIER 2008).

propriétés sur les individus et les documents dont nous disposions.

Toutefois, en pratique, l'implémentation du SPARQL demeure complexe. D'abord, en ce que la documentation, bien que foisonnante sur la toile, ne répondait pas aux requêtes plus complexes désirées dans le cadre de cette recherche ; ensuite, par le temps de réponse allongé en comparaison à l'utilisation d'une API, d'autant que celui-ci retournait souvent une réponse vide sans pour autant signaler une erreur, ce qui ne facilitait pas l'amélioration des requêtes.

Ainsi, nous avons favorisé des stratégies d'enrichissement et de redocumentarisation par APIs ciblées et extraction automatique sur le web, plus adapté à l'hétérogénéité de nos données.

2.3.2 Augmenter la donnée sans la trahir : choix des référentiels et arbitrages épistémologiques.

Afin de redocumentariser les traces récoltées par les RIS, nous avons fait le choix d'une approche hybride sur plusieurs plans, détaillés ci-dessous :

- technique. automatisé pour la plupart, semi-automatisé parfois, manuellement dans les marges ;
- épistémologique par des référentiels reconnus ou par des pratiques faisant moins autorité ;
 - pour les auteurs : VIAF (fichier d'autorité international virtuel), IdRef (Identifiants et référentiels), BnF (Bibliothèque Nationale de France), Orcid (Open Researcher and Contributor ID), Scopus, Wikidata, IEEE (Institute of Electrical and Electronics Engineers) mais aussi des bases locales fournissant quelques informations sur les auteurs et un identifiant unique (Regesta Imperii par exemple).
 - pour les publications : Crossref, Persée, JSTOR, Cairn, ScienceDirect ou Elsevier, Cambridge University Press ou OpenEdition, mais aussi des pratiques moins légales, comme Anna's Archive ou Scihub.

Le tableau récapitulatif (tableau 7.2, 265) a pour objectif de synthétiser le propos sur chacune de ces stratégies²⁸. Je tiens cependant à relever un point essentiel avant même

28. Le lecteur intéressé par une hiérarchisation de ces stratégies par les résultats empiriques produits

d'exposer les bases mobilisées : augmenter la quantité de bases ne permet pas de résoudre les problèmes rencontrés, et les déplace sur d'autres terrains.

Du côté des publications

Deux registres pour la redocumentarisation des notices des publications se distinguent : le registre de la métadonnée, des informations sur le document (langue, auteur, date), et celui du texte de l'article. Les stratégies mobilisées ont articulé ces deux dimensions à la fois, parfois en même temps. Le protocole détaillé pour chacune de ces bases sera détaillé en section 3.2

- les métadonnées : Crossref, Wikidata (non exploité ici mais potentiel)
- les fulltext : Anna's Archive et Scihub, Google Scholar
- les deux : JSTOR, Bases de Données (BDD) ciblées, demande par courriel, Persée

Demander peut constituer une stratégie viable. Si le fait d'envoyer un courriel peut sembler être une perte de temps et d'énergie, en ce que les réponses sont au bon vouloir des destinataires, cette méthode, la plus simple à mettre en place, a porté ses fruits pour nos demandes. J'ai contacté le support de la plateforme Muse (410 documents dans la base) et Paperity (647 documents dans la base), et un exemple de courriel est consultable dans la section 7.1.

Si le support de Muse nous a envoyé un fichier compressé comprenant l'intégralité des métadonnées des journaux dans lesquels les articles étaient publiés, le support de Paperity a évoqué une impossibilité de le faire en raison de l'absence d'interface dédié à l'interrogation automatique de leur site. Toutefois, le 16 février, le fondateur de Paperity, a envoyé un courriel comprenant un lien vers une API permettant d'interroger directement la base de données. Bien que les crédits gratuits étaient limités, il m'a informé qu'au besoin, il pourrait recharger mes crédits à ma demande ; et en a profité pour me demander un retour sur les fonctionnalités de l'API²⁹. Ainsi, les textes intégraux des publications peut se référer à la partie 3.2.5.

29. S'il ne m'a pas demandé d'en faire la publicité, ni de lui donner quelconque crédit, je suppose que l'utilisation de cette API par d'autres peut être profitable dans le cadre d'un travail de recherche. Ainsi, je le mentionne ici, ce n'est pas dans un but commercial, mais bien informatif, dans le cadre d'administration de la méthodologie employée. L'API en question est disponible à l'adresse suivante : <https://scholarapi.net/>.

disponibles sur la plateforme ont pu être récoltées avec un coût minimal, soit celui de l'implémentation du programme pour utiliser l'API, et un échange de courriel.

Pour ce qui est des métadonnées, Crossref a été mobilisé. Il s'agit d'une organisation à but non lucratif fondée en 2000, jouant le rôle d'agence d'enregistrement et registre des DOI (digital object identifier). Regroupant plus de 24 000 membres dans 166 pays, la plateforme semblait être un accès privilégié pour notre protocole de redocumentarisation. En effet, le site web dispose d'une API gratuite et sans authentification³⁰, que l'on peut interroger à partir d'un DOI pour récupérer un ensemble de métadonnées sur la publication³¹. L'interrogation de l'API a permis, par un coût minimal de codage, de compléter nos métadonnées, en particulier celles sur la langue des documents.

Pour les contenus textuels, sans les métadonnées, nous avons envisagé deux méthodes, l'une à partir du DOI, et l'autre sans. La première a été réalisée à l'aide de bibliothèques clandestines : (SciHub et Anna's Archive), offrant un accès gratuit à des publications autrement payantes. SciHub a été lancé en 2011, et revendique un objectif de diffusion du savoir scientifique pour tous, indépendamment des ressources financières requises par les éditeurs académiques. Anna's Archive est, quant à elle, plus récente : sa création en 2022 fait suite aux pressions pour la fermeture de la Z-library, miroir de LibGen, moteur de recherche d'articles et de livres scientifiques soumis aux *paywall*. L'utilisation de ces bibliothèques pour récupérer les textes intégraux des documents soulèvent des questions juridiques et éthiques qu'il convient de mentionner : si leur usage dans un cadre de recherche ou personnel semble répandu (NICHOLAS et al. 2019), il n'est pas légalement établi, comme en témoignent les réguliers changements de nom de domaine de leurs sites, ou les procès intentés contre elles, et pose question quant à la rémunération et la reconnaissance des travaux des chercheurs. La seconde stratégie consistait à utiliser la puissance de l'indexation Google : Google Scholar est un service de recherche d'articles scientifiques créé en 2004, dont l'accès est gratuit et qui présente l'avantage de collecter une masse d'articles et de chapitres non négligeable, bien que ses capacités d'indexation,

30. Disponible à l'adresse suivante : <https://www.crossref.org/documentation/retrieve-metadata/rest-api/>.

31. Notons toutefois que les notices bibliographiques pour lesquelles un DOI était renseigné n'étaient pas nécessairement les moins bien fournies ; au contraire.

reposant sur celles de Google, ne soient pas des standards acceptables pour les contenus proprement scientifiques (données très hétérogènes et incomplètes)³². Toutefois, ces biais ne sont pas rhédictoires pour y récupérer ce qui nous intéresse, les textes. En effet, concurremment à la récupération des identifiants Google Scholar des auteurs dont nous traitons ci-dessous, il est aussi possible, en cliquant sur le document auxquels ces derniers sont liés, d'obtenir un PDF avec le *fulltext*.

Enfin, pour les stratégies plus mixtes, plusieurs solutions s'offraient à notre recherche. D'abord, notre statut étudiant de Paris 1 nous a permis d'utiliser JSTOR, une bibliothèque numérique par abonnement. Fondé en 1995, il recense des articles, ouvrages dans des domaines vastes des Sciences Humaines et Sociales et comptait en 2011 3.4m d'articles complets. Bien qu'ayant accès au site, il était hors de nos compétences de contourner le blocage des programmes de scraping ; mais le site offre des services de fouille de texte³³, en nous offrant un accès à l'intégralité des métadonnées des articles dont nous avons accès ainsi qu'au texte complet, au format `.json`, si nous disposons d'une liste d'identifiant JSTOR. Cette stratégie nous paraissait l'une des plus pertinentes au regard de la quantité de notices dont nous disposions indiquant leur base de données comme étant JSTOR : 5563 documents.

De même, Persée, bien que non utilisé davantage dans le cadre de la présente recherche, aurait pu constituer un outil pertinent. Persée est un portail de revues scientifiques en libre accès, créé par le Ministère de l'Enseignement Supérieur et de la Recherche, et mis en ligne en 2005. Il présente l'avantage d'être libre et gratuit, et interopérable dans le cadre des données ouvertes. Interrogeable via SPARQL, il donne accès aux textes et à leurs métadonnées. Nous l'avons utilisé pour tenter de voir les superpositions entre les bases de données de Worldcat et celle de Persée, afin d'observer si certains de nos documents

32. « on suppose que Google Scholar indexe tous les articles se trouvant sur les plateformes de diffusion des revues savantes, déposés sur les dépôts institutionnels des universités et autres dépôts disciplinaires, et tous ceux mis en ligne sur les sites Web des chercheurs. On sait qu'il recense les documents en plusieurs langues, notamment en russe depuis 2016. Cependant, Google Scholar intègre souvent des articles ne provenant pas de périodiques : des présentations PowerPoint aux chapitres de livres, voire des plans de cours – tout ce qui ressemble de près ou de loin à une parution universitaire. » (LARIVIÈRE et SUGIMOTO 2018).

33. Disponible à l'adresse suivante : <https://support.jstor.org/hc/en-us/articles/32479181127575-JSTOR-Text-Analysis-Support-Getting-Started>.

étaient disponibles par ce biais. Finalement, puisque nous nous sommes tournés vers une analyse du corpus anglophone, son utilisation n’a pas abouti ; mais cette porte d’entrée constitue un point majeur pour quiconque souhaite exploiter un corpus textuel massif francophone.

Des bases de données ciblées ont aussi été mobilisées, tant dans la récupération des articles que dans celle des notices d’autorité. Cet élément fait partie du protocole semi-automatisé, en ce qu’il requiert d’identifier les bases de données les plus fréquentes dans le corpus et d’étudier leur structure HTML et JavaScript une par une pour récupérer les publications. Il s’agit ici de retenir les bases de données pouvant offrir une masse informationnelle suffisante pour justifier un travail de codage et de mise en place d’un protocole dédié pour celles-ci. Par exemple, la base OpenEdition Journals comptait, dans la base originale, 1293 documents, ce qui pouvait justifier la mise en place d’un programme pour les récupérer. En outre, cette stratégie permettait également de repérer des auteurs, lorsque leur identifiant d’autorité leur était lié sur la page de leur document : c’est notamment le cas pour les publications dans ScienceDirect (375 documents) qui donnent accès, lorsqu’il est lié, à l’identifiant Scopus ou Orcid. Toutefois, la quantité d’information disponibles sur ces bases demeure variable (en accès ouvert ou non, dépendance à des abonnements) et il convient de souligner que toutes n’étaient pas aisément récupérables : ScienceDirect requiert la résolution d’un CAPTCHA (Completely Automated Public Turing test to tell Computers and Humans Apart) en début de session de récupération, tandis que la base Directory of Open Access Journal était complètement bloqué par CloudFlare. En revanche, cette méthode présentait l’avantage de ne nécessiter uniquement le titre de l’article et le nom de la base de données dans lequel il était publié.

Du côté des auteurs

Pour les auteurs, des référentiels d’autorité disposant d’une API comme IdRef, BnF (Bibliothèque Nationale de France) ou Wikidata ont d’abord été mobilisés. IdRef est une base de données ouverte et réutilisable de plus de 6.4m de notices d’autorité de personnes physiques et morales, lieux et concepts, et est maintenu par l’Agence Bibliographique de l’Enseignement Supérieur. Recensant notamment les individus français, elle permet aussi la résolution et l’alignement des référentiels, en proposant, avec un identifiant IdRef, les liens vers VIAF (Virtual International Authority File), Orcid, Wikidata, BnF ou Scopus ;

et ses notices sont accessibles via une API³⁴. La BnF met également à disposition des utilisateurs des notices d'autorité, en plus de proposer une API pour les récupérer³⁵. Wikidata, enfin, constitue un cas à part : si ses données sont participatives et ne font pas autorité au sens strict, sa structuration par une ontologie structurée et son potentiel de croisement des référentiels (via les propriétés P214 pour VIAF, P269 pour IdRef, P496 pour ORCID, etc.) en font un outil de réconciliation permettant d'obtenir, en une seule requête, des informations complémentaires normalisées sur la nationalité, l'institution ou la discipline d'un auteur.

Nous avons également eu recours à des référentiels ne disposant pas d'API, nécessitant une lecture directe du code source. En premier lieu, VIAF est un fichier d'autorité international pour identifier des personnes : projet commun de plusieurs bibliothèques, il est maintenu par l'OCLC³⁶. Celui-ci s'est doublé d'un recours à ISNI (Code International Normalisé des Noms), développé par l'ISO, agence internationale, et en vigueur depuis 2012. Lorsque des auteurs avaient publié dans des conférences indexées par IEEE Xplore, leur identifiant IEEE a été récupéré directement sur la plateforme. Enfin, nous avons également consulté le Regesta Imperii OPAC, base de médiévistique germanophone recensant depuis le XIX^e siècle des documents pour l'histoire allemande et européenne, dont les données ouvertes disponibles en fichier CSV permettent d'identifier un sous-ensemble d'auteurs avec un coût d'implémentation faible.

Pour finir, nous avons aussi mobilisé des identifiants reposant sur les déclarations volontaires des auteurs, ou répondant aux logiques commerciales des plateformes : l'ORCID, sur une base déclarative, l'identifiant Scopus Author ID dont la consultation est limitée pour les non utilisateurs d'Elsevier (payant), ainsi que l'identifiant Google Scholar, que les membres peuvent modifier eux mêmes. En ce sens, ces sources favorisent les auteurs dont les institutions valorisent l'utilisation de ces bases et invitent les chercheurs à s'y inscrire. Si ces sources présentent des biais de couverture importantes, des doublons et ne peuvent être considérées comme des notices d'autorité, elles ont permis la désambiguïsation des

34. Disponible à l'adresse suivante : <https://documentation.abes.fr/aideidrefdeveloppeur/index.html#WebServiceRest>.

35. Disponible à l'adresse suivante : <https://api.bnf.fr/index.php/fr/notices-dautorite-personnes-collectivites-oeuvres-lieux-noms-communs-de-bnf-catalogue-general>.

36. Rappelons le, OCLC, dans sa version consultable en ligne, ne fait pas les liens entre les auteurs mentionnés dans les publications sur Worldcat et leurs identifiants VIAF.

auteurs de la base et la réconciliation entre des identifiants divers sur la toile.

Les bases de données mentionnées jusqu'à présent reposent certes sur des avantages techniques et pratiques, mais également des choix épistémologiques. Si Worldcat présente déjà un biais occidental, le choix des référentiels d'autorité présentés ci-dessus conduit structurellement à le reproduire, en se centrant sur la France, le monde Anglo-Saxon, et l'Allemagne. De plus, en privilégiant certaines sources d'informations plutôt que d'autres pour enrichir une notice, il s'agit aussi d'un choix d'ontologie et d'autorité. Il convient en ce sens de rappeler que la redocumentarisation, au delà de pallier aux lacunes des RIS fournis par Worldcat, est un geste de construction du corpus : les quelques 8000 auteurs sans identifiant dans la base représentent ainsi une donnée sur la visibilité différenciée des auteurs dans le champ³⁷.

Malgré la mise en place de ces stratégies, combinées les uns aux autres, des manques d'informations substantiels subsiste, nécessitant parfois un retour à Worldcat lui même afin de croiser les informations entre les référentiels d'autorité et les autres publications suggérées d'un même auteur par Worldcat.

Conclusion de chapitre La réflexion proposée au cours de ce chapitre a tenté de mettre en évidence que la notice exportée de Worldcat est un construit lié aux logiques d'indexation, à l'ambiguïté du modèle économique de la plateforme, et les bruits de la donnée récupérés. Chaque élément représente, en ce sens, des limites quant à nos possibilités d'enquête historique, bien que le geste épistémologique de la redocumentarisation nous permette d'enrichir les notices et re-construire l'objet.

L'identification des limites de la source est une étape fondamentale : elle conduit ici à un protocole permettant de constituer le corpus soumis à l'analyse. Ainsi, le prochain axe de réflexion porte sur comment, à partir de cette matière appauvrie, j'ai mis en place des étapes successives, du *scraping* des données sur la toile à leur analys.

37. Et ce constat a également des conséquences sur l'ensemble de nos analyses ultérieures puisqu'il s'agit d'analyser la part du champ rendue visible par les sources et référentiels retenus.

Chapitre 3

De la notice à la base de données : protocole, modélisation et construction de l’objet.

3.1 L’IA générative comme assistant de protocole : usages, effets cognitifs et réflexivité .

3.1.1 L’utilisation de l’Intelligence Artificielle dans ce projet : assistant de protocole et inférence.

De prime abord, ma posture était réticente quant à l’utilisation des LLMs (grand modèle de langue), puisque je désirais acquérir des fondamentaux sur le plan technique et aussi car, durant mes années de licence, je ne les utilisais que peu. Néanmoins, la question des LLM et de leur usage s’est, de fait, rapidement posée : d’abord, car mon arrivée à l’université concorde avec la démocratisation des LLMs, ce qui en fait un sujet de discussion entre étudiants presque quotidien ; ensuite, car mon cercle familial est averti de ces usages ; enfin, la question n’est pas sans rapport avec l’actualité récente des avancées de ces technologies.

Notre projet ayant mobilisé des LLMs à différents niveaux, il est essentiel de noter les effets de ce dispositif. Il convient d’abord de clarifier ce que j’entends par IA et LLM ici. D’abord, si les modèles de *transformers* sont également des modèles de langue, ceux mobilisés (Spacy, Mpnet) ont moins de dimensions, et ont été utilisés dans le cadre d’un

workflow les impliquant d'un côté pour le traitement des données textuelles et des entités nommées, et de l'autre dans le cas de la vectorisation des titres pour le clustering avec BERTopic (BERT pour Bidirectional Encoder Representations from Transformers), comme nous le verrons dans la suite de cette section.

De quelle IA parle-t-on ?

Notre réflexion porte donc ici plus spécifiquement sur les grands modèles de langage au sens commun du terme, tels que ChatGPT, Gemini, Claude, Mistral ou Perplexity. Leur mobilisation dans le cadre de cette recherche a reposé sur deux usages principaux.

D'abord, ces outils ont été utilisés comme des assistants de protocoles, pour le développement et l'adaptation du code nécessaire à la collecte ou au traitement des données. Particulièrement utiles lors des évolutions de structure des pages web, source des données de la présente recherche, les LLMs permettaient une montée en compétences notable, pour un utilisateur en début d'année sans formation approfondie en programmation.

Aussi, certains LLMs ont été mobilisés dans une logique d'augmentation ou d'enrichissement des données, lorsque cela était documenté dans la littérature scientifique. Il s'agit par exemple de l'usage de MistralAI pour inférer le genre des auteurs à partir du prénom et de la nationalité, en se reposant sur les travaux de GOYANES, DE-MARCOS et DOMÍNGUEZ-DÍAZ sur le sujet (mise en évidence de performances comparables, si ce n'est supérieures, des LLMs pour détecter le genre).

Dans le cadre du protocole, j'ai pu testé plusieurs modèles, avec leur plan gratuit¹, qu'il convient de distinguer pour les différentes tâches :

Parmi les différents modèles mobilisés, Claude apparaît comme celui ayant apporté la contribution la plus significative à mon projet. Outre sa capacité à générer du code, ou me rediriger vers des solutions existantes que je n'avais pas trouvé dans le cadre de mes

1. De manière générale, pour ce projet, aucun investissement financier n'a été fait, que ce soit pour l'utilisation d'API que pour les LLMs. Je tiens à conserver un protocole aussi reproductible que possible, en envisageant des solutions plus accessibles, ou ne nécessitant qu'une adresse e-mail. Pour ces usages, qui sont signalés mais non conditionnels pour mener à bien le protocole (puisque, dans la mesure du possible, nous avons tenté de minimiser les étapes où il était nécessaire de s'identifier), je recommande l'utilisation d'une adresse mail annexe à une adresse mail personnelle afin d'éviter de donner trop d'informations personnelles. Une adresse mail temporaire jetable aurait été une solution envisageable.

Modèle	Usage	Points forts	Limites
Claude Sonnet	Peu utilisé au début, puis usage	Très bonnes performances en codage, bonne mémorisation du contexte, peu d'hallucinations	Montée en puissance progressive, moins pertinent au début du semestre
Gemini Pro	Complément de Claude	Bon niveau global, particulièrement performant en début de semestre	Moins performant que Claude sur les versions récentes
Gemini Raisonnement	Usage ponctuel	Utile pour reformulation et clarification de texte, notamment pour des contenus mal compris ou en langue étrangère	Peu utilisé dans le cadre général du projet
Perplexity Pro	Utilisé au début (abonnement étudiant gratuit)	Efficace pour reformuler du texte	Usage limité et abandonné par la suite
ChatGPT	Très peu utilisé	Utile pour tâches simples	Tendance à produire des réponses trop verbeuses et sujettes à hallucination
NotebookLM	Usage ponctuel	Pertinent pour l'analyse de documents longs	Navigation et exploitation des contenus peu pratiques
MistralAI (chat)	Test exploratoire	–	Moins performant que les autres modèles sur l'ensemble des tâches
MistralAI (API)	Usage technique	Gratuit, utilisé pour l'imputation de genre ²	Usage limité à des tâches spécifiques

TABLE 3.1 – Comparaison des modèles de langage testés dans le cadre du projet

recherches, ce modèle m’a accompagné pour des suggestions d’architecture de scripts et de fichiers : par exemple, proposer, par rapport à un protocole pensé initialement, des modifications dans l’ordre des tâches ou les fonctions de chaque script, invitant ensuite à une réflexion de ma part.

3.1.2 Le prompt comme pensée structurée et posture de décomposition du problème de recherche

WANG développe une « autoethnographie » sur son usage des LLM dans sa recherche en sciences humaines et sociales, ses conditions et ses effets. A son image, je propose ci-dessous un retour introspectif sur ce dispositif technique, qui peut aussi s’envisager comme un mode de raisonnement, invitant à une démarche cognitive différenciée.

Si les LLMs semblent, de prime abord, abaisser les barrières à l’entrée de différents domaines (synthèse, rédaction, programmation³), je tiens à relever qu’il serait plus juste de parler d’une reconfiguration des capitaux nécessaires. En effet, ces outils fonctionnent, du moins dans l’usage fait ici, à partir d’un prompt : en ce sens, leur utilisation repose sur notre capacité à formuler des requêtes pertinentes, évaluer la qualité des résultats produits, identifier les erreurs... De ce point de vue, leurs effets vont au delà des transformations de la matérialité du travail, car le prompt contribue à modifier la manière dont les problèmes sont appréhendés et formulés. Par exemple, comme le montre WANG, le chatbot agit comme un intermédiaire entre le langage naturel et le langage machine, en jouant le rôle de traducteur entre le chinois et le code informatique.

Par conséquent, avant le prompt, l’utilisation de ces outils requiert, pour avoir des réponses plus satisfaisantes, de clarifier ses objectifs et contraintes, ainsi que les étapes intermédiaires nécessaires. En ce sens, il s’agit d’un exercice de formalisation du problème : décomposer la tâche complexe en sous-problèmes, préciser les résultats attendus et expliciter autant que possible les informations contextuelles nécessaires. Je rejoins ici WANG, qui propose d’envisager le prompt comme un « New research language »(WANG 2025). En rendant intelligible un problème pour un modèle, cela m’a conduit aussi à le rendre intelligible pour moi-même, au cours de cet effort d’explicitation des entrées, sorties et

3. Domaine dans lequel plusieurs travaux soulignent leurs performances élevées X. SONG et al. 2025

transformations du projet ⁴.

Ainsi, cette démarche permet d'adopter une posture réflexive sur nos hypothèses de travail et, en les formalisant par le processus d'écriture, peut rendre possible une éventuelle discussion autour de celles-ci ⁵.

En outre, le LLM peut aussi être perçu comme un partenaire de recherche. Si WANG souligne, comme je l'ai fait plus tôt, la complaisance du chatbot vis-à-vis de nos opinions et présupposés, ils peuvent aussi suggérer, lorsque mobilisés dans une logique plus exploratoire, des pistes théoriques ou méthodologiques qui n'auraient pas été envisagées de prime abord. Bien entendu, toutes les propositions ne sont pas pertinentes au regard de notre recherche, et il s'agit plutôt de l'effet de la réponse du LLM quant à l'engagement d'un processus de réflexion de notre part sur des solutions.

Enfin, ces éléments ont eu des effets sur la manière dont j'ai pu envisagé le projet de recherche. En réduisant ⁶ les coûts d'exploration de solutions techniques, les LLMs tendent à reconfigurer ma propre évaluation préalable de ce qui me paraissait réalisable. Si certaines pistes de recherche auraient pu être abandonnées, faute de temps ou de compétences (tant réelles que perçues), elles peuvent devenir des possibles à décomposer, expliciter et expérimenter avec l'usage de l'IA. Pour le dire plus simplement, ma pensée à l'idée de certaines solutions est passée de « ce n'est pas possible je n'aurai pas le temps ! » à quelque chose comme « et si on essayait en demandant à une IA ? »

4. « This process of making it clear to the AI was, in itself, a structured organization of my own theoretical thinking » (WANG 2025).

5. Ici, je tiens à rappeler que les LLMs discutent rarement des hypothèses de travail. Mis à part Claude, aucun n'a semblé remettre en question mes objectifs directement. Par contre, les écrire dans le prompt, recevoir une réponse qui n'était pas nécessairement alignée avec mes buts m'a permis de prendre un pas de recul au regard de mes propres présupposés de recherche. Ce n'est pas le LLM directement qui m'a invité à réfléchir au sujet, mais plutôt la formalisation par écrit dans ce cadre.

6. Comme évoqué plus tôt, il s'agit d'une réduction *du point de vue de ma propre position dans l'espace social*. Si cela reste une hypothèse, je ne crois pas que la popularisation des LLMs reconfigure fondamentalement les rapports au sein du monde social, et tend davantage à les reproduire, à l'image de ce qu'ont pu souligner les travaux portant sur le rôle des médias numériques dans la participation politique (l'essor d'internet a contribué à élargir le débat, et s'il renforce les capacités participatives et mobilisatrices sous la forme de mouvements sociaux des plus politisés et compétents, il reproduit, voire renforce, la distance au politique de ceux qui en étaient déjà distants.)

Bien que WANG (2025) présente les LLMs comme des outils potentiellement pertinents pour l'analyse qualitative des données, cette possibilité n'a pas été retenue dans le cadre de ce mémoire. Il aurait notamment été envisageable d'intégrer un modèle de langage au workflow de topic modelling afin d'assister l'interprétation des thèmes identifiés par BERTopic (par exemple en lui demandant de produire des descriptions des clusters à partir des termes saillants, ou des documents en leur sein).

Par ailleurs, le propos tenu jusqu'à présent doit être replacé dans le contexte temporel de septembre 2025 à mai 2026. Compte tenu du développement rapide des modèles accessibles au grand public, la généralisation et l'évaluation durable sur leurs capacités et usages semble difficile à tenir pour la présente recherche. Ainsi, il s'agit ici davantage d'un reflet de l'expérience située d'une étudiante de Master 1 mobilisant ces outils dans le cadre de son mémoire⁷.

Ainsi, à l'heure d'écriture de cette étude, les principaux modèles utilisés sont Claude Sonnet 4.6 et Gemini 3 Pro pour nos tâches. Leur usage s'est limité à des interactions textuelles, qu'il s'agisse de la production de code, de la résolution de problèmes techniques ou de l'accompagnement de la réflexion méthodologique ; aucune fonctionnalité multimédia n'a été mobilisée. Certains dispositifs, mis en place par ces plateformes au cours de l'année universitaire, ont aussi joué un rôle dans l'organisation de mon travail, avec les fonctionnalités de « mémoire » ou de « Projets » pour conserver des documents, instructions et contextes partagés au sein d'un même environnement de travail : cela m'a permis d'envisager le LLM comme outil plus intégré dans le cadre d'un projet, davantage qu'un requête ponctuel.

3.1.3 *Prompt engineering* : exemple de prompt utile et bonnes pratiques dans mes usages de l'IA

Cette compétence de formalisation scientifique s'inscrit dans le cadre du *prompt engineering*, entendu comme le processus d'écriture, d'affinage et d'optimisation des entrées pour guider les systèmes d'IA générative dans la production de résultats spécifiques et

7. Précision d'autant plus importante au regard de la littérature sur les « AI-assisted protocol », constituant des formes plus intégrées d'assistance par l'IA dans la recherche.

de haute qualité⁸. Ainsi, préciser et construire un prompt peut diminuer les itérations et les messages envoyés au LLMs pour obtenir un résultat exploitable et, à l'inverse, des consignes imprécises conduisent généralement à des demandes de clarification.

WANG décrit ainsi le prompt académique comme une forme condensée de protocole de recherche. Selon lui, un prompt efficace repose sur : l'attribution d'un rôle spécifique au modèle (« role-setting »), la décomposition de la tâche en étapes distinctes (« task decomposition »), la fourniture du contexte nécessaire à sa compréhension (« context provision ») ainsi que la définition explicite des critères et contraintes attendus pour la réponse (« criteria and constraints ») (WANG 2025).

Mon expérience rejoint ce constat, puisque dans le cadre de ce mémoire, les prompts les plus efficaces reposaient sur les éléments suivants.

D'abord, j'ai pu constater qu'explicitier le contexte général du projet en une ou deux phrases permettait de limiter les réponses trop génériques ou inadaptées à la nature de mes données. Cette précision était notamment pertinente lorsque le prompt avait pour objectif d'élargir les méthodes envisagées, tout en demeurant adaptées aux objectifs, voire à la question de recherche.

Préciser les consignes, tant générales que plus précises, est le cœur du prompt. D'un côté, ces consignes peuvent chercher à guider le comportement, sur la forme, du modèle : privilégier la concision, expliciter les raisonnements, produire du code commenté, adapter le niveau de détail à l'utilisateur. De l'autre, il s'agit de consignes spécifiques, portant sur le fond, de préférence décrites étape par étape, pour atteindre notre objectif ; je recommande particulièrement l'utilisation de listes numérotées.

Aussi, ajouter des renseignements clairs (chemins des fichiers, leur structure) sur les ressources disponibles permet au modèle de calibrer les réponses à nos données. Sur le plan pratique, cela peut prendre la forme d'extraits de fichiers, de descriptions détaillées des variables.

Enfin, je suggère de spécifier précisément les résultats attendus en retour du prompt : un script Python, une proposition méthodologique, des informations complémentaires sur un sujet.

Si ces éléments peuvent sembler, de prime abord, triviaux, ils permettent de guider

8. Voir à ce sujet la page IBM dédiée, disponible à l'adresse suivante : <https://www.ibm.com/fr-fr/think/topics/prompt-engineering>.

le modèle dans sa réponse et d'avoir des résultats plus adaptés à nos besoins. En outre, si je ne l'ai pas pratiqué dans le cadre de ce mémoire, j'ai pour souvenir lors d'usages antérieurs de l'IA dans le cadre de projet⁹ qu'une stratégie consistait à demander à un *autre* LLM de produire un prompt pour le modèle que l'on souhaite utiliser : par exemple, demander à ChatGPT d'écrire un prompt pour Claude, selon ce qu'on voulait faire.

Au delà de ces principes, plusieurs pratiques ont été utiles au cours de ce travail, et je les énumère ici afin de fournir quelques conseils sur le sujet :

- ouvrir une nouvelle conversation lorsque le sujet traité change substantiellement, pour éviter que le contexte accumulé ne bruite les réponses ou consomme des *tokens* lors du rechargement de la conversation ;
- privilégier, lorsque cela est possible, les fichiers textes simples plutôt que d'autres formats lorsque l'on souhaite, par exemple, partager un exemple de nos données au format csv ;
- fournir des exemples concrets des données plutôt que des descriptions ;
- considérer le LLM comme un outil d'assistance à la formalisation plutôt que comme un substitut à la réflexion préalable, puisque, dans notre expérience, les résultats les plus satisfaisants étaient obtenus lorsque les grandes étapes du protocole ou du problème étaient déjà identifiées en amont.

Pour finir sur cette question, je tiens à rappeler que les stratégies employées dans la construction du prompt dépendent du modèle utilisé, et des objectifs poursuivis : certains modèles sont, d'expérience¹⁰, plus efficaces pour les tâches de programmation (Claude), d'autres pour l'analyse de documents (Perplexity) ; le *prompt engineering* est, à ce titre, une pratique d'adaptation. Je renvoie à l'annexe 7.2 pour un exemple de prompt, et au Github du projet pour sa réponse.

9. Pour être précise, à l'Université d'Oslo, dans le cadre d'une réflexion sur l'usage de l'IA pour l'histoire.

10. Et, je le rappelle, uniquement dans leur fonction de chatbot.

3.1.4 Enjeux éthiques, moraux et intellectuels de l'utilisation des LLM

Si notre propos a tenté de s'être montré neutre, et pourrait s'interpréter par moments comme positif, à l'égard de l'utilisation des LLM tels que l'on peut les retrouver accessibles sur Internet, il convient de nuancer notre regard et souligner les problématiques que ces usages soulèvent¹¹. Ainsi, le but de cette partie tend à rappeler que l'intégration de ces technologies s'accompagne de contraintes et de risques, au-delà de ses multiples avantages.

Enjeux intellectuels et épistémologiques. Tout d'abord, le risque principal associé aux LLMs est « l'hallucination »¹², puisque ces modèles peuvent produire des énoncés faux avec la même fluidité linguistique et l'assurance que des énoncés vrais¹³ car ils reposent sur des séquences textuelles statistiquement plausibles, et non des connaissances. Dès lors, toute information générée par un modèle nécessite une vérification, et notamment dans le cadre d'une démarche scientifique.

En outre, l'usage de ces outils interroge la place de la technique dans la construction de notre objet de recherche. WANG suggère que les LLMs permettent de libérer du temps cognitif, en déléguant les tâches de « primary coding » pour se tourner vers de l'interprétation. Toutefois, je ne suis pas certaine que l'on puisse dissocier le code (plus globalement, la technique) de la construction de l'objet et de la représentation qu'il induit (et donc de l'interprétation) : les choix algorithmiques, opérations de nettoyages, métadonnées retenues, etc... participent de la manière dont on appréhende notre objet d'étude.

Aussi, cette réflexion pose la question des modalités d'apprentissage avec les LLMs : ces modèles peuvent accélérer l'acquisition de compétences opérationnelles, mais pour quelle pérennité ? et quelle est la nature de ces apprentissages ? quelle est la contrepartie de ce gain ? En effet, nous pouvons nous questionner quant à la pérennité des apprentissages et

11. Sans pour autant faire porter la responsabilité à l'utilisateur de ces technologies.

12. Le terme est discuté, et peut être perçu comme inadéquat quant à la désignation de ce phénomène. Je renvoie à OSLER 2025, qui propose plutôt une hallucination « avec » l'IA : « when we routinely rely on generative AI to help us think, remember, and narrate, we can come to hallucinate with AI » (OSLER 2025).

13. Voir par exemple <https://mitsloanedtech.mit.edu/ai/basics/addressing-ai-hallucinations-and-bias/>.

notre propre capacité à les mobiliser ultérieurement, dans le cas où cela serait nécessaire.

Sur le plan technique. Les usages présentés dans ce mémoire reposent sur des services propriétaires accessibles en ligne. Dès lors, outre la variabilité des réponses par nature des LLMs, les mises à jour des modèles et leurs éventuelles indisponibilités rend difficile la reproductibilité des résultats de prompts.

Aussi, les modèles accessibles gratuitement fonctionnent, de manière générale, sur une logique de quotas d'utilisation : tant de tokens par tranche de 5h, ou tant de pièces jointes par jour etc. Si cette limite semble pertinente en ce qu'elle invite l'utilisateur à réfléchir davantage à la formulation du prompt, elle inscrit aussi l'usage dans un modèle économique où la rareté artificielle des fonctionnalités encourage le passage à des abonnements payants.

Egalement, l'utilisation des LLMs sur ces sujets suppose aussi un niveau minimal de compétences avant de déléguer, afin de pouvoir détecter une erreur ou évaluer la pertinence d'une proposition.

Enjeux éthiques et écologiques. Les données d'entraînement sur lesquelles reposent des modèles, outre avoir été pour parties annotées et modérées par des humains à très bas coût¹⁴ questionnant notre rapport au travail, reproduisent et reflètent les inégalités, les hiérarchies et les rapports de domination présents dans les sociétés qui les ont produites : sexisme (J. Q. H. HO et al. 2025) ou racisme¹⁵ n'en sont que deux exemples, renforçant des principes de vision et division du monde dominants. Sur le plan éthique également, il convient de souligner les engagements d'OpenAI ou Anthropic sur des sujets militaires¹⁶.

Aussi, concernant les données (entraînement et produites) en elles mêmes, il convient de rappeler les questions relatives à la propriété intellectuelle et la protection de la vie privée : les interactions avec des modèles reposent sur des données dont la légalité de leur usage pour l'entraînement est questionnable, tout comme les données récupérées par la

14. Voir à ce sujet <https://www.arte.tv/fr/videos/126831-000-A/madagascar-les-petites-mains-de-l-ia/>.

15. Voir par exemple : <https://www.sir.advancedleadership.harvard.edu/articles/understanding-gender-and-racial-bias-in-ai>.

16. Avec l'armée américaine pour OpenAI (<https://openai.com/fr-FR/index/our-agreement-with-the-department-of-war/>), et Palantir pour Anthropic (<https://investors.palantir.com/news-details/2024/Anthropic-and-Palantir-Partner-to-Bring-Claude-AI-Models-to-AWS-for-U.S.-Government-Intelligence-and-Defense-Operations/>).

conversation (VANHERPE 2025¹⁷).

Enfin, l’empreinte environnementale des modèles est aussi à considérer, tant au cours de l’entraînement que lors de l’envoi de prompts (JI et JIANG 2026), puisque ces éléments sont énergivores. Si l’évaluation précise de ces impacts demeure complexe, les développements et les usages de LLMs participent aux coûts environnementaux du numérique, et se replacent, en ce sens, dans un *continuum* plus large de pratiques technologiques (précédant et dépassant les LLMs) dont les conséquences sur la planète sont déjà étudiées¹⁸. Des alternatives moins intensives en ressources existent : des modèles déployables en local tels que LLaMA ou Qwen auraient pu être envisagés dans le cadre de ce travail, notamment pour un éventuel fine-tuning, mais des contraintes matérielles ont rendu cette option impraticable¹⁹.

3.2 Du *scraping* à la base : hiérarchisation des stratégies de collecte et retours réflexifs sur un protocole de bibliométrie.

3.2.1 Du choix de nos outils

Les outils utilisés dans notre démarche de collecte et de traitement automatisé de nos objets sont des choix techniques et épistémologiques, qu’il convient d’explicitier. Le protocole décrit dans ce chapitre repose principalement sur Python, langage de programmation dont la première version a été publiée en 1991. Ce choix a été orienté par la disponibilité de bibliothèques de récupération et de traitement de données web : BeautifulSoup pour le parsing du HTML, Selenium pour la simulation de navigateur web ; mais aussi de traitements de langage naturel (Spacy) et d’apprentissage automatique (BERTopic, sentence-transformers) intervenant dans des phases ultérieures du protocole. Par la multiplicité des possibles, Python constituait un environnement cohérent pour l’ensemble de

17. Voir aussi le rapport de l’Organisation Mondiale de la Propriété Intellectuelle - World Intellectual Property Organization : <https://www.wipo.int/en/web/frontier-technologies/artificial-intelligence/index>.

18. Voir par exemple cette publication du MIT : <https://impactclimate.mit.edu/2025/03/20/investigating-the-ecological-impacts-of-data-centers/>

19. Mon ordinateur personnel ne pouvant pas supporter de telles installations.




FIGURE 3.1 – Workflow de l’acquisition, de la redocumentarisation et de l’analyse des données

la chaîne de traitement des données, langage qui était aussi enseigné dans le cadre de mes cours.

Toutefois, ce choix s’inscrit dans le cadre d’un débat plus large sur l’outillage en humanités numériques, avec par exemple les discussions autour de la dualité entre R et Python. R, également mobilisé dans le cadre de notre formation et particulièrement adapté à l’analyse statistique et aux visualisations, a été utilisé ponctuellement pour certains traitements. Sans trancher entre ces deux environnements, mon utilisation de Python découle d’une familiarité pratique acquise au fil des besoins de mon protocole, plus qu’un parti pris théorique.

Cette question s’inscrit aussi dans notre réflexion sur la reproductibilité, en ce que Python est largement utilisé et documenté, avec des bibliothèques accessibles gratuitement

et dont les codes des utilisateurs se retrouvent fréquemment sur des plateformes de partage comme StackOverflow ou Github. Ainsi, un tel outillage est préférable à des solutions propriétaires ou aux manipulations manuelles difficilement auditables. Nous verrons toutefois que cette ambition de reproductibilité se confronte, dans les faits, à des contraintes techniques et juridiques que l’outil seul ne peut résoudre.

3.2.2 Récupérer la donnée, scraper Worldcat

Rendre compte de l’intégralité des opérations, une par une, implique de suivre à la trace chaque notice. Pour récupérer la donnée sur Worldcat, nous proposons le protocole suivant, détaillé ci dessous :

1. Faire une liste de mots-clés attachés au sujet recherché²⁰ ;
2. Construire une requête booléenne à partir de ces mots clés selon les filtres souhaités ;
3. Récupérer les URLs attachés aux publications apparaissant dans les résultats du moteur de recherche de Worldcat après la requête ;
4. Visiter chaque URL et cliquer sur l’icône de téléchargement du RIS ;
5. Insérer le RIS dans une base de donnée.

La question de la récupération des données sur Worldcat²¹ a fait l’objet d’un processus intellectuel et technique itératif, en alternant phases de tests, et phases d’évaluation. Pour expliquer la démarche, suivons ci-dessous les étapes du programme de récupération.

Nous devons toutefois souligner que, compte tenu du flou juridique entourant ce type de collecte, des temps de pause substantiels ont été intégrés à chaque étape du protocole. Si ces limitations étaient relativement moins contraignantes en novembre 2025, au moment principal de la récupération des données, qu’elles ne le sont en 2026 (notamment du fait du renforcement des protections mises en place par Cloudflare), chacune des opérations décrites ci-dessous a nécessité l’introduction de délais sans requêtes adressées à WorldCat, afin de limiter la fréquence des sollicitations du serveur²². En ce sens, le protocole

20. Je renvoie le lecteur à la section 4.2 concernant le choix de ces mots.


21. Pour des raisons légales, il est impossible de fournir le programme python ayant permis une telle récupération. Toutefois, nous expliquons sa logique et les choix dans cette section.

22. Worldcat applique une limite de requêtes par adresse IP sur un laps de temps court, signalée explicitement à l’utilisateur (« Trop de demandes. Veuillez réessayer plus tard »). Cloudflare, de son côté,

décrit ne peut être reproduit à l'identique²³. De manière globale, je recommande à tout lecteur désireux de reproduire cette stratégie l'utilisation d'une machine dédiée, puisque le coût en temps augmente proportionnellement au nombre de références bibliographiques envisagées.

De la nécessité de penser les mots avant d'interroger Worldcat

Il semble impératif de construire la liste de mots-clés en amont de la requête booléenne. Exclure des termes au motif de leur faible rendement documentaire reviendrait à subordonner la définition de l'objet d'étude aux propriétés contingentes de l'indexation de WorldCat et valoriser artificiellement les espaces de forte densité documentaire. Or, l'absence de résultats constitue en elle-même une information, et participe de la structuration du champ étudié, au même titre que leur abondance. En ce qui concerne le protocole détaillé ci-dessous, je pars du principe que cette liste est déjà établie, et renvoie le lecteur section 4.2 pour saisir sa composition.



Le choix des mots

Pour obtenir une page de résultats sur Worldcat, contenant des notices, il est impératif de lancer une recherche via la barre dédiée²⁴. Si l'insertion d'un mot dans une barre de recherche peut bloquer l'accès complet pendant environ cinquante minutes après résolution d'un CAPTCHA. Ces restrictions, humainement atteignables, ont été sensiblement renforcées fin 2025 : là où il était auparavant possible de traiter une page en moins de deux secondes sans authentification, le protocole est désormais contraint à un rythme d'environ quarante requêtes par IP et par heure.

23. Le lecteur intéressé pourra se reporter au tableau comparatif en fin de section récapitulatif, pour chaque étape du protocole, les éléments reproductibles à condition que l'interface de Worldcat ne change pas fondamentalement.

24. Notons qu'il est impossible de faire une recherche vide pour afficher tout le contenu.

recherche semble transparent, cette étape répond à des logiques précises d’indexation et de structuration du catalogue, détaillé par Worldcat dans son document public *Directives et exigences pour chercher dans les index de WorldCat*, datant de 2025 : bien qu’il soit prioritairement destiné aux bibliothèques usagères d’OCLC, les informations renseignées sont pertinentes pour notre propos. Il est d’autant plus crucial d’y prêter attention lorsque la recherche porte sur des termes dont l’alphabet n’est pas latin, en cas d’accentuation, ou dans le cas de recherches plus complexes.

Choisir les mots, c’est aussi renoncer à un univers de possible non indexé par Worldcat selon ces termes : puisque la recherche n’est pas dans le fulltext, il s’agit de faire correspondre notre terme de recherche à un *keyword*, un *abstract* lorsqu’ils sont disponibles, ou, à défaut, un *title* ou un *secondary title*. Mais cette idée est en fait fausse : Worldcat semble contenir bien plus d’informations qu’il n’en laisse l’utilisateur percevoir. Premièrement, changer le préfixe dans l’URL affiche plus de résultats, et dans un ordre différent. Prenons l’exemple du simple terme barbare dans la barre de recherche, avec les URLs indiqués dans le tableau ci-dessous. Ces résultats (affichage) ne changent pas, que l’on aie un compte OCLC ou non.

	URL 1	URL 2
URL	https://search.worldcat.org/search?q=barbare&offset=1	https://search.worldcat.org/fr/search?q=barbare&offset=1
Nombre de résultats	9048 résultats selon l’indication en dessous de la barre de recherche	8200 résultats selon l’indication en dessous de la barre de recherche
Premiers résultats	<i>In defence of barbarism : non-whites against the Empire ; Barbarski šport : kritika globalne kuge ; Connie, la barbare (2) : Les bijoux du Transistan</i>	<i>La formation de l’Europe ; Rester barbare ; In defence of barbarism : non-whites against the Empire</i>

TABLE 3.2 – Comparaison des résultats WorldCat selon le préfixe d’URL

Ainsi, on constate deux choses :

- La quantité de résultats affichée en haut de la page diffère que l'on soit sur une interface française ou non : bien que ce nombre ne révèle pas exactement la disponibilité des résultats sur Worldcat, c'est un indicateur d'un ordre de grandeur ;
- L'ordre des résultats diffère aussi, bien que la méthode de tri (localisation, pertinence) n'ait pas changé.

Ces constats ne sont pas triviaux, en ce qu'ils montrent que le préfixe dans l'URL agit comme un paramètre plus ou moins implicite (car l'URL 1 ne précise même pas qu'il s'agit de l'anglais) des règles de classement. D'abord, ils faussent notre aperçu de la disponibilité des sources sur Worldcat : sur des milliers de résultats, cela ne semble pas *si* problématique, mais ils peuvent changer la manière d'aborder la recherche de manière globale (voire renoncer à de la bibliométrie, si l'on juge l'effectif « trop faible »). Le second constat touche à un autre niveau d'analyse, celui des logiques de classement et de production du sens par l'interaction entre l'utilisateur et l'interface de recherche. Si l'ordre des résultats diffère alors même que la requête, le tri, la localisation et l'accès (connecté ou non) restent constants, cela signifie que le moteur de recherche ne se contente pas de restituer un ensemble de résultats neutres, mais opère un tri selon des critères qui ne sont pas tout à fait transparents pour l'utilisateur. Les conséquences de ce phénomène sont importantes. D'une part, dans une interface où les résultats sont paginés et limités à un faible nombre d'occurrences visibles (dix par page), l'utilisateur est exposé à une représentation partielle et orientée du corpus²⁵. D'autre part, cette hiérarchisation peut produire un effet de sens : un mot-clé pourra apparaître comme fortement pertinent, ou au contraire marginal, selon les premiers résultats affichés, indépendamment de la distribution réelle des occurrences dans la base. Ainsi, l'ordre des résultats ne constitue pas seulement un enjeu ergonomique, mais un élément structurant de l'interprétation. Il peut induire un biais cognitif dans l'évaluation de la pertinence d'un terme, en particulier dans les premières phases de constitution d'un corpus. Dès lors, un requis méthodologique s'impose : ne pas limiter l'analyse aux premières pages de résultats, et, dans la mesure du possible, chercher à neutraliser ces effets de classement (par exemple en multipliant les requêtes, en variant les paramètres d'interface, ou en procédant à des extractions systématiques).

25. Je me permets d'émettre l'hypothèse que peu de visiteurs du site défilent manuellement toutes les pages.

De plus, Worldcat n'est pas tout à fait transparent dans son indexation : il n'est pas indiqué la raison pour laquelle les résultats apparaissent à l'issue d'une recherche. Un exemple pour illustrer notre propos consiste à prendre une référence apparaissant après avoir tapé « barbare » dans la barre de recherche, voire même « "barbare" ». Ainsi, prenons l'exemple de l'ouvrage *Histoire économique de la France : de la Gaule à nos jours* de Charles Serfaty (2024). Il n'est question, ni dans son titre, ni dans le nom de l'auteur, du « barbare ». Si l'on considère les mots clés attachés par Worldcat à cette notice (accessibles uniquement en ayant un compte), on constate tout autant l'absence de « barbare » ! Il en va de même pour son résumé. Pourtant, cette notice est indexée à la 3^{ème} page de résultats à la requête « "barbare" », les guillemets indiquant une recherche stricte. Si les mots-clés ne sont pas accessibles aux usagers sans compte OCLC, les raisons d'indexation d'une notice demeurent inconnues aux usagers connectés.

Ces constats étant mentionnés, et puisque notre sujet de recherche porte sur l'historiographie, il convient de préciser le contenu notre demande, en agrémentant notre requête de filtres et d'autres termes qui permettent de cadrer notre requête : des noms de périodes (« Middle Ages », « Late Antiquity »), ou des mots pour qualifier des disciplines telles qu'indexées sur Worldcat (« history », « anthropology ») ; dans le cadre de requêtes booléennes²⁶ et de filtres mis à disposition par le site²⁷.

La barre de recherche de Worldcat permet des recherches booléennes limitées, avec un maximum de nombre de mots par requêtes de 40 (*Search and use query syntax*, Worldcat, 2026). Toutefois, cette limite semble erronée, puisque ce genre de requête est impossible pour Worldcat, alors même qu'elle ne contient que 31 mots (« Impossible de traiter cette demande. Veuillez essayer des termes de recherche différents. ») :

`("barbare" OR "barbarian" OR "barbar")`

26. Les requêtes booléennes sont des commandes de recherche avancées qui utilisent des opérateurs logiques (ET, OU, NON) et des caractères spéciaux pour créer des critères de recherche précis et complexes.

27. Tel que décrit à l'adresse suivante : https://help.oclc.org/Discovery_and_Reference/WorldCat_Discovery/Search_in_WorldCat_Discovery/020Filter_search_results. Par ailleurs, il aurait été envisageable de filtrer avec la fenêtre contenant des cases à cocher à gauche de l'interface, mais elle m'était moins intuitive et moins précise quant aux requêtes que je souhaitais réaliser. Produisant les mêmes résultats, en ce que ces deux méthodes ajoutent des éléments similaires à l'URL, je retiens, pour des questions de préférence dans le programme et pour l'automatisation, la requête booléenne.

```
AND (Middle ages OR late antiquity OR medieval)
AND (su:archaeology OR su:philosophy OR su:history OR su:
    politics OR su:anthropology OR su:sociology)
```

A l'inverse, celle-ci fonctionne, alors même qu'elle est plus restrictive que la première.

```
("barbare")
AND (Middle ages OR late antiquity OR medieval)
AND (su:archaeology OR su:philosophy OR su:history OR su:
    politics OR su:anthropology OR su:sociology)
```

En somme, à en croire l'expérience, la limite de nombre de mots, ou du moins d'opérateurs booléens se situe au niveau de la première requête, soit 31 mots et 11 opérateurs.

Worldcat permet d'insérer des filtres directement dans les requêtes, avec les préfixes comme : le sujet **su:**, le mot clé **kw:**, l'année **yr:**, le titre **ti:**. D'autres options sont disponibles, comme la possibilité d'utiliser un opérateur de proximité ou de cooccurrence si notre recherche porte sur des *n-gram*.²⁸ Notons toutefois que si Worldcat nous permet d'insérer ces options dans la barre de recherche directement, il est aussi possible de passer par l'interface sur la gauche de l'écran nous permettant de sélectionner les filtres. Dès lors qu'un filtre est appliqué, il ne modifie pas notre requête dans la barre de recherche, mais l'URL en haut de la page. Prenons l'exemple de la requête simple « barbare » avec et sans filtre :

- Sans filtre : <https://search.worldcat.org/fr/search?q=barbare>
- Avec filtre « Histoire et sciences auxiliaires » : <https://search.worldcat.org/fr/search?q=barbare&topic=28000000>

En outre, il faut aussi choisir la langue des mots pour chaque mot-clé que retenu dans notre liste. De ce fait, nous avons segmenté notre liste de mots-clés en anglais, français, italien, espagnol et allemand — les mots-clés en latins étant agrémentés de termes en anglais. Par exemple :

- en anglais : "barbarian" AND ("Middle ages" OR "Late antiquity" OR "medieval")
- en français : "barbare" AND ("Moyen Age" OR "Antiquité tardive" OR "médiéval")

28. Je renvoie ici à l'ensemble de la documentation d'OCLC, et en particulier la *Librarians' Toolbox*, dans la section *Searching WorldCat Indexes*, https://help.oclc.org/Librarian_Toolbox/Searching_WorldCat_Indexes.

Ainsi, par ajustements et itérations, nous avons décidé de retenir un cadre épistémologique large, et un filtre minimal : la restriction aux seules publications *peer-reviewed* réduisait notre échantillon de **barbare** AND Moyen âge à 5 résultats²⁹, ce qui ne pouvait prétendre à une étude bibliométrique de la production historiographique.

Requête complète	Filtres	Résultats
kw:barbar* AND (kw:Middle age OR kw:medieval OR kw:late antiquity)	Aucun	3 579 ^a
kw:barbar* AND (kw:Middle age OR kw:medieval OR kw:late antiquity)	<i>Peer-reviewed</i>	261 ^b
kw:barbare AND (kw:Moyen age OR kw:medieval OR kw:Antiquité tardive)	Aucun	58 ^c
kw:barbare AND (kw:Moyen age OR kw:medieval OR kw:Antiquité tardive)	<i>Peer-reviewed</i>	0 ^d

Tests effectués le 13 avril 2026.

^a https://search.worldcat.org/fr/search?q=kw%3Abarbar*+AND+%28kw%3AMiddle+age+OR+kw%3Amedieval+OR+kw%3Alate+antiquity%29&offset=1

^b https://search.worldcat.org/fr/search?q=kw%3Abarbar*+AND+%28kw%3AMiddle+age+OR+kw%3Amedieval+OR+kw%3Alate+antiquity%29&peerReviewed=true

^c <https://search.worldcat.org/fr/search?q=kw%3Abarbare+AND+%28kw%3AMoyen+age+OR+kw%3Amedieval+OR+kw%3AAntiquité%29&offset=1>

^d <https://search.worldcat.org/fr/search?q=kw%3Abarbare+AND+%28kw%3AMoyen+age+OR+kw%3Amedieval+OR+kw%3AAntiquité%29&peerReviewed=true>

TABLE 3.3 – Impact du filtre *peer-reviewed* sur la volumétrie des résultats.

Pour la racine **barbar***, l'activation du filtre réduit le corpus de plus de 90 %, et la recherche francophone (**kw:barbare**) tombe à zéro résultat une fois filtrée. Ce constat suggère que WorldCat n'identifie pas comme « scientifiques » de nombreuses revues d'histoire ou d'archéologie européennes qui pratiquent pourtant l'évaluation par les pairs, mais dont les métadonnées ne sont pas explicitement taguées comme telles dans l'index d'OCLC. De

29. Selon l'interface, chiffre dont nous verrons ultérieurement la faible fiabilité (en 3.2.2)

plus, si comme relevé plus tôt, l'ordre des résultats diffère, alors nous observons immédiatement une divergence dans les résultats affichés, ne permettant pas de savoir au premier coup d'œil si les deux ensembles sont sécants.

Ces quelques éléments permettent d'illustrer plusieurs choses. D'abord, les requêtes booléennes ne sont pas une nécessité : elles permettent de filtrer *a priori* les résultats, sans garantir la suppression totale du bruit. Elles peuvent être pertinentes dans le cas de mots dont le sens commun s'éloigne de celui recherché ; mais une marge de tolérance est impérative en raison de la limitation technique imposée par le nombre d'opérateurs et de mots dans une seule requête. Ces limites ne semblent pas influencer les filtres, qui se greffent à l'URL : ainsi, dans un souci d'économie, nous invitons à considérer dans les requêtes booléennes uniquement les termes souhaités sous forme de *n-grams*, et conserver les questions de date, de type de document, d'auteur et de sujet (discipline) pour l'URL. Ensuite, il est impératif de tester via l'interface les différentes possibilités de filtre, en ce que nous n'avons trouvé, pour les besoins de la présente recherche, aucune liste exhaustive des sujets possibles et leur codes correspondants. C'est par ces expérimentations successives que se construit l'URL finale d'interrogation de WorldCat, ce qui souligne la nécessité d'une démarche itérative dans l'élaboration du protocole de recherche.

Pour notre propos, nous avons utilisé l'URL suivante afin de filtrer les articles (tous confondus), puis les articles *revus par les pairs*. Cette distinction est cruciale, car ce que Worldcat considère comme des « articles scientifiques » se limite très rapidement, et n'intègre pas toutes les formes d'autorat possible. Les deux formes de requêtes utilisées sont les suivantes :

- Une première pour inclure les articles, les chapitres d'ouvrages et les contenus numériques associés, sans le contenu pour les plus jeunes (bandes dessinées, romans) :
`https://search.worldcat.org/fr/search?q=barbare&quickLink=artchap&audience=nonJuv&itemType=artchap&itemSubType=artchap-artcl%2Cartchap-chptr%2Cartchap-digital`
- Une seconde pour les articles évalués par leurs pairs, avec cette fois-ci moins de filtres, car la caractéristique `peer-reviewed` est déjà restreinte : `https://search.worldcat.org/fr/search?q=barbare&peerReviewed=true&audience=nonJuv`

Une fois les filtres choisis, en travaillant par tests successifs, la recherche des publications pouvait commencer.

La récupération des URLs

À chaque requête, l'interface affiche une liste de résultats : si le nombre de résultats total, tel qu'annoncé en dessous de la barre de recherche, varie significativement d'une recherche à l'autre, le nombre de résultats par page demeure de 10. Ainsi, nous ne pouvons visualiser les publications liées à cette requête uniquement 10, par 10. Chaque résultat se présente sous la forme d'un bloc cliquable, affichant des informations minimales sur la publication : titre, auteur, début du sommaire s'il y en a un, type de publication, titre secondaire (titre du livre dans le cas d'un chapitre, titre de la revue dans le cas d'un article), et « éditeur » qui s'apparente davantage à une date de publication. Ces données, restreintes³⁰, sont enrichies dès lors que l'on clique sur le titre de la publication, contenant un lien renvoyant l'utilisateur à la page web dédiée à la publication.

De ce fait, il était nécessaire d'envisager une stratégie qui allait plus en profondeur que la récupération de la liste de résultats. La méthode envisagée repose alors sur la récupération des URLs, page après page, affichées dans les blocs cliquables à l'issue de la requête : cela s'appuie sur l'idée que les publications affichées sont uniquement celles répondant à notre requête, ce qui n'est pas évident, mais intuitif du point de vue empirique par l'affichage, parfois, de « Aucun résultat trouvé », et « Relancez votre recherche en inscrivant des termes différents, ou sélectionnez des filtres différents. » sur la page web.

Au delà du lien vers la publication, l'URL permet aussi de récupérer le numéro OCLC : chaque URL est composée du préfixe de worldcat et de l'identifiant. Ainsi, en dépit de la non-pérennité des URLs, susceptibles d'évoluer avec les mises à jour de la plateforme, ce numéro représente la solution la plus efficace, en termes de rapport bénéfice/temps, pour identifier et désambiguïser les notices de manière systématique.

Ce processus s'est déroulé en trois étapes successives :

1. Détecter le nombre de résultats affichés en dessous de la barre de recherche pour calculer le nombre de fois qu'il faut changer de page ;

30. Restreintes, car elles sont d'autant plus réduites que celles que nous avons pu récupérer avec le RIS : il manque le doi, la langue, la base de données, pages,...

2. Récupérer les 10 résultats sur la page ;
3. Passer à la page suivante.

Afin de récupérer ces URLs, Selenium (avec Geckodriver) a été utilisé, puisque Worldcat repose sur une architecture en HTML et en Javascript, rendant son interface dynamique et dépendante de l'environnement de l'utilisateur. Une requête HTTP (requests) ne suffit donc pas à restituer le contenu de la page ; il est nécessaire de simuler une visite réelle du site, ce qui ralentit sensiblement le protocole. En outre, j'ai pu noter que le plus souvent, lorsque de nombreux résultats étaient affichés en haut de la page, la réalité des URLs accessibles était bien moindre : des différences de quelques notices, à quelques milliers étaient parfois observables !

Les URLs ainsi récupérés sont stockés dans des fichiers textes (.txt), nommés d'après le mot-clé ayant déclenché la requête. Ce dispositif présente un avantage analytique non négligeable : lorsqu'une même notice apparaît pour plusieurs mots-clés distincts, il devient possible de lui associer de 1 à N termes d'entrée, esquisant ainsi une resémantisation minimale *a posteriori*. L'identifiant OCLC, bien que non interopérable avec d'autres bases de données permet de reconstruire, par intersection entre ensembles de résultats, une sémantique approximative des notices, en l'absence d'accès direct à leurs mots-clés d'indexation.

Toutefois, nous tenons à rappeler que récupérer de tels liens revient à recueillir ce que la plateforme a affiché, à un moment donné, depuis une machine donnée, selon des critères de classement non entièrement transparents pour l'utilisateur (ce qui n'est pas nécessairement l'équivalent du catalogue d'OCLC indexé pour ces mots). Le corpus ainsi constitué est par nature un instantané, figé à la date du scraping, alors même que l'objet qu'il tente de saisir est évolutif : tant l'historiographie, que les notices en elles mêmes qui sont modifiées, supprimées, réindexées.

Ainsi, ces URLs permettent de localiser des notices dans Worldcat, mais pas encore d'en restituer le contenu : l'étape suivante consiste donc à visiter chacune de ces pages pour en extraire la notice bibliographique complète, sous un format structuré et interopérable.

Récupérer les RIS

À partir des identifiants OCLC collectés, il est possible de reconstituer une liste d'URLs unique pour chaque notice et de les visiter de manière séquentielle. Une étape de dédou-

blonnage s'impose préalablement. Si le fait qu'une même notice ait été récupérée pour plusieurs mots-clés distincts est pertinent pour notre sémantisation, un dédoublonnage s'impose concernant les visites au serveur pour ne pas alourdir le protocole.

Worldcat offre, pour les utilisateurs connectés, la possibilité de constituer des listes de notices (dans la limite de cinquante listes de cinq cents entrées), et de les exporter. Cette solution a été écartée pour deux raisons : d'abord car elle est réservée aux utilisateurs authentifiés, ce qui contrevient à la posture d'ouverture et de reproductibilité que je cherche à maintenir, et d'autre part, ces exports tronquent l'information disponible : seuls six champs sont restitués (numéro OCLC, titre, auteurs, langues, type de document, éditeur), au prix de la perte du titre secondaire, du DOI, etc., autant d'éléments pertinents pour l'analyse bibliométrique envisagée.

En arrivant sur la page d'une publication, plusieurs choix s'offre à l'utilisateur souhaitant obtenir davantage d'informations. D'un côté, en se connectant³¹, il était possible de déplier le menu « voir plus » afin d'afficher les mots-clés, le sujet, la langue, l'éditeur, et autres informations. De l'autre, l'utilisateur peut cliquer sur le bouton de citation à gauche de l'écran et choisir un format de citation, ou l'exporter directement en RIS. Compte tenu de notre posture, consistant à adopter celle d'un utilisateur déconnecté, nous avons privilégié la récupération du RIS.

Ainsi, page après page, un programme clique sur l'icône de citation, puis de téléchargement, jusqu'à épuisement des numéros OCLC collectés.

Comme nous l'avons vu section 2.2, la citation se différencie de la description exhaustive du document par son appauvrissement notable. En outre, ce geste a aussi des conséquences vis-à-vis de la question de la temporalité : puisque cette étape est la plus coûteuse en temps du protocole (6 secondes par notice au minimum pour cliquer sur « citer » puis « télécharger le RIS »), elle peut s'étaler sur plusieurs jours et les notices ne sont pas exemptes de modifications pendant ce temps. Par ailleurs, en raison du blocage Cloudflare, les limitations sont telles qu'il s'agit de l'étape la moins transposable de notre protocole : au bout de plus ou moins 20 RIS, il est impératif de changer d'IP et de navigateur, ou, à défaut, patienter une heure. N'ayant pas de VPN (Virtual Private Network) permettant

31. Cette observation n'est pas valide aujourd'hui, le 23/05/2026. Elle l'était auparavant : l'utilisateur devait se connecter pour afficher les mots-clés, la langue, l'éditeur etc.

de changer notre IP à volonté, et les solutions gratuites (utilisation de Tor) étant systématiquement bloquées, la seule alternative était l'utilisation d'un partage de connexion via un téléphone, en activant-désactivant le mode avion pour réinitialiser l'IP. Cette solution n'étant pas optimale, nous suggérons vivement l'usage d'un VPN pour reproduire cette étape. De plus, si ce geste nécessite la bibliothèque python pyautogui pour cliquer sur les boutons successivement, cela pose question en termes de reproductibilité, puisque les images à adapter dépendent du moniteur sur lequel le navigateur est projeté.

Par ailleurs, nous devons souligner l'hétérogénéité des RIS récupérés, rendant difficile la comparaison entre toutes les notices et conditionnant l'analyse possible sur le corpus. Pour illustrer notre propos, nous pouvons prendre l'exemple du *Digital Object Identifier* (DOI), qui n'est rempli que pour 21137 documents sur les 35158 de notre base, sans compter les DOI invalides, alors même que celui-ci est le point d'accès vers l'analyse d'une quantité plus importante de métadonnées, voire du plein texte. À ce stade, nous pouvons nous demander ce que Worldcat offre *effectivement* dans ce RIS. Le tableau 7.1, page 264 rend compte de l'état des données après la récupération. Le remplissage systématique de DB, TY et LK s'explique par le fait qu'il s'agit du minimum d'informations pour Worldcat lui-même, à savoir Worldcat, le type de document indexé, et le lien vers la notice porteuse du numéro OCLC du document. Pour le reste, ces champs sont remplis au bon vouloir des bibliothèques partenaires : sont ainsi visibles une importante hétérogénéité et des manques substantiels (résumé, mots-clé). Aussi, les RIS sont particulièrement minimaux et formalisés, puisque parmi les 69 possibles (et ce, dès 2011), les notices récupérées se résument à un tiers des possibles (23 balises), dont certaines ne sont presque jamais remplies, réduisant les descriptions à 17 balises si l'on seuille à 5 %.

Du fichier texte à la base de données : le transfert des RIS avec rispy

Une fois l'intégralité des fichiers RIS récupérés, ceux-ci sont parsés à l'aide de la bibliothèque python rispy : les champs, devenus des dictionnaires pythons, sont ensuite versés dans la base de données locales, devenant des attributs de chaque entité.

Pour des raisons expliquées en section 3.3, les auteurs ont été extraits des notices dans une table séparée, puisqu'un même auteur peut être lié à N publications, et une publication à N auteurs. Ainsi, l'auteur devient une entité autonome plutôt qu'un attribut d'une publication, que l'on peut enrichir. Ce procédé a été reproduit pour les mots-clés,

puisque une publication peut être apparue dans plusieurs résultats de recherche.

Équivalences entre les balises RIS et les champs de la base de données

Balise RIS	Libellé	Champ MySQL
TY	Type de référence	type_of_reference
TI	Titre	title
T2	Titre secondaire	secondary_title
PY	Année	year
LA	Langue	language
SN	ISSN / ISBN	issn
SP	Pages	start_page
VL	Volume	volume
IS	Numéro	number
PB	Éditeur	publisher
DB	Base source	name_of_database
DO	DOI	doi
LK	Lien notice	link
UR	URL ressource	url
<i>Champs absents du RIS, produits en plus</i>		
—	Horodatage d'insertion	date_added
—	Horodatage de modification	date_modified

Ce passage, du RIS à la base de données, substitue à la pluralité des notices et leur éventuelle hétérogénéité (nombre de balises présentes, nombre de balises effectivement remplies) une homogénéité construite par le schéma relationnel, étant le premier modèle choisi (section 3.3) : certains champs sont normalisés (nettoyage, comme nous le verrons section 3.2.3), attributs retenus, et les relations entre les tables sont en ce sens des prises de position sur notre objet.

Traçabilité, audit et reproductibilité du protocole

Le tableau 3.4 résume les points de notre protocole et leur potentiel quant à leur reproductibilité dans le cadre d'une recherche ultérieure.

Étape		Reproductibilité	Conditions et limites
Liste de mots-clés	Oui		Démarche documentée et transposable. L'opacité de l'indexation de Worldcat implique toutefois qu'une liste identique ne produira pas nécessairement des résultats identiques.
Requête booleenne	Sous conditions (faible coût)		Reproductible si l'interface de Worldcat et la syntaxe des filtres d'URL ne changent pas. Les codes de sujet (<code>topic=</code>) ne sont pas documentés exhaustivement par OCLC.
Récupération des URLs	Difficile sur gros corpus		Selenium et geckodriver requis. Le rythme est contraint à environ quarante requêtes par IP et par heure depuis fin 2025 ; une machine dédiée et un VPN sont recommandés.
Récupération des RIS	Inenvisageable sur gros corpus		Étape la plus coûteuse en temps (6 s minimum par notice) et la plus exposée au blocage Cloudflare (environ 20 RIS avant réinitialisation d'IP nécessaire). <code>pyautogui</code> dépend de la résolution du moniteur utilisé.
Transfert en base de données	Oui		Reproductible à partir des fichiers RIS obtenus. Les choix de modélisation sont documentés dans la section précédente.

TABLE 3.4 – Traçabilité et reproductibilité du protocole de collecte, étape par étape.

3.2.3 Nettoyage, normalisation, uniformisation : un requis nécessaire pour les opérations bibliométriques et analytiques

Nettoyage des données et normalisation

Comme rappelé par BEALL, la qualité des données fournies par Worldcat est variable : si certaines notices sont correctement parsées et ont des champs fournis, d'autres sont parcellaires, voire bruitées. « Nettoyer » les données implique de décider de ce qui relève du bruit, et ce qui, au contraire, est pertinent pour notre propos : certains artefacts relèvent des conditions de production des notices, d'autres sont des résidus techniques lors du transfert entre les systèmes (voir section 2.1.3). En nettoyant, nous lisons davantage l'hétérogénéité de la source (davantage, par rapport à leur première insertion dans une base de donnée), mais ce choix procède d'une condition de possibilité de l'analyse bibliométrique et lexicométrique. Toutefois, notre protocole tient à conserver, dans l'entité (ou le document) de notre base de données, la trace : tout le contenu des fichiers `.txt` a été, pour chaque notice, pris comme valeur pour le champ `raw_ris`. Je renvoie au dossier `Chapitre_3` du Github pour rendre compte des scripts python procédant à ce nettoyage semi-automatisé. Les problèmes rencontrés se distribuent en plusieurs groupes, dont nous proposons ci dessous la nature et les décisions de traitement opérées.

Balises HTML et entités non décodées. D'abord X% des notices (au minimum) présentaient des anomalies dont nous supposons qu'elles sont liées au transfert des métadonnées entre systèmes d'information : balises HTML non filtrées (`<i>`, `<span>`, `<sup>`... avec 324 concernés) et entités non décodées (`&`, `ö`... avec 82 concernés) apparaissant dans les champs `title`, `secondary_title` et dans quelques noms d'auteurs (13 concernés)³².

Si ces artefacts disent quelque chose de la manière dont ils sont décrits, ils ne me semblaient pas pertinents pour appréhender le document dans la mesure où ils les rendaient difficilement comparables avec les autres. Pour les champs de la table `reference` (donc `title` et `secondary_title`) et les `NomComplet` des `authors`, un programme de nettoyage a appliqué séquentiellement : le décodage des entités HTML, la suppression des balises résiduelles, la normalisation des apostrophes doublées et des espaces multiples.

32. Pour les identifier, une requête SQL (Structured Query Language) avec ces expressions régulières suffisait pour enlever le plus important.

Artefacts de concaténation : DOI dans des champs inappropriés et auteurs fusionnés. Un second groupe de problèmes détecté relève d’une concaténation de valeurs dans un même attribut mais qui, logiquement, auraient du appartenir à des champs différents. Certaines notices présentaient des DOI insérés directement dans les champs `title` ou `secondary_title`, sous des formes variées (`doi:10.xxxx/...`, `info:doi/...`, URL complète). De même, plusieurs entrées de la table `authors` présentaient des noms fusionnés par une esperluette (`Dupont, Jean & Martin, Paul`), indiquant que plusieurs auteurs distincts avaient été concaténés en une seule valeur lors de l’import. Ces éléments suggèrent soit que les champs étaient déjà mal structurés dans la notice initiale, soit que l’export en RIS n’a pas correctement fonctionné quant à la séparation des champs.

Pour ces cas, puisqu’il s’agissait non seulement de suppression mais aussi de déplacement de données d’un champ à l’autre, le processus automatisé a été davantage décomposé. Pour les DOI concaténés, un programme d’extraction a d’abord identifié et isolé les identifiants à l’aide d’expressions régulières couvrant les formes attestées dans le corpus, puis les a versés dans un fichier intermédiaire avant insertion dans la colonne dédiée `doi` : cette étape intermédiaire, conservée, permet d’auditer les extractions effectuées, mais aussi tester le processus avant une implémentation totale et l’éventuelle suppression de valeurs qui n’auraient pas dû l’être. Pour les auteurs fusionnés, le traitement a consisté à créer les entrées individuelles manquantes dans la table `authors`, à transférer les liens de co-autorat de la table de liaison `ecriture`, puis à laisser temporairement³³ les auteurs originels dénués de toute publication dans la table `authors`.

Ponctuation et mise en forme. Une troisième catégorie, plus marginale, concerne des indicateurs de mise en forme présents dans le champ `title` : points initiaux (`. Titre`), deux-points initiaux (`: Titre`) ou crochets encadrant le titre (`[Titre]`). Ces caractères ont été supprimés dans une logique de normalisation comparative : l’hypothèse retenue était qu’ils ne faisaient pas partie du titre de la publication à proprement parler, mais constituaient des conventions de catalogage hétérogènes introduisant davantage de bruit lors des comparaisons de chaînes de caractères. Ainsi, une notice telle que `[Medical writings on the plague in the Middle Ages in Sweden]` deve-

33. Car ceux-ci ont finalement été supprimés.

Enfin, une part marginale du nettoyage a été effectuée manuellement, notamment lorsque les cas ne permettaient pas, dans leur minorité numérique, d'identifier de règle généralisable à programmer. Par exemple, il s'agit des cas où les titres étaient anormalement longs, étant souvent des recensions dont les titres ont été concaténés les uns aux autres³⁵ ; ou encore des situations identifiées à la marge, en parcourant notre base de données (pour nos auteurs par exemple, seul « Rodrigues, Jorge [Manuel de Oliveira] » avait de tels caractères dans son nom). Ces interventions suggèrent par ailleurs que l'automatisation totale d'un tel protocole, pourtant nécessaire sur un corpus de 35 000 notices, n'est pas intégralement substituable à notre regard sur les cas limites et les éléments rares.

L'ensemble de ces opérations permet d'homogénéiser le corpus selon des critères précis, même si des nettoyages manuels, à la marge, ont été faits. Facilitant la comparaison entre les entités, ce nettoyage était une étape importante avant de pouvoir dédoublonner notre base de données.

Dédoublonnage des références, dédoublonnage des auteurs

Si, de prime abord, nous pouvions penser que les doublons relevaient de cas isolés, gérés en grande partie par Worldcat³⁶, concernant quelques références, il s'avère que leur

34. Cependant, si ce protocole était à refaire, je crois qu'il conviendrait d'agir plus finement ici. En effet, certains cas, et en particulier les crochets, sont des traces d'une traduction du titre original, impliquant qu'il aurait fallu différencier ceux-ci des crochets relevant du bruit. Cette distinction n'a pas été opérée ici faute d'avoir identifié cette convention en amont du traitement.

35. Pour illustrer notre propos, voici l'un des titres les plus longs (pas le plus long, pour ne pas alourdir davantage la quantité de texte de cette note : « Urban development in England - Anne Dodd (ed.). Oxford before the University : the Late Saxon and Norman archaeology of the Thames crossing, the defences and the town (Thames Valley Landscapes Monograph 17). xviii+477 pages, 140 figures, 53 photographs, 69 tables. 2003. Oxford : Oxford Archaeology ; 0-947816-78-X hardback £19.95. - Michael J. Jones, David Stocker & Alan Vince (ed. David Stocker). The city by the pool : assessing the archaeology of the city of Lincoln (Lincoln Archaeological Studies No. 10). viii+424 pages, 314 figures & tables, 43 colour figures. 2003. Oxford : Oxbow ; 1-84217-107-0 hardback £29.95. - Nigel Baker & Richard Holt. Urban growth and the Medieval Church : Gloucester and Worcester. xviii+413 pages, 80 figures, 7 tables. 2004. Aldershot : Ashgate ; 0-7546-0266-4 hardback £75 »

36. « La meilleure version d'une notice : L'équipe de qualité WorldCat entretien et contrôle le logiciel Duplicate Detection and Resolution (DDR) , un logiciel qui examine les notices WorldCat pour détecter

détection et suppression a concerné quelques milliers de notices : entre la base d'origine et la base dédoublonnée, ce sont près de 5 000 références qui ont été supprimées (de 40 091 à 35 158 notices), et plus de 6 000 auteurs (de 34 535 à 28 503).

Le protocole retenu consiste à procéder du plus certain, au plus approximatif quant à l'identification des doublons : d'abord les identifiants uniques, puis les métadonnées textuelles, enfin une passe permissive destinée à capturer les cas résiduels. Aussi, le dédoublonnage des publications a délibérément précédé celui des auteurs, car il était plus facile de statuer sur le fait que deux notices bibliographiques soient les mêmes (dont on disposait de l'année, du titre, éventuellement de l'éditeur) que sur ce fait concernant deux personnes, qui se réduisaient souvent à un nom et un prénom.

Le dédoublonnage des publications Le premier critère utilisé pour dédoubler les publications a été le DOI, identifiant unique et pérenne propre à chaque publication : ainsi, si deux notices partageaient un même DOI (après normalisation et nettoyage), nous considérons qu'il s'agit de doublons. La notice conservée était alors celle ayant le plus de champs renseignés, et les champs de disponibilité³⁷ fusionnés par valeur maximale, avant la suppression du doublon. Toutefois, puisque nous ne sommes pas certains de la qualité des DOI renvoyés par Worldcat, une sécurité à l'automatisation a été conservée : en cas d'écart d'années supérieur à un an pour un même DOI, un conflit était signalé, le cas étant jugé trop ambigu pour une suppression automatique.

Toutefois, puisque toutes les publications n'ont pas de DOI (20 891 renseignés après nettoyage), un second critère de dédoublonnage retenu était l'ISSN (*International Standard Serial Number*), code à huit chiffres identifiant les publications en série. Moins discriminant, puisqu'il enregistre le périodique ou la revue dans lequel est publié l'article, les doublons éventuels ont fait l'objet d'une vérification après regroupement.

Pour les références sans ces identifiants, le dédoublonnage a été permis par des calculs de similarité textuelle des titres, calculée par la distance de Levenshtein³⁸ Ce calcul n'a et fusionner les doublons. En plus de l'utilisation de ce logiciel, l'équipe de qualité WorldCat identifie et fusionne les doublons manuellement selon le cas. », disponible à l'adresse suivante : <https://www.oclc.org/fr/worldcat/cooperative-quality.html>.

37. Par là, nous entendons la disponibilité sur une base de données permettant l'accès au texte de la publication : JSTOR, Persée, Cairn. Comme nous le verrons, nous avons fait le choix d'utiliser un 0 ou un 1 pour signifier la disponibilité, le premier pour non, le second pour oui.

38. Distance permettant de mesurer la différence entre deux chaînes de caractères. « Elle est égale au

pas été appliqué directement à l'ensemble de la base, car une comparaison exhaustive des 40 000 titres deux à deux aurait conduit à un nombre de comparaisons quadratique, de l'ordre de $\frac{n(n-1)}{2}$, soit près de 8×10^8 comparaisons potentielles. Ainsi, des filtres successifs ont été mis en place pour réduire ces comparaisons : regroupement d'abord par année exacte, puis par titre secondaire et, enfin, comparaison des titres principaux avec vérification qu'au moins un auteur était commun entre les deux notices³⁹. De ce programme découlent également des variantes : sans auteurs pour les publications qui n'en ont pas renseigné, en convertissant les numéros de chapitre pour ne pas pénaliser la similarité...

Enfin, afin de vérifier si quelques doublons subsistaient, nous avons étendu la détection de manière permissive : références sans titre secondaire, références sans année, et paires dont l'un des titres est littéralement contenu dans l'autre (détection par contenance, indépendamment de la distance). Ces candidats, potentiellement nombreux et bruités, ont été soumis à vérification manuelle avant toute fusion.

Cependant, pour les dernières méthodes impliquant des distances textuelles, il convient de signaler que le temps de calcul n'est pas une question triviale. Sur l'ordinateur principalement utilisé pour la présente recherche, seuls 8 Gigaoctets de mémoire vive sont disponibles, dont une bonne partie est déjà prise par le simple fonctionnement du système d'exploitation Windows ; d'où les stratégies de réduction des calculs à faire.

Le dédoublonnage des auteurs Cette étape a été pensée pour suivre celui des publications, puisque statuer sur des données plus complètes (au sens de, plus de champs renseignés pour discriminer) était souvent plus aisé que de trancher entre deux individus qui, pour la plupart, étaient réduits à un nom et un prénom. Nom et prénom soulèvent par ailleurs un problème central, qui n'est pas inconnu aux démarches d'enquête sur d'autres sources : l'onomastique. Dans le cas de nos sources, cette question apparaît sous la forme de graphies distinctes, d'inversions, d'initiales : « Dupont, Jean » et « Dupont J. » ou encore « Jean Dupont », ou la présence de la graphie d'origine (cyrillique, arabe, hébreu)

nombre minimal d'opérations nécessaires pour transformer une chaîne de caractères en une autre, à l'aide des trois opérations autorisées : remplacement, suppression et ajout » (https://fr.wikipedia.org/wiki/Distance_de_Levenshtein).

39. La transitivité des similarités (le fait que A ressemble à B et B à C n'implique pas nécessairement que A et C soient des doublons) a été prise en compte via un regroupement itératif des éléments similaires en composantes de doublons.

accompagnée, dans la même entité ou une autre, de sa translittération.

La résolution de la question de l’onomastique ne peut se faire qu’après avoir enrichi et redocumentarisé nos notices bibliographiques, en réconciliant des référentiels d’autorité (IdRef, VIAF), comme nous le verrons dans la section suivante 3.2.4 : des auteurs portant le même identifiant, numéro censé leur être unique, sont automatiquement considérés comme des doublons, et ce, indépendamment des caractéristiques textuelles dont nous disposons sur eux. En cas de conflit entre identifiants au sein d’un même groupe (deux valeurs différentes pour un même champ), le groupe est signalé et écarté de la fusion automatique. Toutefois, en attendant l’enrichissement et surtout, dans la mesure où tous nos auteurs n’ont pas d’identifiants au final, des protocoles de dédoublonnage par similarité textuelle ont été mis en place de la même manière que pour nos références (succession de filtres). Cette démarche est aussi permise par la connaissance préalable, et acquise, du champ étudié : certains noms me sont connus, et l’on peut supposer qu’il n’existe *a priori* pas d’autres auteurs portant le même nom publiant sur le même sujet (à titre d’exemple, « Ian Wood » et « I. Wood », ou « Wood, Ian » sont sans doute la même personne) ; mais aussi sur une approche empirique de la fréquence des noms, l’hypothèse étant qu’un patronyme rare ou complexe est plus aisément attribuable à un unique chercheur.

D’abord, le premier dédoublonnage repose sur une correspondance exacte du nom normalisé : mis en minuscule, suppression des accents et de la ponctuation. Deux auteurs dont le nom normalisé est identique sont ainsi regroupés, et susceptibles d’être des doublons. Puis, la recherche est élargie avec le calcul d’une distance de levenshtein, insensible à l’ordre nom-prénom. Ensuite, une troisième itération du dédoublonnage vise à appliquer, un calcul de similarité des noms et une correspondance par initiale de prénoms, permettant de rapprocher « Pohl, Walter » et « Pohl, W. », en vérifiant que le prénom de l’une des entrées constitue bien un préfixe de l’autre (le tri préalable par nom de famille réduisant le nombre de comparaisons à effectuer). Enfin, puisque cela ne concerne qu’une partie réduite de nos auteurs (716 auteurs non dédoublonnés) un dernier script s’occupe des translittérations : les noms écrits en alphabet non latin sont translittérés avant comparaison par distance de Levenshtein.

Comment évaluer la qualité de notre protocole ? En l’absence de vérité terrain (une liste de tous les doublons), il est impossible de mesurer la quantité de doublons. Nous pouvons toutefois l’approximer, avec la construction d’un intervalle de confiance

entre deux états de notre base : l'originale, et la dédoublonnée.

Pour le premier, il s'agit de notre base telle que constituée à partir des fichiers RIS, sans opération de dédoublonnage préalable. Le second résulte quant à lui d'un dédoublonnage large, éliminant tous les potentiels doublons (même lorsqu'ils ne s'agissaient pas de vrai doublons) reposant sur une distance de Levenshtein entre les titres normalisés. Entre ce dédoublonnage plus strict et l'état initial de notre base se trouve un intervalle de confiance dans lequel nous pouvons considérer que le travail de dédoublonnage effectué semble suffisant pour l'usage fait (figure 3.2).




FIGURE 3.2 – Intervalle entre la base de données d'origine (RIS) et celle dédoublonnée automatiquement. Notre base se situe entre les deux, dédoublonnée semi-automatiquement.

Pour chaque année entre 1975 et 2025, la courbe haute représente la base originale, et celle basse la base dédoublonnée par le script. Les années en dehors de cet intervalle sont signalées (voir figure 3.2).

Cette méthode permet d'évaluer, de manière approximative, notre dédoublonnage, par son inscription dans un intervalle pris entre deux extrêmes ; mais cela ne prouve pas l'exactitude de notre protocole. En outre, nous n'évaluons pas ici les auteurs, pour lesquels la construction d'un tel intervalle serait plus délicat.

3.2.4 Enrichissement des données, redocumentarisation

Nous avons eu l'occasion de décrire les sources mobilisées pour l'enrichissement dans la section 2.3 : notre propos développe ici le protocole pour chacune d'entre elle sans revenir sur leur définition. Pour des raisons pratiques, sont distingués comme précédemment les auteurs des publications, même si certaines bases sont tout aussi pertinentes pour l'un, que pour l'autre (comme Google Scholar par exemple). Toutefois, pour des raisons légales, tous les protocoles ne peuvent être fournis.

Les auteurs

Référentiels d'autorité : une source idéale, mais non suffisante. Les référentiels d'autorité constituent a priori la source la plus fiable pour récolter des informations sur les auteurs de notre corpus : les notices sont produites et contrôlées, selon des normes stabilisées. Ainsi, ont été mobilisés, de manière légale, deux référentiels et Wikidata.

D'abord, IdRef dispose d'une API publique permettant d'interroger les notices au format JSON ou XML (*extensible markup language*) : d'abord, pour demander une liste des identifiants répondant à notre requête de Nom et Prénom pour un auteur, puis pour récupérer les publications associées à cet identifiant. La démarche d'identification mise en oeuvre repose sur une comparaison par distance de Levenshtein entre les titres des publications associées à un auteur en base locale et les œuvres référencées pour chaque candidat PPN : si le score dépasse un seuil fixé empiriquement à 0,8, le candidat est validé (stopnant ainsi la boucle pour chercher ce candidat et, pour chaque auteur, est testé un maximum de 10 notices). Au total, 3 142 auteurs ont pu être identifiés par cette voie.

Une autre manière d'interroger les référentiels d'autorité consiste à récupérer directement les données en local : la BnF met à disposition, au format ISO2709/UNIMARC, ses notices⁴⁰. De la même manière que pour IdRef, pour retrouver un auteur, le script s'appuie sur la similarité du nom par distance de Levenshtein, et correspondance d'au moins un titre commun via le champ UNIMARC 810. De ce fait, l'usage de la BnF comme référentiel présente aussi l'avantage de pouvoir être manipulé localement, indépendamment (au-delà de la récupération de l'ensemble des données), du server. Cependant, l'usage de ce référentiel est resté marginal dans le cadre de ce projet, en raison de notre priorisation

40. Disponibles à l'adresse suivante : <https://api.bnf.fr/fr/notices-dautorite-personnes-collectivites-oeuvres-lieux-noms-communs-de-bnf-catalogue-general>.

d'autres stratégies détaillées ci-dessous : il a tout de même permis l'identification de 227 auteurs, et a été conservé pour des raisons de traçabilité du protocole.

Enfin, Wikidata, si ce n'est pas un référentiel faisant autorité, a été pris comme un *hub* d'alignement. Pour chaque auteur disposant d'au moins un identifiant connu (IdRef, BnF et, nous y revenons ensuite, VIAF, ORCID, ISNI, GND (*Gemeinsame Normdatei*), Scopus, IEEE ou Google Scholar), une requête SPARQL combinant l'ensemble de ses identifiants de notre base permet de retrouver l'entité Wikidata correspondante, et d'en extraire les données souhaitées : ici, les identifiants supplémentaires (pour l'alignement des référentiels), le genre ou sexe (P21 dans wikidata), la nationalité (P27) et les langues d'expressions (P1412). Bien que Wikidata repose sur des contributions participatives ne faisant pas autorité, cette méthode a permis d'enrichir 11 182 auteurs de notre base.

Toutefois, ces trois référentiels ne suffisent pas à l'enrichissement plus approfondi de notre corpus, et il a été nécessaire, pour les besoins de la récupération de données, d'élargir le panel de ressources envisagées.

La nécessité d'augmenter notre panel de sources prises en compte Une partie de nos difficultés quant aux bases établies est liée au fait que nous ne disposons, pour chaque auteur, que d'un ensemble réduit d'oeuvre (une seule dans la majorité des cas), qui ne sont pas nécessairement renseignées sur les référentiels d'autorité. Dès lors, il convient de revenir à la source ayant permis de récupérer, en premier lieu, cet auteur : Worldcat. Si l'on clique sur le nom d'un auteur depuis la notice bibliographique associée, la plateforme renvoie une page web de résultats listant les autres publications associées à ce même nom dans le catalogue⁴¹, comme une recherche dans la barre de recherche standard. Il est difficile de savoir si Worldcat, par son système d'entités⁴², résout lui même la question de l'onomastique quant aux oeuvres associés à un Nom, et, au mieux, notre méthode repose sur l'hypothèse qu'il s'agit bien de publications de l'auteur en question. Par conséquent, sur un principe similaire à notre récupération des notices dans Worldcat à l'issue de la recherche par mots-clés, il devient possible de récupérer un ensemble de titres de publications d'un auteur, et le comparer, comme s'il s'agissait de titres de notre

41. Une requête qui, selon l'architecture décrite précédemment, consiste à mettre un filtre strict sur l'onomastique de l'auteur : <https://search.worldcat.org/fr/search?q=au=%22Herbers%2C%20Klaus%22> pour Herbers Klaus par exemple.

42. Voir la page Worldcat dédiée : <https://www.oclc.org/en/worldcat/entities.html>.

base de données, aux titres des publications issues des référentiels d'autorité. Même si cela implique de revenir sur Worldcat, plateforme dont le scraping est particulièrement lent et difficile, ce protocole a permis de désambiguer 10 662 auteurs, en comparant Worldcat avec IdRef et VIAF.

En effet, VIAF recense bon nombre d'auteurs absents de IdRef : si ce dernier permet, dans une certaine mesure, d'accéder au premier, par son système d'alignement des référentiels, VIAF s'est montré plus complet quant aux publications des auteurs, facilitant leur croisement avec la base locale ou Worldcat. A rebours de IdRef, l'API de VIAF est limitée et nécessite une clé et un identifiant : notre protocole ainsi reposé sur du scraping, et a permis, avec VIAF seul, de faire correspondre 1832 auteurs. A l'instar de VIAF, ORCID a aussi permis la récupération d'identifiants (761 auteurs directement, auxquels s'ajoutent 275 identifiés par croisement avec Wikidata) par croisement du Nom, Prénom et titre des publications.

Pour d'autres sources, notamment Google Scholar (683 auteurs), Scopus (453 auteurs), IEEE (538 auteurs) et une partie plus réduite d'ORCID, la logique a été inverse : il s'agit d'abord de retrouver la publication dans une base de données, de s'assurer par comparaison des titres que ce sont les mêmes références, puis extraire le lien vers le profil auteur correspondant ⁴³. Cette approche a été mobilisée en particulier pour les publications indexées sur des bases ciblées : ScienceDirect, dont les notices comportent généralement de nombreux auteurs, permettant, en une seule visite du site, d'identifier plusieurs individus ; l'IEEE Xplore qui associe un profil IEEE d'auteur à sa publication (et parfois un ORCID), même lorsqu'ils n'ont publié qu'un seul article ; ou Google Scholar, qui, lorsqu'un auteur a été lié à une publication, affiche un lien vers le profil de celui-ci. Si les deux premières bases mentionnées étaient plus simples à scraper, en raison de la moindre présence de CAPTCHA (uniquement un en début de session), Google Scholar a nécessité l'utilisation d'un dépôt Github dédié.

Enfin, une part marginale des identifications a été réalisée manuellement, au fil de la navigation et des tests, mais ne constitue pas l'essentiel de nos auteurs.

L'ensemble des opérations décrites dans ce paragraphe repose sur du scraping web, mis en place avec Selenium et Geckodriver pour gérer les interfaces JavaScript : ainsi,

43. Qui, dans son URL, contient systématiquement l'identifiant unique de l'auteur. En conséquence, il n'était pas nécessaire de visiter une page de redirection pour désambiguer : le scraping de la page de la publication suffisait.

pour des raisons légales, les scripts correspondants ne peuvent être fournis ici. De ce fait, il convient de souligner que le résultat final, qui est l'état actuel de notre base de données en termes d'identifiants, est le produit⁴⁴ d'un mélange de stratégies aux statuts juridiques hétérogènes pour l'utilisateur déconnecté et ne souhaitant pas payer : si l'interrogation d'API publiques ne pose pas de souci, le scraping de pages et le recours à des bases commerciales placent notre démarche dans un espace d'incertitude quant au droit⁴⁵.

Récupérer les informations personnelles des auteurs. Nous avons déjà mentionné la récupération, dans le même temps que l'interrogation de Wikidata pour les identifiants, de données supplémentaires sur les auteurs. En effet, le genre⁴⁶, la nationalité, la langue d'expression, la date de naissance, l'institution d'appartenance, et la discipline ou le métier (pour savoir, *a minima*, si l'individu se revendique historien ou est considéré comme tel), sont autant d'informations qui nous semblaient pertinentes au regard du champ, puisque ces attributs peuvent être pris comme des traces d'une position sociale, propriétés pouvant conditionner l'accès aux capitaux. En outre, la discipline (ou le métier) présente un intérêt en ce qu'il s'agit de questionner les recompositions des frontières disciplinaires et la constitution éventuelle d'un sous-champ, coeur de notre problématique. Ces informations sont également classiques dans la littérature bibliométrique, du moins sur le plan de l'évaluation de la recherche (GINGRAS 2014, p. 36).

Toutefois, la pratique a réduit les ambitions initiales du projet, au regard de la quantité et la qualité des données disponibles. Les informations récupérées se limitent, pour l'immense majorité, au genre et à la nationalité. Les données de nationalité proviennent principalement de VIAF, qui a permis de renseigner 10 114 auteurs, IdRef n'en couvrant qu'une partie réduite de 2021 auteurs. Les données de genre semblent quant à elles plus homogènes pour la couverture : 13 096 auteurs ont un genre issu d'une combinaison de sources puisque VIAF et IdRef le renseignaient, auxquels s'ajoutent 2456 auteurs dont

44. La méthodologie la plus féconde de cet ensemble étant la combinaison de IdRef, VIAF et Worldcat.

45. Cette tension entre la place de l'historien sur le web et les conditions d'accès aux données est discutée plus largement dans la section 2.1.3, à propos du statut de Worldcat comme source.

46. Nous préférons ici le terme « genre » au terme « sexe ». Si la BnF est la seule base de données consultées à continuer d'utiliser le « sexe », il semble plus approprié de parler de « genre » en tant qu'ensemble de normes et de rôles socialement construits. De plus, il semble plus approprié d'utiliser ce terme en ce que la donnée correspondante est fondée sur la déclaration (ORCID par exemple), ou la supposition du genre d'un auteur par les référentiels.

l'information sur le genre provient de VIAF uniquement. En revanche, les données sur la langue d'expression ou le sujet de recherche apparaissent plus rarement, sous des formes hétérogènes⁴⁷. Puisque VIAF agrège des ontologies de différentes bibliothèques en un lieu sans les uniformiser, il n'est pas aisé d'utiliser ces données et, si Wikidata semble plus structuré, nous ne disposons du Wikidata que de 11 182 auteurs dont il n'est pas garanti que ces champs soit renseignés contre 16 892 pour le VIAF. Il en va de même pour le sujet de recherche⁴⁸.

Aussi, certains référentiels contiennent davantage de renseignements que ceux initialement envisagés, ce qui permet, par la pratique, d'élargir le protocole : ORCID, consulté au départ dans l'objectif de récupérer un identifiant unique, permet de renseigner des institutions d'emploi et de formation (pour 5997 auteurs), avec parfois des dates, ce qui rend possible la reconstitution de trajectoires universitaires et professionnelles. En interrogeant ensuite Wikidata pour récupérer la localisation des institutions mentionnées, il devient envisageable de cartographier les déplacements des auteurs dans le temps. Si nous n'avons finalement pas exploité ces données, leur présence doit être signalé afin de rendre compte de la richesse informationnelle de plateformes qui, pourtant, ne font pas autorité⁴⁹.

47. Notons par exemple la multiplicité des sujets d'étude dans VIAF pour un seul auteur, qui ne sont par ailleurs par toujours harmonisés, en opposition avec le cadre structuré de Wikidata. Pour prendre un exemple, Patrick Geary : dans VIAF, voici les mots (dont nous retirons le coréen par ailleurs) décrivant sa profession et son sujet d'étude : « Field of Activity : middle ages », « Occupation : historians, university and college faculty members, profesors, medievalista, medievalist, college teachers » ; et dans Wikidata, son occupation (P106) contient « medievalist » (Q3332711, qui renvoie vers *historian* ensuite) et « university teacher », et son « field of work » (P101) contient « Early Middle Ages » (Q202763).

48. Il aurait été envisageable de reconstituer le sujet principal d'un auteur en croisant ses publications avec les thématiques identifiées dans notre corpus, mais cette piste n'a pas été mise en œuvre ici.

49. Reposant sur le volontariat des auteurs, outre les doublons, nous pouvons souligner un manque prépondérant d'auteurs, ne permettant pas de concevoir des effectifs corrects pour les institutions. L'exemple de Paris 1 constitue un cas limite : alors qu'on s'attendrait à voir apparaître une majorité de femmes au sein de l'institution, ou du moins une part plus élevée que d'autres localités, les femmes ne représentent que 31,2% des employés (sur 33 individus, 22 hommes, 10 femmes, 1 non genré) renseignés sur ORCID, mais 73,3% des formés (sur 16 individus, 4 hommes, 2 femmes, 1 non genré).

Les publications

Crossref, ressource par excellence. L'API publique de Crossref⁵⁰ permet d'interroger gratuitement les données d'une publication à partir de son DOI, et retourne un JSON structuré contenant des informations souvent plus riches que celles fournies par Worldcat : date de dépôt, date de mise en ligne, pages, volume, numéro, ISSN, éditeur, résumé lorsqu'il est disponible, liste des auteurs distinguant chaque individu, son nom et son prénom, et parfois, le lien vers le texte intégral. Ainsi, cette solution permet d'automatiser largement la récupération d'informations complémentaires sur les plus de 20 000 publications disposant d'un DOI.

De ce fait, nous avons d'abord collecté l'ensemble des informations renvoyées par l'API pour la totalité des publications ayant un DOI valide⁵¹, afin de consulter l'intégralité de la réponse pour chaque DOI renvoyé à posteriori, et identifier les champs pertinents à insérer dans notre base de données. Ensuite, les informations étaient insérées dans la table **reference**, sauf si l'information était déjà présente et, pour les auteurs, le programme vérifie l'existence de liens dans la table de liaison avant d'en créer de nouveaux, pour des auteurs soit existants, soit créés s'ils manquent. L'une des informations les plus pertinentes pour notre propos retenu est la récupération de la langue et des auteurs associés à une référence.

La décision de ne pas automatiser la mise à jour du champ **type_of_reference** est le résultat d'une limite méthodologique identifiée à posteriori : lors des premières vérifications de ce que le `.json` retourné par Crossref contenait, les références échantillonnées étaient majoritairement des chapitres d'ouvrages collectifs (book-chapter) ou des articles, ce qui avait laissé croire que la taxonomie exposée par l'API était proche des codes RIS utilisés dans la base pour ne pas modifier ce champ. Ainsi, ce n'est qu'à l'analyse plus systématique des json qu'est apparue la diversité des types renvoyés par le RIS, qui distingue notamment « edited-book », « monograph », « reference-entry », « posted-content » ou encore « peer-review »⁵².

50. Documentation disponible aux adresses <https://api.crossref.org/swagger-ui/index.html>, ou encore <https://www.crossref.org/documentation/research-nexus/>.

51. Worldcat pointe parfois vers des DOI vides, ou ne renvoyant à rien.

52. Nous signalons cet élément car nous ne l'avons pas implémenté, puisque nos processus d'analyses n'utilisent pas, de manière notable, le type de document (à l'exception, comme nous le verrons, de la thématisation). Notre base conserve toujours « CHAP » et « JOUR » pour les types des documents,

JSTOR, source pour les textes, et les métadonnées En complément de Crossref, JSTOR, à l'aide d'un accès institutionnel, permet d'envisager la récupération du texte intégral de publications, en plus de leurs métadonnées. En effet, l'ensemble des métadonnées des documents de JSTOR auxquels nous avons accès m'est fourni en vertu de mon abonnement de l'université Paris 1, sous forme d'un fichier `.jsonl` de plus de 10 Gigaoctets⁵³. Afin de faciliter le traitement automatisé, le fichier a été divisé en sous-ensembles de 300 000 lignes, et la logique de correspondance adoptée reprend celle mise en place pour le dédoublement : d'une recherche du plus strict (DOI) au plus approximatif (titre) dans un souci de performance et de temps de calcul.

D'abord, le script croise les DOI de notre base locale avec le champ `ithaka_doi` de chaque article JSTOR. Pour les références avec un ISSN ou un ISBN, la seconde étape filtre les articles JSTOR dont les identifiants correspondent, après normalisation (suppression des tirets et des espaces) et valide les paires par comparaison de titres via distance de Levenshtein. Ensuite, pour les publications sans DOI ni ISSN, nous filtrons d'abord par année de publication, puis par comparaison de titres. Enfin, pour les références auxquelles tous ces éléments manquent, le programme prévoit une comparaison exhaustive du titre et titre secondaire⁵⁴. Une fois cette correspondance faite, les `jstor_item_id` sont récupérés (ainsi que les métadonnées allant avec) afin de procéder à la demande du texte à JSTOR (2018 publications).

Récupérer le fulltext : Google Scholar, Anna's Archive et Scihub La récupération des textes a reposé sur deux plateformes dont la légalité est contestée. Leur usage dans le cadre de notre recherche n'est ainsi pas légalement établi, ce qui ne permet pas d'administrer le programme complet, à l'image du scraping web auquel nous avons procédé. Ces questions juridiques et éthiques ont été évoquées dans la section 2.3.2 ; nous ne faisons ici que rappeler le principe de la stratégie mobilisée.

Pour Sci-Hub, le protocole repose sur l'interrogation successive de plusieurs miroirs du site (changeant régulièrement) à partir du DOI de la publication : en cas d'échec ou de

hérités du RIS.

53. Qui ne couvre que ce dont j'ai accès à !

54. Les seuils de similarité retenus (Levenshtein) sont indicatifs et ont été ajustés empiriquement : un seuil trop bas génère des faux positifs, un seuil trop haut laisse passer des correspondances réelles. Nous recommandons alors de procéder par itérations, du seuil le plus strict au plus permissif, en évaluant qualitativement le taux de résultats obtenus à chaque passe.

timeout, la requête est relancée automatiquement sur le suivant, jusqu'à l'épuisement de la liste des sites miroirs ou l'obtention d'un fichier valide (certains fichiers disponibles sur le web ont l'apparence de `.pdf`, sans pour autant être exploitables : taille de 0Ko, fichiers corrompus). Pour Anna's Archive, le protocole est similaire : la plateforme est interrogée à partir du DOI et, en cas d'échec ou de délai, le script interroge les miroirs.

Aussi, Google Scholar, en plus de fournir des informations sur nos auteurs, permet de télécharger des publications : si parfois, le lien renvoie vers un fichier inexistant, ou vers l'intégralité du livre pour représenter un chapitre, cette méthode permet de récupérer le texte intégral de publications sans disposer du DOI ! Le titre et l'auteur suffisent, le plus souvent, à retrouver le document via la barre de recherche du moteur. Ainsi, il convient d'envisager ces trois stratégies comme complémentaires, l'une pour le DOI et l'autre pour les publications qu'il est nécessaire de chercher.

Ce protocole a permis de récupérer 3392 publications depuis ces bases, en texte intégral.

3.2.5 Une hiérarchisation des méthodes d'augmentation des données

#	Méthode	Vol.	Impl.	Temps	Reprod.	Qualité	Légal.	Conseil
1	Crossref (API)	++	++	++	++	+	✓	Prioritaire
2	JSTOR	+	+	+	+	++	✓	Recommandée
3	Sci-Hub / Anna's Archive	++	+	+	--	++	×	Avec réserves
4	BDD ciblée	--	--	--	--	++	~	Cas particulier

TABLE 3.5 – Hiérarchisation des méthodes d'augmentation de la donnée pour les publications. « Vol. » désigne le rendement en volume relatif ; « Impl. » la facilité d'implémentation ; « Temps » la vitesse d'exécution effective ; « Reprod. » la reproductibilité du protocole ; « Qualité » la richesse des métadonnées obtenues ; « Légal. » l'absence de risque juridique ou éthique.

#	Référentiel / Source	Vol.	Impl.	Temps	Reprod.	Qualité	Légal.	Conseil
1	IdRef (API)	++	++	++	++	+	✓	Prioritaire
2	Wikidata (API)	+	++	++	++	++	✓	Hub — prioritaire
3	VIAF (code source)	++	+	—	+	+	~	Prioritaire
4	RI OPAC	+	+	++	++	+	✓	Recommandée
5	ORCID (code source)	+	+	+	+	+	~	Recommandée
6	Worldcat (auteur)	+	—	--	--	+	~	Complémentaire
7	IEEE	—	+	+	+	++	~	Ciblée
8	BDD locale en ligne / ciblée	—	--	--	--	+	~	Cas particulier
9	Google Scholar	—	--	--	--	—	~	À éviter

TABLE 3.6 – Hiérarchisation des méthodes d’augmentation de la donnée pour les auteurs. Les mêmes indicateurs que le tableau précédent sont mobilisés. Wikidata est positionné en rang 2 en dépit d’un volume modeste : son rôle de *hub* d’alignement des référentiels (IdRef, VIAF, ORCID, Scopus), la facilité de son interrogation par API et sa rapidité en font un outil transversal dont la valeur dépasse l’effectif brut. VIAF et ORCID, dépourvus d’API publique stable, ont été interrogés par lecture du code source ; leur temps d’exécution en est affecté. Google Scholar présente le moins bon ratio coût/bénéfice de l’ensemble des méthodes testées.

3.2.6 Imputer la donnée : une stratégie envisageable ?

Nous avons pu constater que la donnée sur le web est présente en quantité et qualité hétérogène, et que ses modalités d’accès demeurent floues. Une stratégie afin de pallier à la pauvreté informationnelle du RIS consiste à redocumentariser nos documents en allant chercher l’information *ailleurs*, dans des espaces plus ou moins légaux. Alors, que faire lorsque tout ceci ne suffit pas ? Que faire lorsque la donnée de genre manque pour plus d’un tiers de nos auteurs ? Pour les 17 181 publications qui n’ont pas de langue ? Comment approcher les contenus des publications et les sujets évoqués ?

Pour tenter de répondre à ces questions, le protocole développé propose d’imputer la donnée manquante à l’aide d’éléments dont nous sommes certains : le titre d’une publication, le nom d’un auteur, sa nationalité telle que renseignée sur des référentiels d’autorité ; afin de tenter d’en inférer le genre de l’auteur, la langue d’une publication, voire sa thématique.

Imputer les informations personnelles des auteurs ?

Si le genre est une donnée accessible via les bases de données consultées, elle n'était pas renseignée pour une bonne partie de nos auteurs (GOYANES, DE-MARCOS et DOMÍNGUEZ-DÍAZ 2024) : 15 722 auteurs étaient renseignés sur 28 504, soit plus de 40% d'inconnus ; alors même que c'est une propriété structurante des positions dans le champ, en défaveur des femmes (pour la bibliométrie plus précisément, voir GOYANES, DE-MARCOS et DOMÍNGUEZ-DÍAZ 2024). De ce fait, l'absence du genre d'autant de documents ne permettait pas d'explorer suffisamment l'hypothèse des inégalités structurelles genrées. Ainsi, une stratégie pour surmonter ce manque consiste à s'appuyer sur deux éléments : d'abord, nous considérons que le genre assigné par les tiers est une variable sociale pertinente pour notre objet d'étude ; ensuite, nous faisons l'hypothèse que le prénom, croisé (lorsqu'il est possible de le faire) avec un indice culturel tel que la nationalité, s'avère un indicateur pour inférer le genre le plus probablement attribué à l'auteur. Dès lors, il faut rappeler les présupposés derrière cette imputation :

- que la nationalité, propriété administrative, correspond à l'origine culturelle du prénom qui, pourtant, repose sur un choix du, ou des parents (ou de l'individu, plus rarement) ;
- que tous les auteurs du corpus sont cisgenres et qu'il n'existe que deux genres possibles, femme et homme (critique classique de ce genre d'approche d'imputation de genre, voir GOYANES, DE-MARCOS et DOMÍNGUEZ-DÍAZ 2024) ;
- que le genre socialement assigné aux prénoms existe et est stable, ce qui n'est pas évident pour certains, comme « Camille », ou « Claude » en France par exemple (GOYANES, DE-MARCOS et DOMÍNGUEZ-DÍAZ 2024).

Néanmoins, au sein d'un champ universitaire structurellement marqué par la cisnormativité (PRIEUR 2019) et le sexisme, on peut poser l'hypothèse d'une correspondance majoritaire entre l'identité sociale des auteurs et leur genre assigné à la naissance. Dès lors, le prénom devient un indicateur pertinent pour appréhender cette catégorisation, et nous pouvons utiliser des méthodes computationnelles pour approcher le genre. Le *pipeline* envisagé, largement inspiré de l'évaluation proposée par GOYANES, DE-MARCOS et DOMÍNGUEZ-DÍAZ, repose sur l'usage d'API de Namsor (`genderFullGeoBatch` et `genderFullBatch`) permettant, à partir du prénom (et, lorsque présente, de la natio-

nalité), de renvoyer le genre de l'individu⁵⁵. Afin de confronter Namsor à un autre outil d'imputation de genre, le protocole propose une imputation indépendante via l'API de Mistral, avec une température⁵⁶ fixée à zéro pour maximiser le déterminisme de la réponse⁵⁷. Cette méthode nous a permis d'inférer le genre de 9 657 personnes. D'un point de vue réflexif, les résultats obtenus nous amènent à favoriser le LLM (Mistral ici) : le LLM (plus de 60% de l'échantillon récupéré) a permis d'imputer le genre lorsque Namsor atteignait sa limite de crédit, et l'arbitrage manuel pour un échantillon (vérification empirique) lui a presque systématiquement donné raison. Toutefois, là où Namsor permet une reproductibilité du protocole, Mistral est plus opaque, ce qui constitue le coût de la performance du modèle sur l'imputation du genre.

55. Les prénoms composés d'initiales seules ou trop abrégés pour permettre une inférence fiable sont écartés en amont : un token est considéré comme une initiale s'il ne contient qu'un ou deux caractères après suppression du point final, et les entrées ne comportant pas au moins une partie de prénom de trois lettres ou plus sont exclues du traitement.

56. La température est un hyperparamètre qui contrôle le degré de caractère aléatoire et de créativité des réponses générées par l'intelligence artificielle.

57. Le prompt soumet le nom complet au modèle et lui demande de répondre uniquement par un chiffre : 0 pour féminin, 1 pour masculin, 2 pour inconnu ou ambigu ; la réponse est extraite par expression régulière, ce qui la rend robuste aux éventuels caractères parasites. Les résultats des deux systèmes sont ensuite confrontés : en cas d'accord, le genre est validé et inséré en base avec la source `both_agree` ; en cas de désaccord, la ligne est isolée dans un fichier de conflits avec `genre_final` à `null`, pour arbitrage manuel. Une règle stricte s'applique lors de l'insertion : si le LLM a répondu `unknown` et qu'aucun arbitrage manuel n'a été renseigné dans le fichier de conflits, le document n'est pas inséré, afin d'éviter toute imputation spéculative. Seuls les cas où les deux systèmes convergent, ou ceux tranchés manuellement, sont versés dans la base, dans un champ `genre_impute` distinct du champ `genre` issu des référentiels d'autorité, préservant ainsi la traçabilité de la source de chaque information.

Les titres comme supports informationnels pour l'ordinateur.

Pourquoi le titre ? Le titre⁵⁸ d'une publication semble être un indicateur pertinent à quelques égards, tant pour les usages que nous en avons fait (langue et thématique), que d'une manière plus large dans le champ. Loin de représenter des choix individuels (ou collectifs, dans le cas de multiples auteurs), les titres relèvent de pratiques disciplinaires contraintes par les normes du champ et les attentes des lecteurs supposés (HYLAND et ZOU 2022). En effet, le titre est l'une des premières données par lesquelles un article est perçu (ALEIXANDRE-BENAVENT, MONTALT-RESURECCIÓ et VALDERRAMA-ZURIÁN 2014) : premier point de contact entre l'auteur et son lecteur potentiel, il remplit une fonction à la fois descriptive et rhétorique, devant à la fois résumer le contenu, en ce qu'il « doit » contenir des mots-clés informatifs représentant fidèlement le contenu de l'article, et capter l'attention du potentiel lecteur dans les contraintes d'espace propres au format (ALEIXANDRE-BENAVENT, MONTALT-RESURECCIÓ et VALDERRAMA-ZURIÁN 2014).

Ainsi, si le titre doit à la fois être informatif mais concis, il semble représenter un indicateur pertinent : il est susceptible de contenir des mots jugés essentiels par l'auteur pour communiquer au sein du champ, pouvant être pris comme des traces linguistiques et thématiques. Le titre est le produit d'un ensemble de contraintes qui dépassent parfois l'auteur (normes éditoriales, logiques de visibilité dans le champ) mais constitue aussi, en ce qu'il définit et légitime un objet par les mots choisis pour le désigner, une prise de

58. « Article titles are a rich source of information about disciplines, fields, journals and the proclivities of individual authors. They reveal something of fashionable topics and emerging sub-fields, but for EAP researchers they are important for what they tell us about authors' perceptions of disciplinary practices and how they think they might best reach potential readers. »[...] « The social scientists, however, have their own issues to address. While their research might be more diverse and interdisciplinary, the fact that it follows less linear tracks and seeks to appeal to wider, more heterogeneous audiences, means that it is harder to assume a coherent and expectant cohort of readers. It is therefore possible, because they cannot presuppose the same degree of research background, knowledge of prior work and theoretical understandings among readers, their titles have to be catchier and more explicit to create rather than assume an audience for the work. In other words, titles are not produced from an infinite range of options but from a relatively restricted sub-set which reveal how their authors understand their communities. Any title anticipates a reader's response and addresses wider expectations, so that choices are disciplinary practices as much as individual decisions. Titles, then, like the articles which follow them, are co-constructed within the "conceptual frames" (Hyland, 2012) of disciplines and so represent something of how members understand what is likely to be effective and familiar to colleagues. »(HYLAND et ZOU 2022).

position au sein du champ.

Nous avons envisagé l’usage du titre selon deux axes : la langue, et la thématique.

La langue, inférée à partir du titre. Pour les références sans DOI, ou celles où le DOI était invalide, aucune langue n’a pu être récupérée via Crossref ou la page web de l’éditeur. Ainsi, une stratégie reposait sur l’analyse linguistique du titre à l’aide de modèles de détection automatique de la langue.

Imputer la langue à partir du titre revient à supposer que la langue majoritaire du titre correspond à celle du texte, ce qui n’est pas évident : une publication peut avoir un titre en latin pour rappeler une formule médiévale, comme c’est le cas pour « 8 THE BARBARIANS IN SALVIAN’S DE GUBERNATIONE DEI » (id : 69825516c835c41957df92b1) ; et une recension cite bien souvent le titre d’une publication en langue originale, comme par exemple « Rezension von : l’étranger au Moyen Age. 30e congrès de la Société des Historiens Médiévistes de l’Enseignement Supérieur Public » (id : 69825516c835c41957dfbd47) qui est en allemand, et cite pourtant un titre en français.

Ces limites ne permettent toutefois pas de disqualifier intégralement la stratégie envisagée, puisque les cas mixtes demeurent peu nombreux⁵⁹, et que notre protocole applique un seuil de confiance en dessous duquel aucune langue n’est attribuée, préférant l’absence d’information à une imputation. En outre, les titres trop courts ou génériques (« introduction », « appendix ») sont écartés en amont. Il convient enfin de rappeler que cette étape ne s’applique qu’aux références pour lesquelles aucune autre source n’a pu fournir l’information : elle ne vient qu’en complément de méthodes plus directes, non en substitution. Cette approche n’est par ailleurs pas propre à notre protocole : OpenAlex, base bibliographique en accès ouvert développée par OurResearch, procède de même en inférant la langue de ses notices depuis le titre lorsque le résumé est absent, tout en documentant les mêmes biais que ceux identifiés ici ; et s’inscrit dans la continuité des travaux sur l’identification automatique de la langue sur les textes courts AVENBERG 2026.

Pour les références restant sans langues donc, le titre principal est soumis à une détection automatique via le pipeline de spacy-language-detection. Dans le cas où le titre est jugé non informatif (trop court, ou correspondant à un titre générique), la détection est tentée sur le titre secondaire : puisqu’il s’agit bien souvent de parties d’un ouvrage,

59. Cette affirmation se fonde sur une analyse qualitative, et non systématique.

nous pouvons élargir la supposition dressée précédemment en posant l’hypothèse que la langue du titre d’un livre peut correspondre à la langue du livre. Enfin, la langue détectée n’est retenue que si elle appartient à un ensemble prédéfini de langues académiques plus récurrentes, ce qui permet d’écarter les codes non significatifs renvoyés par le modèle (mais n’excluant pas la possibilité). Les résultats sont versés dans un fichier intermédiaire distinct, avec le champ `source_langue` renseigné à `spacy`, préservant ainsi la traçabilité de l’origine de chaque imputation.

Modéliser la thématique à partir des titres

Nous l’avons évoqué, le titre est porteur d’une sémantique, en tant que résumé de pratiques disciplinaires, objets d’études et positionnements au sein du champ scientifique (HYLAND et ZOU 2022). En ce sens, il s’agit d’un indicateur pertinent pour discerner les différentes thématiques traversant notre corpus, en l’absence du texte complet : l’analyse des disciplines présentes dans notre corpus se ferait plus aisément à partir de l’abstract ou du fulltext, ayant davantage de mots pour permettre un regroupement. Néanmoins, une classification thématique des titres des publications repose sur leur caractère textuel, qui est, par définition (il s’agit d’un titre), réduit sur le plan de la longueur, ce qui complique son traitement informatique.

Cette question est présente dans la littérature portant sur le traitement automatique du langage naturel (TAL), sous la dénomination de *short text clustering* (STC), notamment mobilisé par les auteurs travaillant sur les Tweets. Les auteurs soulignent ainsi des propriétés rendant spécifique le travail sur des textes courts : la parcimonie lexicale (*sparsity*), la haute dimensionnalité de l’espace de représentation, et le manque d’information contextuelle (AHMED et al. 2022). En effet, le faible nombre de co-occurrences lexicales au sein d’un document, et entre les documents qui porte pourtant sur des thématiques proches, exprimées avec des lexiques différents, limite les possibilités envisageables de regroupement par des représentations fréquentielles du vocabulaire.

Ainsi, le modèle classique du « sac de mots » (*Bag of Words*) et la pondération TF-IDF (*Term-Frequency Inverse Document Frequency*), bien que pertinents dans le cadre de textes intégraux (voir section 4.5, créent pour les titres une haute dimensionnalité qui ne permet pas d’établir des distances entre les documents (AHMED et al. 2022), puisqu’elles ne permettent pas de lier sur le plan sémantique les mots d’un même titre. En effet,

la modélisation thématique par allocation de Dirichlet Latente (LDA) repose sur des hypothèses de co-occurrence statistique en ignorant l'ordre des mots et les relations entre les termes. Comme le relève ZHANG et al., l'essor des modèles de langue pré-entraînés a reconfiguré les pratiques de STC : les méthodes fondées sur les *sentence embeddings* sont, de plus en plus, des classiques dans la littérature (ZHANG et al. 2026). Ces dernières reposent sur une projection des textes (ici donc, les titres) dans un espace vectoriel où la distance entre eux repose sur le contexte sémantique, permettant de tempérer les limites des méthodes fréquentielles⁶⁰.

Parmi les architectures disponibles, BERTopic a été rencontré à plusieurs reprises dans la littérature sur le STC. Comparé à LDA sur des corpus hétérogènes, il semble produire des scores de cohérence thématique meilleurs (HANKAR, KASRI et BENI-HSSANE 2025 ; MEDVECKI et al. 2024), même sur des corpus multilingues (MEDVECKI et al. 2024). En outre, les *transformers* n'ont pas besoin nécessairement de lemmatisation préalable des textes ; notamment dans le cas de BERTopic⁶¹, ce qui présente un avantage au regard de l'état de nos données comme évoqué section 2.2. BERTopic présente par ailleurs l'avantage d'une architecture modulable, permettant d'adapter chaque étape du pipeline indépendamment des autres (choix du modèle de vectorisation, de l'algorithme de clustering ou de la représentation thématique) (GROOTENDORST 2022)⁶².

Le pipeline de BERTopic

Le pipeline de BERTopic repose sur des séquences modulables (GROOTENDORST 2022) :

- Les documents sont d'abord projetés dans un espace vectoriel à l'aide d'un modèle *sentence transformer* (sur l'hypothèse que les documents portant sur un même sujet sont sémantiquement proches dans l'espace).
- La dimensionnalité de ces représentations est ensuite réduite par *Uniform*

60. Il convient de noter que cette solution n'était pas l'unique disponible : il était envisageable de dresser une liste de vocabulaires « métiers », qui auraient été des marqueurs forts, en particulier pour détecter les publications portant sur les sciences naturelles et qui auraient eu, dans leurs titres, un technolecte.

61. Voir à ce sujet la discussion sur ce forum : <https://stackoverflow.com/questions/68127754/removal-of-stop-words-and-stemming-lemmatization-for-bertopic#69925621>.

62. Voir aussi la documentation en ligne à ce sujet : <https://maartengr.github.io/BERTopic/algorithm/algorithm.html>.

manifold approximation and projection (UMAP), qui conserve davantage les structures locales des données que PCA (Analyse en composantes principales) ou t-SNE (*t-distributed stochastic neighbor embedding*).

- Puis, les documents sont regroupés par un algorithme de clustering HDBSCAN (Hierarchical Density-Based Spatial Clustering of Applications with Noise). Cependant, cet algorithme semble être inadapté à notre corpus, puisqu’il produisait un cluster regroupant plus de 90% des documents, et le choix s’est porté sur le clustering hiérarchique de Ward (1963), permettant d’assigner l’ensemble des documents à un cluster de manière déterministe, et requiert une spécification du nombre de clusters K .
- Enfin, la représentation thématique de chaque cluster est extraite par c-TF-IDF, qui mesure l’importance des termes au niveau du cluster plutôt qu’au niveau du document individuel, produisant ainsi des mots-clés caractéristiques de chaque thématique (GROOTENDORST 2022).

Dans notre cas, nous avons paramétré la réduction dimensionnelle à `n_components=5`, valeur recommandée par GROOTENDORST (2022) pour le clustering dans BERTopic.

La possibilité de tester différentes configurations implique aussi de choisir et tester quelques unes pour tenter de voir ce qui, au regard de notre corpus, convient le mieux. Afin de sélectionner le modèle de représentation vectorielle dense le plus adapté à la spécificité de notre corpus historiographique, nous avons tenté de mettre en place des tests comparatifs. Nous avons ainsi confronté un modèle spécialisé dans la littérature académique, SPECTER (entraîné sur des graphes de citations scientifiques, voir COHAN et al. 2020), à un modèle plus généraliste, présentant aussi des meilleurs scores dans le cadre de BERT, all-mpnet-base-v2 (K. SONG et al. 2020, qui se penche davantage sur les relations sémantiques entre les documents)⁶³. Afin de les évaluer, plusieurs indicateurs

63. Il aurait, bien entendu, été possible d’en essayer davantage. Notre objectif ici étant de parvenir à une classification thématique acceptable pour sémantiser un minimum notre trentaine de milliers d’articles, nous n’avons pas consacré davantage de temps à cette question.

sont possibles : l'indice de Silhouette⁶⁴, l'indice de Calinski-Harabasz⁶⁵ et l'indice de Davies-Bouldin⁶⁶. La combinaison des trois indices, s'ils ont été choisis arbitrairement, s'inspire du constat de ARBELAITZ et al., qui, dans son étude comparative de 30 indices de validité, montre qu'aucun ne domine dans tous les contextes, et que Silhouette, Calinski-Harabasz et Davies-Bouldin forment le groupe d'indices statistiquement les plus pertinents pour ce travail, notamment avec l'algorithme de Ward (fig. 9 de la référence citée)⁶⁷.

La sélection du nombre de clusters K s'est faite à l'aide d'une grille évaluant Ward pour chaque valeur de $K \in \{2, \dots, 40\}$ dans l'espace UMAP à cinq dimensions. Pour chaque valeur, les trois indices de validité décrits plus tôt ont été calculés, puis agrégés par rang, et la somme des rangs minimisés pouvaient en ce sens approximer un optimum et éviter de trop considérer un critère isolé⁶⁸. Cependant, la sélection finale du nombre de clusters a reposé sur l'analyse qualitative des termes discriminants de chaque cluster, selon le principe faisant de l'interprétabilité un critère de validation à part entière en modélisation thématique (GRIMMER et STEWART 2013)⁶⁹.

La comparaison entre les deux modèles a porté donc sur le plan quantitatif, avec les indicateurs, et l'évaluation qualitative. D'un côté, une grille de valeur de K identique a été évaluée pour les deux modèles, en calculant pour chaque valeur les trois indices retenus : MPNet a des valeurs de Silhouette et de Davies-Bouldin supérieures à SPECTER à partir de $K = 6$, tandis que SPECTER a des valeurs de Calinski-Harabasz plus élevées sur l'ensemble de la grille. De l'autre côté, à K fixé, les topics produits par SPECTER à son optimum statistique ($K = 14$) ont été inspectés qualitativement : les trois premiers clus-

64. L'indice de Silhouette mesure la qualité de l'affectation d'un titre à son cluster par rapport aux autres. Une valeur proche de 1 indique un partitionnement idéal.

65. Fondé sur le ratio de la variance inter-clusters et intra-cluster, l'indice de Calinski-Harabasz privilégie les structures denses et bien séparées.

66. Il évalue la similarité moyenne entre chaque cluster et son plus proche voisin. Contrairement aux deux précédents, une valeur plus faible indique ici un meilleur partitionnement.

67. ARBELAITZ et al. (2013) montrent que Calinski-Harabasz obtient les meilleurs résultats en l'absence de bruit (*op. cit.*, fig. 8), tandis que Silhouette est le seul indice maintenant des performances stables en présence de bruit. Notre corpus contenant des clusters de bruit éditorial identifiés a posteriori (topics 18-24, $n = 235$ documents, 1,9% du corpus), cette combinaison nous a paru pertinente.

68. Par exemple, l'indice de Calinski-Harabasz notamment croît mécaniquement avec K , ce qui le rendrait trompeur pris seul.

69. Nous avons ainsi pu écarter des valeurs de K produisant des clusters soit trop fins pour être interprétables, soit insuffisamment différenciés thématiquement.

ters regroupaient respectivement 17,7 %, 13,2 % et 11,1 % du corpus et mêlaient plusieurs thématiques distinctes, révélant une granularité insuffisante malgré l'avantage structurel de ce modèle sur des corpus académiques. Au final, cette combinaison a conduit à retenir `all-mpnet-base-v2`.

À l'issue du clustering, une étape de nettoyage a été nécessaire, puisque plusieurs topics produits relevaient de bruit éditorial plus que de thématiques (topics 18 à 24). Ces clusters se caractérisaient par un vocabulaire de recensions (*review*, *editor*, *volume*), ou, dans une moindre mesure, du bruit linguistique (articles en français ou en italien), et ont été fusionnés en un topic unique.

Enfin, l'évaluation du modèle repose ici sur une approche qualitative et empirique, en vérifiant, par échantillonnage, que les titres regroupés dans un même cluster semblaient cohérents. Une méthode d'évaluation alternative et plus systématique aurait pu consister à croiser les thématiques issues d'une LDA appliquée aux textes intégraux avec celles générées par BERTopic sur les seuls titres. Néanmoins, en raison de contraintes temporelles et d'une formation universitaire principalement centrée sur l'algorithme LDA, cette idée n'a pu être menée à son terme.

La donnée résultante de ce processus est stockée dans le champ `topic_analysis` de MongoDB, distinct des métadonnées d'origine afin de préserver l'objectif de traçabilité maintenu tout au long du protocole. En ce qui concerne l'interprétation de ces regroupements, je renvoie à la section 4.4 puisque ces derniers participent de l'argument selon lequel il est effectivement envisageable de présupposer le thème d'une publication à partir de son titre, sans nécessairement avoir à disposition le texte intégral.

Conséquences épistémologiques et statut de la donnée imputée

Ainsi, il s'agit ici de la construction d'une nouvelle donnée, qu'il convient, sur le plan épistémologique, de distinguer des données récupérées : nous avons distingué dans notre base `genre` et `genre_impute` pour les auteurs, mais aussi ajouté les champs `source_lang` et le champ `topic_analysis` pour les publications pour différencier l'observé de l'inféré, appliquant le principe de traçabilité et de réflexivité que nous tentons de maintenir au long de ce travail.

En outre, nous devons aussi différencier la fiabilité des données produites au regard de la signification que l'on veut leur accorder : la langue détectée sur le titre est fiable,




FIGURE 3.3 – Workflow pour le clustering des titres à l’aide de BERT

mais sa fiabilité en tant que proxy de la langue de la publication est à nuancer, et il en va de même pour la thématique et pour le genre ; et la fiabilité des données produites en comparaison à celles récoltées.

De plus, imputer la donnée revient aussi à traiter ces publications différemment des autres, puisque la lacune du RIS, outre renseigner sur les conditions de production des notices, devient une condition de possibilité d’un geste de production de « nouvelles »⁷⁰ données à partir des traces disponibles, et non une restitution d’une information existante ailleurs que nous avons pu retrouver.

L’imputation de la thématique à partir du clustering fait par BERT implique aussi un risque de circularité potentielle de la démarche, en ce que BERT produit des regroupements par similarité vectorielle entre les titres, que l’on interprète par notre regard, formé par la connaissance préalable du champ.

⁷⁰. Entre guillemets car, comme nous avons pu le voir, MERZEAU souligne le leurre de la volatilité du web.

3.2.7 Bonnes pratiques, satisfactions et insatisfactions d'un protocole de collecte semi-automatisé

Afin de prolonger le mouvement réflexif que je tente de conserver tout au long de ce travail, je propose ici un condensé des bonnes pratiques à retenir, pour quiconque souhaiterait reproduire ce protocole, ou le transposer à un autre.

En premier lieu, il convient d'adopter une démarche non harcelante quant à la récupération des données. Si les pratiques mises en oeuvre dans le cadre de la présente recherche sont dans une situation de flou juridique, je recommande de ne pas surcharger les serveurs de requêtes pouvant mettre à mal les systèmes⁷¹.

Ensuite, lors de la phase de récupération automatique des données, je recommande de ne pas faire l'économie du scraping : une fois la requête faite au serveur pour afficher ces données, le coût marginal à ajouter pour récupérer davantage de données est moindre⁷², et se réduit à mesure que l'on envisage l'utilisation de LLMs dans le protocole. En effet, sur un plan pratique, cette approche permet de se prémunir contre les oublis de données potentiellement utiles et d'éviter ainsi de devoir relancer ultérieurement le processus de collecte.

Je tiens aussi à souligner la nécessité de se perdre, naviguer puis se retrouver sur des sites et des bases de données différentes. Si cela peut sembler être une perte de temps, il s'agit de mesurer la quantité et la qualité des données que certaines bases peuvent fournir si on les interroge⁷³, et le coût (en temps, en énergie, en formation) par rapport à l'évaluation potentiellement faite en amont des besoins et des priorités. Au fil de la recherche, nous avons pu constater que certaines bases offrent beaucoup, mais ont un fort coût de récupération de données ; contre d'autres, qui ont peut être moins d'informations, mais est bien plus facile à récupérer : en bref, qu'est ce que l'on gagne à réduire la quantité

71. Ce hacking peut amener à un allongement des temps de récupération des données considérable, notamment lorsque les limitations sont particulièrement strictes, comme sur Worldcat depuis la mise à jour de Cloudflare. S'il est nécessaire de récupérer une quantité importante de données, ces temps d'attente peuvent s'avérer particulièrement limitant. Nous recommandons donc quelques pratiques complémentaires afin de contourner, du moins pour partie, ces limitations : utilisation d'un raspberry pi ou autre ordinateur peu consommateur (sous linux par exemple) pour récupérer les données lentement et sans immobiliser une machine, changement d'IP avec VPN ou, à défaut, réinitialisation du réseau depuis un téléphone portable en partage de connexion.

72. Dès lors que l'on est capable de stocker la donnée de manière structurée.

73. Je renvoie ici par exemple à l'agréable surprise d'ORCID et la question des institutions.

d'informations ?

Pour finir, sur un plan plus pragmatique et moins théorique que les recommandations précédentes, j'invite vivement quiconque travaille sur ces sujets à penser à l'architecture de ses fichiers, les ranger et s'y tenir : noms des dossiers, ordre des dossiers, noms des fichiers⁷⁴. D'expérience, j'ai pensé que Claude Sonnet 4.5 proposait des systèmes pertinents et adaptés aux besoins que je définissais dans mon prompt. Outre ces considérations de nommage, j'invite aussi à la conservation de l'intégralité de ses fichiers, du moins temporairement, le temps du projet. Pour ma part, j'ai créé un dossier « TRASH » à chaque sous-dossier et dossier où je souhaitais supprimer un élément.

3.3 De l'entité au document : une migration technique comme choix épistémologique

3.3.1 Les contraintes d'un modèle normalisé : MySQL et l'homogénéité impossible de données bibliographiques hétérogènes

Initialement, les données récoltées ont été modélisées avec une structure relationnelle, mise en oeuvre dans MySQL. Si ce choix peut sembler, *a posteriori*, peu judicieux, il répond à des contraintes de formation. En outre, le modèle relationnel permet un cadre structuré pour formuler des requêtes plus simples, pertinent dans le cadre d'un premier cours sur les bases de données.

Le modèle relationnel Les bases de données relationnelles reposent sur un modèle entité-association, comme population d'individus homogènes caractérisés par des attributs, en relations avec d'autres entités. Cela suppose que chaque entité est réductible à un ensemble fini de propriétés stables, définies à l'avance et partagées par tous les individus : un nom, un prénom, une institution, ou une année de publication, un type de document. Les attributs, comparables entre eux, permettent la requête et la jointure avec

74. Par exemple, pour mon mémoire en LaTeX, chacun de mes fichiers se nomme `X_X_nomdelapartie.tex`, le premier X correspondant au numéro de chapitre et le second au numéro de section




FIGURE 3.4 – Modèle Conceptuel de Données (MCD, notation Merise) de la base MySQL `references_biblio`. Les relations N :N passent nécessairement par des tables de liaison, ce qui est le cas pour les tables *écriture*, entre les auteurs et les références, et *comporte*, entre les références et les mots clés. Les relations entre les hiérarchies de mots-clés ne sont pas sémantisées pour des questions de lisibilité, il s’agit toujours de la même, l’appartenance.

les autres tables qui partagent des clés (identifiants uniques) ; mais ce modèle suppose ainsi de normaliser les entités, les noms, les attributs, les identifiants, et les cardinalités (sens des relations). En outre, ce modèle impose aussi qu'un attribut d'une entité ne peut prendre qu'une seule valeur, et non un ensemble de valeurs.

Le Modèle Conceptuel de Données, figure 3.4 organise la base autour de trois entités principales : AUTEUR, RÉFÉRENCE et MOT-CLÉ. Une référence, entendue comme toute publication scrapée depuis Worldcat, est liée de 0 à plusieurs auteurs par une relation d'écriture et, de leur côté, les auteurs peuvent avoir écrit de 1 à plusieurs publications⁷⁵. Cette cardinalité impose l'utilisation d'une table de liaison. De même, une référence peut comporter un à plusieurs mots-clés, et un mot-clé peut apparaître dans plusieurs références, rendant nécessaire la table de liaison *comporte*. La présence de *source scraping* peut questionner : il s'agit d'un reliquat de la construction initiale de notre base, ou plusieurs sources autres que Worldcat étaient envisageables.

La partie inférieure du schéma modélise la classification thématique envisagée à l'issue de la construction de notre liste de mots-clés pour le scraping, présentée en section 4.2. Chaque mot clé a un lemme (qui a lui, plusieurs mots clés, qui appartient à une sous-catégorie, regroupée avec les autres en catégories et, pour finir, chaque catégorie appartient à un thème. Cette hiérarchie vise à agréger des mots hétérogènes, comme « barbare », « barbarians », « barbaros », indépendamment de la langue⁷⁶ afin d'avoir un premier regard thématique sur nos entités. Cette construction illustre par ailleurs les limites du modèle relationnel pour nos données, que nous allons désormais développer.

Ce choix est devenu de plus en plus contraignant au fur et à mesure des itérations des processus de redocumentarisation décrits précédemment. En effet, le modèle relationnel impose de normaliser l'information avant le stockage, alors même que nos références, nos auteurs et les informations associées proviennent de bases aux structures hétérogènes.

Si le format RIS récupéré initialement sur Worldcat normalise déjà l'information, avec les balises vides et plutôt semblables entre les notices, il faut noter que les descriptions

75. Et non pas 0 à plusieurs, puisque nos auteurs n'existent que dans le cadre de leur relation avec une référence.

76. Ce qui ne signifie pas qu'elle n'est pas prise en compte ! La langue est toujours renseignée au niveau des attributs des publications.

varient selon le type de document tel que déclaré dans le champ **TY**. Ainsi, certains champs comme **SP** (page de début), **VL** (volume) ou **M1** apparaissent dans le type **EJOUR** (article en ligne), et non **JOUR** (article) : l’homogénéité forcée par notre base s’ajoute sur première couche de normalisation liée au format **RIS**.

Il s’agit d’un problème structurel, mais aussi épistémologique, lié à la signification accordée au champ vide. Dans ce schéma MySQL, l’absence de valeur est traitée comme une absence d’information, et, parfois, confondu avec une information négative, alors même que ce vide est polysémique⁷⁷. Par exemple, l’absence du genre d’un auteur de notre base ne signifie pas forcément que cette personne est agenre⁷⁸, puisqu’il peut s’agir d’une incertitude, ou d’une donnée non récupérée. De même, l’absence d’institution de rattachement peut indiquer soit que l’auteur est sans affiliation (cas réel, mais rare), soit que l’information n’est pas disponible dans les sources interrogées (cas fréquent).

De plus, au fur et à mesure de l’enrichissement des données liées aux publications, et surtout aux auteurs (institutions, langues, nationalités), le maintien du schéma relationnel aurait entraîné une multiplication des tables de liaison, comme en témoigne le modèle conceptuel présenté figure 3.4 avec la gestion des mots-clés organisés en hiérarchie thématique à 4 niveaux, multipliant donc les tables de liaisons au regard des relations $N:N$. Une solution consistait à externaliser certaines métadonnées dans des fichiers `.jsonl` annexes pour y stocker les informations plus hétérogènes, mais elle n’était pas viable à long terme : complexification du pipeline, multiplication des formats et sources.... ; en déplaçant les problèmes liés à l’hétérogénéité des données, sans pour autant le résoudre.

3.3.2 Réhabiliter la singularité de la notice : MongoDB et le document

La migration vers MongoDB constitue à la fois un changement d’outil, technique, et un changement de regard sur l’objet et sur nos sources.

Alors que MySQL contraint la donnée par une structure définie en tables et en relations, MongoDB permet de stocker les notices sous forme de documents indépendants au format `.json` : chaque document peut ainsi être structurellement très différent, voire ne

77. Entre l’absence de données et l’absence de phénomène.

78. Ou, si c’était le cas, cela représenterait une population statistiquement très particulière au regard de la part que représentent les personnes agenres sur la population totale.

rien avoir à voir avec un autre document de la même collection, et même évoluer sans fragiliser l'ensemble de la base.

La notice comme document Nous l'avons vu (chapitre 1), la notice bibliographique peut être entendue comme un document, une trace de la publication scientifique et des normes documentaires, pratiques et contraintes ayant rendu possible sa production. De ce fait, il convient de recenser l'ensemble des informations qu'il contient, dans sa singularité, ce que le modèle relationnel complique lorsqu'il s'agit de traiter des documents de sources hétérogènes, puisqu'il suppose que la notice est réductible aux propriétés définies par avance, et qui seraient les mêmes pour toutes les notices ! En somme, il s'agit d'une réduction du caractère singulier de la notice par la projection d'attributs sur un schéma pré-existant.

À l'inverse, dans une base de données « documents » (NoSQL), chaque notice est une unité autonome, qui peut avoir des champs totalement différents d'une autre dans la même collection et peut, en outre, prendre avec elle l'ensemble des informations relatives à la référence sans besoin de clé étrangère. Ces éléments, outre une commodité technique, évitent aussi de dissocier le document de sa configuration globale de sens en créant plusieurs entités pour un même phénomène (dans le modèle SQL, il était nécessaire d'avoir des mots-clés et des documents par exemple), puisqu'ici, tout est pris dans un même objet. La richesse ou pauvreté des informations de chaque notice constituent autant d'informations sur nos objets, comme nous le verrons⁷⁹. Ainsi, cette modélisation semble se rapprocher davantage de la démarche historique évoquée plus tôt que le modèle relationnel, en réhabilitant la singularité de la notice.

Sur le plan technique, la souplesse du `.json` facilite l'interrogation de structures imbriquées et s'aligne sur les standards actuels d'échange de données (API, web sémantique, *pipelines* d'analyse). C'est également un choix d'ouverture et de reproductibilité, puisque structurer les données sous cette forme permet leur réutilisabilité dans des chaînes de traitement plus larges, ce qui est cohérent avec la démarche que j'essaie de maintenir au

79. Par exemple, le fait que les genres des auteurs les mieux renseignés sont les hommes. Sur l'ensemble des genres renseignés, l'imputation bénéficie davantage aux femmes qu'aux hommes : sur l'ensemble des femmes, 44% sont des individus dont le genre a été imputé et, sur l'ensemble des hommes, cette part représente uniquement 34% d'entre eux.

cours de ce projet. Et, sur le plan pratique, cela simplifie davantage la documentation de la base, là où le schéma relationnel aurait impliqué la documentation et l'export d'une dizaine de tables interdépendantes, le NoSQL se réduit à deux fichiers `.json`.

Il convient néanmoins de reconnaître les compromis que cette migration implique. La puissance du modèle relationnel pour certaines requêtes analytiques (jointures, agrégations) se traduit en MongoDB par des *pipelines* d'agrégation parfois plus difficiles à comprendre et mettre en place. Par ailleurs, l'absence de contrainte d'intégrité exige une rigueur dans la gestion de la cohérence entre nos données (rien n'empêche techniquement un document de la collection `references` de référencer un identifiant d'auteur inexistant dans la collection `authors`, ce que MySQL aurait bloqué par une contrainte de clé étrangère).

Architecture retenue : deux collections. Par souci cognitif autant que pratique, deux collections distinctes ont été conservées : `authors` et `references`. Bien que les auteurs n'existent pas indépendamment de leurs publications dans ce modèle, cette séparation facilite la lisibilité et la maintenance, et les opérations d'enrichissement des auteurs. Chaque document de `references` contient un tableau `author_ids` référençant de zéro à N entrées de la collection `authors` ; contrairement au modèle relationnel, aucune contrainte d'intégrité n'est imposée par la base elle-même (figure 3.5).

Conclusion de chapitre Le protocole exposé dans ce chapitre relève aussi bien d'un geste épistémologique de construction d'un objet, que d'une description technique : chaque décision (choix des outils de collecte, dédoublonnage, enrichissement, imputation, migration de BDD) a des conséquences sur nos analyses. Les traces, fournies par Worldcat, sont redocumentarisées afin de les soumettre à l'analyse.

Cette dernière est par ailleurs l'objet du prochain chapitre, en mobilisant, du plus superficiel au plus profond, les métadonnées des publications, des auteurs, puis la textométrie, afin de saisir les régimes discursifs structurant l'espace de publication autour du « barbare ».

Collection auteurs	Collection references
<pre> { _id : ObjectId, idmysql : int, cle : string, nom_complet : string, Nom : string, Prenom : string, identifiants : {...}, genre : {...}, langue : [...], nationalites : [...], date_naissance : {...}, sujets_etude : [...], ... }</pre>	<pre> { _id : ObjectId, idmysql : int, title : string, year : int, type_of_reference : string, doi : string, keywords : [...], abstract : string, auteurs : [{...}], dispo : [...], topic_analysis : {...}, ... }</pre>

FIGURE 3.5 – Structure simplifiée des collections MongoDB. Les documents de la collection **references** stockent les informations nécessaires à la jointure sur les auteurs dans le tableau **auteurs**. La correspondance avec les documents de la collection **auteurs** est réalisée au via le champ **cle** ; aucune contrainte d’intégrité référentielle n’est imposée par la base elle-même.

Chapitre 4

Pour une cartographie du champ : l'objet « barbare » entre structures sociales et régimes discursifs.

4.1 Le choix des mots clés : condition d'accès au corpus.

4.2 Des mots à la trace

Selon ce que nous avons évoqué précédemment, la constitution du corpus a été permise par le *scraping* de Worldcat à l'aide de mots-clés, choisis au préalable. Si le choix d'un accès au document par des mots est contestable, puisque l'on aurait pu envisager une appréhension par des classements thématiques ou des revues particulières, il semble être une pratique commune en bibliométrie, une étape du protocole (DONTU et al. 2021)¹. Condition d'entrée dans l'archive, il convient d'explicitier les choix ayant présidé à retenir ces mots comme pertinents pour approcher le « barbare » dans sa polysémie et son

1. « In this step, scholars will need to define search terms in a way that will yield search results that is large enough to warrant bibliometric analysis and yet focused enough to remain in the dedicated research field or the scope of study specified in the first step. In this regard, scholars have two options : first, scholars can consult the literature to identify a relevant combination of search terms, and second, scholars can brainstorm among themselves or with subject-matter experts to curate suitable search terms. » (DONTU et al. 2021).

plurilinguisme.

Ces décisions découlent, en partie, de la connaissance à priori que nous avons du sujet, le « sens commun » du « barbare » à la nuance qu'il relevait aussi d'un *habitus* universitaire intégré au cours de deux licences, histoire et sciences politiques, à Paris 1 : d'un côté, un concept lié aux « royaumes barbares » et au paganisme, de l'autre, en lien avec l'anthropologie, le geste consistant à rejeter le désigné dans l'infra-humain, voire le non-humain, par refus du décentrement (TODOROV 2008)².

Pour un premier angle d'approche du sujet, nous avons consulté, en français et en anglais, les pages wikipédia dédiées aux « barbares », aux « germains », ou aux « invasions barbares ». Ce comportement s'inscrit dans un contexte plus large : l'usage de wikipédia comme début d'une recherche est attesté parmi les étudiants de la même génération que celle auquel j'appartiens, à savoir ceux nés entre la fin des années 1990 et le début des années 2010 (FRANCISCO, LARA et PADUA 2023), génération « née alors que les communications numériques étaient déjà bien installées dans la société »³. Loin d'être une source illégitime à disqualifier d'un revers de main, Wikipédia peut refléter des usages de la langue historique et en particulier les plus conventionnels (ROSENZWEIG 2006) ; qui n'est pas sans conséquence pour l'historien (CHAPPEY 2019). Bien qu'elle demeure à critiquer, notamment au regard des enjeux de mémoire sur le sujet (comme évoqué section 1.2.1), le rôle central dans le regroupement de termes liés au « barbare » dans différentes langues n'est pas négligeable. La pléthore des syntagmes offerts peut nous permettre d'approcher, de manière polysémique, le « barbare » ; liste d'autant plus difficile que la pluralité des sémantisations du terme revêt des sens parfois opposés (POL-DROIT 2007), voire inclut des désignations plus contemporaines (SOUSSI IKHLEF 2016).

Une autre approche a consisté à utiliser des usuels, des ressources lexicales comme les dictionnaires historiques, ou la page dédiée du CNRTL⁴ avec la consultation des données de proxémie lexicale en français.

Toutefois, en suivant ROSENZWEIG (Wikipédia reflète des usages plus consensuels de l'objet), la polysémie du terme semble être un aperçu de ses multiples sens dans un champ

2. Et, plus largement, la définition qu'en donnait Claude-Levi Strauss suite à la Seconde Guerre Mondiale (LÉVI-STRAUSS 1987).

3. « Génération Z », Wikipédia, consulté le 18/05/2026, https://fr.wikipedia.org/wiki/G%C3%A9n%C3%A9ration_Z.

4. Disponible à l'adresse suivante : <https://www.cnrtl.fr/definition/barbare>.

scientifique. Ainsi, et en suivant la méthodologie de la récupération des mots clés telle que décrite par DONTU et al., la consultation d'un corpus d'historiographie plus spécialisée s'impose pour accéder au lexique employé par les historiens pour accompagner, désigner ou sémantiser le « barbare » au cours du temps. En ce sens, parcourir ces travaux permet de saisir la pluralité des désignations par lesquelles l'historiographie a tenté de saisir ce terme, et nous avons décidé d'adopter un angle large pour ce faire.

4.2.1 Une liste à tendance maximaliste

D'abord, puisque les bornes chronologiques retenues pour ce travail n'avaient pas encore été choisies au moment du *scraping*, il s'agissait de récupérer l'ensemble des publications que Worldcat associait au terme et à ses équivalents. Toutefois, et nous l'avons vu section 1.1, le terme « barbare » a un sens variant dans le temps : l'étranger linguistique, l'altérité religieuse, puis le Moyen Âge tout entier, l'ancêtre germanique. Cette évolution suggère que nous devons, pour embrasser l'historiographie dans sa diachronie (avec pour idée initiale de remonter au XIX^e siècle), il convenait aussi d'utiliser des termes relatifs aux représentations du « barbare » chez les historiens d'il y a deux siècles. En effet, DUMÉZIL rappelle que l'usage de « barbare » pour qualifier les « Germains » demeure marginal, et son utilisation se fait de plus en plus fréquente à partir de 2000 : ainsi, même si une publication d'avant 2000 porte sur ce que nous considérons actuellement comme « barbare », il est probable que le terme n'apparaisse jamais.

Ainsi, une liste restrictive, centrée sur le seul mot « barbare », aurait produit un corpus incapable de rendre compte de l'évolution que nous tentons de saisir : la liste maximaliste est, en ce sens, la condition de possibilité de l'observation.

Les termes du phénomène migratoire, ou les « barbares » dans leur relation démographique avec Rome

Un premier débat au sein de l'historiographie concerne les déplacements de populations « barbares » dans l'Antiquité par rapport à Rome. Là où les historiens français du XIX^e siècle évoquait les « invasions barbares », terme parfois encore utilisé dans les travaux des années 1990. Ce segment est progressivement substitué pour des formulations mettant moins l'accent sur l'aspect de violence, avec « grandes migrations », « migration period ». Du côté allemand, le terme « Völkerwanderung » semblait déjà moins chargé sur

le plan militaire, mais reste daté, avec une première occurrence en 1778 (MICHAUD 2017). Toutefois, la question des migrations correspond à des visions différenciées de la relation entre les « barbares » et les romains : d'un côté, l'idée d'une pression externe des groupes (HEATHER 2010), et, de l'autre, la projection anachronique d'un mythe nationaliste sur des individus qui n'avaient pas conscience de former un collectif (GOFFART 2006). Ainsi, nous pouvons retenir de ce premier ensemble des termes comme : « invasion », « migration », « accommodation ».

Ethnogénèse et identité des « barbares »

Deuxièmement, les débats autour de l'identité des « barbares » ont produit un vocabulaire précis autour de l'objet, qu'il convient de relever. D'un côté, ces termes gravitent autour de l'ethnogénèse, concept central de l'école de Vienne, introduit par WENSKUS 1977 et diffusé par WOLFRAM 1987 autour des Goths, avant de faire l'objet de critiques depuis les années 2000 notamment (GILLET 2002) : *ethnogenesis*, ethnogénèse, *traditionskern*, *origo gentis*, *strategies of distinction* (POHL et REIMITZ 2023). De l'autre, il s'agit des termes connexes portant sur la construction des identités dans l'idée d'une acculturation progressive entre les groupes : romanisation, barbarisation, acculturation, assimilation, *interpretatio romana*. Si ces termes rappellent les processus de contact entre les romains et les « barbares », remettant en cause une telle dichotomie (POHL et BEAUPRÉ 2005), il convient aussi d'y ajouter les formules latines ou grecques fonctionnant comme des termes techniques (*barbarus*, *barbaria*, *semibarbarus*, *feritas*, *furor barbaricus*, *humanitas*, *gentes*, *gentiles*, *ethne*⁵) pour désigner ces groupes du point de vue des contemporains.

Des noms de peuples

Derrière les « peuples barbares » se dévoile en fait une multiplicité de désignations précises, rendant sensible la pluralité des sociétés « barbares ». Ainsi, les noms des peuples représentent des points d'entrée potentiels dans Worldcat pour renvoyer à des publications portant sur l'objet, sans nécessairement que le mot « barbare » y figure. Une telle liste, bien trop longue pour l'énoncer dans son intégralité ici, a été inspirée des entrées de dictionnaire de l'ouvrage DUMÉZIL 2020, complété à la marge et dans son multilinguisme par Wikipédia. Faire l'impasse sur ces termes aurait en outre conduit à sous-représenter

5. Pour ces derniers, voir GILLET 2002, p. 71.

une part significative de la littérature sur le sujet⁶.

Ainsi, nous trouvons, parmi les peuples « barbares » les plus fréquemment mentionnés dans nos lectures : Francs, Wisigoths, Ostrogoths, Goths, Burgondes, Vandales, Lombards, Huns, Alamans, Saxons, Angles, Normands, Vikings, Scythes, Sarmates, Alains, Hérules, Suèves, Gètes, Marcomans, Gépides — mais aussi la formule plus générique « Germains » et « germanique », en dépit de son anachronisme (GILLET 2006). Ces quelques termes ont été doublés de leur traduction dans les langues retenues, ainsi que leurs désignations alternatives ou plus précises (par exemple Carpes, pour évoquer les Daces ou les Gètes.

De plus, outre les « barbares » liés à la fin de l'Empire Romain d'Occident⁷, nous relevons les termes désignant les peuples appelés comme tels : Frisons, Slaves, Avars, Basques, Danois, Magyars, Hongrois, et Polanes, Moraves, et autres opposants de l'Empire Franc (MAZEL 2021, p. 171) ; les Petchénègues, Turcs, Tartares, Turco-Mongols, Mongols (DUMÉZIL 2020).

Des aspects juridiques, institutionnels et politiques

L'historiographie des « barbares » est aussi portée sur des aspects plus juridiques et institutionnels. En effet, les « lois barbares » (*Lex Salica*, *Lex Burgundionum*, *Lex Visigothorum*, *Lex Ribuaria*) constituent un champ historiographique à part entière (JOYE 2025b). De plus, la terminologie institutionnelle des relations avec l'Empire Romain constitue aussi un lexique : « fédérés », « foederati » (GOFFART 2006), « hospitalitas » (DURLIAT 1997), « deditices », « tributaires » (COUMERT et DUMÉZIL 2020). Enfin, nous pouvons également ajouter les noms des personnages historiographiquement fréquents pour leur rôle politique notamment : Théodoric, Genséric, Alaric, Odoacre, Attila, Euric, Wallia.

L'altérité religieuse comme « barbare »

Comme nous avons pu le souligner en section 1.1, le glissement vers l'aspect religieux du « barbare » se déroule avec la christianisation de l'Empire. En ce sens, les termes désignant l'altérité vis-à-vis du christianisme peuvent, eux aussi, approcher le « barbare »

6. Le mot-clé, en tant que forme, le plus fréquent en occurrences parmi les publications récupérées par Worldcat, est « Saxon » (1890 occurrences), suivi de « Pagan » (1680 occurrences) et « Viking » (1679 occurrences).

7. Cela ne signifie pas qu'ils n'étaient pas déjà présents à cette période, mais leur importance sur le plan historiographique nous a semblé ultérieure dans la chronologie du Haut Moyen Âge.

du Haut Moyen Âge.

Premièrement, une manière de qualifier la religion des « barbares » est l'hérésie : l'adhésion d'une partie de ces groupes à la doctrine arienne a été tenue comme facteur d'altérité⁸. Ces éléments permettent d'enrichir notre liste d'aspects religieux, qui, bien qu'en débat, constituent des désignations autour de l'objet : « arianisme » (LE GOFF et SCHMITT 1996, p. 428, DUMÉZIL 2020), « homéisme », « hérésie » ou « anoméisme ».

En ce sens, la religion « barbare » implique aussi du vocabulaire autour de la conversion, et au paganisme, puisque le « barbare » était aussi le synonyme du païen (DUMÉZIL 2020), nous invitant à retenir des termes comme « christianisation », « conversion », « évangélisation », « paganisme », « gentils ».

En outre, l'ennemi de l'affirmation d'universalité du christianisme était aussi perçu comme « barbare » : l'islam (GRUBER et VISMARA 1977). De ce fait, les termes liés comme « musulmans » ou « Abassides », « Saracènes », « Maures », « Sarrasins » ont semblé pertinents.

Cependant, si le non-chrétien est une périphrase pouvant désigner le « barbare », nous ne relevons pas, en suivant GRUBER et VISMARA, les juifs ni le judaïsme, en ce que les auteurs notent que les juifs étaient exclus des « barbares » car ils étaient perçus comme les témoins archaïques d'une phase révolue de l'histoire religieuse de l'humanité⁹.

Dimensions archéologiques, spatiales et matérielles

Si l'archéologie est un champ disciplinaire distinct de l'histoire, elle peut nous apporter des éléments lexicaux pertinents autour de la culture matérielle des « barbares », à même de nous mener sur la piste de l'historiographie. En effet, HALSALL retrace l'histoire de l'utilisation de l'archéologie comme mode d'identification des groupes ethniques, et par là, des « barbares », dont la remise en cause de l'approche de KOSSINA constitue un point central. En ce sens, les objets considérés comme propres à certains groupes dits « barbares » semblaient pertinents pour les approcher : la spatha, le scramasaxe, la francisque,

8. Même si WOOD (WOOD 2013) comme AMORY invitent à nuancer cette lecture, ce dernier soulignant que « the possibility that Arianism was a regional phenomenon, like the possibility that barbarian warlike behavior was a professional phenomenon, has largely passed unnoticed » (AMORY 1997), nous retenons ce terme comme un possible, dans l'historiographie, pour parler des « barbares »

9. Et pourtant, comme nous allons le voir au cours du chapitre, la question de l'altérité religieuse du judaïsme ressort de nos analyses.

l'angon sont des termes que l'on trouve par exemple dans les publications d'archéologie portant sur les « barbares » (COUMERT et DUMÉZIL 2020) et leur présence dans des titres ou des mots-clés de notices Worldcat était tout à fait plausible.

4.2.2 Traduire, c'est trahir ? La question du multilinguisme dans l'historiographie

La constitution d'une liste de mots-clés pose un second défi, d'ordre linguistique : comment prétendre approcher une historiographie dont les travaux sont rédigés en anglais, en allemand, en espagnol, en italien, sans maîtriser l'ensemble de ces langues ? Nos connaissances en anglais, français ou espagnol sont, bien que réduites, suffisantes pour approcher les termes les plus connus, mais ce n'est pas le cas pour l'allemand ou l'italien : réduire la collecte aux premières serait excluant vis-à-vis de pans de l'historiographie européenne, en particulier au regard de l'activité allemande sur le sujet (voir section 1.2.1).

Plusieurs stratégies ont ainsi été mises en place pour pallier ce problème. De manière systématique, et lorsque cela était possible, nous avons exploité les versions multilingues des pages Wikipédia : à partir d'une page généraliste, sur les « barbares », il devient possible de naviguer vers d'autres versions et d'autres pages plus précises, et distinguer parfois des termes connexes propres à chaque historiographie. Ensuite, nous avons eu recours à des outils de traduction automatique (DeepL) ou des modèles de langue, pour vérifier et compléter les équivalents ; permettant de traiter les cas où Wikipédia ne disposait pas de version dans la langue cible¹⁰.

Toutefois, cette démarche présente des limites, en ce qu'un même concept peut recouvrir plusieurs sens selon la langue, et certains n'ont pas d'équivalent d'une langue à l'autre (nous l'avons vu, « Völkerwanderung » n'a pas le même sens que « invasions barbares »). Une tentative de tempérer cette limite a été l'inclusion de termes dans leur forme latine ou grecque originale, pouvant dès lors circuler dans plusieurs espaces linguistiques comme des mots présents dans les sources mobilisées par les historiens.

10. C'était notamment le cas pour des noms de peuples « barbares » de la péninsule ibérique.

4.3 La langue : « structure structurée et structurante » du champ




FIGURE 4.1 – Distribution temporelle des langues des publications (6 langues les plus fréquentes sur l'ensemble du corpus, et la catégorie « autre » désignant l'ensemble des autres langues ainsi que les publications où la langue était impossible à imputer)

L'analyse suivante s'inscrit dans le cadre théorique bourdieusien mobilisé tout au long de ce mémoire. Loin d'être uniquement un médium de communication, la langue de publication peut se penser comme propriété structurale du champ (BOURDIEU 1977), et relève ainsi d'une stratégie ajustée à la valeur anticipée du produit sur un marché déterminé, indexé sur la position de l'agent dans le champ. Cette proposition peut s'appliquer au champ scientifique, mais comme le souligne GINGRAS 1984 : « si l'on désire traiter le problème de l'usage du français dans les publications scientifiques, il faut donc toujours préciser de quelle "science" on parle, la langue n'étant pas un enjeu sur tous les marchés » ; ce qui implique que la distribution linguistique d'un corpus disciplinaire est un indicateur de la structure du champ considéré et de la position relative des sous-champs nationaux qui le composent. En ce sens, s'intéresser à la distribution linguistique de la médiévistique des « barbares » entre 1975 et 2025 permet d'observer les reconfiguration des rapports de

force entre les sous-champs nationaux, les conditions de circulation du capital scientifique au sein d'un espace social et sémantique où les langues choisies pour la publication sont plus traditionnellement orientées vers le public national ou local (HAMMARFELT 2012, IGGERS 2016).

La capacité, permise par les trajectoires de formation et les ressources institutionnelles de chaque espace national, de maîtriser l'anglais oral et écrit, joue aussi un rôle dans la capacité des acteurs à utiliser une langue dominante du champ. Ainsi, à la dimension stratégique du choix de la langue s'ajoute les dispositions incorporées des agents (*habitus*), inégalement réparties selon les espaces.

En outre, le choix d'une langue de publication se comprend aussi comme un acte épistémologique engageant la définition de son objet. Comme le formule BOURDIEU 1977, chaque champ trace, par l'intermédiaire des sanctions qu'il applique aux occupants de ses différentes positions, « la limite entre le dicible et l'indisible qui le définit en propre » : dès lors, la langue est solidaire d'un héritage historiographique et d'un système de catégories dont la traduction soulève des problèmes. Publier en français, en allemand ou en anglais sur le « barbare » revient à mobiliser des traditions conceptuelles différentes, ce qui a des effets non seulement sur la position de l'acteur dans le champ, mais aussi sur les sémantisations de l'objet lui-même¹¹.

Sur le plan méthodologique, les mesures observées sont issues de deux données que nous avons pu récupérer, selon le protocole décrit chapitre 3 : la part annuelle des publications en anglais dans la production de chaque nationalité, calculée en attribuant à chaque publication la nationalité de son, ou ses auteurs (un auteur binational comptant une fois dans chaque nationalité).

4.3.1 La distribution linguistique du corpus : un indicateur des transformations du champ

La figure 4.1 représente la distribution temporelle des effectifs des publications selon leur langue, et permet de constater l'évolution des langues de publication les plus fréquentes

11. Nous pouvons poser l'hypothèse qu'en passant du lexique commun vers le vocabulaire de l'historiographie, le « barbare » subit une requalification conceptuelle qui lui donne une scientificité relative, au prix d'un déplacement sémantique qui varie selon les traditions langagières. Sans corpus de comparaison toutefois, cette idée ne reste qu'à l'état d'hypothèse.

au sein de notre corpus, de manière concomitante à l'évolution des publications.

Dès lors, il semble que l'anglais, plus que les autres langues, domine largement en tant que *lingua franca* de la médiévisique : le basculement linguistique serait indissociable d'un processus d'expansion du champ considéré. Si en 1985 (voir le tableau 7.3, page 284) l'anglais représentait plus des deux tiers des publications de l'année et le français plus de 20%, nous constatons qu'en 2020 l'anglais atteint plus des trois quarts des publications tandis que le français recule à moins de 10%, confirmant ainsi la dévaluation progressive du français par rapport à l'anglais dans l'espace international que notait BOURDIEU 1977, ici quantifiable sur un corpus de 32 588 références dans un champ disciplinaire précis. Ce mouvement n'est cependant pas uniforme : si l'allemand et l'italien suivent une trajectoire analogue au français, le russe et l'espagnol progressent légèrement depuis leur très faible effectif, ce qui suggère que la dynamique à l'œuvre n'est pas une simple bipolarisation anglais/non-anglais, mais une reconfiguration plus complexe des positions relatives des différentes langues dans le champ, malgré une tendance à l'anglicisation des publications.

Plusieurs hypothèses peuvent expliquer ce phénomène. D'abord, nous pouvons nous demander s'il s'agit d'une reproduction des biais d'indexation de Worldcat, en ce que ses notices sont à 61% en anglais, ce qui est susceptible d'entraîner une surreprésentation des publications anglophones dans notre corpus par rapport à la production scientifique globale. Aussi, le biais de requête est notable, puisqu'elle a été formulée en anglais, français, espagnol, italien ou allemand seulement, orientant les résultats vers ces langues. Toutefois, la première proposition doit être nuancée au regard de la présence des autres langues, en quantités non négligeables, dans notre corpus. En outre, des références écrites en arabe, dont le titre est intégralement en arabe, ont tout de même été récupérées, alors que rien n'indique dans leur RIS une quelconque référence à l'anglais. Les biais, s'ils sont tempérés par ces exemples, ne peuvent être mis de côté et nous imposent une prudence¹² quant à l'interprétation de la proportion de références en anglais au sein de notre corpus¹³. Ensuite, nous pourrions suggérer qu'il s'agit d'une augmentation des auteurs nativement

12. Nous pouvons toutefois analyser la direction et la forme de l'évolution observée, si le biais d'anglicisation est supposé comme stable sur la période.

13. Pour compenser cette limite, il aurait été pertinent de comparer notre corpus avec des corpus spécialisés de médiévisique par exemple. Une piste serait les publications sur le Regesta Imperii OPAC, disponibles à l'adresse : https://opac.regesta-imperii.de/lang_en/.

anglophones, publiant dans leur langue d'origine, au sein du champ. Cependant, l'idée que l'anglicisation du champ serait portée par une poussée de ceux-ci semble contredite par les chiffres observés (tableau 7.5, page 284) : entre les années 1970 et les années 2010, alors que l'anglais devenait de plus en plus hégémonique comme langue de publication, la part relative des nouveaux auteurs américains et britanniques dans le corpus s'est effondrée, passant de près de 30% à seulement 14%. Parallèlement, le flux des nouveaux auteurs français a progressé plus vite ($\times 15,5$) que celui des Américains ($\times 14$), suggérant que l'augmentation des publications en anglais provient d'auteurs non-natifs, ou de la masse des auteurs dont nous ne disposons pas de la nationalité ($\times 45$) qui adoptent l'anglais comme standard de communication¹⁴. Ainsi, ce constat peut rejoindre celui de la littérature sur la part plus importante prise par la langue anglaise dans les publications au cours des dernières années : « It is an important fact that the language of international communication is increasingly English » (IGGERS 2016, p. 139). Plus qu'un choix, l'anglais s'impose progressivement comme une contrainte structurelle de participation au discours scientifique international (V. C. RAO, L. RAO et KUMAR V 2025) : comme le montre GINGRAS 1984, « le choix de la langue et celui de la revue sont motivés en grande partie par une quête de notoriété de la part du chercheur et que l'anglais y joue un rôle prépondérant », ce qui en fait moins un support d'expression librement choisi qu'une condition d'accumulation du capital symbolique dans un champ dont le centre semble s'être déplacé vers l'espace anglophone. Ces ajustements au marché peuvent s'expliquer par la perception du chercheur quant à la « réputation » associée à la langue STOCKEMER et WIGGINTON 2019, p. 649 : le sentiment que publier en anglais accroît le prestige et la reconnaissance internationale du travail constitue le principal moteur de l'anglicisation des publications STOCKEMER et WIGGINTON 2019, p. 645 ; mais aussi avec un effet de cohorte, puisque les jeunes chercheurs, plus à l'aise avec cette *lingua franca* internationale, sont statistiquement bien plus

14. Sur cette masse notable d'auteurs, il semble improbable que *tous* soient nativement anglophones, notamment au regard de la multiplicité des nationalités recensées dans notre corpus et des chiffres de l'UNESCO (nombre de chercheurs par million d'habitants par pays, consulté le 12/04/2026, à l'adresse https://databrowser.uis.unesco.org/view#indicatorPaths=UIS-SDG9Monitoring%3A0%3ARESDEN.INHAB.TFTE&geoMode=countries&geoUnits=&browsePath=SCIENCE_TECHNOLOGY_INNOVATION%2FUIS-SDG9Monitoring%2Ft9.5%2Fi9.5.2&timeMode=range&view=table&chartMode=multiple&tableIndicatorId=RESDEN.INHAB.TFTE&chartIndicatorId=RESDEN.INHAB.TFTE&chartHighlightSeries=&chartHighlightEnabled=true&indicatorPaths=UIS-SDG9Monitoring%3A0%3ARESDEN.INHAB.TFTE

enclins à délaisser leur langue maternelle pour l'anglais que leurs aînés STOCKEMER et WIGGINTON 2019, p. 646, 651. Cette dynamique générationnelle et réputationnelle n'est toutefois pas universelle et se heurte aux structures de chaque sous-champ national.

4.3.2 La structure nationale du corpus




FIGURE 4.2 – Distribution temporelle des nationalités (6 nationalités les plus fréquentes) des auteurs ayant écrit une référence entre 1975 et 2025

Nous ne pouvons nous poser la question de la langue sans nous interroger sur l'inégale répartition de l'accès aux langues dominantes dans le champ. En effet, si l'on peut supposer que, pour les auteurs nationaux de pays anglophones, écrire en anglais relève de l'allant de soi, alors ce n'est pas le cas pour les autres nationalités, qui ont comme option leur langue nationale, ou une autre langue maternelle. Ainsi, les stratégies linguistiques des agents du champ ne peuvent prendre leur sens qu'en relation avec leur nationalité, qui peut indiquer les possibilités d'écriture et de publication des auteurs.

La distribution des nationalités (tableau ??, page ??) suggère une forte concentration de la production : au-delà du bloc constitué par les six ou sept nations les plus représentées, la dispersion s'accroît, dessinant un paysage académique émietté. Cette hétérogénéité

des pôles secondaires justifie notre choix méthodologique de nous concentrer sur les nationalités les plus significatives en volume, d'autant que cette répartition fait preuve d'une relative inertie sur la période étudiée, comme l'illustre la figure 4.2. Si le volume global des publications croît, la hiérarchie des nations dominantes demeure stable : les États-Unis et le Royaume-Uni concentrent à eux seuls près de la moitié des auteurs *dont la nationalité a pu être identifiée*. La part des auteurs aux nationalités indéterminées connaît quant à elle une forte croissance sur la période, en particulier à partir de 2000 : il s'agit peut-être d'une trace, au-delà de la limite méthodologique que représente l'absence de données biographiques, de l'élargissement du champ à d'autres nationalités jusqu'alors peu représentées dans les corpus bibliométriques. Toutefois, cette hausse ne semble cependant pas masquer de basculement majeur dans les rapports de force entre les nations historiquement centrales, dont les positions se maintiennent (sur les nationalités connues, les plus représentées le demeurent).

L'augmentation notable de la part des auteurs aux origines indéterminées ne semble pas masquer de basculement majeur dans les rapports de force entre les nations historiquement centrales, dont les positions se maintiennent.

L'agrégation au sein de la catégorie « Autres » ne doit cependant pas occulter l'émergence d'une communauté savante plus globale, que le tableau permet d'entrevoir : « More than in the period before 1990, but already beginning then, an international scholarly community came into existence, as non-Western scholars, foremost Indian, Middle Eastern, Latin American, but also increasingly historians from Sub-Saharan Africa, occupied important academic positions at American, British and Australian universities and to some extent at the École des Hautes Études en Sciences Sociales in Paris. » (IGGERS 2016, p. 139). Ainsi, le contraste entre cette pluralité des trajectoires individuelles et la tendance au quasi-monolinguisme des publications suggère que l'anglais fonctionne comme le vecteur hégémonique indispensable à l'existence même de cette communauté internationale.

4.3.3 La langue, expression de la position d'une nation au sein du champ ?

Si la domination de l'anglais semble avérée, il convient de nuancer cette observation pour souligner la variété des trajectoires nationales à l'aide de la figure 4.3 (et tableau




FIGURE 4.3 – Evolution annuelle de la part des publications en anglais selon la nationalité des auteurs

TABLE 4.1 – Statistiques de la part de l'anglais (Top 6 nationalités)

Pays	Part moy. d'anglais / an	Part min. d'anglais / an	Part max. d'anglais / an	Nb d'années renseignées
Sweden	82.78	33.33	100.00	50
Poland	51.09	0.00	100.00	48
Germany	39.39	0.00	75.45	51
Italy	33.65	0.00	100.00	51
Spain	33.10	0.00	100.00	45
France	17.48	0.00	50.00	51

4.1¹⁵). En effet, il s'agit d'étudier le volume de production associé au pays via la participation du, ou des auteurs, aux publications (un auteur binational compte donc une fois dans chaque nationalité) en anglais sur le total des publications du pays en question. L'épaisseur du trait¹⁶ permet de représenter l'importance des effectifs considérés : les traits les plus épais représentent les effectifs les plus importants, les plus fins, au contraire, les effec-

15. Pour les données brutes, voir le tableau 7.4 page 271. Notons aussi que toutes nos observations sont au lambda de la récupération des données, hétérogène, comme nous l'avons vu dans le chapitre 3

16. Inspiré ici de la *Carte figurative des pertes successives en hommes de l'armée française dans la campagne de Russie 1812-1813* de Charles Minard (MINARD 1844).

tifs plus réduits¹⁷. Avant d'en commenter les résultats, une limite s'impose : la langue de publication ne peut être réduite à une propriété nationale de l'auteur. Les cas de multinationalité (1140 auteurs multinationaux, 13 891 auteurs mononationaux, et 12 180 non identifiés dans notre corpus total), les traditions de publication dans une langue tierce début de période, ou encore la part importante d'auteurs sans nationalité identifiée dans notre base invitent à lire les propos qui suivent comme des tendances structurelles plutôt que comme des déterminismes nationaux. Cela étant mentionné, nous constatons que pour les six nationalités les plus représentées dans notre corpus, la part d'anglais comme langue de publication augmente au cours de la période. Alors que certains pays, comme la Suède, semblent écrire presque systématiquement en anglais, une trajectoire singulière se dessine pour la France. Ainsi, en Suède, alors que le début de la période (1975) semble osciller sous la barre des 75%, les références publiées en anglais par des auteurs suédois passent à près de 85% après 2010. À l'inverse, alors qu'en 1975, moins de 25% des références publiées par les auteurs français sont écrites en anglais, cette part atteint presque 30% en 2025, maximum pour ce pays. Pour les autres nationalités, si la trajectoire semble s'initier dans des proportions similaires à celles de la France, soit environ un quart en 1975, la part des références publiées en anglais monte jusqu'à représenter entre 50% et 75% de leur production. Cette persistance du français comme langue de publication peut s'interpréter comme une autonomie structurelle du sous-champ médiéviste français, pour partie du moins. Comme le note GINGRAS 1984, « un champ scientifique n'est pas toujours isomorphe à une carte géographique où chaque "nation" occuperait une position déterminée » : en ce sens, ce qui maintient la valeur du français dans ce sous-champ, c'est l'existence d'instances de légitimation nationales suffisamment denses pour que le marché francophone reste rentable. Ainsi, la présence notable des *Annales*, du CNRS, de l'EHESS de laboratoires de recherche (LaMOP) ou des collections d'éditions médiévistes, peut agir comme des pôles capables de conférer du capital symbolique de manière plus autonome de l'espace international anglophone. Par conséquent, publier en français en 2020 sur les « barbares » est un ajustement à un horizon d'attente qui, pour les historiens français, reste majoritairement national : « D'un côté, on trouve le petit nombre de ceux qui font le choix de s'intégrer au marché mondial dominé par les États-Unis [...] Mais en

17. Les différences d'épaisseur ont été obtenues par compression logarithmique puis par la puissance 3.6, choix que je justifie par ma volonté de distinguer les petits des grands volumes de publication sans que les seconds n'écrasent, dans la représentation, les premiers.

contrepartie, il ne peut que s'éloigner des préoccupations et des enjeux propres au marché national, dominé par les historiens davantage tournés vers le grand public » (NOIRIEL 1996, p. 27-28). Cette dualité du marché français peut expliquer le basculement notable, mais ralenti, vers l'anglais — comme en témoignent les premières publications des *Annales* en anglais depuis quelques années et, en 2026, la première publication dans les *Cahiers de civilisation médiévale* en anglais (« Articles en langues étrangères dans les Cahiers de civilisation médiévale » 2026) —, en comparaison à des sous-champs aux *habitus* linguistiques (comme « disposition permanente à l'égard du langage [...] objectivement ajustée à un niveau donné d'acceptabilité » (BOURDIEU 1977) différenciés, comme la Suède, même lorsque le marché international s'oriente vers l'anglicisation. La trajectoire des auteurs polonais constitue à cet égard un cas limite, en ce qu'elle ne correspond ni au modèle français ni au modèle suédois et nous invite à questionner nos observables statistiques. L'observation de la figure 4.3 souligne une croissance de la production en anglais, passant de moins d'un quart à plus de 75% en 2025. Nos données permettent de distinguer trois régimes successifs, même si les effectifs des premières décennies invitent à la prudence dans l'interprétation des proportions. En 1975, sur les 12 publications recensées, 11 sont en français et 1 en anglais : le français semble constituer la principale langue d'accès au champ international pour les rares auteurs polonais alors présents dans le corpus, ce qui suggère que leurs pôles académiques de référence sont alors francophones plutôt qu'anglophones (cela pouvant s'expliquer par le fait que la quasi-totalité des polonais publiants à ce moment sont des bi-nationaux français : à titre d'exemple, Joseph Mélèze-Modrzejewski, historien du droit de l'Antiquité, ou Alexandre Eck, Professeur des lettres (russe)). À partir des années 1990, sur des effectifs plus solides, la reconfiguration ne se traduit pas par une conversion immédiate à l'anglais : on observe simultanément le recul du français (29,6 % dans les années 1990, puis 3,6 % dans les années 2000), la montée du polonais (14,8 % puis 19,6 %) et la progression de l'anglais (48,1 % puis 60,7 %). Il est tentant de mettre en relation cette phase de transition avec la dissolution de l'URSS en 1991 et l'ouverture progressive des universités polonaises aux réseaux académiques occidentaux : l'augmentation du polonais pourrait alors signaler un moment de recomposition institutionnelle consécutif à la chute du bloc soviétique, où les chercheurs réinvestissent temporairement leur marché national dans l'intervalle entre deux régimes de référence (l'ancien, structuré autour du français, et le nouveau, structuré autour de l'anglais), avant que l'ouverture

progressive aux réseaux académiques occidentaux (la Pologne rejoint l'OTAN en 1999 et l'UE en 2004) n'oriente massivement la production vers l'anglais. Cette hypothèse reste cependant difficile à vérifier avec nos seules données bibliométriques, et demanderait à être confrontée à une histoire institutionnelle des universités polonaises sur cette période. À partir des années 2010, l'anglais s'impose à plus de 76 % des publications, tandis que le polonais reflue et que le français devient résiduel. Pris dans son ensemble, et malgré la nécessité de précaution liée aux petits effectifs du début de la période, ce résultat illustre ce que GINGRAS 1984 décrit : le déplacement du marché de référence ne s'opère pas mécaniquement, mais par des formes transitoires d'ajustement où les agents, confrontés à la dévaluation de leur ancienne langue de capitalisation symbolique, passent par un retour provisoire au marché national avant de s'ajuster au nouveau centre du champ. Cette trajectoire polonaise s'inscrit plus largement dans la dynamique propre aux chercheurs européens qui manifestent aujourd'hui la plus forte propension mondiale à adopter l'anglais comme langue de publication STOCKEMER et WIGGINTON 2019, p. 646 ; mais est sans doute également à lier avec les facteurs historiques et politiques propres à l'histoire de ce pays¹⁸.

Ces observations nous invitent à formuler plusieurs hypothèses. D'abord nous pouvons nous demander si l'usage des termes anglais à l'échelle internationale pourrait figer leur sens, alors même que les langues nationales, en préservent des nuances sémantiques. Sans postuler que la langue détermine la pensée, on admet qu'elle peut orienter les possibilités et les cadres conceptuels pour appréhender le monde (SAPIR 1929) : l'uniformisation linguistique, par l'anglais, peut aussi s'appréhender comme une désappropriation des modes de pensées de cet objet¹⁹.

Aussi, nous pouvons poser l'hypothèse que le rythme d'adoption de l'anglais comme langue de publication pourrait être inversement corrélé au degré d'institutionnalisation de la médiévistique dans chaque pays. En ce sens, les espaces nationaux avec une tradition médiévisite (revues, laboratoires de recherche, instances de légitimation) plus ancrée dans le temps disposeraient des ressources nécessaires pour maintenir leur langue nationale

18. Voir, sur un autre sujet, les collaborations franco-polonaises au sujet de la géographie, qui traite aussi des liens universitaires : COUDROY DE LILLE 2021.

19. En ce sens, la pléthore de termes dans de multiples langues au sein de l'historiographie représenterait la pluralité des cadres interprétatifs pour appréhender le « barbare ».

afin d’accumuler du capital symbolique, résistant à la pression vers l’anglicisation. À l’inverse, les espaces où la médiévistique a été plus récemment institutionnalisée adopteraient l’anglais plus rapidement, en raison du manque d’instances de légitimation nationales, de public. Cette proposition demeure à l’état d’hypothèse, pouvant être confrontée avec l’histoire institutionnelle des espaces mentionnés.

Cependant, ce passage d’un régime linguistique à un autre ne répond pas seulement à une quête de visibilité bibliographique, puisqu’il semble affecter la capacité même des chercheurs à s’insérer dans des structures de travail collectives plus larges. Si la Pologne affiche une telle propension à l’anglicisation, c’est que l’adoption de la *lingua franca* constitue le préalable à l’intégration dans les réseaux de collaboration transnationaux. En ce sens, la langue n’est pas seulement un attribut du texte, elle devient une propriété du réseau qui permet la rencontre des nœuds au sein du graphe de coautorat.

4.4 Qui écrit avec qui ? Topologie et inégalités structurelles du réseau de coautorat

Si la langue permet d’appréhender certaines propriétés des agents (positionnement national et ajustement au champ qui s’anglicise), elle ne permet pas d’approcher les relations entre ceux-ci au sein de l’espace de la production scientifique sur le Haut Moyen Âge ; alors même qu’il s’agit d’une propriété au cœur de la notion de champ, puisqu’il est entendu comme « configuration de relations objectives » (CHAMPAGNE et CHRISTIN 2012). Les relations entre les agents peuvent s’envisager de multiples manières, mais nous mobilisons ici une pratique reconnue dans le champ historiographique comme dans la littérature bibliométrique : le coautorat. Bien que d’autres formes de relations auraient pu être utilisées, comme la citation, la correspondance, voire les conférences comme lieu de constitution du capital social (CHEN, DAI et CHEUNG 2026)²⁰, ces données sont inaccessibles à notre corpus, ou non systématiquement renseignées dans nos sources²¹. En revanche, le coautorat

20. CHEN, DAI et CHEUNG conduit une analyse bibliométrique des réseaux de coautorat en sciences sociales chinoises à l’aune du cadre bourdieusien, dont nous transposons ici certaines conclusions méthodologiques.

21. Il aurait pu être envisageable de faire un réseau de citation plus formalisé si nos données venaient de WoS ou Scopus par exemple, en ce que ces bases bibliométriques les enregistrent de manière systématique. En ce sens, notre réseau porte sur les relations objectivées et sanctionnées par la publication, mais

présente l'avantage d'être lisible dans les métadonnées bibliographiques : chaque publication cosignée constitue une trace objectivée d'une collaboration²². Il convient de ce fait de souligner que l'objet considéré ne permet de modéliser que les relations de coautorat ayant abouti à une publication portant des marqueurs distinctifs de plusieurs auteurs, et non l'ensemble des relations structurant le champ²³. Aussi, sur le plan méthodologique, cette analyse repose sur la capacité à désambiguïser les auteurs de notre corpus, protocole décrit dans la section 3.2.3.

Le coautorat désigne le processus par lequel deux agents ou plus produisent conjointement une publication, depuis la conceptualisation jusqu'à la soumission (MACFARLANE et al. 2017). Nous pouvons cependant enrichir cette définition par ce que le coautorat implique, et entre autres, mobiliser un réseau, signaler une appartenance : plus qu'un indicateur de sociabilité scientifique, le coautorat peut s'envisager comme une « stratégie de conversion de capital » (BOURDIEU 1984), dont les logiques reflètent des positions dans le champ et des anticipations sur la valeur des liens noués par le sens du jeu incorporé (CHEN, DAI et CHEUNG 2026).

Envisager les métadonnées des publications pour modéliser un réseau de coautorat permet de déplacer notre regard vers la structure du champ, telle qu'elle se donne à lire dans ses collaborations formalisées, et considérer les positions comme définies par les rapports entre les agents. L'analyse de réseau de coautorat nous permet en ce sens de poser la question des régularités de collaborations, leurs conditions et leurs temporalités ; mais aussi de nous inscrire dans l'étude des dispositifs matériels et institutionnels de la science, ses sociabilités et réseaux (CALLON 1986, LATOUR, WOOLGAR et SALK 1979) autour du « barbare ».

ne permettent pas d'accéder à l'ensemble des relations informelles qui, sans conditionner le coautorat, peuvent avoir un rôle à y jouer.

22. À la limite de certains cas qui, comme nous allons le voir, peuvent rendre plus complexe nos analyses, en particulier lorsque tous les co-auteurs d'un ouvrage signent tous les chapitres ensemble.

23. En particulier étant données les règles, parfois floues, sur la question de l'autorat, de l'ordre des auteurs ou encore la mention des directeurs de recherche des étudiants (SYED et al. 2015).

4.4.1 Construction et lecture du réseau : méthodologie et épistémologie

Méthodologie de la construction du réseau

L’analyse des collaborations scientifiques repose ici sur une modélisation par graphe biparti non dirigé (SAVIĆ, IVANOVIĆ et JAIN 2019, p. 181). Formellement, ce réseau est défini par un triplet $G = (A, P, E)$, où :

- $A = \{a_1, a_2, \dots, a_n\}$ représente l’ensemble des auteurs ;
- $P = \{p_1, p_2, \dots, p_m\}$ représente l’ensemble des publications ;
- $E \subseteq A \times P$ est l’ensemble des arêtes, où une arête $e = (a_i, p_j)$ existe si et seulement si l’auteur a_i a contribué à la publication p_j .

Dans ce cadre, aucune arête ne peut relier directement deux nœuds appartenant au même ensemble ($A \times A$ ou $P \times P$). La publication agit ainsi comme un nœud matérialisant l’événement de co-production scientifique. Selon GASKÓ, LUNG et SUCIU (2016), substituer la publication à l’auteur comme unité de base du réseau permet d’illustrer la production scientifique de manière plus tangible. Ainsi, l’auteur joue un rôle de pivot : ses multiples publications créent les arêtes du réseau, et chaque article co-autoré permet les liens au sein de la structure globale. Cette modélisation permet de capturer non seulement la quantité de collaborations, mais aussi la diversité des contributions : un auteur prolifique apparaîtra, en un sens, central par ses nombreux liens vers diverses publications, tandis qu’une publication apparaîtra comme un *hub* connectant un grand nombre d’auteurs par exemple. De ce fait, à l’instar de HSIEH et al. 2020, nous avons privilégié une structure bipartite pour éviter les biais liés à la projection unipartite et préserver la dualité entre auteurs et publications. Cette approche en graphe biparti pour analyser les formes de coautorat n’est pas nouvelle. En effet, comme l’explique BEAUGUITTE (2013) : « Newman a très tôt (2001) cherché à appliquer ces méthodes aux réseaux de co-publication : les deux ensembles sont les articles et les auteurs, un lien existant entre deux auteurs s’ils ont co-signé un article. On peut d’ailleurs se demander s’il ne serait pas judicieux de le considérer comme un graphe simple, la co-signature d’un article supposant a priori un minimum d’interactions entre les auteurs. . . L’intérêt est pourtant réel dans la mesure où cela permet de calculer des indices tant sur les auteurs que sur les articles et de chercher

les relations entre ces deux séries d'indices. ».

De plus, les arêtes sont différentes, si l'on se concentre sur le graphe biparti, ou le graphe avec une projection unipartie auteur-auteur. Dans un graphe biparti, l'arête relie un auteur à une publication, et en ce sens l'arête enregistre un évènement de production intellectuelle publiée à un instant T , il n'est pas question de pondération ou de direction. En projection unipartie, elle compte une relation de coautorat.

Aussi, il aurait été envisageable d'appliquer une méthode de pondération sur la projection unipartie : si d'un côté la projection simple est non pondérée, traitant de la même manière deux auteurs qui ont co-signé une fois dans un collectif de 12, et deux auteurs qui ont co-signé 8 articles en duo, la projection de Newman permet de modéliser l'intensité de la relation, en ce que le poids de l'arête reflète la proximité (duo ou grand groupe) et la répétition de la relation de coautorat.

La pondération de Newman (NEWMAN 2001)

La méthode de projection simple, permettant de caractériser les liens entre nos auteurs, crée des cliques pour chaque article, ce que NEWMAN (2001) note comme un biais majeur. Une projection classique considère que deux auteurs sont liés s'ils ont cosigné au moins un article. Cependant, cette approche induit un *biais de clique* : un article comportant k auteurs génère $k(k-1)/2$ liens d'égale importance. Comme le souligne Newman, cette méthode surestime l'intensité de la collaboration dans les grands groupes et sous-estime la force des liens dans les duos ou trios de chercheurs (NEWMAN 2001). Afin d'atténuer ce biais, il propose que le poids w_{ij} du lien entre deux auteurs i et j soit calculé par la somme des contributions de chaque publication p qu'ils ont en commun :

$$w_{ij} = \sum_{p \in P_{ij}} \frac{1}{k_p - 1} \quad (4.1)$$

Où :

- P_{ij} est l'ensemble des publications co-écrites par les auteurs i et j .
- k_p est le nombre total d'auteurs de la publication p .

L'utilisation du facteur $1/(k_p - 1)$ repose sur l'hypothèse que le temps et l'effort consacrés par un chercheur à collaborer avec un autre sur un article donné sont inversement proportionnels au nombre total de co-auteurs sur cet article.

La mise en oeuvre de ces choix consiste alors à calculer le graphe biparti avec quatre projections, une pour les auteurs et une pour les publications, et, à chaque fois, un calcul des indicateurs (tableau 4.2) pour la projection simple et celle de Newman.

TABLE 4.2 – Indicateurs de centralité calculés sur les deux projections du réseau biparti

Indicateur	Réseau auteur-auteur	Réseau publication-publication
Degré	Nombre de co-auteurs distincts.	Nombre de publications partageant au moins un auteur.
Betweenness	Fréquence à laquelle un auteur se trouve sur le plus court chemin entre deux autres nœuds du réseau, normalisée sur l'ensemble des paires possibles.	Même mesure appliquée aux publications : fréquence à laquelle un texte s'interpose sur les plus courts chemins entre deux autres.
PageRank	Score de centralité itératif : un auteur est d'autant mieux classé qu'il est connecté à des auteurs eux-mêmes bien classés.	Même algorithme appliqué aux publications : un texte est central s'il est relié à des textes centraux via des auteurs partagés.
Centralité de Katz	Variante du PageRank comptant tous les chemins entre deux nœuds, pondérés exponentiellement par leur longueur ($\alpha = 0,85 / \lambda_{\max}$).	Même mesure sur le réseau de publications.
Eigenvector	Le score d'un nœud est proportionnel à la somme des scores de ses voisins directs. Sensible aux effets de clique (grands collectifs d'auteurs).	Même mesure sur le réseau de publications.
Clustering local	Part des paires de co-auteurs d'un auteur qui sont eux-mêmes co-auteurs entre eux (de 0 à 1).	Même mesure : part des publications voisines qui partagent elles-mêmes un auteur.

Ainsi, pour la formation de ce réseau, nous retenons l'ensemble des publications de notre base ayant plus d'un auteur, soit 4734 documents. Pour identifier les publications coautorisées, le RIS fourni par Worldcat permet de distinguer les auteurs d'une même

publication avec l'utilisation de plusieurs balises AU – dans le fichier²⁴. S'il aurait été pertinent d'approcher le capital symbolique et les inégalités structurelles des agents à partir de la question de l'ordre des auteurs (c'est à dire, quels noms sont mis avant le « et al. »)²⁵, Worldcat ne nous fournit pas une telle donnée : rien ne nous indique, dans l'ordre des champs AU –, qu'il respecte l'ordre des auteurs de la publication. De plus, la nature et la mesure des contributions ne nous sont pas fournies, ce qui, dans notre modèle, met tous les auteurs dont le nom figure dans le RIS sur un pied d'égalité ; alors même que les contributions ne sont souvent pas également réparties ; (MACFARLANE et al. montre par exemple que les auteurs les plus installés dans le champ, les directeurs de recherche ou les enseignants sont plus souvent surcrédités par rapport aux doctorants). Pour l'ensemble de nos analyses ultérieures, et sauf indication explicitement signalées, notre propos se concentre sur la composante connexe principale de notre réseau (nous retenons l'abréviation LCC, à l'image des publications anglo-saxonnes sur le sujet).

Un microcosme aux règles propres

Avant d'analyser la topologie du réseau construit par les méthodes détaillées précédemment, il convient de s'interroger sur la signification du coautorat dans le cadre d'analyse que nous nous sommes donnés, le champ. Si la rencontre entre la *Social Network Analysis* et l'outillage théorique développé par Bourdieu n'est pas un donné, en ce que Bourdieu lui-même privilégiait les analyses des correspondances, la recherche a pu montrer que leur articulation peut être faite (DE NOOY 2003 ; MU 2019 ; TURNBULL et al. 2019)²⁶.

Le coautorat s'envisage ainsi comme une pratique située, expression d'un *habitus* ajusté aux contraintes et aux possibles du champ : pressions institutionnelles, dispositions incorporées par les trajectoires scolaires, interaction avec ses pairs, position structurelle dans le champ (CHEN, DAI et CHEUNG 2026). Il s'agit en ce sens d'un lieu stratégique d'accumulation et de conversion des capitaux (CHEN, DAI et CHEUNG 2026), puisque co-autorer revient aussi à mobiliser un capital social (accès à des réseaux, institutions et

24. À condition de bien nettoyer les cas où plusieurs auteurs sont dans le même champ.

25. Par exemple, MACFARLANE et al. met en avant une moindre visibilité des femmes dans les premiers auteurs, indépendamment de leur contribution.

26. En l'occurrence, l'analyse de réseaux sociaux tente de saisir les relations structurelles et leurs implications, les structures de connectivité et de distribution du pouvoir dans un système social, dans le cadre d'une approche systématique et paradigmatique ; ce qui n'est pas incompatible avec les instruments de Bourdieu (MU 2019).

légitimités), le convertir en capital symbolique par la publication, et potentiellement le redistribuer vers des agents moins dotés, mais coauteurs (CHEN, DAI et CHEUNG 2026). Les agents dominants dans un champ peuvent être pris comme des points de référence pour tous les autres agents du champ, en ce qu'ils déterminent les formes de capital légitime, ceux qui entrent dans le champ, et combien les autres agents possèdent et peuvent posséder de capital scientifique et symbolique²⁷ De plus, Bourdieu note que la logique des grandes équipes, qui sont de plus en plus nombreuses comme nous allons le voir, modifie structurellement les pratiques d'écriture et de publication (BOURDIEU 2001, p. 6).

L'interprétation de notre réseau en termes bourdieusiens implique de traiter les indicateurs de centralité comme des indices sur la position structurale des agents et des publications au sein du champ²⁸.

- D'abord, les relations intersubjectives permettent d'approcher le capital social (DE NOOY 2003), ce qui peut se traduire par les indicateurs de degré projeté sur le réseau auteur-auteur (et, par extension, le degré pondéré).
- Le capital symbolique se concentre quant à lui sur l'asymétrie des relations (DE NOOY 2003), que le coautorat, relation non dirigée par construction, ne peut pas restituer directement. Dans ce cadre, l'eigenvector ne mesure pas l'asymétrie des échanges mais la qualité du voisinage : être co-auteur d'agents eux-mêmes centraux ; le capital symbolique ne pourrait, en ce sens, qu'être approximé à l'aune des citations²⁹.
- La structure centre-périphérie du champ peut se rendre visible par l'indicateur de closeness, en mesurant la proximité structurale de chaque agent au reste du réseau (DE NOOY 2003).

27. Toutefois, ces agents ne sont pas nécessairement les noeuds les plus centraux de notre réseau (On peut penser ici à GILLET, POHL, BROWN, WOOD, GEARY et autres) - d'autant que le coautorat reste une pratique, comme nous allons le voir, peu récurrente en histoire.

28. Pour toutes nos analyses ultérieures, sauf indication du contraire, notre propos porte sur la composante connexe principale du réseau.

29. Néanmoins, nous pouvons aussi proposer une autre approche à l'aide des indicateurs qualitatifs dont nous disposons sur notre réseau. En effet, comme nous le verrons en section 4.5, il est possible de projeter la thématique des articles dans notre réseau. En ce sens, et en suivant TURNBULL et al., nous pouvons lier nos observations au capital symbolique des agents (« the life science fields tend to be viewed as high in symbolic capital (prestige) », TURNBULL et al. 2019).

- Enfin, la question de la circulation ou de la conversion des capitaux peut s’interpréter au regard de la betweenness, permettant de connecter des groupes qui, autrement, ne communiqueraient pas ensemble : (« transverse movements entail a shift into another field and the reconversion of one type of capital into another or of one subtype into another subtype... and therefore a transformation of the asset structure which protects overall capital volume and maintains position in the vertical dimension, » (TURNBULL et al. 2019))

Si nous pouvons tenter de lier indicateurs et formes de capitaux, il faut souligner qu’ils ne peuvent s’interpréter comme des équivalents : nous les mobilisons ici comme des outils théoriques pour interpréter nos observables statistiques et analyser la structure du réseau. En traitant les indicateurs comme des indices de position structurale, l’analyse de réseau permet, en un sens, de tenir un propos sur le champ et l’espace des positions, et en particulier sur la distribution du capital social.

4.4.2 Cadrage général et premiers observables statistiques




FIGURE 4.4 – Distribution temporelle des groupes de coautorat

Un premier constat, à la quantification des publications répondant à notre critère, est que cette pratique demeure minoritaire (figure 4.4) : la médiane du nombre d’auteurs par publication est à 1 sur l’ensemble de la période. Si cela semble évident pour des objets touchant aux sciences humaines et sociales, comme l’a montré ANDERSEN en comparant systématiquement les publications sur WoS entre 2000 et 2020 (ANDERSEN 2023), cela signifie que le coautorat présenté ici est un espace d’espace, sous-champ construit à partir de notre corpus global (et non à partir de l’ensemble des publications publiées par les auteurs de notre base³⁰), qui n’isole qu’une pratique minoritaire qu’il convient de décrire, puis de positionner les agents en son sein.

Un second constat concerne l’évolution du coautorat, qui augmente au fil du temps : la figure 4.4 témoigne de sa lente croissance. Ce dernier point ne semble pas surprenant au regard des travaux portant sur ces pratiques (MACFARLANE et al. 2017 ; ANDERSEN 2023 ; GINGRAS 2014, p. 41 ; CHEN, DAI et CHEUNG 2026), qui soulignent plusieurs raisons pouvant expliquer cette augmentation à partir de données qualitatives (MACFARLANE et al. 2017) :

- l’augmentation de la compétition dans le champ vis-à-vis des pairs. Les interrogés déclarent ressentir qu’une obligation de publier pèse sur les chercheurs en début de carrière, expliquant pourquoi certains agents les plus installés co-publient avec leurs étudiants.
- l’accessibilité accrue du coautorat. Les réseaux de collaboration internationaux et le rôle de la technologie (internet et les réseaux sociaux) semblent favoriser le coautorat en permettant aux auteurs de travailler sur le document simultanément et communiquer plus facilement.
- les mutations de la recherche. L’augmentation de l’interdisciplinarité, des recherches participatives et des méthodologies différenciées semble requérir une collaboration plus importante.
- une meilleure acception du coautorat - voire une pression. Certains interrogés déclarent que le coautorat est mieux perçu qu’avant, et pourrait même être une source de financement pour la recherche.

30. Ce qui aurait pu élargir notre réseau, en ce que les auteurs considérés ont peut être publié des documents que nous n’avons pas récupérés, qui les auraient pourtant liés avec une composante, voire le réseau.

Toutefois, la présence d’une composante principale aussi importante, comme nous le verrons ultérieurement, a de quoi surprendre (voir figure 7.1, page 287). En effet, la majorité des composantes (c’est à dire les 2334 autres) comporte un faible nombre d’auteurs et, par extension, de publications : la seconde plus grande composante compte moins de 130 auteurs.




FIGURE 4.5 – Boxplot du nombre de coauteurs par auteur dans la composante connexe principale et dans les autres composantes connexes

De plus, comme en témoigne la figure 4.5, la composante connexe principale est d’autant plus particulière qu’elle concentre des publications avec des larges nombres de coauteurs, éloignant l’écrasante majorité des duos et trios en sciences humaines, comme en témoigne la médiane à 3 coauteurs pour les composantes connexes (contre 13 pour la composante connexe principale!). Cette tension, entre pratique rare en humanités et en sciences humaines et la présence d’une telle topologie du réseau nous invite à poser l’hypothèse que cet espace de coautorat, isolé par notre modélisation, constitue un microcosme distinct du champ, mais pourtant pris en son sein, qu’il convient de qualifier.

Le réseau, arrêté en 2025, compte 19 746 nœuds (15 012 auteurs et 4 734 publications), organisés en 2335 composantes connexes, avec une densité de $8,3 \times 10^{-4}$, ce qui traduit la forte fragmentation du réseau en composantes largement isolées dans ce champ historiographique (voir tableau 4.3). Le coefficient de clustering moyen, mesurant la propension des coauteurs à être eux-mêmes coauteurs entre eux, est de 0,03 en projection simple, et chute à 0,012 en projection Newman³¹. La composante connexe principale, dont le diamètre est de 18 (soit le plus long des plus courts chemins entre deux nœuds quelconques

31. Cet écart reflète le biais de formation de cliques évoqué plus haut. La projection simple surestime la densité locale des triangles en traitant toute co-signature collective comme un réseau dense de paires,

TABLE 4.3 – Indicateurs descriptifs du réseau de co-autorat

Indicateur	Valeur	Remarque
Noeuds (total)	19 746	auteurs + publications
dont auteurs	15 012	
dont publications	4 734	
Arêtes (biparti)	20 480	auteur–publication
Arêtes (projection unipartie)	93 378	auteur–auteur
Facteur multiplicateur	$\times 4,5600$	biais de clique
Densité	$8,29 \times 10^{-4}$	
Composantes connexes	2 335	
Diamètre (comp. princ.)	18	
Clustering moyen (proj. simple)	0,0299	
Clustering moyen (proj. Newman)	0,0120	–60%

de la LCC) suggère qu’il existe des groupes isolés dont les liens se font par des ponts indispensables à la structure en composante connexe principale.

4.4.3 Qui ou quoi est dans la composante principale ? Accès et premières inégalités

Avant de nous concentrer sur les indicateurs propres au réseau, il convient de décrire dans un premier temps les caractéristiques de la sous-population étudiée par rapport à notre corpus global — et dans une moindre mesure, par rapport aux autres composantes connexes. Si la composante principale est le lieu où se structurent les collaborations les plus denses et les plus globales, y accéder constitue déjà, en soi, une première forme d’inégalité que les indicateurs de centralité ne peuvent pas restituer seuls.

En premier lieu, et nous l’avons esquissé dans la section 4.3, la langue semble être un critère de sélection structurant (tableau 7.13, page 294). L’anglais représente 70,2 % des

tandis que la pondération Newman, en atténuant les contributions des grands collectifs, souligne un réseau localement moins cohésif qu’il n’y paraît, même si, en l’occurrence, le clustering moyen n’était déjà pas très élevé.

publications de la base de données et 71,9 % du réseau de coautorat, mais atteint 81,9 % dans la LCC : ainsi, si la langue n'est pas nécessairement une condition de l'écriture à plusieurs, l'écriture en anglais semble conditionner le réseau des relations les plus structurées et les coautorats plus globaux. Cette domination anglophone s'accompagne d'un mouvement inverse : le français recule de 12,5 % (BDD) à 9,8 % (réseau) puis à 7,1 % (LCC) ; l'espagnol de 3,8 % à 4,3 % puis à 0,7 % ; l'italien de 3 % à 1,7 % à 0,4 %. D'un autre côté, certaines langues sont plus favorisées dans le réseau, comme le russe (4,2 % contre 2,0 % dans la base, puis 1,7 % dans la LCC), voire dans la LCC, comme le slovène (0,8 % dans notre base, 1,0 % dans le réseau et 1,7 % dans la composante principale), même si ces écarts sont sensiblement moindres que l'augmentation de l'anglais (tant dans l'effectif qu'en points de pourcentages).

Si la question de la langue est liée à la nationalité, nous notons un mouvement similaire (tableau 7.14, 297). Les auteurs britanniques passent de 18,7 % à 19,8 % puis à 24,9 % ; les États-Uniens de 22,8 % à 21,6 % puis à 25,3 %. La Pologne progresse de 3,5 % à 4,1 % puis à 5,2 %, et la Suède de 4,1 % à 5,1 % puis à 5,3 % ; ces nationalités étant celles identifiées dans la figure 4.3 comme ceux ayant une anglicisation importante. De l'autre côté, la France passe de 17,6 % des auteurs de la base, puis à 16,4 % dans le réseau et à 11,4 % dans la LCC. L'Italie suit le même mouvement (8,9 %, puis 8,0 % et enfin 4,5 %), tout comme l'Espagne (4,8 % puis 4,6 %, et enfin 2,5 %).

Du point de vue de l'articulation entre nationalité et langue, l'accès à la LCC du réseau n'est pas socialement neutre, en ce qu'il sélectionne de manière structurelle les agents et les communautés dont l'*habitus* d'écriture est adapté à la maîtrise de l'anglais comme capital linguistique légitime, règle du jeu structurant les formes de coautorat les plus intégrées. En revanche, il convient de noter que l'accès à la LCC ne semble pas discriminant en termes de genre (tableau 7.11, 293), puisque les femmes représentent 31,6 % des auteurs de la base, 32,4 % du réseau de coautorat et 32,9 % de la composante principale ; soit des proportions stables, si ce n'est qui tendent à l'augmentation (s'expliquant probablement par une diminution des NA)³².

Du côté des publications cette fois, si nous avons vu que le coautorat est en augmentation, il l'est notamment au sein de la composante principale (tableau 7.10) : la médiane de

32. Cette observation ne préjuge en rien de la distribution des positions structurales au sein du réseau, interrogeables par les indicateurs de centralité.

publication est de 2013 pour l'ensemble de la base, de 2015 pour le réseau de coautorat, et de 2016 pour la LCC. En ce sens, en plus d'être une pratique minoritaire, le coautorat et son pendant le plus dense est une pratique de la dernière décennie.

Interprétation des topics BERT

En suivant le protocole détaillé dans la section 3.2.6, il semble possible d'acquérir une première idée de la thématique abordée par les publications anglophones de notre corpus, et de projeter ces thèmes sur notre réseau. Cependant, il convient de prime abord d'interpréter les résultats de BERTopic, tant sur les titres que sur les chapitres, que nous avons analytiquement séparé. Les tableaux 7.16 et 7.17, page 302 permettent de présenter les labels retenus et les termes c-TF-IDF caractéristiques. En effet, en convertissant tous les titres d'un topic en un sac de mot, et appliquant un c-TF-IDF dessus, il devient possible de faire ressortir les mots les plus discriminants du corpus. L'interprétation des clusters s'est fondée sur les termes c-TF-IDF les plus discriminants par topic, complétés par un tirage aléatoire de titres représentatifs afin de valider qualitativement chaque label retenu.

Du côté des articles _____

Pour les articles (effectif de 12 136 dans le corpus, 1706 dans les autres composantes et 1108 dans la LCC), nous avons regroupé les titres en 15 topics, que nous décrivons ci dessous.

Le topic 0, en raison des tokens présents, semble porter sur le monde nordique et viking (*viking, scandinavian, norse*), et présente des documents comme « Gudrid Thorbjarnardottir (born c. 980) : fearless explorer » (id : 69825516c835c41957df9443), ou encore « Eastward and northward : a geographical conception of 'Noromannaland' in Ohthere's Voyage and its analogues in old Norse/Icelandic literature » (id : 69825516c835c41957dfa3e3).

Le topic 1 regroupe des publications liées à la bioarchéologie, l'ostéoarchéologie et aux sciences naturelles, en ce qu'il regroupe des mots particulièrement spécifiques : *analysis, population, evidence, genetic*. Si les premiers termes peuvent sembler communs, il convient de croiser leur sens à l'analyse qualitative des titres du cluster, soulignant l'orientation thématique particulière de ce dernier : « Origins of East Caucasus Gene Pool : Contributions of Autochthonous Bronze Age Populations and Migrations from West Asia Estimated from Y-Chromosome Data » (id : 69825516c835c41957df9ca1), ou encore « Multi-proxy bioarchaeological analysis of skeletal remains shows genetic discontinuity in a Medieval Sicilian community » (id : 69825516c835c41957dfa593).

Le topic 2 semble porté sur la religion, la théologie ou la scolastique, comme en témoignent les tokens *pagan, christian, god, religious, church* ou *saints*. Ainsi, nous retrouvons associés à ce cluster des documents comme « Catholic and Protestant Translations of the Imitatio Christi, 1425–1650 : From Late Medieval Classic to Early Modern Bestseller St. Andrews Studies in Reformation History » (id : 69825516c835c41957df9e05), ou « Least of the laity : the minimum requirements for a medieval Christian » (id : 69825516c835c41957dfa4c0).

Le topic 3, bien que plus difficile à interpréter au regard des mots les plus spécifiques au c-TF-IDF, semble porter sur la littérature, la philologie et la musique : *english, poetry, music, literature*. En ce sens, il relèverait d’une historiographie attentive aux sources textuelles, regroupant des documents avec les titres « Archbishop Wulfstan’s criticism of King Edgar in the Anglo-Saxon Chronicle » (id : 69825516c835c41957df9d5b), ou « Semiramis an Early 11th c. Norman Text with Anglo-Danish Connotations Reviewed as a Dramatic Script » (id : 69825516c835c41957dfa332).

Le topic 4 semble tourné vers l’art, l’architecture et l’iconographie : *manuscript, sculpture, textiles, architecture, art*. Bien que la présence de *manuscript* rappelle le topic 3, nous notons qu’il s’agit, dans les titres observés qualitativement du moins, d’un rappel de la source de laquelle est issue l’iconographie. Quelques exemples de titres sont « Gestures, positions and pictorial communication in the late-medieval visual life of Saint Barbara » (id : 69825516c835c41957df9f0f), ou « Unlocking the menagerie : Exploring symbolic animal depictions in ninth-century Anglo-Saxon manuscripts » (id : 69825516c835c41957dfa8b1).

Les mots c-TF-IDF du topic 5 semblent suggérer une orientation vers le monde Méditerranéen, l’Islam et le judaïsme : *spain, jews, arabic, islamic, saracens* ; ou la diversité de l’altérité religieuse du point de vue de la chrétienté. Ainsi, nous retrouvons au sein de ce cluster des documents comme « Religious Diversity in the Early Medieval Middle East through the Lens of the Syriac Chronicle of Zuqnin » (id : 69825516c835c41957df9c98) ou « The military orders and the conversion of Muslims in the twelfth and thirteenth centuries » (id : 69825516c835c41957dfa440).

Le topic 6 regroupe des titres rapprochant le cœur du sujet, avec des mots comme *barbarians, roman, byzantine, merovingian* ; ce qui n’est pas sans rappeler les « royaumes barbares » prenant place en Europe à la fin de l’Empire Romain d’Occident. Dans ce cluster, nous pouvons retrouver des titres tels que « The “Fear” of the Barbarians and the Fifth-Century Western Chroniclers » (id : 69825516c835c41957df9ddf), ou « The Church and its bishops in the Ostrogothic Italy : a study of the ownership relations » (id :

69825516c835c41957dfa8c2).

Le topic 7, bien qu'unique en théorie, peut se subdiviser en deux parties désignant le monde à l'Est de l'Europe. D'un côté, le topic 7a porte sur l'Europe centrale et Orientale et Byzance ; de l'autre, le topic 7b est distinct sur le plan géographique en approchant des mots liés au Monde mongol, à la Russie ou à l'Asie centrale : « The Gradisce above Baselj archaeological site » (id : 69825516c835c41957df9dce) ; « Iron technology and medieval nomadic communities of East Mongolia » (id : 69825516c835c41957dfb819).

Le topic 8 semble un peu plus périphérique vis à vis de notre sujet, en abordant l'histoire sociale et économique : *slavery, trade, migration* ; portant hypothétiquement sur l'esclavage et le commerce au Moyen Âge. Les titres regroupés vont dans ce sens : « FROM THE MARKETS OF DAMOT TO THAT OF BÄRARA : A Note on Slavery in Medieval Ethiopia » (id : 69825516c835c41957df9de3), ou « Eastern Europe in the Mediterranean system : Stages of Medieval Globalization » (id : 69825516c835c41957dfa047) ; mais l'hétérogénéité et la polysémie vis à vis des « slaves » rend l'interprétation de ce cluster plus difficile.

Le topic 9, en rassemblant les tokens *italy, france church, fresco, miniature, mosaic*, semble tourné vers l'iconographie religieuse en France et en Italie. Quelques exemples de titres vont dans ce sens : « “Mudéjar”, Islamic Influence or Memory of the Past ? Some Considerations on the Wooden Painted Ceiling of the Palazzo Chiaromonte-Steri in Palermo » (id : 69825516c835c41957dfa250), « Study of Medieval Artistic Stained Windows : The Case of the Rose Window of Sant’Ambrogio Chapel in the Basilica of San Petronio in Bologna—Italy » (id : 69825516c835c41957dfb9d2).

Le topic 11 porte sur le droit, les institutions et la guerre, avec les tokens *law, legal, war* et *battle* ; et des titres comme « Making or Declaring Law ? Legislative Intent and Privileged Speech in Anglo-Saxon England » (id : 69825516c835c41957df9442) ou « BURGUNDIAN BOOTY AND THE RISE OF THE SWISS THE BATTLE OF GRANDSON » (id : 69825516c835c41957df9f2d).

Le topic 13 semble quant à lui porter sur l'archéologie médiévale, et en particulier le peuplement, avec *civilization* ou *settlement*. Si le topic présente également les termes *norman, england, burgundian*, nous pouvons supposer qu'il s'agit du cadre géographique dans lequel la thématique s'inscrit : « Hidden riches in the Early Medieval Rhine Delta : Iron working at Merovingian Oegstgeest » (id : 69825516c835c41957df9e2c), ou « Goldworking in Britain From Iron Age to Medieval Times » (id : 69825516c835c41957df9fb3).

Le topic 14 semble porté sur l'histoire environnementale et la paléolimnologie. En effet,

on y retrouve les termes *climate, holocene, changes, evidence*, associés à des termes géographiques avec *sweden* ou *germany* ; et des titres comme « Late Quaternary fluvial environments at Abo Arroyo, New Mexico, U.S.A. ; response to millennial-scale climate change » (id : 69825516c835c41957df9d50), ou « An integrated archaeo-palaeoenvironmental approach to the study of human-environment relationships in the Wierzchowo Lake microregion (Northern Poland) during the Mid- to Late Holocene » (id : 69825516c835c41957df9d5e).

Le topic 15 regroupe des termes liés à la question du genre et du corps, avec *women, gender, female, power*, probablement dans la littérature anglo-saxonne (*england*). Par exemple, le cluster regroupe des titres comme « Chapter 24. Queens, heroines and slaves : Women in two Persian Alexander romances (12th century) » (id : 69825516c835c41957df9e5a) ou « Citation and marginalisation : the ethics of feminism in Medieval Studies » (id : 69825516c835c41957dfa397).

Enfin, le topic 18 regroupe le bruit éditorial et les recensions que nous avons identifié : *reviews, buchbesprechungen, notice*, avec des titres comme « Review : Unfinished Christians : Ritual Objects and Silent Subjects in Late Antiquity , by Georgia Frank » (id : 69825516c835c41957dfa18a) ou « John Hines & Nelleke IJssennagger-van der Pluijm (ed.). 2021. Frisians of the Early Middle Ages (Studies in Historical Archaeoethnology 10) . Woodbridge : Boydell ; 978-1-78327-561-8 hardcover £90 » (id : 69825516c835c41957df9d56)

Du côté des chapitres _____

Pour les chapitres (effectif de 9 703 dans le corpus, 726 dans les autres composantes et 316 dans la LCC), notre protocole a abouti à la formation de 15 clusters.

Le chap 1 porte sur l'archéologie, la culture matérielle et le bâti, notamment au sein de l'espace anglo-saxon : *saxon, archaeology, landscape, textiles*. Ainsi, il regroupe des chapitres comme « 2 Roads and Tracks in Anglo-Saxon England », dans *The Material Culture of the Built Environment in the Anglo-Saxon World* (id : 69825516c835c41957df9385), ou encore « 3 Colonial settlement », dans *Castles and colonists : An archaeology of Elizabethan Ireland* (id : 69825516c835c41957df9394).

Le chap 2 semble se rapporter aux structures législatives et institutionnelles du pouvoir : *law, society, military, power* ; avec des titres comme « TWO The Origins of the French Nobility » dans *Those of My Blood : Creating Noble Families in Medieval Francia* (id : 69825516c835c41957df91ba), ou « From Feudal to National Monarchy » dans *A History of the Middle Ages 284-1500* (id : 69825516c835c41957dfb5cf).

De son côté, le chap 3 se rapproche beaucoup du topic 0, avec un vocabulaire se rapportant au même sujet : *scandinavia, viking, age, norse, denmark*. Nous pouvons trouver,

dans les chapitres dont le titre est dans ce topic, « 5 Weland, Ulfberht, and Other Artisans » dans *The Conversion of Scandinavia : Vikings, Merchants, and Missionaries in the Remaking of Northern Europe* (id : 69825516c835c41957df91b3), ou encore « 2 Houses of Wood, Houses of Stone », dans *Facing Otherness in Early Modern Sweden : Travel, Migration and Material Transformations, 1500-1800* (id : 69825516c835c41957df9426).

Le chap 4 semble se rapporter davantage à la culture de l'écrit et à la littérature, avec comme tokens c-TF-IDF les plus contributifs *language, writing, latin, encyclopedia*. Par exemple, il présente les chapitres « History of the Italian Lexicon » dans *Oxford Research Encyclopedia of Linguistics* (id : 69825516c835c41957df919d) et « Introduction » dans *Between the Text and the Page : Studies on the Transmission of Medieval Ideas in Honour of Frank T. Coulson* (id : 69825516c835c41957df9f41).

Le chap 5 semble, à son tour, proche du topic 15 : *women, female, rape, gender*, aussi localisé vers l'anglais (*scots, english, literature*). Comme titres, nous pouvons relever la présence de « 6 Privileging the Feminine » dans *Courtly Desire and Medieval Homophobia : The Legitimation of Sexual Pleasure in Cleanness and its Contexts* (id : 69825516c835c41957df91af), ou encore « 1 DOMESTIC SECRETS » dans *Domestic Secrets : Women and Property in Sweden, 1600-1857* (id : 69825516c835c41957df9881).

Le chap 6, de la même manière que le topic 5, porte sur l'altérité religieuse et la question des relations entre les religions : *jews, islamic, muslims, christians, othering*. En ce sens, il regroupe des titres comme « 4 Creating a Christian Aristocracy » dans *A State of Mixture : Christians, Zoroastrians, and Iranian Political Culture in Late Antiquity* (id : 69825516c835c41957df91ab), ou « CHAPTER 1 Being Muslim in Christian Spain » dans *To Live Like a Moor : Christian Perceptions of Muslim Identity in Medieval and Early Modern Spain* (id : 69825516c835c41957df934c).

Le chap 7, évoquant explicitement le *barbarian*, semble avoir pour thème l'Europe de l'Est et la question des identités ethniques : *slavs, identity, ethnicity, byzantine, slavic*. Quelques titres de ce cluster sont par exemple « Visiting Pannonia », dans *Hungarian Rhapsodies : Essays on Ethnicity, Identity, and Culture* (id : 69825516c835c41957df948f) ou « 3 ROMAN LAW AND BARBARIAN IDENTITY IN THE LATE ROMAN WEST » dans *Ethnicity and Culture in Late Antiquity* (id : 69825516c835c41957df9290).

Le chap 8 porte, comme le topic 3, sur la littérature anglaise, le théâtre, la musique et la poésie, avec les tokens *magic, english, poetry, music, literature, heroes*. Ainsi, nous trouvons dans ce cluster des titres comme « Introduction » dans *Poems and Prose from the Old English* (id : 69825516c835c41957df91b4) ou « 1 The Mouth of Hell » dans *Stages*

of Evil : Occultism in Western Theater and Drama (id : 69825516c835c41957df933f).

Le chap 9 est toutefois spécifique, en ce qu'il porte sur les conférences internationales liées à l'archéologie ou à l'informatique, avec les termes *conference*, *ieee*, *international*, *digital*. Unique en son genre dans notre corpus, nous retrouvons en son sein « RECONSTRUCTING THE SPATIAL LAYOUT OF THE CHURCH OF ST. LAWRENCE, SIGTUNA, SWEDEN USING GROUND-PENETRATING RADAR AND PHOTOGRAMMETRY » dans *Archaeological Prospection : Proceedings of the 10th International Conference - Vienna May 29th - June 2nd 2013* (id : 69825516c835c41957df94a5) ou « Proceedings 2002 International Conference on Image Processing (Cat. No.02CH37396) » dans *Proceedings. International Conference on Image Processing* (id : 69825516c835c41957dfc80a).

La question de l'Est de l'Europe se situe cette fois-ci du côté du chap 10, avec les termes *chinese*, *mongol*, *huns* et *dariali* (en référence à la Passe de Daria, entre la Géorgie et la Russie). Ce cluster regroupe des titres comme « 9 Japanese Ethnicity » dans *Ruins of Identity : Ethnogenesis in the Japanese Islands* (id : 69825516c835c41957df9269), ou encore « 7 Sogdiana in the Kidarite and Hephthalite Periods », dans *ReOrienting the Sasanians : East Iran in Late Antiquity* (id : 69825516c835c41957df97a4).

Le chap 11 se concentre autour de la péninsule ibérique et de l'esclavage (ou les slaves comme peuple), avec les termes *ibera*, *spanish*, *hispanic*, *trade* ou *slavery*. Parmi les titres du cluster, on retrouve : « CHAPTER 1 The History of Slavery in Iberia » dans *Slavery in Medieval and Early Modern Iberia* (id : 69825516c835c41957df91d8); « CHAPTER ELEVEN Barlaam and Josaphat in Early Modern Spain and the Colonial Philippines » dans *Iberian Empires and the Roots of Globalization* (id : 69825516c835c41957df9285).

Le chap 12 semble quant à lui porter sur la question de la littérature anglo-saxonne, et plus particulièrement celle autour de la légende arthurienne, comme en témoigne les mots *arthurian*, *literature*, *legend*, mais aussi *scottish*, *schots*. Ainsi, certains titres rendent ce thème plutôt explicite, comme « 2 Troy in the Older Scots Romance and Nine Worthies Tradition » dans *The Trojan Legend in Medieval Scottish Literature* (id : 69825516c835c41957df98c5), ou encore « 13 FIRST TRANSMISSION TO ENGLAND AND FRANCE » dans *The Arthur of the Welsh : The Arthurian Legend in Medieval Welsh Literature* (id : 69825516c835c41957dfa183).

Le chap 13, à l'image du topic 18 pour une partie, contient du bruit éditorial : des références en français, allemand, ou des recensions étiquetées comme des chapitres. Par exemple, des titres comme « Lésions osseuses peri mortem d'origine anthropique dans la

nécropole alto-médiévale d’Erstein (Bas-Rhin) corps ravagés ou corps outragés ? » (id : 69825516c835c41957dfd5c0) ou « Findlen, Paula, Michelle M. Fontaine, and Duane J. Osheim, ed. *Beyond Florence : The Contours of Medieval and Early Modern Italy*. Stanford : Stanford University Press, 2003. Pp. 324, nine maps & figures » (id : 69825516c835c41957df98a8) s’y trouvent.

Le chap 14, un des clusters les plus importants sur le plan quantitatif, porte sur la religion chrétienne dans l’Antiquité Tardive (hagiographie, culture chrétienne), comme en témoignent les mots *pagan*, *christian*, *religious*, *antiquity*. Ce cluster regroupe des publications ayant, entre autres, des titres proches de « Servi Beatae Marie Virginis » dans *Church and Belief in the Middle Ages : Popes, Saints, and Crusaders* (id : 69825516c835c41957df91b1), ou « Apostolic Succession and Church Freedom : the Oxford Movement’s Political Discourse and the Church Temporalities Act of 1833 » dans *Episcopal Elections in the Churches* (id : 69825516c835c41957dfa87b).

La question de la chute de Rome est abordée dans le chap 15, avec des termes comme *rome*, *fall*, *antiquity* ; mais aussi la question des royaumes « barbares » avec *charlemagne*. Ainsi, nous pouvons y trouver les titres « 5 Getting the Word Around » dans *News and Frontier Consciousness in the Late Roman Empire* (id : 69825516c835c41957df9cd5), ou « The breaking of the frontier by the Visigoths » dans *An introduction to the study of the Middle Ages (375-814)*. (id : 69825516c835c41957dfe22a).

Pour finir, le chap 16, réduit sur le plan quantitatif, semble aborder l’histoire des sciences et de la médecine, avec les termes *science*, *medical*, *astronomy*, *hospital*, *mathematics*. Il rapproche des publications comme « 3. Medieval Maximization and Some Modern Twists » dans *When Least Is Best : How Mathematicians Discovered Many Clever Ways to Make Things as Small (or as Large) as Possible* (id : 69825516c835c41957df92a4), ou « Astronomies and Cultures in Early Medieval Europe by S. C. McCluskey » dans *Aestimatio : Critical Reviews in the History of Science (Volume 3)* (id : 69825516c835c41957dfee2b).

La description de ces topics soulève la question de la similarité des thèmes entre les chapitres et les articles, suggérant la cohérence du corpus en termes thématiques. Toutefois, elle dessine aussi une tension au sein du corpus, à savoir la coexistence en un même espace de publications qui semblent a priori difficilement compatibles : les sciences de la vie et de la Terre et la philologie ; autour d’un même objet. Ces regroupements sont mobilisés dans les sections suivantes afin d’analyser la composition thématique du réseau de coautorat et de sa LCC. Pour parler des articles, largement majoritaires, nous utilisons le terme de « topic » ; pour les chapitres, nous privilégions « chap », suivi à chaque fois du numéro de

cluster présenté dans le tableau 7.9.

La caractéristique la plus notable de cette description demeure la composition thématique de cet espace. Microcosme, au sens fort, la sélection thématique s’opère dès l’entrée dans le réseau de coautorat, avant d’atteindre la LCC (tableau 7.15, page 298). Les documents dont les topics identifiés par BERTopic sont liés à la bioarchéologie et la médecine historique (topic 1 : *population, cemetery, burial, remains*) représentaient 4,8 % de la base complète : cette part augmente à 19,7 % dès le réseau de coautorat, puis atteint 25,8 % dans la LCC. L’histoire environnementale et paléoclimatique (topic 14 : *climate, record, lake, tree*) suit la même trajectoire : de 2,2 % à 11,8 %, puis 17,8 %. Ainsi, ces deux thèmes concentrent à eux seuls près de 44 % des publications de la composante principale. À l’inverse, les thématiques les plus représentées dans la base (religion et théologie, littérature et philologie, royaumes barbares) se réduisent à environ 1 % des publications dans la LCC.

Un test du χ^2 sur le tableau de contingence croisant topics et appartenance à la composante principale suggère que ces fréquences ne sont pas issues d’une distribution aléatoire, mais plutôt d’une distribution différenciée entre la composante connexe principale et le reste du réseau (tableau 7.9, page 292).

Du côté des surreprésentations, deux topics sont plus fortement associés à la LCC : la bioarchéologie et la médecine (+10,25) et l’histoire environnementale et paléoclimatique (+11,03) ; et sont les principaux contributeurs de l’association observée entre LCC et thématique. Dans une moindre mesure, avec des surreprésentations entre +2 et +5, la LCC surreprésente aussi les recensions (topic 18), les thématiques nordiques et viking (topic 0), l’archéologie du peuplement (topic 13), l’archéologie et la culture matérielle (chap 1). De plus, paradoxalement, alors que ces thématiques sont sous représentées dans la LCC sur le plan des articles, les thèmes liés à Rome et à Charlemagne présentent ici des résidus positifs (chap 15, +2,38). À l’inverse, plusieurs topics sont sous-représentés dans la LCC. Les publications sans topics assignés, correspondant pour l’essentiel aux pratiques de coautorat dans des langues autres que l’anglais, ont les résidus les plus importants (-11,75), rejoignant notre constat sur la langue évoqué précédemment. Parmi les topics identifiés, l’art, l’architecture et les manuscrits (topic 4, -4,88), la littérature/théâtre/poésie anglaise (chap 8, -32), la religion, la théologie et la scolastique (topic 2, -2,62 et chap 14, -3,2), l’histoire sociale et économique (topic 8, -2,55) ainsi que les thèmes directement liés

à l'Antiquité tardive et aux royaumes barbares (topic 6, -2,2)³³ présentent des résidus négatifs.

S'il est possible de soulever l'aspect inférentiel des thématiques des articles obtenues à partir de BERTopic, les observations proposées sont renforcées par la modélisation thématique du texte entier sur un échantillon de 756 documents, détaillée dans la section 4.5.2. La projection des topics issue de la LDA sur le réseau permet, en plus des thèmes BERT, de poser l'hypothèse d'une sélection thématique différenciée selon la position dans le réseau. L'analyse des résidus de distribution entre publications présentes dans le réseau et publications hors réseau au sein du corpus de textométrie³⁴ permet d'observer une association significative entre topic et position (voir les tableaux à partir de 7.18, page 303) : le topic 4 (*sample, individual, analysis, population, archaeological*) et le topic 6 (*lake, sediment, climate, record*), qui correspondent respectivement aux pratiques archéogénomiques et paléolimnologiques déjà identifiées par la première modélisation, y sont surreprésentés, et, à l'inverse, le topic 1 portant directement sur le « barbare » et le topic 10, identifié comme fond commun de la production altimédiéviste présent dans près de 40% des documents du corpus, présentent des résidus négatifs. En outre, une seconde analyse portant cette fois-ci uniquement sur les publications présentes dans le réseau permet de renforcer l'hypothèse d'une sélection thématique³⁵ : le topic 4 concentre 28 des 57 publications de la LCC présentes dans le corpus de textométrie.

Par conséquent, les deux modélisations thématiques se rejoignent sur un constat : la LCC constitue un sous-espace dont la composition reflète des pratiques d'écriture et des épistémologies propres aux sciences naturelles, tandis que les publications relevant de l'historiographie plus traditionnelle (philologie, droit, religion) en sont marginalisées ou exclues. En ce sens, et si nous pouvons tout de même trouver des topics plus liés à l'historiographie traditionnelle dans la LCC, la croissance du coautorat témoigne peut être d'une hybridation du champ par l'arrivée, de plus en plus, de méthodes issues des sciences

33. Signalant peut être une asymétrie documentaire, les articles étant davantage l'apanage des sciences naturelles que les chapitres.

34. Etant donné le fort γ de notre matrice, nous retenons le topic majoritaire comme topic du document. Si l'on décide de compter plusieurs topics pour une publication, soit des occurrences de topic, les effets sur les phénomènes de surreprésentation ou sous-représentation sont uniquement visibles pour le topic 12, cluster minoritaire au sein du corpus. En d'autres termes, quelle que soit la méthode de comptage, cela change peu les observations présentées ici.

35. Quelle que soit, encore une fois, la méthode de comptage.

naturelles, en faveur de capitaux scientifiques perméables à plusieurs champs : il convient de ne pas lire dans ce réseau un remplacement de la médiévistique plus textuelle par les sciences naturelles, mais plutôt un espace de dialogue au sein de cette structure sociale autour du « barbare » ; pouvant déjà être une trace des mutations des usages savants du mot.

Puisque la recherche expérimentale impose autour de cet objet commun un droit d'entrée comparable à ce que Bourdieu décrit comme l'effet de la mathématisation (BOURDIEU 2001, p., 49, 96) : une « forte coupure sociale entre les professionnels et les amateurs », opérée par la technicisation du discours, qui contribue à la formation d'un sous-espace relativement autonome³⁶ ; ceci pourrait aussi expliquer la relégation de l'historiographie traditionnelle, dans sa majorité, aux composantes connexes. En ce sens, la paléoclimatologie ou la bioarchéologie agissent comme des barrières à l'entrée à la LCC pour des historiens dont la formation repose sur une orientation textuelle, alors même que les deux partagent a priori l'objet « barbare ».

En outre, et pour revenir sur l'aspect méthodologique de notre démarche, nous pouvons poser l'hypothèse qu'une approche bibliométrique à visée historiographique peut ainsi s'appuyer sur une analyse du coautorat pour voir apparaître la structure de l'interdisciplinarité³⁷ (ou non) du champ, ce qui a des conséquences disciplinaires et épistémologiques, au sens où d'autres approches coexistent et emploient, pour un même objet, des méthodes et modes de production du savoir, de pratiques d'écriture et de publication issus d'autres champs scientifiques.

Ces observations appellent à des précautions interprétatives pour la suite de notre analyse. Les indicateurs de centralité ne sont pas généralisables à l'ensemble du champ portant sur les « barbares », mais bien sur cet espace décrit ci dessus : anglophone, aux nationalités à tendance à publier en anglais, et dont les sujets semblent relever des sciences naturelles, ou sont du moins en dialogue avec elles. Si, comme nous le verrons, certains

36. Bourdieu souligne toutefois que cet effet ne s'exerce pas nécessairement avec la même intensité dans les sciences sociales (BOURDIEU 2001, p., 49, 96).

37. Cette remarque ne signifie pas que les autres publications ne sont pas interdisciplinaires, mais plutôt que les publications de la LCC ont la particularité de faire partie de notre corpus, portant sur les « barbares » du Haut Moyen Âge tout en portant des outils, méthodes ou approches issues des sciences naturelles, réconciliant ainsi des approches pourtant traditionnellement éloignées (comme en témoigne la division classique entre sciences naturelles et sciences sociales par exemple).

noms connus de la production historiographique y figurent, leur présence s'explique moins par leur volume de collaborations que par leur position de médiateurs entre ces disciplines.

4.4.4 Les positions dans le réseau : formes de capitaux et logiques d'inégalité

Ces inégalités d'accès au réseau et à la LCC se doublent d'inégalités de position au sein de cette dernière. Pour analyser ces dynamiques, il convient d'abord de nous concentrer sur la distribution des indicateurs, puis sur leurs relations entre elles, à la fois pour les auteurs et pour les publications.

Les auteurs

La figure 7.2, page 295 nous permet d'avoir une vue d'ensemble des indicateurs de centralité calculés pour les auteurs, par nationalité les plus fréquentes dans la LCC³⁸. Ces observations visuelles sont confirmées statistiquement : une analyse de variance non paramétrique³⁹ (test de Kruskal-Wallis) conduite sur chacun des six indicateurs de centralité suggère que la nationalité est associée à des distributions significativement différentes pour l'ensemble d'entre eux : degree ($H = 355,6$; $p < 0,001$), closeness ($H = 408,8$; $p < 0,001$), betweenness ($H = 260,4$; $p < 0,001$), katz ($H = 375,9$; $p < 0,001$), eigenvector ($H = 378,7$; $p < 0,001$), et dans une moindre mesure pagerank ($H = 95,0$; $p < 0,001$). L'hypothèse nulle d'égalité des distributions entre groupes nationaux est donc rejetée pour chaque indicateur⁴⁰.

Tout d'abord, la distribution des degrés semble suivre la forme attendue d'une loi de puissance, puisque la majorité des auteurs ne compte qu'un faible nombre de co-auteurs distincts, tandis qu'une minorité dépasse la centaine. Si les chercheurs américains et britanniques dominent les sommets de cette distribution, le réseau met également en lumière des pôles de connectivité intenses détenus par des auteurs allemands, et ce, malgré

38. Nous faisons le choix de représenter la nationalité plutôt que le genre car nous avons, au cours de notre recherche, posé l'hypothèse d'inégalités structurelles de genre dans la LCC. L'expérimentation suggère que si ces différences existent, elles concernent surtout les quantiles les plus élevés de notre distribution.

39. Car nos distributions ne suivent pas une loi normale.

40. Ces tests indiquent qu'il existe un effet de la nationalité sur la position des auteurs dans le réseau, mais ne permettent pas à eux seuls de conclure à une inégalité structurelle avec un effet important.

un poids démographique moindre au sein du corpus. Toutefois, la France et la Suède semblent être les nationalités les plus fréquentes pour les plus faibles degrés, compris entre 1 et 10.

La closeness reproduit, de manière similaire, ces inégalités, puisque les valeurs les plus élevées sont atteintes principalement par des auteurs américains et allemands. Toutefois, le graphique présente une distribution visuellement difficile à interpréter, les valeurs étant très resserrées sur une plage étroite, vision corroborée par un gini de 0,9 (voir figure 7.5, page 299) : on constate tout de même une tendance des américains à présenter des fréquences plus élevées pour les valeurs de closeness plus importantes que les français.

La distribution de l'eigenvector est dominée par un outlier allemand dont la valeur dépasse celle de toutes les autres nationalités⁴¹ ; en dehors de cet artefact, les valeurs les plus élevées sont atteintes par des auteurs américains, britanniques et suédois. Il s'agit par ailleurs de la distribution la plus inégalitaire, avec un coefficient de Gini de 0.9. En dehors de la clique identifiées les premiers historiens du Haut Moyen Âge dont nous connaissons les noms à figurer dans ce classement n'apparaissent qu'au-delà de la cinquantième position : Patrick GEARY en cinquantième, Walter POHL en cinquante-troisième.

De pair avec l'eigenvector, la betweenness est l'indicateur dont la distribution l'une des plus inégalement répartie (voir figure 7.5b, 299). D'une part, les auteurs polonais et suédois présentent les médianes les plus élevées, ce qui indique qu'une proportion importante d'entre eux occupe des positions de pont dans le réseau. D'autre part, les auteurs américains et britanniques, malgré des médianes plus basses, concentrent les valeurs extrêmes les plus élevées et le plus fort écart entre médiane et moyenne, suggérant l'existence de quelques grands agents structurels capables de relier des zones du réseau. La France, l'Italie et l'Espagne se distinguent aussi, en ce que près de 70% de leurs auteurs ont une betweenness nulle, renforçant notre hypothèse d'un positionnement tendancielle-ment périphérique dans la circulation de l'information au sein du champ. Toutefois, nous devons rappeler que la périphérie de la LCC n'implique pas nécessairement une position marginale dans le champ : en suivant la distinction entre capital d'autorité proprement scientifique et capital de pouvoir sur le monde scientifique (BOURDIEU 2001, p. 113), nous

41. Pouvant s'expliquer par une clique publiant systématiquement ensemble en Allemand : en 2013, un groupe de 7 auteurs apparaissent simultanément dans un groupe de 21 publications allemandes de 7-8 auteurs chacune, formant une clique quasi-parfaite (il s'agit du *Übersetzung : ein internationales Handbuch zur Übersetzungsforschung* (encyclopédie internationale de recherche sur la traduction)).

pourrions poser l'hypothèse que les auteurs français ou italiens sont davantage dotés en capital institutionnel national, peu convertible dans un réseau de coautorat structuré par des pratiques d'écriture anglophone et interdisciplinaire, ce qui serait par ailleurs cohérent par rapport à nos observations sur la langue de publication des auteurs français.

Betweenness et notoriété : deux dimensions non assimilables

L'analyse qualitative de ces positions nous permet de dissocier, dans une certaine mesure, centralité structurelle et notoriété académique. Parmi les auteurs à betweenness nulle figurent des chercheurs dont les noms ne nous sont pas inconnus : par exemple, Alan HARDING, historien médiéviste britannique reconnu pour ses travaux sur le droit et les institutions de l'Angleterre médiévale. Leur absence de betweenness traduit qu'au sein de cet espace, ils ne jouent pas le rôle d'intermédiaires entre les coauteurs.

À l'inverse, la betweenness la plus élevée de la LCC ($b = 0,0155$) appartient à Michael RICHARDS, professeur d'archéologie spécialisé dans l'analyse isotopique des régimes alimentaires préhistoriques et des migrations humaines en Eurasie. Sa position de pont s'explique vraisemblablement par la nature interdisciplinaire de ses méthodes. Dans les 10 premiers auteurs avec la plus forte betweenness, nous retrouvons également des noms plus connus par rapport à notre objet, comme Walter POHL (0.009533), Ian WOOD (0.009743) ou Patrick GEARY (0.005753).

Les quelques points hors-diagonale visibles dans la matrice de Barber (figure ??, page ??), dont la méthodologie de construction est précisée plus loin, matérialisent ces agents, des auteurs ou publications qui assurent la circulation de l'information entre des sous-espaces qui, sans eux, resteraient isolés les uns des autres.

Ces observations invitent à ne pas interpréter la betweenness comme un proxy de prestige, mais bien une trace de la position relationnelle dans la topologie du réseau, sa fonction de médiation entre des groupes qui, sans cet agent, ne communiqueraient pas.

Pris isolément, ces indicateurs dessinent déjà des formes d'inégalité : d'abord, dans les concentrations des positions de centralité (voir figure 7.5, page 299), ensuite, entre les nationalités. En plus d'être mieux représentés au sein de la LCC, les britanniques et les américains occupent les positions les plus centrales de l'espace ; mais dès lors, nous pouvons

nous demander si les mêmes agents les cumulent, ce que l'analyse des corrélations⁴² nous permet d'approcher, à l'image de KANYOU, KOUOKAM et EMVUDU.

La corrélation la plus importante pour nos auteurs est celle entre closeness et eigenvector ($\rho = 0.858$) : la chute de cet indicateur de relation lorsque l'on passe à la pondération Newman ($\rho = 0.649$) suggère que la forte association entre proximité structurale et prestige par voisinage est partiellement un effet des cliques. Les auteurs dans ces positions seraient, en ce sens, ceux pris dans des groupements denses de la composante connexe principale, au coeur d'autres noeuds bien positionnés et qui coautoient souvent entre eux. En examinant les 100 personnes ayant l'eigenvector le plus important et leurs publications, nous constatons qu'il s'agit notamment de cliques formées par des publications réunissant beaucoup d'auteurs, et nous permet d'observer une régularité structurale : la queue de la distribution est massivement investie par la bioarchéologie (ART_1, 31.6%) et de la paléolimnologie (ART_14, 3.5 %) ⁴³ représentant à elles seules près de la moitié de la production des auteurs de ce top (seul la clique sur la recherche en traduction apparaît également, comme chapitres de l'ouvrage).

Ainsi, il existerait une affinité entre position de centralité de prestige, proximité au coeur du réseau de coautorat, et sciences naturelles, au sein même de la recherche sur le « barbare » ; et l'isolement des thématiques plus traditionnelles (topic 10 et topic 1) pourrait s'interpréter comme l'expression d'habitus disciplinaires distincts (BOURDIEU 2001, p. 86) : leur coprésence dans la LCC serait à interpréter comme la rencontre de dispositions incorporées lors de trajectoires de formations différentes, avec des pratiques d'écriture et d'autorat propres. En ce sens, le réseau de coautorat matérialise une forme de polarisation entre une domination des sciences naturelles en termes de capital social au sein de la LCC, de centralité de prestige et de proximité au coeur du réseau ; et les approches historiographiques plus éloignées de celles-ci, plus périphériques.

D'un autre côté, la betweenness semble être l'indicateur le plus indépendant, avec un ρ maximum de 0.5 dans la projection de Newman avec le degré : occuper une position de pont serait indépendant avec une insertion dans un voisinage dense ou prestigieux (ce qui rejoint notre hypothèse ci dessus, entre la betweenness et la notoriété). En ce sens, si le coeur du réseau est occupé par des auteurs très interconnectés et dont le prestige se renforce

42. Nous utilisons la corrélation de Spearman, mesure de dépendance statistique non paramétrique, plutôt que Pearson, qui mesure la relation linéaire entre deux variables.

43. Les publications inconnues représentent 45.6% des publications.

par les multiples connexions qu'ils entretiennent entre eux, les passeurs d'information dans le réseau, soit ceux capables de faire les liens entre ces cliques, ne sont pas les mêmes agents que ceux les plus dotés en capital social, renforçant l'hypothèse d'un réseau segmenté. Les agents fortement dotés en betweenness seraient en ce sens ceux capables de convertir leurs capitaux d'un sous groupe à l'autre, ne nécessitant pas forcément un fort nombre de connections. Toutefois, lorsque l'on s'intéresse aux publications cette fois des 100 personnes ayant la plus forte betweenness, on constate que les thématiques sont sensiblement proches de celles de l'eigenvector : ART_1 à 30.7%, ART_14 à 14.3% et ART_13 (archéologie du peuplement) à 8.2%; suggérant que les agents occupant les positions de ponts sont aussi contributifs des publications des sciences naturelles, mais n'en sont pas les noeuds les plus prestigieux ou les auteurs les plus centraux (d'où la faible corrélation).

Toutefois, si les auteurs peuvent obtenir de telles positions au sein de notre réseau, c'est en raison de l'acte de publier avec, ce qui nous invite à nous pencher désormais sur les indicateurs de centralité des publications.

Les publications

Pour les publications (figure 7.3, page 296), nous faisons le choix de représenter les langues, afin de prolonger l'analyse de la sélection à l'entrée de la LCC. La donnée thématique, par ailleurs disponible pour un sous-ensemble plus restreint des publications, fait l'objet d'une analyse séparée (voir à partir de la figure 7.7, page 305). L'influence de la langue de publication sur la position topologique des travaux au sein de la LCC est confirmée par une analyse de variance non paramétrique (test de Kruskal-Wallis) : degree ($H = 230,0$; $p < 0,001$), closeness ($H = 238,1$; $p < 0,001$), betweenness ($H = 159,1$; $p < 0,001$), eigenvector ($H = 227,9$; $p < 0,001$). L'hypothèse nulle d'égalité des distributions entre les groupes linguistiques est donc systématiquement rejetée⁴⁴.

De manière globale, les observations sur les graphes semblent renforcer l'effet de surreprésentation de l'anglais dans la LCC, déjà évoqué (tableau 7.13, page 294). D'abord, si la distribution des degrés se rapproche d'une loi de puissance, semble apparaître un plafond

44. Comme pour l'analyse des auteurs, ces tests démontrent un effet statistique significatif de la langue sur la centralité, sans pour autant mesurer l'amplitude de cet effet (taille d'effet) ou les causalités sous-jacentes.

de verre, semblant indiquer une barrière structurelle (bien que les effectifs des publications regroupant le plus d’auteurs soient limités) autour de 20 auteurs. Ainsi, la seule langue capable de regrouper au sein de la LCC des grands groupes d’auteurs (consortiums, colloques) est l’anglais. Cette hiérarchisation est aussi visible pour la closeness, puisque les valeurs les plus élevées sont monopolisées par les publications en anglais (à l’inverse du slovène qui, lui, semble occuper les positions les plus basses de la closeness malgré une fréquence bien plus élevée), ce qui suggère que ces dernières sont bien mieux insérées au coeur de la LCC. L’eigenvector peut s’interpréter ici comme la mesure de la connexion entre des publications centrales, elles mêmes connectées aux publications centrales de notre réseau. Si le Gini est de 0,9 pour cet indicateur, il demeure dominé pour partie par l’allemand (je suppose qu’il s’agit de la clique identifiée), et l’anglais⁴⁵. Enfin, l’analyse de la betweenness souligne une nuance : si l’anglais sature les valeurs maximales d’intermédiarité, on observe une concentration notable du français, de l’allemand et du slovène aux sommets de leurs distributions respectives, avec des fréquences proportionnellement supérieures à celles de l’anglais pour ces tranches de valeurs. Cela suggère que, bien que ces langues accèdent plus rarement à une centralité globale, elles jouent un rôle de pivot structurellement plus fréquent au sein des sous-groupes du réseau.

Ainsi, la hiérarchie des langues dans les indicateurs de centralité des publications reproduit celle établie dans notre section sur la langue de publication sur le plan topologique. Les publications centrales de la LCC, que ce soit en termes de nombre d’auteurs, de prestige ou de pivot sont largement anglophones. Davantage qu’être sous-représentées dans la LCC, les langues non anglophones sont presque systématiquement exclues des positions les plus centrales ; et nous pouvons supposer que la betweenness des publications dans les langues nationales permet de jouer un rôle de pont entre des sous-groupes de ces langues.

Si la langue structure les positions des publications dans la LCC, elle n’en est pas la seule dimension pertinente. La figure 7.7 et les suivantes, page 305, permet d’examiner la distribution des indicateurs, cette fois selon la thématique des publications (degré $H = 90$, closeness $H = 348$, eigenvector $H=223$ et betweenness $H=118$). Pour le degré et la closeness, la hiérarchie thématique reproduit celle déjà observée pour le réseau dans son ensemble : bioarchéologie_médecine et histoire_environnementale_paléoclimat ont

45. Notons la présence d’un point français plus fréquent mais pour les mêmes valeurs d’eigenvector que l’anglais, même si sa distribution semble moins inégalitaire que les autres indicateurs en termes de langue.

les distributions les plus étendues et les médianes les plus élevées, suggérant que ces thématiques concentrent les publications à fort nombre de co-auteurs et les mieux insérées au cœur de la LCC ; concentration par ailleurs davantage marquée pour l'eigenvector, avec l'outlier extreme pour chap_culture de l'écrit, correspondant probablement à la clique allemande identifiée. La betweenness quant à elle suggère que d'autres topics, notamment ceux davantage tournés vers l'historiographie plus traditionnelle, peuvent aussi jouer des rôles de passage entre les sous-espaces de la LCC.

Ainsi, l'analyse de la distribution de ces indicateurs de centralité permet de rappeler l'importance capitale de l'anglais, en plus des thèmes identifiés précédemment. La hiérarchie linguistique des indicateurs de centralité confirme ainsi que la langue structure les positions au sein de la LCC de manière différenciée selon la forme de centralité considérée : monopole de l'anglais pour la connectivité et le prestige, rôle de pont non négligeable pour les langues nationales.

Du côté des corrélations, les publications, en projection simple, ont des coefficients relativement proches de la situation des auteurs. D'abord, la corrélation entre closeness et eigenvector (0,78) suggère qu'une publication, lorsqu'elle est au coeur du réseau, est également liée à d'autres publications très centrales (ou inversement, lorsqu'elle hérite du prestige de ses voisins par association, elle est aussi accessible rapidement dans le réseau) ; mais d'une manière moins importante que pour les auteurs, où la redondance entre ces aspects est plus importante.

A l'inverse, le degré, qui dans cette projection publication-publication représente le nombre d'autres publications qui partagent au moins un auteur avec elle, ne semble que modérément corrélé aux autres indicateurs (entre 0,499 pour degré et closeness et 0,534 pour degré et eigenvector). Cette relation pourrait s'interpréter comme le fait que le nombre de publications voisines d'une publication ne garantit pas une insertion dans la LCC, que ce soit en termes de proximité au coeur du réseau, en prestige, ou en capacité de passage de l'information : le champ semble alors fragmenté, avec plusieurs groupes de publications qui ont des liens entre elles mais pas avec les autres du réseau (ce qui serait cohérent avec l'existence de sous-espaces linguistiques ou disciplinaires). Nous pouvons poser l'hypothèse qu'il s'agirait alors d'une trace indiquant des groupes aux capitaux spécifiques, plus difficilement convertibles dans l'espace le plus central du réseau.

En revanche, la betweenness publications corrèle plus avec le degré (0,509) et la close-

ness (0,513) que chez les auteurs (0,435 et 0,458), bien que celle ci demeure modérée : les publications faisant les liens entre des espaces du réseau ne sont pas les plus centrales, ni les plus connectées (s'il n'est pas nécessaire d'être au sommet de la hiérarchie pour assurer l'intermédiarité, il semble qu'un seuil de connectivité minimal soit plus déterminant pour les travaux que pour les agents eux-mêmes).

La pondération Newman augmente toutefois la relation entre ces indicateurs, en la faisant passer à 0,649. Si dans la projection publication-publication, le degré en projection simple est gonflé pour les publications à grand nombre d'auteurs, qui partagent mécaniquement des co-auteurs avec de nombreuses autres publications sans que cela reflète nécessairement une insertion structurale diversifiée, en projection Newman, cette augmentation suggère que lorsqu'on corrige ce biais, une publication est un pont lorsqu'elle est cosignée par des auteurs qui publient beaucoup⁴⁶

Des sous-espaces disciplinaires ou des collectifs de pratique ? En outre, la segmentation du réseau mise en évidence par la détection de clusters sur le graphe biparti (algorithme de Leiden, modularité de Barber), comme en témoigne la figure 7.17 (page 314, renforce ces observations.

Si nos indicateurs suggéraient une segmentation du co-autorat entre des groupes distincts, la matrice permet de rendre visible la diagonale : les auteurs et les publications regroupés dans un même cluster co-publient davantage entre eux qu'avec le reste du réseau (ils ont des comportements de connectivité proches).

Les 12 premiers clusters à l'exception du cluster 0⁴⁷, les plus en haut à gauche de la matrice, sont presque intégralement peuplés de publications portant sur l'ADN, l'archéogénomique, la dendochronologie et la paléoclimatologie (les clusters 1, 2, 5, 7 et 8 regroupent les publications autour de la génomique et de l'ADN ; les clusters 3, 4 6 et 9 autour de la dendrochronologie et de l'archéologie du climat), et représentent plus du quart des auteurs, et plus du quart des publications de la LCC (contre 15% des clusters, 12 parmi 79). En ce sens, la proximité thématique est également une proximité sociale : les mêmes agents co-publient dans des cadres structurés comme les laboratoires de re-

46. En d'autres termes, il s'agirait du fait que les auteurs possèdent eux mêmes un fort degré qui confèrerait à une publication un rôle de pont dans la LCC : une publication est un pont pas si elle réunit beaucoup d'agents, mais si elle réunit des agents productifs quantitativement dans le réseau.

47. Qui, nous y reviendrons, est dédié aux recensions et, dans une moindre mesure, à l'histoire militaire.

cherches, les projets, les institutions. Ces derniers, dont nous pouvons poser l'hypothèse qu'ils représentent des configurations instrumentales, infrastructures matérielles partagées (séquenceurs d'ADN par exemple⁴⁸), ou encore division du travail scientifique (entre historien, et biologiste pour le séquençage d'ADN par exemple) seraient la condition de reproductibilité de leur co-publication⁴⁹. Ce constat rejoint, à une autre échelle, ce que la sociologie des revues scientifiques a pu montrer, puisque la forme de publication n'est pas séparable de ses conditions institutionnelles et matérielles de production (BOURE 1993) : dès lors, nous pourrions poser l'hypothèse que les clusters représentent des groupements autour des mêmes revues⁵⁰.

L'observation permet aussi de constater qu'autour de ces 13 clusters gravitent des points en dehors de la diagonale, et qui s'étendent aussi sur la partie inférieure gauche de la matrice et supérieure droite. Traces de la circulation entre ces structures, la concentration de celles-ci suggère que la circulation entre les groupes s'effectue davantage depuis, ou vers ces sous-espaces : si les sciences naturelles se fragmentent en sous-espaces, les échanges maintenus entre elles sont visibles, suggérant une affinité dépassant les frontières de chaque cluster.

Le cluster 0, plus important en termes de nombre d'auteurs (plus de 700 !), est quant à lui presque intégralement dédié aux recensions, publications que nous avons décrites dans notre premier chapitre comme un espace de « gatekeeping » et de lutte pour la reconnaissance symbolique (VERBERGT et HAGEN 2025 ; SINGH et HAN 2010)⁵¹. Bien qu'il concentre autant d'agents, il semble que ses auteurs ne co-publient rien d'autre dans le réseau, et les auteurs des clusters 1 à 12 (identifiés comme presque exclusivement tournés

48. Le coût du séquençage varie, et a diminué au fil de notre période. Toutefois, certains modèles de séquenceurs sont autour de quelques milliers de dollars, et le coût par séquence varie entre plusieurs centaines de dollars, à plusieurs milliers (BAYLE et al. 2024)

49. Ainsi, autour d'instruments se créeraient des espaces interdisciplinaires, mobilisant par définition des relations de coautorat structurées et répétées.

50. Hypothèse relativement vérifiée pour le cluster 0, avec 17 publications (sur 35) de la *The International History Review* et tous les autres à 2 ou 1 publications. Le cluster 1 a, quant à lui, 7 publications (sur 38) de PloS, le cluster 3 avec 8 publications sur 5 de *Dendrochronologia*, le cluster 14 avec 14 publications, sur 62, de *The Oxford Handbook of the Merovingian World*.

51. Et, comme nous avons pu le voir, sa densité apparente résulte bien de quelques publications concentrant une cinquantaine de signataires, une collection de recensions (soit une coprésence dans un même objet éditorial).

vers les sciences naturelles) n’y figurent pas non plus⁵². En quelque sorte, cet isolement traduit l’individualité de la pratique de la recension, mais permet aussi à des centaines d’agents d’appartenir à la LCC sans y tisser des liens sociaux plus denses. En outre, la quasi-absence des auteurs des clusters de sciences naturelles suggère aussi que ce genre de pratique n’est pas celle de leur propre champ, puisqu’en sciences naturelles la publication principale demeure l’article. Ainsi, deux modes de participation au champ coexistent au sein de la LCC, à la fois épistémologiquement distincts, mais aussi structurellement séparés : d’un côté, la production collective des sciences naturelles, où la cosignature est une condition de publication (nous l’avons vu, matérielle, mais aussi épistémologique) et de l’autre, la critique individuelle.

Ainsi, nous avons pu voir que la LCC dessine une structure, objectivée (mais non réductible) par les indicateurs de centralité et leurs croisement avec les caractéristiques de nos données. Pour les auteurs, les indicateurs de connectivité (degré), de proximité au cœur du réseau (closeness) et de prestige par voisinage (eigenvector) se concentrent parmi les nationalités anglophones, et leur corrélation avec les thématiques de sciences naturelles suggère une affinité entre position centrale dans la LCC et pratiques d’écriture importées d’autres champs scientifiques. En revanche, la betweenness semble appartenir aux agents dont la position relationnelle n’est pas celle de prestige, et dont la présence dans les thématiques des sciences naturelles sans pour autant en occuper les positions les plus prestigieuses suggère une logique de conversion de capital entre des groupes qui ne seraient autrement pas connectés (dont nous posons l’hypothèse de thématiques, au sens donc de capital scientifique, ou de langues, au sens de capital linguistique donc).

Si les valeurs de betweenness les plus élevées appartiennent à des scientifiques dont les méthodes (archéogénomique (RICHARDS, KRAUSE, HOFMANOVÁ, WILLERSLEV), analyse isotopique (PRICE, FREI), paléoécologie (VANNIERE, BOLDGIV)) requièrent de larges coalitions de co-auteurs, les autres membres du classement sont plutôt du côté des SHS. En effet, parmi les 38 premiers agents par betweenness, on compte une dizaine de médiévistes

52. Cette surreprésentation des recensions dans la LCC (topic 18, résidu +2 dans le tableau 7.9 page 292) s’explique alors par la composition du cluster 0 : ce sont ces publications qui, en concentrant de nombreux signataires, permettent à des centaines d’agents d’appartenir à la LCC, augmentant mécaniquement la part des recensions dans la composante principale sans que cela traduise une intégration réelle dans les dynamiques de coautorat.

dont la position de pont s'explique peut être par leur inscription simultanée dans les deux espaces que le réseau tend à séparer : WOOD et POHL, historiens des royaumes barbares et de l'ethnogenèse, MCCORMICK, dont les travaux sur l'économie du haut Moyen Âge ont donné lieu à des collaborations étendues avec des climatologues et des épidémiologistes au sein de la *Harvard Initiative for the Science of the Human Past*, ou encore GEARY, dont la participation au projet HistoGenes avec POHL,⁵³ et l'ouvrage *Comment la génétique réécrit l'histoire du Moyen Âge* (P. J. GEARY 2024) témoignent d'un habitus d'écriture à l'interface de l'histoire et des sciences naturelles.

Nous pouvons interpréter la coordination d'un tel projet, doté de ressources financières, comme une forme de capital (BOURDIEU 2001, p. 113), se rendant visible dans la position de W. POHL : à la fois doté en betweenness et en eigenvector, il cumulerait à la fois un capital d'autorité scientifique (valeur intrinsèque des travaux, pour leur capacité à faire avancer la connaissance selon les critères internes au champ) reconnu par ses pairs, mais aussi un capital de pouvoir sur le monde scientifique (capacité à orienter les ressources, à coordonner des équipes, à accéder aux instances de consécration et de financement) conférant aux projets qu'il coordonne une certaine visibilité⁵⁴. Cette hypothèse ferait sens au regard de BOURDIEU 2001, p. 127, pour qui les révolutions dans le champ ne peuvent être accomplies que par des gens maîtrisant les acquis de la tradition : POHL, GEARY ou WOOD seraient ainsi les garants de ces acquis, une autorité scientifique, parmi des équipes de chercheurs en sciences naturelles, dont le coautorat reconfigure les capitaux légitimes au sein du champ. En ce sens, la betweenness de ces médiévistes serait certes une mesure de l'interdisciplinarité (LIU et XIA 2015), mais aussi une dotation en capital scientifique et un capital lié au pouvoir institutionnel⁵⁵, trace d'une capacité à convertir du capital entre deux sous espaces du champ.

Pour les publications, la langue et la thématique produisent tous deux des hiérarchies : si les publications anglophones, portant sur les sciences naturelles sont celles

53. ERC Synergy Grant réunissant historiens et généticiens autour des migrations des peuples barbares : <https://www.histogenes.org/principal-investigators>.

54. Mais cette hypothèse ne saurait dépasser le cadre d'une piste interprétative, ne disposant pas des données nécessaires pour fonder notre propos.

55. Par ailleurs, si la participation à de tels projets est conditionnée par des capitaux scientifiques et institutionnels, elle agit rétroactivement sur eux en les renforçant, permettant par exemple à Pohl de publier avec ces chercheurs, renforçant sa position dans le réseau. En ce sens, ce cumul serait la condition de possibilité des « révolutions » dans le champ.

qui attirent les positions les plus centrales en termes de connectivité et de prestige, les publications dans les langues plus minoritaires et les topics historiographiques en semblent exclus. De la même manière que les auteurs, la *betweenness* nous permet de nuancer ce constat, en ce que les topics *antiquité_tardive_royaumes_barbares*, *littérature_philologie* ou *monde_nordique_viking* y maintiennent des médianes non négligeables, indiquant que les positions d’intermédialité ne sont pas le monopole des seules sciences naturelles ; de même que le français ou l’allemand.

Toutefois, ces observations ne peuvent répondre qu’à l’état du champ en 2025, et ne permettent pas de questionner la genèse et la stabilité des positions décrites ci dessus, bien que nous avons pu voir que le coautorat est surtout une pratique récente. En ce sens, il convient désormais de s’intéresser aux dynamiques temporelles du réseau.

4.4.5 Une structure qui se sédimente : dynamiques temporelles et effet d’ancienneté

Bourdieu, dans *Science de la science et réflexivité : cours du Collège de France (2000–2001)*, souligne la nécessité de prendre en compte l’histoire du champ afin de saisir l’état actuel des positions, puisque chaque agent occupe une position qui est le résultat d’une trajectoire, et la structure actuelle du champ est le produit de ses états antérieurs ; ne pas historiciser le champ reviendrait à naturaliser une configuration contingente. Dans le cadre de notre réseau, la temporalité y est cumulative (LIU et XIA 2015), comme un réseau de citation : les publications, ni les auteurs, une fois entré dans le réseau, n’en disparaissent jamais (à la rigueur, il peuvent quitter la LCC en ce qu’elle est relative). Cela a des conséquences différenciées pour nos indicateurs : si le degré ne peut que croître ou rester stable au fil du temps, la *closeness* et la *betweenness* peuvent évoluer dans les deux sens ; invitant à différencier les formes de centralité qui bénéficient de l’ancienneté ou non.

Trois périodes de la LCC

L’évolution de la LCC entre 1975 et 2025 suggère qu’il faudrait plutôt parler des LCC. Avant 2000, la LCC est instable et change en 1976, 1979 et 1999, témoignant de la relativité des structures de coautorat au sein de notre corpus. La LCC la plus durable de la période, entre 1979 et 1988, est organisée autour d’un thème précis, les « Droits de l’An-

tiquité »⁵⁶, dont les auteurs principaux sont KARABÉLIAS et MÉLÈZE-MODRZEJEWSKI : contrairement à nos constats précédents, ceux d’une LCC dont les centres sont autour des thèmes de bioarchéologie et dont la langue de publication surreprésente l’anglais, il s’agit ici d’un noyau autour de l’histoire du droit, écrit en français. Ainsi, la marginalisation du français dans le coautorat n’est pas nécessairement un trait de l’historiographie francophone, mais est pour partie un effet lié à la temporalité, avant que le coautorat anglo-saxon ne s’impose dans la topologie du réseau.

La rupture de 1999-2000, la plus visible sur nos graphiques, constitue le changement de LCC le plus important de notre période, car il s’agit du plus grand en termes de nombres de noeuds concernés, mais aussi car il s’agit du dernier. Pour les publications, comme pour les auteurs (figure 7.12, page 310), s’observe une chute soudaine de la moyenne de l’ensemble des indicateurs de centralité (sauf pour le degré et la betweenness moyenne des auteurs), suivi d’une augmentation à partir de 2000-2001, à l’exception de l’eigenvector. Cette tendance s’accompagne d’une recomposition de la LCC : alors que celle d’avant 1999 réunissait peu d’auteurs, pour beaucoup de publications, il s’agit d’une situation inverse en 2000, avec 236 auteurs connectés par 15 publications⁵⁷.

La nature des publications composant cette nouvelle LCC semble reconfigurer les capitaux légitimes au sein du champ : d’une part, il s’agit de recensions à grands nombre de signataires ; d’autre part, des publications relevant des sciences naturelles appliquées aux périodes médiévales (génétique⁵⁸, paléoenvironnement, archéométrie⁵⁹). Si ces pratiques de coautorat existaient avant, elles ne reliaient pas encore suffisamment d’agents pour détrôner la place occupée par le droit de l’antiquité. En ce sens, la LCC post-2000 peut

56. Cette caractérisation thématique repose sur l’examen manuel, puisque concernant un corpus très restreint, des publications composant la LCC à cette date.

57. Afin d’éviter de comptabiliser des entrées dans des composantes transitoires qui ne constituent pas encore la LCC dominante, nous n’enregistrons, pour nos analyses de corrélation, l’année d’entrée d’un auteur qu’à partir du moment où la LCC dépasse 200 noeuds, seuil atteint en 2000.

58. Oui, aussi tôt, cela peut paraître surprenant !

59. Parmi les publications fondatrices de la LCC de 2000 figurent notamment : *The genetic position of the autochthonous subpopulation of Northern Navarre in relation to other Basque subpopulations; Allochthonous and autochthonous mire deposits, slope instability and palaeoenvironmental investigations in the Borve Valley, Barra; Atmospheric Lead Pollution History during Four Millennia (2000 BC to 2000 AD) in Sweden* ; ou encore *Laser ablation inductively coupled plasma mass spectrometry for spatially resolved trace analysis of early-medieval archaeological iron finds*.

s'interpréter moins comme une rupture dans les pratiques d'écriture que comme un effet de seuil (par un plus grand nombre de noeuds interconnectés), et dont nous pouvons supposer que les formes de capitaux valorisés (interdisciplinarité, sciences naturelles) s'imposent progressivement comme règles du jeu de l'espace de coautorat le plus dense.

A partir de 2000, la LCC se stabilise et ne fait que croître, en attirant de plus en plus de nouveaux entrants, selon une logique conforme au principe de l'attachement préférentiel de BARABASI et ALBERT (BARABASI et ALBERT 1999)⁶⁰ : les noeuds déjà bien connectés attirent préférentiellement de nouveaux liens⁶¹, formant de ce fait un « cohesive core » (LIU et XIA 2015), noyau dense et interconnecté capable d'absorber de nouveaux entrants tout en conservant sa cohésion interne. Ce renforcement temporel en termes de quantité de noeuds de la LCC peut être aussi interprété à la lumière des transformations des conditions de possibilité du coautorat international : la fin de la Guerre Froide rendant la circulation de l'information plus aisée, et peut être surtout le développement du *World Wide Web* ont profondément modifié les conditions matérielles de la collaboration scientifique (HENRIKSEN 2018, p. 4).

Nous pourrions aussi interpréter ces mouvements comme les trois stades décrits par LIU et XIA : une phase de séparation (composantes isolées sans liens entre elles), suivie d'une phase de communautés enchaînées (*chained-communities*, sous-groupes reliés par des ponts fragiles), puis d'un noyau cohésif (*cohesive core*) où les agents les mieux connectés forment un centre stable. En ce sens, la stabilisation de la LCC après 2000 relève du passage à une structure fragmentée de communautés isolées, à une composante géante interconnectée, restructuration du champ du coautorat autour d'un centre capable d'intégrer des sous-espaces auparavant séparés.

Ancienneté dans la LCC et centralité ?

Si notre réseau est cumulatif et présente une dynamique d'attachement préférentiel, il convient de se questionner sur le lien entre ancienneté et mesures de centralité à l'instar de LIU et XIA. Pour ce faire, nous proposons de travailler à l'aide des corrélations de Spearman (figures 7.16–7.15, page 313), sur les rangs, pour mesurer le lien entre ces deux variables :

60. Ou des avantages cumulatifs, si l'on se réfère plutôt à PRICE (D. J. D. S. PRICE 1965)

61. L'observation des snapshots successifs de la LCC suggère cette dynamique, d'autant qu'en 2010, la LCC a attiré les publications qui appartenaient à des sous-espaces isolés auparavant.

une pour toute la population après stabilisation de la LCC, et une autre uniquement pour le quantile supérieur choisi (ici, 5%)⁶².

Sur l'ensemble de la population, toutes les corrélations sont négatives : degree ($\rho = -0,264$, $p < 0,001$), closeness ($\rho = -0,143$, $p < 0,001$), betweenness ($\rho = -0,079$, $p < 0,001$) et eigenvector ($\rho = -0,098$, $p < 0,001$) ; indique que les auteurs entrés les plus tôt tendent à occuper des positions plus centrales, mais les coefficients de corrélation sont particulièrement faibles. Nous pouvons interpréter l'ancienneté comme un facteur associé à la centralité (les agents les plus anciens accumulent davantage de closeness et de degré), mais elle n'est pas un déterminant suffisant. Si l'on réduit la population d'étude au top 5% des auteurs les plus centraux pour chaque indicateur, comptant entre 312 (closeness et betweenness) et 349 (degré) individus, les valeurs des coefficients semblent plus importantes : degree ($\rho = -0.33$, $p < 0,001$), closeness ($\rho = -0.29$, $p < 0,001$), betweenness ($\rho = -0.1302$, $p < 0,03$) et eigenvector ($\rho = -0.67$, $p < 0,001$)⁶³ ; suggérant que si l'on considère uniquement les parts les plus centrales de notre distribution, la centralité de degré et de proximité a quelque chose à voir avec l'ancienneté (plus on est ancien dans la LCC, plus on a de coauteurs et plus on est proche du centre de la LCC), mais de manière faible.

Si ces corrélations sont faibles, cela ne signifie pour autant pas que la temporalité n'a pas d'effet sur la structure du réseau. En effet, les courbes de Lorenz des indicateurs de centralité des auteurs et des publications permettent de souligner une dynamique d'accumulation des inégalités (figures 7.14–7.13, page 311).

Pour les auteurs, comme pour les publications, la betweenness présente dès 1979 un coefficient de Gini important : s'il reste relativement stable pour les publications, autour de 0,7 entre 1980 et 2000 et 0.8 entre 2000 et 2025, celui des auteurs semble augmenter par paliers, d'abord en 1979 (0,6), puis en 1999 (0,9). Ainsi, le rôle de pont au sein du réseau est une propriété structurellement inégalitaire, que le changement de LCC contribue à

62. Notons que l'eigenvector doit être interprété avec précaution en raison de la clique quasi-parfaite identifiée autour de l'encyclopédie de recherche sur la traduction (2013), qui sature cet indicateur pour un petit groupe d'auteurs indépendamment de leur ancienneté.

63. Nous nous refusons à une interprétation ici en ce que l'eigenvector est largement issu de la clique écrivant en allemand, et que la corrélation est largement tirée par le fait que la publication a eu lieu en 2013, en comparaison à la masse entrée entre 2013 et 2025.

augmenter pour les auteurs et pour les publications. En observant la distribution de la betweenness moyenne des auteurs, bien qu'écrasée, par les valeurs minimum et maximum, nous notons que les quantiles supérieurs connaissent un premier pic autour de 2002, avant de redescendre, puis un autre autour de 2014-2016, puis de chuter de nouveau : ces dynamiques pourraient s'interpréter comme des périodes où la LCC croît, mais qu'il n'existe pas encore de connexions suffisantes pour la densifier⁶⁴.

Le Gini de l'eigenvector des auteurs connaît quant à lui des phases de croissance, entre 1979 et 1998, correspondant à notre première LCC, puis, après un retour à un niveau plus bas (0,3), il reprend son augmentation jusqu'à un pic en 2013, sédimentant la structure inégalitaire autour de 1. Si le pic de 2013 représente surtout la clique allemande identifiée précédemment, la tendance générale à la hausse du Gini de l'eigenvector entre 2000 et 2025 traduit bien une concentration progressive du prestige par voisinage au sein de la LCC. Pour les publications, la trajectoire est similaire mais continue, avec, en 2000, une accélération de son augmentation au lieu d'une diminution : partant d'un coefficient de 0,2 en 1980, il atteint 0,99 en 2025.

A l'inverse, la closeness présente, pour les deux types de noeuds, un Gini stable, et autour de 0,1 durant toute notre période, résistant aux changements de LCC. En ce sens, la temporalité aurait peu d'impact quant à la structure inégalitaire de la proximité au centre. La diminution constante de la closeness moyenne entre 1979 et 1999 reflète la croissance progressive de la première LCC : à mesure que le réseau croît, les distances moyennes augmentent mécaniquement, éloignant structurellement chacun du centre ; puis, aux prémices de la nouvelle LCC de 2000, son augmentation suggère une densification du réseau par des publications avec de nombreux auteurs, jusqu'à une diminution entre 2005 et 2017 (la LCC augmenterait en taille plus vite qu'elle ne se densifierait). Enfin, la nouvelle augmentation après 2017 suggère peut être une nouvelle phase de densification portée par les publications aux équipes plus importantes, et qui pourrait être portée par les thèmes issus des sciences naturelles. En ce sens, une partie de l'égalité apparente du coefficient de Gini de la closeness est un artefact de la structure de la projection, puisque tout noeud connecté à une publication avec un grand nombre d'auteurs hérite de chemins courts vers de nombreux autres noeuds. Toutefois, sa stabilité suggère aussi

64. Il s'agirait d'un mouvement analogue à celui observé par LIU et XIA, d'abord des *chained-communities* puis un *cohesive core*, mais répété à deux reprises.

que l'appartenance à la LCC, indépendamment de la temporalité, permet d'être à une distance réduite d'un grand nombre d'autres noeuds.

Le degré des auteurs présente un Gini, relativement stable autour de 0,3 entre 1979 et 1999, chute à 0,15 en 2000, avant de reprendre une croissance régulière pour atteindre 0,52 en 2025. Cette chute est directement lisible comme un effet du changement de LCC : quand 236 auteurs composent la même année la LCC, leurs degrés sont mécaniquement repartis de niveaux comparables, produisant une égalisation momentanée (surtout au regard des publications avec 50 coauteurs). En revanche, le Gini des publications lui, ne fait qu'augmenter, suggérant des inégalités de plus en plus importantes dans les publications coautorées par les mêmes auteurs, ce qui peut s'expliquer par le fait que la majorité des nouveaux entrants n'ont écrit qu'une unique publication, tirant la distribution vers le bas.

La lecture longitudinale des indicateurs de centralité et de leur distribution modère l'importance de l'effet d'ancienneté après la stabilisation d'une LCC, pourtant caractéristique de l'idée des avantages cumulatifs pour les auteurs : s'il semble avéré pour l'eigenvector, il est à nuancer pour la closeness et la betweenness, et semble plus modéré pour le degré. Les corrélations de Spearman, au regard de leur faible coefficient, nous permettent également de rendre compte de la faible influence de l'ancienneté sur la position individuelle des agents. Ainsi, une arrivée précoce dans la LCC ne semble pas être une condition de centralité sauf pour les quantiles les plus supérieurs de notre distribution, et nous pouvons dès lors poser l'hypothèse que, pour y être central, il convient d'y arriver avec les règles du jeu valorisées post-2000 dans le champ. En ce sens, la sédimentation des inégalités au sein de la LCC serait moins un effet de temporalité que de capacité des agents à convertir des capitaux dans un champ qui, sur le plan disciplinaire, se reconfigure en faveur de l'archéologie et des sciences naturelles. L'effet de temporalité agit alors davantage sur le plan structurel que sur le plan individuel : il transforme la structure globale du réseau plutôt que les indicateurs de centralité des agents.

4.4.6 Les apports de la topologie et la nécessité du tournant textuel

L'analyse du réseau de coautorat, et surtout de sa composante principale, rend visible un microcosme aux règles propres, dont l'accès et les structures des positions sont inéga-

lement distribués, et plus largement un espace où se définit la signification des pratiques d'écriture sur le « barbare » dans l'historiographie plutôt récente. Ces inégalités d'accès et de position recoupent les clivages linguistiques et disciplinaires déjà documentés : la maîtrise de l'anglais comme capital linguistique légitime et l'inscription dans les pratiques de publication des sciences naturelles constituent les deux conditions d'entrée dans les positions les plus centrales de cet espace. Au sein de la LCC, les positions des noeuds suggèrent une hiérarchie des formes de centralité qui semblent par ailleurs excluantes : la connectivité et le prestige par le voisinage d'un côté, la *betwenness* comme mesure de la conversion de capital de l'autre ; mais dont les positions les plus avantageées, observables par l'analyse qualitative des distributions des quantiles supérieurs, semblent appartenir aux sciences naturelles ou des agents écrivant avec. La LCC semble en ce sens valoriser un capital scientifique lié aux méthodes issues des sciences naturelles, et des larges consortiums d'auteurs, ce qui n'est pas nécessairement corrélé avec le capital symbolique reconnu dans le champ historiographique au sens large.

Aussi, ces inégalités se renforcent dans la durée, moins par un effet d'ancienneté individuelle que par une recomposition structurelle du champ liée au développement de pratiques de publication importées des sciences naturelles depuis la stabilisation de la LCC en 2000 ; car, avant 2000, la LCC était francophone, autour d'un unique groupe publiant sur des thèmes liés au droit à l'Antiquité Tardive. Ainsi, l'augmentation du coautorat pourrait s'interpréter au regard d'une mutation des pratiques d'écriture de l'histoire, mais aussi comme un lieu de lutte pour accumuler ou convertir du capital (CHEN, DAI et CHEUNG 2026).

Si cette analyse de réseau dit qui écrit avec qui, et les métadonnées de ce qu'ils écrivent, elle ne permet pas d'accéder au contenu textuel et au discours qui s'échange dans cette structure, et au delà, soit les prises de positions autour du « barbare »⁶⁵. Si la structure sociale du champ est indissociable de la production du discours, il convient de nous intéresser à l'analyse textuelle.

65. Il convient de noter à cet égard que le corpus textométrique mobilisé dans la section suivante, composé de 756 documents, comporte 16.5% de publications coautorisées, contre 14% dans le corpus global : cet écart suggère que l'analyse des textes surreprésente peu les pratiques d'écriture collective mises en évidence ici, et qu'elle est en mesure d'embrasser le champ dans une optique plus large.

4.5 Les mots pour le dire

« lorsqu’une langue domine le marché, c’est par rapport à elle, prise comme norme, que se définissent les prix attribués aux autres expressions »

(BOURDIEU 1977, p. 23)

Nous l’avons vu, l’anglais est le cadre dans lequel le débat international sur les « barbares » se formule et se stabilise, et à partir duquel les positions des autres traditions nationales se définissent. Dès lors, chaque espace social produit ses propres espaces linguistiques, et la langue doit être étudiée dans son rapport au social et ses conditions d’utilisation (BOURDIEU 1982). En ce sens, le corpus constitue certes un ensemble textuel homogène sur le plan linguistique, mais surtout un espace structuré manifestant des positions différenciées au sein d’un champ académique international, comme nous l’avons vu section 4.3 qui traduit la position dominante de l’anglais comme langue de légitimation scientifique. Ainsi, en se concentrant sur un corpus anglophone, il s’agit d’objectiver les formes discursives par lesquelles les acteurs du champ construisent et prennent position à travers des mots, et notamment de celui de « barbar », en tant que trace empirique des prises de positions les plus susceptibles de structurer l’ensemble du débat historiographique.

Cette démarche d’objectivation lexicale s’inscrit dans une tradition historiographique remontant aux années 1960, et dont le protocole est maintenant établi : Jean DUBOIS apporte à l’analyse linguistique héritée de SAUSSURE la temporalité et le contexte socio-historique, en traitant les textes historiques comme des discours interrogeables plutôt que comme des réservoirs de citations (J. DUBOIS 1962). Les critères qui en découlent (homogénéité, contrastivité, diachronie) restent les fondements de la construction de corpus en histoire (PROST 1988), et c’est à leur aune que nous présentons le nôtre. Si la démarche adoptée est quantitative et orientée vers l’analyse computationnelle, le retour au texte est essentiel : des appels aux concordances et recontextualisations sont faits lorsque cela est nécessaire pour mieux saisir le sens.

Avant de procéder à l’analyse lexicale elle-même, il convient de présenter la construction de ce corpus, les traitements qu’il a subis, et de vérifier qu’il répond bien à ces critères.

4.5.1 Construire le corpus : entre contraintes techniques et choix épistémologiques

Méthodologie de la récupération et la construction du corpus




FIGURE 4.6 – Workflow de notre analyse textométrique

Dans un premier temps, il convient d'exposer la méthodologie d'acquisition du corpus avant tout prétraitement, en ce qu'elle est indissociable des contraintes techniques de récupération des textes complets. Une fois les notices bibliographiques collectées depuis Worldcat (voir section 3.2.2), l'accès au contenu textuel lui-même devait être adapté à un protocole automatisé, alors même que celui-ci n'est ni toujours accessible, et lorsqu'il l'est, ni toujours libre de droit : en somme, il s'agit d'une question d'accès à la donnée sur le web. Ainsi, ce que nous proposons à analyser n'est pas le corpus que nous aurions pu envisager dans le cadre d'un environnement soumis à des droits d'accès différenciés, soit l'ensemble des documents de notre base. Cet objet constitue un sous ensemble contraint par la disponibilité effective, pour une étudiante de Paris 1 et les abonnements et droits qui en découlent⁶⁶, des données textuelles sur le web, constituant une limite structurelle qui n'est pas sans rappeler les contraintes d'accès à Worldcat, décrites précédemment

⁶⁶. Il s'agit ici non seulement des abonnements institutionnels aux revues électroniques, mais aussi du capital symbolique que confère l'appartenance à une université reconnue : se présenter comme étudiante

(voir 3.2.2). Plusieurs stratégies d’automatisation ont néanmoins été mises en œuvre pour maximiser la taille du corpus envisageable avant le filtrage : exploitation du DOI comme identifiant unique pour localiser les documents sur le web, ciblage de plateformes récurrentes dans le corpus comme OpenEdition, demande à des administrateurs de ces bases, et recours à JSTOR dans le cadre de l’abonnement institutionnel de Paris 1. Ce dernier représente à lui seul 32 % du contenu textuel accessible (2 018 documents sur 6 316) dans notre base de données et 55 % du corpus final ($N = 421$). L’ensemble de ces stratégies a permis de constituer une base de 6 316 textes disponibles en plein texte (PDF natif, fichier texte ou PDF image), soit 5 917 documents publiés entre 1975 et 2025⁶⁷. Puis, deux filtrages successifs ont permis de délimiter un corpus répondant à notre problématique. Le premier porte sur la langue : en retenant uniquement les documents en anglais, le corpus se réduit à 2723 documents. Le second consiste à ne conserver que les textes comportant au moins une occurrence du segment « barbar » dans leur contenu, ce qui constitue la condition d’entrée dans notre objet d’étude et permet de retenir 758 documents. S’il est tentant de penser que l’accès aux grandes masses documentaires sur le web facilite mécaniquement l’analyse textométrique de l’historien, il convient de questionner la difficulté de le penser, puisque « tout corpus linguistique est d’abord représentatif du système d’hypothèses que le chercheur s’est fabriqué » (TOURNIER 1988, p. 31). Ainsi, nous cherchons à comprendre comment une communauté savante anglophone a, au cours de ces cinquante dernières années, construit et reconstruit les sens et l’emploi du terme « barbare » dans ses publications, et quels sont les thèmes environnants ce lemme. Envisager la lexicométrie comme un instrument pour une lecture distante de l’historiographie, au sens de MORETTI (2013) permet de rendre visible des phénomènes comme les évolutions sémantiques, les contextes d’emploi récurrents, les tensions lexicales qui traduisent, en un sens, des prises de position au sein du champ.

Dès lors, il convient de s’assurer que notre corpus n’introduit pas de biais systématique par rapport à l’ensemble des notices de notre base. La seule vérification praticable en l’absence de métadonnées exhaustives sur les *fulltexts* manquants est d’ordre temporel : le

de Paris 1 auprès des gestionnaires de bases de données (effet symbolique renforcé par l’utilisation de l’adresse académique) n’est pas sans effet sur la disposition de ces derniers à faciliter l’accès aux données. L’accès au corpus textuel est donc aussi une question sociale, et non seulement technique ou juridique.

67. Les autres documents étant hors de ces bornes chronologiques.

corpus doit suivre approximativement la distribution annuelle de la base⁶⁸. La figure 7.18, page 315 montre un coefficient de corrélation de Pearson de $r = 0,896$ entre les deux distributions temporelles, calculé en excluant l’année 2014 dont le volume exceptionnel de publications en fait une valeur aberrante (avec un intervalle de confiance à 95 % associé, $[0,823 ; 0,940]$ (tableau 4.4)). Cette forte corrélation atteste d’une adéquation globale entre les deux distributions⁶⁹. La figure 4.7 permet de visualiser cette observation : certaines années sont légèrement sur- ou sous-représentées, dans une fourchette oscillant entre -1 et $+4$ %. On remarque en particulier que les années les plus anciennes tendent à être surreprésentées dans le corpus.

Test	Variante	Statistique	Intervalle de Confiance 95 %	p
Pearson r	avec 2014 ($n = 51$)	0,863	$[0,770 ; 0,920]$	$< 0,001$
	sans 2014 ($n = 50$)	0,894	$[0,820 ; 0,939]$	$< 0,001$
Spearman ρ	avec 2014	0,889	$[0,813 ; 0,935]$	$< 0,001$
	sans 2014	0,887	$[0,808 ; 0,934]$	$< 0,001$
		χ^2 (ddl)	V de Cramér	p
χ^2 de conformité	avec 2014	164,454 (32)	0,0824	$< 0,001$
	sans 2014	139,847 (31)	0,0788	$< 0,001$
	post-2000, sans 2014	38,942 (24)	0,0546	0,0277

TABLE 4.4 – Statistiques de représentativité temporelle du corpus : mesure de la concordance entre la distribution annuelle du corpus et celle de la base de données de référence.⁷⁰

68. Il aurait été envisageable de s’aider des données produites par BERTopic sur les titres (voir 3.2.6), mais ces dernières n’étant pas exhaustives sur nos documents, et fondées sur une imputation par rapport au titre, il semblait moins pertinent que le critère temporel pour évaluer la correspondance entre notre base et notre corpus

69. Si nous testons désormais l’adéquation des proportions exactes par un test du χ^2 de conformité sur l’ensemble de la période, il rejette l’hypothèse nulle ($\chi^2(32) = 135,6$, $p < 0,001$), mais le V de Cramér associé révèle une taille d’effet négligeable ($V = 0,076$) : le test, mécaniquement sensible à la taille des effectifs, enregistre une asymétrie statistiquement détectable mais avec de faibles conséquences analytiques. Ce résultat est en outre potentiellement imputable à l’instabilité des effectifs pré-2000, particulièrement faibles : restreint à la période 2000-2025, où les effectifs satisfont pleinement les conditions d’application du test, le V de Cramér tombe à 0,054 (tableau 4.4), suggérant le caractère négligeable de l’écart.




FIGURE 4.7 – Années sous ou sur représentées dans le corpus par rapport à la base de données

À l’issue de ce filtrage, le corpus de 758⁷¹ documents a été soumis à un prétraitement, étape nécessaire à notre analyse textométrique (ANANDARAJAN, HILL et NOLAN 2019).

Le prétraitement comme geste épistémologique : de la trace textuelle au corpus analysable

Avant toute opération d’analyse sur ce corpus, un prétraitement a été effectué. Celui-ci a constitué en différentes étapes dont nous détaillons la méthodologie ci dessous.

- correction des erreurs d’OCR (décollage ou recollage de chaines) ;
- correction linguistique ;
- suppression de certains artefacts éditoriaux ou bibliographiques.

En premier lieu, nous avons procédé à la correction des textes issues d’une reconnaissance optique de caractères, soit récupérés par océrisation sur nos PDFs, soit par la récupération de la surcouche de texte sur nos PDF, soit issus de JSTOR. Si la question des erreurs d’OCR est ancienne, les problèmes que nous avons le plus fréquemment rencontrés étaient les termes joints, ou séparés (BAZZO et al. 2020, p. 105), comme par exemple `CambridgeUniversityPress` ou `Cam-bridge`. Pour les premiers, nous avons identifié les documents contenant des formes de plus de vingt caractères, puis arbitré manuellement leur caractère problématique — un mot long n’étant pas nécessairement une erreur, l’allemand en offrant de nombreux exemples légitimes. Sur les 280 documents ainsi signalés, 90 se sont révélés réellement affectés : 87 ont été resegmentés automatiquement à l’aide de

71. Je tiens à clarifier ici le nombre de documents initiaux, et retenus. Comme le lecteur pourra le lire par la suite, le corpus initial de 758 documents a finalement été réduit à 756 documents. C’est ce dernier nombre que nous retenons pour l’ensemble de nos analyses, mais il était nécessaire d’expliquer les raisons derrière ces choix d’exclusion et de suivre exactement les effectifs.

Wordsegment sous Python, et 3 ont fait l'objet d'une correction manuelle en raison d'erreurs trop localisées pour être traitées algorithmiquement. Pour les seconds, deux cas se présentaient, selon que la coupure était signalée par un tiret ou non. Lorsque le tiret était présent, il était plus aisé de repérer automatiquement les paires, soumises ensuite à un arbitrage manuel pour les plus fréquentes, avant une généralisation à l'ensemble du corpus : sur les 60 566 occurrences ainsi traitées (soit 0,81 % de l'ensemble des tokens), 16 579 ont été recollées (27,4 %), représentant 2 116 paires uniques⁷². À l'inverse, lorsque la coupure du mot ne se manifestait pas par un tiret, une approche indirecte a été privilégiée : ces erreurs étant par définition rares à l'échelle du corpus, les formes concernées devaient se concentrer dans le bas de la distribution des fréquences. Leur repérage a donc reposé sur la détection de collocations anormalement fréquentes entre des mots peu attestés, révélant ainsi les fragments d'un même token artificiellement séparés.

Ensuite, j'ai procédé à la suppression de certains caractères et chaînes en raison de leur caractère problématique sur le plan statistique. Les artefacts éditoriaux ou bibliographiques isolés (comme par exemple [?], °, ®) ont été systématiquement retirés. De plus, la question des occurrences de « barbar » situées dans des titres d'ouvrages cités en référence posait problème en ce que celles-ci gonflent mécaniquement les cooccurents du terme sans pour autant traduire une prise de position sémantique de l'auteur : un article citant *On Barbarian Identity* (GILLET 2002) ou *Empires and Barbarians* (HEATHER 2010) n'emploie pas nécessairement le terme dans sa sémantique, mais reproduit des titres de publications. Ces occurrences ont donc été identifiées de sorte à pouvoir les exclure pour les analyses nécessaires. Enfin, un document notable posait problème puisqu'il s'agissait d'un compte rendu de conférences sur la reconstitution digitale des manuscrits Anglo-Saxons, et présentait ainsi des textes en plusieurs langues. Celui-ci a été écarté d'office, d'autant que les occurrences de « barbar » qu'il comprenait faisaient toute référence au prénom « Barbara ».⁷³

72. Les 71,5 % d'occurrences non arbitrées correspondent quasi exclusivement à des hapax (83,5 % des paires uniques), dont la fréquence trop faible ne permettait pas de statuer avec certitude. Les paires les plus fréquentes recollées incluent **cen-tury** (111 occurrences, 70 documents), **Cam-bridge** (93) ou **reli-gious** (84).

73. Pour le lecteur intéressé, l'id du document dans la base de données est 69825517c835c41957e003ac, *The advantages and disadvantages of digital reconstruction and Anglo-Saxon manuscripts*. Ce choix explique que nous passons de 758 à 757 documents.




FIGURE 4.8 – Comparaison du nombre de tokens entre corpus avant et après prétraitement

Ce protocole de prétraitement repose délibérément sur les propriétés intrinsèques de la langue plutôt que sur un traitement par modèle de langue : partir des occurrences les plus fréquentes du corpus, dont la distribution suit nécessairement une loi de Zipf, permettait de couvrir l’essentiel des erreurs avec un effort d’arbitrage manuel limité, avant généralisation automatique. Une correction assistée par grand modèle de langue aurait certes pu gagner en précision sur les cas rares, et la proposition fait l’objet de travaux récents (KANERVA et al. 2025 ; BIRIUCHINSKII, ALRAHABI et ROE 2025 ; KOYNOV et DOAN 2025) ; mais le volume de notre corpus rendait cette approche difficilement praticable, tant en termes de coût computationnel et énergétique qu’en raison du risque d’hallucinations sur des formes rares ou spécifiques au vocabulaire médiévisique peu représentées dans les données d’entraînement.

Enfin, une dernière étape du prétraitement a consisté au nettoyage du corpus des erreurs imputables à l’automatisation de la collecte. Si le protocole de récupération des *fulltexts* par identifiant DOI visait à circonscrire la collecte aux seuls articles et chapitres (voir section 2.3.2), j’ai pu constater, en observant qualitativement le corpus, plusieurs cas problématiques. Pour six documents, c’est l’ouvrage entier qui avait été collecté à la place de l’extrait attendu ; pour un septième, identifié comme recension dans notre base, le document récupéré correspondait à l’ouvrage recensé et non à la publication elle-même. Ces anomalies ont été détectées par l’étude de la distribution des longueurs de documents : la présence de fichiers dépassant 500 000 occurrences, alors même que la médiane du corpus se situait en dessous de 10 000, justifiait une vérification manuelle. En isolant les documents concernés, j’ai ensuite délimité manuellement les bornes à partir des originaux afin

de n'en conserver que la portion pertinente. En effet, le cas contraire, le volume textuel des documents les aurait fait dominer les distributions lexicales, déformant mécaniquement les résultats de l'ensemble de l'analyse au détriment des tendances structurelles du corpus. La recension a quant à elle été écartée du corpus, ce qui explique le passage de 757 à 756 documents dans notre corpus final.

Indicateur	Corpus complet	Corpus propre	Réduction
Nb documents	757	756	-0.1%
Nb occurrences	11,313,873	6,485,978	-42.7%
Nb lemmes uniques	444,583	384,829	-13.4%
Nb hapax	291,025 (65.5%)	244,970	-15.8%
Longueur moy. des documents. (lem)	14,946	8579	-42.6%
Longueur méd. des documents (lem)	10,547	7358	-30.2%

TABLE 4.5 – Impact du prétraitement sur les caractéristiques du corpus

Le corpus et ses critères

Avant toute description statistique du corpus considéré, il convient, après ces traitements et choix techniques et épistémologiques, de s'assurer que le corpus répond aux critères proposés par Jean Dubois, et rappelés par Antoine Prost à sa suite (PROST 1988).

Le corpus doit être :

- homogène ;
- contrastif ;
- diachronique.

Le corpus délimité est homogène sur le plan de la langue et de la thématique : les 756 documents sont tous en anglais, et ont été réunis pour leur partage d'une caractéristique, l'apparition du segment « barbar » dans leur contenu. En termes de longueur en revanche, la distribution est asymétrique : si la médiane s'établit à 7 358 tokens, quelques documents extrêmes tirent la moyenne à la hausse (8579 tokens), depuis des textes très courts d'une cinquantaine de mots jusqu'à des dissertations dépassant 90 000 tokens⁷⁴. Ce regroupe-

⁷⁴. Premier quartile : 4 099 tokens ; troisième quartile : 10 920 tokens. L'écart interquartile (6 821 tokens) confirme que la majorité des documents sont des articles de longueur standard, les cas extrêmes

ment est également contrastif : les 756 documents proviennent de revues et d'ouvrages collectifs distincts, couvrant des traditions historiographiques variées, et leur répartition sur cinquante ans (1975–2025) introduit une dimension diachronique permettant d'observer les évolutions sémantiques de « barbar » dans le temps long. En outre, l'ensemble des documents se situent en situation de communication, puisqu'il est constitué de textes publiés dans des revues à comité de lecture ou des ouvrages collectifs scientifiques, dont les auteurs s'adressent à une communauté savante internationale et obéissent aux mêmes conventions d'écriture académique. L'homogénéité énonciative des documents permet, en ce sens, de comparer les variations lexicales en les interprétant comme des positionnements vis-à-vis des pairs, plutôt que des différences de genre discursif.

Si nous avons souligné la particularité des recensions en tant que type de document dans la sous-section 1.2.2, il convient de noter que la nature exacte des documents ne peut être établie à partir des seules métadonnées de Worldcat. Cependant, nous avons vu que les recensions sont des genres à part entière, dont les propriétés lexicales pourraient différer de celles des publications observées. Ainsi, il convient de signaler que notre corpus retenu pour la lexicométrie peut contenir des recensions, et cela doit être gardé à l'esprit pour nos interprétations.

Propriétés distributionnelles et représentativité temporelle

Les caractéristiques du corpus après prétraitement sont récapitulées dans le tableau 4.5 : le corpus propre retenu compte 756 documents pour 6.5 millions d'occurrences, soit une réduction d'un tiers par rapport au corpus brut, principalement imputable à la suppression des artefacts éditoriaux et bibliographiques et au recollage d'occurrences. À l'image de la distribution des notices, le volume textuel annuel croît tendanciellement au cours du temps (figure 4.9) : le nombre de tokens par année est systématiquement plus élevé dans les années 2000 et 2010 que dans les années 1990, ce qui s'explique avant tout par l'augmentation du nombre de documents disponibles par année plutôt que par un allongement des textes eux-mêmes. Notre corpus obéit par ailleurs à la loi de Zipf, résultat attendu de tout corpus de textes en langue naturelle. Comme l'illustre la figure 7.19, page 315, la fréquence d'un mot est inversement proportionnelle à son rang dans la liste relevant principalement d'ouvrages complets intégrés au corpus.

des formes classées par ordre décroissant d’occurrences : quelques mots très fréquents dominent massivement le vocabulaire (les mots outils), tandis que la grande majorité des formes n’apparaissent qu’un petit nombre de fois. Cette distribution, caractéristique de tout corpus textuel de grande taille, confirme que notre ensemble de documents ne présente pas de biais structurel majeur dans sa composition, et qu’il se prête aux traitements lexicométriques usuels.




FIGURE 4.9 – Distribution temporelle des caractéristiques textuelles du corpus

Si ces propriétés statistiques attestent de la cohérence formelle du corpus, nous devons désormais nous pencher sur son contenu pour approcher notre objet d’étude. Pour nos analyses ultérieures, nous nous appuierons sur les formes lemmatisées de notre corpus, et non sur les formes fléchies : le retour au token en tant que tel est ponctuel, pour une explication nécessaire, ou dans le cadre des concordances ou des cooccurrences. S’il aurait été pertinent d’utiliser un processus de *stemming*, ou « recherche du radical » pour réduire la variation morphologique, nous avons privilégié la lemmatisation, plus coûteuse sur le plan computationnel mais elle permet de regrouper les formes fléchies sous une même entrée lexicale sans produire de radicaux artificiels, limite la dispersion fréquentielle des occurrences et facilite ainsi des analyses sémantiques et statistiques (BRUNET 2000 ; PANT, SHARMA et KUNDU 2024)⁷⁵. La lemmatisation ne constitue toutefois pas une opération

⁷⁵. Si une représentation vectorielle du corpus constituait une option méthodologiquement pertinente, son intérêt apparaît plus limité dans le cadre de cette étude en raison de son coût computationnel et des analyses privilégiées ici (régularités lexicales). En effet, les travaux récents montrent que les approches fondées sur des embeddings contextuels, telles que BERT, peuvent rendre certains traitements de nor-




FIGURE 4.10 – Distribution temporelle des documents et des occurrences de notre corpus

neutre en ce qu'elle repose sur des choix algorithmiques et linguistiques pouvant introduire des erreurs, notamment en cas d'homographie ou de polysémie (par exemple, en français, la forme « suis » pouvant renvoyer au verbe « être » comme au verbe « suivre »). En outre, en ramenant plusieurs formes fléchies à une même entrée lexicale, elle peut effacer certaines informations grammaticales (temps, mode, nombre, genre, personne) parfois pertinentes selon l'objet étudié (BRUNET 2000). Néanmoins, dans le cadre de cette recherche, centrée sur les structures lexicales, les proximités sémantiques et les régularités distributionnelles du corpus, les avantages heuristiques de la lemmatisation l'emportent sur ces réserves ; c'est donc sur cette représentation normalisée des données que reposeront les analyses suivantes.

4.5.2 Une première lecture : le corpus délinéarisé

Aborder notre corpus par la question du lexique permet de nous questionner sur les lemmes gravitant, de près ou de loin, autour du « barbare » dans nos documents, qu'ils soient des lemmes précis ou des thématiques plus vastes. Dès lors, leur coprésence peut malisation (lemmatisation, stemming) non indispensables, voire parfois délétères pour les performances des modèles, en particulier lorsque les données sont déjà suffisamment riches (C. F. HO 2025).

constituer une trace sur la compétition pour l'autorité légitime à parler de cet objet. Une première approche de ce corpus textuel consiste à l'envisager comme un *sac de mots*, en le délinéarisant : en isolant les mots de leur contexte syntagmatique, nous substituons à la lecture séquentielle une représentation vectorielle. Il devient alors possible de décrire chaque document par un vecteur, correspondant à son dictionnaire ; revenant à créer une matrice où chaque ligne correspond à un document du corpus, et en colonne le vecteur de mot correspondant.

	mot ₁	mot ₂	mot ₃	...
doc ₁	2	0	1	...
doc ₂	0	3	0	...
doc ₃	1	1	4	...
⋮	⋮	⋮	⋮	⋮

TABLE 4.6 – Représentation du corpus comme matrice documents-termes (modèle du sac de mots).

Notes de lecture pour les cooccurrences et les concordances

Afin de contextualiser les mots évoqués ici, il convient de revenir à leur contexte d'énonciation. Pour la suite de cette section, deux conventions de lecture sont à signaler, et seront présentes en bas de page :

- Pour les concordances, elles seront signalées ainsi : CONCORDANCE : « *Ceci est une concordance du mot concordance.* »
- Pour les co-occurrences, elles seront signalées ainsi : COOCC. SPÉC. *mot co-occurent* (1.5) avec, entre parenthèses, l'indice de spécificité de la co-occurrence positive (sauf contre-indication).

Pour ne pas surcharger le propos, ces éléments ne sont indiqués que lorsque les mots peuvent soulever des différences majeures de sens. Toutefois, l'ensemble des fichiers de co-occurrences pour les termes présentés ci-dessous sont disponibles sur le dépôt Github du projet.

Spécificités lexicales et diversité des capitaux disciplinaires : une lecture par le TF-IDF

Une première approche consiste à s'intéresser aux termes les plus spécifiques à un document par le calcul du *tf-idf*, *term-frequency inverse document frequency* : il permet de pondérer la fréquence brute d'un terme par sa rareté relative dans l'ensemble du corpus, et ainsi dégager la spécificité lexicale de chaque document (« The specificity of a term can be quantified as an inverse function of the number of documents in which it occurs. », SPARCK JONES 1972). Le TF-IDF décrit chaque terme isolément : un score élevé signifie qu'un mot est fréquent dans un document donné mais rare dans le reste du corpus. Il ne dit rien des relations entre les termes eux-mêmes : deux mots saillants pour une même année n'ont pas nécessairement de lien sémantique. Les regroupements esquissés ci-dessous résultent donc d'une lecture interprétative, étayée par les concordanciers : ils constituent des hypothèses de lecture, que les analyses suivantes permettront de mettre à l'épreuve. S'intéresser aux termes les plus spécifiques d'un document revient à travailler à la surface lexicale du discours, par les *mots*, qui peuvent déjà constituer des éléments sur le champ. Ces termes peuvent en effet fonctionner comme des indices de compétence légitime au sens de Bourdieu : des technoclectes disciplinaires dont la maîtrise et l'usage signalent l'appartenance à une tradition historiographique ou méthodologique particulière, et par là même, une position dans le champ. Par exemple, le fait que *fibula* ou *radiocarbon* figure parmi les termes les plus spécifiques d'un document, constitue déjà une information sur la posture savante de son auteur, avant même que l'on sache ce qu'il dit sur les « barbares » : le choix lexical constitue une prise de position (BOURDIEU 1982). Ainsi, appliquer le TF-IDF par document permet de repérer les lexiques gravitant autour du « barbar » et d'esquisser, en creux, la diversité des compétences et des approches légitimes mobilisées dans le champ. Appliqué à notre corpus, cet outil permet une première lecture descriptive, avec par exemple :

Ainsi, la figure 4.11 suggère que les termes les plus spécifiques à ce document ont à voir avec l'archéologie du bâti, et on peut supposer qu'il s'agit d'un site en zone urbaine romaine.

Le TF-IDF rend également possible des lectures par partition, comme par exemple une agrégation par année, permettant alors de distinguer les termes les plus spécifiques




FIGURE 4.11 – Exemple du TF-IDF pour le document 69825516c835c41957df9ddf, *The “Fear” of the Barbarians and the Fifth-Century Western Chroniclers* (2021)

à chaque année de publication, comme en témoigne le tableau 7.20, page 315. Pour les années antérieures aux années 2000, où le corpus ne compte souvent qu’un faible nombre de documents, les termes dominants reflètent la spécificité d’articles isolés plutôt qu’une tendance du champ : ils appellent à la prudence quant à leur interprétation. À une échelle plus large, une lecture des termes saillants laisse entrevoir, par leur sens, des familles lexicales qui *semblent* thématiquement cohérentes⁷⁶.

D’abord, est visible un premier ensemble de vocabulaire institutionnel et juridique : *duke*⁷⁷, *patrician*⁷⁸, *rector*⁷⁹, *count*⁸⁰, puis *jury*⁸¹, *marriage*, *divorce*, *state*⁸², *king*, *public*, *private*, *defendant*, *witness*, *accuser*, *accuse* (1994). On distingue de même un vocabu-

76. Un premier résultat doit être souligné avant toute lecture thématique : le lemme *barbarian* n’apparaît que très rarement parmi les termes saillants (parmi les trois lemmes les plus spécifiques des documents, seuls 11 ont le lemme « barbarian »), et constitue de fait le fond commun du corpus. Ce résultat n’est pas étonnant dans la mesure où il s’agissait de la condition de constitution du corpus, mais invite à lire les termes spécifiques des documents comme des champs lexicaux plus ou moins associés à celui-ci.

77. CONCORDANCE : « *whose protection also made dependent upon duke. second servants ducal household* »

78. CONCORDANCE : « *provide us basis analysis dukes somewhat similar rectors patricians, counts well, tended function Regnum Francorum* »

79. CONCORDANCE : « *one dukes, five patricians, three rectors, twenty - five counts ; Fredegar* »

80. COOCC. SPÉC. *duke, louis, lothar* (93, 67, 55) , nous indiquant qu’il ne s’agit pas du verbe « to count »

81. COOCC. SPÉC. *law, trial, proof, vicinage* (100)

82. Avec, d’abord, des références claires à l’Est de l’Europe : COOCC. SPÉC. *ulus, chinggisid* (100) suivi d’un vocabulaire autour de *law, nation, realm, federal, ruler*.

laire évoquant le fait religieux : *pagan*, *temple*⁸³, *statue*⁸⁴, *monument*, COOCC. SPÉC. *pagan* (45) (1990), *arian*, *bishop* (1997), *missionary*⁸⁵ (1992), *psalter* (1993), *cult* (1984), *reform*⁸⁶ (1987). Plus récemment, *muslim*, *buddhist* ou *jewish* apparaissent ponctuellement, suggérant, à la lecture, une diversification du vocabulaire religieux dans le corpus. Un troisième groupe de termes évoque le champ archéologique et matériel. Nous pouvons ainsi souligner *site*⁸⁷, *sherd*⁸⁸, *glass*⁸⁹ (1993), *archaeology*, *migration*, *archaeologist* (1998), puis *brooch*, *buckle*, *fibulae*, *fibula* (2005), *settlement* (2011), et plus récemment *ware*, *sample*, *glaze* (2022), *glass*, *material* (2023), *radiocarbon*, *date*⁹⁰ (2024), puis *ancestry*, *individual*⁹¹, *population*, *genetic* (2025). La trajectoire de ces termes, lus chronologiquement, semble dessiner une recomposition des méthodologies archéologiques mobilisées, mais cette inférence demeure à vérifier par nos analyses ultérieures. Aussi, ce tableau permet de repérer quelques termes évoquant le texte et la littérature : *poem*, *poet* (1981), *cynewulf* (1986)⁹², *writing*, *utterance*, *cursive* (1988), *poetry*, *poem*, *poet* (2003), *tradition*, *poem*, *english* (2006), *performance*⁹³, *play*⁹⁴ (2007), *alldhelm* (2008)⁹⁵. Enfin, il convient de mettre en lumière la récurrence du lemme *woman*⁹⁶, dont la répétition rend visible une éventuelle interprétation vis-à-vis de l'histoire du genre, sans pour autant que le TF-IDF

83. COOCC. SPÉC. *pagan*, *rebuild*, *destruction*, *church*, *jerusalem* (100, 82, 81, 77, 66)

84. COOCC. SPÉC. *cult*, *pagan*, *temple* (69, 61, 50)

85. COOCC. SPÉC. *mission*, *boniface*, *caste*, *kerala* (100) . Pour le second, nous pouvons supposer qu'il s'agit de Boniface de Mayence ; pour le dernier, une référence à la christianisation de l'Inde (et, plus loin dans les cooccurrences, *christian*, *church*, *conversion*, *convert*, *school*).

86. Si les cooccurrences les plus spécifiques ne relèvent pas nécessairement de la religion, quelques uns y font tout de même références : COOCC. SPÉC. *gregorian*, *church*, *confession*, *monastic* (30, 28, 23, 22)

87. COOCC. SPÉC. *study*, *period*, *area*, *settlement*, *archaeological*, *burial*, *caste*, *bone*, *excavation* (100)

88. COOCC. SPÉC. *amphora*, *abrade*, *ware*, *tile*, *site*, *pottery* (100, 95, 86, 51, 57, 59)

89. COOCC. SPÉC. *composition*, *layer*, *alter*, *alteration*, *stain*, *diffusion*, *oxide*, *silicate*, *corrosion* (100)

90. COOCC. SPÉC. *site*, *burial*, *grave*, *radiocarbon*, *14c* (100)

91. COOCC. SPÉC. *population*, *sample*, *genetic*, *ancestry*, *diet*, *genome*, *ia* (100)

92. *Cynewulf* est un poète anglo-saxon du VIII^e ou IX^e siècle, auteur de plusieurs poèmes en vieil anglais (« C » 2013). Sa présence parmi les termes les plus spécifiques d'une année témoigne de publications sur les sources littéraires de la période.

93. COOCC. SPÉC. *text*, *play*, *audience*, *biblical*, *criticism*, *shakespeare* (100)

94. COOCC. SPÉC. *role*, *performance*, *drama* (100)

95. *Aldhelm* (v. 639–709) est un lettré et évêque anglo-saxon (LAPIDGE 2007).

96. Les cooccurrences permettent ici particulièrement de rendre compte de la sémantisation dans le cadre du genre : COOCC. SPÉC. *man*, *power*, *wife*, *female*, *male*, *marriage*, *husband*, *gender*, *sexual* (100) . Aussi, et de manière plutôt étonnante, les co-occurrences spécifiques montrent aussi un vocabulaire lié à la profession médicale : COOCC. SPÉC. *medical*, *practitioner* (100) , et plus loin *midwife*, *care*.

permette d'en préciser les contextes d'emploi ni les associations lexicales.

La coexistence de ces lexiques constitue, en tant que tel, une piste interprétative selon laquelle le champ ne dispose pas d'un unique capital discursif pour appréhender les « barbares », suggérant peut être que les règles du jeu n'imposent pas (ou pas encore) une méthodologie exclusive sur cet objet. Ces observations restent néanmoins ponctuelles et ne permettent pas, à ce stade, de saisir ce qui organise le vocabulaire du corpus dans son ensemble : le TF-IDF traite chaque terme isolément, indépendamment des autres mots qui l'entourent, et décrit chaque document ou chaque année séparément, sans rendre compte de ce qui les relie ou les oppose à l'échelle du corpus. Néanmoins, il permet d'établir la pluralité et l'hétérogénéité des technoclectes mobilisés autour du « barbar » : juridique, religieux, archéologique, littéraire. Ces lexiques spécialisés coexistent dans le corpus sans que l'on puisse encore dire s'ils s'opposent, se succèdent ou se hiérarchisent ; autrement dit, si leur pluralité reflète une division du travail savant stabilisée, ou les traces d'une recomposition des formes de compétence légitime dans le champ. Pour dépasser cette limite, et interroger non plus des termes pris un à un mais les structures d'association et d'opposition qui organisent l'espace lexical dans son ensemble, il est nécessaire de recourir à une méthode traitant le corpus globalement.

Les oppositions structurantes du champ : l'Analyse Factorielle des Correspondances (AFC)

Les observations précédentes invitent à interroger la possible dimension diachronique du vocabulaire associé aux « barbares » : les différentes manières d'appréhender cet objet se répartissent-elles différemment selon les années de publication des articles, selon des oppositions structurées ?

Notre corpus est, par définition, un corpus historiographique : il est constitué d'écrits d'histoire et reflète, à ce titre, les pratiques, les outils et les questionnements des historiens à l'égard de leur objet (OFFENSTADT 2017). Examiner la distribution du vocabulaire selon les années de publication revient donc à se demander si les transformations du champ laissent, à l'échelle du corpus, une empreinte lexicale objectivable. Pour ce faire, nous construisons une matrice de contingence années×termes, en agrégeant l'ensemble des articles publiés au cours d'une même année, comme l'illustre le tableau 4.7 : chaque

	mot ₁	mot ₂	mot ₃	mot ₄	...	mot _p
1975	3	0	1	2	...	0
1976	0	4	0	1	...	2
1977	2	1	3	0	...	1
1978	1	0	2	5	...	0
⋮	⋮	⋮	⋮	⋮	⋮	⋮
2025	0	2	1	0	...	4

TABLE 4.7 – Matrice de contingence années-termes représentant la distribution du vocabulaire selon l’année de publication. Chaque cellule indique la fréquence d’un lemme dans l’ensemble des publications parues cette année-là.

cellule correspond à la fréquence d’un lemme dans l’ensemble des publications parues cette année-là.

Se questionner sur cette distribution temporelle revient à interroger les recompositions du champ (paradigmes, méthodes et objets légitimes) et leur inscription dans le lexique : ce qui constitue le capital scientifique légitime pour parler des « barbares » a-t-il changé sur cinquante ans, et ce changement est-il visible dans la langue ? En ce sens, l’AFC permet d’explorer l’éventuelle historicité des luttes de définition par le vocabulaire au sein de cet espace savant à travers leurs manifestations lexicales.

Ainsi, il convient d’identifier dans ce tableau ce qui s’écarte de l’attendu, de l’hypothèse nulle, selon laquelle la distribution du vocabulaire est indépendante des années. Si c’était le cas, chaque ligne de la matrice ne serait qu’une reproduction proportionnelle du profil lexical global du corpus. Pour ce faire, nous mesurons, par le χ^2 , les écarts à l’indépendance. Cependant, notre matrice compte 51 années pour 384 829 lemmes, soit 19 626 279 cellules, rendant la lecture directe impossible. Pour résumer les écarts à l’indépendance de cette matrice, nous mobilisons l’Analyse Factorielle des Correspondances (AFC), mise au point par Jean-Paul Benzécri (J.-P. BENZÉCRI et al. 1973) et popularisée par BOURDIEU dans *La distinction critique sociale du jugement* : il s’agit d’un algorithme de décomposition itérative qui résume les écarts à l’indépendance du tableau en les projetant sur des axes factoriels hiérarchisés, chacun concentrant une part décroissante de l’information. Les premiers axes retiennent ainsi les oppositions les plus structurantes du corpus, qu’il s’agisse d’oppositions entre termes ou entre années. Notre démarche s’ins-

crit ainsi dans une tradition d’usage de l’AFC en histoire, qui remonte aux années 1970 (PROST et ROSENZVEIG 1971) et que les développements récents de la textométrie ont contribué à renouveler (*Textométrie et temporalité* 2024, et notamment SALEM 2024)

Le vocabulaire retenu pour notre AFC résulte d’un filtrage en trois étapes successives. En premier lieu, les catégories morphosyntaxiques sans charge sémantique pour notre analyse sont écartées : ponctuation, déterminants, prépositions, pronoms, conjonctions, auxiliaires et symboles sont exclus sur la base des étiquettes POS attribuées par spaCy lors de l’annotation du corpus. En second lieu, un ensemble de formes fréquentes mais non discriminantes, des termes parasites issus de l’OCR ou des métadonnées (*https*, *http*) ou des connecteurs logiques (*however*, *also*), sont écartés manuellement. En troisième lieu, à l’image de MIAO et SALEM (2021), seuls les lemmes dépassant un seuil minimal d’occurrences dans l’ensemble du corpus sont retenus, afin d’éliminer les hapax, dont la distribution est par définition non interprétable à cette échelle. Parmi les formes survivant à ces filtres, les 500 lemmes les plus fréquents sont finalement sélectionnés pour constituer les lignes du tableau.⁹⁷ Le tableau résultant croise en lignes les 500 lemmes retenus et en colonnes les 51 années de publication (1975–2025), chaque cellule x_{ij} contenant le nombre d’occurrences du lemme i dans les documents publiés l’année j . L’étude de ce tableau par une AFC permettrait de voir si des années surreprésentent ou sous-représentent des lexiques spécifiques par rapport aux autres⁹⁸.

Une première AFC, conduite avec les années, produit un émiettement de l’inertie (voir figure 7.22, page 320) : les facteurs 1 et 2 captent respectivement 9,2% et 7,4% de la variance totale, et la proximité des profils annuels rend le plan factoriel difficilement lisible (figure 7.20, page 318 pour les axes 1 et 2 et figure 7.21, page 319 pour les axes 2 et 3). Si nous plaçons l’année 1989 en variable supplémentaire, dont les contributions aux deux premiers facteurs s’élèvent respectivement à 30% et 40% de l’inertie, en variable supplémentaire, et si nous seuillons à 0.5 les contributions des lemmes, le plan semble plus

97. Ce choix répond à la règle des effectifs théoriques minimaux de COCHRAN (1954), selon laquelle au moins 80 % des cellules doivent présenter un effectif théorique supérieur à 5 pour que la statistique du χ^2 soit stable. En deçà, le χ^2 est instable et les contributions factorielles peu fiables. Retenir les lemmes les plus fréquents maximise la densité du tableau et réduit la proportion de cellules à effectif nul.

98. Pour des raisons de commodité, les facteurs seront parfois abrégés par « F », premier facteur ou facteur 1 devenant ainsi F1.

interprétable (figure 7.23, page 321) : on distingue une opposition entre les années 2020 et le reste du corpus. Néanmoins, cette opposition, si elle peut être avérée sur le plan lexical, peut s’expliquer par la volumétrie : si les années les plus récentes captent une bonne partie de l’inertie du premier facteur (2022 à 16%, 2023 à 6%, 2020 à 4,8%, 2025 à 3,8%, 2024 à 0,9% avec 2009 à 6% du même côté. La présence de 2009 de ce côté de l’AFC peut questionner : l’année, selon la figure 4.9, ne présente pas une rupture significative dans la volumétrie de notre corpus. Son positionnement s’explique cependant par un artefact de projection : avec un $\cos^2$ faible sur les axes 1 et 2, 2009 est en réalité mieux représentée sur le facteur 6, auquel elle contribue à hauteur de 4,8%. Le vocabulaire qui lui est associé sur cet axe (*muslim*, *island*) peut souligner la spécificité d’une ou plusieurs publications, et constitue peut-être lui-même une trace diachronique qui rapprocherait cette année d’une période plus contemporaine, mais que la structure du plan factoriel 1–2 ne permet pas d’isoler. Cette limite tient à la nature de l’AFC, en ce qu’elle repose sur la distance au χ^2 et est donc sensible aux effectifs marginaux : les modalités les plus volumineuses exercent une attraction plus forte sur les axes factoriels. Cependant, nous avons pu constater par la figure 4.9 des disparités dans la volumétrie de documents et de tokens dans les années les plus récentes, par rapport aux plus anciennes de notre corpus.

Pour pallier ces limites, nous regroupons les 51 années couvertes par le corpus en périodes aux effectifs de volumétrie plus comparables. Le nombre de classes est déterminé par la règle de Sturges⁹⁹, puis les frontières entre ces classes sont établies par l’algorithme de Jenks (JENKS 1967), qui minimise la variance interne de chaque groupe tout en maximisant la variance entre groupes, appliqué ici non aux valeurs annuelles brutes mais à leur distribution cumulée, afin que chaque période regroupe une masse de tokens comparable. On obtient ainsi 6 périodes, dont les profils lexicaux sont suffisamment contrastés et les effectifs suffisamment équilibrés pour que l’AFC soit interprétable (figure 4.12) : il faut toutefois souligner leur inégalité temporelle, car si la première période regroupe 20 années ensemble, les dernières ne couvrent que trois ou quatre années, invitant à la précaution quant aux interprétations diachroniques que nous pourrions suggérer ; tout contraste dégagé entre les périodes repose alors sur des tendances tributaires d’effectifs très différents. De plus, le choix de l’échelle temporelle n’est jamais neutre, en ce que comparer des textes à l’année, à la décennie ou à la période ne produit pas les mêmes effets (LAMASSÉ 2021)

99. $k = 1 + \log_2 N$, où N désigne le nombre d’années non vides du corpus (STURGES 1926).

parce que chaque échelle fait émerger des réalités différentes du corpus. Le passage de l'année à la période volumétriquement homogène que nous opérons ici est ainsi un choix interprétatif autant que technique : en lissant les irrégularités de production, il favorise la lisibilité du plan factoriel ; mais il présuppose que les évolutions lexicalement significatives sont observables à cette échelle, ce qui n'a rien d'évident.

Ce découpage permet d'égaliser les masses de tokens, pour rendre comparable des périodes entre elles sur le plan statistique, améliorant, de ce fait, la lisibilité du plan factoriel. Cependant, sur le plan méthodologique, il ne se fonde pas sur des dynamiques du corpus (ruptures dans la production par exemple, en quantité de documents ou de tokens), et plus largement, des évolutions historiographiques ou discursives qui auraient pu justifier une périodisation différente¹⁰⁰. Par exemple, la coupure de 1994 résulte uniquement du seuil volumétrique, alors qu'il n'aurait pas été incohérent de couper un an avant ou après. Le recours à un critère unique, la volumétrie de tokens, parmi d'autres segmentations possibles est un choix réducteur au regard de la diversité des analyses que nous proposons : un découpage par analyse aurait pu être envisagé, mais cela aurait introduit une complexité technique et méthodologique qu'il m'a semblé difficile à tenir dans le cadre de ce travail. Ainsi, le découpage retenu représente un outil grossier, pertinent pour faire émerger quelques tendances sans pour autant parvenir à rendre compte des dynamiques plus fines du corpus.

Enfin, il convient de signaler une limite de l'AFC appliquée à des données ordonnées temporellement : l'effet Guttman tend à produire sur le plan factoriel une forme en croissant qui n'est pas spécifiquement temporelle, mais qui « reflète seulement des transformations, des remplacements de vocables d'un texte à l'autre » (LAMASSÉ 2021) ; c'est-à-dire que la progression chronologique que peut dessiner le plan factoriel peut constituer, pour partie, un artefact géométrique plutôt que la preuve d'une évolution discursive que le corpus porterait intrinsèquement. Si le regroupement en périodes volumétriquement homogènes réduit l'instabilité des effectifs marginaux faibles, et que le seuillage des contributions que nous appliquons ci-dessous tente d'atténuer ce biais, il demeure nécessaire de considérer les oppositions constatées comme des hypothèses de lecture formulées à partir de cette représentation.

100. Ce geste de construction est ainsi justifié sur le plan technique, mais pas historiographique.





FIGURE 4.12 – Périodisation par la volumétrie selon l'algorithme de Jenks

Nous pouvons en premier lieu constater que la catégorisation en 6 groupes d'années consécutives permet de concentrer l'inertie (figure 4.15) : le facteur 1 capte, à lui seul, 40% de la variance, et le facteur 2, 20%, le troisième 16%, tandis que les facteurs suivants n'en concentrent chacun que 12 et 7%. Plutôt qu'une lecture facteur par facteur, nous proposons ci-dessous des axes interprétatifs croisant ceux-ci.

La première opposition structurante, concordante avec la temporalité, que suggère l'AFC, est d'ordre méthodologique : ce qui oppose les périodes entre elles, c'est d'abord la nature du capital disciplinaire mobilisé pour construire l'autorité sur l'objet « barbare ».

Sur le premier facteur, d'un côté, on retrouve un lexique de l'ordre de la philologie, des approches littéraires et culturelles, associé aux périodes 1975–1994 et 1995–2005 : *wife* (2,1), *woman* (1,9), *poem* (1,8), *english* (1,8), *poetry* (1,5), *man* (1,4), *saxon*¹⁰¹ (1), *poet* (0,9), *book* (0,5), *literature* (0,5), *play* (0,4), *literary* (0,3). La concentration de termes relatifs aux sources textuelles vernaculaires rappelle ainsi la présence de *Cynewulf* (1986) ou d'*Aldhelm* (2008) dans le TF-IDF, suggérant, pour ces périodes plus anciennes, l'ancrage dans le courant des *Anglo-Saxon studies*, caractérisé par l'attention portée à la littérature en ancien anglais et à ses contextes de production. De l'autre côté du plan factoriel, nous observons un lexique fortement connoté vers les sciences naturelles et l'ar-

101. COOCC. SPÉC. *english, old, anglo, england* (100)



chéogénomique, spécifique à la production 2021–2025¹⁰² : *sample* (4,1), *population* (1,9), *burial* (1,8), *datum* (1,6), *individual* (1,46), *analysis* (1,33), *archaeological* (1,1), auxquels s'ajoutent *result* (0,5), *site* (0,48), *area* (0,48), *material* (0,35). La coprésence de *burial*, *sample*, *population* et *individual*¹⁰³ renvoie probablement aux développements récents de l'archéogénomique, dont les travaux sur les populations de l'Antiquité tardive et du Haut Moyen Âge mobilisent l'analyse de restes osseux, d'échantillons biologiques et la reconstitution des populations (P. J. GEARY 2025¹⁰⁴), en accord avec les lemmes *ancestry*, *genetic* et *radiocarbon* identifiés dans l'analyse TF-IDF : ainsi, si le TF-IDF nous suggérait leur présence spécifique dans les années les plus récentes, l'AFC confirme leur statut constitutif d'une opposition méthodologique au sein du corpus.

Ce paradigme se prolonge sur le second facteur, avec, du côté des périodes antérieures à 2006, le lemme *law* (1,2), suggérant un lexique centré sur les structures législatives du Haut Moyen Âge : l'analyse des cooccurents de *law* suggère un vocabulaire portant sur les corpus textuels normatifs (*roman law*, *customary law*, *ecclesiastical law*), mais aussi un ensemble de désignations de lois *barbares* spécifiques : *lex salica*, *lex burgundionum*, *lex baiuvariorum*, *visigothic*, *frankish*, *bavarian*, *alemannic*. Les concordanciers suggèrent que *king*, premier cooccurrent de *law*, renvoie à des souverains législateurs : Clothaire, Rothari, Aethelstan, Alaric, Théodoric ; tandis que *code* convoque à la fois les codes *barbares* et les codes justinien et théodosien, faisant sans doute référence à une historiographie attentive à l'articulation entre droit romain et droit barbare. Ce résultat invite à le mettre en relation avec l'historiographie des lois barbares, dont JOYE signale un renouveau interprétatif à partir des années 1990 (JOYE 2018, p. 130, n. 3). Toutefois, la position de *law* du côté des périodes les plus anciennes de notre corpus appelle à nuancer cette périodisation : si l'année

102. Il ne faut pas interpréter cette proposition comme une absence totale de cette méthodologie dans les années précédentes. En effet, si ces approches sont favorisées sur une période contemporaine, il convient de souligner la présence d'une publication en 1975 dont le vocabulaire constitue notamment la spécificité du F3, abordant la paléolimnologie appliquée à un lac Egyptien (*Climate and the History of Egypt : The Middle Kingdom*).

103. Cette interprétation est suggérée par les cooccurrences. Pour *population*, ses cooccurrents sont *ancestry*, *sample*, *data* par exemple ; pour *population*, les cooccurents sont notamment *genetic*, *model*, et encore *ancestry* ou *data*.

104. Je n'ai pas eu l'opportunité de lire cet article. La citation de cette référence est ici une supposition de lien entre mon propos, et le résumé de l'article présent sur la page web de celui ci, mais aussi par la recension SOT 2026 de l'ouvrage de GEARY, *Comment la génétique réécrit l'histoire du Moyen Âge*, 2025.

médiane des publications recensées dans la bibliographie de l'ouvrage collectif récemment paru sur les lois barbares s'établit à 2011, pour une moyenne à 2007 (JOYE 2025a), le premier quartile autour de 1978 confirme l'existence d'une production antérieure, en cohérence avec notre observation. La spécificité lexicale de *law* pour les périodes 1975–2005 dans notre AFC pourrait ainsi refléter cette strate historiographique plus ancienne, présente dans un corpus où les années antérieures à 2000 ne comptent souvent que peu de documents ; et suggère aussi une approche du *barbare* par les textes. De l'autre côté du facteur, pour les publications 2006–2011 (44 % de l'inertie du F2), l'angle méthodologique est suggéré par le vocabulaire à tonalité spatiale : *castle* (3,9), *settlement* (2,9), *town*¹⁰⁵ (2,6), *site* (1,4), suggérant une rencontre entre archéologie médiévale et contexte urbain au tournant des années 1990–2000 (VANETTI 2022 ; LEFEBVRE 2021 ; BURNOUF et JOURNOT 2020).

Aussi, cette question de méthodologie se retrouve sur le facteur 3 (16 % de la variance), dont l'inertie est portée à plus de 10% par la contribution du lemme *lake* (11.83), renvoyant aux publications sur l'analyse des sédiments, du climat, de la température et des flux dans les bassins (les cooccurrents *stella*, *angel* et *teresa* sont des noms propres de lacs), et fait sans doute référence aux publications, autour des années 2012–2016 en paléolimnologie. D'un autre côté, on observe la contribution négative de « Tale » (0,7) qui renvoie, selon nos concordances, aux Contes de Canterbury, ce qui rattache ce pôle à la littérature vernaculaire médiévale anglaise déjà associée aux périodes plus anciennes.

Enfin, c'est également sur le facteur 4 que se prolonge cette question de méthodologie, avec, pour la période 1995–2005, les lemmes *manuscript* (2,3) (qui renvoie dans ses cooccurrents non seulement à une pratique philologique d'édition et d'analyse des sources, mais aussi aux manuscrits des lois barbares ainsi qu'aux traditions manuscrites persanes et arabes), *saga* (0,5), *chronicle* (0,5) peuvent être rapportés à l'ancrage de cette période dans les études de sources manuscrites¹⁰⁶ ; mais aussi le lemme *image* (1,9)¹⁰⁷, suggérant une approche par l'histoire de l'art. Sur le facteur 5, en association avec la période 2017–2020, nous notons toujours cette archéologie du bâti avec les contributions de *castle* (5)

105. COOCC. SPÉC. *wall*, *urban*, *defence* (100)

106. En ce qui concerne le terme *irish*, les co-occurrences relèvent davantage de noms propres : *gerald* (10), peut être en référence à Gerald of Wales, *macneill* (100) en lien avec Eoin MACNEILL

107. COOCC. SPÉC. *art*, *christ*, *figure*, *scene*, *depict*, *artist*, *representation*, *visual* (100, 100, 99, 86, 78, 64, 76, 99)

et *building* (3).

Au-delà de cette recomposition méthodologique, l'AFC fait apparaître des vocabulaires plus directement thématiques qui structurent les manières d'approcher le « barbare » dans le corpus : certains se concentrent sur une fenêtre chronologique précise, tandis que d'autres traversent l'ensemble de la période en se reconfigurant. Si nous avons distingué, pour des raisons analytiques, les dimensions méthodologiques et thématiques, il convient toutefois de souligner leur lien : les objets d'étude ne prescrivent pas mécaniquement une méthode particulière, mais peuvent s'accompagner d'outillages spécifiques. En ce sens, choisir d'interroger un objet peut aussi revenir à mobiliser certains capitaux plutôt que d'autres.

Parmi les thèmes plus anciens, mais persistants, le vocabulaire du droit semble spécifique aux périodes 1975–2005, comme nous l'avons vu à propos de *law* (qui par ailleurs se trouve du même côté que *state* sur le facteur 5, auquel ce lemme a une contribution de 0,8 et *law* de 1, *authority*¹⁰⁸ à 0,2, *imperial* à 0,3, *system* à 0,77, *legal* à 1) : l'approche du *barbare* par les corpus normatifs et une histoire institutionnelle semble constitutive du vocabulaire dans l'historiographie de ces décennies, mais également 2017–2020 dans une moindre mesure compte tenu de la plus faible inertie prise par le facteur 5. Ainsi, si ce vocabulaire est spécifique aux décennies plus lointaines, il demeure présent de manière latente vis à vis de l'inertie. De la même manière, les lemmes suggèrent aussi l'influence de l'anthropologie et du *cultural turn* attentif aux conditions de production des discours, mais aussi aux rapports de genre comme catégorie d'analyse (MAIREY 2008 ; BRUBAKER et SMITH 2004, p. 1–2¹⁰⁹) avec des lemmes comme *woman* (1,9 de F1, et 4 de F4), *wife* (2,1 sur F1 et 3,6 sur F4), *man* (1,4 sur F1 et 2,1 sur F4) et *image*¹¹⁰ (1,9 sur F4). L'analyse des cooccurrents, au-delà des plus spécifiques, de *woman* le suggère : le lemme s'inscrit dans plusieurs registres discursifs, de la relation de genre (*man*, *gender*) aux structures familiales (*wife*, *child*, *household*), en passant par le cadre religieux et hagiographique (*saint*, *mary*, *christ*) et les structures sociales (*queen*, *enslave*, *authority*). Ce vocabulaire semble en ce sens plus caractéristique de la production de 1975–1994, même s'il demeure latent

108. COOCC. SPÉC. *temporal*, *church*, *power*, *religious*, *political*, *secular* (100, 87, 83, 80, 64, 55)

109. Voir notamment la bibliographie en note de bas de page BRUBAKER et SMITH 2004, p. 9

110. Si l'image fait référence aux représentations du Christ, le lemme *woman* et *man* en sont des cooccurrents fréquents)

en ce qu'il ne se distingue de la période 1995-2005 qu'à partir du facteur 4, indiquant un fond commun aux deux périodes, et n'est pas absent des périodes plus récente.¹¹¹

Egalement, et de manière plus localisée, nous notons la présence du registre militaire et narratif, avec ses grandes figures contributives du facteur 3, en association avec la période 2012-2016 : *henry* (1,5 et selon les concordances, Henry III, VI et VII notamment), *william* (1,2, à la fois Guillaume le Conquérant, mais aussi Guillaume de Malmesbury et William Dunbar), *richard* (1,2, Richard II, Richard coeur de Lyon et l'historien Richard William Southern), *battle* (0,8), *chronicle* (0,5) et *military* (0,8), ainsi que la collocation *holy cross* et *holy land* (*holy* contribuant à 0,9) ; qui semble proposer historiographie attentive à la conquête, la croisade et à ses récits. Néanmoins, nous ne pouvons ici trancher entre une histoire de la guerre et une histoire mobilisant les chroniques comme sources sur la guerre.

Enfin, l'identité et l'ethnicité (*ethnic* (0,4 F2 et 2 F3, *identity* (2,6 F2 et 1,2 F3), *narrative*) forment un registre à cheval sur les périodes 2006-2011 et 2012-2016, suggérant une concentration de la production sur le sujet dans cet intervalle temporel. La coprésence de « ethnic » et « identity » semble cohérent, au moins en partie, à la publication en 2013 du volume collectif *Strategies of Distinction. Ethnicity and Religion in Early Medieval Europe* dirigé par W. POHL et G. HEYDEMANN, ouvrage majeur de l'historiographie. Ces éléments peuvent être mis en relation avec le débat sur l'ethnogénèse des « barbares », que COUMERT et DUMEZIL situent dans une phase de remise en question depuis les années 2000, notamment sous l'impulsion de la critique de l'école de Vienne portée par GILLETT (GILLETT 2002 COUMERT et DUMÉZIL 2020) ; et serait en ce sens un dialogue autour de ces objets.

Du côté des thèmes plus transversaux, nous constatons une recomposition du vocabulaire autour de la religion. Ainsi, le lemme *bishop* (F2 et F3, périodes 1975-2005), avec ses cooccurents renvoyant aux institutions ecclésiastiques, à l'arianisme et à la conversion des royaumes barbares¹¹², représente une première manière de désigner l'altérité religieuse : le

111. Si l'on peut relier l'histoire des structures familiales aux *gender studies*, que les lemmes *daughter* (7,5 sur F2), *father* (2 sur F2) pourraient suggérer et constituer ainsi une continuité pertinente, il convient de ne pas surinterpréter leur présence puisque leur inertie est largement liée à un document de 2011 *Relative identities : Father-daughter incest in medieval English religious literature* (2011), qui présente aussi des occurrences de *god*.

112. (*church*, *abbot*, *council*, *pope*, *diocese*) et à Rome (*emperor*, *roman*), mais aussi, de façon notable, à l'arianisme (*arian*, troisième cooccurent par fréquence)

« barbare » y est appréhendé par sa relation à la christianisation romaine et au débat dogmatique qui la traverse. Cette observation invite à suggérer l'existence, dans cette période du corpus, d'une historiographie attentive à la conversion des royaumes barbares et à la concurrence entre catholicisme et arianisme ; une thématique que Bruno DUMEZIL notait comme relativement délaissée au moment de la publication de ses *Racines chrétiennes de l'Europe* (DUMÉZIL 2005), ce qui rendrait d'autant plus significative sa présence lexicale ici. À cette désignation relationnelle succède, sur les périodes 2006–2011, l'apparition de *muslims* (2,1 sur F2) et *muslim* (0,9 sur F2 et 1,2 sur F5 pour la période 2017–2020) dans un registre spatial (Sicile normande, Méditerranée) : la religion n'est plus seulement un cadre de conversion, mais une ligne de contact et de frontière. Enfin, sur la période la plus récente, *jewish* (2,5 F1) et *jew* (4,7 F1) font partie des lemmes les plus contributifs de la période 2021–2025. Ce vocabulaire semble traduire, non pas un changement dans les croyances étudiées, mais peut être un déplacement du cadre interprétatif pour appréhender l'altérité religieuse vis-à-vis du christianisme dans le champ ¹¹³.

Les espaces de contact suivent une logique partiellement similaire. Le vocabulaire méditerranéen et normand (*island* (1,4), *norman* (1,17) ¹¹⁴, *empire* (0,7), *viking* (0,48) sur F2) ¹¹⁵ semble s'inscrire dans un mouvement historiographique autour des identités normandes et de la Méditerranée médiévale, porté par exemple par le projet *The Norman Edge* de l'université de Lancaster, actif entre 2008 et 2011, et par la série *The Medieval Mediterranean* (Brill), dont les publications font de la Sicile un cas d'étude privilégié des contacts entre chrétienté et islam. Ce lexique cède progressivement la place, sur les facteurs suivants, à un espace eurasiatique (*mongol* (1,2), *black* (0,7) ¹¹⁶, F3, 2006–2011), comme nous le suggère également les vocables *west* et *east* ¹¹⁷ Enfin, le cinquième facteur, en association avec 2017–2020, déplace l'espace de contact vers un horizon africain et

113. Cette trajectoire, de la théologie et des institutions aux autres religions monothéistes n'est par ailleurs pas sans rappeler le contexte politique des 20 dernières années, tels que les médias nous les transmettent (printemps arabe et attentats terroristes dans les pays occidentaux, puis médiatisation de l'invasion de la Palestine).

114. En collocation avec *anglo* pour former *anglo-norman*.

115. La cooccurrence avec *sicilian* et *sicily* confirme que le lemme *island* renvoie directement à la Sicile.

116. Renvoyant pour partie à la mer Noire, mais aussi : COOCC. SPÉC. *white*, *blackness*, *african*, *slavery*, *blackface* (100, 100, 88, 61, 55)

117. *west*, contre notre attente au segment répété *roman west* dès les premiers résultats, est en réalité davantage cofréquent des autres points cardinaux (de *slavic* mais puisqu'un seul document en fait état, nous l'écartons ici.) et *demedieval*, en référence à l'Occident Médiéval sans doute.

commercial : *slave* (2,5), *trade* (1,0), *master* (1,15)¹¹⁸ et *africa* (0,4) y dessinent un lexique de l'échange et de la servitude, tandis que la réapparition de *mongol* (2,6), déjà présent sur F3, suggère moins un remplacement du vocabulaire eurasiatique qu'un élargissement des espaces de contact envisagés.

Ces observations invitent à revenir sur le statut du lemme « barbarian » lui-même dans l'espace factoriel. Celui-ci n'apparaît comme lemme discriminant (1,9) qu'à partir du quatrième facteur (12 % de la variance), en association avec la période 1995–2005. Si le concept de « barbare » reste le socle du corpus, son émergence sous cette forme lexicale spécifique peut s'interpréter comme une stratégie de distinction scientifique par la réflexivité au sein du champ, devenant objet de discours en soi. L'hypothèse est cohérente avec la mise en place du projet *Transformation of the Roman World* (ESF, 1993–1998), qui approfondit la problématisation du « barbare » dans le cadre du monde « post-romain »¹¹⁹. Sa faible présence sur les facteurs précédents ne signifie pas son absence des périodes antérieures, puisqu'il pouvait y être dilué par des vocabulaires plus larges ou plus précis, comme nous avons pu le voir avec les désignations propres aux corpus juridiques (*lex salica*, *lex baiuvariorum*) ou aux souverains¹²⁰. Ce constat n'est pas suprenant : puisque « barbarian » est la condition d'entrée dans notre corpus, il est attendu qu'il ne structure pas de manière spécifique les oppositions entre les modalités. Ainsi, il s'agit des contextes lexicaux autour du « barbare » qui varient, appréhendé à travers la loi et la conversion, la littérature vernaculaire et le genre, l'espace habité et les identités en contact, la conquête et l'ethnicité, enfin le corps et le génome.

L'AFC fait apparaître une recomposition des lexiques mobilisés autour du « barbare » sur cinquante ans : un déplacement du philologique vers le génomique, des re compositions thématiques plus fines sur les périodes intermédiaires. Entre ces deux pôles, des

118. Les cooccurents suggèrent un usage en dialectique *master-slave*

119. Cette centralité peut être mise à l'épreuve par une observation de terrain dans le champ lui-même : lors d'échanges avec Sylvie JOYE, spécialiste du Haut Moyen Âge, et Agnès GRACEFFA, spécialiste d'historiographie contemporaine et d'histoire culturelle, une piste bibliographique spontanément évoquée à l'annonce de ce sujet de recherche fut ce projet. Ce moment d'enquête, au sens où la conversation informelle constitue une donnée d'enquête à part entière (WEBER 2010, p. 171), suggère que la période 1995–2005 occupe une position centrale dans la mémoire collective du champ comme moment de réflexivité sur le « barbare »

120. Ce qui, bien entendu, est applicable à d'autres vocables.

recompositions lexicales semblent caractériser certaines périodes : l'espace méditerranéen et normand, le registre militaire et narratif, les vocabulaires de l'ethnicité et de l'identité, sans pour autant que nous parvenions à interpréter ces changements de vocabulaire comme une trajectoire cohérente. Parmi les 500 lemmes les plus fréquents retenus pour cette analyse, ceux qui contribuent peu aux axes et non mentionnés jusqu'à présent (non visibles sur les plans seuillés (figures 4.13 et 4.14)) dessinent en creux un fond lexical commun que l'historiographie partage autour du « barbare », indépendamment des époques et des approches. D'autre part, les oppositions structurantes détaillées plus haut suggèrent une recomposition du capital scientifique légitime par le vocabulaire : le déplacement d'un lexique philologique et juridique, nécessitant des compétences spécifiques, au lexique de l'archéogénomique peut être, dans le même temps, un déplacement des capitaux nécessaires pour parler des « barbares » que le *distant reading* permet ici, par le vocabulaire, de formaliser. Il ne faudrait néanmoins pas l'interpréter comme un remplacement, mais du moins une reconfiguration vis-à-vis du statut de la preuve en tant que règle du jeu au sein du champ.

Néanmoins, en introduisant l'année de publication, ou les périodes volumétriques que nous en avons dérivées, comme variable de partition, nous avons projeté sur le corpus une temporalité *exogène* à son lexique. Comme le souligne LAMASSÉ (2021), il faut « prendre garde à ne pas forcer une approche où la temporalité des textes est donnée par un contexte externe », sous peine de « projeter une évolution que l'on connaît déjà ». La progression chronologique que dessine notre plan factoriel peut alors être considéré, pour partie, comme un artefact géométrique et non la preuve d'une évolution discursive que le corpus porterait intrinsèquement. En ce sens, les regroupements de vocabulaire identifiés constituent des hypothèses de lecture, formulées à partir d'une représentation qui a ses propres conventions de construction. Pour chercher des périodisations « propres au discours et non pas seulement à un contexte externe » (LAMASSÉ 2021), nous proposons un changement de regard méthodologique et analytique en recourant à la modélisation thématique par LDA.

Cartographier les sous-espaces du champ : topics, capitaux et orthodoxies

Si l'AFC nous renseigne sur les grandes oppositions structurantes entre les vocabulaires et suggère des pistes interprétatives sur le plan du lexique, elle ne permet pas d'accéder

aux concepts latents de notre corpus qui structurent les pratiques discursives autour de « barbare ». Là où l’AFC ordonne les vocabulaires selon des axes d’inertie, la *Latent Dirichlet Analysis* (LDA) (BLEI, NG et JORDAN 2003) repose sur une autre hypothèse, celle du *topic modelling* : les documents sont envisagés comme des mélanges de « topics » latents, eux-mêmes définis comme des distributions probabilistes de mots. Le regroupement lexical n’est dès lors plus pensé en termes d’opposition, mais de co-présence récurrente au sein des texte, selon une logique proche de l’isotopie, entendue comme répétition de motifs linguistiques. D’abord, un nombre de thèmes à identifier doit être choisi, puis les mots sont initialement assignés de manière aléatoire à ces thèmes ; ensuite, les probabilités d’appartenance à un thème sont ajustés de manière itérative, selon leur distribution dans les documents, jusqu’à stabilisation. Ainsi, la LDA permet d’approcher, par la probabilité, les structures thématiques susceptibles d’avoir présidé à la production des documents du corpus (en postulant que certains ensembles de mots tendent à apparaître conjointement parce qu’ils participent de mêmes structures discursives latentes). Toutefois, ces « concepts latents » ne sauraient être appréhendés comme des entités sémantiques substantielles : ils constituent des artefacts statistiques, dépendants des paramètres du modèle (au premier rang desquels le nombre de topics fixé *a priori*) et requièrent en ce sens une interprétation critique à l’image de celle que nous avons pu proposer pour l’Analyse Factorielle des Correspondances, section 4.5.2. La LDA répond à la question des sous-espaces thématiques du discours, et peut permettre de questionner la circulation, dans ces thèmes, du « barbare ». En ce sens, elle permet d’approcher les enjeux structurels autour desquels s’organise ce discours puisque ces *topics* peuvent être interprétés comme la manifestation de *l’illusio* du champ : la croyance collective, incorporée dans les pratiques d’écriture, que certains objets valent la peine d’être travaillés, que certains problèmes méritent d’être posés (DENORD, SAPIRO, DUVAL, HAUCHECORNE, HEILBRON, POUPEAU, SEILER, AMBROISE et al. 2020 ; BOURDIEU 1994).

La mise en œuvre de la LDA implique de fixer *a priori* le nombre de topics à identifier, paramètre dont dépend largement la qualité du modèle. Afin de ne pas imposer arbitrairement ce choix, nous avons procédé à un protocole exploratoire par *sweep*, en testant successivement des modèles entre 4 et 20 topics, puis en élargissant la fenêtre jusqu’à 25. Trois indicateurs ont guidé notre évaluation :

- la perplexité qui mesure la capacité du modèle à généraliser sur des données non vues : si le modèle a bien appris les structures thématiques du corpus, il ne devrait pas être « perplexe » face à de nouveaux documents abordant les mêmes thèmes. Un score trop proche de 0 signalerait en outre un risque de surentraînement (*overfitting*), où le modèle aurait appris les particularités du corpus d’entraînement de façon trop précise pour pouvoir en reconnaître d’autres.
- la cohérence globale et la cohérence des topics individuels, qui évalue dans quelle mesure les mots les plus probables d’un topic co-occurent effectivement dans le corpus : si un topic est bien construit, les mots qui le composent devraient se retrouver fréquemment ensemble RÖDER, BOTH et HINNEBURG 2015.
- l’interprétation que nous avons pu faire des topics en nous fondant sur les mots les plus représentatifs du topic

Nous avons appliqué les mêmes exclusions de fonctions morpho-syntaxiques et de tokens que pour l’AFC, auxquelles ont été ajoutés plusieurs tokens supplémentaires. Ces ajouts s’expliquent par une contrainte propre à la LDA : certains tokens, bien que peu fréquents à l’échelle du corpus, saturaient un topic au point de rendre celui-ci non interprétable. Ce phénomène n’était pas apparu lors de l’AFC, qui ne portait que sur les 500 lemmes les plus fréquents du corpus. La LDA, en travaillant sur un vocabulaire plus large, les a en revanche fait remonter comme contributeurs dominants de certains topics, nécessitant leur exclusion *a posteriori*¹²¹.

L’élargissement de la fenêtre d’exploration du nombre optimal de topic entendu par la mesure de la cohérence suggère un optimum instable, et la recherche du k a été itérée dans le but de choisir au mieux l’optimum (figure 7.24, page 386)

Si un optimum local se situe à 13 topics, la tendance de la courbe suggère qu’au delà de l’optimum de 18 topics, il semble qu’augmenter le nombre de topics puisse améliorer la cohérence. Toutefois, cette hausse apparente du nombre optimal se fait au détriment de la qualité du modèle : le score de perplexité produit par cet algorithme se dégrade (-12,9748 pour 13 topics et -13,8 pour 18 topics) et notre capacité interprétative se trouve davantage limitée. D’abord, il convient de souligner que l’écart entre $k = 13$ et $k = 18$ est relativement faible, 0,007 points, ce qui est à peser par rapport à notre capacité

121. À titre d’exemple, quelques artefacts linguistiques comme « der », « die » ou liés à l’OCR ou de la bibliographie comme « rrr », « - ».

à l'interpréter, car à $k = 18$, le cluster le plus important de $k = 13$ se trouve divisé en des configurations sous disciplinaires qu'il est difficile d'identifier (et notre capacité interprétative semble prépondérante CHANG et al. 2009)¹²².

Nous retenons donc le modèle avec 13 topics, dont les mots les plus caractéristiques sont fournis dans le tableau 4.8.

L'évaluation du modèle de LDA à 13 topics

La cohérence globale C_v atteint 0,4338, résultat optimal au regard de notre fenêtre de *sweep*^a. À l'échelle des topics individuels, les disparités sont notables : le topic 6 présente la cohérence la plus élevée (0,585), suivi du topic 1 (0,510) et du topic 4 (0,490), tandis que les topics 0, 7, 10 et 12 restent en deçà de 0,39, ce qui est cohérent avec la difficulté interprétative que rencontrée pour ces derniers. La log-perplexité (−12,97) s'éloigne de la plage optimale (−5 à −10), ce qui est attendu pour un corpus de textes académiques au vocabulaire spécialisé et dense : un score plus proche de 0 signalerait un risque de surentraînement. Enfin, la courbe de convergence confirme enfin la stabilisation du modèle au terme des itérations, le $\Delta\beta$ tendant vers 0 de manière monotone (figure 7.25, page 386).

^a. Des valeurs supérieures à 0,5 sont considérées comme bonnes, mais restent difficiles à atteindre sur ce genre de corpus.

TABLE 4.8 – Principaux mots des topics LDA avec probabilités associées

Topic	Principaux mots (probabilités)
Topic 0	<i>church</i> (0.0067), <i>note</i> (0.0052), <i>bishop</i> (0.0045), <i>huizinga</i> (0.0041), <i>century</i> (0.0036), <i>merovingian</i> (0.0036), <i>philostorgius</i> (0.0029), <i>temple</i> (0.0027), <i>witness</i> (0.0027), <i>language</i> (0.0026), <i>history</i> (0.0025), <i>council</i> (0.0024), <i>duke</i> (0.0022), <i>time</i> (0.0022), <i>law</i> (0.0021)

Suite page suivante

¹²². Je tiens à signaler que ma capacité interprétative est en grande partie dépendante l'ancrage historiographique, qui est nécessairement partiel et situé : un corpus de 35 000 références ne saurait être systématiquement recoupé avec l'ensemble de la littérature secondaire.

Table 4.8 – suite

Topic	Principaux mots (probabilités)
1	Topic <i>roman</i> (0.0081), <i>century</i> (0.0046), <i>empire</i> (0.0046), <i>rome</i> (0.0043), <i>king</i> (0.0039), <i>history</i> (0.0036), <i>barbarian</i> (0.0035), <i>emperor</i> (0.0034), <i>time</i> (0.0029), <i>army</i> (0.0027), <i>late</i> (0.0026), <i>imperial</i> (0.0026), <i>people</i> (0.0025), <i>bishop</i> (0.0024), <i>church</i> (0.0023)
2	Topic <i>jews</i> (0.0120), <i>jewish</i> (0.0064), <i>christian</i> (0.0044), <i>medieval</i> (0.0038), <i>century</i> (0.0030), <i>jew</i> (0.0029), <i>church</i> (0.0028), <i>jesus</i> (0.0026), <i>ende</i> (0.0026), <i>mary</i> (0.0025), <i>christ</i> (0.0024), <i>wind</i> (0.0023), <i>miracle</i> (0.0021), <i>legend</i> (0.0020), <i>version</i> (0.0020)
3	Topic <i>ware</i> (0.0060), <i>helen</i> (0.0036), <i>late</i> (0.0034), <i>century</i> (0.0033), <i>glaze</i> (0.0032), <i>coin</i> (0.0029), <i>god</i> (0.0029), <i>pottery</i> (0.0028), <i>lead</i> (0.0027), <i>fabric</i> (0.0026), <i>rime</i> (0.0025), <i>corinth</i> (0.0025), <i>glazed</i> (0.0023), <i>type</i> (0.0022), <i>chicken</i> (0.0021)
4	Topic <i>century</i> (0.0084), <i>period</i> (0.0066), <i>late</i> (0.0050), <i>medieval</i> (0.0048), <i>roman</i> (0.0045), <i>population</i> (0.0042), <i>archaeological</i> (0.0040), <i>settlement</i> (0.0039), <i>sample</i> (0.0037), <i>age</i> (0.0037), <i>datum</i> (0.0037), <i>individual</i> (0.0037), <i>analysis</i> (0.0036), <i>bo-rough</i> (0.0033), <i>study</i> (0.0032)
5	Topic <i>century</i> (0.0062), <i>mongol</i> (0.0050), <i>medieval</i> (0.0044), <i>history</i> (0.0040), <i>slavic</i> (0.0033), <i>mongols</i> (0.0033), <i>source</i> (0.0030), <i>islamic</i> (0.0030), <i>arabic</i> (0.0030), <i>russian</i> (0.0028), <i>study</i> (0.0027), <i>manuscript</i> (0.0026), <i>people</i> (0.0025), <i>europe</i> (0.0024), <i>permission</i> (0.0023)
6	Topic <i>lake</i> (0.0107), <i>temperature</i> (0.0038), <i>change</i> (0.0033), <i>vessel</i> (0.0031), <i>castle</i> (0.0030), <i>climate</i> (0.0029), <i>study</i> (0.0027), <i>base</i> (0.0026), <i>western</i> (0.0024), <i>century</i> (0.0023), <i>medieval</i> (0.0022), <i>basin</i> (0.0022), <i>sediment</i> (0.0021), <i>record</i> (0.0020), <i>stella</i> (0.0020)
7	Topic <i>century</i> (0.0066), <i>art</i> (0.0051), <i>medieval</i> (0.0040), <i>viking</i> (0.0032), <i>building</i> (0.0031), <i>roman</i> (0.0029), <i>time</i> (0.0026), <i>archaeology</i> (0.0025), <i>scotland</i> (0.0024), <i>form</i> (0.0024), <i>age</i> (0.0023), <i>image</i> (0.0022), <i>period</i> (0.0021), <i>history</i> (0.0021), <i>late</i> (0.0020)

Suite page suivante

Table 4.8 – suite

Topic	Principaux mots (probabilités)
8	<i>law</i> (0.0058), <i>woman</i> (0.0053), <i>slave</i> (0.0045), <i>century</i> (0.0043), <i>power</i> (0.0040), <i>political</i> (0.0037), <i>wife</i> (0.0036), <i>medieval</i> (0.0034), <i>people</i> (0.0031), <i>legal</i> (0.0028), <i>daughter</i> (0.0027), <i>religious</i> (0.0027), <i>war</i> (0.0026), <i>king</i> (0.0026), <i>society</i> (0.0025)
9	<i>english</i> (0.0046), <i>medieval</i> (0.0040), <i>irish</i> (0.0037), <i>century</i> (0.0035), <i>law</i> (0.0034), <i>history</i> (0.0029), <i>ireland</i> (0.0029), <i>england</i> (0.0028), <i>london</i> (0.0025), <i>king</i> (0.0021), <i>time</i> (0.0020), <i>people</i> (0.0019), <i>alldhelm</i> (0.0019), <i>slave</i> (0.0018), <i>town</i> (0.0018)
10	<i>medieval</i> (0.0048), <i>century</i> (0.0044), <i>english</i> (0.0041), <i>history</i> (0.0038), <i>god</i> (0.0034), <i>book</i> (0.0030), <i>christian</i> (0.0030), <i>latin</i> (0.0028), <i>write</i> (0.0027), <i>anglo</i> (0.0026), <i>manuscript</i> (0.0025), <i>word</i> (0.0024), <i>time</i> (0.0024), <i>tradition</i> (0.0022), <i>woman</i> (0.0022)
11	<i>sicily</i> (0.0076), <i>century</i> (0.0047), <i>palermo</i> (0.0036), <i>norman</i> (0.0035), <i>muslims</i> (0.0033), <i>neville</i> (0.0026), <i>muslim</i> (0.0023), <i>trade</i> (0.0021), <i>twelfth</i> (0.0019), <i>lead</i> (0.0019), <i>island</i> (0.0018), <i>remain</i> (0.0018), <i>christian</i> (0.0018), <i>mediterranean</i> (0.0018), <i>merchant</i> (0.0017)
12	<i>saga</i> (0.0076), <i>medieval</i> (0.0053), <i>king</i> (0.0041), <i>icelandic</i> (0.0037), <i>saxo</i> (0.0032), <i>history</i> (0.0028), <i>iceland</i> (0.0027), <i>author</i> (0.0025), <i>century</i> (0.0023), <i>report</i> (0.0022), <i>letter</i> (0.0020), <i>christian</i> (0.0020), <i>danish</i> (0.0020), <i>animal</i> (0.0019), <i>deer</i> (0.0019)

Tout d’abord, un constat s’impose avant interprétation : les topics ne sont pas parfaitement homogènes, ce qui est attendu dans un corpus de cet ordre, et articulent simultanément plusieurs niveaux de discours, à la fois des zones géographiques (Russie, Islande), des objets d’étude (les institutions religieuses), ou encore des méthodes d’approche des sources (archéologie, étude des sources écrites) non excluants. Pour en rendre compte, il convient d’interpréter ces topics au regard de leurs oppositions sur le plan factoriel ¹²³, en ce que la position relative des topics peut nous renseigner, en un sens, sur la structure thématique du champ et la répartition des capitaux disciplinaires légitimes pour parler

¹²³. Nous renvoyons le lecteur au fichier `ldavis_barbar.html` pour une lecture plus interactive des topics.

du « barbare ». Le premier, horizontal, discrimine principalement deux types de capitaux pour parler des « barbares » ; le second, vertical, discrimine les sous-espaces dominants des sous-espaces périphériques (ou, en termes de champ, ses centres et ses périphéries).

Les oppositions les plus structurantes du champ sont représentées par le premier facteur, qui sépare des capitaux disciplinaires spécifiques. À gauche du plan se concentrent les sous-espaces fondés sur la trace matérielle du « barbare » : l'archéogénomique, les Mongols et l'Eurasie, la culture matérielle viking, et, plus vers le centre, le topic barbare/Rome, et la céramologie. À droite du plan, on retrouve les topics liés aux institutions ecclésiastiques et médiévales, à la théologie judéo-chrétienne, aux sagas islandaises et le topic droit/genre. S'il est tentant de proposer une lecture dichotomique de ce premier facteur entre le matériel et le textuel, il convient de nuancer le propos en ce que le topic 1, portant principalement sur la relation entre les « barbares » et Rome, mobilise un vocabulaire lié aux sources textuelles. Dans cette optique, la gauche du plan factoriel regrouperait des topics évoquant le « barbare » comme des corps, des groupes, et des contacts (commerciaux ou militaires). Les topics sur la droite du plan permettent d'affiner cette lecture, en regroupant les institutions ecclésiastiques, la théologie judéo-chrétienne, les sagas islandaises et, dans une moindre mesure, le topic sur le droit et le genre : en somme, des approches mobilisant largement des sources littéraires, narratives ou théologiques ; suggérant une appréhension du « barbare » comme producteur de texte, de normes et d'institutions. L'opposition porte donc moins sur la nature documentaire des sources que sur le statut ontologique conféré à l'objet étudié : d'un côté, des entités ethniques et politiques et de l'autre, les questions de droit, d'institution et de religion.

C'est dans ce cadre que les topics de chaque pôle peuvent être interprétés. Du côté gauche, le topic4 (archéogénomique) est le plus clairement identifiable : *population* (0,0042), *individual* (0,00365), *sample* (0,00372), *datum* (0,0037), *burial* (0,00319), *archaeological* (0,00403) et *human* (0,00287) rappellent le vocabulaire de la bioarchéologie et de l'archéogénomique. Comme nous l'avons vu dans la section 4.5.2, ce vocabulaire se trouve en opposition structurelle avec les approches textuelles puisque la question des « barbares » et de leurs mouvements y est abordée par des restes biologiques, distinguant les capitaux nécessaires pour formuler une position dans ce thème de ceux liés à la philologie. De même, le topic 7 (Viking/art/bâti) partage cette appartenance au pôle gauche

avec les mots *art* (0,0051), *style*, *image* (0,0022), *form* (0,0024), *identity*, *architecture*, *stone*, *wall*, *culture* et *building* (0,0031), qui suggèrent un sous-espace considérant les traces esthétiques et architecturales de l'espace scandinave (*viking*, 0,0032)¹²⁴. Le topic 5 (Mongol/Eurasie) complète ce pôle gauche : *mongol* (0,005), *slavic* (0,00333), *russian* (0,00282), *tatars* (0,00224), *khan* (0,00214) et *arabic* (0,00296) composent une thématique cohérente sur les entités politiques à l'est de l'Europe. L'examen des cooccurents précise toutefois le capital mobilisé : *islamic* apparaît en collocation avec *manuscripts* et *works*, tandis qu'*arabic* renvoie à *persian*, *literature*, *poetry* et *source*, rappelant les caractéristiques textuelles du pôle droit, appliquées ici à des sources arabes et persanes. Sa proximité relative avec le topic archéogénomique laisse ouverte l'hypothèse que l'appréhension des migrations des « barbares » de l'Est se fonde, pour certaines publications, sur des données ostéologiques ou génétiques en plus des manuscrits ; ou, du moins, qu'il est présent en raison de son opposition aux topics portant sur la théologie ou les institutions ecclésiastiques. Enfin, le topic 3 (céramologie) s'inscrit dans une archéologie des objets : *ware* (0,00595), *pottery* (0,00278), *glaze* (0,00321), *coin* (0,00293), *fabric* (0,00257) et *sgraffito* (0,00184) évoquent la céramologie et la numismatique, probablement dans un contexte byzantin ou méditerranéen oriental, comme le suggère la présence de *corinth*¹²⁵. Ce topic présente par ailleurs le γ dominant moyen le plus bas du modèle (0,626), indiquant que le modèle hésite lors du classement et que ce sous-espace ne constitue pas un registre discursif aussi stabilisé que les autres¹²⁶. Le topic 1 occupe une position centrale sur l'axe 1 mais légèrement en retrait : il s'agit du seul topic où *barbarian* apparaît explicitement parmi les mots les plus probables (0,00352), aux côtés de *roman* (0,0081), *empire* (0,00457), *rome* (0,00431), *emperor*, *army*, *war*, *military*, *goths*, *ethnic* et *byzantine*. Nous pouvons poser l'hypothèse que ce topic constitue le lieu de la réflexion sur le « barbare » comme objet de discours, dans un cadre défini : la confrontation militaire et religieuse avec Rome, rendant le politique et le religieux inséparables. En ce sens, le topic 1 relève de la définition de l'orthodoxie du champ au sens bourdieusien (discours que le champ

124. Par ailleurs, au regard de sa position sur le plan factoriel, ce topic suggère presque que l'archéologie du bâti est un thème de transition, moins spécifique, entre le topic sur Rome et les « barbares » et celui sur l'archéogénomique

125. Corinthe était l'un des ateliers de fabrication de vaisselle de table glaçurée byzantine (BALARD et al. 2005 ; SANDERS 2000).

126. La présence difficile à interpréter de *helen* (sainte Hélène?), *nowa* (Nowa Huta?) et *chicken* renforce ce constat d'instabilité.

produit sur lui-même pour définir ce qui constitue un usage légitime du terme (DENORD, SAPIRO, DUVAL, HAUCHECORNE, HEILBRON, POUPEAU, SEILER, LORDON et al. 2020)) en concentrant les termes consacrés et leurs associations pour nommer les « barbares »¹²⁷. L’orthodoxie s’exerce alors à deux niveaux : sur le lexique légitime pour parler des « barbares », et sur la chronologie qui délimite ce qui peut légitimement être ainsi désigné. On peut y lire la manifestation d’un préconstruit au sens de Pêcheux (PAVEAU 2017) : une construction antérieure et extérieure à laquelle tout auteur du champ s’insère ou s’oppose, prolongeant nos observations sur l’appartenance de *barbarian* au facteur 4 de l’AFC (voir 4.5.2). De l’autre côté du plan factoriel, le topic 8 (droit et genre) rassemble un vocabulaire juridique et social : *law* (0,00578), *legal* (0,00282), *wife* (0,00361), *daughter* (0,00267), *husband* (0,00248) côtoient *woman* (0,0053), *slave* (0,00452), *power* (0,00404), *political* et *society*. Ces éléments suggèrent un sous-espace entre histoire du genre et histoire du droit médiéval, autour de questions proches des structures familiales et des rapports sociaux dans les codes législatifs. La présence de *war*, *king* et *political* semble rappeler que le droit n’y est pas dissocié du pouvoir militaire et royal, tandis que *christian* souligne les imbrications entre droit et religion, indissociable dans l’étude des lois barbares (DUMÉZIL et MARTIN 2025, p. 139). Plus à droite du plan factoriel, le topic 0 (institutions ecclésiastiques et laïques) semble en ce sens plus spécialisé que l’histoire sociale et juridique : centré sur *church* (0,0067), *bishop* (0,00447), *ecclesiastical* (0,00201), *council* (0,00245), dont les cooccurents renvoient aux conciles de Nicée et du Latran, il côtoie des figures laïques (*duke*, *king*) et la cour (*court*, dont les cooccurents principaux sont *royal*, *imperial*, *church* et *law*). Dès lors, nous pouvons poser l’hypothèse que si le droit et les structures de pouvoir laïc semblent participer du fond thématique commun du champ, les institutions ecclésiastiques et les figures d’autorités politiques en sont un sous-espace thématique plus spécialisé. Ces éléments font sens au regard de l’inégale christianisation des royaumes « barbares » (DUMÉZIL 2005), et donc du poids de ses institutions entendue comme cadre structurant des siècles ultérieurs ; pouvant être la source de la distance factorielle observée vis-à-vis du vocabulaire commun. Le topic 2 (théologie judéo-chrétienne), proche sur l’axe 1 du topic 0, s’en distingue en ce qu’il aborde des questions de théologie comparée, orienté sur l’altérité religieuse par rapport au christianisme, avec les mots *jews* (0,01205), *jewish*

127. Cette interprétation doit être nuancée : d’autres topics définissent aussi, à leur manière, les frontières du champ (les topics juridiques par les corpus normatifs, les topics archéologiques par les méthodes), mais de manière moins explicite sur le terme lui-même.

(0,00642), *jesus* (0,00257), *christ* (0,00244), *mary*, *miracle* et *legend*¹²⁸. Enfin, l’inertie du premier facteur est aussi liée au topic 12 (sagas islandaises), dessinant un sous-espace porté sur la philologie nordique : *saga* (0,00755), *icelandic* (0,00368), *author* (0,00250), *danish* et les enjeux de la conversion (*christian*, 0,00198 ; *conversion*, 0,00185) suggèrent une attention aux figures d’autorité (au sens d’atorat) et aux récits de christianisation, non sans rappeler le thème de certaines sagas, comme la *Kristni saga* (A. JAKOBSSON et S. JAKOBSSON 2017))¹²⁹. Au milieu de cet axe, la présence de deux topics suggèrent leur position de transition entre ces deux approches : la Sicile/Méditerranée (11) et l’Irlande/droit irlandais (9). Le premier articule un discours sur les espaces de contact entre Normands et Musulmans avec une archéologie des échanges commerciaux (*sicily*, *palermo*, *norman*, *muslims*, *trade*, *merchant*, et la présence de *pigment*, *lead* et *glaze* prolongeant le vocabulaire céramologique du topic 3). Le second, dont la lisibilité s’améliore avec un ajustement de la *relevance* à 0,68, peut être lu comme relevant du droit et des procédures judiciaires en Irlande ou dans le Pays de Galles (*jury*, *trial*, *ordeal*, *law*, *proof*), semble devoir sa position centrale à son intermédiarité entre législatif et sources plus matérielles, avec la mention, dans les mots également, de *smell* et *smellscape*, *contorniate*, ou encore la mention de « black death »¹³⁰.

Le facteur 2 semble quant à lui suggérer une opposition entre des vocabulaires dominants et ceux plus périphériques du champ. En effet, au Nord du plan factoriel, se concentrent les sous-espaces les plus dominants numériquement et thématiquement : le topic 10 comme fond commun textualiste (sur lequel nous allons revenir, avec 40% des documents), le topic « barbare »/Rome/Empire (9,5%), la question du droit (8%), celui des institutions ecclésiastiques (2,2%) – et, dans une moindre mesure, les topics d’archéogénomiques (8,3%), d’architecture du bâti Viking (8%) et du droit irlandais (5,8%). À l’inverse, au Sud du plan, nous trouvons des sous-espaces aux lexiques moins courants : la paléolimnologie (1%) et la céramologie (2%) et la théologie judéo-chrétienne (4,4%),

128. La présence de *buddhist* (0,0017), dont les cooccurrents renvoient aux monastères et à la Chine, demeure difficile à interpréter.

129. La présence de *deer* et *animal*, dont les cooccurrents donnent à voir des associations avec *eucharist*, *monastery*, *rite* et *baptism*, introduit une hétérogénéité qui suggère une réflexion possible sur le symbolisme religieux médiéval.

130. Les deux mots ne sont pas pris ensemble en tant qu’un seul dans la LDA, mais cette interprétation demeure cohérente au regard des cooccurrents.

ainsi que l'espace sicilien (3%) et mongol (6,6%). Une interprétation en termes de distance lexicale vis-à-vis du langage du champ expliquerait la relégation, tout au Sud de notre plan, des topics les plus spécialisés (paléolimnologie et céramologie), ou sur des espaces géographiques plus distants de Rome et ses « barbares ». Si l'on pourrait souligner le fait que la bioarchéologie a elle aussi des vocabulaires très particuliers, éloignés des approches philologiques du « barbare », il convient de noter que ces publications traitent particulièrement de la question des mouvements de population, des « migrations » ou des « invasions » de ces « barbares » sur Rome (voir le récent travail sur le sujet, BLÖCHER et al. 2026). Par conséquent, l'axe 2 du plan factoriel peut s'entendre comme la projection spatiale de capital symbolique au sein du champ : les topics les plus en haut correspondent aux approches les plus légitimées par la doxa du champ (entendue comme « forme de rapport au monde qui enferme un arrière-plan d'évidences à la fois omniprésentes et inaperçues, certitudes, jugements implicites, expectations » (DENORD, SAPIRO, DUVAL, HAUCHECORNE, HEILBRON, POUPEAU, SEILER, LORDON et al. 2020), soit la philologie, l'histoire de Rome, du droit ou des structures institutionnelles ; à l'inverse, les plus en bas occuperaient des positions périphériques du champ en raison de la mobilisation de capitaux scientifiques hétérodoxes au champ difficilement convertibles, ou encore avec un objet d'étude différencié (Mongol, Juifs) ¹³¹.

Tout en haut de cet axe, le topic 10 est le plus représentatif de ce centre du champ : il bénéficie de la probabilité moyenne la plus élevée du corpus (γ moyen = 0,368 ¹³²) et relève moins comme un sous-espace spécialisé que comme un socle commun diffus : la textualité y est centrale (*book, write, latin, manuscript, word, poem*), mêlée à un registre religieux (*god, christian, church*) et à des marqueurs d'ancrage culturel (*anglo, saxon*). Ainsi, il semble désigner une approche du « barbare » par les sources écrites dont les opérations de lecture, d'édition et d'interprétation constituent le capital d'entrée. À sa gauche, le topic 1 est le seul où *barbarian* apparaît explicitement parmi les mots les plus probables : son positionnement en haut du plan, en chevauchement partiel avec le topic 10, suggère que la réflexion sur le « barbare » et ses liens avec Rome participe du fond commun du champ (sans s'y réduire) : parler des « barbares » impliquerait, quelle que

131. Le cas du topic de bioarchéologie serait, selon cette interprétation, légitimé par son objet d'étude.

132. La probabilité γ exprime, pour chaque document, la proportion estimée de ses mots qui relèvent de ce topic. Une valeur moyenne de 0,368 signifie qu'en moyenne plus d'un tiers du vocabulaire de chaque document lui est associé, témoignant de sa prégnance.

soit la position disciplinaire ou thématique de l’auteur, de mobiliser ce cadre de référence. À la droite du topic 10, le topic droit/genre rassemble également un vocabulaire proche, chevauchant, suggérant que les sources normatives y sont abordées par les mêmes capitaux que les sources narratives ou littéraires. Enfin, le topic 0 (institutions ecclésiastiques et laïques) cette position dominante, plus à droite sur le plan, en ce que son vocabulaire, plus centré sur les évêques et les institutions religieuses le distingue en tant que sous-espace plus spécialisé. De l’autre côté du second facteur, le topic 6 occupe la position la plus en bas du plan, avec un technolecte particulier : *lake, temperature, climate, basin, chironomid, holocene, environmental* ; semblant désigner la paléolimnologie ; et une taille réduite, témoignant de sa marginalité dans notre champ. Ce sous-espace spécialisé peut s’interpréter comme une trace d’une rencontre, dans le champ, entre le Haut Moyen Âge et les sciences naturelles liées à l’environnement. Il en va de même pour le topic sur la céramologie (3), qui ne peut prétendre à bénéficier de la légitimité de son pendant en archéologie du bâti ou de la génétique. Le topic relatif à la théologie judéo-chrétienne (topic 2) demeure le plus difficile à considérer selon cette interprétation¹³³, en ce que sa faible représentation dans le corpus suggère que les approches théologiques du « barbare » restent relativement peu investies par la littérature académique récente, du moins dans les sources indexées, et sa position sur le plan factoriel pourrait signifier une excentricité partielle vis-à-vis des objets et lexiques dominants du champ.

De plus, il convient de constater, à l’aide de l’entropie normalisée¹³⁴ de 0,235, que les documents sont fortement associés à un seul topic, et, par conséquent, que les sous-espaces que nous avons précisés précédemment sont imperméables entre eux, suggérant que les capitaux disciplinaires nécessaires pour les occuper sont difficilement permutable. Si nous avons pu voir que les agents de notre champ ne publient en majorité qu’une seule publication, occupant de fait un seul de ces espaces, les auteurs publiant dans plusieurs de ces sous-espaces seraient des ponts entre ces espaces discursifs¹³⁵. L’indicateur γ do-

133. Dans le cadre de la présente recherche, la consultation de l’historiographie portant sur les juifs demeure un travail en cours.

134. L’entropie normalisée mesure le degré de dispersion d’un document entre plusieurs topics. Une valeur faible (proche de 0) signifie qu’un document est concentré sur un seul topic ; une valeur élevée (proche de 1) indique une répartition plus diffuse.

135. Si un auteur parvient à publier sur des sujets structurellement opposés, on peut supposer une forte *betweenness* dans le réseau de coautorat : Walter POHL, co-auteur de publications d’archéogénétique, en

minant moyen, de 0,745, signifie que 75% du contenu de chaque document est pris par un seul topic. Néanmoins, cette structuration n'est pas homogène : le topic 10 est central, avec 40.1% des documents dont il est le topic dominant (contre 7,7% attendus dans une répartition équilibrée à 13 topics), tandis que le topic 6 (1,1%) et le topic 3 (2.0%) apparaissent nettement sous-représentés ; entre ces extrêmes, les topics 1, 4, 7, 8 et 9 occupent des positions intermédiaires, chacun entre 5,8% et 9,5%. Le γ dominant moyen *par topic* précise cette observation : si le topic 10 présente un γ de 0,765, il est comparable à celui du topic archéogénomique (0,779) ou du topic barbare/Rome (0,766), ce qui suggère que, lorsqu'ils dominent, ces topics structurent le document avec une intensité similaire. À l'inverse, les topics 3 (0,626) et 12 (0,675) présentent des valeurs plus faibles, ce qui souligne une moindre stabilité dans leur structuration, et pourrait expliquer les difficultés interprétatives rencontrées les concernant.

Ces observations permettent de formuler un premier observable : le corpus n'est pas organisé autour d'une définition stable du « barbare », ce qui n'est pas sans rappeler la polysémie du terme « barbare » (section 1.1) Si l'on pouvait s'attendre à ce que notre corpus soit relativement homogène sur le plan thématique, ou moins dispersé qu'il ne l'est effectivement au regard de sa condition de constitution, la LDA suggère que cet objet historiographique est traversé par une pluralité de thèmes, d'approches et de méthodes qui ne dialoguent pas toujours sur le plan lexical, rendus ici visibles par le *distant reading*.

En ce sens, nous pouvons nous questionner quant à la chronologie des dynamiques du champ autour de ces approches : dans cette perspective, si l'AFC introduit la temporalité comme variable extrinsèque au lexique, il est possible de reprendre cette même interrogation par le biais de la LDA, selon un autre angle d'analyse. Il ne s'agit plus ici d'observer des mots dans le temps, mais des thèmes latents, leur distribution chronologique et leurs recompositions successives pouvant dès lors s'interpréter comme le résultats des luttes pour le monopole de la légitimité scientifique sur le « barbare »¹³⁶.

serait un cas emblématique, avec une *betweenness* de 0,009533, soit la sixième plus importante de notre réseau.

136. Si les proportions des thèmes dans les articles du corpus changent, cela ne signifie pas pour autant leur reconnaissance effective au sein du champ par les pairs, ce qui dépasserait le cadre de cette recherche et relèverait d'une analyse de la citation par exemple.




FIGURE 4.16 – Evolution de la proportion de documents ayant le topic comme topic dominant dans le temps

La distribution chronologique des topics permet d’observer comment se recomposent les capitaux dominants du champ, cette fois par le biais des thématiques. Un premier constat concerne deux mouvements opposés : la diminution de la part du topic 10, fond commun orienté vers la textualité, passant d’environ 45% des documents autour de 2015 à moins de 30% depuis 2020 (avec un minimum de 10% en 2022), et l’augmentation simultanée du topic 4, portant sur l’archéogénomique, avec, pour les deux, un point de rupture en 2020. Sans poser l’hypothèse d’une causalité, cette observation suggère que le renforcement des sciences naturelles, et en particulier la génétique, s’est faite en concurrence avec le sous-espace le plus dominant du champ, modifiant la structure thématique d’ensemble du corpus. Parmi les autres tendances observables, les topics sur les Mongols (topic 5) et les sagas (topic 12) connaissent une progression plus modeste depuis les années 2000, tandis que les topics sur le droit (topic 8), l’Irlande médiévale (topic 9) et la relation Rome-barbares (topic 1) semblent se stabiliser ou décliner légèrement. Les topics concernant la céramologie (topic 3), la paléolimnologie (topic 6) ou la Sicile (topic 11), moins importants sur le plan volumétrique, demeurent marginaux sur l’ensemble de la période, sans trajectoire d’expansion notable. Nous pouvons poser l’hypothèse que l’augmentation notable de l’archéogénomique au détriment du centre traditionnel du champ a été facilitée par la diminution, presque constante depuis 2007, du coût du séquençage de l’ADN humain (BAYLE et al. 2024, passant de 10M de dollars en 2008 à moins de 1000 dollars en 2019 (*The Cost of Sequencing a Human Genome* 2026) ; mais également par la récupération des premières données génomiques sur des restes humains anciens (*Massive ancient-DNA study reveals natural selection has accelerated in recent human evolution* 2026) en 2010¹³⁷. De plus, il s’agirait d’une sorte de retour paradoxal du paradigme biologique, contre lequel s’est construit ce champ (GRACEFFA 2009, par rapport à la « race » notamment), selon un autre régime de scientificité. En parallèle, la stabilité notable du topic 1 sur la définition du « barbare » semble suggérer que ces questions sont des acquis du champ, sédimentées au fil du temps et dont les débats sur la question sont moins récurrents. Ces observations invitent à une lecture en termes de recomposition du capital scientifique légitime au sein du champ : les nouveaux entrants, porteurs de capitaux disciplinaires issus des sciences du vivant ne peuvent bénéficier de légitimité d’emblée au coeur d’un espace structuré autour

137. Le temps de constitution des bases génétiques étant conséquent, il semble cohérent que les publications soient référencées plusieurs années après les évolutions techniques décrites ici.

de la philologie. Dès lors, l'augmentation de ce topic 4 depuis 2020 pourrait s'interpréter comme le résultat d'une lutte pour la conversion des capitaux issus des sciences naturelles vers des capitaux légitimes au sein du champ du Haut Moyen Âge.

Si les approches précédentes ont permis de dégager des structures lexicales et thématiques à l'échelle du corpus, elles reposent toutes sur une abstraction commune : le document y est traité comme une distribution de fréquences, indépendamment de l'ordre des mots. Le lemme « barbarian » lui-même, apparaît uniquement dans les mots les plus saillants du topic 1, mais dans un cadre tout autre de celui du sens commun (voir section 1.1) : la confrontation avec Rome et l'Empire. Ainsi, le glissement du lemme du langage ordinaire au langage du champ suggère une requalification au sein de ce cadre historique particulier, devenant à la fois un présupposé suffisamment stable pour les auteurs, mais également l'objet de luttes de définition qu'il n'est possible de cerner qu'à partir d'une approche reconstruisant la chaîne syntagmatique. En effet, les formes ne prennent de sens que dans le cadre d'une relation avec les autres formes, et il n'est pas possible de définir le sens d'une unité lexicale prise isolément (HARRIS 1952). L'analyse des cooccurrences constitue dès lors un retour au texte nécessaire : il s'agit de reconstituer l'environnement lexical immédiat de « barbar » pour en saisir les usages sémantiques effectifs.

4.5.3 Restituer le sens : analyse des cooccurrences de « barbar »

Comme le relève MARTINEZ, la statistique textuelle « trahit d'emblée la réalité textuelle dans ce qu'elle a de fondamental : sa séquentialité syntagmatique » MARTINEZ 2012 puisqu'en réduisant le texte à un dictionnaire de fréquences, elle rompt le lien qui fonde le sens¹³⁸. Si nous souhaitons nous pencher sur la question de la sémantique du « barbar » dans le champ, il convient de rétablir la chaîne pour réinscrire cet objet dans le cours du discours. En repérant les lemmes apparaissant ensemble dans une fenêtre contextuelle autour de la forme-pôle « barbare », nous proposons de « recompose[r] progressivement le texte dans sa dimension syntagmatique afin d'identifier les préférences combinatoires de

138. Par exemple, deux termes peuvent appartenir au même sous-espace thématique sans jamais se côtoyer dans le même texte, et deux documents peuvent partager le même profil lexical en mobilisant ces mots dans des configurations de sens différentes.

ses composantes » par l'analyse des cooccurrences. Ce déplacement méthodologique est aussi analytique, en ce qu'il permet d'aborder comment le « barbare » est mis en jeu et en sens par ses configurations avec d'autres lemmes au sein de l'espace possible du champ (ce qui est d'autant plus fondamental dans le cadre d'un terme aussi polysémique, comme expliqué en section 1.1).

Méthodologie

Avant tout, je tiens à remercier mon directeur de recherche, M. LAMASSÉ pour ce protocole d'analyse mobilisant, entre autres, des langages que je ne maîtrise pas (C++).

Une fenêtre de +40 tokens¹³⁹, et de multiples formes renvoyant au « barbare », comme « barbarians » ou « barbarians, », « barbarians. », nécessaire au regard de l'hétérogénéité de la qualité de nos données ont été retenus en tant que filtres pour le vocabulaire considéré.

Ensuite, un second filtre porte sur les fréquences et la qualité des données : il faut que le mot apparaisse au moins cinq fois dans l'ensemble du corpus, en excluant des catégories grammaticales et une liste de termes indésirables choisis *a priori*¹⁴⁰.

Pour mesurer la proximité entre les termes retenus et nos formes pôles, nous avons retenu la mesure de spécificité de Lafon (LAFON 1980) : pour chaque paire de lemmes (i, j) , elle évalue si leur cooccurrence observée k est significativement supérieure (attraction, score > 0) ou inférieure (répulsion, score < 0) à ce qu'elle serait à pour une distribution aléatoire¹⁴¹.

Le tableau ensuite utilisé pour produire une Analyse Factorielle des Correspondances compte, en ligne, les termes les plus spécifiques (positif et négatif) aux formes pôles retenues et les formes pôles, et, en colonne, seulement les termes les plus spécifiques aux

139. La fenêtre est unidirectionnelle : pour chaque token à la position t , les cooccurrences enregistrées sont celles avec les tokens aux positions $t + 1$ à $t + 40$ (ce qui est cohérent aussi au regard de la syntaxe anglaise, où l'adjectif est avant le nom (*barbarian kingdoms*) par exemple). L'analyse porte donc sur ce qui suit le terme-pôle dans le fil du discours ; les lemmes qui le précèdent sont capturés symétriquement lorsqu'ils apparaissent eux-mêmes comme pôles dans leurs propres vecteurs.

140. Résidus liés à l'OCR, métadonnées bibliographiques ou encore des termes multilingues.

141. Et, ensuite, seules les paires présentant au moins quatre cooccurrences brutes sont prises en compte ($k_{\min} = 4$), les valeurs extrêmes étant écrêtées à ± 100 .

formes pôles. De la sorte, il s'agit de visualiser les termes qui, parmi les co-occurents du « barbare », s'attirent ou s'opposent de manière significativement différente à l'indépendance (puisque chaque cellule compte les fréquences de co-occurrences)¹⁴².

Il convient toutefois de noter que notre analyse des cooccurrences aplatit la temporalité, rendant difficile toute observation de l'évolution de la sémantisation du « barbare ».


Analyse

L'AFC conduite sur cette matrice d'adjacence permet de projeter ces associations dans un espace factoriel où les oppositions entre cooccurents révèlent les dimensions sémantiques structurantes de « barbar » dans le corpus. En résumant les oppositions au sein de la matrice de cooccurrences, elle permet d'accéder aux formes concrètes par lesquelles les agents du champ, en combinant ce terme à certains lemmes plutôt qu'à d'autres, prennent position sur sa valeur et ses contours.

Les lemmes proches du centre de l'espace factoriel ont une signification analytique propre sur laquelle nous reviendrons, en ce qu'ils constituent le substrat commun de sémantisation du « barbare ». À l'inverse, les lemmes éloignés du centre, avec les contributions factorielles les plus importantes, structurent les oppositions dans les pratiques discursives. La proximité de deux lemmes sur le plan factoriel peut indiquer, au delà des effets liés à la projection, des profils de cooccurrence similaires par rapport aux termes pôles retenus (sans nécessairement partager la même fenêtre syntaxique).

La première structure d'opposition que l'AFC rend visible est celle du rapport à l'objet, d'une posture épistémologique, contribuant à 5,2% de l'inertie : d'un côté, un lexique porté sur l'historiographie du « barbare », et de l'autre, sur le récit historique du « barbare » ; et dans le même temps, oppose deux temporalités, celle contemporaine à celle du Haut Moyen Âge. Du côté positif de F1, les cooccurents de nos pôles semblent tournés vers les controverses religieuses et des institutions de l'Antiquité tardive (*arian* (0,09), *nicene* (0,07), *episcopus* (0,04), *presbyter* (0,009), *bishop* (0,05) et *bishops* (0,007), *sacerdote* (0,005), *sacerdo* (0,005)), des protagonistes liés à la christianisation des royaumes

142. Et, le tableau de contingence est réduit à 150 termes les plus attirés et 150 termes les plus repoussés par rapport aux formes pôles, filtrés donc à l'aide de l'indice de spécificité.



227

germaniques (*cyrila* (0,006), *leovigild* (0,004), *maximinus* (0,007))¹⁴³, des désignations des peuples (*goths* (0,01), *visigoths* (0,01), *vandal* (0,004), *huns* (0,006)) et des acteurs et événements qui structurent la période (*army* (0,008), *emperor* (0,01), *attila* (0,003)¹⁴⁴, *alaric* (0,002), *theodoric* (0,002)). En ce sens, ce côté de l'axe sémantise le « barbare » comme un objet de discours, mis au temps du récit et mobilisé dans le cadre de la fin de l'Antiquité entendue par les enjeux militaires et religieux.

De l'autre côté du premier facteur, nous constatons la présence d'un lexique plus contemporain, portant sur la réflexivité des historiens autour du concept. En effet, les lemmes les plus contributifs renvoient à la production même de l'historiographie, en suggérant des lieux (*london* (0,02), *york* (0,02)) et des dates de publications (*2005* (0,01), *2006* (0,007), *2007* (0,006), *2009* (0,006), *2011* (0,007), *2015* (0,005)), voire certains auteurs, comme (*pohl* (0,002), *walter* (0,002¹⁴⁵))¹⁴⁶. Ces termes rejoignent un vocabulaire plus méta sur le champ : *archaeology*, *modern*, *ages*, *culture*, *society*, *europe*, *identity*, *medievalism*, *transformation*, *ethnicity*). Parmi ces derniers, le regroupement de *identity*, *ethnicity* et *transformation* n'est pas sans rappeler le projet *Transformation of the Roman World* (ESF, 1993–1998), dont nous avons souligné le rôle de jalon historiographique dans la problématisation du « barbare » comme cadre de référence sur les pratiques discursives dans le champ¹⁴⁷. En somme, le « barbare » est ici sémantisé dans le cadre du débat histo-

143. *Cyrila* renvoie à un « patriarche Vandale » durant le règne de Huneric (477-484) (MATHISEN 1997 ; *leovigild* est un roi wisigoth arien ; *maximinus* désigne, pour partie l'évêque arien interlocuteur d'Augustin lors de la controverse de 427 (MATHISEN 1997). Leur présence conjointe suggère que le registre convoqué est celui de la conversion arienne des peuples germaniques.

144. Doù ici la double sémantisation de *maximinus*, qui désigne aussi le diplomate romain, ambassadeur auprès d'Attila.

145. Pouvant être Walter POHL ou Walter GOFFART en l'occurrence.

146. Plus loin, on constate aussi la présence de *wickham* (0,0012) en référence à Chris WICKHAM (médiéviste britannique ayant publié *Framing the Early Middle Ages* en 2005), *geary* (0,0011) pour Patrick GEARY (médiéviste américain, particulièrement connu pour *The Myths of Nations*, publié en 2002), *florin* (0,001 sur le F3) pour Florin CURTA (archéologue et professeur d'histoire médiévale américain, connu pour son approche particulière de l'ethnogénèse des Slaves en 2001 (*The Making of the Slavs*)), *brather* (0,0006 sur F1) pour Sebastian BRATHER (médiéviste et archéologue allemand, éditeur du *Germanische Altertumskunde Online*)

147. Il convient aussi de noter que ces auteurs ont écrit sur la question de l'identité « barbare ». Walter POHL est le fondateur de l'Ecole de Vienne, Gerda HEYDEMANN l'une de ses représentantes ; mais Patrick GEARY, Chris WICKHAM et Florin CURTA sont des interlocuteurs gravitant autour de la question de la construction et la définition des identités barbares, débat dont l'AFC des cooccurrences suggère

riographique, par les cooccurrences situées dans le texte, produisant à la fois un discours sur l'objet (le « barbare ») et sur la prise de position déclarée (positionnement vis-à-vis d'autrui).

La coprésence de ces noms de chercheurs, de ces dates et de ce vocabulaire métahistoriographique dans l'environnement contextuel de « barbare » invite à formuler l'hypothèse selon laquelle certains travaux et certains auteurs seraient devenus, dans la période récente, des références difficilement contournables pour qui souhaite prendre position sur le « barbare » dans le champ. Si l'analyse des données faite ici ne permet pas d'en préciser le contexte (légitimation, contestation, mention plus neutre), la fréquence de leur apparition à proximité de la forme pôle suggère que nommer le « barbare » et citer certains pairs sont, dans une part du corpus, des gestes liés dans la chaîne syntagmatique. Ainsi, ces mentions de travaux peuvent être pris comme des traces de citation en tant qu'« unités de capital symbolique potentiellement convertibles » dans l'espace académique (CRONIN 1998) ; ou encore « frontières contestées entre spécialités » au sein desquelles les auteurs « positionnent leurs affirmations de connaissance » (LEYDESDORFF 1998).

En poussant davantage la réflexion, nous pourrions poser l'hypothèse que certains travaux, auteurs, jalons historiographiques auraient acquis suffisamment d'autorité pour que leur mention devienne une condition de prise de parole légitime sur le « barbare » (PINTO 2020) : ils relèveraient alors des « citations de déférence obligée » : des « signes du droit d'entrée sur des territoires appropriés par des spécialistes », en vertu desquels « sur le sujet X, il faut évoquer l'article, le livre ou l'œuvre de Y » (PINTO 2020). De fait, la mention de ces références dans l'environnement textuel du « barbare » relèverait d'un *habitus* académique incorporé, réglant « la sélection et la hiérarchisation des textes et auteurs cités » en fonction de la position occupée dans l'espace scientifique (PINTO 2020) ¹⁴⁸.

L'opposition de ces mentions de l'historiographie avec le reste des lemmes pourrait s'expliquer par le fait que, lorsqu'un travail est cité, il est généralement cité avec d'autres travaux (LEYDESDORFF 1998, p. 8), saturant la fenêtre de cooccurrence. En ce sens, la variance prise par le F1 constitue une opposition entre deux pratiques de l'écriture en

qu'il constitue l'un des nœuds les plus actifs des pratiques citationnelles dans le corpus.

148. PINTO souligne par ailleurs que la non-citation d'un auteur tenu pour incontournable « peut être un acte de rébellion » (PINTO 2020) : nos données, en objectivant les noms les plus fréquemment associés à « barbar* », permettraient en ce sens d'identifier, en creux, les absences potentiellement significatives.

histoire, une où l'on parle du « barbare » et l'autre comme une prise de position explicite au sein du champ par rapport à ses pairs¹⁴⁹.

Le second facteur introduit quant à lui une opposition portant sur le registre du discours sur le « barbare », contribuant à 3.8% de l'inertie. Du côté positif de F2, nous retrouvons les lemmes qui structuraient l'opposition du facteur 1, cette fois-ci ensemble : lemmes du registre théologique et ecclésiastique (*arian* (0,12), *nicene* (0,11), *episcopus* (0,05), *presbyter* (0,012), *cyrila* (0,008), *sacerdo* (0,007), *arianism* (0,003), *cleric* (0,003), *salviani* (0,003), *avitus* (0,001), *maximinus* (0,006)) et ceux du méta-discours historiographique contemporain (*new* (0,02), *london* (0,02), *york* (0,01), *history* (0,01), *early* (0,01), *archaeology* (0,006), *ages* (0,007), *2006* (0,006), *2005* (0,008), *2011* (0,006), *antiquity* (0,003)). Du côté négatif se concentre un vocabulaire militaire, politique et administratif : *army* (0,01), *military* (0,009), *soldier* (0,006), *troop* (0,005), *raid* (0,005), *invasion* (0,002), *incursion* (0,004), *enemy* (0,004), *attack* (0,003), *defeat* (0,005), *victory* (0,003), *recruit* (0,002), mais aussi *emperor* (0,002), *territory* (0,002), *state* (0,002), *political* (0,001), *government* (0,001), *border* (0,003), *tribe* (0,007), auxquels s'ajoutent les lemmes géographiques et frontaliers déjà identifiés (*gates* (0,01), *caucasus* (0,009), *oikoumene* (0,005), *dariali* (0,003), *caspian* (0,003), *impermeability* (0,002), ces lemmes faisant référence à la Passe de Darial et aux Portes d'Alexandre, dans la région du Caucase)¹⁵⁰. Par conséquent, le facteur 2 semble opposer un registre religieux, entendant le « barbare » dans le cadre de sa religion ou de sa conversion, à un acteur militaire et politique (armée et administration du territoire).. Ainsi, ce facteur distingue deux sémantisations distinctes du « barbare » investies par les historiens : d'un côté, celui liée au concile de Nicée et à l'arianisme, au sens de l'altérité religieuse, et de l'autre, des « envahisseurs » sur le plan politique et militaire. En ce sens, on peut supposer que le champ construit l'objet « barbare » selon certes un fond commun, centré sur notre plan, mais aussi autour de ces définitions concurrentes, entre le rapport à l'Église et celui au territoire.

149. Explicite, car le discours constitue en tant que tel déjà une prise de position.

150. Si le tableau accorde des contributions plus importantes à ces derniers lemmes, il convient de nuancer leur prépondérance dans notre corpus en ce qu'ils sont largement portés par un unique document. En refaisant l'AFC avec ce document neutralité, le vocabulaire militaire et administratif ressort davantage : *people*, *army*, *state*, *military*, *territory*, *government*, *nation*, *law*, *legal*), ce qui renforce plutôt que ne contredit l'interprétation proposée.

Ces définitions concurrentes s'élargissent au delà de l'opposition résumée par le facteur 2, se rendant visible sur les facteurs 3 et 4.

Tout d'abord, un registre est visible portant sur un lexique intertextuel sur le facteur 3 : les textes tardo-antiques décrivant les « invasions barbares » des années 390–420. La coprésence de *hilberg* (0,006) (l'éditeur des *Epistulae* de Jérôme dans le *Corpus Scriptorum Ecclesiasticorum Latinorum*), des lemmes *epistulae* (0,005), *jer* (0,008) et *fabiola* (0,02)¹⁵¹, et des auteurs qui écrivent dans la même fenêtre temporelle : *claudian* (0,02)¹⁵² ainsi que *rufinus* (0,01)¹⁵³, *eutropius* (0,003)¹⁵⁴ et *synesius* (0,002)¹⁵⁵, *chron* (0,005) faisant référence aux *Chronica Gallica de 452*¹⁵⁶ suggèrent une tradition textuelle cohérente. Aussi, cette tradition textuelle se prolonge avec un retour sur les origines plus anciennes des « barbares » et la mention de *herodotus* (0,004) et *strabo* (0,002), suggérant par ailleurs une réflexion sur les origines du mot. Si l'on neutralise le document sur le Caucase, mentionné plus haut, nous retrouvons des contributions (sur une AFC sans le document donc) pour les actes de Paul (0,005 et les mentions de *28 :1-6* ou *28 :1-10* à 0.002)¹⁵⁷ ou encore *chrysostom* (0,06, Jean Chrysostome (344-407), archevêque de Constantinople et père de l'Eglise) *ambrose* (0.001, Ambroise de Milan (339-397) ou *eusebius* (0,0008, Eusèbe de Césarée (260-340), évêque en Judée) prolongeant cette question de la textualité. Ces lexiques suggèrent une sémantisation du « barbare » avec une référence proche aux sources primaires évoquant le « barbare ». En ce sens, ce côté de l'axe inscrit le « barbare » dans une tradition philologique, où sa définition relève d'une lecture des auteurs antiques lui conférant le sens : l'objet est sémantisé par l'autorité de la source ou leurs éditions critiques.

À l'opposé, sur le côté négatif du facteur 3 (et dans une moindre mesure sur le côté

151. *Fabiola* est la destinataire de la Lettre 77 de Jérôme, dans laquelle il décrit la fuite devant les invasions et mentionne les routes orientales d'irruption ; et c'est dans ce contexte que la Passe de Darial et les Portes caucasiennes sont évoquées.

152. Claudien (370-404), poète latin lié à la cour d'Honorius)

153. Faisant référence à *Contre Rufinus* de Claudien, poète latin associé à la cour d'Honorius et au général *stilicho* (0,003)

154. Politicien de l'Empire Romain d'Orient et eunuque de la cour, sur lequel a écrit Claudien dans *In Eutropium*

155. Probablement Synésios de Cyrène, évêque de Ptolémaïs, et auteur de *De Regno*

156. Chronique historique de l'Antiquité Tardive, éditée par Theodor MOMMSEN, qui serait une continuation de la Chronique de Jérôme.

157. Probablement en raison de la mention des « barbares » dans le texte.

positif du facteur 4), des termes faisant référence à la législation et à la politique administrative sont lisibles : *law* (0,03), *legal* (0,01), *term* (0,01), *ethnic* (0,004), *identity* (0,003), *principle* (0,009), *apply* (0,006), *political* (0,008), *land* (0,005), *act* (0,01), *state* (0,009), *nation* (0,003), *kingdom* (0,004), *vulgar* (0,002), *government* (0,002), *usage* (0,001), *iustitia* (0,001), ce qui n'est pas sans rappeler le sujet de l'ouvrage *Les lois barbares* (JOYE 2025b). En effet, si nous lisons ces termes à la lumière de l'historiographie des « lois barbares », nous pouvons constater la présence de l'historiographie du XIX^e siècle avec *nation*, *ethnic*, *identity* identifiée comme une quête de l'identité germanique commune aux barbares qui serait le moteur des études sur ces lois JOYE 2025b. La présence de *vulgar* peut aussi s'inscrire dans ce cadre¹⁵⁸ en ce qu'il renvoie au débat sur le droit romain « vulgaire », concept forgé par Heinrich BRUNNER et Ernst LEVY dans les années 1950 JOYE 2025b, aujourd'hui revu notamment parce qu'il supposait une opposition entre romanité et germanité. De même, *state* peut être rapporté à ce que JOYE signale comme un impensé persistant de l'historiographie du droit barbare : « l'idée à la fois d'une évolution qui se devrait d'aller vers le droit écrit et la notion d'État (centralisé) est souvent sous-entendue dans les études sur le droit barbare » JOYE 2025b. Enfin, les lemmes *legal*, *personality* (0,0001), *iustitia*, semblent faire référence au concept de personnalité des lois¹⁵⁹, ayant « polarisé les discussions au sujet de la pluralité des lois » (JOYE 2025b) : leur coprésence avec *code* (0,003), *legal* et *ethnic* semble alors cohérente. Ainsi, l'opposition observée sur le facteur 3 peut se lire comme la distinction entre des statuts distincts de « barbar » dans l'historiographie anglophone : d'un côté, le terme est l'objet du discours étudié, produit par les auteurs antiques portant un regard sur des peuples nommés comme tels ; de l'autre, le « barbare » est pris comme adjectif pour définir un corpus de textes juridiques (JOYE 2025b).

Enfin, le quatrième facteur (2,4% de l'inertie) affine cette lecture en suggérant une nuance supplémentaire dans les pratiques discursives autour de « barbar* », isolant une historiographie structurée par les événements militaires et leur datation précise. Le cluster lexical le plus saillant de ce facteur semble isoler un épisode précis : l'invasion d'Attila et la confrontation avec le pape Léon I^{er}. La coprésence de *attila* (0,0013), *prosper* (0,013), *leo* (0,012) et *chron* (0,017) peut faire ainsi référence à Prosper d'Aquitaine, dont la chronique

158. L'analyse des concordances suggère soit son association avec *Latin*, soit avec *Roman vulgar law*.

159. Régime juridique par lequel chaque individu est jugé selon la loi de son groupe d'appartenance.

constitue une source narrative sur ce sujet. La mention de *hydatius* (0,005) prolonge cette logique, ce dernier ayant lui aussi livré une chronique documentant les invasions de la même période, tandis que *451* (0,002) ancre l'ensemble dans la bataille des Champs Catalauniques. Plus largement, ce facteur signale une historiographie organisée autour de la datation elle-même : la présence de *fourth* (0,008), *fifth* (0,007), *sixth* (0,003) aux côtés de *451* suggère que le « barbare » y est défini aussi par son cadre chronologique, celui de la fin de l'Antiquité et du début du Haut Moyen Âge ; suggérant que la temporalité est, en un sens, déjà une sémantisation du « barbare ».

En plus des lemmes contributifs sur chacun des axes, il convient également de s'intéresser aux lemmes les moins contributifs, ou ceux les plus proches du barycentre du plan factoriel : un lemme faiblement contributif sur l'ensemble des axes est donc un lemme dont le profil de cooccurrence ne s'écarte pas significativement du profil marginal du corpus. Ainsi, ces lemmes sont présents dans des contextes d'occurrence de « barbar* » relativement indépendamment des autres lexiques, ne structurant aucune structure majeure d'opposition. Toutefois, leur faible contribution n'interdit pas une forte cofréquence avec nos formes pôles : en ce sens, se pencher sur les mots les moins contributifs mais qui ont les plus fortes cofréquences avec notre forme pôle permet d'analyser les termes que le champ investit systématiquement aux côtés du pivot, une sorte de substrat commun.¹⁶⁰

D'abord, au regard de sa fréquence de cooccurrence, le lemme le plus saillant est *paganism* (1483 cooccurrences, contribution sur 4 axes de 0,0002), qui n'est pas sans rappeler le vocabulaire religieux lié à l'arianisme et au concile de Nicée évoqué plus haut. En ce

160. Ces lemmes ont été identifiés par croisement de leur contribution et leur cofréquence. D'une part, leur contribution absolue cumulée sur les quatre axes factoriels a été calculée : les lemmes dont cette somme est inférieure au vingt-cinquième percentile de la distribution ont été retenus comme « peu contributifs », au sens où leur profil de cooccurrence ne s'écarte pas significativement du profil marginal du corpus. D'autre part, leur fréquence brute dans la fenêtre de cooccurrence de « barbar* » a été extraite de la matrice de cooccurrence, puis rapportée à leur fréquence d'occurrence dans le corpus lemmatisé complet, afin d'écarter les lemmes dont la faible spécificité s'explique par leur rareté. Les lemmes retenus pour l'analyse du substrat commun sont donc ceux qui cumulent une faible spécificité factorielle et une fréquence de cooccurrence avec « barbar* » suffisamment élevée pour ne pas relever du bruit : ils sont présents dans l'environnement du pivot de façon stable et transversale, sans être caractéristiques d'aucun registre discursif particulier. Entre parenthèses, est indiquée la fréquence de cooccurrence, puis la contribution cumulée sur les quatres axes.

sens, la conversion au christianisme (ou son absence) semble être une sémantisation commune du corpus : le « barbare » se définirait par son non-christianisme. La présence de *moslem* (199, 0,000187) et *crusaders* (218, 0,000097) dans cette liste pourrait indiquer que cette sémantisation ne se limite pas à l'Antiquité tardive et porte sur l'Islam. Ensuite, un ensemble de lemmes concerne la romanité comme miroir du « barbare » avec les lemmes *romanitas* (294, 0,000327), *romanness* (236, 0,000109) et *gallo* (collocation avec « roman », 337, 0,000056), auxquels s'ajoutent *lime* (le *limes*, 306, 0,000366), suggérant que le « barbare » est systématiquement défini en relation avec Rome, sur le plan géographique ou culturel ; en lien *raider* (263, 0,000362), qui semble renvoyer aux « raids barbares » envers l'Empire Romain.

De même, des noms propres renvoyant à des auteurs sont présents. *Wolfram* (556, 0,000231) et *amory* (407, 0,00039) apparaissent tous deux dans ce substrat commun : Herwig WOLFRAM, dont *History of the Goths* (1988) a popularisé le concept d'ethnogénèse et contribué à la reconnaissance de l'école de Vienne, et Patrick AMORY, dont *People and Identity in Ostrogothic Italy* (1997) conteste ce cadre interprétatif en montrant que l'ethnogénèse des ostrogoths ne repose sur aucun fondement ethnique stable. Leur co-présence dans ces lemmes fréquents mais peu contributifs suggère que la controverse sur l'ethnogénèse, opposant l'école de Vienne à ses critiques et matérialisée par ces travaux, constitue une référence partagée par l'ensemble du corpus. En ce sens, si les citations des travaux des années 2000 constituent des lemmes spécifiques dans notre plan factoriel, ils ne doivent pas occulter la citation partagée dans ces fenêtres cooccurentielles, des publications des années 1990, qui peuvent être interprétées comme des conditions d'entrée dans ce champ.

Enfin, les formes latines *barbari* (271, 0,00016) et *barbarorum* (202, 0,000298) se trouvent également dans ces lemmes fréquents, mais non spécifiques aux premiers axes. Si *barbari* renvoie vraisemblablement à des citations de sources primaires en latin, *barbarorum* apparaît en collocation avec *leges*, renvoyant à l'expression *Leges Barbarorum*, présupposant une unité artificielle entre des textes aux fonctions et aux contextes de rédaction très divers (JOYE 2025b). Leur présence transversale dans le substrat commun du corpus suggère alors que cette expression, malgré sa fragilité épistémologique reconnue, continue d'être mobilisée comme catégorie de référence partagée dans le champ, sans doute en tant qu'étiquette fonctionnant faute d'alternative (JOYE 2025b). De plus, ces

deux lemmes se distinguent de deux autres, lexicalement proches mais contributifs sur F3, *barbarism* (0,0009 sur F3) et *barbarous* (0,0009 sur F3), cette fois ci en anglais¹⁶¹. En ce sens, la différence entre les formes latines et les formes anglaises relève certes de la forme, mais aussi de la sémantisation, avec d’un côté une référence partagée et peu discriminante (le latin) et, de l’autre, une catégorie analytique¹⁶².

4.5.4 Ce que le lexique dit du champ

Plusieurs résultats convergents se dégagent sur les structures discursives entourant et sémantisant le « barbare ».

Le TF-IDF a d’abord révélé la pluralité des technolèctes gravitant autour du « barbare » : juridique, religieux, archéologique, littéraire. Cette coexistence de lexiques spécialisés suggère que le champ ne dispose pas d’un capital discursif unique pour appréhender son objet, et que les règles du jeu n’imposent pas, ou du moins pas encore une méthodologie exclusive.

Ensuite, l’AFC a permis de rendre compte des oppositions structurantes sur le plan lexical, avec une opposition temporelle, mais aussi méthodologique : d’un lexique philologique et juridique, caractéristique des périodes 1975–2005, vers un lexique archéogénomique, constitutif de la production 2021–2025. L’intervalle entre les deux souligne aussi des lexiques liés aux registre militaire et narratif, l’ethnicité et de l’identité, les espaces méditerranéens et normands.

La LDA a mis en évidence des structures du champ, que les sous-espaces thématiques

161. *Barbarism* apparaît systématiquement en collocation avec *civilization* : il désigne moins un peuple ou une pratique qu’un état opposé à la civilisation, inscrivant « barbar* » dans la dyade conceptuelle *barbarism/civilization* héritée de la pensée des Lumières et du XIX^e siècle. *Barbarous*, en revanche, se construit différemment : ses cooccurrents principaux sont *person*, *people*, puis *christian*, *latin* et *roman*, sans que *civilization* n’y apparaisse

162. Les lemmes *discover*, *finding*, *americans*, *italians*, *cruelty*, en raison de leur polysémie, sont particulièrement difficiles à interpréter. Si les premiers semblent renvoyer à un registre historiographique en lien avec les sources, la « cruauté » oscille entre un lien avec le lexique militaire et religieux (dans les passions notamment). Il en va de même pour le lemme *accommodation*, renvoyant à la fois au sens d’une tentative linguistique d’adaptation à son interlocuteur, il peut également s’agir du titre de l’ouvrage de Walter Goffart, *Barbarians and Romans, A.D. 418-584 : the techniques of accommodation* ; ou encore , *unification* (311, 0,00031) renvoyant à l’union des « peuples barbares » contre Rome, ou à l’unification Italienne au XIX^e siècle.

identifiés sont fortement imperméables. En ce sens, parler du « barbare » par l'archéogénomique ou par la philologie n'engage pas les mêmes formes de légitimité scientifique, et les agents qui publient dans plusieurs de ces espaces font sans doute figure d'exception structurelle. La LDA a également permis de confirmer et qualifier les déplacements lexicaux observés par l'AFC, en ce que la trajectoire temporelle des topics suggère une diminution du topic philologique pour une augmentation de l'archéogénomique, notamment depuis 2020. Loin d'être une rupture, les sous-espaces anciens demeurant présents, ces observations peuvent s'interpréter comme une reconfiguration des rapports de force au sein du champ, avec de nouvelles formes de discours légitimes pour parler des « barbares ».

L'analyse des cooccurrences a enfin restitué la chaîne syntagmatique que les trois approches précédentes avaient abstraite, et distingué au moins quatre sémantisations du terme dans le corpus : religieuse, militaire et politique, juridique, et historiographique. Surtout, l'analyse factorielle des cooccurrences a permis de mettre en évidence, davantage que nos autres approches, la relation étroite entre le « barbare » et Rome (*romanitas*, *limes*), avec le christianisme (arianisme, conversion), avec le droit romain (personnalité des lois). Il s'agit en ce sens des mises en sens légitimes du « barbare » au sein du champ.

Au-delà de ces sémantisations, l'analyse des cooccurrences a également rendu visible l'importance des pratiques citationnelles comme mode de prise de position dans le champ. La présence, dans l'environnement contextuel de « barbar* », de noms d'auteurs (POHL, WOLFRAM, WICKHAM, GEARY), de dates de publication récentes et d'un vocabulaire sur l'historiographie elle-même (*identity*, *ethnicity*, *transformation*) constitue une opposition structurante sur le premier facteur de l'AFC des cooccurrences : elle oppose un registre narratif, où l'on parle du « barbare », à un registre réflexif par rapport à ses pairs. Cependant, les auteurs mentionnés, et les lemmes associés, suggèrent que ce registre réflexif renvoie directement à l'école de Vienne et un interlocuteur critique, AMORY : le débat sur l'ethnogénèse serait alors, encore dans les publications récentes, un cadre structurant sémantisant le « barbare », sorte de préconstruit sur lequel tout auteur doit se positionner pour produire un propos dans le champ.

Conclusion de chapitre Dans ce chapitre, les analyses conduites ont permis de produire une image, nécessairement partielle, de la structure du sous-champ, en l'appréhendant à la fois par les métadonnées des publications, que par le corpus textuel. L'anglicisation progressive du champ, inégale selon les nationalités, est moins un fait textuel qu'un

indicateur de la valeur inégalement distribuée du capital linguistique et institutionnel pour légitimer la langue nationale : la persistance d'une production francophone contraste avec la conversion rapide des auteurs suédois, polonais et italiens. La composante connexe principale du réseau de co-autorat a dessiné un microcosme thématiquement sélectif, orienté vers les sciences naturelles au détriment des approches philologiques et institutionnelles dominantes dans le corpus global, et dont la composition temporelle signale que la re-composition en cours depuis les années 2000 est aussi une re-composition des conditions sociales de production du savoir. Enfin, l'analyse du corpus textuel a permis d'étudier la coexistence de plusieurs lexiques disciplinaires gravitant autour du « barbare », structurés par une opposition entre un registre narratif et un registre réflexif, et par le débat sur l'ethnogenèse comme préconstruit partagé et condition d'entrée du discours dans le champ.

Ces résultats permettent désormais de revenir à la question posée en introduction, et aux limites de notre enquête.

Chapitre 5

Conclusion

Ce mémoire de recherche a tenté d’objectiver la structure d’un sous-champ historiographique, à partir d’un corpus de publications portant sur les « barbares » du Haut Moyen Âge entre 1975 et 2025, à l’aide d’une approche combinant bibliométrie historique et lexicométrie. Il s’agissait d’essayer d’appréhender comment une communauté savante internationale a produit, distribué et structuré un savoir sur cet objet disputé, et de rendre visible la structure sociale qui sous-tend cette production. Par ce travail, j’ai cherché à interroger la transformation d’une écriture scientifique autour d’un objet, le « barbare » sur cinquante ans et ai tenté de voir quelque chose qui relève de la construction d’un champ, en tant que cadre d’intelligibilité de nos données, en postulant que les publications, leurs langues, les réseaux de co-autorat et les lexiques constituent des traces des positions et prises de position des agents au sein de cet espace.

5.1 Ce que l’enquête a montré.

L’analyse, dont nous avons détaillé le protocole, permet de proposer une première image de cet espace. D’abord, sur le plan linguistique, s’observe une anglicisation progressive du champ, au détriment des langues nationales. Cette dynamique n’est cependant pas uniforme, puisque la persistance d’une production francophone, interprétable comme l’effet d’instances de légitimation nationales suffisamment denses pour maintenir la valeur de la publication dans l’espace francophone, contraste avec la conversion beaucoup plus rapide vers l’anglais des auteurs suédois, polonais ou italiens. Plus qu’un attribut textuel des publications regroupées en corpus, la langue s’interprète comme capital linguistique dont la

valeur est inégalement distribuée selon les nationalités. Sa maîtrise conditionne, en outre, l'accès aux formes de co-autorat les plus denses.

En effet, sur le plan de la structure sociale, l'analyse du réseau biparti et de sa composante connexe principale a permis de mettre en évidence un microcosme au sein du sous-champ, avec ses propres règles. Sa composition thématique et sociale est distincte du corpus global : linguistiquement sélective en faveur de l'anglais, elle est aussi l'apanage des nationalités britanniques, américaines, polonaises ou suédoises (dont la production s'anglicise donc) et, surtout, elle est thématiquement orientée en faveur des sciences naturelles comme la bioarchéologie ou la paléoclimatologie, et au détriment des thématiques les plus représentées dans la base complète — religion et théologie, littérature et philologie, royaumes « barbares ». Ce sont moins les médiévistes les plus connus vis-à-vis de ma propre appréhension qualitative de l'historiographie (WOOD, POHL, GEARY) qui structurent la topologie du réseau, que des agents dont la position de pont permet de circuler entre les groupes : j'ai interprété cette capacité comme une forme de conversion de capital entre des sous-espaces qui ne communiqueraient pas autrement. Cependant, cette configuration n'est pas intemporelle : l'analyse longitudinale de la LCC a pu montrer qu'avant 1999-2000, cet espace était francophone et centré sur l'histoire du droit de l'Antiquité, signalant que la résémantisation éventuelle de l'objet « barbare » est aussi une reconfiguration des conditions sociales de sa production.

Enfin, sur le plan lexical, l'analyse du corpus textuel de 756 documents par distribution fréquentielle du vocabulaire et modélisation thématique a pu rendre visible la coexistence de plusieurs lexiques disciplinaires gravitant autour du « barbare » : un vocabulaire institutionnel et juridique, un vocabulaire religieux et hagiographique, un vocabulaire archéologique et matériel qui se recompose au fil du temps (des *fibula* et *buckle* des années 2000 aux *radiocarbon*, *ancestry* et *genetic* des années 2020), et un vocabulaire littéraire et philologique. Le voisinage lexical du « barbare », suggéré par l'analyse des co-occurrences, dessine des sémantisations concurrentes : acteur religieux de l'Antiquité tardive, envahisseur militaire, catégorie juridique, enjeu de positionnement historiographique ; qui peuvent s'interpréter comme des prises de position sur ce qu'est le Haut Moyen Âge comme espace disciplinaire. Le fait que WOLFRAM et AMORY apparaissent comme substrat commun à l'ensemble du corpus, indépendamment des clivages disciplinaires, invite à formuler l'hypothèse que la controverse sur l'ethnogénèse fonctionne comme une référence partagée,

condition d'entrée du discours sur les « barbares » plutôt que prise de position. La fréquence de leur apparition à proximité de la forme-pôle suggère que nommer le « barbare » et citer certains pairs sont, dans une part du corpus, des gestes liés.

5.2 Retour à la problématique : existe-t-il un champ du Haut Moyen Âge ?

L'espace historiographique décrit par la présente recherche a des traits proches de l'hypothèse d'un sous-champ en cours de cristallisation : des instances de légitimation propres (revues spécialisées, chaires dédiées, projets de grande envergure comme *HistoGenes* ou *The Transformation of the Roman World*), une structure sociale différenciée avec des positions inégalement distribuées, des auteurs devenus centraux dans le discours autour d'un objet, le « barbare », dont la définition est elle-même un enjeu de lutte. Toutefois, les frontières de ce sous-champ demeurent poreuses, comme nous avons pu le voir avec l'entrée massive des sciences naturelles, reconfigurant les règles du jeu. Et, c'est peut être parce que le « barbare » est un objet dont la définition reste disputée (sur le plan de l'identité, de la migration, de l'origine) que la génomique, l'archéologie outillée de l'analyse isotopique et la paléoclimatologie y trouvent une prise. En ce sens, la composition de la composante connexe principale du réseau de co-autorat pourrait être entendue comme une trace des enjeux du Haut Moyen Âge comme espace disciplinaire, champ dont l'objet central reste suffisamment ouvert pour attirer des disciplines qui, par leurs propres méthodes, peuvent tenter de le circonscrire.

5.3 Portée, limites et perspectives.

La principale limite de notre travail porte sur la source, en ce que notre unique lieu de références bibliographiques a été Worldcat et, bien que choisi pour son ouverture et sa meilleure représentation des sciences humaines et sociales par rapport à d'autres bases de données bibliographiques, il représente surtout les institutions volontaires et anglophones, et fournit une donnée appauvrie, imposant un protocole de redocumentarisation dont les résultats demeurent partiels.

Plus fondamentalement, la recherche est prise elle-même dans une partie du champ

qu'elle observe, en ce qu'elle a été conduite depuis une université française, par moi-même, une étudiante formée en histoire, et les choix l'orientant (l'entrée par le mot, la fenêtre chronologique, les analyses proposées) sont aussi des effets de position.

J'ai, tout au long de ma rédaction, tenté de rendre compte des limites des propositions avancées, sur le plan méthodologique et analytique. Pour le traitement, le réseau de co-autorat ne capte qu'une dimension de la structure sociale du champ, réduite, et l'analyse des co-occurrences ne permet pas encore d'observer la temporalité de la sémantisation du « barbare ». Sur le plan interprétatif enfin, nos résultats décrivent des régularités, mais ne permettent pas de trancher si elles sont propres au Haut Moyen Âge, ou communes à la médiévisque, ce que seule une comparaison systématique avec d'autres corpus pourrait permettre de confirmer.

Ces limites permettent de proposer des angles d'approches pour de futures recherches. La construction d'un réseau de citations à partir des références bibliographiques, pour partie réalisable à partir des données présentées, permettrait de croiser la sémantique textuelle et la topologie sociale pour permettre, peut-être, un autre regard sur le champ. La question du genre, laissée de côté pour la présente rédaction mais abordée au cours de la recherche, mérite sans doute qu'on s'y attarde davantage, afin de tenter de percevoir la nature des dynamiques genrées au sein du champ. Enfin, une extension du corpus à d'autres sources bibliographiques moins biaisées vers l'anglophone permettrait de tester si les régularités observées ici sont propres à WorldCat ou reflètent une structure de l'espace scientifique.

Avant tout, cette recherche est une expérience méthodologique, en tant qu'historienne à l'heure du numérique. Il s'agit d'une tentative, depuis ma position d'étudiante en première année de Master, de construire un objet historique appréhendé par la bibliométrie, à partir de sources hétérogènes, et en tirer quelque chose qui peut informer la structure d'un champ scientifique. J'ai posé en introduction que l'enjeu n'était pas de raconter l'histoire des « barbares », ni l'histoire de leur histoire : c'est, je l'espère, ce que ce travail a fait, en tentant de décrire comment une communauté savante a produit et disputé un savoir, en laissant les traces de ces disputes visibles dans les données permettant de cartographier un espace.

À sa manière, ce travail a essayé de contribuer aux quelques publications mobilisant

la bibliométrie historique, en montrant qu'il est possible d'adopter cette démarche pour observer et cartographier des logiques d'écriture de la science historique, avec un protocole qui s'est voulu reproductible avec d'autres vocables.

Chapitre 6

Bibliographie

6.1 Ouvrages

- AMORY, Patrick (juin 1997). *People and Identity in Ostrogothic Italy, 489–554*. 1^{re} éd. Cambridge University Press. DOI : 10.1017/CB09780511523069. (Visité le 25/10/2025).
- ANDERSON, Benedict (1983). *Imagined communities reflections on the origin and spread of nationalism*. London : Verso, 160 p.
- BALARD, M. et al. (2005). *Byzance et le monde extérieur : Contacts, relations, échanges*. Éditions de la Sorbonne. DOI : 10.4000/books.psorbonne.1829.
- BELIN, éd. (2011). *Revue d'histoire moderne et contemporaine supplément 2011-4bis. Le métier d'historien à l'ère numérique : nouveaux outils, nouvelle épistémologie ?* T. n° 58-4bis. 5.
- BENZÉCRI, Jean-Paul et al. (1973). *L'analyse des données. Tome 2 : L'analyse des correspondances : introduction, théorie, applications diverses, notamment à l'analyse des questionnaires, programmes de calcul*. Sous la dir. de Jean-Paul BENZÉCRI. Paris, Bruxelles et Montréal : Dunod, p. VI-619.
- BLOCH, Marc (1949). *Apologie pour l'histoire ou Métier d'historien [Suivi de Comment se présentaient les manuscrits de métier d'historien]*. Cahiers des annales 3. Paris : Librairie Armand Colin, 1 volume (XVII-110 pages).
- BOURDIEU, Pierre (1979). *La distinction critique sociale du jugement*. Le sens commun. [Paris] : Les Éditions de minuit, 1 volume (VIII-670 pages).
- (1982). *Ce que parler veut dire l'économie des échanges linguistiques*. [Paris] : Fayard.

- BOURDIEU, Pierre (1984). *Homo academicus*. Le sens commun. Paris : les Éditions de Minuit, 1 vol. (302 p.)
- (1994). *Raisons pratiques sur la théorie de l'action*. Paris : Éditions du Seuil, 1 vol. (251 p.)
- (2001). *Science de la science et réflexivité : cours du Collège de France (2000–2001)*. Cours et travaux. Paris : Raisons d'agir, p. 237.
- BRUBAKER, L. et J.M.H. SMITH (2004). *Gender in the Early Medieval World : East and West, 300-900*. Gender in the Early Medieval World : East and West, 300-900. Cambridge University Press.
- COUMERT, Magali et Bruno DUMÉZIL (2020). *Les Royaumes barbares en Occident*. T. 5e éd. Que sais-je ? Presses Universitaires de France.
- DELON, Michel (2007). *Dictionnaire européen des Lumières*. Paris : PUF.
- DENORD, François, Gisèle SAPIRO, Julien DUVAL, Mathieu HAUCHECORNE, Johan HEILBRON, Franck POUPEAU, Hélène SEILER, Frédéric LORDON et al. (nov. 2020). *Dictionnaire international Bourdieu*. CNRS Éditions, p. 99-220.
- DOSSE, François (1987). *L'Histoire en miettes : des "Annales" à la "nouvelle histoire"*. Armillaire. Paris : la Découverte.
- DUBOIS, Jean (1962). *Le vocabulaire politique et social en France de 1869 à 1872 à travers les oeuvres des écrivains, les revues et les journaux*. Larousse, 1 vol. (XXIX-460 p.)
- DUMÉZIL, Bruno (2005). *Les racines chrétiennes de l'Europe : Conversion et liberté dans les royaumes barbares Ve - VIIIe siècle*. Nouvelles Etudes Historiques. Fayard.
- (2020). *Les Barbares*. Quadrige. Presses Universitaires de France. DOI : 10.3917/puf.dumez.2020.02.
- FARGE, Arlette (1989). *Le goût de l'archive*. La Librairie du XXe siècle. [Paris] : Éditions du Seuil, 1 vol. (152 p.)
- GARFIELD, Eugene et Robert King MERTON (1979). *Citation indexing : its theory and application in science, technology, and humanities*. Information sciences series. New York Chichester Brisbane Torotno : John Wiley & Sons.
- GEARY, P.J. (2003). *The Myth of Nations : The Medieval Origins of Europe*. Medieval Origins of Europe. Princeton University Press.
- GEARY, Patrick J. (2024). *Comment la génétique réécrit l'histoire du Moyen Âge*. Paris : CNRS Éditions, p. 175.

- GEIGER, Roger L. (sept. 2017). *Research and Relevant Knowledge : American Research Universities Since World War II*. New York : Routledge. DOI : 10.4324/9781315128481.
- GILLET, Andrew, éd. (jan. 2002). *On Barbarian Identity : Critical Approaches to Ethnicity in the Early Middle Ages*. T. 4. Studies in the Early Middle Ages. Turnhout, Belgium : Brepols Publishers. DOI : 10.1484/M.SEM-EB.6.09070802050003050101060809. (Visité le 04/10/2025).
- GINGRAS, Yves (2014). *Les dérives de l'évaluation de la recherche : du bon usage de la bibliométrie*. Paris : Raisons d'agir éditions, p. 122.
- GOFFART, Walter (2006). *Barbarian tides : the migration age and the later Roman Empire*. The Middle Ages series. Philadelphia (Pa.) : Penn.
- GRACEFFA, Agnès (jan. 2009). *Les historiens et la question franque : Le peuplement franc et les Mérovingiens dans l'historiographie française et allemande des XIXe-XXe siècles*. T. 8. Haut Moyen Âge. Turnhout, Belgium : Brepols Publishers. DOI : 10.1484/M.HAMA-EB.5.106055. (Visité le 25/03/2026).
- HALSALL, Guy (déc. 2007). *Barbarian Migrations and the Roman West, 376–568*. 1^{re} éd. Cambridge University Press. DOI : 10.1017/CB09780511802393. (Visité le 20/10/2025).
- HAMMARFELT, Björn (2012). *Following the footnotes : a bibliometric analysis of citation patterns in literary studies*. Uppsala : Inst. för ABM vid Uppsala universitet.
- HEATHER, Peter (2010). *Empires and Barbarians : the Fall of Rome and the Birth of Europe*. Melbourne : Oxford University Press, USA.
- HOBBSAWM, Eric John (1990). *Nations and nationalism since 1780 programme, myth, reality*. The Wiles lectures given at the Queen's university of Belfast 1985. Cambridge : Cambridge University Press, 1 vol. (VIII-191 p.)
- IGGERS, Georg (sept. 2016). *A Global History of Modern Historiography*. 2^e éd. Second edition. | New York, NY : Routledge, [2016] : Routledge. DOI : 10.4324/9781315543499. (Visité le 20/02/2026).
- JAKOBSSON, Armann et Sverrir JAKOBSSON (2017). *The Routledge Research Companion to the Medieval Icelandic Sagas*. Routledge. DOI : 10.4324/9781315613628.
- LARIVIÈRE, Vincent et Cassidy R. SUGIMOTO (2018). *Mesurer la science*. Montréal : Les Presses de l'Université de Montréal. DOI : 10.1515/9782760639522.

- LATOUR, Bruno, Steve WOOLGAR et Jonas Préfacier SALK (1979). *Laboratory life : the social construction of scientific facts*. Beverly Hills, Etats-Unis d'Amérique, Royaume-Uni de Grande-Bretagne et d'Irlande du Nord.
- LE GOFF, Jacques (1988). *La Nouvelle histoire*. Bruxelles : Editions Complexe. (Visité le 01/04/2026).
- LÉVI-STRAUSS, Claude (1987). *Race et histoire*. Collection Folio 58. Paris : Gallimard.
- MACFARLANE, Bruce et al. (oct. 2017). *Co-authorship in Humanities and the Social Sciences : A global view*. English. United Kingdom : Taylor & Francis Group.
- MAZEL, Florian (oct. 2021). *Nouvelle Histoire du Moyen Âge* : Le Seuil. DOI : 10.3917/ls.mazel.2021.01. (Visité le 04/10/2025).
- MORETTI, Franco (2007). *Graphs, maps, trees : abstract models for literary history*. Paperback edition. London New York : Verso.
- (2013). *Distant reading*. London : Verso.
- NOIRIEL, Gérard (1996). *Sur la crise de l'histoire*. Socio-histoires. Paris : Belin.
- OFFENSTADT, Nicolas (2017). *L'historiographie*. Que sais-je ? Paris : Presses universitaires de France.
- POHL, Walter et Helmut REIMITZ, éd. (août 2023). *Strategies of Distinction : The Construction of Ethnic Communities, 300-800*. Brill. (Visité le 11/10/2025).
- POL-DROIT, Roger (oct. 2007). *Généalogie des barbares* : Odile Jacob. DOI : 10.3917/oj.droit.2007.01. (Visité le 04/10/2025).
- PRICE, Derek J. de Solla (1963). *Little science, big science*. New York : Columbia University Press. (Visité le 04/10/2025).
- ROSTAING, Hervé (1996). *La bibliométrie et ses techniques*. Outils et méthodes. Sciences de la Société. (Visité le 04/10/2025).
- SAVIĆ, Miloš, Mirjana IVANOVIĆ et Lakhmi C. JAIN (2019). *Complex Networks in Software, Knowledge, and Social Systems*. T. 148. Intelligent Systems Reference Library. Cham : Springer International Publishing. DOI : 10.1007/978-3-319-91196-0. (Visité le 05/03/2026).
- TODOROV, T. (2008). *La peur des barbares : au-delà du choc des civilisations*. R. Laffont.
- WEBER, Florence (2010). *Guide de l'enquête de terrain produire et analyser des données ethnographiques*. 4e édition augmentée. Grands Repères. Paris : La Découverte, 1 volume (334 pages).

- WENSKUS, Reinhard (1977). *Stammesbildung und Verfassung : das Werden der frühmittelalterlichen gentes*. ger. 2., unveränd. Aufl. Köln : Böhlau.
- WOLFRAM, Herwig (1987). *History of the Goths*. Berkeley : Univ. of California Pr.

6.2 Articles de revues

- AHMED, Majid Hameed et al. (déc. 2022). « Short Text Clustering Algorithms, Application and Challenges : A Survey ». In : *Applied Sciences* 13.1, p. 342. DOI : 10.3390/app13010342. (Visité le 28/02/2026).
- ALEIXANDRE-BENAVENT, Rafael, Vicent MONTALT-RESURECCIÓ et Juan Carlos VALDERRAMA-ZURIÁN (oct. 2014). « A descriptive study of inaccuracy in article titles on bibliometrics published in biomedical journals ». In : *Scientometrics* 101.1, p. 781-791. DOI : 10.1007/s11192-014-1296-5. (Visité le 23/02/2026).
- ALTBACH, Philip G. et Roger GEIGER (2024). « Higher Education in the US and Abroad : Historical and Contemporary Perspectives ». In : *History of Education Quarterly* 64.4, p. 538-549. DOI : 10.1017/heq.2024.37.
- ANDERSEN, Jens Peter (mai 2023). « Field-level differences in paper and author characteristics across all fields of science in Web of Science, 2000–2020 ». In : *Quantitative Science Studies* 4.2, p. 394-422. DOI : 10.1162/qss_a_00246.
- ARBELAITZ, Olatz et al. (2013). « An extensive comparative study of cluster validity indices ». In : *Pattern Recognition* 46.1, p. 243-256. DOI : <https://doi.org/10.1016/j.patcog.2012.07.021>.
- « Articles en langues étrangères dans les Cahiers de civilisation médiévale » (2026). In : p. 7-8. DOI : 10.3917/ccm.273.0007.
- BARABASI, Albert-Laszlo et Reka ALBERT (oct. 1999). « Emergence of scaling in random networks ». In : *Science* 286.5439, p. 509-512. DOI : 10.1126/science.286.5439.509. (Visité le 15/05/2026).
- BAYLE, Arnaud et al. (2024). « Coût des technologies de séquençage haut débit (NGS) : revue de la littérature et enseignements ». In : *Bulletin du Cancer* 111.2, p. 190-198. DOI : <https://doi.org/10.1016/j.bulcan.2023.08.013>.
- BLEI, David M., Andrew Y. NG et Michael I. JORDAN (mars 2003). « Latent dirichlet allocation ». In : *J. Mach. Learn. Res.* 3, p. 993-1022.

- BLÖCHER, Jens et al. (avr. 2026). « Demography and life histories across the Roman frontier in Germany 400–700 ce ». In : *Nature*. DOI : 10.1038/s41586-026-10437-3.
- BOURDIEU, Pierre (1976). « Le champ scientifique ». In : *Actes de la recherche en sciences sociales* 2.2, p. 88-104. DOI : 10.3406/arss.1976.3454. (Visité le 14/01/2026).
- (1977). « L'économie des échanges linguistiques ». In : *Langue française* 34.1, p. 17-34. DOI : 10.3406/lfr.1977.4815.
- (1995). « Sur les rapports entre la sociologie et l'histoire en Allemagne et en France ». In : *Actes de la Recherche en Sciences Sociales* 106.1, p. 108-122. DOI : 10.3406/arss.1995.3141.
- BOURE, Robert (1993). « Sociologie des revues de sciences sociales et humaines ». In : *Réseaux. Communication - Technologie - Société* 11.58, p. 91-105. DOI : 10.3406/reso.1993.2306. (Visité le 30/05/2026).
- CHAPPEY, Jean-Luc, Pierre SERNA et Camille NOÛS (oct. 2020). « L'invention du Barbare sauvage et du Sauvage barbare : un coup d'état sémantique contre la Révolution : » in : *Dix-huitième siècle* n° 52.1, p. 199-219. DOI : 10.3917/dhs.052.0199. (Visité le 04/10/2025).
- CHEN, Shuzhen, Kun DAI et Alan Chi Keung CHEUNG (mars 2026). « Surviving publication pressure collaboratively ? Peer co-authorship habitus and capital formation among Chinese doctoral students in humanities and social sciences ». In : *Higher Education*. DOI : 10.1007/s10734-025-01615-9. (Visité le 11/05/2026).
- COCHRAN, William G. (1954). « Some Methods for Strengthening the Common chi2 Tests ». In : *Biometrics* 10.4, p. 417-451. (Visité le 29/04/2026).
- COLAVIZZA, Giovanni (2018). « Understanding the History of the Humanities from a Bibliometric Perspective : Expansion, Conjunctures, and Traditions in the Last Decades of Venetian Historiography (1950–2013) ». In : *History of Humanities* 3.2, p. 377-406. DOI : 10.1086/699300.
- CRONIN, Blaise (1998). « Metatheorizing citation ». In : *Scientometrics* 43.1, p. 45-55. DOI : 10.1007/BF02458393.
- DE NOOY, Wouter (2003). « Fields and networks : correspondence analysis and social network analysis in the framework of field theory ». In : *Poetics* 31.5, p. 305-327. DOI : [https://doi.org/10.1016/S0304-422X\(03\)00035-4](https://doi.org/10.1016/S0304-422X(03)00035-4).

- DONTHU, Naveen et al. (sept. 2021). « How to conduct a bibliometric analysis : An overview and guidelines ». In : *Journal of Business Research* 133, p. 285-296. DOI : 10.1016/j.jbusres.2021.04.070. (Visité le 07/10/2025).
- DROUIN-HANS, Anne-Marie (1988). « Le modèle en questions ». In : *Aster : Recherches en didactique des sciences expérimentales* 7.1, p. 1-20. DOI : 10.4267/2042/9214.
- FRANCISCO, Ian Roger Mabazza, Kristinne Joyce A LARA et Patrianne M PADUA (2023). « To use or not to use Wiki : Gen Z* Perception, Motivational Factors, and Use of the People's Encyclopedia in Course-Related ». In : *Journal for ReAttach Therapy and Developmental Diversities*.
- GASKÓ, Noémi, Rodica Ioana LUNG et Mihai Alexandru SUCIU (août 2016). « A new network model for the study of scientific collaborations : Romanian computer science and mathematics co-authorship networks ». In : *Scientometrics* 108.2, p. 613-632. DOI : 10.1007/s11192-016-1968-4. (Visité le 05/03/2026).
- GATES, Alexander J. et al. (nov. 2019). « Nature's reach : narrow work has broad impact ». In : *Nature* 575.7781, p. 32-34. DOI : 10.1038/d41586-019-03308-7. (Visité le 04/10/2025).
- GEARY, Patrick J. (2025). « Integrating Natural Scientific Methodologies into Medieval History ». In : *Journal of Medieval History* 51.4, p. 557-560. DOI : 10.1080/03044181.2025.2519763.
- GILLETT, Andrew (mars 2006). « Ethnogenesis : A Contested Model of Early Medieval Europe ». In : *History Compass* 4.2, p. 241-260. DOI : 10.1111/j.1478-0542.2006.00311.x. (Visité le 04/10/2025).
- GINGRAS, Yves (1984). « La valeur d'une langue dans un champ scientifique ». In : *Recherches sociographiques* 25.2, p. 285-296. DOI : 10.7202/056095ar.
- GINZBURG, Carlo (1980). « Signes, traces, pistes. Racines d'un paradigme de l'indice ». fr. In : *Le Débat* n° 6.6, p. 3-44. DOI : 10.3917/deba.006.0003.
- GLÄNZEL, Wolfgang (jan. 2003). « Bibliometrics as a research field : A course on theory and application of bibliometric indicators ». In : *Course Handouts*.
- GOYANES, Manuel, Luis DE-MARCOS et Adrián DOMÍNGUEZ-DÍAZ (nov. 2024). « Automatic gender detection : a methodological procedure and recommendations to computationally infer the gender from names with ChatGPT and gender APIs ». In :

- Scientometrics* 129.11, p. 6867-6888. DOI : 10.1007/s11192-024-05149-2. (Visité le 13/02/2026).
- GRIMMER, Justin et Brandon M. STEWART (2013). « Text as Data : The Promise and Pitfalls of Automatic Content Analysis Methods for Political Texts ». In : *Political Analysis* 21.3, p. 267-297. DOI : 10.1093/pan/mps028.
- HANKAR, Mustapha, Mohammed KASRI et Abderrahim BENI-HSSANE (mai 2025). « A comprehensive overview of topic modeling : Techniques, applications and challenges ». In : *Neurocomputing* 628. DOI : 10.1016/j.neucom.2025.129638. (Visité le 28/02/2026).
- HARRIS, Zellig S. (1952). « Discourse Analysis ». In : *Language* 28.1, p. 1-30. (Visité le 27/04/2026).
- HENRIKSEN, Dorte (mars 2018). « What factors are associated with increasing co-authorship in the social sciences ? A case study of Danish Economics and Political Science ». In : *Scientometrics* 114.3, p. 1395-1421. DOI : 10.1007/s11192-017-2635-0. (Visité le 17/05/2026).
- HÉRUBEL, Jean-Pierre V. M. (1999). « Historical Bibliometrics : Its Purpose and Significance to the History of Disciplines ». In : *Libraries & Culture* 34.4. Sous la dir. de Virgil DIODATO et Mary K. SELLEN, p. 380-388. (Visité le 14/01/2026).
- (juill. 2006). « Clio's View of the History of Science : A Preliminary Bibliometric Appreciation ». In : *Behavioral & Social Sciences Librarian* 24.2, p. 69-91. DOI : 10.1300/J103v24n02_03. (Visité le 14/01/2026).
- HICKS, Diana (fév. 1999). « The difficulty of achieving full coverage of international social science literature and the bibliometric consequences ». In : *Scientometrics* 44.2, p. 193-215. DOI : 10.1007/BF02457380. (Visité le 17/01/2026).
- HO, Jerlyn Q. H. et al. (mai 2025). « Gender biases within Artificial Intelligence and ChatGPT : Evidence, Sources of Biases and Solutions ». In : *Computers in Human Behavior : Artificial Humans* 4, p. 100145. DOI : 10.1016/j.chbah.2025.100145. (Visité le 04/06/2026).
- HSIEH, Chih-Sheng et al. (2020). « Collaboration in Bipartite Networks, with an Application to Coauthorship Networks ». In : *SSRN Electronic Journal*. DOI : 10.2139/ssrn.3688804. (Visité le 05/03/2026).

- HYLAND, Ken et Hang (Joanna) ZOU (mars 2022). « Titles in research articles ». In : *Journal of English for Academic Purposes* 56, p. 101094. DOI : 10.1016/j.jeap.2022.101094. (Visité le 23/02/2026).
- JI, Zhenya et Ming JIANG (2026). « A systematic review of electricity demand for large language models : evaluations, challenges, and solutions ». In : *Renewable and Sustainable Energy Reviews* 225. DOI : <https://doi.org/10.1016/j.rser.2025.116159>.
- JOYE, Sylvie (2018). « Retour aux lois barbares : un point sur les recherches en cours ». In : *Bulletin de la Société nationale des Antiquaires de France* 2015.1, p. 129-135. DOI : 10.3406/bsnaf.2018.12429.
- LAFON, Pierre (1980). « Sur la variabilité de la fréquence des formes dans un corpus ». In : *Mots. Les langages du politique* 1.1, p. 127-165. DOI : 10.3406/mots.1980.1008.
- LAMASSÉ, Stéphane (2021). « Textométrie et temporalité ». In : *Histoire & mesure* XXXVI.2, p. 3-20. DOI : 10.4000/histoiremesure.14774.
- LAPIDGE, Michael (2007). « The career of Aldhelm ». In : *Anglo-Saxon England* 36, p. 15-69. DOI : 10.1017/S0263675107000026.
- LE GOFF, Jacques et Jean-Claude SCHMITT (1996). « L'histoire médiévale ». In : *Cahiers de civilisation médiévale* 39.153, p. 9-25. DOI : 10.3406/ccmed.1996.2636. (Visité le 28/02/2026).
- LEDoux, Sébastien (déc. 2016). « La mémoire, mauvais objet de l'historien ? » In : *Vingtième Siècle* N° 133.1, p. 113-128.
- LEFEBVRE, Bastien (2021). « Alice Vanetti, Archéologie du bâti, Histoire et épistémologie des origines à nos jours (France, Italie, Suisse) ». In : *Archéologie médiévale* 51, p. 343-345. DOI : 10.4000/archeomed.39754.
- LEYDESDORFF, L. (1998). « Theories of citation ? » In : *Scientometrics* 43.1, p. 5-25. DOI : 10.1007/bf02458391.
- LIM, Weng Marc et Satish KUMAR (jan. 2024). « Guidelines for interpreting the results of bibliometric analysis : A sensemaking approach ». In : *Global Business and Organizational Excellence* 43.2, p. 17-26. DOI : 10.1002/joe.22229. (Visité le 04/10/2025).
- LIU, Peng et Haoxiang XIA (avr. 2015). « Structure and evolution of co-authorship network in an interdisciplinary research field ». In : *Scientometrics* 103.1, p. 101-134. DOI : 10.1007/s11192-014-1525-y. (Visité le 17/05/2026).

- MAIREY, Aude (2008). « L'HISTOIRE CULTURELLE DU MOYEN ÂGE DANS L'HISTORIOGRAPHIE ANGLO-AMÉRICAINE Quelques éléments de réflexion ». In : *Médiévales* 55, p. 147-161. (Visité le 21/02/2026).
- MARTINEZ, William (jan. 2012). « Au-delà de la cooccurrence binaire... Poly-cooccurrences et trames de cooccurrence ». In : *Corpus* 11. DOI : 10.4000/corpus.2262. (Visité le 14/04/2026).
- MATHISEN, Ralph W. (1997). « Barbarian Bishops and the Churches "in Barbaricis Gentibus" During Late Antiquity ». In : *Speculum* 72.3, p. 664-697. (Visité le 09/05/2026).
- MERZEAU, Louise (août 2003). « Web en stock ». In : *Cahiers de médiologie* 16, p. 158-167.
- (2009). « Du signe à la trace : l'information sur mesure ». In : *Hermès, La Revue - Cognition, communication, politique*. Traçabilité et réseaux 53, p. 23-29. DOI : 10.4267/2042/31471.
- MIAO, Jun et André SALEM (2021). « Des textes en mouvement... » In : *Hist. Mes.* XXXVI.2, p. 91-124.
- MICHAUD, Éric (nov. 2017). « L'invention moderne des “ barbares ” : ethnicité et transmission des formes (France-Allemagne, XIXe et XXe siècles) ». In : *Passés Futurs*. Responsabilités publiques de l'historien 2. (Visité le 08/10/2025).
- MILLIGAN, Ian (2012). « Mining the 'Internet Graveyard' : Rethinking the Historians' Toolkit ». In : *Journal of the Canadian Historical Association / Revue de la Société historique du Canada* 23.2, p. 21-64. DOI : <https://doi.org/10.7202/1015788ar>.
- MONGEON, Philippe et Adèle PAUL-HUS (oct. 2015). « The journal coverage of Web of Science and Scopus : a comparative analysis ». In : *Scientometrics* 106.1, p. 213-228. DOI : 10.1007/s11192-015-1765-5.
- MORSEL, Joseph (2004). « Le médiéviste, le lignage et l'effet de réel. La construction du Geschlecht par l'archive en Haute-Allemagne à partir de la fin du Moyen Âge ». In : *Revue de synthèse* 125, p. 83-110.
- MUSTIGMAN, Hava (2015). « A Bibliometric Study : The Historiography of the Jewish National Movement ». In : *Qualitative and Quantitative Methods in Libraries*, p. 81-91. (Visité le 14/01/2026).
- NEDERHOF, Anton J. (jan. 2006). « Bibliometric monitoring of research performance in the Social Sciences and the Humanities : A Review ». In : *Scientometrics* 66.1, p. 81-100. DOI : 10.1007/s11192-006-0007-2. (Visité le 17/01/2026).

- NEWMAN, M. E. J. (jan. 2001). « The structure of scientific collaboration networks ». In : *Proceedings of the National Academy of Sciences* 98.2, p. 404-409. DOI : 10.1073/pnas.98.2.404. (Visité le 05/03/2026).
- NICHOLAS, David et al. (2019). « Sci-Hub : The new and ultimate disruptor ? View from the front ». In : *Learned Publishing* 32.2, p. 147-153. DOI : <https://doi.org/10.1002/leap.1206>.
- PASSAS, Ioannis (juin 2024). « Bibliometric Analysis : The Main Steps ». In : *Encyclopedia* 4.2, p. 1014-1025. DOI : 10.3390/encyclopedia4020065. (Visité le 08/10/2025).
- PINTO, Louis (2020). « Citations et références. Pour une sociologie des habitus académiques ». In : *Savoir/Agir* 54, p. 117-122.
- POHL, Walter et Nicolas BEAUPRÉ (2005). « Aux origines d'une Europe ethnique : Transformations d'identités entre Antiquité et Moyen Âge ». In : *Annales. Histoire, Sciences Sociales* 60.1, p. 183-208. (Visité le 04/10/2025).
- PRICE, Derek J. De Solla (juill. 1965). « Networks of Scientific Papers : The pattern of bibliographic references indicates the nature of the scientific research front. » In : *Science* 149.3683, p. 510-515. DOI : 10.1126/science.149.3683.510. (Visité le 14/10/2025).
- PRIEUR, Cha (déc. 2019). « Les violences envers les personnes trans* à l'université. Des conséquences sur la santé mentale aux pistes pour s'en sortir ». In : *Genre, sexualité & société* 22. DOI : 10.4000/gss.5726. (Visité le 31/05/2026).
- PROST, Antoine et Christian ROSENZVEIG (1971). « La Chambre des députés (1881-1885). Analyse factorielle des scrutins ». In : *Revue française de science politique* 21.1, p. 5-50. DOI : 10.3406/rfsp.1971.393277.
- RAO, V. Chandra, Laxmi RAO et Phani KUMAR V (jan. 2025). « English As the Language of Research and Worldwide Academic Journals ». In : *Journal for Research Scholars and Professionals of English Language Teaching* 9. DOI : 10.54850/jrspelt.9.47.001.
- RASTIER, François (2008). « Sémantique du web vs. Semantic Web ? : Le problème de la pertinence ». In : *Syntaxe & Sémantique* 9.1, p. 15-36. DOI : 10.3917/ss.009.0015. (Visité le 17/10/2025).

- RICHE, Pierre et al. (1989). « Le haut Moyen Âge occidental ». In : *Actes des congrès de la Société des historiens médiévistes de l'enseignement supérieur public* 20.1, p. 305-329. DOI : 10.3406/shmes.1989.1514. (Visité le 25/03/2026).
- ROSENZWEIG, Roy (juin 2006). « Can History Be Open Source ? Wikipedia and the Future of the Past ». In : *Journal of American History* 93.1, p. 117-146. DOI : 10.2307/4486062.
- RYGIEL, Philippe (2011). « De quoi le web est-il l'archive ? » In : *Publications de l'École française de Rome* 444.1, p. 289-308. (Visité le 31/03/2026).
- SANDERS, Guy (jan. 2000). « New relative and absolute chronologies for 9th to 13th century glazed wares at Corinth : Methodology and social conclusions ». In : *Byzanz als Raum*, p. 153-173.
- SAPIR, Edward (1929). « A study in phonetic symbolism. » In : *Journal of Experimental Psychology* 12, p. 225-239.
- SCHIRONE, Marco (mars 2023). « Field, capital, and habitus : The impact of Pierre Bourdieu on bibliometrics ». In : *Quantitative Science Studies* 4.1, p. 186-208. DOI : 10.1162/qss_a_00232.
- SINGH, Michael et Jinghe HAN (2010). « Peer review, Bourdieu and honour : connecting Chinese and Australian intellectual projects ». In : *British Journal of Sociology of Education* 31.2, p. 185-198. (Visité le 04/04/2026).
- SIRINELLI, Jean-François (juin 2005). « Réflexions sur l'histoire et l'historiographie du XXe siècle français : » in : *Revue historique* n° 635.3, p. 609-625. DOI : 10.3917/rhis.053.0609. (Visité le 27/02/2026).
- SOT, Michel (2026). « Patrick J. Geary. *Comment la génétique réécrit l'histoire du Moyen Âge*. CNRS Éditions, 2025, 176 pages, 23 € ». In : *Études* 4333.1, 127a-128. DOI : 10.3917/etu.4333.0129a.
- SOUSSI IKHLEF, Nadia (déc. 2016). « Analyse synchronique et diachronique du mot barbare dans les discours dictionnaires ». In : *Multilinguales* 7. DOI : 10.4000/multilinguales.540. (Visité le 04/10/2025).
- SPARCK JONES, KAREN (jan. 1972). « A STATISTICAL INTERPRETATION OF TERM SPECIFICITY AND ITS APPLICATION IN RETRIEVAL ». In : *Journal of Documentation* 28.1, p. 11-21. DOI : 10.1108/eb026526.

- STOCKEMER, Daniel et Michael J. WIGGINTON (fév. 2019). « Publishing in English or another language : An inclusive study of scholar's language publication preferences in the natural, social and interdisciplinary sciences ». In : *Scientometrics* 118.2, p. 645-652. DOI : 10.1007/s11192-018-2987-0.
- STURGES, Herbert A. (1926). « The Choice of a Class Interval ». In : *Journal of the American Statistical Association* 21.153, p. 65-66. (Visité le 29/04/2026).
- SYED, Sana et al. (nov. 2015). « Authorship Concerns and Who Truly Owns a Research Idea ? » In : *Pediatrics* 136.5, p. 969-973. DOI : 10.1542/peds.2015-1421.
- TASKIN, Zehra et Sümeyye AKÇA (déc. 2016). « Mapping and Bibliometric Analysis of *American Historical Review* Citations and Its Contribution to the Field of History ». In : *Journal of Information & Knowledge Management* 15.04, p. 1650039. DOI : 10.1142/S0219649216500398. (Visité le 14/01/2026).
- TURNBULL, Steven Martin et al. (sept. 2019). « Bourdieu, networks, and movements : Using the concepts of habitus, field and capital to understand a network analysis of gender differences in undergraduate physics ». In : *PLOS ONE* 14.9, e0222357. DOI : 10.1371/journal.pone.0222357. (Visité le 12/05/2026).
- VERBERGT, Marie-Gabrielle et Sjang ten HAGEN (2025). « The Past and Present of Peer Review in the Humanities : An Introduction ». In : *Minerva* 63, p. 637-657. DOI : 10.1007/s11024-025-09615-w.
- WANG, Shuo (2025). « AI for social science : A sociology PhD candidate's autoethnography on how LLMs are changing research work ». In : *AI Magazine* 46.4, e70046. DOI : <https://doi.org/10.1002/aaai.70046>.
- WOOD, Ian (jan. 2013). « The Pagans and the Other : Varying Presentations in the Early Middle Ages ». In : *Networks and Neighbours*. (Visité le 21/10/2025).
- ZHANG, Weizhen et al. (mai 2026). « Improving short text clustering through hybrid augmentation and contrastive learning ». In : *Neurocomputing* 677, p. 133130. DOI : 10.1016/j.neucom.2026.133130. (Visité le 28/02/2026).

6.3 Chapitres d'ouvrages collectifs

- BEALL, Jeffrey (2008). « OCLC : A Review ». In : *Radical Cataloging : Essays at the Front*. Sous la dir. de K. R. ROBERTO. McFarland, p. 85-93. (Visité le 08/04/2026).

- BOULANGER, Jean-François (2006). « L'Église et le XVe centenaire du baptême de Clovis. Une tourmente politique inattendue ». fr. In : *Politiques du passé*. Aix-en-Provence : Presses universitaires de Provence, p. 197-205.
- CALLON, Michel (1986). « The Sociology of an Actor-Network : The Case of the Electric Vehicle ». In : *Mapping the Dynamics of Science and Technology*. Sous la dir. de Michel CALLON, John LAW et Arie RIP. London : Palgrave Macmillan UK, p. 19-34. DOI : 10.1007/978-1-349-07408-2_2. (Visité le 05/11/2025).
- CHAMPAGNE, Patrick et Olivier CHRISTIN (2012). « Champ ». In : *Pierre Bourdieu : Une initiation*. Hors collection. Lyon : Presses universitaires de Lyon, p. 147-183. DOI : 10.4000/books.pul.5151. (Visité le 23/03/2026).
- CHAPPEY, Jean-Luc (2019). « Wikipédia et l'écriture de l'histoire : conservation ou révolution ? » In : *Dans les dédales du web : Historiens en territoires numériques*. Sous la dir. de Gaëtan BONNOT et Stéphane LAMASSÉ. Homme et société. Paris : Éditions de la Sorbonne, p. 143-164. DOI : 10.4000/11yw6. (Visité le 18/05/2026).
- COUDROY DE LILLE, Lydia (2021). « Conclusion, La géographie en partage : coopérations franco-polonaises hier et aujourd'hui ». In : *La géographie en partage : coopérations franco-polonaises hier et aujourd'hui*. Sous la dir. de Lydia Coudroy de LILLE et al. Histoire(s). Eur'Orbem, p. 219-225.
- DURLIAT, Jean (1997). « Cité, impôt et intégration des barbares ». In : *Kingdoms of the Empire*, p. 133-180. (Visité le 17/03/2026).
- FOUCAULT, Michel (2014). « V. L'a priori historique et l'archive ». In : *L'archéologie du savoir*. Tel. Paris : Gallimard, p. 173-180.
- HAMMARFELT, Björn (2016). « Beyond Coverage : Toward a Bibliometrics for the Humanities ». In : *Research Assessment in the Humanities*. Sous la dir. de Michael OCHSNER, Sven E. HUG et Hans-Dieter DANIEL. Cham : Springer International Publishing, p. 115-131. DOI : 10.1007/978-3-319-29016-4_10. (Visité le 12/01/2026).
- JOYE, Sylvie (2025a). « Bibliographie ». In : *Les lois barbares*. Rennes : Presses universitaires de Rennes. DOI : 10.4000/159od.
- (2025b). « Une multiplicité de droits pour des royaumes pluriels ». In : *Les lois barbares : Dire le droit et le pouvoir en Occident après la disparition de l'Empire romain*. Histoire. Rennes : Presses universitaires de Rennes, p. 9-32. DOI : 10.4000/159o5. (Visité le 31/03/2026).

- MATHISEN, Ralph W. (jan. 2021). « Not ‘the Other’. Barbarians and the End of the Western Roman Empire ». In : *International Medieval Research*. Sous la dir. d’Hans-Werner GOETZ et Ian WOOD. T. 25. Turnhout, Belgium : Brepols Publishers, p. 275-287. DOI : 10.1484/M.IMR-EB.5.123595. (Visité le 14/10/2025).
- MEDVECKI, Darija et al. (2024). « Multilingual transformer and BERTopic for short text topic modeling : The case of Serbian ». In : t. 872, p. 161-173. DOI : 10.1007/978-3-031-50755-7_16. (Visité le 28/02/2026).
- MORSEL, Joseph (2021). « Production d’archives, ou archives de la reproduction ? : La question des archives au miroir de la continuité seigneuriale ». In : *Les archives familiales dans l’Occident médiéval et moderne : Trésor, arsenal, mémorial*. Sous la dir. de Véronique LAMAZOU-DUPLAN. Collection de la Casa de Velázquez. Madrid : Casa de Velázquez, p. 17-27. DOI : 10.4000/books.cvz.25790. (Visité le 26/03/2026).
- OCHSNER, Michael (jan. 2021). « 2.5 Bibliometrics in the Humanities, Arts and Social Sciences ». In : *Handbook Bibliometrics*. Sous la dir. de Rafael BALL. De Gruyter, p. 117-124. DOI : 10.1515/9783110646610-013. (Visité le 14/01/2026).
- PANSU, Pascal, Nicole DUBOIS et Jean-Léon BEAUVOIS (2014). « Chapitre 2. Une introduction à la bibliométrie d’impact ». In : *Dis-moi qui te cite, et je saurai ce que tu vaux*. Points de vue et débats scientifiques. FONTAINE : Presses universitaires de Grenoble, p. 17-43.
- PANT, Vinay Kumar, Rupak SHARMA et Shakti KUNDU (2024). « An overview of Stemming and Lemmatization Techniques ». In : *Advances in Networks, Intelligence and Computing*. CRC Press.
- PAVEAU, Marie-Anne (nov. 2017). « Le préconstruit. Généalogie et déploiements d’une notion plastique ». In : *Le préconstruit, approche pluridisciplinaire*. Sous la dir. de Florent BRÉCHET et al. Rencontres 192. Classiques Garnier.
- PERRAULT, Anna H. (2003). « The Role of WorldCat in Resources Sharing ». In : *The New Dynamics and Economics of Cooperative Collection Development*. Routledge.
- PROST, Antoine (1988). « Les mots ». In : *Pour une histoire politique*. Sous la dir. de René RÉMOND. Paris : Éditions du Seuil, p. 255-285.
- ROUEFF, Olivier (juin 2013). « Trente ans après La Distinction, de Pierre Bourdieu ». In : *Trente ans après La Distinction, de Pierre Bourdieu*. La Découverte, p. 153-164.

SCHMITT, Jean-Claude et Dominique IOGNA-PRAT (2003). « Trente ans d’histoire médiévale en France ». In : *Les tendances actuelles de l’histoire du Moyen Âge en France et en Allemagne*. Sous la dir. d’Otto Gerhard OEXLE et Jean-Claude SCHMITT. Paris : Éditions de la Sorbonne, p. 399-424. DOI : 10.4000/books.psorbonne.20806. (Visité le 27/02/2026).

6.4 Autres

CLAVERT, Frédéric (2019). *L’archive interfacée / Le goût de l’archive à l’ère numérique*. fr-FR. URL : <https://gout-numerique.net/table-of-contents/archives-nees-numeriques/larchive-interfacee> (visité le 23/03/2026).

COHAN, Arman et al. (mai 2020). *SPECTER : Document-level Representation Learning using Citation-informed Transformers*. DOI : 10.48550/arXiv.2004.07180. URL : <http://arxiv.org/abs/2004.07180> (visité le 28/02/2026).

GROOTENDORST, Maarten (mars 2022). *BERTopic : Neural topic modeling with a class-based TF-IDF procedure*. DOI : 10.48550/arXiv.2203.05794. URL : <http://arxiv.org/abs/2203.05794> (visité le 28/02/2026).

KANERVA, Jenna et al. (2025). *OCR Error Post-Correction with LLMs in Historical Documents : No Free Lunches*. URL : <https://arxiv.org/abs/2502.01205>.

LEHMAN, Philipp, Philip KIME et Moritz WEMHEUER (s. d.). *The biblatex Package*.

LUPOVICI, Catherine (1991). *Conversion rétrospective des catalogues (La)*. Text. URL : <https://www.enssib.fr/bibliotheque-numerique/notices/33775-la-conversion-retrospective-des-catalogues> (visité le 25/03/2026).

Massive ancient-DNA study reveals natural selection has accelerated in recent human evolution (avr. 2026). URL : <https://www.broadinstitute.org/news/massive-ancient-dna-study-reveals-natural-selection-has-accelerated-recent-human-evolution> (visité le 04/05/2026).

MINARD, Charles-Joseph (1844). *Tableaux graphiques et cartes figuratives : transports de voyageurs et marchandises en France et Europe (1845–1870)*. Collection de cartes figuratives. Paris. URL : https://patrimoine.enpc.fr/document/ENPC01_Fol_10975.

- OSLER, Lucy (2025). *Hallucinating with AI : AI Psychosis as Distributed Delusions*. URL : <https://arxiv.org/abs/2508.19588>.
- SERRES, Alexandre (déc. 2002). *Quelle(s) problématique(s) de la trace ?* URL : https://archivesic.ccsd.cnrs.fr/sic_00001397.
- SONG, Kaitao et al. (2020). *MPNet : Masked and Permuted Pre-training for Language Understanding*. URL : <https://arxiv.org/abs/2004.09297>.
- SONG, Xinyi et al. (2025). *Performance Evaluation of Large Language Models in Statistical Programming*. URL : <https://arxiv.org/abs/2502.13117>.
- The Cost of Sequencing a Human Genome* (2026). URL : <https://www.genome.gov/about-genomics/fact-sheets/Sequencing-Human-Genome-cost> (visité le 05/05/2026).

Chapitre 7

Annexes

Les annexes sont classées par section. Les titres des figures et tableaux sont au dessus pour les plus longs, au dessous sinon. Seuls les tableaux issus du site AnalyseSHS, pour l'AFC, ont un titre en dessous malgré leur longueur.

7.1 Annexes pour la section 2.3

Tag	Libellé	% présent	% significatif	Creux	Long. moy.
DB	Nom de la base de données	100,0	100,0	0	17,3
TY	Type de référence	100,0	100,0	0	4,2
LK	Lien (WorldCat)	100,0	100,0	0	37,1
TI	Titre	100,0	99,97	10	83,6
T2	Titre secondaire / Revue	98,24	98,24	0	48,8
PY	Année de publication	95,81	95,81	0	4,0
SN	ISSN / ISBN	83,09	83,09	0	18,2
AU	Auteur	79,34	79,34	0	16,8
SP	Page de début	66,16	63,02	1 104	4,9
UR	URL	57,22	57,22	0	45,4
DO	DOI	54,19	54,19	0	25,2
VL	Volume	40,77	34,62	2 160	2,3
IS	Numéro	27,10	4,26	8 030	3,1
EP	Page de fin	25,06	23,32	611	2,7
M2	Numéro de <i>start</i>	33,95	31,52	855	2,9
LA	Langue	18,29	18,29	0	7,1
PB	Éditeur (organisme)	7,30	6,56	261	40,9
M1	Numéro de rapport / série	5,11	1,42	1 300	2,8
T3	Titre tertiaire / Série	1,60	1,60	0	28,2
ET	Edition / Version	0,19	0,19	1	43,1
TT	Titre traduit	0,11	0,11	0	2,0
RP	Adresse de réimpression	0,01	0,01	0	8,0
TA	Titre abrégé	0,00	0,00	0	19,0

TABLE 7.1 – Complétude des champs RIS dans le corpus WorldCat ($n = 35\,157$ notices)

Note. % **présent** : tag présent dans le champ RIS brut. % **significatif** : tag dont la valeur est réellement exploitable (hors placeholders de type -, N/A, etc.). **Creux** : nombre de notices où le tag est présent mais non significatif. **Long. moy.** : longueur moyenne (en caractères) des valeurs significatives. Le champ **IS** présente le taux de creux le plus élevé (8 030 notices, soit 84 % des occurrences), principalement dû à des valeurs non renseignées.

TABLE 7.2 – Stratégies d’augmentation de la donnée : synthèse comparative. Indicateurs de difficulté/coût : [+] faible, [++] modéré, [+++] élevé. [!] problème juridique ou éthique. Le terme « code source » désigne systématiquement Selenium + lecture du code source de la page.

	Stratégie	Prérequis	Avantage	Inconvénient	Difficulté	Bénéfice
Enrichissement des publications	Demander (e-mail)	Liste précise des références souhaitées (titre, titre secondaire, auteur, date à minima)	Possibilité d’obtenir le <i>fulltext</i> ou des métadonnées complètes directement auprès des auteurs	Temps de réponse variable ; anxiété sociale ; compétences linguistiques et communicationnelles requises [+++]	Rédaction du mail + identification de la personne à contacter et des références [+]	<i>Fulltext</i> ou meilleures métadonnées, variable selon la réponse
	Crossref (API)	DOI	API, rapide à implémenter et à interroger	Nécessite des compétences en code [+]	Faible [+]	Langue, auteur et autres informations, mais apport limité par rapport au RIS. Principalement utilisé ici pour la langue.
	JSTOR	Titre + titre secondaire + année à minima ; sinon titre + auteur (au moins 1)	JSON local, peu coûteux	Difficile de retrouver la référence sans son <i>itemid</i> ; coût en temps de calcul [++]	Compte Paris 1 [++]	Récupération de l’ <i>itemid</i> nécessaire à la demande du <i>fulltext</i> ; accès à une plateforme permettant la demande de <i>fulltext</i>
	Persée	Titre + titre secondaire + année à minima ; sinon titre + auteur (au moins 1)	<i>Fulltext</i> en libre accès	Surtout pour le français [+++]	Selenium + code source de la page [+++]	Accès au <i>fulltext</i> des références disponibles sur la plateforme
	BDD ciblée	Liste précise des références publiées sur la même BDD	Gain massif d’informations possible (ex. OpenEdition : <i>fulltext</i> + références associées)	Non systématisable à l’ensemble de la BDD ; structure variable selon la base (mapping SQL ou équivalences NoSQL nécessaires) [+++]	Selenium + code source de la page ; parfois compte Paris 1 ; temps [+++]	Variable, de l’abstract au <i>fulltext</i> . Pertinent si peu de blocage Cloudflare et si grand nombre de références concernées.
	Sci-Hub / Anna’s Archive	DOI	Gain du <i>fulltext</i> possible	[!] Illégal ; URL des sites changeantes [+++]	Implémentation via un dépôt GitHub [++]	<i>Fulltext</i> lorsque disponible sur ces sites

suite page suivante...

Table 7.2 (*suite*)

	Stratégie	Prérequis	Avantage	Inconvénient	Difficulté	Bénéfice
Enrichissement des auteurs	BDD ciblée (auteur)	Liste précise des références publiées sur une même BDD dont les auteurs ne sont pas encore identifiés (typiquement 20+ auteurs non identifiés après passage par VIAF, IdRef, Worldcat, etc.)	Gain ponctuel important pour les publications à nombreux auteurs	Pertinent uniquement pour les publications à nombreux auteurs ; risque de blocage Cloudflare [+++]	Selenium + code source de la page ; éventuellement compte Paris 1 ; temps [+++]	Identifiant auteur (souvent ORCID ou Scopus) permettant le dédoublonnage ; accès au Scopus ID pour l'interrogation de Wikidata
	IEEE	Liste précise de références publiées par IEEE (identifiables par des motifs spécifiques au corpus, ex. « consortium about... »)	Notice d'auteur structurée ; pas de blocage Cloudflare ; informations riches : genre, prénom, nom, institution, champs de recherche	Ciblé et limité aux références IEEE [+]	Selenium + code source de la page ; éventuellement compte Paris 1 ; temps [++]	Identifiant auteur et informations biographiques riches ; lien vers d'autres notices d'autorité (ORCID)
	ORCID	Aucun prérequis strict (récupérer la liste des publications via Worldcat est une bonne pratique mais non nécessaire)	Pas de blocage Cloudflare	Données déclaratives uniquement ; plusieurs ORCID possibles pour une même personne ; peu pratique hors des milieux anglo-saxons [++]	Temps + code source [+]	Identifiant auteur ; genre, institution d'emploi et de formation (spécifique à ORCID). Permet la récupération du Scopus ID pour l'interrogation de Wikidata.
	IdRef (API)	Aucun prérequis strict (récupérer la liste des publications via Worldcat est une bonne pratique mais non nécessaire)	API, rapide à implémenter et à interroger	Doublons fréquents ; difficile de confirmer l'identité (peu de publications indexées, alignement imparfait avec VIAF) ; principalement utile pour les auteurs français [++]	Faible [+]	Identifiant auteur, genre, nationalité, liste d'œuvres, liens vers d'autres notices d'autorité. Sélection de co-auteurs (non exploité ici).

suite page suivante...

Table 7.2 (*suite*)

Stratégie	Prérequis	Avantage	Inconvénient	Difficulté	Bénéfice
VIAF	Aucun prérequis strict (récupérer la liste des publications via Worldcat est une bonne pratique mais non nécessaire)	Quantité d'informations disponibles importante; pas de blocage Cloudflare	Données peu structurées et non normalisées (nationalités saisies selon les conventions de chaque bibliothèque, ex. « french », « französisch »...); doublons fréquents; interface non hiérarchisée [+++]	Temps + code source (variable selon les notices) [++]	Identifiant auteur, genre, nationalité, formes du nom, liste d'œuvres, langue d'expression, liens vers d'autres notices d'autorité, champ disciplinaire, éditeurs. Souvent limité à un nom et une œuvre.
BDD locale en ligne	Auteurs appartenant à un corpus thématique très précis dont la base contient un identifiant unique (ex. <i>goldhorde.ru</i>)	Pas de blocage Cloudflare; code source simple; description préliminaire des auteurs	Non autoritaire; très ciblé sur un petit nombre d'auteurs [+]	Temps + Selenium [++]	Identifiant unique (non interopérable) et quelques informations complémentaires
RI OPAC	Aucun prérequis strict (récupérer la liste des publications via Worldcat est une bonne pratique mais non nécessaire)	Données disponibles en CSV, libre accès, données ouvertes. Interrogation locale possible.	Interface peu ergonomique; documentation en anglais/allemand lacunaire [++]	Temps de compréhension de l'interface [++]	Liste d'œuvres; ID RI OPAC (partiellement interopérable avec Wikidata); lien vers GND (interopérable avec Wikidata)
Google Scholar	Aucun prérequis strict (récupérer la liste des publications via Worldcat est une bonne pratique mais non nécessaire)	Couverture très large; importante liste de publications	Difficile à scraper (via un dépôt GitHub); présence de doublons [+++]	Temps (très lent) + Selenium [+++]	ID Google Scholar; institution de rattachement parfois; liste de publications
Wikidata (API)	Identifiant auteur issu d'une des bases précédentes (ORCID, VIAF, IdRef, IEEE, Scopus)	Interopérabilité; API rapide; interrogation par paquet; données structurées	Données participatives, ne faisant pas autorité [++]	Requiert une récupération préalable d'un identifiant [++]	Alignement des référentiels auteurs : genre, institution, nationalité, langue, sujet, discipline, etc.

suite page suivante...

Table 7.2 (*suite*)

Stratégie	Prérequis	Avantage	Inconvénient	Difficulté	Bénéfice
Wikidata (recherche)	Aucun prérequis strict (récupérer la liste des publications via Worldcat est une bonne pratique mais non nécessaire)	Pas de blocage Cloudflare ; données très structurées	Peu de résultats : auteurs souvent sans profil complet ni toutes leurs publications indexées [++]	Temps [+]	Identifiant auteur puis alignement des référentiels : genre, institution, nationalité, langue, sujet, discipline, etc.
Worldcat (auteur)	Aucun ; on retourne sur la page d'une référence liée à l'auteur et on clique sur son nom	On s'attend à ce que ce soit le même auteur ; permet de relancer une recherche par nom exact	Blocage Cloudflare ; données non harmonisées (absence de publications ou amalgame d'auteurs homonymes) [+++]	Temps (très lent) [++]	Liste de publications pour interroger ensuite les référentiels d'autorité et comparer les listes (si match → même personne). Attention : le <i>sequence matcher</i> peut être trompé par des titres tronqués ou reformulés.

Hello Mr, Ms,

I am a french student studying in La Sorbonne, Paris (Paris 1 Panthéon-Sorbonne), a Master's degree in digital humanities (data science, history and culture). Here's my academic e-mail if you need it : enora.roy@etu.univ-paris1.fr .Please excuse my poor english, due to the fact that I do not practice often - I hope I am still understandable to an extent and not appearing as rude.

I am sending you this e-mail in order to ask you for some text and data mining, as noted on your website (around 700 references, probably less). Indeed, my master's thesis is about the concept of the barbarian in historiography (focused on recent english, german, french, spanish and italian historiography). Hence, I need to get a lot of data about it. I already have a list of references I do want to explore more deeply (first of all to know if they're relevant, and then to do a science mapping analysis), and some of these are on your website.

Therefore, may I ask you for the right to scrape these references without the website blocking me, or maybe you could provide them to me please (To this e-mail is attached the list of the references I do need the abstract and the keyword at the very least - but the fulltext would also be great.) ?

Thank you in advance for your time and your answer,

Yours sincerely,

7.2 Annexes pour la section 3.1.3

Un exemple de prompt adressé à Claude Sonnet 4.6

Prompt : Pipeline de topic modelling sur titres d'articles

Contexte

Je suis étudiante en master d'histoire - sciences des données. Dans le cadre de mon mémoire, j'ai constitué une base de données bibliographique de publications académiques en anglais sur le Haut Moyen Âge. Je dispose d'un corpus de 12 136 titres d'articles, prétraités avec SpaCy et exportés au format JSON. Je souhaite identifier les grandes thématiques disciplinaires présentes dans ce corpus afin d'en dresser une cartographie.

Ressources disponibles

Le corpus est un fichier JSON structuré comme suit (extrait) :

```
[
  {
    "document": {
      "_id": "ref_001",
      "lexical_features": [
        {"token": "Vikings", "lemma": "Viking"},
        {"token": "and", "lemma": ""},
        {"token": "trade", "lemma": ""}
      ]
    }
  }
]
```

J'ai également un fichier `stop_words_english.txt` avec mes stopwords personnalisés, un mot par ligne.

Objectif

Produis un script Python complet `bertopic_pipeline.py` qui :

1. Charge le JSON et prépare le corpus pour le topic modelling

2. Encode les titres avec un modèle de transformers MPNET (par défaut de BERT)
3. Réduit la dimensionnalité pour le clustering
4. Fais un sweep pour visualiser, par l'évolution de la cohérence, le nombre optimal de thématiques.
5. Ajuste le modèle BERTopic selon le nombre de topic sélectionné
5. Affiche les termes les plus discriminants par thématique (c-tf-idf)
6. Exporte les résultats dans deux fichiers CSV :

`document_topics.csv` (identifiant du document et topic assigné) et
`topic_terms.csv` (termes caractéristiques par topic)

Contraintes

- Tous les paramètres configurables (chemins, seuils, nombre de topics) doivent être regroupés en haut du script
- Le script doit, autant que possible, réutiliser des outils existants (bibliothèques), sans classes ni fonctions utilitaires superflues
- Justifie brièvement dans les commentaires les choix méthodologiques structurants (modèle d'embedding, algorithme de clustering, méthode de sélection du nombre de topics)

7.3 Annexes pour la section 4.3

TABLE 7.4 – Données annuelles ayant permis de construire le graphique d'anglicisation

pays	année	total_pub	nb_anglais	part_anglais	ma_anglais
France	1975	16	8	50.00	
Germany	1975	6	3	50.00	
Italy	1975	1	0	0.00	

Suite à la page suivante...

TABLE 7.4 – Données annuelles ayant permis de construire le graphique d’anglicisation
– Suite

pays	année	total_pub	nb_anglais	part_anglais	ma_anglais
Poland	1975	2	0	0.00	
Sweden	1975	3	1	33.33	
France	1976	10	1	10.00	20.00
Germany	1976	13	4	30.77	26.92
Italy	1976	2	2	100.00	33.33
Poland	1976	3	1	33.33	11.11
Sweden	1976	2	2	100.00	77.78
France	1977	9	0	0.00	5.71
Germany	1977	6	0	0.00	26.92
Italy	1977	2	0	0.00	33.33
Poland	1977	2	0	0.00	11.11
Sweden	1977	1	1	100.00	100.00
France	1978	14	1	7.14	5.71
Germany	1978	10	5	50.00	27.78
Italy	1978	1	0	0.00	16.67
Poland	1978	2	0	0.00	0.00
Sweden	1978	1	1	100.00	100.00
France	1979	20	2	10.00	14.05
Germany	1979	6	2	33.33	44.44
Italy	1979	6	3	50.00	16.67
Poland	1979	3	0	0.00	8.33
Spain	1979	2	0	0.00	
Sweden	1979	1	1	100.00	100.00
France	1980	8	2	25.00	21.92
Germany	1980	4	2	50.00	27.78

Suite à la page suivante...

TABLE 7.4 – Données annuelles ayant permis de construire le graphique d’anglicisation
– Suite

pays	année	total_pub	nb_anglais	part_anglais	ma_anglais
Italy	1980	6	0	0.00	16.67
Poland	1980	4	1	25.00	30.56
Spain	1980	1	1	100.00	33.33
Sweden	1980	2	2	100.00	83.33
France	1981	13	4	30.77	21.62
Germany	1981	3	0	0.00	25.00
Italy	1981	7	0	0.00	0.00
Poland	1981	3	2	66.67	30.56
Spain	1981	1	0	0.00	44.44
Sweden	1981	2	1	50.00	69.05
France	1982	11	1	9.09	18.05
Germany	1982	8	2	25.00	15.74
Italy	1982	3	0	0.00	3.33
Poland	1982	3	0	0.00	25.93
Sweden	1982	7	4	57.14	60.71
France	1983	14	2	14.29	10.69
Germany	1983	9	2	22.22	24.83
Italy	1983	10	1	10.00	13.59
Poland	1983	9	1	11.11	20.37
Sweden	1983	4	3	75.00	77.38
France	1984	23	2	8.70	9.05
Germany	1984	11	3	27.27	23.91
Italy	1984	13	4	30.77	13.59
Poland	1984	4	2	50.00	20.37
Spain	1984	3	1	33.33	11.11
Suite à la page suivante...					

TABLE 7.4 – Données annuelles ayant permis de construire le graphique d’anglicisation
– Suite

pays	année	total_pub	nb_anglais	part_anglais	ma_anglais
France	1985	24	1	4.17	7.86
Germany	1985	9	2	22.22	22.85
Italy	1985	4	0	0.00	22.76
Poland	1985	1	0	0.00	16.67
Spain	1985	1	0	0.00	27.78
Sweden	1985	4	4	100.00	83.33
France	1986	28	3	10.71	4.96
Germany	1986	21	4	19.05	22.09
Italy	1986	8	3	37.50	16.20
Poland	1986	1	0	0.00	0.00
Spain	1986	2	1	50.00	16.67
Sweden	1986	4	3	75.00	83.33
France	1987	15	0	0.00	4.96
Germany	1987	8	2	25.00	19.44
Italy	1987	9	1	11.11	19.71
Spain	1987	1	0	0.00	16.67
Sweden	1987	4	3	75.00	83.33
France	1988	24	1	4.17	2.54
Germany	1988	21	3	14.29	24.21
Italy	1988	19	2	10.53	7.21
Poland	1988	1	0	0.00	16.67
Spain	1988	2	0	0.00	0.00
Sweden	1988	2	2	100.00	75.00
France	1989	29	1	3.45	2.54
Germany	1989	9	3	33.33	29.21
Suite à la page suivante...					

TABLE 7.4 – Données annuelles ayant permis de construire le graphique d’anglicisation
– Suite

pays	année	total_pub	nb_anglais	part_anglais	ma_anglais
Italy	1989	6	0	0.00	8.27
Poland	1989	2	1	50.00	16.67
Spain	1989	3	0	0.00	16.67
Sweden	1989	4	2	50.00	77.78
France	1990	23	0	0.00	2.82
Germany	1990	10	4	40.00	30.00
Italy	1990	7	1	14.29	4.76
Poland	1990	2	0	0.00	16.67
Spain	1990	4	2	50.00	27.78
Sweden	1990	6	5	83.33	73.61
France	1991	40	2	5.00	6.21
Germany	1991	12	2	16.67	34.68
Italy	1991	5	0	0.00	15.87
Spain	1991	3	1	33.33	37.30
Sweden	1991	8	7	87.50	79.17
France	1992	22	3	13.64	10.81
Germany	1992	19	9	47.37	27.60
Italy	1992	6	2	33.33	11.11
Spain	1992	7	2	28.57	26.19
Sweden	1992	9	6	66.67	72.22
France	1993	29	4	13.79	14.19
Germany	1993	16	3	18.75	33.15
Italy	1993	36	0	0.00	11.11
Poland	1993	2	0	0.00	22.22
Spain	1993	6	1	16.67	20.63

Suite à la page suivante...

TABLE 7.4 – Données annuelles ayant permis de construire le graphique d’anglicisation
– Suite

pays	année	total_pub	nb_anglais	part_anglais	ma_anglais
Sweden	1993	8	5	62.50	65.28
France	1994	33	5	15.15	9.65
Germany	1994	18	6	33.33	26.13
Italy	1994	7	0	0.00	7.41
Poland	1994	3	2	66.67	55.56
Spain	1994	6	1	16.67	11.11
Sweden	1994	6	4	66.67	70.83
France	1995	34	0	0.00	8.08
Germany	1995	19	5	26.32	28.22
Italy	1995	9	2	22.22	16.50
Poland	1995	1	1	100.00	62.22
Spain	1995	9	0	0.00	12.22
Sweden	1995	6	5	83.33	78.57
France	1996	33	3	9.09	6.16
Germany	1996	24	6	25.00	21.63
Italy	1996	11	3	27.27	24.83
Poland	1996	5	1	20.00	65.00
Spain	1996	5	1	20.00	15.00
Sweden	1996	7	6	85.71	78.57
France	1997	32	3	9.38	8.99
Germany	1997	59	8	13.56	24.45
Italy	1997	20	5	25.00	31.31
Poland	1997	4	3	75.00	48.33
Spain	1997	4	1	25.00	27.50
Sweden	1997	3	2	66.67	73.02
Suite à la page suivante...					

TABLE 7.4 – Données annuelles ayant permis de construire le graphique d’anglicisation
– Suite

pays	année	total_pub	nb_anglais	part_anglais	ma_anglais
France	1998	47	4	8.51	9.19
Germany	1998	23	8	34.78	28.02
Italy	1998	12	5	41.67	32.37
Poland	1998	6	3	50.00	61.67
Spain	1998	8	3	37.50	39.02
Sweden	1998	9	6	66.67	77.78
France	1999	62	6	9.68	9.09
Germany	1999	42	15	35.71	36.51
Italy	1999	23	7	30.43	34.45
Poland	1999	5	3	60.00	61.67
Spain	1999	11	6	54.55	39.94
Sweden	1999	9	9	100.00	81.64
France	2000	66	6	9.09	11.81
Germany	2000	41	16	39.02	36.02
Italy	2000	16	5	31.25	32.84
Poland	2000	4	3	75.00	67.22
Spain	2000	18	5	27.78	44.11
Sweden	2000	23	18	78.26	89.72
France	2001	54	9	16.67	14.60
Germany	2001	27	9	33.33	37.00
Italy	2001	19	7	36.84	32.22
Poland	2001	3	2	66.67	80.56
Spain	2001	12	6	50.00	35.45
Sweden	2001	11	10	90.91	87.87
France	2002	61	11	18.03	16.44
Suite à la page suivante...					

TABLE 7.4 – Données annuelles ayant permis de construire le graphique d’anglicisation
– Suite

pays	année	total_pub	nb_anglais	part_anglais	ma_anglais
Germany	2002	44	17	38.64	39.68
Italy	2002	14	4	28.57	29.38
Poland	2002	6	6	100.00	55.56
Spain	2002	7	2	28.57	29.52
Sweden	2002	18	17	94.44	95.12
France	2003	41	6	14.63	17.56
Germany	2003	51	24	47.06	37.10
Italy	2003	22	5	22.73	21.70
Poland	2003	3	0	0.00	61.11
Spain	2003	10	1	10.00	16.78
Sweden	2003	11	11	100.00	91.90
France	2004	60	12	20.00	15.39
Germany	2004	82	21	25.61	34.39
Italy	2004	29	4	13.79	22.89
Poland	2004	6	5	83.33	38.89
Spain	2004	17	2	11.76	15.59
Sweden	2004	16	13	81.25	88.99
France	2005	78	9	11.54	18.39
Germany	2005	59	18	30.51	31.90
Italy	2005	28	9	32.14	25.41
Poland	2005	3	1	33.33	65.56
Spain	2005	12	3	25.00	20.19
Sweden	2005	14	12	85.71	71.04
France	2006	55	13	23.64	15.72
Germany	2006	48	19	39.58	34.65

Suite à la page suivante...

TABLE 7.4 – Données annuelles ayant permis de construire le graphique d’anglicisation
– Suite

pays	année	total_pub	nb_anglais	part_anglais	ma_anglais
Italy	2006	33	10	30.30	37.91
Poland	2006	5	4	80.00	50.28
Spain	2006	21	5	23.81	25.79
Sweden	2006	13	6	46.15	73.12
France	2007	75	9	12.00	16.32
Germany	2007	65	22	33.85	38.58
Italy	2007	39	20	51.28	47.37
Poland	2007	8	3	37.50	62.50
Spain	2007	21	6	28.57	29.29
Sweden	2007	16	14	87.50	70.94
France	2008	120	16	13.33	21.95
Germany	2008	52	22	42.31	36.74
Italy	2008	38	23	60.53	55.79
Poland	2008	10	7	70.00	48.33
Spain	2008	31	11	35.48	28.02
Sweden	2008	24	19	79.17	86.87
France	2009	116	47	40.52	21.39
Germany	2009	91	31	34.07	44.30
Italy	2009	45	25	55.56	54.38
Poland	2009	8	3	37.50	52.50
Spain	2009	30	6	20.00	30.72
Sweden	2009	33	31	93.94	84.69
France	2010	155	16	10.32	31.81
Germany	2010	69	39	56.52	45.75
Italy	2010	51	24	47.06	50.54

Suite à la page suivante...

TABLE 7.4 – Données annuelles ayant permis de construire le graphique d’anglicisation
– Suite

pays	année	total_pub	nb_anglais	part_anglais	ma_anglais
Poland	2010	16	8	50.00	59.47
Spain	2010	30	11	36.67	25.56
Sweden	2010	21	17	80.95	86.50
France	2011	157	70	44.59	23.82
Germany	2011	75	35	46.67	52.48
Italy	2011	51	25	49.02	48.24
Poland	2011	11	10	90.91	75.54
Spain	2011	30	6	20.00	34.17
Sweden	2011	39	33	84.62	83.76
France	2012	145	24	16.55	28.58
Germany	2012	59	32	54.24	51.76
Italy	2012	37	18	48.65	48.90
Poland	2012	14	12	85.71	88.21
Spain	2012	24	11	45.83	38.61
Sweden	2012	28	24	85.71	85.53
France	2013	126	31	24.60	23.95
Germany	2013	114	62	54.39	55.58
Italy	2013	51	25	49.02	52.82
Poland	2013	25	22	88.00	84.57
Spain	2013	22	11	50.00	49.12
Sweden	2013	51	44	86.27	85.72
France	2014	114	35	30.70	26.40
Germany	2014	74	43	58.11	48.61
Italy	2014	51	31	60.78	55.12
Poland	2014	20	16	80.00	86.11

Suite à la page suivante...

TABLE 7.4 – Données annuelles ayant permis de construire le graphique d’anglicisation
– Suite

pays	année	total_pub	nb_anglais	part_anglais	ma_anglais
Spain	2014	33	17	51.52	48.42
Sweden	2014	27	23	85.19	87.63
France	2015	113	27	23.89	26.71
Germany	2015	153	51	33.33	49.96
Italy	2015	63	35	55.56	51.28
Poland	2015	31	28	90.32	79.58
Spain	2015	32	14	43.75	42.87
Sweden	2015	35	32	91.43	90.05
France	2016	141	36	25.53	22.74
Germany	2016	77	45	58.44	51.72
Italy	2016	72	27	37.50	46.96
Poland	2016	19	13	68.42	74.54
Spain	2016	42	14	33.33	38.19
Sweden	2016	31	29	93.55	93.30
France	2017	117	22	18.80	24.51
Germany	2017	112	71	63.39	65.26
Italy	2017	69	33	47.83	48.44
Poland	2017	37	24	64.86	67.51
Spain	2017	32	12	37.50	40.28
Sweden	2017	59	56	94.92	93.38
France	2018	113	33	29.20	23.86
Germany	2018	119	88	73.95	68.49
Italy	2018	75	45	60.00	57.30
Poland	2018	39	27	69.23	69.70
Spain	2018	36	18	50.00	46.31

Suite à la page suivante...

TABLE 7.4 – Données annuelles ayant permis de construire le graphique d’anglicisation
– Suite

pays	année	total_pub	nb_anglais	part_anglais	ma_anglais
Sweden	2018	48	44	91.67	91.02
France	2019	123	29	23.58	30.57
Germany	2019	91	62	68.13	72.51
Italy	2019	64	41	64.06	63.30
Poland	2019	28	21	75.00	73.08
Spain	2019	35	18	51.43	50.48
Sweden	2019	37	32	86.49	90.44
France	2020	113	44	38.94	27.40
Germany	2020	110	83	75.45	71.55
Italy	2020	79	52	65.82	61.14
Poland	2020	28	21	75.00	79.76
Spain	2020	48	24	50.00	52.65
Sweden	2020	44	41	93.18	89.82
France	2021	132	26	19.70	28.74
Germany	2021	114	81	71.05	72.76
Italy	2021	71	38	53.52	60.09
Poland	2021	28	25	89.29	82.54
Spain	2021	46	26	56.52	47.73
Sweden	2021	49	44	89.80	90.99
France	2022	116	32	27.59	27.07
Germany	2022	85	61	71.76	64.14
Italy	2022	64	39	60.94	59.42
Poland	2022	36	30	83.33	84.62
Spain	2022	30	11	36.67	49.81
Sweden	2022	30	27	90.00	91.04

Suite à la page suivante...

TABLE 7.4 – Données annuelles ayant permis de construire le graphique d’anglicisation
– Suite

pays	année	total_pub	nb_anglais	part_anglais	ma_anglais
France	2023	115	39	33.91	30.11
Germany	2023	129	64	49.61	54.58
Italy	2023	58	37	63.79	61.68
Poland	2023	16	13	81.25	82.64
Spain	2023	32	18	56.25	53.19
Sweden	2023	30	28	93.33	88.38
France	2024	111	32	28.83	35.50
Germany	2024	118	50	42.37	55.11
Italy	2024	63	38	60.32	69.80
Poland	2024	36	30	83.33	83.75
Spain	2024	30	20	66.67	66.61
Sweden	2024	33	27	81.82	87.72
France	2025	64	28	43.75	
Germany	2025	60	44	73.33	
Italy	2025	34	29	85.29	
Poland	2025	15	13	86.67	
Spain	2025	13	10	76.92	
Sweden	2025	25	22	88.00	

Year	English	French	German	Italian	Russian	Spanish
1980	68.5	18.6	5.9	5.9	0.0	1.2
1985	57.0	23.9	8.2	8.9	0.0	1.9
1990	63.5	21.5	6.8	6.3	0.0	1.9
1995	62.6	17.1	10.1	6.3	0.0	4.0
2000	68.4	16.9	8.1	3.3	0.3	3.0
2005	69.6	12.5	8.7	3.6	0.3	5.3
2010	71.4	14.5	5.4	2.2	1.6	4.8
2015	75.0	9.5	5.3	2.1	3.6	4.4
2020	78.4	9.9	2.8	2.1	2.5	4.3

TABLE 7.3 – Part des publications par année et par langue (en %)

Groupe	1970s	1980s	1990s	2000s	2010s	2020s
Other	110 (27.2%)	350 (33.1%)	752 (30.6%)	1720 (30.9%)	3222 (29.3%)	1776 (26.9%)
France	55 (13.5%)	112 (10.6%)	227 (9.3%)	471 (8.5%)	852 (7.8%)	443 (6.7%)
Undetermined	119 (29.4%)	305 (28.9%)	744 (30.3%)	1977 (35.5%)	5326 (48.5%)	3709 (56.1%)
UK	62 (15.3%)	113 (10.7%)	346 (14.1%)	596 (10.7%)	745 (6.8%)	298 (4.5%)
US	59 (14.6%)	176 (16.6%)	384 (15.7%)	803 (14.4%)	837 (7.6%)	380 (5.8%)

TABLE 7.5 – Flux de nouveaux auteurs par groupe de nationalité et décennie (effectif pondéré et part % du total des entrants)

7.4 Annexes pour la section 4.4

TABLE 7.6 – Sur- et sous-représentation des nationalités dans la composante principale (LCC)

pays	Hors LCC	Dans LCC	Total	% Réseau	Résidu
UK	475	740	1215	15.73	6.54
USA	571	751	1322	17.12	4.67
Poland	97	154	251	3.25	3.08
Canada	37	59	96	1.24	1.92
Armenia	0	4	4	0.05	1.51

TABLE 7.6 – Sur- et sous-représentation des nationalités dans la composante principale (LCC)

pays	Hors LCC	Dans LCC	Total	% Réseau	Résidu
Germany	468	492	960	12.43	1.50
Lithuania	2	8	10	0.13	1.47
Estonia	8	16	24	0.31	1.33
Georgia	0	3	3	0.04	1.30
Serbia	7	14	21	0.27	1.24
Slovakia	8	13	21	0.27	0.93
Taiwan	1	3	4	0.05	0.78
Sweden	153	157	310	4.01	0.70
Iceland	6	9	15	0.19	0.68
Hungary	39	43	82	1.06	0.59
Australia	45	48	93	1.20	0.52
New Zealand	7	9	16	0.21	0.48
Bosnia and Herzegovina	1	2	3	0.04	0.47
Turkey	13	15	28	0.36	0.43
Switzerland	71	72	143	1.85	0.42
Finland	22	21	43	0.56	0.09
Kazakhstan	3	3	6	0.08	0.07
Iran	34	32	66	0.85	0.07
Ireland	19	18	37	0.48	0.07
Egypt	2	2	4	0.05	0.06
Latvia	2	2	4	0.05	0.06
Czech Republic	46	43	89	1.15	0.06
Denmark	48	43	91	1.18	-0.09
Russia	42	37	79	1.02	-0.14
Algeria	5	4	9	0.12	-0.15
Austria	56	49	105	1.36	-0.18
Cyprus	3	2	5	0.06	-0.26
Tunisia	3	2	5	0.06	-0.26

TABLE 7.6 – Sur- et sous-représentation des nationalités dans la composante principale (LCC)

pays	Hors LCC	Dans LCC	Total	% Réseau	Résidu
Vietnam	3	2	5	0.06	-0.26
Slovenia	41	34	75	0.97	-0.32
Peru	2	1	3	0.04	-0.36
Croatia	28	22	50	0.65	-0.40
Japan	4	2	6	0.08	-0.52
India	11	7	18	0.23	-0.55
Belgium	67	53	120	1.55	-0.59
Greece	10	6	16	0.21	-0.60
Brazil	6	3	9	0.12	-0.63
Mexico	5	2	7	0.09	-0.74
Bulgaria	7	3	10	0.13	-0.82
Chile	6	2	8	0.10	-0.94
China	17	9	26	0.34	-0.98
Morocco	8	3	11	0.14	-0.99
Mongolia	5	1	6	0.08	-1.11
Pakistan	4	0	4	0.05	-1.38
Israel	34	18	52	0.67	-1.38
Portugal	26	12	38	0.49	-1.45
Netherlands	90	59	149	1.93	-1.47
Norway	53	30	83	1.07	-1.55
Argentina	8	1	9	0.12	-1.59
South Korea	12	2	14	0.18	-1.82
Romania	19	5	24	0.31	-1.92
South Africa	34	6	40	0.52	-3.01
Spain	211	73	284	3.68	-5.41
France	663	340	1003	12.99	-6.41
Italy	355	134	489	6.33	-6.55




FIGURE 7.1 – Modélisation du réseau de coautorat avec Gephi. Les couleurs des noeuds correspondent au genre des individus (bleu pour les hommes, rouge pour les femmes, vert pour les NA ; et noir pour les publications. La taille du noeud dépend du degré dans le réseau biparti (sans projection).

TABLE 7.7 – Sur- et sous-représentation des nationalités dans le réseau de coautorat. Les titres des colonnes sont en français, mais les lignes en anglais, car c’est comme cela qu’elles sont encodées dans ma BDD.

Nationalité	Hors réseau	Dans réseau	Total	% population	Résidu
Sweden	253	310	563	3.30	3.47
China	5	26	31	0.18	3.20
Poland	225	251	476	2.79	2.44
South Korea	3	14	17	0.10	2.28
Estonia	10	24	34	0.20	2.20
Czech Republic	69	89	158	0.93	2.08
Vietnam	0	5	5	0.03	1.82
Croatia	37	50	87	0.51	1.70
Portugal	26	38	64	0.38	1.68
Kazakhstan	1	6	7	0.04	1.59
Mongolia	1	6	7	0.04	1.59
Turkey	18	28	46	0.27	1.58
United Kingdom	1359	1215	2574	15.09	1.49
Lithuania	4	10	14	0.08	1.46
Germany	1067	960	2027	11.88	1.43
Morocco	5	11	16	0.09	1.40
Norway	75	83	158	0.93	1.37
Russia	71	79	150	0.88	1.36
Slovakia	14	21	35	0.21	1.30
Algeria	4	9	13	0.08	1.29
Latvia	1	4	5	0.03	1.16
Denmark	88	91	179	1.05	1.12
New Zealand	11	16	27	0.16	1.08
Cyprus	2	5	7	0.04	1.03
Belgium	125	120	245	1.44	0.87
Egypt	2	4	6	0.04	0.78
Taiwan	2	4	6	0.04	0.78

TABLE 7.7 – Sur- et sous-représentation des nationalités dans le réseau de coautorat. Les titres des colonnes sont en français, mais les lignes en anglais, car c’est comme cela qu’elles sont encodées dans ma BDD.

Nationalité	Hors réseau	Dans réseau	Total	% population	Résidu
Bosnia and Herzegovina	2	3	5	0.03	0.49
Hungary	90	82	172	1.01	0.48
Slovenia	82	75	157	0.92	0.47
Austria	122	105	227	1.33	0.23
Australia	108	93	201	1.18	0.22
Greece	18	16	34	0.20	0.16
South Africa	48	40	88	0.52	0.03
Romania	30	24	54	0.32	-0.09
Finland	54	43	97	0.57	-0.13
Switzerland	178	143	321	1.88	-0.18
Chile	11	8	19	0.11	-0.20
Iran	86	66	152	0.89	-0.33
Mexico	11	7	18	0.11	-0.40
Hong Kong	4	2	6	0.04	-0.43
Japan	10	6	16	0.09	-0.46
Ireland	52	37	89	0.52	-0.51
Iceland	24	15	39	0.23	-0.63
Canada	132	96	228	1.34	-0.70
India	29	18	47	0.28	-0.71
Netherlands	202	149	351	2.06	-0.77
Spain	375	284	659	3.86	-0.81
Colombia	7	2	9	0.05	-1.03
Bulgaria	22	10	32	0.19	-1.18
Serbia	41	21	62	0.36	-1.33
Yugoslavia	9	2	11	0.06	-1.33
Tunisia	15	5	20	0.12	-1.34
Brazil	26	9	35	0.21	-1.72

TABLE 7.7 – Sur- et sous-représentation des nationalités dans le réseau de coautorat. Les titres des colonnes sont en français, mais les lignes en anglais, car c’est comme cela qu’elles sont encodées dans ma BDD.

Nationalité	Hors réseau	Dans réseau	Total	% population	Résidu
Israel	95	52	147	0.86	-1.78
Argentina	28	9	37	0.22	-1.89
United States of America	1809	1322	3131	18.35	-2.50
Italy	733	489	1222	7.16	-2.71
France	1414	1003	2417	14.17	-2.72

TABLE 7.8 – Statistiques descriptives des métriques de centralité par nationalité (Top 6)

pays	N	mean	median	std	min	q1	q3	max	iqr	metric
France	1003.0000	0.0001	0.0000	0.0004	0.0000	0.0000	0.0000	0.0090	0.0000	betweenness
Germany	960.0000	0.0001	0.0000	0.0005	0.0000	0.0000	0.0000	0.0090	0.0000	betweenness
Italy	489.0000	0.0000	0.0000	0.0002	0.0000	0.0000	0.0000	0.0043	0.0000	betweenness
Sweden	310.0000	0.0001	0.0000	0.0003	0.0000	0.0000	0.0000	0.0031	0.0000	betweenness
UK	1215.0000	0.0001	0.0000	0.0005	0.0000	0.0000	0.0000	0.0097	0.0000	betweenness
USA	1322.0000	0.0001	0.0000	0.0006	0.0000	0.0000	0.0000	0.0149	0.0000	betweenness
France	1003.0000	0.3718	0.3684	0.2435	0.0450	0.0878	0.6000	0.7500	0.5122	closeness
Germany	960.0000	0.3120	0.1189	0.2465	0.0527	0.0857	0.5714	0.7500	0.4857	closeness
Italy	489.0000	0.4257	0.5294	0.2292	0.0541	0.1096	0.6000	0.8333	0.4904	closeness
Sweden	310.0000	0.3129	0.1144	0.2533	0.0541	0.0835	0.6000	0.7500	0.5165	closeness
UK	1215.0000	0.2697	0.0999	0.2434	0.0452	0.0857	0.5556	0.7500	0.4698	closeness
USA	1322.0000	0.2902	0.1023	0.2457	0.0450	0.0915	0.5714	0.8333	0.4799	closeness
France	1003.0000	1.3759	1.0000	1.2775	1.0000	1.0000	1.0000	22.0000	0.0000	degree
Germany	960.0000	1.7240	1.0000	2.2691	1.0000	1.0000	2.0000	39.0000	1.0000	degree
Italy	489.0000	1.3129	1.0000	0.9089	1.0000	1.0000	1.0000	8.0000	0.0000	degree
Sweden	310.0000	1.7806	1.0000	1.6943	1.0000	1.0000	2.0000	15.0000	1.0000	degree
UK	1215.0000	1.5572	1.0000	1.4083	1.0000	1.0000	2.0000	16.0000	1.0000	degree
USA	1322.0000	1.4735	1.0000	1.5995	1.0000	1.0000	1.0000	28.0000	0.0000	degree
France	1003.0000	0.0029	0.0008	0.0084	0.0004	0.0005	0.0021	0.1318	0.0016	eigenvector
Germany	960.0000	0.0212	0.0016	0.0634	0.0004	0.0005	0.0073	0.6459	0.0067	eigenvector
Italy	489.0000	0.0046	0.0009	0.0142	0.0004	0.0005	0.0023	0.1275	0.0018	eigenvector
Sweden	310.0000	0.0072	0.0010	0.0203	0.0004	0.0005	0.0032	0.1955	0.0027	eigenvector
UK	1215.0000	0.0106	0.0017	0.0186	0.0004	0.0006	0.0147	0.2551	0.0141	eigenvector
USA	1322.0000	0.0141	0.0026	0.0221	0.0004	0.0006	0.0275	0.2414	0.0269	eigenvector
France	1003.0000	0.4202	0.4470	0.2715	0.0466	0.0951	0.6667	0.8333	0.5715	harmonic_closeness
Germany	960.0000	0.3485	0.1385	0.2744	0.0548	0.0945	0.6250	0.8333	0.5305	harmonic_closeness
Italy	489.0000	0.4749	0.5556	0.2540	0.0566	0.1260	0.6667	0.9000	0.5406	harmonic_closeness
Sweden	310.0000	0.3565	0.1349	0.2861	0.0566	0.0903	0.6667	0.8333	0.5764	harmonic_closeness
UK	1215.0000	0.3037	0.1155	0.2724	0.0466	0.0946	0.6000	0.8333	0.5054	harmonic_closeness
USA	1322.0000	0.3269	0.1197	0.2727	0.0466	0.1061	0.6250	0.9000	0.5190	harmonic_closeness
France	1003.0000	1.3759	1.0000	1.2775	1.0000	1.0000	1.0000	22.0000	0.0000	weighted degree
Germany	960.0000	1.7240	1.0000	2.2691	1.0000	1.0000	2.0000	39.0000	1.0000	weighted degree
Italy	489.0000	1.3129	1.0000	0.9089	1.0000	1.0000	1.0000	8.0000	0.0000	weighted degree
Sweden	310.0000	1.7806	1.0000	1.6943	1.0000	1.0000	2.0000	15.0000	1.0000	weighted degree
UK	1215.0000	1.5572	1.0000	1.4083	1.0000	1.0000	2.0000	16.0000	1.0000	weighted degree
USA	1322.0000	1.4735	1.0000	1.5995	1.0000	1.0000	1.0000	28.0000	0.0000	weighted degree

Topic	O	E	p	Repr.	Contrib. χ^2 (%)
ART_14	231	132.3	$< 0,001$	+11.03	20.21
ART_1	335	220.3	$< 0,001$	+10.25	16.40
ART_18	33	17.1	$< 0,001$	+4.78	4.10
ART_0	103	72.0	$< 0,001$	+4.61	3.68
ART_13	70	45.7	$< 0,001$	+4.49	3.55
CHAP_1	48	33.8	$= 0,002$	+3.05	1.65
CHAP_15	25	17.1	$= 0,017$	+2.38	1.02
ART_7	69	58.0	$= 0,069$ (<i>ns</i>)	—	0.58
CHAP_4	36	28.3	$= 0,072$ (<i>ns</i>)	—	0.57
ART_13	73	62.1	$= 0,081$ (<i>ns</i>)	—	0.53
CHAP_7	22	17.4	$= 0,171$ (<i>ns</i>)	—	0.34
CHAP_6	19	15.7	$= 0,300$ (<i>ns</i>)	—	0.19
CHAP_3	17	14.3	$= 0,381$ (<i>ns</i>)	—	0.14
CHAP_10	3	2.0	$= 0,411$ (<i>ns</i>)	—	0.12
ART_11	20	17.7	$= 0,505$ (<i>ns</i>)	—	0.08
CHAP_12	3	2.7	$= 0,839$ (<i>ns</i>)	—	0.01
ART_15	18	17.7	$= 0,937$ (<i>ns</i>)	—	0.00
CHAP_11	4	5.5	$= 0,442$ (<i>ns</i>)	—	0.11
ART_5	18	21.8	$= 0,310$ (<i>ns</i>)	—	0.18
CHAP_5	9	11.9	$= 0,293$ (<i>ns</i>)	—	0.20
CHAP_2	16	19.8	$= 0,292$ (<i>ns</i>)	—	0.20
ART_9	2	4.8	$= 0,117$ (<i>ns</i>)	—	0.44
CHAP_13	0	1.7	$= 0,108$ (<i>ns</i>)	—	0.47
ART_3	32	40.6	$= 0,093$ (<i>ns</i>)	—	0.50
ART_10	4	8.9	$= 0,044$	−2.02	0.73
CHAP_16	0	2.7	$= 0,042$	−2.04	0.75
ART_6	10	17.4	$= 0,028$	−2.20	0.86
ART_8	16	26.6	$= 0,011$	−2.55	1.16
ART_2	16	26.9	$= 0,009$	−2.62	1.22
CHAP_14	5	15.0	$= 0,001$	−3.20	1.83
CHAP_8	3	11.9	$= 0,001$	−3.20	1.84
ART_17	5	16.4	$< 0,001$	−3.48	2.17
ART_4	14	38.2	$< 0,001$	−4.88	4.21
CHAP_9	15	73.0	$< 0,001$	−8.56	12.65
NO_TOPIC	319	495.8	$< 0,001$	−11.75	17.32
$\chi^2(34) = 552.57, p = 0.0000, N = 4730$					

TABLE 7.9 – Sur- (+) et sous-représentation (−) des topics dans la composante principale (LCC) du réseau de coautorat. O : effectif observé ; E : effectif attendu sous indépendance ; *ns* : non significatif ($p \geq 0,05$) ; contrib. : part de chaque topic dans le χ^2 global (%).

Indicateur	BDD complète	Réseau complet	LCC
Min	1301	1975	1975
Max	2025	2025	2025
Moyenne	2008.3	2012.7	2013.4
Médiane	2013	2015	2016
Écart-type	20.7	10.2	9.2
Q1 (25%)	2004	2008	2009
Q3 (75%)	2018	2020	2020

TABLE 7.10 – Statistiques descriptives des années de publication pour les trois portées d’analyse (BDD complète / réseau complet / LCC).

TABLE 7.11 – Répartition par genre des auteurs selon les trois portées d’analyse : base de données complète (BDD, tous les auteurs et publications dans MongoDB), réseau complet (nœuds ayant au moins une arête dans le graphe biparti) et composante connexe principale (LCC). Le genre obtenu (via identifiants d’autorité) est prioritaire sur le genre imputé (NamSor + LLM).


Genre	N (BDD complète)	% (BDD complète)	N (Réseau complet)	% (Réseau complet)	N (LCC)	% (LCC)
Hommes	16364	57.4000	8187	54.5000	3641	58.4000
Femmes	9011	31.6000	4860	32.4000	2051	32.9000
Non renseigné	3125	11.0000	1965	13.1000	547	8.8000

Portée	Source	N	Part (%)
BDD complète	obtenu	15719	55.2000
BDD complète	impute	9657	33.9000
BDD complète	absent	3124	11.0000
Réseau complet	obtenu	7131	47.5000
Réseau complet	impute	5916	39.4000
Réseau complet	absent	1964	13.1000
Réseau complet	absent_mongo	1	0.0000
LCC	obtenu	3420	54.8000
LCC	impute	2272	36.4000
LCC	absent	547	8.8000


TABLE 7.12 – Sources du genre renseigné selon la portée d’analyse. *obtenu* : issu des identifiants d’autorité (IdRef, VIAF, Wikidata). *impute* : NamSor + vérification LLM. *absent_mongo* : auteur absent de MongoDB.

Langue	N (BDD complète)	% (BDD complète)	N (Réseau complet)	% (Réseau complet)	N (LCC)	% (LCC)
anglais	24051	70.2000	3305	71.9000	1314	81.9000
français	4271	12.5000	452	9.8000	114	7.1000
allemand	2007	5.9000	244	5.3000	90	5.6000
Slovenian	276	0.8000	44	1.0000	28	1.7000
russe	675	2.0000	192	4.2000	28	1.7000
espagnol	1318	3.8000	196	4.3000	12	0.7000
italien	1034	3.0000	79	1.7000	7	0.4000
polonais	91	0.3000	12	0.3000	4	0.2000
néerlandais	53	0.2000	18	0.4000	4	0.2000
Inconnu	496	1.4000	56	1.2000	3	0.2000


TABLE 7.13 – Top 10 des langues de publication selon les trois portées d’analyse (BDD complète / réseau complet / LCC). Champ `language_name` normalisé depuis MongoDB.




(a) Eigenvector



(b) Degree




(c) Betweenness




(d) Closeness


FIGURE 7.2 – Distributions log-log des principales mesures de centralité des auteurs, colorées par nationalité.




(a) Eigenvector



(b) Degree



(c) Betweenness



(d) Closeness

FIGURE 7.3 – Distributions log-log des principales mesures de centralité des publications, colorées par langue.

Nationalité	N (BDD complète)	% (BDD complète)	N (Réseau complet)	% (Réseau complet)	N (LCC)	% (LCC)
United States of America	3131	22.8000	1322	21.6000	751	25.3000
United Kingdom	2573	18.7000	1215	19.8000	740	24.9000
Germany	2027	14.8000	960	15.7000	492	16.6000
France	2417	17.6000	1003	16.4000	340	11.4000
Sweden	563	4.1000	310	5.1000	157	5.3000
Poland	476	3.5000	251	4.1000	154	5.2000
Italy	1222	8.9000	489	8.0000	134	4.5000
Spain	659	4.8000	284	4.6000	73	2.5000
Switzerland	321	2.3000	143	2.3000	72	2.4000
Netherlands	351	2.6000	149	2.4000	59	2.0000

TABLE 7.14 – Top 10 des nationalités représentées selon les trois portées d’analyse (BDD complète / réseau complet / LCC). Un auteur multinational est compté une fois par nationalité.






FIGURE 7.4 – Boxplot de la betweenness par nationalité, en excluant les valeurs nulles du calcul

topic_id	N (BDD complète)	% (BDD complète)	N (Réseau complet)	% (Réseau complet)	N (LCC)	% (LCC)
ART_1	1053	4.8000	646	19.7000	335	25.8000
ART_14	487	2.2000	388	11.8000	231	17.8000
ART_0	1144	5.2000	211	6.4000	103	7.9000
ART_13	522	2.4000	182	5.5000	73	5.6000
ART_13	458	2.1000	134	4.1000	70	5.4000
ART_7	618	2.8000	170	5.2000	69	5.3000
CHAP_1	1137	5.2000	99	3.0000	48	3.7000
CHAP_4	826	3.8000	83	2.5000	36	2.8000
ART_18	803	3.7000	50	1.5000	33	2.5000
ART_3	904	4.1000	119	3.6000	32	2.5000
CHAP_15	365	1.7000	50	1.5000	25	1.9000
CHAP_7	692	3.2000	51	1.6000	22	1.7000
ART_11	516	2.4000	52	1.6000	20	1.5000
CHAP_6	835	3.8000	46	1.4000	19	1.5000
ART_5	677	3.1000	64	2.0000	18	1.4000
ART_15	479	2.2000	52	1.6000	18	1.4000
CHAP_3	867	4.0000	42	1.3000	17	1.3000
ART_2	1066	4.9000	79	2.4000	16	1.2000
CHAP_2	1107	5.1000	58	1.8000	16	1.2000
ART_8	592	2.7000	78	2.4000	16	1.2000
CHAP_9	302	1.4000	214	6.5000	15	1.2000
ART_4	727	3.3000	112	3.4000	14	1.1000
ART_6	725	3.3000	51	1.6000	10	0.8000
CHAP_5	774	3.5000	35	1.1000	9	0.7000
CHAP_14	1080	4.9000	44	1.3000	5	0.4000
ART_17	378	1.7000	48	1.5000	5	0.4000
ART_10	282	1.3000	26	0.8000	4	0.3000
CHAP_11	278	1.3000	16	0.5000	4	0.3000
CHAP_12	218	1.0000	8	0.2000	3	0.2000
CHAP_10	291	1.3000	6	0.2000	3	0.2000
CHAP_8	739	3.4000	35	1.1000	3	0.2000
ART_18	77	0.4000	3	0.1000	2	0.2000
ART_9	596	2.7000	14	0.4000	2	0.2000
ART_15	31	0.1000	1	0.0000	1	0.1000
CHAP_13	99	0.5000	5	0.2000	0	0.0000
CHAP_16	93	0.4000	8	0.2000	0	0.0000
ART_15	1	0.0000	0	0.0000	0	0.0000


TABLE 7.15 – Fréquences des thèmes des publications selon les trois portées d’analyse (champ `topic_analysis.label` dans MongoDB). Les publications sans `topic_analysis` sont exclues.




(a) Eigenvector



(b) Betweenness




(c) Closeness




(d) Degree


FIGURE 7.5 – Courbes de Lorenz des principales mesures de centralité des auteurs.




(a) Eigenvector



(b) Betweenness



(c) Closeness



(d) Degree

FIGURE 7.6 – Courbes de Lorenz des principales mesures de centralité des publications.

ID	Label Thématique	Mots représentatifs
0	Monde nordique viking	<i>viking, sweden, scandinavian, scandinavia, norse, ice-land, norway</i>
1	Bioarchéologie et médecine	<i>analysis, population, ancient, period, evidence, genetic, human</i>
2	Religion, théologie et scolastique	<i>pagan, christian, god, original, religious, church, saints</i>
3	Littérature, philologie et musique	<i>english, poetry, england, music, literature, norman, french</i>
4	Art, architecture et iconographie	<i>art, manuscripts, architecture, manuscript, sculpture, textiles, england</i>
5	Méditerranée, Islam et judaïsme	<i>spain, jews, jewish, arabic, islam, saracens, islamic</i>
6	Antiquité tardive et royaumes barbares	<i>italy, merovingian, roman, barbarians, byzantine, norman, barbarian</i>
7a	Europe centrale, orientale et Byzance	<i>slavs, archaeological, slavic, archaeology, historical, hungary, poland</i>
7b	Monde mongol, Russie et Asie centrale	<i>mongol, mongols, china, empire, invasion, russian, golden</i>
8	Histoire sociale et économique	<i>slaves, slave, slavery, trade, europe, african, migration</i>
9	France et Italie médiévales	<i>italy, church, fresco, france, miniature, san, mosaic</i>
11	Droit, institutions et guerre	<i>norman, law, england, legal, war, burgundian, battle</i>
13	Archéologie médiévale	<i>civilization, roman, england, italy, longobard, ireland, settlement</i>
14	Histoire environnementale	<i>climate, holocene, evidence, sweden, central, changes, germany</i>
15	Genre, corps et émotions	<i>women, england, gender, female, power, europe, literature</i>
18	Recensions et bruit éditorial	<i>reviews, nan, buchbesprechungen, short, notices, london, eds</i>

TABLE 7.16 – Synthèse globale des thématiques identifiées pour les articles ($K = 17$)

Topic	<i>n</i>	Termes c-TF-IDF (top-15)
1	1137	<i>saxon, archaeology, chapter, ad, landscape, anglo, landscapes, textiles</i>
2	1107	<i>law, norman, military, society, power, england, anglo, world</i>
3	867	<i>vikings, age, scandinavia, scandinavian, north, denmark, vikings, norse</i>
4	826	<i>language, writing, latin, england, encyclopedia, honour, women, palgrave</i>
5	774	<i>women, female, rape, literature, scots, culture, gender, english</i>
6	835	<i>jews, islamic, jewish, islam, east, muslims, christians, othering</i>
7	692	<i>slavs, barbarian, identity, europe, byzantine, identities, ethnicity, slavic</i>
8	739	<i>magic, english, poetry, music, chaucer, renaissance, literature, heroes</i>
9	302	<i>conference, international, ieee, systems, analysis, digital, heritage, virtual</i>
10	291	<i>chinese, dariali, bibliographical, guide, mongol, texts, huns, gorge</i>
11	278	<i>slave, slavery, slaves, spain, spanish, hispanic, trade, iberia</i>
12	218	<i>scotland, scottish, scots, arthurian, literature, legend, alexander, nation</i>
13	99	<i>corps, pierre, vergnolle, mise, quadris, lapidibus, oeuvre, sa</i>
14	1080	<i>antiquity, pagan, christian, philosophy, renaissance, religious, chapter, new</i>
15	365	<i>rome, roman, italy, fall, charlemagne, oxford, antiquity, handbook</i>
16	93	<i>science, medical, astronomy, hospital, medicine, mathematics, practice, scientific</i>
Total		9 703 documents

TABLE 7.17 – Représentation thématique des clusters des chapitres (mots-clés c-TF-IDF).

Topic	Contenu dominant	Hors réseau	Dans réseau
T0	Religion, Église, droit canonique	0,48	−1,08
T1	Monde romain et barbares	1,28	−2,87
T2	Judaïsme et christianisme médiéval	0,08	−0,17
T3	Archéologie céramique et numismatique	0,14	−0,30
T4	Archéogénomique et archéologie quantitative	−3,67	8,24
T5	Histoire orientale et monde islamique	−0,58	1,30
T6	Paléolimnologie et paléoclimat	−1,04	2,33
T7	Art, archéologie et monde nordique	−0,83	1,86
T8	Genre, droit et société médiévale	0,71	−1,60
T9	Histoire britannique et irlandaise	0,05	−0,10
T10	<i>Fond commun</i> (culture textuelle)	1,52	−3,40
T11	Méditerranée normande et islamique	−0,78	1,76
T12	Sagas islandaises	−0,31	0,30

TABLE 7.18 – Résidus standardisés : surreprésentation des topics LDA dans le réseau de coautorat et hors réseau (topic majoritaire du document). Sur 756 documents, 125 sont dans le réseau, soit 16% du corpus. Un résidu positif indique une surreprésentation, négatif une sous-représentation.

Topic	Contenu dominant	CCP	Autres CC
T0	Religion, Église, droit canonique	−0,68	0,62
T1	Monde romain et barbares	0,09	−0,08
T2	Judaïsme et christianisme médiéval	−1,17	1,07
T3	Archéologie céramique et numismatique	0,09	−0,08
T4	Archéogénomique et archéologie quantitative	2,71	−2,48
T5	Histoire orientale et monde islamique	−0,63	0,58
T6	Paléolimnologie et paléoclimat	1,61	−1,48
T7	Art, archéologie et monde nordique	−1,22	1,12
T8	Genre, droit et société médiévale	−0,85	0,78
T9	Histoire britannique et irlandaise	−1,23	1,12
T10	<i>Fond commun</i> (culture textuelle)	−0,54	0,49
T11	Méditerranée normande et islamique	−0,67	0,61
T12	Sagas islandaises	−0,31	0,29

TABLE 7.19 – Résidus standardisés : surreprésentation des topics LDA dans la composante connexe principale (CCP) et dans les autres composantes connexes. Sur 756 documents, 125 sont dans le réseau, soit 16% du corpus. Un résidu positif indique une surreprésentation relative.




FIGURE 7.7 – Boxplot de la closeness par thème




FIGURE 7.8 – Boxplot de la betweenness par thème




FIGURE 7.9 – Boxplot de l'eigenvector par thème








FIGURE 7.10 – Boxplot du degré par thème




(a) Heatmap des corrélations des indicateurs de centralité des publications (projection Newman) (b) Heatmap des corrélations des indicateurs de centralité des publications (projection simple)




(c) Heatmap des corrélations des indicateurs de centralité des auteurs (projection Newman) (d) Heatmap des corrélations des indicateurs de centralité des auteurs (projection simple)

Évolution des indicateurs de centralité — Publications
(moyenne sur la LCC, réseau cumulatif — barres grises = taille LCC)



(a) Evolution temporelle des moyennes des indicateurs de centralité des publications
(LCC reconstituée à chaque pas de temps)

Évolution des indicateurs de centralité — Auteurs
(moyenne sur la LCC, réseau cumulatif — barres grises = taille LCC)



(b) Evolution temporelle des moyennes des indicateurs de centralité des auteurs (LCC
reconstituée à chaque pas de temps)

FIGURE 7.12 – Evolution temporelle des moyennes des indicateurs de centralité des publications et des auteurs de la LCC




FIGURE 7.13 – Evolution du coefficient de Gini des indicateurs de centralité des publications de la LCC




FIGURE 7.14 – Evolution du coefficient de Gini des indicateurs de centralité des auteurs de la LCC



FIGURE 7.15 – Corrélation entre l'année d'entrée dans le réseau et les indicateurs de centralité des publications dans la LCC

Corrélation entre année d'entrée dans la LCC et centralité finale
Auteurs (Spearman ρ , snapshot final, réseau cumulatif)




FIGURE 7.16 – Corrélation entre l'année d'entrée dans le réseau et les indicateurs de centralité des auteurs dans la LCC




FIGURE 7.17 – Matrice des communautés détectées par l’algorithme de Leiden, modularité de Barber

7.5 Annexes pour la section 4.5




FIGURE 7.18 – Corrélation entre la distribution temporelle des documents dans la base de données et dans notre corpus : l’année 2014, en tant que valeur abhorrante, a été écartée d’un calcul de corrélation




FIGURE 7.19 – Fréquence des mots en fonction du rang dans notre corpus (756 documents)

TABLE 7.20 – Top 5 des lemmes (TF-IDF) par année

Année	Top 1	Top 2	Top 3	Top 4	Top 5
1975	flood	level	year	water	king

suite page suivante


Année	Top 1	Top 2	Top 3	Top 4	Top 5
1976	duke	patrician	rector	count	official
1977	child	slave	suicide	coroner	edition
1978	witch	croatian	fertility	slave	history
1979	sect	ovidian	army	danish	borough
1980	art	game	painter	like	play
1981	prosopographical	crime	poem	poet	social
1982	russian	coin	grammatical	illegible	boy
1983	state	figure	diagram	photo	rice
1984	byzantine	statuette	slavic	festival	cult
1985	salt	catalog	saharan	manuscript	cataloging
1986	poem	sign	cynewulf	sociology	elephant
1987	marriage	man	reform	cardinal	fiscal
1988	writing	utterance	cursive	act	kind
1989	woman	man	wife	husband	image
1990	pagan	temple	statue	monument	christian
1991	public	private	monk	burgher	like
1992	woman	missionary	king	station	mission
1993	psalter	site	medieval	sherd	glass
1994	defendant	witness	capital	accuser	accuse
1995	revolt	peasant	woman	line	reconsider
1996	rime	ende	foundation	law	irish
1997	wind	arian	bishop	dalmatian	medieval
1998	archaeology	migration	liturgical	archaeologist	german
1999	arch	history	jury	proof	land
2000	elect	advisor	family	silver	barbarian
2001	language	manganese	immunity	reindeer	minstrel
2002	lawbook	divorce	roman	woman	coin
2003	poetry	medieval	poem	scottish	poet
2004	permission	manuscript	prohibit	arabic	owner


suite page suivante

Année	Top 1	Top 2	Top 3	Top 4	Top 5
2005	saga	brooch	buckle	fibulae	fibula
2006	tradition	history	king	poem	english
2007	performance	fool	play	world	blackness
2008	aldhelm	church	history	letter	people
2009	muslim	town	silk	sicilian	commercial
2010	armenian	angel	history	king	pagan
2011	incest	daughter	site	specie	settlement
2012	cistercian	like	church	christian	piano
2013	lake	temperature	narrative	motet	history
2014	infamia	woman	people	lapidary	rye
2015	buddhist	deer	medieval	history	man
2016	roman	history	medieval	people	man
2017	castle	muslim	anger	history	religious
2018	history	horse	art	language	latin
2019	history	people	pleated	textile	medieval
2020	trafficking	moneyer	slave	unicorn	building
2021	history	medieval	people	roman	saga
2022	borough	jewish	ware	sample	glaze
2023	glass	dance	medieval	site	material
2024	chicken	radiocarbon	date	king	graf
2025	ancestry	individual	population	genetic	medieval

7.5.1 Les Analyses Factorielles des Correspondances

L'AFC lemme x année








FIGURE 7.22 – Décroissance factorielle de l’AFC lemme-année




FIGURE 7.23 – AFC, facteur 1 et 2, seuillés en ligne à 0.5, avec 1989 en variable supplémentaire, du tableau lemme-année

	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
1975	-0.09	0.23	0.14	0.63	0.06	0.14	-0.37	5.71	0.21	2.05	-0.03	0.05	0.42	9.46	0.60	23.72	-0.42	12.34	0.06	0.27
1976	-0.05	0.02	0.00	0.00	-0.10	0.12	0.04	0.02	0.00	0.00	0.12	0.24	0.05	0.04	0.18	0.67	-0.03	0.03	0.11	0.26
1977	-0.28	1.21	0.05	0.05	0.01	0.00	0.14	0.50	-0.01	0.00	0.16	0.72	0.04	0.06	-0.06	0.12	-0.19	1.45	0.16	1.15
1978	-0.02	0.01	-0.03	0.02	-0.06	0.08	0.09	0.24	-0.05	0.07	0.03	0.03	-0.09	0.28	0.07	0.21	-0.08	0.30	0.00	0.00
1979	-0.15	0.31	0.38	2.55	0.18	0.63	-0.09	0.18	-0.12	0.34	0.39	4.08	0.06	0.09	-0.61	13.25	-0.23	2.05	0.00	0.00
1980	-0.34	1.36	0.07	0.06	-0.04	0.03	-0.01	0.00	-0.26	1.46	0.18	0.73	0.10	0.26	0.23	1.56	-0.11	0.41	-0.16	0.79
1981	-0.15	0.22	0.14	0.23	-0.01	0.00	0.14	0.29	-0.02	0.01	0.08	0.13	0.09	0.17	-0.04	0.05	-0.13	0.43	-0.02	0.01
1982	-0.20	1.05	0.06	0.13	-0.05	0.09	0.25	2.61	-0.02	0.03	0.01	0.01	0.20	2.12	0.16	1.76	-0.08	0.41	0.01	0.01
1983	-0.09	0.08	0.04	0.02	-0.05	0.03	-0.04	0.03	-0.01	0.00	0.07	0.11	0.02	0.01	0.06	0.12	-0.16	0.81	0.03	0.03
1984	0.03	0.01	-0.08	0.04	-0.11	0.11	0.09	0.09	-0.16	0.27	0.03	0.01	-0.21	0.58	0.27	1.11	-0.19	0.60	0.03	0.02
1985	0.09	0.09	0.01	0.00	0.00	0.00	0.17	0.47	0.21	0.74	0.07	0.10	-0.00	0.00	0.09	0.21	-0.19	0.98	-0.01	0.00
1986	-0.31	1.05	0.24	0.83	0.03	0.01	0.01	0.00	-0.18	0.64	0.06	0.07	0.13	0.41	-0.20	1.19	-0.12	0.40	-0.18	1.03
1987	-0.28	0.11	-0.04	0.00	-0.09	0.02	0.02	0.00	-0.00	0.00	-0.05	0.01	-0.00	0.00	-0.01	0.00	0.09	0.03	0.09	0.03
1988	-0.17	0.19	0.16	0.19	-0.14	0.19	0.11	0.13	-0.11	0.14	-0.08	0.08	0.07	0.07	0.12	0.22	-0.01	0.00	-0.11	0.22
1989	-0.78	29.86	-0.83	42.12	-0.12	0.97	-0.31	7.57	0.25	5.61	0.12	1.28	-0.22	5.07	-0.04	0.25	-0.04	0.19	-0.01	0.02
1990	0.09	0.06	-0.03	0.01	-0.17	0.34	0.04	0.02	-0.30	1.31	0.07	0.08	-0.10	0.16	0.18	0.71	-0.01	0.00	-0.07	0.10
1991	-0.21	0.59	0.06	0.07	0.01	0.00	0.05	0.05	-0.10	0.27	0.11	0.31	0.06	0.12	0.06	0.12	0.01	0.00	0.02	0.02
1992	-0.29	1.66	-0.05	0.07	-0.05	0.09	0.11	0.41	0.02	0.01	0.10	0.40	0.07	0.22	0.08	0.30	0.01	0.00	-0.04	0.10
1993	0.13	0.38	-0.03	0.03	0.14	0.64	0.03	0.04	-0.01	0.01	0.10	0.46	-0.03	0.04	-0.05	0.12	-0.45	11.99	-0.00	0.00
1994	-0.18	0.97	0.04	0.06	-0.12	0.68	0.06	0.18	-0.03	0.04	-0.02	0.03	0.13	1.16	0.17	2.38	-0.15	1.98	-0.00	0.00
1995	-0.26	0.98	0.05	0.04	0.02	0.01	-0.09	0.19	-0.07	0.14	0.19	1.05	-0.00	0.00	-0.32	3.90	0.01	0.00	0.03	0.04
1996	-0.11	0.51	0.02	0.03	0.02	0.03	0.06	0.28	-0.14	1.43	0.04	0.11	-0.04	0.14	-0.00	0.00	0.02	0.05	0.11	1.45
1997	-0.06	0.21	0.08	0.38	-0.03	0.05	0.01	0.00	-0.14	1.86	0.10	1.01	-0.05	0.25	0.09	1.14	-0.13	2.16	0.08	0.91
1998	-0.16	1.05	0.17	1.45	0.00	0.00	0.03	0.04	-0.08	0.46	0.08	0.45	-0.12	1.17	-0.30	9.10	-0.08	0.72	-0.01	0.02
1999	-0.17	1.47	0.16	1.71	-0.03	0.09	0.03	0.07	0.02	0.03	0.13	1.81	0.08	0.69	-0.17	4.01	-0.09	1.15	0.02	0.07
2000	-0.15	0.46	0.02	0.01	-0.08	0.20	0.16	0.89	-0.26	2.61	-0.07	0.19	-0.17	1.32	0.22	2.53	0.16	1.54	1.10	70.55
2001	-0.17	0.69	0.12	0.41	0.02	0.01	0.04	0.06	-0.06	0.15	0.05	0.12	-0.03	0.05	-0.04	0.08	-0.18	2.16	-0.03	0.05
2002	-0.14	0.37	-0.01	0.00	-0.12	0.42	0.08	0.21	-0.01	0.01	0.02	0.01	-0.17	1.27	-0.08	0.32	0.06	0.23	0.12	0.88
2003	-0.22	0.86	0.18	0.70	0.03	0.03	0.13	0.50	-0.16	0.83	0.06	0.12	0.16	0.92	-0.00	0.00	0.05	0.12	-0.04	0.07
2004	-0.31	7.68	0.07	0.55	-0.25	7.31	0.36	17.12	0.33	15.87	-0.32	15.45	0.29	13.78	-0.12	3.08	0.04	0.31	0.03	0.23
2005	0.00	0.00	0.03	0.02	0.09	0.31	0.02	0.02	0.07	0.25	0.03	0.06	-0.13	0.91	0.18	2.24	-0.11	0.83	-0.11	0.93
2006	-0.23	1.35	0.31	3.26	0.14	0.75	-0.10	0.46	-0.11	0.55	0.12	0.73	0.11	0.62	-0.25	4.25	0.04	0.10	-0.02	0.04
2007	-0.11	0.66	0.05	0.18	0.05	0.16	0.06	0.32	-0.05	0.23	-0.05	0.23	-0.04	0.13	0.06	0.40	0.01	0.03	-0.14	2.85
2008	-0.09	0.56	0.12	1.38	-0.06	0.33	0.01	0.01	-0.15	2.93	0.13	2.20	-0.02	0.07	-0.03	0.14	0.05	0.55	-0.01	0.01
2009	0.31	6.18	-0.07	0.37	0.07	0.43	0.23	5.88	0.37	15.72	0.55	39.57	0.15	3.06	0.08	1.14	0.09	1.35	0.04	0.23
2010	-0.10	0.55	0.05	0.19	-0.05	0.19	0.06	0.34	-0.12	1.52	-0.09	0.84	0.05	0.35	0.20	6.22	0.06	0.59	-0.19	5.85
2011	-0.02	0.06	-0.21	6.10	0.67	71.14	0.12	2.73	-0.03	0.14	-0.15	4.86	0.09	1.95	-0.04	0.42	0.00	0.00	0.05	0.80
2012	-0.07	0.47	0.10	0.99	-0.03	0.11	-0.07	0.75	-0.11	1.86	0.08	1.07	0.07	0.89	-0.07	1.19	-0.12	3.16	0.01	0.05
2013	-0.00	0.00	0.31	19.25	0.10	2.45	-0.35	31.18	0.28	22.15	-0.09	2.45	-0.07	1.44	0.00	0.01	0.07	1.97	0.05	1.08
2014	-0.03	0.09	-0.04	0.25	-0.01	0.02	-0.01	0.02	0.01	0.01	0.06	0.73	-0.02	0.11	0.04	0.51	0.07	1.30	-0.04	0.41

2015	-0.09	1.09	0.02	0.04	0.09	1.68	-0.03	0.18	-0.14	5.05	-0.04	0.50	0.00	0.01	0.08	2.56	0.10	3.82	-0.09	3.17
2016	-0.03	0.12	0.07	0.80	-0.02	0.07	-0.01	0.03	-0.09	1.93	0.01	0.03	-0.04	0.35	0.02	0.17	0.11	4.72	-0.04	0.73
2017	0.07	0.67	-0.03	0.18	0.02	0.10	0.09	1.59	0.09	1.96	0.07	1.15	-0.02	0.06	0.00	0.00	0.22	16.53	-0.07	1.57
2018	-0.03	0.12	0.03	0.12	-0.10	1.96	-0.00	0.00	-0.11	3.19	-0.04	0.41	-0.00	0.00	0.05	0.84	0.02	0.17	-0.00	0.00
2019	0.06	0.33	-0.01	0.02	0.01	0.03	-0.01	0.01	-0.03	0.19	-0.07	1.08	-0.13	3.60	0.02	0.12	0.00	0.00	-0.07	1.54
2020	0.18	4.89	-0.03	0.12	0.01	0.01	0.03	0.15	0.04	0.44	0.04	0.48	-0.09	2.58	-0.04	0.58	-0.15	8.32	0.03	0.36
2021	0.10	1.49	-0.02	0.04	-0.07	1.00	-0.03	0.21	-0.03	0.32	0.02	0.18	-0.05	0.67	-0.02	0.11	0.12	5.88	0.04	0.81
2022	0.27	16.33	-0.22	13.37	-0.12	4.72	-0.19	12.83	-0.09	3.18	-0.06	1.59	0.23	25.36	-0.09	4.74	0.01	0.09	0.03	0.42
2023	0.22	6.36	-0.07	0.82	-0.04	0.27	0.10	2.05	0.05	0.70	-0.03	0.27	-0.13	4.94	0.03	0.23	-0.10	3.98	-0.04	0.75
2024	0.10	0.98	-0.02	0.07	-0.09	1.16	0.06	0.63	0.04	0.28	-0.03	0.16	-0.16	5.25	0.04	0.31	0.01	0.01	-0.01	0.01
2025	0.20	3.96	-0.01	0.01	-0.07	0.78	0.13	2.70	0.08	1.01	-0.25	12.18	-0.19	7.70	-0.08	1.61	-0.12	3.74	-0.01	0.06

TABLE 7.21 – Résultats pour l'ensemble des facteurs

	1	2	3	4	5	6	7	8	9	10
1975	0.01	0.01	0.00	0.10	0.03	0.00	0.13	0.27	0.13	0.00
1976	0.00	0.00	0.01	0.00	0.00	0.01	0.00	0.03	0.00	0.01
1977	0.07	0.00	0.00	0.02	0.00	0.02	0.00	0.00	0.03	0.02
1978	0.00	0.00	0.01	0.01	0.00	0.00	0.01	0.01	0.01	0.00
1979	0.01	0.10	0.02	0.01	0.01	0.10	0.00	0.25	0.04	0.00
1980	0.12	0.01	0.00	0.00	0.07	0.03	0.01	0.06	0.01	0.03
1981	0.03	0.03	0.00	0.03	0.00	0.01	0.01	0.00	0.03	0.00
1982	0.06	0.01	0.00	0.09	0.00	0.00	0.05	0.04	0.01	0.00
1983	0.01	0.00	0.00	0.00	0.00	0.01	0.00	0.01	0.04	0.00
1984	0.00	0.00	0.01	0.01	0.01	0.00	0.03	0.04	0.02	0.00
1985	0.01	0.00	0.00	0.03	0.04	0.01	0.00	0.01	0.04	0.00
1986	0.08	0.05	0.00	0.00	0.03	0.00	0.01	0.03	0.01	0.03
1987	0.06	0.00	0.01	0.00	0.00	0.00	0.00	0.00	0.01	0.01
1988	0.01	0.01	0.01	0.00	0.00	0.00	0.00	0.01	0.00	0.00
1989	0.39	0.44	0.01	0.06	0.04	0.01	0.03	0.00	0.00	0.00
1990	0.01	0.00	0.02	0.00	0.06	0.00	0.01	0.02	0.00	0.00
1991	0.08	0.01	0.00	0.00	0.02	0.02	0.01	0.01	0.00	0.00
1992	0.14	0.01	0.01	0.02	0.00	0.02	0.01	0.01	0.00	0.00
1993	0.02	0.00	0.03	0.00	0.00	0.01	0.00	0.00	0.27	0.00
1994	0.05	0.00	0.02	0.01	0.00	0.00	0.03	0.05	0.04	0.00
1995	0.06	0.00	0.00	0.01	0.01	0.03	0.00	0.10	0.00	0.00
1996	0.03	0.00	0.00	0.01	0.04	0.00	0.00	0.00	0.00	0.03
1997	0.01	0.02	0.00	0.00	0.07	0.04	0.01	0.03	0.06	0.02
1998	0.06	0.07	0.00	0.00	0.01	0.01	0.03	0.20	0.01	0.00
1999	0.09	0.08	0.00	0.00	0.00	0.06	0.02	0.09	0.03	0.00
2000	0.01	0.00	0.00	0.02	0.04	0.00	0.02	0.03	0.02	0.76
2001	0.05	0.03	0.00	0.00	0.01	0.00	0.00	0.00	0.06	0.00
2002	0.03	0.00	0.02	0.01	0.00	0.00	0.05	0.01	0.01	0.03
2003	0.07	0.05	0.00	0.03	0.04	0.01	0.04	0.00	0.00	0.00
2004	0.15	0.01	0.10	0.20	0.17	0.15	0.13	0.02	0.00	0.00
2005	0.00	0.00	0.01	0.00	0.01	0.00	0.02	0.05	0.02	0.02

2006	0.07	0.14	0.03	0.01	0.02	0.02	0.01	0.08	0.00	0.00
2007	0.04	0.01	0.01	0.01	0.01	0.01	0.00	0.01	0.00	0.07
2008	0.03	0.07	0.01	0.00	0.10	0.07	0.00	0.00	0.01	0.00
2009	0.13	0.01	0.01	0.08	0.19	0.43	0.03	0.01	0.01	0.00
2010	0.03	0.01	0.01	0.01	0.04	0.02	0.01	0.12	0.01	0.10
2011	0.00	0.08	0.80	0.03	0.00	0.04	0.01	0.00	0.00	0.01
2012	0.03	0.04	0.00	0.02	0.06	0.03	0.02	0.02	0.06	0.00
2013	0.00	0.28	0.03	0.35	0.23	0.02	0.01	0.00	0.01	0.01
2014	0.01	0.02	0.00	0.00	0.00	0.04	0.01	0.02	0.05	0.01
2015	0.05	0.00	0.05	0.01	0.13	0.01	0.00	0.04	0.06	0.05
2016	0.01	0.04	0.00	0.00	0.07	0.00	0.01	0.00	0.12	0.02
2017	0.03	0.01	0.00	0.04	0.04	0.02	0.00	0.00	0.22	0.02
2018	0.01	0.01	0.06	0.00	0.08	0.01	0.00	0.01	0.00	0.00
2019	0.02	0.00	0.00	0.00	0.01	0.04	0.12	0.00	0.00	0.04
2020	0.21	0.00	0.00	0.00	0.01	0.01	0.05	0.01	0.13	0.01
2021	0.07	0.00	0.03	0.01	0.01	0.00	0.01	0.00	0.11	0.01
2022	0.29	0.19	0.06	0.14	0.03	0.01	0.21	0.03	0.00	0.00
2023	0.29	0.03	0.01	0.06	0.02	0.01	0.11	0.00	0.07	0.01
2024	0.06	0.00	0.04	0.02	0.01	0.01	0.14	0.01	0.00	0.00
2025	0.14	0.00	0.02	0.06	0.02	0.21	0.12	0.02	0.05	0.00

TABLE 7.22 – Cos2 pour l'ensemble des facteurs

	facteur	1	2	3	4	5	6	7	8	9
century	0.10	0.04	0.06	0.10	0.12	0.10	0.06	0.00	0.08	0.01
medieval	0.05	0.01	0.08	0.10	0.01	0.07	0.00	0.03	0.00	0.10
early	0.17	0.02	0.01	0.02	0.01	0.03	0.13	0.00	0.22	0.00
use	0.06	0.04	0.12	0.03	0.04	0.06	0.03	0.05	0.02	0.00
history	0.02	0.05	0.11	0.02	0.00	0.05	0.03	0.04	0.04	0.00
new	0.01	0.05	0.01	0.00	0.14	0.09	0.00	0.03	0.02	0.00
make	0.31	0.07	0.05	0.01	0.00	0.03	0.00	0.04	0.02	0.00
time	0.02	0.00	0.00	0.05	0.00	0.01	0.02	0.12	0.03	0.00

work	0.25	0.04	0.12	0.11	0.02	0.08	0.00	0.02	0.00	0.02
text	0.04	0.05	0.00	0.01	0.00	0.11	0.01	0.04	0.00	0.05
first	0.00	0.02	0.04	0.14	0.00	0.06	0.00	0.01	0.06	0.01
university	0.08	0.00	0.00	0.00	0.00	0.02	0.02	0.02	0.07	0.03
find	0.02	0.02	0.00	0.02	0.03	0.00	0.00	0.03	0.03	0.01
roman	0.22	0.00	0.03	0.00	0.03	0.05	0.03	0.02	0.04	0.07
late	0.50	0.05	0.05	0.00	0.00	0.01	0.04	0.01	0.01	0.00
king	0.04	0.01	0.02	0.02	0.01	0.01	0.07	0.10	0.00	0.03
study	0.03	0.00	0.03	0.02	0.02	0.04	0.09	0.08	0.02	0.01
even	0.36	0.02	0.00	0.01	0.00	0.01	0.02	0.07	0.00	0.01
well	0.06	0.00	0.00	0.03	0.02	0.04	0.03	0.20	0.01	0.04
people	0.01	0.01	0.07	0.00	0.08	0.04	0.05	0.03	0.09	0.00
christian	0.21	0.02	0.06	0.14	0.07	0.01	0.02	0.01	0.08	0.00
church	0.04	0.01	0.04	0.01	0.19	0.07	0.00	0.00	0.00	0.00
man	0.52	0.31	0.00	0.05	0.02	0.00	0.00	0.00	0.00	0.00
part	0.01	0.00	0.19	0.10	0.01	0.00	0.02	0.02	0.01	0.01
take	0.22	0.06	0.00	0.00	0.00	0.06	0.16	0.08	0.03	0.00
press	0.13	0.00	0.00	0.01	0.01	0.05	0.01	0.03	0.06	0.04
english	0.11	0.24	0.06	0.01	0.04	0.09	0.01	0.21	0.00	0.00
period	0.32	0.08	0.02	0.00	0.00	0.00	0.01	0.00	0.11	0.00
source	0.06	0.01	0.04	0.03	0.04	0.17	0.05	0.01	0.01	0.00
write	0.05	0.03	0.03	0.06	0.00	0.00	0.01	0.00	0.01	0.02
give	0.13	0.01	0.02	0.00	0.03	0.01	0.07	0.11	0.01	0.14
example	0.01	0.00	0.02	0.09	0.01	0.01	0.00	0.00	0.12	0.02
middle	0.03	0.01	0.00	0.01	0.01	0.00	0.03	0.02	0.01	0.04
place	0.00	0.01	0.00	0.00	0.00	0.18	0.08	0.02	0.00	0.06
present	0.07	0.01	0.00	0.02	0.00	0.08	0.00	0.01	0.00	0.02
name	0.02	0.00	0.03	0.02	0.01	0.06	0.00	0.05	0.01	0.01
world	0.00	0.06	0.00	0.00	0.10	0.01	0.08	0.04	0.06	0.07
include	0.12	0.05	0.00	0.00	0.08	0.11	0.01	0.01	0.03	0.00
note	0.02	0.01	0.00	0.02	0.02	0.01	0.04	0.04	0.07	0.00
know	0.11	0.01	0.01	0.01	0.05	0.03	0.03	0.11	0.09	0.07

god	0.01	0.00	0.00	0.00	0.10	0.04	0.09	0.10	0.05	0.11
form	0.03	0.02	0.03	0.01	0.06	0.00	0.00	0.00	0.01	0.01
become	0.01	0.02	0.02	0.19	0.01	0.00	0.00	0.00	0.16	0.00
many	0.18	0.00	0.00	0.00	0.00	0.08	0.01	0.05	0.03	0.09
year	0.01	0.08	0.00	0.02	0.00	0.01	0.06	0.18	0.02	0.03
old	0.10	0.02	0.03	0.02	0.02	0.03	0.00	0.10	0.04	0.00
great	0.11	0.04	0.02	0.11	0.06	0.04	0.15	0.08	0.02	0.00
historical	0.02	0.02	0.06	0.01	0.00	0.09	0.06	0.14	0.02	0.02
case	0.01	0.01	0.06	0.07	0.07	0.01	0.00	0.00	0.00	0.00
law	0.02	0.00	0.06	0.01	0.00	0.01	0.00	0.04	0.02	0.01
woman	0.37	0.45	0.00	0.04	0.03	0.01	0.06	0.00	0.00	0.00
way	0.06	0.13	0.06	0.16	0.02	0.00	0.00	0.01	0.07	0.01
state	0.01	0.01	0.01	0.00	0.03	0.15	0.02	0.01	0.07	0.01
book	0.15	0.08	0.05	0.07	0.01	0.02	0.04	0.10	0.01	0.00
suggest	0.10	0.01	0.21	0.07	0.07	0.03	0.03	0.03	0.10	0.01
later	0.04	0.00	0.01	0.01	0.03	0.05	0.00	0.03	0.04	0.00
show	0.15	0.16	0.04	0.00	0.00	0.00	0.02	0.01	0.22	0.00
come	0.06	0.02	0.01	0.05	0.03	0.01	0.21	0.09	0.00	0.03
der	0.00	0.00	0.04	0.02	0.01	0.02	0.08	0.02	0.04	0.01
evidence	0.00	0.00	0.00	0.02	0.11	0.01	0.05	0.01	0.44	0.00
life	0.04	0.00	0.01	0.01	0.18	0.00	0.07	0.00	0.05	0.00
word	0.17	0.00	0.01	0.03	0.07	0.00	0.00	0.08	0.00	0.01
seem	0.29	0.00	0.06	0.00	0.01	0.10	0.00	0.00	0.15	0.01
manuscript	0.01	0.02	0.10	0.13	0.04	0.30	0.01	0.02	0.01	0.03
power	0.19	0.17	0.00	0.23	0.02	0.01	0.05	0.00	0.07	0.02
appear	0.05	0.02	0.00	0.09	0.05	0.18	0.02	0.10	0.09	0.00
different	0.09	0.01	0.13	0.01	0.01	0.07	0.05	0.01	0.02	0.05
follow	0.00	0.10	0.13	0.01	0.00	0.06	0.01	0.01	0.00	0.01
group	0.03	0.01	0.17	0.00	0.00	0.07	0.03	0.00	0.00	0.23
term	0.00	0.16	0.01	0.01	0.04	0.03	0.05	0.00	0.06	0.00
date	0.13	0.00	0.04	0.01	0.06	0.01	0.05	0.00	0.17	0.00
point	0.13	0.01	0.01	0.07	0.00	0.03	0.01	0.11	0.08	0.02

mean	0.17	0.01	0.09	0.01	0.00	0.01	0.02	0.06	0.01	0.04
political	0.03	0.03	0.01	0.06	0.02	0.06	0.00	0.04	0.12	0.01
latin	0.02	0.02	0.07	0.02	0.03	0.02	0.01	0.00	0.00	0.03
site	0.16	0.10	0.47	0.01	0.00	0.02	0.00	0.00	0.04	0.00
london	0.11	0.10	0.00	0.00	0.06	0.10	0.00	0.16	0.03	0.01
thus	0.15	0.02	0.01	0.03	0.02	0.03	0.00	0.14	0.05	0.01
die	0.11	0.01	0.07	0.01	0.01	0.01	0.04	0.00	0.07	0.07
cambridge	0.17	0.03	0.00	0.01	0.01	0.00	0.12	0.16	0.00	0.00
long	0.00	0.03	0.00	0.00	0.00	0.01	0.02	0.00	0.01	0.09
modern	0.00	0.01	0.05	0.01	0.02	0.01	0.02	0.20	0.06	0.02
europe	0.22	0.02	0.01	0.05	0.02	0.07	0.08	0.03	0.02	0.14
tradition	0.08	0.10	0.01	0.01	0.07	0.00	0.00	0.03	0.06	0.05
change	0.01	0.09	0.03	0.09	0.10	0.02	0.07	0.00	0.01	0.00
society	0.16	0.01	0.01	0.03	0.03	0.00	0.00	0.10	0.06	0.01
age	0.06	0.03	0.00	0.01	0.00	0.01	0.05	0.03	0.00	0.00
social	0.02	0.09	0.00	0.01	0.00	0.00	0.04	0.06	0.02	0.01
provide	0.01	0.00	0.03	0.01	0.25	0.01	0.00	0.01	0.01	0.00
land	0.01	0.09	0.01	0.08	0.07	0.01	0.03	0.00	0.00	0.00
number	0.08	0.02	0.08	0.00	0.04	0.06	0.10	0.00	0.10	0.00
england	0.05	0.12	0.00	0.02	0.03	0.03	0.04	0.28	0.03	0.00
rather	0.21	0.00	0.02	0.00	0.05	0.02	0.01	0.04	0.01	0.07
remain	0.38	0.01	0.00	0.03	0.00	0.00	0.04	0.04	0.02	0.05
order	0.06	0.01	0.04	0.01	0.00	0.00	0.01	0.00	0.05	0.00
anglo	0.05	0.17	0.08	0.01	0.01	0.06	0.01	0.32	0.04	0.00
author	0.01	0.00	0.11	0.05	0.00	0.19	0.00	0.00	0.07	0.04
much	0.18	0.01	0.01	0.01	0.01	0.10	0.09	0.08	0.04	0.00
city	0.25	0.06	0.06	0.00	0.03	0.03	0.01	0.00	0.01	0.00
figure	0.01	0.00	0.00	0.10	0.00	0.00	0.01	0.00	0.08	0.05
empire	0.14	0.00	0.00	0.01	0.11	0.01	0.01	0.02	0.06	0.01
religious	0.01	0.00	0.01	0.03	0.06	0.00	0.01	0.05	0.33	0.05
language	0.04	0.01	0.01	0.01	0.00	0.01	0.00	0.00	0.01	0.00
fact	0.17	0.04	0.08	0.04	0.02	0.02	0.07	0.01	0.05	0.04

end	0.03	0.04	0.03	0.02	0.04	0.01	0.06	0.04	0.04	0.01
image	0.14	0.33	0.00	0.05	0.00	0.02	0.07	0.00	0.04	0.00
culture	0.00	0.04	0.01	0.07	0.09	0.00	0.17	0.00	0.02	0.02
area	0.45	0.05	0.03	0.02	0.04	0.06	0.02	0.00	0.06	0.00
art	0.08	0.00	0.03	0.00	0.06	0.04	0.03	0.03	0.05	0.02
good	0.00	0.02	0.00	0.03	0.01	0.01	0.11	0.02	0.06	0.00
human	0.06	0.00	0.01	0.00	0.07	0.10	0.03	0.01	0.01	0.06
high	0.10	0.00	0.01	0.03	0.00	0.02	0.05	0.15	0.06	0.00
saxon	0.03	0.12	0.03	0.03	0.01	0.07	0.00	0.31	0.03	0.00
call	0.05	0.03	0.00	0.00	0.14	0.00	0.00	0.10	0.00	0.08
begin	0.03	0.00	0.03	0.04	0.03	0.01	0.03	0.00	0.01	0.00
base	0.26	0.04	0.01	0.05	0.04	0.05	0.06	0.00	0.01	0.01
say	0.15	0.04	0.01	0.00	0.06	0.00	0.27	0.14	0.01	0.00
important	0.00	0.00	0.00	0.04	0.06	0.05	0.00	0.00	0.02	0.05
large	0.18	0.01	0.03	0.00	0.03	0.12	0.02	0.01	0.19	0.00
describe	0.13	0.01	0.03	0.01	0.07	0.11	0.00	0.00	0.04	0.00
mention	0.04	0.01	0.03	0.02	0.07	0.07	0.01	0.01	0.03	0.04
north	0.26	0.00	0.00	0.05	0.11	0.08	0.03	0.02	0.00	0.00
oxford	0.01	0.18	0.06	0.02	0.05	0.05	0.02	0.16	0.00	0.00
second	0.01	0.01	0.03	0.03	0.03	0.01	0.00	0.00	0.17	0.00
view	0.17	0.03	0.00	0.00	0.13	0.04	0.00	0.06	0.00	0.01
practice	0.04	0.06	0.10	0.01	0.01	0.00	0.20	0.00	0.01	0.06
john	0.04	0.20	0.02	0.12	0.00	0.00	0.05	0.03	0.09	0.02
material	0.26	0.02	0.02	0.00	0.00	0.01	0.13	0.00	0.01	0.05
ancient	0.18	0.00	0.04	0.00	0.08	0.10	0.09	0.06	0.00	0.03
result	0.52	0.02	0.02	0.07	0.00	0.04	0.00	0.01	0.00	0.00
analysis	0.51	0.04	0.04	0.00	0.00	0.06	0.04	0.03	0.00	0.01
rome	0.05	0.00	0.03	0.01	0.08	0.06	0.01	0.01	0.00	0.03
ages	0.01	0.01	0.01	0.05	0.03	0.03	0.05	0.03	0.04	0.21
context	0.03	0.06	0.04	0.00	0.01	0.04	0.38	0.02	0.03	0.06
lead	0.10	0.06	0.03	0.10	0.12	0.00	0.17	0.01	0.01	0.00
hand	0.18	0.12	0.08	0.00	0.00	0.02	0.07	0.02	0.00	0.00

account	0.07	0.06	0.01	0.04	0.01	0.00	0.03	0.08	0.03	0.01
cultural	0.04	0.07	0.00	0.04	0.02	0.01	0.29	0.00	0.10	0.00
accord	0.03	0.01	0.04	0.01	0.00	0.01	0.01	0.09	0.03	0.00
often	0.08	0.03	0.01	0.05	0.00	0.01	0.04	0.01	0.00	0.06
individual	0.22	0.01	0.03	0.01	0.01	0.19	0.07	0.03	0.03	0.01
line	0.14	0.06	0.00	0.04	0.01	0.00	0.04	0.00	0.00	0.10
role	0.01	0.05	0.00	0.02	0.06	0.09	0.03	0.01	0.03	0.00
western	0.06	0.06	0.01	0.00	0.14	0.15	0.00	0.00	0.01	0.00
narrative	0.00	0.09	0.32	0.12	0.04	0.08	0.02	0.00	0.10	0.00
community	0.06	0.00	0.26	0.00	0.06	0.03	0.00	0.01	0.22	0.00
identity	0.00	0.16	0.20	0.16	0.02	0.02	0.02	0.00	0.22	0.00
research	0.13	0.01	0.01	0.02	0.06	0.20	0.12	0.09	0.01	0.00
jews	0.08	0.28	0.07	0.22	0.01	0.00	0.21	0.05	0.01	0.00
record	0.00	0.01	0.13	0.01	0.21	0.01	0.04	0.04	0.00	0.00
war	0.01	0.00	0.02	0.11	0.02	0.00	0.14	0.01	0.01	0.01
region	0.46	0.03	0.00	0.01	0.08	0.01	0.03	0.00	0.03	0.00
still	0.11	0.04	0.06	0.00	0.01	0.04	0.00	0.17	0.01	0.00
rule	0.18	0.05	0.08	0.01	0.18	0.00	0.01	0.00	0.01	0.00
consider	0.00	0.00	0.03	0.02	0.01	0.12	0.00	0.00	0.02	0.04
local	0.30	0.01	0.03	0.01	0.01	0.01	0.00	0.02	0.00	0.01
death	0.01	0.00	0.03	0.02	0.00	0.06	0.02	0.02	0.08	0.00
reference	0.05	0.02	0.05	0.01	0.21	0.01	0.00	0.00	0.01	0.01
west	0.04	0.01	0.40	0.02	0.00	0.00	0.00	0.00	0.01	0.01
population	0.30	0.04	0.01	0.05	0.01	0.01	0.05	0.02	0.01	0.00
slave	0.00	0.00	0.01	0.10	0.03	0.00	0.02	0.00	0.01	0.00
york	0.07	0.05	0.01	0.01	0.12	0.11	0.00	0.03	0.00	0.03
literature	0.36	0.00	0.00	0.08	0.04	0.00	0.01	0.01	0.02	0.01
settlement	0.11	0.10	0.52	0.08	0.01	0.00	0.01	0.00	0.02	0.00
similar	0.05	0.07	0.00	0.06	0.01	0.00	0.09	0.08	0.03	0.02
question	0.17	0.01	0.00	0.04	0.01	0.01	0.00	0.01	0.02	0.03
right	0.05	0.07	0.10	0.02	0.02	0.00	0.07	0.00	0.01	0.00
story	0.02	0.02	0.03	0.00	0.06	0.02	0.10	0.00	0.07	0.03

son	0.06	0.02	0.02	0.02	0.03	0.00	0.02	0.10	0.01	0.19
refer	0.00	0.00	0.02	0.00	0.01	0.01	0.04	0.10	0.01	0.02
bishop	0.00	0.00	0.05	0.00	0.09	0.04	0.00	0.00	0.00	0.00
read	0.17	0.06	0.04	0.02	0.06	0.01	0.04	0.00	0.00	0.00
family	0.03	0.01	0.01	0.04	0.02	0.00	0.01	0.00	0.03	0.64
saint	0.00	0.00	0.03	0.00	0.12	0.02	0.00	0.02	0.01	0.00
represent	0.03	0.01	0.01	0.03	0.02	0.02	0.13	0.00	0.08	0.02
body	0.03	0.00	0.03	0.13	0.02	0.07	0.02	0.01	0.01	0.02
journal	0.10	0.07	0.02	0.03	0.08	0.00	0.03	0.01	0.04	0.00
version	0.02	0.00	0.04	0.03	0.00	0.04	0.01	0.03	0.02	0.04
type	0.00	0.08	0.00	0.02	0.00	0.07	0.09	0.01	0.00	0.03
day	0.06	0.04	0.00	0.03	0.03	0.03	0.07	0.06	0.00	0.16
nature	0.09	0.04	0.01	0.00	0.02	0.03	0.01	0.09	0.00	0.03
royal	0.10	0.11	0.07	0.02	0.00	0.03	0.26	0.06	0.00	0.01
therefore	0.01	0.11	0.00	0.04	0.01	0.01	0.11	0.01	0.02	0.04
central	0.35	0.04	0.00	0.01	0.01	0.06	0.12	0.00	0.03	0.00
small	0.25	0.12	0.02	0.01	0.00	0.07	0.00	0.01	0.07	0.01
letter	0.02	0.03	0.02	0.00	0.02	0.01	0.01	0.01	0.01	0.00
common	0.00	0.01	0.01	0.05	0.04	0.00	0.01	0.03	0.01	0.00
european	0.16	0.01	0.06	0.01	0.10	0.11	0.05	0.02	0.07	0.05
identify	0.04	0.00	0.03	0.09	0.14	0.13	0.02	0.01	0.04	0.00
christ	0.06	0.01	0.00	0.09	0.13	0.02	0.16	0.00	0.00	0.00
live	0.04	0.00	0.00	0.09	0.00	0.09	0.07	0.02	0.15	0.00
set	0.03	0.16	0.00	0.15	0.05	0.01	0.02	0.00	0.00	0.00
several	0.06	0.23	0.08	0.04	0.04	0.03	0.08	0.00	0.01	0.00
influence	0.00	0.14	0.01	0.01	0.00	0.01	0.02	0.04	0.05	0.04
east	0.16	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00
archaeological	0.35	0.06	0.11	0.00	0.00	0.03	0.06	0.05	0.01	0.01
origin	0.05	0.05	0.01	0.00	0.01	0.00	0.24	0.07	0.01	0.00
value	0.30	0.06	0.01	0.06	0.02	0.08	0.01	0.01	0.00	0.00
understand	0.02	0.12	0.02	0.00	0.03	0.06	0.04	0.00	0.05	0.12
leave	0.05	0.09	0.00	0.01	0.05	0.00	0.00	0.04	0.00	0.00

translation	0.02	0.08	0.00	0.01	0.04	0.09	0.02	0.00	0.00	0.01
less	0.07	0.01	0.02	0.00	0.03	0.00	0.06	0.07	0.03	0.01
possible	0.06	0.00	0.01	0.03	0.01	0.00	0.00	0.00	0.21	0.00
general	0.06	0.02	0.04	0.03	0.00	0.09	0.05	0.01	0.06	0.01
especially	0.00	0.02	0.03	0.06	0.16	0.00	0.01	0.04	0.00	0.00
claim	0.16	0.09	0.00	0.00	0.03	0.01	0.00	0.00	0.08	0.04
article	0.06	0.03	0.02	0.03	0.06	0.08	0.18	0.01	0.00	0.01
idea	0.04	0.07	0.02	0.00	0.21	0.00	0.04	0.00	0.01	0.05
indicate	0.01	0.25	0.01	0.00	0.18	0.00	0.01	0.01	0.18	0.02
event	0.00	0.01	0.00	0.06	0.00	0.27	0.00	0.01	0.04	0.05
play	0.06	0.02	0.00	0.00	0.05	0.09	0.00	0.02	0.01	0.04
poem	0.14	0.06	0.06	0.06	0.02	0.05	0.08	0.00	0.00	0.02
support	0.01	0.09	0.24	0.00	0.07	0.01	0.02	0.04	0.00	0.01
regard	0.06	0.00	0.01	0.04	0.01	0.02	0.00	0.02	0.16	0.08
pagan	0.00	0.01	0.02	0.00	0.12	0.00	0.01	0.05	0.02	0.05
probably	0.00	0.02	0.01	0.01	0.00	0.12	0.00	0.09	0.14	0.00
town	0.11	0.08	0.37	0.06	0.04	0.10	0.06	0.00	0.01	0.00
non	0.00	0.00	0.03	0.00	0.01	0.05	0.01	0.00	0.04	0.03
hold	0.24	0.10	0.01	0.01	0.00	0.06	0.00	0.01	0.00	0.03
relate	0.00	0.00	0.04	0.09	0.04	0.08	0.36	0.00	0.01	0.00
studies	0.02	0.06	0.18	0.01	0.01	0.09	0.01	0.04	0.06	0.00
need	0.08	0.00	0.00	0.04	0.04	0.01	0.00	0.00	0.00	0.01
perhaps	0.12	0.01	0.03	0.04	0.00	0.03	0.02	0.17	0.20	0.00
court	0.10	0.03	0.10	0.11	0.09	0.04	0.18	0.01	0.02	0.00
least	0.07	0.02	0.00	0.03	0.00	0.04	0.00	0.02	0.25	0.00
chapter	0.08	0.00	0.07	0.17	0.22	0.14	0.14	0.04	0.00	0.00
south	0.13	0.00	0.01	0.02	0.00	0.01	0.01	0.03	0.01	0.00
last	0.00	0.14	0.00	0.10	0.01	0.02	0.00	0.00	0.03	0.00
argue	0.21	0.07	0.12	0.00	0.01	0.04	0.02	0.02	0.04	0.01
turn	0.05	0.02	0.02	0.01	0.04	0.00	0.03	0.09	0.00	0.01
scholar	0.12	0.04	0.01	0.11	0.01	0.03	0.01	0.06	0.12	0.01
emperor	0.15	0.02	0.12	0.00	0.00	0.05	0.00	0.06	0.00	0.00

particular	0.03	0.17	0.01	0.00	0.00	0.03	0.02	0.00	0.00	0.07
contemporary	0.06	0.08	0.03	0.02	0.01	0.04	0.08	0.04	0.04	0.01
cross	0.00	0.01	0.01	0.02	0.06	0.02	0.04	0.04	0.04	0.00
chronicle	0.00	0.06	0.00	0.00	0.01	0.01	0.04	0.03	0.03	0.02
subject	0.20	0.00	0.00	0.01	0.00	0.01	0.03	0.02	0.00	0.00
knowledge	0.09	0.02	0.05	0.19	0.00	0.19	0.01	0.00	0.02	0.07
kingdom	0.02	0.01	0.02	0.07	0.03	0.02	0.15	0.11	0.01	0.00
william	0.01	0.27	0.01	0.13	0.21	0.01	0.01	0.00	0.07	0.02
structure	0.23	0.00	0.00	0.05	0.01	0.01	0.03	0.01	0.08	0.00
literary	0.18	0.03	0.01	0.14	0.00	0.05	0.06	0.02	0.01	0.01
bring	0.18	0.04	0.01	0.04	0.04	0.00	0.01	0.20	0.00	0.01
model	0.06	0.11	0.00	0.01	0.04	0.18	0.29	0.00	0.00	0.00
element	0.00	0.01	0.01	0.03	0.07	0.00	0.06	0.01	0.09	0.02
relationship	0.00	0.00	0.18	0.02	0.01	0.02	0.00	0.05	0.10	0.00
concern	0.19	0.01	0.02	0.03	0.01	0.01	0.05	0.00	0.00	0.01
act	0.00	0.01	0.00	0.09	0.00	0.04	0.01	0.01	0.03	0.00
northern	0.09	0.00	0.01	0.00	0.01	0.00	0.01	0.02	0.00	0.01
establish	0.00	0.03	0.05	0.10	0.01	0.00	0.01	0.05	0.04	0.04
contain	0.04	0.00	0.12	0.00	0.00	0.01	0.00	0.01	0.03	0.03
authority	0.09	0.03	0.09	0.02	0.00	0.00	0.01	0.00	0.03	0.02
create	0.04	0.00	0.02	0.03	0.01	0.01	0.10	0.00	0.08	0.10
original	0.00	0.04	0.01	0.08	0.01	0.00	0.02	0.01	0.01	0.06
far	0.02	0.06	0.01	0.00	0.06	0.04	0.02	0.10	0.00	0.04
religion	0.01	0.02	0.00	0.00	0.07	0.00	0.04	0.03	0.25	0.05
continue	0.10	0.01	0.00	0.01	0.04	0.15	0.01	0.01	0.05	0.01
various	0.01	0.01	0.00	0.00	0.01	0.12	0.00	0.00	0.04	0.00
sense	0.25	0.13	0.00	0.01	0.01	0.01	0.01	0.01	0.02	0.00
iii	0.05	0.00	0.03	0.02	0.05	0.04	0.27	0.10	0.08	0.06
system	0.03	0.06	0.00	0.04	0.12	0.01	0.01	0.00	0.04	0.01
jewish	0.13	0.20	0.09	0.18	0.03	0.00	0.21	0.03	0.03	0.00
norman	0.02	0.01	0.01	0.03	0.15	0.26	0.04	0.00	0.01	0.01
publish	0.09	0.00	0.12	0.04	0.01	0.00	0.07	0.01	0.05	0.01

process	0.16	0.01	0.01	0.03	0.01	0.08	0.00	0.00	0.01	0.03
report	0.01	0.00	0.01	0.08	0.01	0.07	0.03	0.02	0.02	0.00
battle	0.16	0.00	0.00	0.31	0.10	0.01	0.01	0.00	0.02	0.01
discuss	0.17	0.06	0.02	0.01	0.23	0.04	0.00	0.04	0.00	0.01
force	0.17	0.07	0.00	0.05	0.06	0.01	0.01	0.00	0.00	0.01
likely	0.23	0.01	0.00	0.00	0.12	0.12	0.00	0.00	0.00	0.01
clear	0.03	0.10	0.04	0.09	0.04	0.04	0.00	0.01	0.01	0.00
interpretation	0.05	0.06	0.01	0.00	0.03	0.00	0.00	0.00	0.04	0.04
section	0.00	0.05	0.02	0.06	0.03	0.03	0.11	0.03	0.09	0.02
already	0.01	0.12	0.19	0.05	0.01	0.01	0.01	0.05	0.02	0.02
level	0.00	0.01	0.01	0.10	0.01	0.00	0.13	0.24	0.13	0.01
low	0.05	0.02	0.01	0.08	0.00	0.00	0.10	0.09	0.24	0.02
development	0.00	0.00	0.02	0.01	0.02	0.01	0.00	0.00	0.02	0.02
trade	0.18	0.03	0.01	0.00	0.09	0.11	0.04	0.01	0.00	0.00
datum	0.29	0.06	0.13	0.00	0.03	0.14	0.00	0.01	0.01	0.00
approach	0.01	0.04	0.01	0.05	0.02	0.15	0.09	0.04	0.01	0.06
german	0.02	0.00	0.02	0.00	0.02	0.05	0.02	0.07	0.02	0.00
greek	0.00	0.00	0.00	0.00	0.05	0.00	0.03	0.07	0.00	0.16
military	0.07	0.02	0.02	0.07	0.04	0.03	0.01	0.00	0.13	0.00
indeed	0.06	0.01	0.01	0.05	0.02	0.03	0.06	0.17	0.10	0.00
eastern	0.33	0.02	0.03	0.00	0.00	0.09	0.00	0.00	0.03	0.00
think	0.12	0.07	0.04	0.04	0.07	0.01	0.00	0.01	0.00	0.04
historian	0.02	0.04	0.13	0.03	0.01	0.00	0.00	0.03	0.10	0.01
issue	0.04	0.01	0.01	0.18	0.03	0.00	0.00	0.00	0.03	0.01
reason	0.16	0.00	0.00	0.00	0.03	0.01	0.04	0.03	0.06	0.12
other	0.05	0.11	0.01	0.02	0.00	0.01	0.01	0.03	0.10	0.00
byzantine	0.11	0.01	0.03	0.00	0.03	0.00	0.01	0.03	0.01	0.01
certain	0.09	0.10	0.00	0.01	0.01	0.02	0.15	0.02	0.04	0.01
national	0.00	0.14	0.00	0.05	0.01	0.00	0.04	0.03	0.13	0.01
legal	0.03	0.00	0.06	0.08	0.06	0.02	0.01	0.03	0.13	0.00
interest	0.14	0.01	0.00	0.01	0.12	0.04	0.00	0.01	0.01	0.01
draw	0.03	0.04	0.01	0.05	0.00	0.08	0.00	0.00	0.02	0.00

serve	0.01	0.16	0.04	0.00	0.03	0.00	0.01	0.07	0.04	0.06
archaeology	0.06	0.01	0.00	0.00	0.00	0.00	0.07	0.10	0.01	0.02
information	0.04	0.12	0.19	0.05	0.08	0.03	0.00	0.01	0.00	0.00
position	0.06	0.04	0.01	0.00	0.00	0.01	0.04	0.00	0.00	0.00
explain	0.03	0.00	0.07	0.00	0.01	0.03	0.00	0.03	0.00	0.01
produce	0.01	0.00	0.01	0.05	0.03	0.13	0.00	0.04	0.05	0.01
british	0.04	0.07	0.11	0.00	0.00	0.02	0.00	0.16	0.00	0.00
focus	0.04	0.02	0.00	0.02	0.01	0.04	0.07	0.02	0.06	0.07
und	0.00	0.00	0.03	0.03	0.00	0.01	0.11	0.04	0.04	0.00
imperial	0.03	0.02	0.01	0.02	0.00	0.04	0.04	0.00	0.01	0.00
child	0.09	0.10	0.05	0.00	0.00	0.00	0.01	0.00	0.01	0.00
christians	0.17	0.03	0.03	0.01	0.00	0.15	0.05	0.03	0.11	0.01
close	0.07	0.01	0.00	0.00	0.05	0.00	0.00	0.04	0.17	0.01
antiquity	0.16	0.01	0.07	0.00	0.03	0.01	0.16	0.00	0.01	0.01
edition	0.13	0.11	0.02	0.06	0.01	0.00	0.02	0.03	0.03	0.00
barbarian	0.00	0.02	0.01	0.00	0.06	0.00	0.04	0.03	0.02	0.63
sample	0.44	0.09	0.10	0.04	0.00	0.09	0.01	0.04	0.01	0.00
associate	0.00	0.03	0.04	0.02	0.00	0.02	0.15	0.04	0.05	0.01
discussion	0.30	0.00	0.01	0.00	0.00	0.01	0.02	0.02	0.03	0.01
status	0.02	0.01	0.00	0.03	0.00	0.01	0.00	0.01	0.06	0.03
building	0.29	0.03	0.00	0.01	0.04	0.18	0.01	0.02	0.05	0.00
offer	0.08	0.04	0.21	0.07	0.00	0.01	0.00	0.01	0.02	0.00
house	0.01	0.03	0.00	0.06	0.06	0.32	0.00	0.00	0.02	0.00
speak	0.07	0.01	0.03	0.03	0.06	0.00	0.01	0.04	0.01	0.01
fall	0.01	0.05	0.00	0.19	0.01	0.00	0.08	0.10	0.02	0.01
attempt	0.23	0.03	0.04	0.02	0.01	0.00	0.12	0.01	0.00	0.01
main	0.45	0.03	0.07	0.00	0.01	0.08	0.01	0.00	0.03	0.00
christianity	0.03	0.00	0.06	0.03	0.25	0.04	0.00	0.05	0.12	0.01
italy	0.19	0.03	0.02	0.01	0.00	0.27	0.00	0.00	0.01	0.05
problem	0.16	0.00	0.01	0.03	0.00	0.00	0.05	0.01	0.00	0.00
mark	0.00	0.06	0.08	0.04	0.00	0.06	0.01	0.01	0.00	0.02
henry	0.07	0.15	0.00	0.24	0.19	0.00	0.02	0.01	0.02	0.02

wife	0.40	0.45	0.00	0.03	0.06	0.00	0.03	0.00	0.00	0.00
particularly	0.00	0.09	0.03	0.00	0.05	0.09	0.00	0.01	0.00	0.00
relation	0.02	0.03	0.00	0.00	0.03	0.00	0.01	0.04	0.00	0.02
father	0.02	0.07	0.67	0.01	0.01	0.06	0.04	0.00	0.00	0.02
description	0.06	0.00	0.03	0.00	0.03	0.03	0.00	0.00	0.01	0.00
animal	0.01	0.00	0.02	0.00	0.12	0.01	0.02	0.01	0.07	0.00
von	0.01	0.01	0.02	0.03	0.01	0.00	0.08	0.00	0.09	0.00
holy	0.04	0.00	0.00	0.04	0.17	0.01	0.03	0.04	0.08	0.02
twelfth	0.00	0.04	0.00	0.03	0.24	0.22	0.04	0.00	0.00	0.01
activity	0.20	0.09	0.00	0.06	0.01	0.02	0.01	0.02	0.03	0.01
cause	0.01	0.08	0.02	0.09	0.01	0.00	0.00	0.06	0.00	0.03
little	0.06	0.00	0.03	0.01	0.00	0.12	0.07	0.12	0.08	0.00
control	0.05	0.09	0.01	0.04	0.04	0.00	0.21	0.04	0.01	0.01
review	0.02	0.03	0.00	0.03	0.02	0.02	0.00	0.04	0.00	0.00
allow	0.00	0.04	0.04	0.02	0.03	0.16	0.02	0.00	0.00	0.00
paul	0.00	0.12	0.01	0.14	0.00	0.00	0.00	0.01	0.03	0.00
theory	0.03	0.09	0.01	0.01	0.02	0.01	0.03	0.02	0.00	0.06
list	0.04	0.02	0.00	0.02	0.03	0.00	0.01	0.00	0.00	0.28
table	0.14	0.15	0.01	0.02	0.00	0.19	0.18	0.06	0.04	0.09
reflect	0.00	0.01	0.02	0.06	0.04	0.17	0.04	0.01	0.02	0.00
link	0.07	0.03	0.01	0.03	0.07	0.01	0.17	0.03	0.01	0.00
difference	0.07	0.00	0.03	0.12	0.01	0.03	0.01	0.00	0.00	0.01
recent	0.00	0.20	0.00	0.01	0.10	0.01	0.07	0.01	0.04	0.01
experience	0.01	0.02	0.04	0.00	0.06	0.04	0.06	0.00	0.00	0.06
third	0.12	0.00	0.02	0.07	0.03	0.00	0.11	0.01	0.15	0.00
introduction	0.03	0.15	0.01	0.05	0.15	0.18	0.00	0.03	0.04	0.00
castle	0.00	0.04	0.37	0.03	0.00	0.01	0.00	0.00	0.14	0.01
past	0.00	0.03	0.00	0.07	0.01	0.00	0.00	0.10	0.11	0.00
feature	0.01	0.00	0.00	0.00	0.00	0.00	0.03	0.00	0.23	0.00
character	0.07	0.00	0.03	0.10	0.00	0.00	0.02	0.00	0.09	0.07
classical	0.02	0.01	0.02	0.04	0.06	0.01	0.01	0.01	0.00	0.05
detail	0.02	0.01	0.00	0.00	0.00	0.00	0.00	0.01	0.05	0.02

reveal	0.00	0.09	0.01	0.01	0.01	0.15	0.01	0.02	0.01	0.01
presence	0.10	0.09	0.00	0.01	0.00	0.01	0.01	0.02	0.00	0.00
ruler	0.07	0.06	0.00	0.17	0.15	0.01	0.00	0.01	0.03	0.00
compare	0.01	0.00	0.09	0.13	0.09	0.21	0.18	0.06	0.00	0.00
conquest	0.06	0.11	0.01	0.00	0.19	0.02	0.00	0.04	0.03	0.00
islamic	0.00	0.01	0.09	0.15	0.29	0.09	0.01	0.02	0.01	0.01
army	0.00	0.06	0.00	0.04	0.00	0.02	0.00	0.08	0.01	0.01
concept	0.01	0.01	0.05	0.08	0.00	0.25	0.00	0.01	0.01	0.01
female	0.18	0.35	0.00	0.01	0.00	0.00	0.12	0.02	0.01	0.04
course	0.08	0.08	0.05	0.00	0.02	0.03	0.12	0.08	0.01	0.15
look	0.36	0.14	0.04	0.00	0.01	0.10	0.01	0.01	0.03	0.01
mongol	0.01	0.01	0.05	0.13	0.00	0.20	0.00	0.00	0.01	0.01
poet	0.14	0.00	0.24	0.04	0.03	0.02	0.08	0.00	0.00	0.00
clearly	0.23	0.18	0.08	0.07	0.00	0.00	0.00	0.01	0.06	0.00
stand	0.28	0.10	0.01	0.03	0.01	0.00	0.00	0.02	0.00	0.03
collection	0.09	0.01	0.08	0.04	0.00	0.00	0.00	0.00	0.02	0.00
daughter	0.00	0.07	0.73	0.03	0.00	0.05	0.02	0.00	0.00	0.00
public	0.00	0.00	0.00	0.02	0.04	0.01	0.00	0.00	0.01	0.00
edit	0.28	0.01	0.02	0.01	0.06	0.10	0.01	0.02	0.02	0.00
page	0.01	0.00	0.06	0.01	0.04	0.10	0.06	0.01	0.00	0.01
light	0.03	0.00	0.02	0.06	0.15	0.00	0.00	0.03	0.02	0.05
burial	0.28	0.00	0.01	0.01	0.03	0.02	0.12	0.00	0.01	0.00
kind	0.07	0.07	0.00	0.00	0.01	0.00	0.01	0.02	0.00	0.00
function	0.00	0.00	0.04	0.06	0.01	0.00	0.08	0.00	0.00	0.01
thing	0.08	0.03	0.00	0.01	0.12	0.00	0.08	0.07	0.00	0.09
build	0.38	0.04	0.01	0.00	0.00	0.00	0.01	0.01	0.01	0.02
southern	0.17	0.01	0.07	0.09	0.13	0.00	0.00	0.00	0.00	0.01
whole	0.07	0.06	0.01	0.06	0.07	0.01	0.00	0.00	0.06	0.00
copy	0.02	0.00	0.06	0.14	0.01	0.15	0.06	0.01	0.05	0.00
muslim	0.12	0.00	0.00	0.07	0.22	0.23	0.00	0.01	0.13	0.01
significant	0.24	0.02	0.03	0.03	0.01	0.01	0.01	0.02	0.01	0.01
contrast	0.12	0.00	0.01	0.03	0.02	0.08	0.03	0.00	0.01	0.10

object	0.00	0.06	0.00	0.00	0.10	0.00	0.00	0.03	0.00	0.07
receive	0.02	0.06	0.18	0.09	0.10	0.07	0.01	0.00	0.07	0.04
together	0.00	0.04	0.10	0.03	0.03	0.00	0.01	0.06	0.01	0.00
develop	0.00	0.11	0.03	0.00	0.00	0.00	0.03	0.01	0.02	0.04
irish	0.01	0.00	0.02	0.01	0.09	0.01	0.01	0.01	0.01	0.02
economic	0.17	0.03	0.00	0.03	0.04	0.15	0.04	0.01	0.05	0.01
open	0.07	0.05	0.00	0.02	0.00	0.03	0.02	0.00	0.01	0.01
believe	0.05	0.07	0.00	0.00	0.09	0.01	0.01	0.08	0.00	0.18
faith	0.00	0.02	0.06	0.01	0.09	0.00	0.00	0.01	0.24	0.00
instance	0.03	0.24	0.01	0.25	0.11	0.03	0.03	0.00	0.00	0.00
half	0.01	0.11	0.06	0.04	0.00	0.01	0.03	0.02	0.00	0.33
writing	0.01	0.00	0.01	0.01	0.01	0.01	0.00	0.00	0.00	0.01
tell	0.09	0.00	0.00	0.01	0.05	0.00	0.11	0.07	0.02	0.07
space	0.07	0.01	0.00	0.06	0.00	0.00	0.12	0.00	0.01	0.03
specific	0.00	0.01	0.00	0.01	0.00	0.19	0.21	0.06	0.00	0.00
lake	0.00	0.20	0.03	0.40	0.25	0.03	0.00	0.04	0.00	0.01
britain	0.00	0.11	0.08	0.06	0.00	0.00	0.00	0.07	0.01	0.00
demonstrate	0.04	0.20	0.06	0.00	0.07	0.01	0.00	0.05	0.00	0.00
almost	0.06	0.00	0.00	0.00	0.01	0.19	0.03	0.00	0.07	0.01
increase	0.03	0.00	0.00	0.42	0.17	0.04	0.02	0.00	0.00	0.01
robert	0.00	0.01	0.01	0.01	0.00	0.05	0.00	0.00	0.04	0.00
head	0.00	0.01	0.00	0.04	0.04	0.01	0.12	0.09	0.04	0.00
side	0.04	0.01	0.01	0.02	0.08	0.07	0.03	0.11	0.01	0.01
popular	0.04	0.02	0.02	0.00	0.03	0.03	0.02	0.02	0.08	0.00
matter	0.38	0.03	0.00	0.01	0.01	0.03	0.03	0.00	0.01	0.00
return	0.05	0.00	0.00	0.01	0.01	0.00	0.07	0.03	0.03	0.04
reader	0.14	0.00	0.01	0.15	0.02	0.07	0.20	0.00	0.01	0.00
occur	0.03	0.00	0.09	0.07	0.01	0.00	0.02	0.11	0.10	0.00
never	0.18	0.00	0.17	0.02	0.08	0.01	0.09	0.07	0.00	0.01
passage	0.13	0.04	0.01	0.00	0.01	0.00	0.01	0.00	0.00	0.00
help	0.09	0.02	0.04	0.00	0.02	0.01	0.00	0.01	0.10	0.00
add	0.22	0.01	0.06	0.02	0.01	0.03	0.00	0.05	0.02	0.01

wall	0.09	0.10	0.47	0.03	0.00	0.00	0.01	0.01	0.01	0.00
exist	0.02	0.01	0.11	0.00	0.00	0.05	0.04	0.00	0.01	0.00
member	0.01	0.00	0.00	0.02	0.07	0.00	0.01	0.01	0.05	0.58
addition	0.01	0.08	0.00	0.01	0.12	0.21	0.00	0.01	0.00	0.06
island	0.09	0.00	0.03	0.00	0.10	0.26	0.02	0.00	0.16	0.00
bear	0.07	0.04	0.03	0.01	0.14	0.01	0.05	0.01	0.01	0.00
back	0.02	0.03	0.01	0.01	0.06	0.01	0.00	0.04	0.00	0.01
pattern	0.19	0.01	0.00	0.00	0.00	0.04	0.02	0.00	0.08	0.01
series	0.00	0.01	0.00	0.00	0.03	0.16	0.01	0.02	0.04	0.25
ireland	0.01	0.00	0.05	0.01	0.10	0.01	0.00	0.00	0.04	0.01
grant	0.05	0.12	0.03	0.03	0.04	0.00	0.27	0.10	0.02	0.04
peter	0.00	0.00	0.01	0.13	0.04	0.07	0.00	0.05	0.00	0.00
face	0.03	0.00	0.01	0.00	0.01	0.00	0.00	0.04	0.05	0.01
carry	0.01	0.22	0.04	0.03	0.04	0.04	0.02	0.04	0.07	0.00
muslims	0.13	0.01	0.00	0.08	0.22	0.36	0.01	0.01	0.08	0.00
library	0.03	0.00	0.00	0.10	0.00	0.12	0.01	0.04	0.03	0.19
person	0.06	0.01	0.04	0.05	0.00	0.05	0.03	0.01	0.00	0.01
poetry	0.11	0.03	0.01	0.11	0.00	0.02	0.10	0.00	0.00	0.00
yet	0.24	0.03	0.00	0.00	0.00	0.04	0.00	0.01	0.00	0.01
connection	0.05	0.01	0.03	0.04	0.07	0.06	0.04	0.01	0.01	0.05
natural	0.00	0.00	0.07	0.00	0.09	0.03	0.01	0.09	0.00	0.01
slavic	0.02	0.01	0.29	0.03	0.00	0.12	0.09	0.00	0.01	0.00
arabic	0.03	0.00	0.08	0.29	0.23	0.09	0.13	0.00	0.00	0.00
self	0.03	0.02	0.18	0.00	0.06	0.01	0.00	0.04	0.16	0.03
method	0.07	0.01	0.00	0.01	0.00	0.01	0.04	0.01	0.05	0.00
single	0.01	0.08	0.06	0.01	0.00	0.01	0.00	0.03	0.07	0.01
water	0.01	0.00	0.01	0.02	0.08	0.03	0.02	0.18	0.19	0.00
lack	0.00	0.01	0.00	0.00	0.01	0.04	0.00	0.13	0.17	0.00
style	0.03	0.03	0.02	0.01	0.01	0.05	0.00	0.01	0.03	0.00
mary	0.11	0.09	0.02	0.14	0.14	0.00	0.29	0.04	0.03	0.00
cite	0.21	0.03	0.00	0.02	0.03	0.04	0.01	0.03	0.12	0.01
thomas	0.15	0.02	0.03	0.10	0.02	0.04	0.09	0.04	0.14	0.01

instead	0.09	0.05	0.04	0.14	0.07	0.05	0.06	0.01	0.07	0.03
production	0.30	0.05	0.00	0.05	0.03	0.12	0.00	0.00	0.02	0.00
short	0.02	0.07	0.04	0.03	0.00	0.00	0.00	0.06	0.02	0.04
sea	0.22	0.00	0.01	0.02	0.00	0.07	0.00	0.01	0.01	0.02
david	0.00	0.04	0.01	0.00	0.01	0.09	0.01	0.00	0.01	0.04
true	0.10	0.03	0.01	0.00	0.14	0.00	0.12	0.08	0.01	0.00
territory	0.38	0.07	0.00	0.01	0.00	0.02	0.01	0.04	0.05	0.01
lord	0.01	0.00	0.00	0.04	0.01	0.00	0.28	0.04	0.05	0.01
access	0.37	0.01	0.01	0.00	0.03	0.01	0.03	0.00	0.06	0.00
major	0.00	0.00	0.01	0.00	0.01	0.04	0.01	0.00	0.18	0.01
master	0.03	0.00	0.01	0.02	0.03	0.01	0.02	0.03	0.02	0.66
ethnic	0.01	0.24	0.03	0.23	0.14	0.00	0.05	0.03	0.01	0.01
richard	0.08	0.28	0.01	0.01	0.11	0.02	0.02	0.03	0.04	0.01
viking	0.04	0.05	0.03	0.01	0.02	0.08	0.01	0.09	0.01	0.00
paper	0.00	0.01	0.03	0.01	0.04	0.04	0.01	0.03	0.01	0.00
aspect	0.05	0.00	0.00	0.05	0.01	0.00	0.01	0.01	0.00	0.03
involve	0.05	0.00	0.00	0.04	0.00	0.06	0.00	0.00	0.00	0.00
africa	0.01	0.00	0.00	0.04	0.01	0.07	0.07	0.02	0.00	0.02
define	0.01	0.03	0.28	0.00	0.01	0.11	0.03	0.07	0.01	0.01
shape	0.07	0.05	0.13	0.06	0.01	0.06	0.04	0.00	0.01	0.03
black	0.00	0.01	0.00	0.00	0.02	0.00	0.01	0.02	0.01	0.04
representation	0.00	0.10	0.08	0.06	0.01	0.00	0.01	0.01	0.02	0.00
germanic	0.00	0.23	0.01	0.23	0.04	0.00	0.03	0.00	0.00	0.08
direct	0.05	0.00	0.00	0.05	0.00	0.04	0.06	0.00	0.00	0.09
argument	0.30	0.02	0.00	0.00	0.00	0.00	0.00	0.09	0.00	0.00
post	0.28	0.00	0.00	0.03	0.00	0.02	0.01	0.03	0.11	0.00
survive	0.00	0.01	0.03	0.14	0.00	0.16	0.01	0.01	0.11	0.03
gregory	0.01	0.00	0.01	0.01	0.02	0.01	0.00	0.03	0.09	0.00
seek	0.12	0.14	0.02	0.00	0.00	0.01	0.00	0.01	0.13	0.02
put	0.31	0.00	0.00	0.00	0.00	0.03	0.02	0.03	0.02	0.00
country	0.02	0.00	0.00	0.00	0.04	0.00	0.03	0.00	0.02	0.02
saga	0.00	0.01	0.00	0.00	0.00	0.00	0.02	0.05	0.03	0.04

action	0.06	0.02	0.00	0.07	0.03	0.10	0.01	0.00	0.01	0.01
always	0.17	0.00	0.01	0.00	0.03	0.01	0.06	0.01	0.03	0.00
effect	0.03	0.06	0.09	0.02	0.01	0.03	0.00	0.00	0.02	0.00
tale	0.05	0.23	0.20	0.01	0.05	0.08	0.15	0.02	0.00	0.00
river	0.14	0.01	0.00	0.02	0.01	0.01	0.05	0.08	0.14	0.01
due	0.20	0.06	0.03	0.00	0.00	0.04	0.11	0.00	0.00	0.01
young	0.26	0.26	0.00	0.05	0.01	0.05	0.00	0.00	0.00	0.02
american	0.00	0.08	0.01	0.01	0.00	0.04	0.01	0.00	0.14	0.00
move	0.05	0.01	0.00	0.02	0.00	0.03	0.05	0.00	0.00	0.00
construction	0.02	0.01	0.58	0.00	0.02	0.03	0.01	0.02	0.01	0.01
learn	0.14	0.00	0.01	0.07	0.02	0.00	0.02	0.00	0.00	0.02
available	0.07	0.00	0.20	0.00	0.03	0.17	0.00	0.03	0.01	0.00

TABLE 7.23 – Cos2 pour l'ensemble des facteurs

	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
century	0.09	0.31	-0.05	0.13	-0.07	0.27	0.09	0.47	0.10	0.66	0.09	0.58	-0.07	0.39	-0.01	0.01	-0.08	0.66	0.03	0.12
medieval	0.07	0.14	-0.03	0.03	0.08	0.31	0.10	0.45	-0.03	0.06	-0.08	0.40	-0.01	0.01	-0.06	0.24	-0.01	0.01	0.09	0.75
early	0.11	0.33	0.04	0.06	0.02	0.01	-0.04	0.07	-0.02	0.03	0.04	0.10	-0.09	0.51	-0.01	0.01	-0.12	1.16	-0.01	0.01
use	0.07	0.12	-0.05	0.09	-0.10	0.34	-0.05	0.10	0.06	0.15	-0.07	0.22	-0.05	0.12	-0.06	0.25	-0.04	0.13	0.02	0.02
history	-0.04	0.03	0.06	0.10	-0.09	0.28	0.04	0.05	-0.00	0.00	-0.06	0.17	0.05	0.11	-0.06	0.18	0.06	0.21	0.01	0.01
new	-0.03	0.02	0.06	0.08	0.02	0.01	0.01	0.00	-0.10	0.35	0.08	0.25	-0.01	0.01	-0.04	0.09	-0.03	0.06	0.01	0.00
make	-0.12	0.26	-0.06	0.07	0.05	0.07	-0.02	0.02	-0.00	0.00	0.04	0.06	0.01	0.01	0.04	0.08	-0.03	0.04	0.01	0.00
time	0.04	0.03	0.02	0.01	-0.02	0.01	-0.06	0.10	-0.02	0.01	-0.03	0.02	0.03	0.05	0.09	0.42	-0.05	0.12	-0.01	0.01
work	-0.18	0.56	0.07	0.10	-0.12	0.38	0.12	0.40	0.05	0.08	-0.10	0.33	0.01	0.00	-0.05	0.14	-0.00	0.00	-0.05	0.11
text	-0.10	0.17	0.10	0.22	-0.03	0.02	-0.04	0.05	-0.01	0.00	-0.15	0.79	-0.04	0.05	-0.09	0.37	-0.01	0.01	-0.10	0.48
first	-0.01	0.00	0.03	0.02	-0.04	0.05	0.08	0.19	0.01	0.00	0.05	0.10	-0.01	0.00	0.02	0.01	-0.05	0.13	-0.02	0.01
university	0.11	0.19	0.00	0.00	-0.02	0.01	-0.01	0.00	-0.00	0.00	-0.06	0.12	-0.05	0.09	-0.06	0.13	0.10	0.49	-0.07	0.20
find	0.04	0.03	-0.04	0.04	0.00	0.00	-0.04	0.04	-0.05	0.07	-0.01	0.00	-0.02	0.01	0.05	0.09	-0.05	0.10	-0.03	0.03
roman	0.24	0.94	0.01	0.00	-0.08	0.16	-0.03	0.02	-0.08	0.19	0.12	0.45	-0.08	0.23	0.07	0.18	0.10	0.41	0.13	0.82
late	0.26	0.98	-0.08	0.11	-0.08	0.14	0.00	0.00	-0.02	0.01	0.03	0.02	-0.08	0.19	-0.03	0.03	-0.03	0.05	-0.01	0.00
king	-0.12	0.20	0.04	0.03	-0.07	0.10	-0.08	0.15	0.07	0.12	0.05	0.07	0.15	0.69	0.17	1.10	-0.01	0.00	-0.10	0.38
study	0.05	0.04	0.01	0.00	0.05	0.05	0.04	0.04	0.04	0.04	-0.06	0.11	-0.09	0.27	-0.09	0.30	-0.04	0.06	0.02	0.02
even	-0.13	0.23	-0.03	0.02	-0.00	0.00	-0.02	0.01	0.00	0.00	0.03	0.02	0.03	0.03	0.06	0.12	0.01	0.00	-0.02	0.01
well	-0.05	0.03	0.01	0.00	-0.01	0.00	0.03	0.02	-0.03	0.02	0.04	0.04	0.03	0.03	0.08	0.25	-0.02	0.02	-0.04	0.06
people	0.03	0.01	0.03	0.02	0.08	0.12	-0.00	0.00	-0.09	0.19	-0.06	0.11	-0.07	0.13	0.05	0.10	0.09	0.34	-0.01	0.00
christian	0.22	0.68	-0.07	0.09	-0.12	0.27	-0.18	0.74	-0.13	0.41	0.05	0.08	0.07	0.13	0.06	0.11	0.14	0.72	0.03	0.04
church	0.11	0.16	-0.06	0.05	-0.11	0.24	-0.05	0.05	-0.24	1.43	0.14	0.55	0.02	0.02	-0.00	0.00	0.03	0.02	0.03	0.03
man	-0.54	4.00	-0.42	2.95	0.02	0.01	-0.16	0.59	0.12	0.33	-0.01	0.00	-0.02	0.02	-0.03	0.04	0.02	0.02	-0.01	0.00
part	0.01	0.00	-0.01	0.00	0.08	0.13	0.06	0.08	-0.02	0.01	-0.01	0.00	0.03	0.02	0.03	0.03	-0.01	0.01	0.02	0.01
take	-0.08	0.08	-0.04	0.03	-0.01	0.00	-0.01	0.00	0.01	0.00	0.04	0.04	0.07	0.13	0.05	0.08	0.03	0.03	-0.00	0.00
press	0.13	0.23	-0.02	0.01	0.01	0.00	-0.04	0.04	0.04	0.03	-0.08	0.17	-0.05	0.06	-0.06	0.12	0.09	0.31	-0.07	0.18
english	-0.24	0.76	0.35	2.01	0.18	0.62	-0.06	0.09	-0.14	0.49	0.22	1.21	0.08	0.16	-0.33	3.77	-0.04	0.05	-0.03	0.04
period	0.23	0.69	-0.12	0.22	-0.06	0.06	0.01	0.00	0.02	0.01	0.02	0.01	-0.04	0.05	0.01	0.00	-0.14	0.68	0.02	0.02
source	0.08	0.08	0.03	0.01	-0.07	0.08	0.06	0.06	0.06	0.09	-0.14	0.49	-0.08	0.16	-0.03	0.03	-0.03	0.03	-0.01	0.00
write	-0.14	0.26	0.12	0.21	-0.11	0.23	0.15	0.48	-0.04	0.03	-0.04	0.03	0.06	0.11	0.04	0.05	0.05	0.08	-0.09	0.27
give	-0.10	0.12	0.03	0.01	0.04	0.03	0.01	0.00	-0.04	0.04	0.03	0.02	0.07	0.14	0.09	0.28	-0.03	0.03	0.11	0.38
example	-0.03	0.01	-0.02	0.00	-0.05	0.05	0.10	0.22	-0.03	0.02	0.03	0.02	-0.02	0.01	-0.02	0.01	-0.12	0.49	-0.06	0.10
middle	0.06	0.04	-0.02	0.01	-0.01	0.00	-0.03	0.02	0.03	0.01	-0.01	0.00	0.05	0.06	0.05	0.07	-0.03	0.04	0.06	0.12
place	0.01	0.00	-0.02	0.01	-0.01	0.00	0.01	0.00	-0.01	0.00	0.09	0.19	-0.06	0.09	0.03	0.03	0.01	0.00	-0.05	0.09
present	0.08	0.07	-0.03	0.01	-0.00	0.00	-0.04	0.03	0.01	0.00	-0.09	0.17	0.00	0.00	0.02	0.01	-0.00	0.00	-0.04	0.06
name	-0.07	0.05	0.01	0.00	0.08	0.10	0.07	0.08	0.06	0.06	0.11	0.29	0.00	0.00	0.10	0.29	-0.04	0.05	0.05	0.07
world	0.02	0.00	0.08	0.09	0.00	0.00	-0.00	0.00	-0.11	0.24	-0.03	0.02	-0.09	0.21	0.07	0.15	0.08	0.21	-0.09	0.27
include	0.09	0.08	-0.06	0.04	0.01	0.00	-0.00	0.00	-0.07	0.10	-0.08	0.15	-0.02	0.01	-0.03	0.02	-0.04	0.06	-0.01	0.00
note	-0.12	0.16	0.06	0.05	-0.05	0.04	0.10	0.19	0.10	0.19	0.08	0.13	0.16	0.58	0.15	0.67	-0.20	1.21	0.04	0.05
know	-0.08	0.08	0.02	0.00	0.02	0.01	0.03	0.01	-0.06	0.06	0.05	0.04	0.04	0.04	0.08	0.20	-0.07	0.17	-0.07	0.13

god	-0.10	0.12	0.03	0.02	0.04	0.03	0.01	0.00	-0.27	1.49	-0.18	0.72	0.25	1.50	0.27	2.14	0.18	1.03	-0.29	2.62
form	-0.06	0.05	0.05	0.04	0.06	0.07	0.04	0.03	-0.10	0.20	0.03	0.02	-0.01	0.00	-0.01	0.00	-0.03	0.03	-0.04	0.05
become	-0.02	0.01	-0.03	0.01	0.03	0.02	-0.10	0.18	-0.02	0.01	-0.01	0.00	0.01	0.00	0.00	0.00	0.09	0.26	-0.01	0.00
many	-0.09	0.09	-0.01	0.00	0.00	0.00	-0.01	0.00	0.01	0.00	0.06	0.08	0.02	0.01	0.05	0.07	0.04	0.04	-0.06	0.13
year	-0.04	0.02	0.13	0.22	-0.01	0.00	-0.07	0.08	0.01	0.00	0.04	0.03	0.11	0.26	0.19	1.00	-0.06	0.12	0.08	0.19
old	-0.16	0.26	0.06	0.05	0.09	0.13	-0.07	0.10	-0.07	0.09	0.09	0.18	-0.02	0.01	-0.16	0.70	-0.10	0.29	-0.01	0.00
great	-0.12	0.14	0.07	0.07	-0.05	0.04	-0.12	0.24	0.09	0.14	-0.07	0.09	0.13	0.41	0.10	0.28	-0.05	0.07	0.02	0.01
historical	0.05	0.02	0.05	0.03	-0.08	0.09	0.03	0.01	-0.01	0.00	-0.10	0.19	-0.08	0.13	-0.12	0.38	0.04	0.05	-0.04	0.05
case	-0.04	0.02	0.03	0.01	-0.09	0.12	0.10	0.16	0.09	0.16	-0.03	0.02	-0.00	0.00	-0.01	0.00	-0.01	0.01	0.01	0.00
law	-0.10	0.11	-0.04	0.02	-0.19	0.52	0.09	0.13	0.02	0.01	-0.06	0.07	0.02	0.01	-0.15	0.59	0.11	0.31	0.08	0.18
woman	-0.96	9.46	-1.06	14.34	-0.03	0.02	-0.31	1.65	0.28	1.46	0.17	0.61	-0.39	3.39	-0.11	0.30	0.09	0.24	-0.08	0.18
way	-0.07	0.05	0.10	0.12	0.07	0.07	-0.11	0.20	-0.04	0.03	-0.02	0.01	0.01	0.00	0.03	0.03	0.07	0.14	-0.03	0.02
state	-0.05	0.02	0.04	0.02	0.04	0.02	0.03	0.02	0.08	0.13	-0.19	0.73	0.07	0.12	-0.04	0.04	0.13	0.44	0.06	0.10
book	-0.21	0.42	0.15	0.29	-0.12	0.21	0.14	0.35	-0.05	0.04	-0.08	0.12	0.11	0.25	-0.17	0.77	-0.06	0.08	-0.02	0.01
suggest	-0.11	0.13	-0.03	0.01	0.16	0.39	-0.09	0.14	0.09	0.15	-0.06	0.07	-0.07	0.09	0.06	0.10	-0.11	0.34	-0.04	0.04
later	-0.06	0.04	0.01	0.00	-0.02	0.01	0.03	0.02	-0.05	0.04	0.06	0.08	0.02	0.00	0.05	0.06	-0.06	0.09	-0.01	0.00
show	0.13	0.18	-0.14	0.23	-0.07	0.06	-0.02	0.00	0.00	0.00	-0.01	0.00	-0.04	0.04	-0.04	0.03	-0.16	0.69	-0.01	0.01
come	-0.05	0.03	0.03	0.01	0.02	0.01	-0.05	0.04	-0.04	0.03	0.03	0.01	0.10	0.21	0.07	0.11	0.01	0.00	-0.04	0.04
der	0.01	0.00	-0.03	0.01	-0.12	0.22	0.09	0.13	0.06	0.06	0.09	0.14	-0.17	0.64	-0.09	0.21	0.13	0.48	0.07	0.12
evidence	0.01	0.00	-0.01	0.00	0.00	0.00	0.06	0.05	0.15	0.39	0.05	0.05	0.10	0.19	0.04	0.04	-0.30	2.33	0.02	0.01
life	-0.07	0.05	-0.01	0.00	0.02	0.01	0.03	0.02	-0.14	0.35	0.00	0.00	0.09	0.17	0.00	0.00	0.07	0.14	-0.02	0.01
word	-0.21	0.42	-0.02	0.00	-0.04	0.02	0.09	0.12	-0.14	0.34	0.03	0.02	-0.03	0.02	0.15	0.51	-0.02	0.01	0.04	0.04
seem	-0.20	0.36	-0.01	0.00	0.09	0.12	0.01	0.00	0.05	0.03	0.12	0.25	0.02	0.00	0.02	0.01	-0.14	0.51	0.03	0.02
manuscript	-0.09	0.08	0.10	0.11	-0.25	0.83	0.28	1.20	0.15	0.37	-0.42	3.23	0.06	0.08	-0.12	0.33	-0.10	0.23	0.14	0.48
power	-0.19	0.33	-0.18	0.38	-0.00	0.00	-0.21	0.68	0.07	0.07	-0.05	0.05	-0.09	0.17	0.01	0.00	0.12	0.36	-0.06	0.08
appear	-0.07	0.05	-0.04	0.02	-0.01	0.00	0.10	0.15	0.08	0.09	0.14	0.35	0.04	0.03	0.10	0.24	-0.10	0.23	0.02	0.01
different	0.08	0.06	0.03	0.01	-0.09	0.12	0.03	0.01	-0.02	0.01	-0.07	0.08	-0.06	0.07	0.02	0.01	0.04	0.03	-0.06	0.08
follow	-0.00	0.00	0.06	0.04	-0.07	0.06	-0.02	0.01	-0.01	0.00	-0.04	0.03	0.02	0.01	0.02	0.01	0.01	0.00	0.01	0.00
group	0.09	0.08	-0.04	0.02	0.22	0.63	0.03	0.02	0.01	0.00	-0.14	0.33	-0.09	0.15	-0.03	0.02	-0.01	0.00	0.25	1.59
term	0.00	0.00	0.13	0.19	-0.03	0.01	0.04	0.02	0.06	0.06	-0.05	0.05	-0.07	0.10	-0.02	0.01	0.08	0.15	0.00	0.00
date	0.18	0.29	-0.00	0.00	-0.10	0.13	0.03	0.02	0.12	0.24	-0.04	0.02	-0.11	0.24	0.02	0.01	-0.21	1.07	0.00	0.00
point	-0.09	0.07	0.02	0.00	0.02	0.01	-0.06	0.06	-0.01	0.00	0.04	0.03	0.02	0.01	0.08	0.15	-0.07	0.11	0.03	0.03
mean	-0.11	0.11	0.02	0.00	0.08	0.08	-0.03	0.01	-0.01	0.00	-0.03	0.02	0.04	0.03	0.06	0.10	-0.02	0.01	-0.06	0.08
political	0.06	0.04	0.06	0.05	-0.04	0.02	-0.09	0.12	0.05	0.04	-0.09	0.16	-0.00	0.00	-0.08	0.13	0.13	0.39	0.04	0.03
latin	-0.12	0.12	0.11	0.14	-0.22	0.64	0.11	0.16	-0.13	0.26	0.12	0.23	-0.08	0.12	0.01	0.00	-0.01	0.00	0.14	0.51
site	0.41	1.50	-0.33	1.15	0.71	6.45	0.13	0.23	0.03	0.02	-0.13	0.30	0.03	0.02	-0.01	0.00	-0.22	1.14	-0.02	0.01
london	-0.17	0.27	0.16	0.29	0.03	0.01	0.02	0.00	-0.13	0.27	0.16	0.46	0.00	0.00	-0.21	1.00	-0.09	0.21	0.06	0.10
thus	-0.11	0.10	-0.04	0.02	-0.03	0.01	-0.05	0.04	-0.04	0.02	-0.05	0.04	-0.02	0.01	0.10	0.24	-0.06	0.09	-0.02	0.01
die	-0.17	0.25	-0.05	0.03	-0.14	0.23	0.06	0.05	0.04	0.03	0.04	0.02	-0.10	0.18	-0.03	0.02	0.13	0.43	0.13	0.43
cambridge	0.13	0.15	0.05	0.03	-0.00	0.00	0.03	0.01	0.03	0.01	0.01	0.00	-0.11	0.22	-0.13	0.37	-0.01	0.00	0.01	0.00
long	0.01	0.00	0.04	0.02	0.00	0.00	0.00	0.00	-0.00	0.00	0.02	0.01	-0.03	0.02	0.01	0.00	-0.03	0.02	0.07	0.10
modern	0.00	0.00	0.04	0.02	0.10	0.13	-0.03	0.01	-0.07	0.06	-0.04	0.02	0.07	0.09	0.21	0.94	-0.11	0.27	-0.06	0.09

europa	0.23	0.44	-0.07	0.05	-0.06	0.04	-0.11	0.16	-0.06	0.06	-0.13	0.27	-0.13	0.32	-0.08	0.13	0.07	0.11	0.18	0.77
tradition	-0.13	0.14	0.14	0.21	-0.03	0.01	-0.04	0.03	-0.12	0.20	0.03	0.01	-0.01	0.00	-0.08	0.13	0.11	0.26	-0.10	0.22
change	0.04	0.01	0.13	0.17	0.08	0.08	-0.13	0.25	0.14	0.28	-0.06	0.05	-0.12	0.25	0.01	0.00	0.05	0.06	0.01	0.00
society	-0.16	0.21	0.03	0.01	0.04	0.02	0.07	0.07	0.07	0.07	0.02	0.01	0.01	0.00	-0.12	0.34	0.09	0.20	0.03	0.03
age	0.10	0.08	0.07	0.05	0.02	0.00	-0.03	0.01	-0.03	0.01	0.05	0.03	-0.08	0.13	-0.07	0.09	-0.01	0.00	-0.03	0.02
social	-0.07	0.05	0.14	0.21	0.01	0.00	-0.03	0.02	-0.01	0.00	-0.01	0.00	-0.09	0.16	-0.12	0.32	0.07	0.13	-0.03	0.03
provide	0.02	0.00	0.01	0.00	-0.04	0.02	0.02	0.01	0.12	0.21	-0.03	0.01	0.00	0.00	-0.03	0.02	-0.02	0.01	-0.00	0.00
land	0.06	0.02	0.14	0.19	0.06	0.04	-0.13	0.23	0.12	0.19	0.04	0.03	0.08	0.10	-0.01	0.00	-0.01	0.00	0.01	0.00
number	0.10	0.08	-0.05	0.03	0.10	0.13	0.02	0.01	0.07	0.07	0.09	0.12	0.12	0.23	-0.00	0.00	-0.12	0.30	0.01	0.00
england	-0.18	0.27	0.28	0.80	0.05	0.03	-0.12	0.18	-0.15	0.32	0.14	0.33	0.15	0.38	-0.42	3.73	-0.13	0.37	0.03	0.02
rather	-0.10	0.08	0.01	0.00	0.03	0.01	0.00	0.00	-0.05	0.03	0.03	0.01	-0.02	0.01	0.05	0.05	-0.02	0.01	-0.06	0.08
remain	0.14	0.15	-0.03	0.01	0.01	0.00	0.04	0.02	0.00	0.00	0.01	0.00	-0.05	0.04	0.04	0.04	-0.03	0.02	0.05	0.06
order	-0.08	0.05	0.04	0.02	-0.06	0.05	-0.04	0.02	0.01	0.00	-0.02	0.01	0.03	0.02	-0.02	0.01	0.08	0.12	-0.01	0.00
anglo	-0.20	0.32	0.38	1.47	0.26	0.78	-0.08	0.09	-0.09	0.10	0.22	0.76	0.06	0.07	-0.52	5.61	-0.18	0.70	0.03	0.02
author	-0.03	0.01	0.01	0.00	-0.14	0.22	0.10	0.12	0.02	0.00	-0.18	0.53	0.00	0.00	-0.02	0.01	0.11	0.28	-0.09	0.17
much	-0.13	0.13	0.03	0.01	0.03	0.01	-0.03	0.01	-0.02	0.01	0.10	0.15	0.09	0.14	0.08	0.14	-0.06	0.09	0.01	0.00
city	0.26	0.54	-0.13	0.17	0.13	0.19	-0.02	0.00	-0.09	0.12	-0.10	0.14	0.04	0.03	-0.03	0.02	0.04	0.03	-0.03	0.02
figure	-0.05	0.02	-0.02	0.00	-0.00	0.00	-0.18	0.43	0.01	0.00	0.03	0.01	-0.07	0.08	0.01	0.00	-0.16	0.57	0.13	0.36
empire	0.18	0.25	-0.02	0.00	-0.01	0.00	-0.05	0.04	-0.16	0.35	-0.04	0.02	-0.04	0.02	0.06	0.08	0.12	0.28	-0.04	0.03
religious	0.06	0.03	-0.00	0.00	-0.05	0.02	0.09	0.11	-0.14	0.27	0.03	0.01	-0.06	0.07	0.12	0.29	0.31	2.12	-0.12	0.34
language	-0.20	0.32	0.11	0.11	-0.08	0.07	0.12	0.17	-0.04	0.03	0.08	0.10	-0.02	0.01	0.02	0.01	-0.13	0.33	-0.06	0.08
fact	-0.11	0.10	0.05	0.03	0.08	0.07	0.05	0.03	0.04	0.02	-0.04	0.02	0.07	0.09	0.02	0.01	0.06	0.08	-0.05	0.06
end	0.04	0.01	-0.04	0.02	-0.04	0.02	0.03	0.01	0.05	0.03	0.03	0.01	0.06	0.05	0.05	0.04	-0.05	0.05	0.02	0.01
image	-0.33	0.81	-0.51	2.47	-0.02	0.00	-0.19	0.47	0.04	0.02	0.13	0.24	-0.23	0.82	0.03	0.02	-0.18	0.66	0.03	0.02
culture	-0.02	0.00	0.09	0.08	-0.03	0.01	0.12	0.18	-0.13	0.25	0.00	0.00	-0.18	0.53	0.00	0.00	0.06	0.08	-0.07	0.09
area	0.41	1.24	-0.14	0.19	0.09	0.10	0.09	0.11	0.12	0.21	0.15	0.34	-0.08	0.11	0.00	0.00	-0.15	0.48	-0.02	0.01
art	-0.27	0.56	-0.05	0.03	-0.17	0.30	-0.02	0.01	-0.23	0.74	0.20	0.56	-0.16	0.39	0.16	0.49	-0.22	1.01	-0.12	0.31
good	-0.00	0.00	-0.04	0.02	-0.02	0.01	0.06	0.04	0.04	0.02	0.03	0.02	0.11	0.19	0.05	0.04	-0.08	0.14	0.00	0.00
human	0.14	0.15	-0.04	0.01	0.07	0.05	-0.01	0.00	-0.15	0.29	-0.18	0.46	-0.09	0.13	0.05	0.04	-0.07	0.09	-0.14	0.39
high	0.17	0.20	-0.03	0.01	0.06	0.04	-0.08	0.09	0.00	0.00	-0.07	0.07	0.12	0.22	0.20	0.77	-0.12	0.30	-0.02	0.01
saxon	-0.25	0.47	0.50	2.31	0.25	0.70	-0.25	0.74	-0.13	0.23	0.37	2.03	-0.02	0.01	-0.81	12.46	-0.24	1.18	0.06	0.06
call	-0.08	0.04	0.06	0.03	-0.00	0.00	-0.02	0.01	-0.13	0.21	-0.01	0.00	-0.00	0.00	0.11	0.22	0.02	0.01	-0.10	0.18
begin	-0.05	0.02	0.02	0.00	-0.04	0.02	0.06	0.04	0.05	0.03	0.03	0.01	0.05	0.04	-0.00	0.00	-0.03	0.01	-0.01	0.00
base	0.17	0.21	0.07	0.04	-0.04	0.01	-0.07	0.06	0.07	0.06	-0.08	0.08	-0.08	0.11	0.01	0.00	-0.04	0.03	-0.03	0.02
say	-0.17	0.21	0.09	0.07	0.04	0.02	-0.03	0.01	-0.10	0.14	-0.02	0.01	0.23	0.81	0.16	0.51	-0.04	0.04	-0.01	0.00
important	-0.01	0.00	0.01	0.00	-0.01	0.00	0.04	0.02	-0.05	0.03	0.05	0.03	0.01	0.00	-0.00	0.00	0.03	0.01	-0.05	0.04
large	0.16	0.17	-0.03	0.01	0.07	0.05	-0.01	0.00	0.06	0.04	0.13	0.23	0.05	0.03	-0.03	0.02	-0.16	0.51	-0.02	0.01
describe	0.10	0.07	-0.03	0.01	-0.05	0.02	-0.02	0.01	0.07	0.07	0.10	0.13	0.02	0.00	0.02	0.01	0.05	0.06	0.01	0.00
mention	0.08	0.04	-0.03	0.01	-0.06	0.03	0.05	0.03	0.09	0.11	-0.10	0.13	-0.03	0.02	0.03	0.02	0.06	0.07	-0.08	0.11
north	0.24	0.42	0.01	0.00	0.02	0.00	0.11	0.13	0.16	0.31	0.14	0.26	-0.09	0.11	0.07	0.10	0.03	0.01	-0.02	0.01
oxford	0.03	0.01	0.13	0.15	0.08	0.06	-0.04	0.02	-0.07	0.07	0.07	0.07	-0.04	0.03	-0.13	0.29	0.00	0.00	0.01	0.00
second	0.03	0.01	0.03	0.01	-0.05	0.02	0.05	0.03	0.05	0.03	0.03	0.01	0.01	0.00	0.02	0.00	-0.11	0.25	0.01	0.00

view	-0.18	0.22	0.08	0.05	-0.01	0.00	-0.01	0.00	-0.15	0.29	0.09	0.10	-0.00	0.00	0.10	0.19	0.03	0.02	-0.04	0.03
practice	-0.10	0.06	-0.12	0.12	-0.15	0.23	0.05	0.03	0.04	0.02	-0.02	0.01	-0.21	0.64	-0.02	0.00	0.05	0.04	-0.11	0.25
john	-0.10	0.06	0.21	0.37	0.07	0.05	-0.16	0.29	-0.01	0.00	-0.02	0.01	0.10	0.15	0.08	0.12	0.14	0.35	-0.06	0.08
material	0.21	0.31	-0.05	0.03	-0.06	0.04	0.03	0.01	-0.01	0.00	-0.05	0.04	-0.15	0.32	0.00	0.00	-0.04	0.03	-0.09	0.17
ancient	0.23	0.35	-0.03	0.01	-0.10	0.10	-0.01	0.00	-0.15	0.27	-0.17	0.38	-0.16	0.36	0.13	0.29	-0.03	0.02	0.09	0.15
result	0.27	0.48	-0.05	0.02	-0.05	0.03	-0.09	0.10	-0.01	0.00	-0.07	0.07	0.01	0.00	-0.05	0.04	0.01	0.00	-0.02	0.00
analysis	0.36	0.89	-0.10	0.09	-0.10	0.09	0.01	0.00	0.03	0.01	-0.12	0.19	-0.10	0.14	-0.09	0.13	-0.02	0.00	-0.04	0.04
rome	0.20	0.26	0.05	0.02	-0.15	0.21	0.07	0.06	-0.25	0.75	0.22	0.64	-0.08	0.10	0.09	0.14	-0.06	0.06	0.16	0.49
ages	0.03	0.01	-0.04	0.01	0.03	0.01	-0.09	0.09	-0.07	0.05	0.06	0.05	0.09	0.11	-0.07	0.08	0.08	0.11	0.18	0.61
context	0.05	0.02	0.08	0.05	-0.06	0.04	0.00	0.00	-0.03	0.01	-0.06	0.05	-0.19	0.52	-0.04	0.03	-0.05	0.05	-0.07	0.10
lead	0.12	0.10	-0.10	0.08	-0.06	0.04	-0.12	0.16	-0.13	0.22	-0.01	0.00	0.16	0.35	-0.04	0.02	0.04	0.03	-0.00	0.00
hand	-0.18	0.21	-0.15	0.18	-0.12	0.14	-0.02	0.00	0.00	0.00	-0.06	0.04	0.11	0.18	-0.06	0.06	-0.02	0.01	0.01	0.00
account	-0.10	0.07	0.09	0.06	0.04	0.02	-0.07	0.06	0.04	0.02	-0.02	0.01	-0.06	0.05	0.10	0.18	0.07	0.08	-0.04	0.02
cultural	0.08	0.04	0.11	0.09	0.01	0.00	0.08	0.07	-0.05	0.04	-0.04	0.02	-0.22	0.65	0.03	0.01	0.13	0.29	0.02	0.01
accord	0.05	0.01	0.02	0.00	-0.05	0.03	0.03	0.01	-0.01	0.00	-0.02	0.01	-0.03	0.02	0.08	0.12	0.04	0.03	0.01	0.00
often	-0.06	0.03	-0.04	0.01	0.02	0.00	0.05	0.03	0.01	0.00	0.02	0.01	-0.04	0.03	0.02	0.01	0.00	0.00	-0.05	0.05
individual	0.33	0.72	-0.08	0.05	-0.12	0.13	0.06	0.04	-0.06	0.04	-0.31	1.21	-0.19	0.51	-0.12	0.26	-0.11	0.23	0.08	0.10
line	-0.23	0.35	0.16	0.20	0.02	0.00	0.12	0.15	-0.07	0.06	0.00	0.00	0.13	0.22	0.01	0.00	-0.02	0.00	0.20	0.70
role	0.02	0.00	-0.08	0.05	0.01	0.00	0.04	0.02	0.08	0.08	0.10	0.12	-0.05	0.04	0.03	0.02	0.06	0.06	-0.01	0.00
western	0.11	0.07	0.11	0.09	-0.05	0.02	-0.02	0.00	0.17	0.34	-0.18	0.40	0.02	0.01	-0.03	0.01	0.05	0.05	-0.00	0.00
narrative	0.00	0.00	0.22	0.37	0.40	1.45	-0.24	0.59	0.14	0.24	-0.20	0.50	-0.10	0.14	-0.00	0.00	0.22	0.86	-0.02	0.01
community	0.11	0.08	0.01	0.00	0.22	0.46	0.01	0.00	0.11	0.13	0.08	0.08	-0.03	0.01	-0.05	0.03	0.21	0.73	-0.02	0.01
identity	0.04	0.01	0.28	0.60	0.31	0.89	-0.28	0.81	0.10	0.11	-0.09	0.11	-0.11	0.15	-0.02	0.01	0.33	1.81	-0.04	0.03
research	0.15	0.14	0.03	0.01	-0.05	0.02	0.06	0.04	0.11	0.12	-0.19	0.42	-0.14	0.26	-0.12	0.25	0.04	0.03	-0.02	0.01
jews	0.53	1.75	-0.98	7.32	-0.49	2.16	-0.86	7.54	-0.21	0.50	-0.07	0.06	0.84	9.21	-0.40	2.60	0.21	0.74	0.10	0.17
record	0.00	0.00	0.03	0.01	0.17	0.26	0.03	0.01	0.21	0.49	0.05	0.03	0.09	0.10	0.09	0.13	-0.02	0.01	0.00	0.00
war	0.05	0.02	-0.04	0.02	-0.09	0.08	-0.23	0.53	-0.10	0.10	-0.03	0.01	0.27	0.93	0.08	0.11	0.07	0.07	0.05	0.04
region	0.43	1.12	-0.11	0.10	-0.00	0.00	0.06	0.04	0.18	0.37	-0.06	0.04	-0.11	0.15	0.04	0.02	-0.10	0.17	-0.01	0.00
still	-0.09	0.04	-0.05	0.02	-0.06	0.04	0.01	0.00	0.03	0.01	0.05	0.03	-0.01	0.00	0.11	0.18	-0.03	0.01	-0.01	0.00
rule	-0.22	0.30	-0.12	0.10	-0.14	0.18	0.05	0.02	0.22	0.51	0.02	0.01	0.06	0.05	-0.01	0.00	0.06	0.07	-0.02	0.01
consider	0.01	0.00	0.01	0.00	-0.04	0.01	0.03	0.01	-0.02	0.01	-0.08	0.07	-0.01	0.00	0.01	0.00	0.03	0.01	-0.05	0.04
local	0.28	0.48	-0.05	0.02	-0.10	0.08	0.04	0.01	0.04	0.02	-0.05	0.03	-0.02	0.01	-0.07	0.08	-0.02	0.01	-0.05	0.04
death	-0.04	0.01	-0.01	0.00	-0.06	0.04	-0.06	0.04	-0.01	0.00	-0.10	0.12	0.06	0.04	-0.05	0.04	0.11	0.20	0.01	0.00
reference	-0.07	0.03	0.04	0.01	-0.08	0.05	0.04	0.01	0.15	0.25	-0.03	0.01	0.01	0.00	-0.01	0.00	0.04	0.03	0.03	0.02
west	0.12	0.09	-0.05	0.02	0.40	1.41	0.09	0.08	0.00	0.00	0.01	0.00	-0.00	0.00	-0.03	0.02	-0.06	0.06	0.05	0.04
population	0.53	1.67	-0.20	0.28	-0.08	0.06	0.22	0.48	0.11	0.13	-0.12	0.16	-0.23	0.64	-0.14	0.28	-0.07	0.09	-0.00	0.00
slave	0.04	0.01	-0.06	0.02	-0.09	0.06	0.41	1.59	0.23	0.57	0.03	0.01	-0.20	0.48	0.01	0.00	-0.15	0.38	-0.02	0.01
york	-0.12	0.08	0.10	0.07	0.05	0.02	-0.04	0.01	-0.15	0.24	0.14	0.24	0.02	0.00	-0.07	0.08	-0.03	0.01	0.07	0.09
literature	-0.32	0.58	0.01	0.00	-0.02	0.00	0.15	0.22	-0.11	0.12	0.02	0.01	0.06	0.04	-0.06	0.06	0.07	0.08	-0.05	0.04
settlement	0.36	0.76	-0.33	0.81	0.78	5.10	0.30	0.84	0.12	0.14	0.00	0.00	0.08	0.08	-0.05	0.04	-0.15	0.34	0.00	0.00
similar	0.07	0.03	-0.08	0.04	-0.01	0.00	-0.07	0.04	-0.03	0.01	-0.01	0.00	-0.08	0.09	0.08	0.10	-0.05	0.04	-0.04	0.03
question	-0.13	0.10	0.03	0.01	0.00	0.00	0.07	0.04	-0.02	0.01	-0.03	0.01	0.01	0.00	-0.03	0.01	0.05	0.03	-0.06	0.06

right	-0.12	0.08	-0.14	0.14	-0.16	0.23	-0.08	0.06	-0.08	0.07	-0.03	0.01	0.14	0.26	-0.00	0.00	-0.04	0.03	0.00	0.00
story	-0.09	0.04	-0.09	0.05	0.11	0.10	-0.03	0.01	-0.15	0.24	-0.09	0.10	0.19	0.46	0.02	0.01	0.16	0.42	-0.11	0.20
son	-0.12	0.08	-0.07	0.03	0.07	0.05	0.06	0.04	-0.08	0.06	-0.01	0.00	0.06	0.04	0.15	0.33	0.04	0.02	0.21	0.69
refer	-0.00	0.00	0.01	0.00	-0.05	0.02	0.02	0.00	0.03	0.01	0.03	0.01	-0.07	0.06	0.12	0.21	0.03	0.02	-0.05	0.04
bishop	0.05	0.02	-0.01	0.00	-0.23	0.43	-0.04	0.01	-0.31	0.96	0.20	0.45	-0.05	0.03	0.01	0.00	-0.06	0.07	0.05	0.04
read	-0.16	0.15	0.10	0.06	0.07	0.04	0.05	0.02	-0.09	0.09	-0.04	0.02	0.08	0.07	-0.02	0.01	-0.02	0.00	-0.02	0.00
family	-0.19	0.21	-0.09	0.06	0.10	0.07	0.22	0.46	-0.14	0.20	-0.08	0.06	-0.11	0.14	0.06	0.06	0.18	0.53	0.91	13.10
saint	0.03	0.01	0.02	0.00	-0.12	0.13	0.02	0.00	-0.26	0.68	0.11	0.14	-0.02	0.01	0.12	0.20	0.07	0.07	0.01	0.00
represent	0.05	0.01	-0.03	0.01	0.03	0.01	-0.04	0.02	-0.04	0.01	-0.04	0.01	-0.09	0.10	-0.00	0.00	-0.07	0.08	0.04	0.02
body	0.10	0.05	0.01	0.00	0.10	0.09	-0.21	0.40	-0.08	0.06	-0.15	0.25	-0.09	0.09	0.05	0.04	0.07	0.08	-0.08	0.09
journal	0.13	0.10	0.11	0.09	0.06	0.03	-0.08	0.06	0.12	0.15	0.00	0.00	-0.08	0.07	-0.04	0.02	0.09	0.12	-0.03	0.01
version	-0.07	0.03	0.03	0.01	-0.11	0.10	-0.10	0.09	-0.02	0.00	-0.11	0.13	0.04	0.02	-0.09	0.11	0.07	0.08	-0.11	0.18
type	-0.02	0.00	-0.19	0.24	-0.01	0.00	0.09	0.07	0.02	0.01	0.18	0.35	-0.20	0.49	0.07	0.07	-0.00	0.00	0.12	0.24
day	0.10	0.06	-0.08	0.05	0.00	0.00	-0.07	0.05	-0.08	0.06	-0.08	0.07	0.11	0.15	0.11	0.16	0.00	0.00	0.18	0.47
nature	-0.14	0.10	-0.09	0.05	0.05	0.02	-0.01	0.00	-0.07	0.05	-0.08	0.07	-0.04	0.02	0.13	0.25	0.03	0.01	-0.08	0.10
royal	0.21	0.24	-0.22	0.32	-0.18	0.26	-0.10	0.09	0.02	0.00	0.12	0.16	0.34	1.31	-0.16	0.37	-0.04	0.02	0.05	0.03
therefore	-0.04	0.01	-0.11	0.08	-0.00	0.00	-0.06	0.03	-0.04	0.01	0.02	0.01	-0.10	0.12	-0.04	0.02	-0.04	0.03	-0.06	0.05
central	0.28	0.42	-0.09	0.05	0.03	0.01	0.06	0.03	0.03	0.01	-0.12	0.14	-0.16	0.30	0.02	0.00	-0.08	0.09	-0.02	0.01
small	0.19	0.20	-0.13	0.12	0.05	0.02	0.03	0.01	-0.03	0.01	0.10	0.10	0.02	0.00	0.03	0.01	-0.10	0.15	0.03	0.01
letter	-0.11	0.07	0.13	0.10	-0.10	0.08	0.01	0.00	-0.10	0.10	0.08	0.07	-0.08	0.08	0.06	0.04	0.08	0.09	0.02	0.01
common	0.00	0.00	0.02	0.00	-0.03	0.01	0.07	0.04	0.06	0.04	0.01	0.00	-0.03	0.01	-0.05	0.04	0.03	0.01	-0.01	0.00
european	0.16	0.14	-0.04	0.01	-0.10	0.08	0.05	0.02	-0.13	0.17	-0.14	0.19	-0.09	0.09	-0.05	0.04	0.11	0.16	0.09	0.12
identify	0.07	0.02	-0.02	0.00	-0.06	0.03	0.09	0.07	0.12	0.14	-0.11	0.14	-0.05	0.02	-0.02	0.01	-0.06	0.05	0.02	0.01
christ	0.19	0.19	-0.08	0.04	-0.01	0.00	-0.22	0.44	-0.28	0.72	0.12	0.15	0.31	1.05	-0.04	0.02	-0.03	0.01	-0.04	0.02
live	0.07	0.03	-0.02	0.00	0.00	0.00	0.11	0.11	-0.00	0.00	0.11	0.13	0.10	0.11	0.05	0.03	0.15	0.30	-0.00	0.00
set	0.05	0.01	0.11	0.08	0.02	0.00	-0.11	0.10	0.07	0.04	-0.03	0.01	-0.04	0.02	0.01	0.00	0.01	0.00	-0.01	0.00
several	0.07	0.03	-0.15	0.14	-0.08	0.05	-0.06	0.03	-0.06	0.04	0.06	0.03	-0.08	0.08	-0.00	0.00	-0.03	0.02	-0.01	0.00
influence	0.01	0.00	0.12	0.09	-0.03	0.01	-0.04	0.01	-0.02	0.00	0.04	0.01	-0.05	0.03	-0.07	0.06	0.07	0.07	-0.06	0.06
east	0.19	0.19	0.03	0.00	-0.00	0.00	-0.01	0.00	-0.02	0.00	-0.00	0.00	0.00	0.00	-0.03	0.01	-0.03	0.01	-0.02	0.01
archaeological	0.42	0.92	-0.18	0.21	0.23	0.41	0.04	0.01	-0.02	0.00	-0.12	0.14	-0.17	0.32	-0.16	0.36	-0.08	0.09	-0.07	0.06
origin	0.10	0.05	0.09	0.06	0.03	0.01	-0.01	0.00	0.03	0.01	-0.01	0.00	-0.21	0.47	-0.11	0.16	-0.05	0.03	0.02	0.01
value	0.29	0.44	-0.13	0.11	-0.05	0.02	-0.13	0.14	-0.07	0.04	-0.15	0.24	0.06	0.04	-0.04	0.02	0.01	0.00	0.03	0.01
understand	-0.05	0.01	0.13	0.12	0.05	0.02	-0.01	0.00	-0.06	0.03	-0.09	0.09	-0.08	0.06	0.02	0.00	0.08	0.10	-0.13	0.25
leave	-0.06	0.02	-0.09	0.05	-0.00	0.00	-0.03	0.01	-0.06	0.04	0.01	0.00	-0.01	0.00	0.06	0.04	-0.01	0.00	-0.00	0.00
translation	-0.07	0.03	0.16	0.15	0.00	0.00	0.06	0.03	0.11	0.10	0.17	0.29	0.09	0.08	-0.02	0.01	-0.03	0.02	-0.04	0.02
less	-0.09	0.04	0.03	0.01	0.05	0.02	0.01	0.00	-0.06	0.03	0.01	0.00	0.08	0.07	0.09	0.11	-0.06	0.04	-0.03	0.01
possible	0.07	0.03	-0.00	0.00	0.02	0.00	0.05	0.02	0.02	0.01	0.01	0.00	-0.00	0.00	-0.02	0.00	-0.14	0.29	0.01	0.00
general	-0.09	0.04	-0.05	0.01	-0.07	0.04	0.06	0.03	0.01	0.00	0.10	0.11	0.08	0.07	-0.04	0.02	-0.08	0.10	0.03	0.01
especially	-0.00	0.00	0.04	0.01	-0.05	0.01	0.07	0.04	-0.11	0.12	0.00	0.00	0.02	0.01	0.05	0.04	-0.00	0.00	0.01	0.00
claim	-0.12	0.08	0.09	0.06	0.00	0.00	-0.01	0.00	0.05	0.02	0.03	0.01	0.01	0.00	-0.00	0.00	0.09	0.11	-0.07	0.06
article	0.12	0.07	0.08	0.04	-0.07	0.04	0.07	0.05	-0.11	0.11	-0.13	0.17	-0.20	0.43	-0.04	0.02	0.01	0.00	-0.06	0.05
idea	-0.09	0.04	0.12	0.09	0.07	0.03	-0.02	0.00	-0.21	0.38	-0.03	0.01	-0.09	0.09	-0.02	0.00	0.05	0.03	-0.10	0.14

indicate	-0.06	0.02	-0.23	0.34	-0.04	0.01	-0.01	0.00	0.20	0.35	0.00	0.00	-0.04	0.01	0.06	0.04	-0.20	0.54	0.06	0.05
event	0.02	0.00	0.03	0.00	-0.01	0.00	-0.08	0.05	-0.00	0.00	-0.16	0.26	0.02	0.00	-0.03	0.01	0.06	0.05	-0.07	0.07
play	-0.20	0.20	0.12	0.09	0.03	0.01	0.04	0.01	-0.17	0.26	0.24	0.54	-0.02	0.00	0.13	0.20	-0.10	0.13	-0.16	0.34
poem	-0.43	0.91	0.28	0.49	0.29	0.59	0.28	0.64	-0.17	0.26	0.27	0.69	0.34	1.20	0.04	0.02	0.05	0.04	-0.15	0.32
support	0.03	0.01	-0.09	0.05	-0.15	0.16	0.01	0.00	0.08	0.06	-0.03	0.01	0.04	0.02	-0.07	0.05	0.01	0.00	-0.03	0.01
regard	-0.08	0.03	-0.02	0.00	-0.03	0.01	0.06	0.03	0.03	0.01	-0.04	0.02	-0.01	0.00	0.05	0.03	0.13	0.22	-0.09	0.12
pagan	0.04	0.01	0.11	0.07	-0.18	0.24	0.02	0.00	-0.44	1.71	-0.00	0.00	-0.13	0.19	0.29	1.09	0.17	0.38	-0.28	1.04
probably	0.00	0.00	-0.07	0.03	-0.03	0.01	0.05	0.02	0.02	0.01	0.15	0.22	0.02	0.00	0.13	0.20	-0.16	0.33	0.03	0.01
town	0.38	0.72	-0.33	0.67	0.71	3.57	0.28	0.65	0.23	0.47	0.37	1.28	0.27	0.77	-0.05	0.03	0.10	0.12	0.03	0.01
non	0.02	0.00	-0.02	0.00	-0.08	0.04	0.02	0.00	-0.06	0.03	-0.11	0.12	0.05	0.03	-0.01	0.00	-0.09	0.11	0.08	0.09
hold	-0.18	0.15	-0.12	0.08	-0.04	0.01	0.03	0.01	-0.01	0.00	0.09	0.07	-0.02	0.00	-0.04	0.02	0.01	0.00	0.06	0.04
relate	0.02	0.00	0.02	0.00	-0.08	0.04	-0.11	0.10	0.08	0.05	-0.11	0.11	-0.23	0.54	0.02	0.01	-0.04	0.02	-0.01	0.00
studies	-0.05	0.01	0.07	0.03	0.13	0.12	-0.03	0.01	-0.03	0.01	0.09	0.08	0.03	0.01	-0.06	0.05	0.07	0.07	-0.00	0.00
need	-0.08	0.03	0.02	0.00	-0.01	0.00	-0.06	0.03	-0.06	0.03	0.03	0.01	0.01	0.00	0.01	0.00	-0.01	0.00	-0.03	0.01
perhaps	-0.14	0.10	0.04	0.01	0.08	0.04	-0.09	0.06	0.02	0.00	0.08	0.05	0.06	0.04	0.17	0.37	-0.19	0.47	-0.02	0.01
court	-0.26	0.33	0.15	0.13	-0.26	0.47	0.28	0.60	0.25	0.52	-0.18	0.29	0.35	1.25	-0.06	0.05	0.13	0.21	0.02	0.01
least	-0.06	0.02	-0.03	0.01	0.01	0.00	-0.04	0.01	-0.01	0.00	0.05	0.02	-0.00	0.00	0.04	0.02	-0.11	0.17	-0.01	0.00
chapter	-0.41	0.80	0.05	0.02	-0.37	0.94	0.59	2.70	0.66	3.67	-0.54	2.70	0.52	2.78	-0.27	0.90	0.09	0.11	0.09	0.11
south	0.20	0.20	-0.01	0.00	0.06	0.02	0.07	0.04	0.00	0.00	0.07	0.04	-0.05	0.03	-0.09	0.11	-0.05	0.03	-0.01	0.00
last	0.02	0.00	0.11	0.07	-0.02	0.00	-0.09	0.07	0.04	0.01	-0.04	0.01	0.01	0.00	0.01	0.00	0.05	0.03	0.01	0.00
argue	-0.17	0.13	0.09	0.05	0.12	0.11	-0.02	0.00	0.03	0.01	0.07	0.04	-0.05	0.02	-0.05	0.04	0.07	0.07	-0.04	0.02
turn	-0.06	0.02	0.04	0.01	0.04	0.01	-0.03	0.01	-0.05	0.02	0.00	0.00	0.04	0.02	0.08	0.08	0.00	0.00	-0.03	0.01
scholar	-0.16	0.12	0.10	0.05	-0.05	0.02	0.15	0.18	-0.05	0.02	-0.08	0.06	0.05	0.02	0.11	0.14	0.16	0.34	-0.05	0.04
emperor	0.24	0.28	-0.10	0.05	-0.21	0.31	-0.02	0.00	-0.01	0.00	0.13	0.16	-0.01	0.00	0.15	0.27	-0.00	0.00	-0.03	0.01
particular	-0.06	0.01	0.13	0.10	0.03	0.00	0.01	0.00	0.01	0.00	0.06	0.03	-0.05	0.02	-0.02	0.00	0.02	0.00	-0.09	0.10
contemporary	-0.07	0.03	0.09	0.04	-0.05	0.02	0.04	0.01	-0.03	0.01	-0.06	0.04	-0.08	0.07	-0.06	0.05	0.06	0.05	-0.02	0.01
cross	-0.01	0.00	0.12	0.08	-0.10	0.07	-0.17	0.21	-0.31	0.79	0.15	0.21	0.26	0.65	-0.23	0.67	-0.26	0.83	-0.08	0.08
chronicle	0.02	0.00	0.21	0.26	-0.03	0.01	-0.04	0.01	0.07	0.04	-0.07	0.05	-0.17	0.28	0.14	0.22	0.15	0.29	-0.12	0.19
subject	-0.19	0.16	-0.01	0.00	0.00	0.00	0.04	0.01	-0.01	0.00	-0.03	0.01	-0.07	0.04	0.06	0.05	-0.00	0.00	0.00	0.00
knowledge	-0.17	0.14	0.08	0.04	-0.14	0.12	0.25	0.48	0.03	0.01	-0.25	0.59	0.06	0.03	0.03	0.01	0.09	0.10	-0.15	0.30
kingdom	0.11	0.05	0.09	0.05	0.11	0.09	-0.21	0.35	0.13	0.14	0.11	0.10	0.31	0.93	0.26	0.83	-0.06	0.05	-0.01	0.00
william	-0.10	0.04	0.50	1.44	0.09	0.06	-0.34	0.89	0.45	1.63	0.08	0.05	-0.06	0.04	-0.04	0.02	0.26	0.87	0.15	0.29
structure	0.22	0.22	0.01	0.00	-0.02	0.00	0.10	0.08	0.05	0.02	0.04	0.02	-0.08	0.07	-0.06	0.04	-0.13	0.21	-0.01	0.00
literary	-0.28	0.36	0.12	0.09	-0.07	0.04	0.25	0.46	-0.03	0.01	-0.15	0.20	0.17	0.27	-0.09	0.09	0.06	0.05	-0.05	0.04
bring	-0.12	0.06	-0.06	0.02	-0.02	0.00	0.05	0.02	-0.05	0.02	-0.00	0.00	0.03	0.01	0.12	0.18	0.01	0.00	0.02	0.01
model	0.15	0.10	0.20	0.23	-0.00	0.00	-0.06	0.02	0.13	0.13	-0.26	0.60	-0.34	1.08	-0.03	0.01	-0.04	0.02	-0.01	0.00
element	0.02	0.00	-0.03	0.01	0.04	0.01	-0.07	0.03	-0.10	0.09	0.01	0.00	-0.10	0.10	-0.05	0.03	-0.12	0.18	-0.05	0.03
relationship	-0.02	0.00	-0.02	0.00	0.14	0.14	-0.05	0.02	0.03	0.01	-0.05	0.02	0.01	0.00	-0.07	0.06	0.11	0.14	-0.01	0.00
concern	-0.15	0.11	0.03	0.01	-0.05	0.02	0.06	0.03	-0.04	0.01	-0.03	0.01	0.08	0.06	-0.01	0.00	-0.00	0.00	0.03	0.01
act	0.03	0.00	0.07	0.03	0.02	0.00	-0.20	0.29	0.02	0.00	-0.12	0.14	0.08	0.06	-0.07	0.06	0.11	0.16	-0.04	0.02
northern	0.16	0.11	0.03	0.00	-0.06	0.02	-0.01	0.00	0.06	0.03	0.01	0.00	-0.06	0.03	-0.07	0.05	-0.02	0.00	0.06	0.04
establish	-0.00	0.00	0.05	0.01	0.06	0.03	0.09	0.06	-0.02	0.00	0.01	0.00	-0.03	0.01	-0.06	0.04	0.06	0.04	-0.06	0.04

contain	0.07	0.02	-0.01	0.00	-0.12	0.09	-0.01	0.00	-0.02	0.00	-0.03	0.01	0.02	0.00	-0.03	0.01	-0.05	0.04	-0.06	0.04
authority	-0.12	0.07	-0.07	0.02	-0.12	0.09	0.06	0.03	0.01	0.00	-0.01	0.00	-0.03	0.01	0.02	0.00	0.07	0.06	-0.06	0.04
create	0.07	0.02	0.00	0.00	0.05	0.02	-0.06	0.03	-0.04	0.01	-0.03	0.01	-0.11	0.12	0.02	0.01	0.10	0.11	-0.11	0.15
original	-0.03	0.00	0.09	0.05	-0.06	0.02	0.13	0.12	-0.05	0.02	0.00	0.00	-0.06	0.03	0.05	0.03	-0.05	0.03	-0.11	0.16
far	-0.04	0.01	0.07	0.03	0.02	0.00	0.02	0.00	-0.06	0.03	0.05	0.03	0.04	0.01	0.08	0.08	-0.01	0.00	-0.05	0.03
religion	-0.05	0.01	0.10	0.05	-0.04	0.01	0.02	0.00	-0.18	0.27	-0.00	0.00	-0.14	0.19	0.12	0.17	0.36	1.57	-0.16	0.32
continue	0.10	0.05	-0.03	0.01	-0.02	0.00	-0.03	0.00	0.06	0.03	0.13	0.14	0.02	0.01	0.03	0.01	0.07	0.07	0.03	0.01
various	-0.03	0.00	-0.03	0.00	0.01	0.00	0.01	0.00	-0.02	0.00	-0.09	0.08	-0.01	0.00	0.01	0.00	-0.06	0.04	-0.02	0.00
sense	-0.23	0.24	0.17	0.15	0.02	0.00	-0.04	0.01	-0.03	0.01	0.05	0.02	0.05	0.02	0.05	0.03	0.06	0.05	0.00	0.00
iii	-0.23	0.23	0.05	0.01	-0.18	0.21	0.14	0.15	0.24	0.45	-0.21	0.37	0.53	2.67	0.32	1.17	-0.29	1.01	0.24	0.71
system	0.11	0.05	0.16	0.13	0.04	0.01	-0.12	0.11	0.21	0.36	-0.08	0.05	-0.04	0.02	-0.03	0.01	0.13	0.20	-0.07	0.07
jewish	0.49	1.05	-0.61	2.02	-0.41	1.04	-0.58	2.36	-0.25	0.48	0.00	0.00	0.63	3.67	-0.23	0.58	0.23	0.60	0.03	0.01
norman	0.17	0.13	0.11	0.06	0.14	0.12	0.21	0.32	0.48	1.74	0.63	3.34	0.26	0.62	0.01	0.00	0.14	0.22	0.13	0.21
publish	0.15	0.10	0.03	0.00	-0.18	0.20	0.11	0.08	-0.05	0.02	0.03	0.01	-0.14	0.18	-0.05	0.03	-0.11	0.15	0.05	0.03
process	0.14	0.09	-0.04	0.01	-0.04	0.01	0.06	0.03	0.03	0.01	-0.10	0.09	-0.02	0.01	-0.02	0.01	0.04	0.02	-0.06	0.05
report	0.04	0.01	0.02	0.00	0.05	0.02	-0.12	0.11	-0.05	0.02	-0.12	0.12	0.08	0.05	0.06	0.04	0.07	0.06	0.01	0.00
battle	-0.33	0.47	-0.02	0.00	0.05	0.02	-0.46	1.48	0.26	0.51	0.08	0.05	-0.09	0.07	0.02	0.00	-0.11	0.13	-0.08	0.08
discuss	-0.15	0.10	-0.10	0.05	-0.06	0.02	-0.05	0.02	0.18	0.25	0.08	0.05	-0.01	0.00	-0.07	0.06	-0.02	0.00	-0.04	0.02
force	-0.21	0.19	-0.14	0.11	0.02	0.00	-0.12	0.09	0.13	0.12	0.06	0.03	-0.04	0.01	-0.03	0.01	0.03	0.01	-0.04	0.02
likely	0.20	0.16	-0.04	0.01	-0.02	0.00	0.00	0.00	0.14	0.15	0.14	0.17	0.00	0.00	0.01	0.00	0.00	0.00	-0.03	0.01
clear	-0.04	0.01	0.08	0.03	0.05	0.01	-0.07	0.04	0.05	0.02	0.05	0.02	-0.00	0.00	0.02	0.01	-0.02	0.00	-0.01	0.00
interpretation	-0.14	0.09	0.16	0.14	-0.06	0.02	0.01	0.00	-0.11	0.09	-0.02	0.00	0.02	0.00	-0.02	0.00	-0.13	0.18	-0.12	0.18
section	0.01	0.00	0.15	0.13	-0.09	0.05	-0.16	0.18	0.11	0.09	-0.11	0.11	0.22	0.43	-0.12	0.16	-0.20	0.48	0.09	0.09
already	-0.03	0.00	-0.09	0.04	-0.11	0.08	0.06	0.02	0.02	0.00	-0.02	0.00	0.03	0.01	-0.06	0.04	-0.04	0.02	-0.03	0.01
level	0.06	0.01	0.13	0.08	0.10	0.06	-0.43	1.29	0.14	0.15	-0.01	0.00	0.49	2.16	0.67	4.99	-0.51	2.95	0.12	0.17
low	0.14	0.08	-0.07	0.03	0.07	0.03	-0.17	0.19	0.01	0.00	0.01	0.00	0.19	0.31	0.17	0.33	-0.29	0.98	0.09	0.09
development	0.01	0.00	0.01	0.00	-0.05	0.01	0.03	0.01	-0.05	0.02	0.03	0.01	0.02	0.00	-0.01	0.00	0.05	0.03	-0.05	0.03
trade	0.39	0.62	-0.15	0.12	-0.09	0.05	0.05	0.02	0.26	0.52	0.30	0.74	0.18	0.29	-0.07	0.05	-0.02	0.00	0.03	0.01
datum	0.41	0.69	-0.19	0.18	-0.27	0.43	-0.04	0.01	0.12	0.11	-0.28	0.66	-0.02	0.00	-0.09	0.09	-0.07	0.05	0.03	0.01
approach	0.05	0.01	0.07	0.03	-0.05	0.01	0.09	0.05	-0.05	0.02	-0.15	0.19	-0.12	0.13	-0.08	0.07	-0.05	0.03	-0.10	0.11
german	-0.17	0.11	0.03	0.00	-0.13	0.11	0.02	0.00	-0.16	0.19	0.23	0.44	-0.13	0.16	-0.27	0.81	0.16	0.30	0.00	0.00
greek	0.04	0.01	0.01	0.00	-0.01	0.00	0.01	0.00	-0.18	0.25	0.05	0.02	-0.13	0.14	0.21	0.47	-0.01	0.00	0.32	1.22
military	0.16	0.11	0.09	0.04	-0.09	0.05	-0.16	0.18	0.13	0.13	-0.11	0.10	0.07	0.04	0.02	0.01	0.22	0.56	-0.02	0.01
indeed	-0.09	0.03	-0.04	0.01	0.04	0.01	-0.08	0.04	-0.05	0.02	0.07	0.03	0.09	0.07	0.15	0.24	-0.11	0.15	-0.01	0.00
eastern	0.25	0.26	-0.07	0.02	-0.07	0.03	0.01	0.00	0.00	0.00	-0.13	0.14	0.01	0.00	0.00	0.00	0.07	0.06	-0.01	0.00
think	-0.15	0.09	0.11	0.07	0.09	0.05	-0.08	0.04	-0.11	0.09	0.04	0.01	-0.01	0.00	0.03	0.01	0.01	0.00	-0.09	0.09
historian	-0.06	0.01	0.09	0.04	-0.16	0.15	0.08	0.04	0.04	0.01	0.02	0.00	0.02	0.00	-0.07	0.05	0.14	0.22	0.05	0.03
issue	-0.10	0.04	0.05	0.01	-0.05	0.02	0.20	0.28	-0.08	0.05	0.01	0.00	0.02	0.00	-0.01	0.00	0.08	0.07	-0.05	0.03
reason	-0.17	0.12	0.00	0.00	0.01	0.00	-0.01	0.00	-0.07	0.04	-0.03	0.01	0.09	0.07	0.07	0.06	0.11	0.13	-0.15	0.25
other	-0.06	0.01	0.09	0.04	0.02	0.00	-0.04	0.01	-0.00	0.00	0.02	0.00	0.03	0.01	0.04	0.02	0.09	0.09	-0.02	0.00
byzantine	0.40	0.64	-0.15	0.11	-0.23	0.30	0.01	0.00	-0.20	0.29	0.02	0.00	-0.13	0.16	0.22	0.50	-0.14	0.21	-0.08	0.08
certain	-0.10	0.04	-0.11	0.06	-0.02	0.00	-0.04	0.01	0.04	0.01	0.04	0.01	-0.13	0.14	0.05	0.02	-0.06	0.04	-0.03	0.01

national	0.00	0.00	0.27	0.36	-0.02	0.00	-0.16	0.17	-0.06	0.03	0.01	0.00	-0.14	0.16	-0.12	0.14	0.26	0.75	-0.07	0.06
legal	0.15	0.08	-0.05	0.01	-0.22	0.28	0.25	0.40	0.22	0.33	-0.13	0.13	-0.11	0.10	-0.15	0.25	0.31	1.07	-0.02	0.00
interest	-0.12	0.05	0.04	0.01	0.02	0.00	-0.02	0.00	-0.11	0.08	0.07	0.03	0.01	0.00	-0.04	0.01	-0.02	0.01	0.03	0.01
draw	-0.06	0.01	0.07	0.02	-0.03	0.01	0.07	0.03	0.00	0.00	0.09	0.07	-0.02	0.00	0.01	0.00	-0.04	0.02	0.01	0.00
serve	0.02	0.00	0.11	0.07	0.06	0.02	0.00	0.00	0.05	0.02	-0.01	0.00	-0.03	0.01	0.08	0.06	0.05	0.03	0.07	0.05
archaeology	0.25	0.24	0.12	0.07	0.03	0.00	-0.05	0.02	-0.02	0.00	0.06	0.03	-0.25	0.54	-0.32	1.05	-0.08	0.07	-0.13	0.18
information	0.08	0.03	-0.16	0.12	-0.20	0.22	0.10	0.07	0.13	0.11	-0.08	0.05	-0.02	0.00	0.04	0.02	0.03	0.01	-0.03	0.01
position	0.08	0.02	-0.07	0.02	0.03	0.01	0.01	0.00	0.01	0.00	-0.03	0.01	-0.07	0.04	-0.01	0.00	0.01	0.00	0.02	0.00
explain	-0.05	0.01	-0.00	0.00	-0.08	0.04	0.01	0.00	-0.02	0.00	-0.05	0.02	-0.00	0.00	0.05	0.02	0.01	0.00	-0.03	0.01
produce	0.06	0.01	0.01	0.00	0.06	0.02	0.11	0.08	0.09	0.06	0.18	0.25	0.01	0.00	0.10	0.10	-0.11	0.14	-0.04	0.02
british	-0.15	0.09	0.20	0.20	0.26	0.40	-0.02	0.00	-0.04	0.01	0.10	0.07	-0.04	0.02	-0.31	0.99	0.02	0.00	0.04	0.01
focus	0.06	0.02	0.05	0.01	0.01	0.00	0.04	0.01	0.02	0.00	-0.06	0.03	-0.08	0.05	-0.04	0.02	0.07	0.06	-0.08	0.07
und	0.04	0.01	-0.02	0.00	-0.13	0.10	0.12	0.09	0.04	0.01	0.08	0.05	-0.24	0.50	-0.14	0.21	0.14	0.22	0.03	0.01
imperial	0.10	0.04	-0.08	0.03	-0.06	0.02	0.09	0.05	-0.02	0.00	0.13	0.14	-0.12	0.13	0.02	0.00	-0.06	0.04	-0.00	0.00
child	-0.35	0.48	-0.39	0.73	0.27	0.41	0.04	0.01	-0.08	0.04	-0.00	0.00	0.11	0.11	-0.07	0.05	-0.10	0.10	0.03	0.01
christians	0.34	0.46	-0.14	0.10	-0.14	0.12	-0.10	0.07	-0.03	0.01	0.32	0.79	0.18	0.27	0.15	0.22	0.27	0.80	-0.08	0.07
close	0.07	0.02	0.02	0.00	-0.00	0.00	0.01	0.00	-0.06	0.02	-0.00	0.00	-0.00	0.00	0.05	0.03	-0.10	0.12	0.02	0.00
antiquity	0.23	0.21	0.05	0.01	-0.16	0.14	-0.01	0.00	-0.10	0.06	-0.04	0.02	-0.23	0.45	-0.03	0.01	0.05	0.03	-0.04	0.02
edition	-0.33	0.43	0.31	0.47	-0.12	0.09	0.23	0.32	0.12	0.10	-0.03	0.01	0.13	0.14	-0.16	0.24	-0.17	0.29	0.05	0.02
barbarian	-0.02	0.00	0.22	0.23	-0.14	0.12	-0.02	0.00	-0.35	0.86	-0.01	0.00	-0.28	0.66	0.24	0.58	0.19	0.40	1.14	14.13
sample	0.79	2.37	-0.35	0.59	-0.37	0.76	-0.24	0.37	0.00	0.00	-0.36	0.97	0.11	0.10	-0.24	0.56	-0.15	0.23	0.03	0.01
associate	0.02	0.00	0.06	0.02	0.07	0.03	-0.04	0.01	0.02	0.00	-0.05	0.02	-0.13	0.13	0.07	0.04	-0.07	0.05	-0.03	0.01
discussion	-0.20	0.16	0.02	0.00	0.04	0.01	0.02	0.00	-0.01	0.00	0.03	0.01	-0.05	0.02	-0.06	0.03	-0.07	0.05	0.04	0.02
status	0.06	0.02	-0.05	0.01	0.00	0.00	0.08	0.04	-0.01	0.00	-0.05	0.02	0.01	0.00	-0.05	0.03	0.10	0.11	-0.07	0.05
building	0.61	1.40	-0.18	0.16	-0.01	0.00	0.13	0.11	0.21	0.30	0.48	1.74	0.10	0.09	-0.15	0.23	-0.25	0.68	0.04	0.01
offer	-0.11	0.05	0.08	0.03	0.18	0.17	0.10	0.06	0.02	0.00	-0.04	0.01	0.02	0.00	0.03	0.01	0.05	0.03	-0.02	0.00
house	0.06	0.01	-0.13	0.08	0.04	0.01	0.18	0.20	0.18	0.21	0.41	1.26	0.03	0.01	0.02	0.00	0.09	0.09	0.01	0.00
speak	-0.13	0.06	0.04	0.01	0.08	0.04	0.09	0.05	-0.12	0.11	-0.02	0.00	0.03	0.01	0.11	0.11	-0.04	0.01	-0.06	0.04
fall	-0.03	0.00	0.07	0.02	0.01	0.00	-0.15	0.14	-0.02	0.00	-0.01	0.00	0.10	0.08	0.11	0.11	-0.04	0.02	-0.04	0.02
attempt	-0.17	0.10	-0.06	0.01	0.07	0.02	-0.05	0.01	-0.03	0.00	0.02	0.00	-0.12	0.11	0.03	0.01	0.01	0.00	-0.03	0.01
main	0.28	0.29	-0.07	0.03	-0.11	0.07	0.02	0.00	-0.04	0.01	0.12	0.10	0.05	0.02	-0.02	0.01	0.07	0.04	-0.02	0.00
christianity	0.13	0.06	-0.00	0.00	-0.17	0.16	-0.13	0.10	-0.35	0.81	-0.14	0.13	0.02	0.00	0.16	0.25	0.24	0.57	-0.06	0.04
italy	0.35	0.45	-0.12	0.07	-0.12	0.08	0.06	0.02	0.05	0.02	0.41	1.24	0.04	0.01	0.01	0.00	0.05	0.03	0.17	0.31
problem	-0.14	0.07	0.01	0.00	-0.03	0.01	0.06	0.02	0.02	0.00	0.00	0.00	-0.08	0.05	-0.03	0.01	-0.02	0.00	-0.02	0.01
mark	0.02	0.00	0.10	0.05	0.12	0.07	-0.09	0.05	-0.02	0.00	-0.10	0.08	-0.03	0.01	0.03	0.01	-0.01	0.00	0.06	0.03
henry	-0.29	0.30	0.42	0.81	-0.03	0.00	-0.53	1.73	0.47	1.45	0.01	0.00	0.15	0.19	0.08	0.07	-0.16	0.27	0.14	0.22
wife	-1.66	10.21	-1.75	14.24	-0.08	0.03	-0.43	1.14	0.66	2.94	0.06	0.03	-0.43	1.48	-0.17	0.28	0.01	0.00	0.06	0.04
particularly	-0.01	0.00	-0.12	0.07	0.07	0.03	-0.02	0.00	0.09	0.06	0.12	0.11	0.02	0.00	0.03	0.01	-0.00	0.00	0.01	0.00
relation	-0.06	0.01	0.08	0.03	-0.02	0.00	-0.01	0.00	-0.08	0.04	0.00	0.00	-0.03	0.01	0.09	0.08	-0.01	0.00	-0.06	0.04
father	-0.15	0.09	-0.32	0.46	0.99	5.30	0.13	0.10	-0.10	0.07	-0.30	0.65	0.23	0.43	-0.00	0.00	0.04	0.02	0.18	0.32
description	0.12	0.05	0.00	0.00	0.07	0.03	-0.01	0.00	0.07	0.03	-0.08	0.04	0.02	0.00	0.02	0.00	-0.04	0.01	0.03	0.01
animal	0.07	0.02	-0.00	0.00	0.13	0.09	0.01	0.00	-0.29	0.55	-0.06	0.03	-0.11	0.09	0.08	0.06	-0.22	0.48	-0.04	0.02

von	0.06	0.01	-0.06	0.02	-0.11	0.06	0.13	0.10	0.08	0.04	0.03	0.01	-0.21	0.34	-0.02	0.00	0.23	0.52	0.01	0.00
holy	0.12	0.06	-0.04	0.01	-0.02	0.00	-0.12	0.09	-0.26	0.45	-0.05	0.02	0.12	0.10	0.13	0.16	0.18	0.32	-0.08	0.07
twelfth	0.00	0.00	0.21	0.20	-0.05	0.02	0.18	0.19	0.49	1.57	0.47	1.57	0.21	0.34	0.04	0.02	0.03	0.01	0.11	0.13
activity	0.22	0.18	-0.15	0.10	0.02	0.00	-0.12	0.09	-0.05	0.01	-0.08	0.04	-0.05	0.02	-0.08	0.05	-0.09	0.08	-0.05	0.03
cause	-0.05	0.01	-0.12	0.06	-0.06	0.02	-0.13	0.09	-0.04	0.01	0.01	0.00	0.02	0.00	0.10	0.09	0.01	0.00	-0.08	0.06
little	-0.08	0.03	0.01	0.00	0.06	0.02	-0.04	0.01	0.02	0.00	0.12	0.11	0.09	0.06	0.12	0.15	-0.10	0.10	-0.02	0.00
control	0.15	0.08	-0.20	0.18	0.07	0.03	-0.14	0.12	0.12	0.10	0.03	0.01	0.30	0.70	-0.12	0.14	0.05	0.03	0.05	0.02
review	-0.10	0.03	0.11	0.06	-0.00	0.00	0.12	0.09	-0.11	0.08	0.10	0.07	-0.03	0.01	-0.14	0.20	-0.03	0.01	0.04	0.01
allow	-0.00	0.00	-0.05	0.01	0.06	0.02	0.04	0.01	0.05	0.02	-0.12	0.10	0.04	0.01	-0.01	0.00	0.02	0.00	-0.02	0.00
paul	-0.03	0.00	0.24	0.25	0.08	0.03	-0.26	0.39	-0.01	0.00	0.02	0.00	-0.00	0.00	-0.06	0.03	0.12	0.14	0.05	0.02
theory	-0.12	0.05	0.21	0.20	-0.06	0.02	0.06	0.02	-0.10	0.07	-0.07	0.03	-0.13	0.12	-0.09	0.08	0.00	0.00	-0.17	0.28
list	-0.10	0.03	-0.06	0.02	-0.02	0.00	0.06	0.02	0.09	0.05	0.02	0.00	0.06	0.03	0.02	0.00	0.02	0.00	0.26	0.70
table	0.25	0.23	-0.27	0.33	0.05	0.01	-0.10	0.06	0.03	0.00	-0.30	0.63	0.29	0.66	-0.16	0.24	-0.14	0.18	0.20	0.41
reflect	-0.01	0.00	0.03	0.00	-0.05	0.01	0.09	0.04	-0.07	0.03	-0.15	0.16	-0.07	0.04	0.03	0.01	-0.06	0.03	0.01	0.00
link	0.10	0.03	0.06	0.02	-0.03	0.01	-0.07	0.03	0.10	0.06	-0.03	0.01	-0.15	0.18	-0.06	0.03	-0.04	0.02	-0.01	0.00
difference	0.15	0.08	0.01	0.00	-0.09	0.04	-0.19	0.21	-0.07	0.03	-0.09	0.06	0.06	0.03	0.00	0.00	0.02	0.00	0.05	0.02
recent	0.02	0.00	0.16	0.12	0.01	0.00	-0.04	0.01	0.11	0.08	0.04	0.01	-0.09	0.07	-0.03	0.01	-0.07	0.05	-0.03	0.01
experience	-0.08	0.02	0.10	0.04	-0.14	0.10	0.04	0.01	-0.16	0.16	-0.13	0.11	-0.16	0.20	0.03	0.01	0.04	0.02	-0.17	0.29
third	0.12	0.05	-0.01	0.00	-0.05	0.01	0.09	0.05	0.06	0.02	0.02	0.00	-0.12	0.11	-0.04	0.02	-0.14	0.19	0.02	0.00
introduction	-0.07	0.02	0.18	0.14	-0.04	0.01	0.10	0.06	0.18	0.21	-0.20	0.28	-0.00	0.00	-0.08	0.06	0.09	0.08	0.03	0.01
castle	0.08	0.02	-0.34	0.50	1.04	5.58	0.30	0.52	0.01	0.00	-0.13	0.12	0.10	0.07	0.01	0.00	0.64	3.90	-0.16	0.27
past	0.01	0.00	0.10	0.04	0.01	0.00	-0.14	0.12	-0.06	0.02	-0.02	0.00	-0.01	0.00	-0.18	0.28	0.18	0.31	-0.03	0.01
feature	0.04	0.01	-0.02	0.00	0.03	0.00	0.03	0.00	0.00	0.00	0.01	0.00	-0.10	0.08	0.01	0.00	-0.31	0.89	-0.02	0.00
character	-0.11	0.04	-0.01	0.00	0.07	0.02	-0.12	0.09	-0.03	0.00	-0.02	0.00	-0.06	0.02	0.02	0.00	0.12	0.13	-0.10	0.10
classical	-0.16	0.09	0.07	0.02	-0.14	0.11	0.20	0.23	-0.25	0.38	0.07	0.04	-0.12	0.10	-0.09	0.07	0.01	0.00	0.24	0.56
detail	0.05	0.01	0.04	0.01	-0.02	0.00	0.02	0.00	-0.01	0.00	0.00	0.00	0.01	0.00	0.04	0.02	-0.09	0.07	-0.06	0.04
reveal	-0.01	0.00	-0.15	0.10	0.04	0.01	0.05	0.01	-0.05	0.01	-0.19	0.25	-0.04	0.01	-0.07	0.04	-0.06	0.03	-0.05	0.03
presence	0.15	0.08	-0.14	0.09	-0.03	0.00	0.04	0.01	-0.03	0.01	0.05	0.02	-0.04	0.01	0.06	0.03	0.01	0.00	-0.02	0.00
ruler	0.14	0.07	0.14	0.08	0.01	0.00	-0.22	0.28	0.21	0.28	-0.04	0.01	-0.01	0.00	0.06	0.03	0.10	0.09	-0.01	0.00
compare	-0.11	0.04	-0.04	0.01	-0.27	0.36	0.32	0.58	0.27	0.44	-0.40	1.12	0.37	1.03	-0.22	0.42	-0.01	0.00	0.03	0.01
conquest	0.13	0.06	0.17	0.13	-0.05	0.01	0.03	0.00	0.23	0.34	0.08	0.05	-0.00	0.00	-0.11	0.11	-0.09	0.08	0.01	0.00
islamic	0.03	0.00	0.11	0.05	-0.34	0.59	0.43	1.06	0.61	2.27	-0.33	0.75	0.11	0.09	-0.16	0.22	0.13	0.16	-0.10	0.09
army	0.06	0.01	0.30	0.39	0.01	0.00	-0.23	0.29	-0.07	0.03	0.16	0.18	0.02	0.00	-0.34	1.02	-0.11	0.12	-0.09	0.09
concept	-0.06	0.01	0.06	0.02	-0.14	0.09	0.16	0.15	-0.02	0.00	-0.30	0.61	0.00	0.00	-0.05	0.03	0.07	0.05	-0.05	0.02
female	-0.45	0.70	-0.62	1.67	0.00	0.00	-0.09	0.05	0.06	0.02	0.06	0.02	-0.36	0.95	0.14	0.16	0.09	0.08	-0.22	0.45
course	-0.13	0.05	0.12	0.07	0.10	0.05	0.01	0.00	-0.06	0.02	0.07	0.03	0.15	0.17	0.13	0.15	-0.04	0.01	0.18	0.29
look	-0.28	0.28	-0.18	0.13	0.09	0.04	-0.03	0.01	-0.04	0.01	0.15	0.16	-0.03	0.01	0.03	0.01	-0.08	0.05	-0.05	0.03
mongol	0.17	0.10	-0.16	0.10	0.30	0.43	0.49	1.37	-0.05	0.01	-0.62	2.56	-0.06	0.03	0.06	0.03	-0.10	0.10	-0.16	0.25
poet	-0.44	0.65	0.06	0.01	0.58	1.66	0.23	0.30	-0.19	0.22	0.16	0.18	0.34	0.81	-0.05	0.02	0.02	0.00	-0.01	0.00
clearly	-0.16	0.09	-0.14	0.09	0.10	0.05	-0.09	0.05	-0.00	0.00	-0.02	0.00	-0.01	0.00	-0.03	0.01	-0.08	0.07	-0.01	0.00
stand	-0.21	0.15	-0.13	0.07	-0.05	0.01	-0.07	0.03	-0.04	0.01	0.03	0.00	0.02	0.00	0.05	0.03	0.01	0.00	-0.07	0.04
collection	-0.15	0.07	-0.04	0.01	-0.14	0.10	0.09	0.05	0.00	0.00	0.02	0.00	-0.02	0.00	0.02	0.00	-0.06	0.04	0.03	0.01

daughter	-0.09	0.03	-0.64	1.72	2.04	20.48	0.41	0.92	-0.14	0.11	-0.54	1.95	0.30	0.64	-0.05	0.02	0.11	0.11	0.15	0.22
public	-0.04	0.01	0.02	0.00	0.05	0.01	0.11	0.07	-0.16	0.16	0.08	0.05	0.03	0.01	-0.04	0.01	0.07	0.05	0.04	0.02
edit	0.43	0.61	-0.06	0.01	-0.11	0.06	-0.07	0.03	0.19	0.22	0.26	0.44	0.07	0.03	-0.10	0.09	0.12	0.12	0.04	0.01
page	-0.07	0.02	0.04	0.01	-0.14	0.10	0.07	0.02	-0.12	0.09	-0.19	0.23	0.14	0.14	-0.07	0.04	-0.03	0.01	-0.07	0.05
light	0.07	0.02	-0.01	0.00	-0.06	0.02	-0.10	0.06	-0.16	0.15	-0.02	0.00	0.01	0.00	0.08	0.05	0.06	0.03	-0.09	0.08
burial	0.58	1.12	-0.06	0.02	-0.13	0.08	-0.07	0.03	0.18	0.20	-0.14	0.13	-0.38	1.01	-0.03	0.01	-0.12	0.13	-0.05	0.02
kind	-0.19	0.12	0.19	0.15	-0.00	0.00	-0.04	0.01	-0.06	0.02	0.04	0.01	0.08	0.04	0.09	0.08	-0.04	0.02	-0.04	0.01
function	-0.02	0.00	0.03	0.00	0.11	0.06	0.13	0.09	-0.05	0.01	0.01	0.00	-0.16	0.18	0.03	0.01	-0.03	0.01	-0.05	0.02
thing	-0.15	0.08	0.09	0.04	-0.03	0.00	-0.06	0.02	-0.19	0.21	0.01	0.00	0.16	0.17	0.14	0.18	-0.03	0.01	-0.16	0.24
build	0.32	0.34	-0.11	0.05	0.06	0.02	0.01	0.00	-0.01	0.00	0.02	0.00	0.04	0.01	0.04	0.02	-0.05	0.03	-0.07	0.04
southern	0.23	0.17	-0.05	0.01	0.14	0.09	0.16	0.15	0.20	0.23	-0.00	0.00	0.01	0.00	0.02	0.00	-0.03	0.01	-0.05	0.02
whole	-0.12	0.05	0.11	0.05	0.03	0.00	-0.11	0.07	-0.12	0.09	0.05	0.02	0.02	0.00	-0.01	0.00	-0.11	0.10	0.00	0.00
copy	-0.12	0.05	0.03	0.00	-0.22	0.24	0.33	0.60	0.11	0.07	-0.34	0.76	-0.22	0.35	-0.10	0.08	-0.20	0.37	-0.01	0.00
muslim	0.52	0.90	-0.09	0.03	0.03	0.01	0.41	0.92	0.71	2.94	0.72	3.34	-0.00	0.00	0.17	0.25	0.54	2.62	-0.18	0.29
significant	0.17	0.09	-0.05	0.01	-0.06	0.01	-0.06	0.02	-0.03	0.01	-0.04	0.01	-0.04	0.01	-0.05	0.02	-0.03	0.01	-0.04	0.01
contrast	-0.12	0.05	0.02	0.00	0.03	0.00	0.06	0.02	-0.06	0.02	-0.10	0.06	0.06	0.03	0.02	0.00	0.04	0.02	0.11	0.11
object	-0.01	0.00	-0.12	0.06	0.03	0.00	-0.01	0.00	-0.15	0.13	0.00	0.00	-0.02	0.00	0.08	0.06	0.02	0.00	-0.12	0.14
receive	0.05	0.01	-0.10	0.04	-0.17	0.13	-0.12	0.07	-0.12	0.09	-0.10	0.06	0.03	0.01	0.01	0.00	0.10	0.09	0.08	0.05
together	0.01	0.00	-0.05	0.01	-0.07	0.02	-0.04	0.01	-0.04	0.01	-0.01	0.00	-0.02	0.00	0.05	0.02	0.03	0.01	-0.01	0.00
develop	-0.01	0.00	0.10	0.04	0.05	0.01	0.01	0.00	0.02	0.00	-0.01	0.00	-0.05	0.02	0.03	0.01	0.04	0.01	-0.06	0.04
irish	-0.15	0.08	0.05	0.01	0.25	0.30	0.15	0.12	-0.51	1.50	0.15	0.15	-0.17	0.19	0.13	0.14	0.13	0.16	0.23	0.50
economic	0.27	0.24	-0.12	0.06	0.02	0.00	0.12	0.08	0.14	0.11	0.26	0.42	0.13	0.12	-0.08	0.05	0.14	0.19	0.05	0.03
open	0.07	0.02	-0.06	0.02	0.00	0.00	-0.04	0.01	0.01	0.00	-0.04	0.01	-0.04	0.01	0.01	0.00	0.02	0.01	-0.03	0.01
believe	-0.11	0.04	0.12	0.06	0.02	0.00	-0.02	0.00	-0.14	0.12	-0.04	0.01	0.04	0.01	0.14	0.16	0.01	0.00	-0.20	0.38
faith	0.04	0.00	0.09	0.03	-0.16	0.12	-0.07	0.03	-0.20	0.23	0.00	0.00	-0.00	0.00	0.07	0.04	0.33	0.94	-0.03	0.01
instance	-0.11	0.04	0.32	0.42	0.08	0.03	-0.33	0.57	0.21	0.26	-0.11	0.08	-0.11	0.09	0.03	0.01	0.00	0.00	0.02	0.00
half	0.05	0.01	-0.16	0.10	-0.11	0.06	0.09	0.05	0.00	0.00	-0.04	0.01	-0.08	0.04	0.06	0.03	-0.02	0.01	0.27	0.67
writing	-0.17	0.09	0.09	0.03	-0.17	0.13	0.15	0.12	-0.15	0.12	-0.15	0.15	0.05	0.02	0.05	0.02	0.02	0.00	-0.11	0.11
tell	-0.14	0.07	-0.02	0.00	-0.01	0.00	-0.03	0.01	-0.11	0.06	-0.01	0.00	0.16	0.17	0.12	0.12	-0.07	0.04	-0.13	0.14
space	0.16	0.08	0.06	0.01	0.04	0.01	0.15	0.12	-0.03	0.00	-0.01	0.00	-0.21	0.29	-0.02	0.01	0.07	0.05	-0.11	0.11
specific	0.02	0.00	-0.03	0.00	-0.01	0.00	0.03	0.00	0.01	0.00	-0.16	0.15	-0.16	0.18	-0.08	0.06	-0.01	0.00	0.02	0.00
lake	-0.03	0.00	1.27	6.49	0.52	1.26	-1.81	17.28	1.43	11.73	-0.48	1.46	-0.08	0.04	0.55	2.54	0.07	0.04	0.28	0.73
britain	-0.08	0.02	0.48	0.94	0.41	0.78	-0.34	0.60	0.02	0.00	-0.03	0.00	-0.07	0.04	-0.38	1.18	0.13	0.14	0.03	0.01
demonstrate	0.08	0.02	-0.18	0.12	0.10	0.04	-0.00	0.00	0.11	0.06	-0.05	0.01	0.02	0.00	-0.09	0.06	0.01	0.00	-0.01	0.00
almost	-0.08	0.02	-0.02	0.00	-0.01	0.00	-0.02	0.00	-0.02	0.00	0.16	0.15	0.06	0.02	-0.01	0.00	-0.09	0.08	-0.03	0.01
increase	0.10	0.03	0.04	0.01	0.03	0.00	-0.38	0.74	0.24	0.33	-0.11	0.07	-0.08	0.05	0.00	0.00	0.02	0.01	0.04	0.02
robert	-0.07	0.01	0.11	0.05	-0.11	0.05	0.10	0.06	-0.02	0.00	0.27	0.46	0.02	0.00	0.04	0.01	0.25	0.55	-0.01	0.00
head	-0.00	0.00	-0.06	0.02	0.01	0.00	-0.10	0.05	0.10	0.06	0.04	0.01	-0.18	0.22	0.16	0.20	-0.10	0.09	0.02	0.00
side	0.06	0.01	0.03	0.00	-0.03	0.01	-0.04	0.01	-0.09	0.05	0.09	0.05	0.06	0.02	0.11	0.10	-0.04	0.01	0.03	0.01
popular	-0.18	0.10	-0.12	0.06	-0.13	0.08	-0.00	0.00	-0.14	0.11	0.15	0.14	-0.12	0.10	-0.12	0.12	0.25	0.54	0.01	0.00
matter	-0.26	0.21	0.07	0.02	-0.03	0.00	0.04	0.01	0.05	0.01	-0.07	0.03	0.08	0.04	0.03	0.01	0.05	0.02	-0.02	0.00
return	-0.09	0.03	-0.02	0.00	0.01	0.00	-0.03	0.01	0.04	0.01	0.02	0.00	0.10	0.07	0.07	0.04	0.06	0.03	0.08	0.06

reader	-0.26	0.20	0.03	0.00	0.06	0.01	0.26	0.36	-0.11	0.06	-0.17	0.19	0.30	0.62	0.04	0.02	0.05	0.02	-0.04	0.01
occur	-0.07	0.02	-0.00	0.00	0.13	0.07	-0.11	0.06	0.04	0.01	-0.01	0.00	0.06	0.03	0.14	0.16	-0.14	0.16	-0.02	0.00
never	-0.18	0.10	0.02	0.00	0.17	0.13	0.06	0.02	-0.12	0.08	0.04	0.01	0.13	0.11	0.11	0.10	0.01	0.00	-0.04	0.02
passage	-0.24	0.18	0.14	0.07	-0.06	0.02	-0.03	0.00	-0.06	0.02	0.03	0.01	-0.07	0.04	0.00	0.00	-0.00	0.00	-0.03	0.01
help	-0.09	0.02	-0.04	0.01	-0.06	0.01	-0.02	0.00	-0.04	0.01	-0.03	0.01	-0.00	0.00	0.03	0.01	0.09	0.07	0.02	0.00
add	-0.16	0.08	0.02	0.00	-0.08	0.03	0.04	0.01	0.03	0.00	-0.06	0.02	0.01	0.00	0.08	0.05	-0.05	0.02	0.04	0.01
wall	0.26	0.22	-0.29	0.32	0.61	1.71	0.16	0.13	0.04	0.01	-0.01	0.00	0.10	0.07	-0.07	0.04	0.09	0.07	-0.03	0.01
exist	-0.04	0.01	0.03	0.00	0.09	0.04	-0.00	0.00	0.01	0.00	-0.06	0.02	-0.06	0.02	0.01	0.00	0.02	0.00	-0.01	0.00
member	-0.11	0.04	0.07	0.02	-0.01	0.00	0.16	0.13	-0.32	0.58	-0.05	0.01	-0.15	0.15	0.14	0.17	0.27	0.64	0.92	7.46
addition	0.05	0.01	-0.11	0.05	-0.00	0.00	0.04	0.01	0.14	0.11	0.19	0.21	-0.01	0.00	0.05	0.02	0.02	0.00	0.10	0.09
island	0.34	0.36	0.07	0.02	0.19	0.16	0.01	0.00	0.37	0.76	0.59	2.12	0.15	0.14	0.04	0.01	0.46	1.82	0.04	0.02
bear	-0.10	0.03	0.08	0.02	0.07	0.02	-0.03	0.01	-0.15	0.12	0.04	0.01	0.08	0.05	0.04	0.01	-0.03	0.01	-0.02	0.00
back	-0.04	0.00	-0.05	0.01	-0.04	0.01	-0.03	0.01	-0.08	0.03	0.02	0.00	0.01	0.00	0.06	0.03	-0.02	0.00	-0.03	0.01
pattern	0.26	0.21	-0.06	0.01	-0.03	0.00	0.03	0.00	0.01	0.00	0.12	0.08	-0.08	0.04	0.02	0.00	-0.16	0.23	-0.06	0.03
series	-0.01	0.00	0.04	0.01	-0.00	0.00	0.02	0.00	-0.07	0.02	0.15	0.14	-0.03	0.01	-0.05	0.02	-0.08	0.05	0.19	0.31
ireland	-0.11	0.04	-0.01	0.00	0.29	0.38	0.12	0.07	-0.41	0.91	0.10	0.06	-0.08	0.04	0.06	0.03	0.24	0.48	0.12	0.12
grant	0.20	0.13	-0.32	0.39	-0.16	0.11	-0.16	0.13	-0.19	0.20	0.03	0.01	0.47	1.46	-0.29	0.67	0.14	0.17	0.19	0.29
peter	-0.03	0.00	0.02	0.00	-0.05	0.01	-0.19	0.19	-0.11	0.07	0.14	0.12	-0.03	0.01	-0.12	0.11	0.01	0.00	0.03	0.01
face	-0.14	0.06	-0.02	0.00	-0.09	0.04	0.02	0.00	-0.09	0.04	0.02	0.00	0.01	0.00	0.16	0.20	-0.18	0.28	-0.10	0.08
carry	0.03	0.00	-0.16	0.10	-0.07	0.02	-0.06	0.02	0.07	0.03	-0.07	0.03	-0.05	0.02	-0.07	0.04	-0.09	0.07	0.00	0.00
muslims	0.79	1.89	-0.19	0.14	0.03	0.00	0.61	1.88	1.02	5.59	1.32	10.27	0.19	0.23	0.27	0.57	0.61	3.10	-0.06	0.03
library	-0.12	0.04	0.02	0.00	0.00	0.00	0.21	0.23	0.04	0.01	-0.23	0.31	0.06	0.02	-0.14	0.15	-0.11	0.10	0.29	0.73
person	-0.14	0.06	0.07	0.02	-0.13	0.07	0.13	0.09	-0.01	0.00	-0.14	0.11	0.10	0.07	0.06	0.03	0.03	0.01	-0.05	0.02
poetry	-0.56	0.95	0.31	0.36	-0.13	0.08	0.58	1.67	0.01	0.00	0.23	0.31	0.55	1.90	0.04	0.01	-0.07	0.04	-0.01	0.00
yet	-0.13	0.05	0.04	0.01	-0.01	0.00	-0.01	0.00	0.00	0.00	-0.05	0.02	0.01	0.00	0.03	0.01	-0.01	0.00	-0.02	0.00
connection	0.08	0.02	0.04	0.01	-0.06	0.01	-0.07	0.02	0.09	0.04	-0.08	0.04	-0.07	0.03	0.04	0.01	0.04	0.01	-0.08	0.05
natural	-0.02	0.00	-0.02	0.00	0.18	0.14	-0.03	0.00	-0.20	0.21	-0.11	0.07	0.07	0.03	0.21	0.33	0.04	0.01	-0.05	0.02
slavic	0.22	0.14	-0.15	0.08	0.80	2.75	0.23	0.27	0.09	0.04	-0.51	1.55	-0.45	1.30	0.08	0.05	-0.17	0.22	-0.09	0.07
arabic	-0.34	0.34	0.10	0.04	-0.56	1.36	1.06	5.50	0.95	4.78	-0.60	2.10	0.70	3.13	-0.11	0.10	0.10	0.08	-0.09	0.06
self	-0.09	0.02	0.06	0.02	0.22	0.21	-0.03	0.01	-0.12	0.08	-0.05	0.02	0.02	0.00	0.11	0.09	0.21	0.35	-0.09	0.06
method	0.19	0.11	0.05	0.01	-0.03	0.00	0.08	0.03	0.00	0.00	-0.09	0.05	-0.15	0.14	-0.08	0.05	-0.16	0.20	0.04	0.01
single	-0.03	0.00	0.09	0.03	0.08	0.03	0.03	0.00	-0.01	0.00	-0.03	0.01	0.00	0.00	-0.05	0.02	-0.08	0.06	-0.03	0.01
water	0.10	0.03	0.06	0.01	-0.09	0.04	-0.17	0.13	0.33	0.58	-0.20	0.23	0.17	0.19	0.51	1.97	-0.53	2.21	0.03	0.01
lack	0.01	0.00	-0.04	0.01	0.02	0.00	0.00	0.00	0.05	0.01	-0.08	0.04	-0.00	0.00	0.15	0.17	-0.17	0.23	-0.01	0.00
style	-0.14	0.06	0.15	0.08	-0.11	0.05	0.08	0.03	-0.09	0.04	0.19	0.22	0.00	0.00	-0.06	0.03	-0.15	0.18	-0.00	0.00
mary	0.35	0.36	-0.31	0.34	-0.16	0.11	-0.39	0.74	-0.38	0.76	-0.04	0.01	0.56	1.92	-0.22	0.36	0.17	0.24	-0.01	0.00
cite	-0.31	0.29	0.11	0.04	-0.02	0.00	0.10	0.04	-0.12	0.08	0.14	0.11	-0.05	0.02	-0.11	0.09	-0.23	0.44	0.05	0.02
thomas	-0.29	0.24	0.11	0.04	-0.14	0.08	0.23	0.26	0.11	0.07	-0.15	0.12	0.23	0.31	-0.16	0.18	0.28	0.62	-0.05	0.02
instead	-0.11	0.03	0.09	0.03	0.07	0.02	-0.14	0.09	0.10	0.05	-0.09	0.04	-0.09	0.05	0.03	0.01	0.10	0.08	-0.06	0.03
production	0.43	0.53	-0.17	0.10	0.01	0.00	0.18	0.16	0.12	0.08	0.27	0.41	-0.04	0.01	-0.00	0.00	-0.10	0.08	-0.01	0.00
short	-0.07	0.01	0.12	0.05	-0.09	0.03	0.09	0.03	-0.03	0.00	-0.01	0.00	0.01	0.00	0.12	0.10	-0.07	0.04	0.09	0.06
sea	0.26	0.20	-0.00	0.00	-0.04	0.01	-0.07	0.02	0.03	0.00	0.15	0.12	0.03	0.01	0.07	0.04	-0.07	0.04	-0.07	0.04

david	0.00	0.00	0.15	0.08	0.07	0.02	-0.02	0.00	-0.08	0.03	0.24	0.33	0.06	0.02	0.01	0.00	-0.08	0.06	-0.16	0.20
true	-0.14	0.05	0.08	0.02	-0.05	0.01	0.00	0.00	-0.16	0.13	-0.00	0.00	0.15	0.13	0.12	0.11	-0.04	0.01	-0.01	0.00
territory	0.41	0.49	-0.18	0.12	-0.02	0.00	-0.05	0.01	0.02	0.00	-0.10	0.05	0.06	0.02	-0.13	0.13	0.14	0.16	-0.06	0.03
lord	0.06	0.01	-0.03	0.00	-0.00	0.00	-0.11	0.06	-0.07	0.02	-0.01	0.00	0.30	0.55	-0.11	0.08	-0.12	0.12	-0.06	0.02
access	0.37	0.40	-0.06	0.01	-0.04	0.01	0.03	0.00	0.11	0.06	0.06	0.02	-0.10	0.06	-0.01	0.00	0.14	0.16	-0.02	0.00
major	0.01	0.00	0.01	0.00	0.03	0.00	0.01	0.00	-0.03	0.01	0.08	0.04	-0.03	0.01	-0.03	0.01	-0.18	0.27	-0.03	0.01
master	-0.31	0.27	-0.12	0.05	-0.15	0.10	0.28	0.37	-0.34	0.59	-0.16	0.14	-0.24	0.34	0.34	0.87	0.29	0.67	1.54	18.91
ethnic	0.08	0.02	0.60	1.30	0.20	0.16	-0.59	1.66	0.46	1.08	-0.07	0.02	-0.28	0.47	-0.20	0.29	0.11	0.09	0.15	0.18
richard	-0.25	0.18	0.47	0.78	-0.08	0.03	-0.10	0.05	0.29	0.42	-0.11	0.07	0.12	0.08	-0.15	0.18	0.17	0.23	0.07	0.04
viking	0.23	0.15	0.27	0.26	0.19	0.15	-0.14	0.09	0.16	0.13	0.32	0.59	-0.09	0.05	-0.35	0.89	0.11	0.10	0.02	0.00
paper	-0.01	0.00	0.06	0.01	-0.11	0.05	0.04	0.01	-0.12	0.08	0.12	0.08	0.07	0.03	-0.11	0.09	-0.04	0.01	-0.00	0.00
aspect	-0.09	0.02	0.01	0.00	-0.01	0.00	0.09	0.03	-0.04	0.01	0.00	0.00	-0.03	0.01	-0.03	0.01	-0.02	0.00	-0.06	0.03
involve	0.13	0.05	-0.01	0.00	-0.02	0.00	0.12	0.06	0.01	0.00	0.15	0.13	0.01	0.00	0.01	0.00	0.01	0.00	0.01	0.00
africa	0.13	0.05	0.07	0.02	-0.02	0.00	0.24	0.26	0.09	0.04	0.31	0.54	-0.32	0.63	0.17	0.21	-0.07	0.04	-0.16	0.21
define	-0.04	0.00	0.07	0.02	0.21	0.18	-0.02	0.00	0.04	0.01	-0.13	0.10	-0.07	0.03	-0.10	0.08	-0.03	0.01	-0.04	0.01
shape	0.13	0.04	-0.10	0.04	0.17	0.11	0.12	0.06	-0.05	0.01	-0.11	0.07	-0.10	0.05	0.03	0.01	0.04	0.02	-0.08	0.04
black	0.02	0.00	0.08	0.02	0.03	0.00	0.03	0.00	-0.15	0.11	0.03	0.01	-0.14	0.11	0.16	0.18	-0.09	0.07	-0.24	0.44
representation	0.03	0.00	-0.21	0.15	-0.18	0.13	-0.16	0.11	-0.06	0.02	-0.00	0.00	-0.06	0.02	0.07	0.03	-0.09	0.06	-0.03	0.01
germanic	-0.02	0.00	0.47	0.75	0.10	0.04	-0.47	1.02	0.21	0.21	0.02	0.00	-0.16	0.16	-0.06	0.02	0.05	0.02	0.28	0.60
direct	-0.07	0.01	-0.02	0.00	-0.01	0.00	0.07	0.02	-0.00	0.00	-0.06	0.02	0.08	0.03	0.00	0.00	-0.01	0.00	-0.09	0.06
argument	-0.26	0.19	0.07	0.02	-0.01	0.00	-0.01	0.00	-0.01	0.00	0.03	0.00	0.01	0.00	-0.15	0.16	0.03	0.01	-0.01	0.00
post	0.35	0.35	-0.02	0.00	-0.01	0.00	-0.11	0.05	-0.03	0.00	-0.09	0.05	-0.07	0.03	-0.12	0.10	-0.23	0.39	-0.01	0.00
survive	0.00	0.00	0.04	0.01	0.09	0.03	0.20	0.19	0.01	0.00	0.22	0.26	0.05	0.01	0.05	0.02	-0.18	0.25	0.10	0.07
gregory	0.11	0.03	-0.08	0.02	-0.12	0.05	-0.14	0.09	-0.18	0.17	0.12	0.08	0.00	0.00	0.21	0.31	0.38	1.09	0.01	0.00
seek	-0.15	0.06	0.16	0.09	0.06	0.01	-0.01	0.00	-0.01	0.00	-0.03	0.00	0.02	0.00	0.05	0.02	0.15	0.17	0.07	0.03
put	-0.30	0.24	0.01	0.00	-0.02	0.00	-0.00	0.00	-0.03	0.01	0.09	0.04	0.07	0.03	0.09	0.06	-0.08	0.05	0.00	0.00
country	0.07	0.01	-0.01	0.00	-0.03	0.00	-0.03	0.00	-0.11	0.06	0.01	0.00	0.09	0.05	-0.03	0.01	0.08	0.05	-0.07	0.04
saga	0.08	0.02	0.16	0.09	-0.07	0.02	-0.07	0.02	-0.11	0.06	0.00	0.00	-0.26	0.39	0.46	1.48	0.33	0.83	-0.38	1.13
action	-0.09	0.02	-0.05	0.01	0.01	0.00	-0.09	0.04	0.06	0.02	-0.12	0.07	-0.03	0.01	-0.00	0.00	0.04	0.01	-0.03	0.01
always	-0.13	0.05	-0.01	0.00	-0.02	0.00	-0.02	0.00	-0.05	0.01	0.04	0.01	0.08	0.03	0.03	0.01	0.06	0.02	-0.02	0.00
effect	0.06	0.01	0.07	0.02	0.10	0.04	-0.05	0.01	-0.04	0.01	-0.05	0.02	-0.00	0.00	0.00	0.00	-0.05	0.02	0.02	0.00
tale	0.29	0.23	-0.60	1.23	0.56	1.24	-0.14	0.08	-0.27	0.37	-0.35	0.67	0.48	1.33	-0.19	0.26	0.05	0.02	0.04	0.01
river	0.28	0.22	-0.07	0.02	-0.02	0.00	-0.10	0.04	0.07	0.02	0.05	0.01	0.16	0.15	0.22	0.33	-0.28	0.57	-0.07	0.04
due	0.19	0.10	-0.10	0.04	-0.08	0.03	-0.02	0.00	-0.03	0.00	-0.08	0.04	-0.14	0.12	0.00	0.00	0.02	0.00	-0.04	0.01
young	-0.26	0.19	-0.26	0.24	-0.01	0.00	-0.11	0.06	-0.04	0.01	0.12	0.07	-0.03	0.01	-0.01	0.00	0.03	0.01	-0.07	0.04
american	-0.04	0.01	0.23	0.17	0.09	0.03	0.06	0.01	0.03	0.01	0.16	0.14	-0.06	0.02	0.01	0.00	0.30	0.68	-0.01	0.00
move	0.08	0.02	0.03	0.00	0.02	0.00	0.06	0.01	0.02	0.00	0.07	0.02	-0.08	0.04	-0.01	0.00	-0.00	0.00	0.02	0.00
construction	0.09	0.02	-0.05	0.01	0.55	1.19	0.00	0.00	-0.11	0.06	-0.12	0.08	0.07	0.03	-0.09	0.06	0.05	0.02	-0.05	0.02
learn	-0.29	0.23	0.04	0.01	-0.07	0.02	0.21	0.19	-0.12	0.06	-0.05	0.01	0.12	0.08	0.02	0.00	0.03	0.01	-0.11	0.09
available	0.11	0.04	0.02	0.00	-0.20	0.15	0.03	0.00	0.08	0.03	-0.18	0.17	-0.02	0.00	-0.07	0.04	-0.05	0.02	0.02	0.00

TABLE 7.24 – Résultats pour l'ensemble des facteurs

L'AFC lemme x période

		1	2	3	4	5	6	7	8	9	10
1975	1994	0.22	20.87	-0.14	17.79	-0.08	6.89	-0.18	43.51	-0.01	0.10
1995	2005	0.18	17.27	-0.13	17.18	0.01	0.21	0.18	51.74	-0.01	0.36
2006	2011	0.08	3.23	0.21	44.37	-0.17	36.11	0.03	1.54	-0.03	1.68
2012	2016	0.06	2.57	0.09	13.53	0.17	55.01	-0.03	3.19	-0.04	4.32
2017	2020	-0.08	4.52	0.01	0.05	0.01	0.04	-0.00	0.00	0.17	77.94
2021	2025	-0.23	51.53	-0.06	7.07	-0.03	1.74	-0.00	0.01	-0.07	15.60

TABLE 7.25 – Résultats pour l'ensemble des facteurs

		1	2	3	4	5
1975	1994	0.45	0.19	0.06	0.29	0.00
1995	2005	0.41	0.20	0.00	0.38	0.00
2006	2011	0.08	0.54	0.36	0.01	0.01
2012	2016	0.07	0.20	0.67	0.03	0.03
2017	2020	0.18	0.00	0.00	0.00	0.81
2021	2025	0.86	0.06	0.01	0.00	0.07

TABLE 7.26 – Cos2 pour l'ensemble des facteurs

	1	2	3	4	5
century	0.14	0.64	0.22	0.00	0.00
medieval	0.16	0.13	0.03	0.46	0.23
early	0.86	0.07	0.02	0.05	0.01
use	0.58	0.29	0.02	0.00	0.11
history	0.00	0.09	0.00	0.50	0.41
new	0.28	0.03	0.52	0.09	0.08
make	0.82	0.02	0.03	0.08	0.06
time	0.18	0.18	0.02	0.60	0.03
work	0.71	0.09	0.03	0.04	0.13
text	0.54	0.21	0.04	0.04	0.18

first	0.02	0.15	0.77	0.00	0.05
university	0.63	0.15	0.07	0.09	0.06
find	0.09	0.60	0.02	0.09	0.20
roman	0.67	0.15	0.18	0.00	0.00
late	0.99	0.00	0.00	0.00	0.00
king	0.25	0.00	0.17	0.56	0.02
study	0.23	0.03	0.33	0.18	0.23
even	0.77	0.02	0.00	0.19	0.02
well	0.73	0.01	0.02	0.24	0.00
people	0.09	0.61	0.25	0.03	0.02
christian	0.75	0.05	0.04	0.14	0.01
church	0.17	0.01	0.00	0.01	0.81
man	0.61	0.07	0.01	0.29	0.02
part	0.15	0.04	0.79	0.01	0.00
take	0.75	0.04	0.06	0.14	0.01
press	0.63	0.30	0.01	0.04	0.02
english	0.74	0.12	0.02	0.06	0.07
period	0.59	0.21	0.11	0.08	0.00
source	0.74	0.14	0.01	0.04	0.07
write	0.72	0.16	0.05	0.02	0.06
give	0.82	0.00	0.02	0.08	0.09
example	0.58	0.28	0.01	0.01	0.11
middle	0.45	0.34	0.11	0.10	0.00
place	0.01	0.08	0.08	0.82	0.01
present	0.63	0.00	0.02	0.34	0.02
name	0.60	0.17	0.17	0.00	0.06
world	0.01	0.51	0.35	0.10	0.03
include	0.69	0.01	0.00	0.12	0.17
note	0.53	0.06	0.10	0.27	0.04
know	0.85	0.08	0.03	0.03	0.01
god	0.04	0.80	0.01	0.01	0.14
form	0.67	0.07	0.16	0.09	0.02

become	0.01	0.30	0.51	0.14	0.04
many	0.82	0.08	0.01	0.09	0.00
year	0.35	0.22	0.11	0.20	0.12
old	0.25	0.01	0.00	0.38	0.35
great	0.54	0.34	0.01	0.09	0.02
historical	0.48	0.03	0.00	0.21	0.27
case	0.02	0.75	0.17	0.00	0.05
law	0.00	0.50	0.11	0.17	0.22
woman	0.43	0.17	0.05	0.33	0.02
way	0.20	0.31	0.38	0.01	0.10
state	0.00	0.00	0.10	0.26	0.63
book	0.42	0.23	0.00	0.33	0.03
suggest	0.65	0.07	0.00	0.28	0.00
later	0.69	0.20	0.00	0.10	0.00
show	0.54	0.30	0.06	0.08	0.02
come	0.61	0.05	0.01	0.18	0.16
der	0.15	0.47	0.02	0.32	0.04
evidence	0.25	0.38	0.25	0.07	0.05
life	0.19	0.05	0.01	0.01	0.74
word	0.50	0.02	0.00	0.12	0.35
seem	0.90	0.04	0.04	0.01	0.01
manuscript	0.01	0.27	0.00	0.51	0.21
power	0.01	0.13	0.23	0.52	0.12
appear	0.73	0.00	0.22	0.04	0.00
different	0.84	0.02	0.06	0.05	0.02
follow	0.03	0.17	0.69	0.01	0.09
group	0.43	0.08	0.07	0.17	0.25
term	0.21	0.05	0.12	0.38	0.24
date	0.43	0.55	0.02	0.00	0.00
point	0.82	0.12	0.01	0.02	0.02
mean	0.76	0.00	0.00	0.24	0.00
political	0.29	0.00	0.49	0.20	0.02

latin	0.10	0.41	0.05	0.00	0.44
site	0.25	0.37	0.31	0.03	0.04
london	0.79	0.04	0.10	0.07	0.00
thus	0.36	0.40	0.05	0.16	0.03
die	0.11	0.59	0.07	0.20	0.02
cambridge	0.68	0.05	0.02	0.25	0.01
long	0.78	0.13	0.03	0.03	0.04
modern	0.12	0.17	0.34	0.16	0.20
europe	0.68	0.04	0.04	0.18	0.05
tradition	0.15	0.74	0.02	0.04	0.06
change	0.05	0.60	0.22	0.00	0.13
society	0.73	0.09	0.01	0.13	0.04
age	0.50	0.13	0.27	0.03	0.08
social	0.43	0.02	0.10	0.22	0.22
provide	0.15	0.22	0.09	0.32	0.21
land	0.18	0.06	0.48	0.27	0.01
number	0.05	0.02	0.57	0.28	0.08
england	0.59	0.00	0.02	0.38	0.00
rather	0.75	0.11	0.09	0.02	0.03
remain	0.86	0.01	0.06	0.06	0.01
order	0.03	0.00	0.58	0.07	0.32
anglo	0.61	0.05	0.27	0.04	0.03
author	0.47	0.00	0.05	0.46	0.01
much	0.94	0.01	0.01	0.00	0.03
city	0.73	0.11	0.02	0.00	0.13
figure	0.15	0.62	0.06	0.09	0.09
empire	0.35	0.50	0.02	0.00	0.12
religious	0.31	0.45	0.16	0.00	0.08
language	0.45	0.23	0.01	0.06	0.25
fact	0.69	0.03	0.09	0.10	0.09
end	0.07	0.49	0.29	0.11	0.05
image	0.14	0.04	0.03	0.60	0.19

culture	0.03	0.03	0.29	0.40	0.26
area	0.63	0.02	0.10	0.06	0.19
art	0.18	0.31	0.02	0.06	0.42
good	0.17	0.19	0.51	0.12	0.00
human	0.38	0.21	0.09	0.02	0.30
high	0.23	0.01	0.12	0.20	0.44
saxon	0.73	0.00	0.18	0.07	0.02
call	0.62	0.25	0.01	0.06	0.07
begin	0.64	0.29	0.02	0.03	0.01
base	0.69	0.00	0.14	0.03	0.14
say	0.78	0.02	0.00	0.05	0.15
important	0.59	0.02	0.07	0.01	0.31
large	0.19	0.02	0.39	0.35	0.04
describe	0.24	0.30	0.15	0.00	0.30
mention	0.86	0.06	0.06	0.02	0.00
north	0.28	0.24	0.15	0.12	0.20
oxford	0.01	0.34	0.01	0.53	0.12
second	0.12	0.24	0.25	0.02	0.37
view	0.76	0.00	0.04	0.05	0.14
practice	0.12	0.14	0.39	0.12	0.22
john	0.43	0.33	0.24	0.00	0.00
material	0.74	0.01	0.16	0.04	0.05
ancient	0.89	0.09	0.01	0.00	0.01
result	0.93	0.00	0.01	0.00	0.05
analysis	0.96	0.02	0.00	0.00	0.01
rome	0.64	0.19	0.11	0.07	0.00
ages	0.02	0.07	0.07	0.31	0.53
context	0.79	0.02	0.04	0.14	0.02
lead	0.77	0.02	0.01	0.15	0.04
hand	0.17	0.64	0.07	0.11	0.02
account	0.60	0.08	0.17	0.00	0.15
cultural	0.30	0.46	0.15	0.07	0.02

accord	0.33	0.00	0.52	0.04	0.12
often	0.56	0.14	0.00	0.29	0.01
individual	0.92	0.05	0.02	0.01	0.00
line	0.77	0.01	0.02	0.19	0.02
role	0.00	0.73	0.01	0.06	0.19
western	0.27	0.00	0.54	0.02	0.16
narrative	0.00	0.62	0.37	0.00	0.00
community	0.05	0.90	0.00	0.04	0.00
identity	0.01	0.67	0.28	0.00	0.04
research	0.76	0.01	0.08	0.06	0.10
jews	0.71	0.10	0.02	0.03	0.14
record	0.27	0.07	0.34	0.01	0.31
war	0.30	0.03	0.09	0.04	0.54
region	0.82	0.02	0.06	0.00	0.10
still	0.51	0.20	0.01	0.27	0.00
rule	0.47	0.34	0.03	0.15	0.00
consider	0.36	0.06	0.26	0.00	0.32
local	0.90	0.04	0.01	0.05	0.00
death	0.18	0.04	0.16	0.27	0.35
reference	0.48	0.00	0.02	0.17	0.33
west	0.01	0.26	0.71	0.00	0.01
population	0.74	0.10	0.14	0.01	0.01
slave	0.00	0.13	0.16	0.04	0.67
york	0.80	0.03	0.10	0.07	0.00
literature	0.77	0.12	0.01	0.08	0.02
settlement	0.04	0.44	0.50	0.00	0.02
similar	0.22	0.00	0.06	0.72	0.00
question	0.81	0.00	0.02	0.13	0.05
right	0.01	0.43	0.00	0.54	0.01
story	0.09	0.17	0.28	0.07	0.39
son	0.37	0.14	0.46	0.01	0.02
refer	0.01	0.00	0.14	0.40	0.45

bishop	0.01	0.59	0.00	0.38	0.01
read	0.86	0.01	0.07	0.01	0.05
family	0.35	0.16	0.07	0.31	0.11
saint	0.01	0.05	0.52	0.39	0.03
represent	0.16	0.06	0.10	0.62	0.06
body	0.23	0.04	0.59	0.13	0.01
journal	0.35	0.51	0.08	0.02	0.05
version	0.05	0.01	0.42	0.17	0.35
type	0.04	0.31	0.08	0.18	0.39
day	0.37	0.39	0.15	0.02	0.07
nature	0.33	0.12	0.11	0.39	0.04
royal	0.35	0.23	0.22	0.00	0.20
therefore	0.22	0.28	0.25	0.15	0.10
central	0.93	0.00	0.04	0.04	0.00
small	0.47	0.00	0.27	0.17	0.09
letter	0.08	0.21	0.06	0.11	0.54
common	0.01	0.13	0.17	0.67	0.03
european	0.78	0.03	0.04	0.14	0.00
identify	0.87	0.00	0.00	0.07	0.05
christ	0.05	0.21	0.11	0.45	0.19
live	0.08	0.33	0.11	0.24	0.23
set	0.14	0.49	0.14	0.21	0.01
several	0.53	0.23	0.07	0.17	0.00
influence	0.01	0.27	0.66	0.06	0.00
east	0.78	0.11	0.01	0.11	0.00
archaeological	0.86	0.00	0.09	0.02	0.03
origin	0.31	0.01	0.34	0.29	0.04
value	0.86	0.03	0.08	0.00	0.02
understand	0.00	0.81	0.12	0.01	0.07
leave	0.03	0.06	0.03	0.80	0.08
translation	0.91	0.06	0.02	0.02	0.00
less	0.63	0.03	0.27	0.00	0.07

possible	0.10	0.57	0.31	0.03	0.00
general	0.33	0.50	0.08	0.04	0.04
especially	0.18	0.59	0.11	0.00	0.11
claim	0.33	0.25	0.33	0.09	0.00
article	0.83	0.00	0.11	0.04	0.02
idea	0.05	0.33	0.53	0.09	0.00
indicate	0.01	0.34	0.07	0.57	0.01
event	0.52	0.01	0.31	0.11	0.05
play	0.38	0.19	0.41	0.02	0.00
poem	0.74	0.07	0.19	0.00	0.00
support	0.61	0.21	0.02	0.05	0.11
regard	0.00	0.23	0.02	0.00	0.75
pagan	0.01	0.44	0.18	0.37	0.00
probably	0.06	0.31	0.26	0.15	0.21
town	0.00	0.57	0.42	0.00	0.01
non	0.27	0.24	0.19	0.23	0.08
hold	0.69	0.21	0.08	0.01	0.01
relate	0.43	0.00	0.47	0.10	0.01
studies	0.36	0.38	0.02	0.14	0.10
need	0.64	0.02	0.08	0.23	0.02
perhaps	0.78	0.03	0.00	0.16	0.03
court	0.52	0.15	0.03	0.29	0.01
least	0.41	0.26	0.16	0.08	0.09
chapter	0.21	0.20	0.01	0.59	0.00
south	0.11	0.06	0.08	0.03	0.72
last	0.63	0.00	0.33	0.04	0.00
argue	0.47	0.37	0.13	0.04	0.00
turn	0.44	0.20	0.32	0.02	0.02
scholar	0.63	0.17	0.03	0.17	0.01
emperor	0.56	0.06	0.01	0.05	0.33
particular	0.39	0.32	0.28	0.00	0.00
contemporary	0.10	0.07	0.25	0.44	0.14

cross	0.02	0.04	0.58	0.13	0.23
chronicle	0.12	0.00	0.49	0.35	0.03
subject	0.73	0.02	0.02	0.01	0.22
knowledge	0.20	0.00	0.06	0.69	0.06
kingdom	0.00	0.09	0.07	0.80	0.04
william	0.28	0.20	0.45	0.06	0.01
structure	0.46	0.04	0.02	0.00	0.49
literary	0.58	0.08	0.07	0.21	0.06
bring	0.61	0.01	0.34	0.03	0.01
model	0.39	0.05	0.19	0.03	0.34
element	0.05	0.00	0.38	0.00	0.57
relationship	0.01	0.86	0.06	0.07	0.01
concern	0.79	0.17	0.03	0.00	0.01
act	0.07	0.07	0.34	0.37	0.16
northern	0.28	0.01	0.03	0.60	0.07
establish	0.08	0.46	0.38	0.07	0.01
contain	0.15	0.19	0.23	0.34	0.10
authority	0.02	0.00	0.14	0.06	0.78
create	0.14	0.21	0.38	0.00	0.27
original	0.38	0.03	0.01	0.20	0.38
far	0.64	0.00	0.00	0.01	0.35
religion	0.00	0.62	0.35	0.01	0.01
continue	0.05	0.86	0.02	0.05	0.02
various	0.01	0.03	0.14	0.61	0.21
sense	0.72	0.04	0.14	0.05	0.04
iii	0.26	0.59	0.02	0.04	0.09
system	0.07	0.05	0.37	0.03	0.49
jewish	0.93	0.02	0.00	0.04	0.01
norman	0.18	0.60	0.01	0.21	0.00
publish	0.59	0.06	0.19	0.09	0.07
process	0.86	0.01	0.03	0.00	0.09
report	0.17	0.03	0.25	0.17	0.38

battle	0.33	0.01	0.31	0.27	0.09
discuss	0.61	0.22	0.00	0.09	0.08
force	0.47	0.01	0.05	0.35	0.12
likely	0.66	0.33	0.01	0.01	0.00
clear	0.32	0.63	0.01	0.03	0.02
interpretation	0.35	0.02	0.00	0.33	0.30
section	0.12	0.00	0.84	0.01	0.03
already	0.24	0.54	0.19	0.01	0.02
level	0.19	0.26	0.02	0.51	0.02
low	0.02	0.29	0.19	0.48	0.02
development	0.11	0.09	0.75	0.04	0.01
trade	0.18	0.10	0.32	0.00	0.40
datum	0.84	0.13	0.01	0.00	0.01
approach	0.41	0.13	0.09	0.34	0.03
german	0.04	0.23	0.03	0.23	0.47
greek	0.10	0.01	0.00	0.09	0.80
military	0.32	0.00	0.65	0.02	0.01
indeed	0.67	0.01	0.05	0.16	0.11
eastern	0.83	0.04	0.00	0.11	0.01
think	0.68	0.22	0.09	0.01	0.00
historian	0.00	0.15	0.03	0.37	0.46
issue	0.15	0.03	0.30	0.48	0.03
reason	0.54	0.10	0.23	0.00	0.13
other	0.55	0.22	0.04	0.06	0.14
byzantine	0.44	0.15	0.00	0.17	0.24
certain	0.07	0.18	0.00	0.65	0.09
national	0.07	0.13	0.16	0.07	0.57
legal	0.55	0.11	0.01	0.07	0.24
interest	0.48	0.00	0.51	0.01	0.00
draw	0.66	0.31	0.03	0.00	0.00
serve	0.07	0.23	0.49	0.06	0.16
archaeology	0.71	0.12	0.07	0.09	0.01

information	0.44	0.20	0.23	0.00	0.14
position	0.87	0.00	0.07	0.06	0.00
explain	0.14	0.21	0.14	0.32	0.19
produce	0.59	0.04	0.18	0.01	0.18
british	0.60	0.13	0.13	0.11	0.03
focus	0.31	0.36	0.17	0.15	0.01
und	0.32	0.40	0.00	0.15	0.12
imperial	0.08	0.21	0.07	0.00	0.64
child	0.32	0.02	0.42	0.24	0.00
christians	0.40	0.45	0.01	0.13	0.01
close	0.08	0.79	0.02	0.07	0.03
antiquity	0.92	0.01	0.02	0.04	0.01
edition	0.62	0.19	0.03	0.16	0.01
barbarian	0.07	0.07	0.13	0.59	0.13
sample	0.82	0.07	0.00	0.01	0.10
associate	0.04	0.02	0.64	0.29	0.01
discussion	0.85	0.10	0.04	0.01	0.01
status	0.60	0.18	0.09	0.12	0.01
building	0.27	0.00	0.20	0.00	0.53
offer	0.46	0.31	0.00	0.19	0.04
house	0.03	0.04	0.81	0.05	0.08
speak	0.64	0.02	0.20	0.07	0.07
fall	0.47	0.43	0.03	0.01	0.05
attempt	0.64	0.08	0.00	0.27	0.01
main	0.97	0.00	0.01	0.01	0.02
christianity	0.52	0.15	0.06	0.06	0.22
italy	0.78	0.00	0.18	0.02	0.02
problem	0.61	0.37	0.01	0.00	0.00
mark	0.06	0.13	0.80	0.00	0.00
henry	0.38	0.00	0.62	0.00	0.00
wife	0.44	0.18	0.15	0.23	0.01
particularly	0.10	0.27	0.29	0.32	0.02

relation	0.12	0.01	0.05	0.41	0.41
father	0.12	0.52	0.32	0.02	0.02
description	0.02	0.25	0.02	0.68	0.02
animal	0.24	0.06	0.30	0.04	0.36
von	0.45	0.22	0.01	0.02	0.31
holy	0.19	0.01	0.55	0.05	0.20
twelfth	0.62	0.04	0.00	0.09	0.25
activity	0.78	0.01	0.00	0.15	0.05
cause	0.01	0.01	0.02	0.70	0.26
little	0.70	0.00	0.08	0.09	0.13
control	0.26	0.00	0.31	0.03	0.40
review	0.45	0.18	0.04	0.29	0.04
allow	0.49	0.04	0.19	0.12	0.16
paul	0.02	0.10	0.35	0.00	0.52
theory	0.17	0.10	0.56	0.07	0.11
list	0.23	0.44	0.16	0.13	0.04
table	0.70	0.09	0.07	0.04	0.11
reflect	0.00	0.25	0.17	0.59	0.00
link	0.16	0.00	0.66	0.16	0.01
difference	0.37	0.03	0.27	0.13	0.21
recent	0.26	0.04	0.19	0.12	0.40
experience	0.05	0.09	0.05	0.33	0.48
third	0.59	0.18	0.22	0.00	0.00
introduction	0.06	0.00	0.07	0.84	0.03
castle	0.00	0.46	0.01	0.00	0.53
past	0.38	0.02	0.07	0.21	0.32
feature	0.17	0.65	0.02	0.07	0.09
character	0.12	0.19	0.60	0.00	0.09
classical	0.35	0.20	0.01	0.43	0.00
detail	0.06	0.02	0.02	0.01	0.89
reveal	0.30	0.00	0.50	0.04	0.16
presence	0.48	0.01	0.32	0.18	0.00

ruler	0.14	0.37	0.37	0.10	0.03
compare	0.00	0.31	0.00	0.68	0.00
conquest	0.04	0.00	0.58	0.13	0.24
islamic	0.06	0.09	0.12	0.70	0.01
army	0.00	0.01	0.78	0.20	0.01
concept	0.08	0.10	0.43	0.24	0.15
female	0.29	0.05	0.05	0.61	0.01
course	0.97	0.00	0.01	0.00	0.02
look	0.51	0.01	0.16	0.28	0.05
mongol	0.14	0.10	0.33	0.00	0.43
poet	0.61	0.15	0.23	0.00	0.01
clearly	0.80	0.00	0.02	0.13	0.06
stand	0.51	0.00	0.08	0.39	0.02
collection	0.50	0.30	0.11	0.00	0.08
daughter	0.03	0.56	0.36	0.03	0.02
public	0.14	0.26	0.52	0.05	0.03
edit	0.63	0.01	0.06	0.04	0.26
page	0.00	0.24	0.00	0.11	0.65
light	0.19	0.10	0.33	0.15	0.23
burial	0.84	0.12	0.00	0.01	0.03
kind	0.75	0.00	0.18	0.06	0.00
function	0.22	0.11	0.13	0.20	0.34
thing	0.44	0.00	0.14	0.17	0.25
build	0.64	0.00	0.07	0.01	0.28
southern	0.30	0.10	0.28	0.00	0.31
whole	0.55	0.27	0.00	0.12	0.06
copy	0.00	0.47	0.11	0.15	0.27
muslim	0.24	0.43	0.05	0.00	0.28
significant	0.84	0.06	0.01	0.04	0.06
contrast	0.53	0.00	0.06	0.32	0.09
object	0.09	0.14	0.32	0.30	0.16
receive	0.53	0.12	0.07	0.01	0.27

together	0.74	0.26	0.00	0.00	0.00
develop	0.07	0.44	0.43	0.01	0.06
irish	0.31	0.00	0.14	0.38	0.17
economic	0.23	0.21	0.52	0.02	0.03
open	0.47	0.01	0.03	0.18	0.32
believe	0.24	0.62	0.00	0.08	0.05
faith	0.40	0.34	0.23	0.03	0.00
instance	0.19	0.07	0.65	0.09	0.00
half	0.24	0.63	0.13	0.00	0.00
writing	0.22	0.60	0.03	0.13	0.01
tell	0.63	0.01	0.24	0.00	0.12
space	0.25	0.08	0.00	0.09	0.58
specific	0.90	0.00	0.02	0.08	0.01
lake	0.07	0.13	0.67	0.10	0.03
britain	0.01	0.87	0.02	0.00	0.10
demonstrate	0.17	0.59	0.08	0.03	0.13
almost	0.56	0.39	0.01	0.01	0.03
increase	0.17	0.01	0.54	0.19	0.09
robert	0.00	0.14	0.07	0.28	0.51
head	0.02	0.20	0.01	0.76	0.01
side	0.01	0.01	0.46	0.15	0.37
popular	0.06	0.06	0.25	0.08	0.54
matter	0.86	0.02	0.08	0.04	0.00
return	0.69	0.28	0.02	0.01	0.01
reader	0.55	0.01	0.02	0.27	0.15
occur	0.55	0.00	0.09	0.34	0.02
never	0.70	0.12	0.08	0.00	0.09
passage	0.70	0.00	0.27	0.00	0.02
help	0.22	0.04	0.67	0.07	0.00
add	0.51	0.09	0.03	0.34	0.02
wall	0.12	0.36	0.49	0.01	0.02
exist	0.24	0.02	0.58	0.03	0.14

member	0.11	0.00	0.08	0.78	0.03
addition	0.08	0.49	0.04	0.23	0.16
island	0.12	0.77	0.12	0.00	0.00
bear	0.79	0.09	0.01	0.08	0.02
back	0.06	0.08	0.00	0.71	0.15
pattern	0.25	0.00	0.16	0.23	0.36
series	0.34	0.13	0.45	0.08	0.01
ireland	0.16	0.03	0.30	0.49	0.02
grant	0.24	0.01	0.22	0.20	0.33
peter	0.06	0.09	0.54	0.04	0.28
face	0.14	0.07	0.24	0.51	0.03
carry	0.51	0.44	0.01	0.04	0.00
muslims	0.12	0.51	0.35	0.01	0.01
library	0.20	0.19	0.15	0.36	0.10
person	0.16	0.25	0.40	0.05	0.14
poetry	0.71	0.18	0.10	0.00	0.00
yet	0.71	0.04	0.22	0.02	0.01
connection	0.50	0.15	0.25	0.03	0.07
natural	0.08	0.81	0.04	0.07	0.00
slavic	0.09	0.55	0.29	0.04	0.03
arabic	0.17	0.33	0.06	0.41	0.03
self	0.10	0.84	0.02	0.00	0.04
method	0.27	0.01	0.19	0.01	0.52
single	0.63	0.16	0.06	0.00	0.15
water	0.02	0.42	0.03	0.44	0.09
lack	0.02	0.28	0.11	0.49	0.11
style	0.50	0.26	0.00	0.12	0.11
mary	0.65	0.00	0.08	0.04	0.23
cite	0.70	0.19	0.07	0.03	0.01
thomas	0.34	0.00	0.14	0.52	0.01
instead	0.05	0.30	0.62	0.00	0.03
production	0.38	0.07	0.48	0.05	0.02

short	0.39	0.07	0.06	0.24	0.23
sea	0.76	0.08	0.10	0.02	0.04
david	0.27	0.53	0.00	0.18	0.01
true	0.69	0.12	0.04	0.04	0.11
territory	0.96	0.00	0.00	0.00	0.04
lord	0.03	0.12	0.02	0.00	0.82
access	0.93	0.06	0.02	0.00	0.00
major	0.29	0.04	0.24	0.03	0.39
master	0.11	0.29	0.01	0.23	0.35
ethnic	0.01	0.20	0.78	0.01	0.01
richard	0.39	0.00	0.51	0.09	0.00
viking	0.14	0.43	0.40	0.01	0.02
paper	0.02	0.19	0.47	0.09	0.24
aspect	0.20	0.08	0.01	0.01	0.70
involve	0.01	0.08	0.24	0.61	0.06
africa	0.17	0.13	0.01	0.01	0.68
define	0.07	0.46	0.01	0.06	0.41
shape	0.84	0.05	0.08	0.00	0.02
black	0.01	0.44	0.46	0.05	0.05
representation	0.23	0.31	0.01	0.45	0.01
germanic	0.15	0.01	0.76	0.04	0.05
direct	0.19	0.01	0.06	0.69	0.05
argument	0.59	0.01	0.01	0.29	0.10
post	0.80	0.04	0.01	0.09	0.07
survive	0.40	0.02	0.49	0.03	0.05
gregory	0.36	0.08	0.12	0.17	0.27
seek	0.55	0.11	0.25	0.00	0.08
put	0.87	0.03	0.09	0.00	0.01
country	0.13	0.00	0.14	0.45	0.28
saga	0.00	0.11	0.18	0.28	0.43
action	0.04	0.00	0.43	0.14	0.39
always	0.75	0.00	0.18	0.04	0.03

effect	0.09	0.11	0.00	0.00	0.80
tale	0.31	0.12	0.41	0.01	0.15
river	0.15	0.15	0.13	0.07	0.50
due	0.89	0.00	0.01	0.05	0.04
young	0.17	0.00	0.06	0.66	0.10
american	0.19	0.55	0.25	0.01	0.01
move	0.20	0.00	0.04	0.69	0.08
construction	0.01	0.92	0.03	0.03	0.01
learn	0.59	0.03	0.32	0.01	0.06
available	0.35	0.47	0.02	0.15	0.01

TABLE 7.27 – Cos2 pour l'ensemble des facteurs

	1	2	3	4	5	6	7	8	9	10
century	-0.03	0.06	-0.07	0.53	-0.04	0.22	0.01	0.00	0.00	0.00
medieval	-0.05	0.09	-0.04	0.15	0.02	0.04	0.08	0.81	-0.06	0.49
early	-0.06	0.13	-0.02	0.02	-0.01	0.01	0.01	0.02	-0.01	0.00
use	-0.13	0.58	-0.09	0.57	0.02	0.04	-0.01	0.01	-0.06	0.44
history	-0.00	0.00	-0.03	0.07	0.00	0.00	0.08	0.61	0.07	0.60
new	0.04	0.03	0.01	0.01	-0.05	0.15	0.02	0.04	-0.02	0.04
make	0.11	0.29	0.01	0.01	-0.02	0.03	-0.03	0.09	-0.03	0.08
time	-0.04	0.03	-0.04	0.07	-0.01	0.01	-0.07	0.36	-0.02	0.02
work	0.11	0.27	-0.04	0.07	-0.02	0.03	0.03	0.05	0.05	0.19
text	0.04	0.03	0.02	0.02	0.01	0.00	0.01	0.01	-0.02	0.04
first	0.01	0.00	-0.04	0.08	-0.09	0.48	-0.01	0.00	-0.02	0.05
university	-0.17	0.61	0.08	0.30	0.05	0.16	0.06	0.29	-0.05	0.23
find	-0.03	0.02	-0.07	0.24	0.01	0.01	-0.03	0.06	-0.04	0.15
roman	-0.15	0.47	0.07	0.21	0.08	0.31	-0.01	0.01	-0.01	0.00
late	-0.24	1.19	-0.01	0.00	-0.01	0.01	0.01	0.01	-0.01	0.00
king	0.07	0.11	-0.00	0.00	-0.06	0.18	-0.11	0.79	-0.02	0.03
study	-0.06	0.07	-0.02	0.01	-0.07	0.22	0.05	0.16	-0.06	0.26
even	0.11	0.23	-0.02	0.01	0.00	0.00	-0.06	0.19	0.02	0.02

well	0.08	0.13	-0.01	0.00	-0.01	0.01	-0.05	0.13	0.00	0.00
people	-0.04	0.04	0.11	0.46	0.07	0.22	0.02	0.04	-0.02	0.03
christian	-0.25	1.16	0.06	0.15	0.06	0.17	-0.11	0.70	-0.03	0.07
church	-0.06	0.07	-0.02	0.01	-0.00	0.00	-0.01	0.01	0.14	1.43
man	0.28	1.45	-0.09	0.31	-0.04	0.06	-0.19	2.19	-0.06	0.22
part	0.02	0.01	0.01	0.01	-0.06	0.13	0.01	0.00	-0.00	0.00
take	0.07	0.08	0.02	0.01	-0.02	0.02	-0.03	0.05	0.01	0.01
press	-0.22	0.82	0.15	0.78	0.03	0.03	0.05	0.16	-0.04	0.12
english	0.32	1.79	0.13	0.57	0.05	0.11	0.09	0.45	-0.10	0.66
period	-0.21	0.75	-0.12	0.54	-0.09	0.35	-0.08	0.33	0.01	0.01
source	-0.09	0.15	-0.04	0.06	-0.01	0.01	0.02	0.02	-0.03	0.05
write	0.12	0.26	-0.06	0.11	-0.03	0.04	-0.02	0.02	0.04	0.08
give	0.15	0.38	0.00	0.00	-0.02	0.02	-0.05	0.11	-0.05	0.16
example	0.05	0.05	-0.04	0.05	0.01	0.00	-0.01	0.00	-0.02	0.04
middle	-0.06	0.06	-0.06	0.10	-0.03	0.04	0.03	0.04	-0.01	0.00
place	0.01	0.00	-0.01	0.01	0.01	0.01	-0.05	0.11	0.00	0.00
present	-0.11	0.18	0.00	0.00	-0.02	0.01	-0.08	0.31	0.02	0.02
name	0.14	0.28	0.07	0.16	-0.07	0.18	0.01	0.00	-0.04	0.11
world	-0.01	0.00	0.12	0.40	0.10	0.33	0.05	0.13	0.03	0.05
include	-0.07	0.08	-0.01	0.00	-0.00	0.00	0.03	0.04	-0.04	0.08
note	0.23	0.78	-0.08	0.18	-0.10	0.34	-0.16	1.29	-0.06	0.24
know	0.12	0.20	-0.04	0.04	-0.02	0.01	-0.02	0.02	-0.01	0.01
god	0.07	0.08	0.33	3.20	-0.04	0.05	-0.04	0.06	-0.14	1.07
form	0.10	0.14	-0.03	0.03	0.05	0.08	0.03	0.06	0.02	0.02
become	-0.01	0.00	0.06	0.09	0.07	0.19	-0.04	0.07	-0.02	0.02
many	0.10	0.16	0.03	0.03	0.01	0.00	-0.03	0.05	-0.01	0.00
year	0.09	0.11	-0.07	0.14	-0.05	0.08	-0.07	0.21	-0.05	0.14
old	0.09	0.12	-0.02	0.01	0.00	0.00	-0.11	0.58	0.11	0.67
great	0.10	0.15	-0.08	0.19	0.01	0.00	-0.04	0.09	-0.02	0.03
historical	-0.11	0.16	-0.03	0.02	-0.01	0.00	0.07	0.23	0.08	0.36
case	0.02	0.01	-0.13	0.47	0.06	0.13	0.01	0.00	0.03	0.06
law	0.01	0.00	-0.21	1.24	0.10	0.31	0.12	0.68	0.14	1.05

woman	0.37	1.92	-0.23	1.50	-0.13	0.54	-0.32	4.65	-0.07	0.29
way	0.08	0.09	0.10	0.26	0.11	0.39	0.02	0.01	-0.06	0.17
state	0.01	0.00	-0.01	0.00	0.05	0.08	0.08	0.30	0.13	0.87
book	0.21	0.58	-0.15	0.64	0.00	0.00	0.18	1.47	-0.05	0.15
suggest	0.12	0.20	0.04	0.04	0.00	0.00	-0.08	0.28	-0.01	0.00
later	0.10	0.13	-0.05	0.07	0.00	0.00	-0.04	0.06	-0.01	0.00
show	-0.15	0.29	-0.11	0.32	-0.05	0.08	-0.06	0.13	-0.03	0.05
come	0.07	0.06	0.02	0.01	0.01	0.00	-0.04	0.06	-0.03	0.06
der	-0.09	0.11	-0.16	0.67	0.03	0.03	0.13	0.72	0.05	0.11
evidence	0.11	0.14	-0.13	0.44	-0.11	0.35	-0.06	0.13	0.05	0.11
life	0.04	0.02	0.02	0.01	0.01	0.00	0.01	0.00	-0.08	0.33
word	0.15	0.27	-0.03	0.02	0.01	0.00	-0.07	0.21	0.12	0.74
seem	0.24	0.73	-0.05	0.06	-0.05	0.08	-0.02	0.02	-0.03	0.04
manuscript	0.03	0.01	-0.18	0.76	-0.01	0.00	0.24	2.32	-0.15	1.16
power	0.01	0.00	0.05	0.07	0.07	0.16	-0.11	0.48	-0.05	0.13
appear	0.15	0.28	-0.01	0.00	-0.08	0.20	0.03	0.05	0.01	0.01
different	-0.14	0.22	-0.02	0.01	0.04	0.04	0.03	0.04	0.02	0.02
follow	-0.01	0.00	-0.04	0.03	0.07	0.15	-0.01	0.00	-0.03	0.03
group	-0.07	0.06	0.03	0.02	-0.03	0.02	0.05	0.08	-0.05	0.14
term	-0.05	0.03	0.02	0.01	0.04	0.04	0.06	0.16	-0.05	0.13
date	-0.15	0.26	-0.17	0.66	-0.03	0.02	-0.01	0.00	-0.01	0.01
point	0.11	0.15	-0.04	0.04	0.01	0.01	-0.02	0.01	0.02	0.02
mean	0.10	0.11	0.00	0.00	0.00	0.00	-0.05	0.11	0.00	0.00
political	-0.08	0.09	0.00	0.00	0.11	0.35	0.07	0.19	-0.02	0.02
latin	0.07	0.07	-0.15	0.53	0.05	0.08	-0.01	0.00	0.16	1.12
site	-0.20	0.49	0.25	1.46	-0.23	1.45	-0.08	0.21	-0.08	0.33
london	0.22	0.56	-0.05	0.05	-0.08	0.17	0.07	0.16	-0.01	0.00
thus	0.06	0.05	-0.07	0.10	0.02	0.01	-0.04	0.07	0.02	0.02
die	0.07	0.05	-0.16	0.60	0.06	0.09	0.10	0.34	0.03	0.05
cambridge	-0.16	0.30	0.04	0.04	-0.03	0.02	0.10	0.35	-0.01	0.01
long	0.04	0.02	-0.02	0.01	-0.01	0.00	0.01	0.00	0.01	0.00
modern	0.04	0.02	0.05	0.06	-0.07	0.14	-0.05	0.09	0.05	0.14

europe	-0.25	0.74	-0.06	0.09	0.06	0.11	0.13	0.62	-0.07	0.23
tradition	0.07	0.06	0.17	0.63	-0.03	0.02	0.04	0.05	-0.05	0.09
change	-0.03	0.01	0.11	0.26	0.07	0.12	-0.00	0.00	-0.05	0.11
society	0.16	0.28	-0.05	0.07	0.02	0.01	0.07	0.16	0.04	0.07
age	-0.11	0.14	0.06	0.07	-0.08	0.17	-0.03	0.03	0.04	0.08
social	0.05	0.03	-0.01	0.00	0.02	0.02	0.04	0.05	0.04	0.06
provide	-0.02	0.00	-0.02	0.01	-0.01	0.01	0.03	0.03	-0.02	0.02
land	0.06	0.03	0.03	0.03	0.09	0.23	0.07	0.17	-0.01	0.01
number	0.02	0.00	0.01	0.00	-0.06	0.10	-0.04	0.06	0.02	0.02
england	0.23	0.55	0.01	0.00	-0.04	0.05	0.18	1.15	-0.02	0.01
rather	0.10	0.10	0.04	0.03	-0.03	0.03	-0.01	0.01	-0.02	0.02
remain	-0.11	0.12	-0.01	0.00	-0.03	0.02	-0.03	0.03	0.01	0.01
order	0.03	0.01	0.00	0.00	0.12	0.37	-0.04	0.06	0.09	0.33
anglo	0.28	0.83	0.08	0.13	0.18	0.86	0.07	0.18	-0.06	0.16
author	-0.08	0.07	0.00	0.00	-0.03	0.02	0.08	0.21	-0.01	0.01
much	0.22	0.50	-0.03	0.01	-0.02	0.01	-0.01	0.01	-0.04	0.07
city	-0.22	0.51	0.09	0.16	0.04	0.03	0.00	0.00	-0.09	0.35
figure	0.05	0.03	-0.11	0.26	0.04	0.03	-0.04	0.06	0.04	0.07
empire	-0.16	0.25	0.19	0.73	0.04	0.04	0.01	0.01	0.09	0.36
religious	-0.14	0.20	0.17	0.57	0.10	0.25	0.00	0.00	0.07	0.20
language	0.17	0.32	-0.12	0.32	0.02	0.01	0.06	0.14	0.13	0.69
fact	0.12	0.15	0.02	0.01	0.04	0.05	0.04	0.07	0.04	0.08
end	-0.02	0.00	-0.05	0.04	-0.04	0.03	-0.02	0.02	-0.01	0.01
image	0.12	0.14	-0.06	0.07	-0.05	0.06	-0.24	1.93	0.14	0.76
culture	0.02	0.00	0.02	0.01	0.05	0.06	0.06	0.10	0.05	0.08
area	-0.22	0.48	0.04	0.04	-0.09	0.18	-0.07	0.15	0.12	0.58
art	0.16	0.26	-0.21	0.90	-0.06	0.08	-0.10	0.30	0.25	2.43
good	0.05	0.03	-0.06	0.07	-0.09	0.21	0.05	0.07	0.01	0.00
human	-0.17	0.28	0.12	0.31	0.08	0.16	0.04	0.04	0.15	0.89
high	-0.11	0.13	-0.02	0.01	-0.08	0.16	-0.10	0.35	0.16	0.94
saxon	0.33	1.08	-0.02	0.00	0.16	0.64	0.10	0.33	-0.05	0.11
call	0.09	0.07	0.06	0.06	-0.01	0.00	-0.03	0.02	-0.03	0.03

begin	0.08	0.06	-0.05	0.06	-0.01	0.01	0.02	0.01	-0.01	0.01
base	-0.15	0.21	-0.00	0.00	0.07	0.11	-0.03	0.03	0.07	0.17
say	0.22	0.48	0.03	0.02	-0.01	0.00	-0.05	0.09	-0.10	0.36
important	0.03	0.01	-0.00	0.00	-0.01	0.00	-0.00	0.00	0.02	0.01
large	-0.06	0.04	-0.02	0.01	-0.09	0.19	-0.09	0.23	-0.03	0.04
describe	-0.05	0.02	0.05	0.05	-0.04	0.03	-0.00	0.00	0.05	0.10
mention	-0.12	0.13	-0.03	0.02	-0.03	0.02	0.02	0.01	-0.00	0.00
north	-0.13	0.15	0.12	0.26	-0.09	0.19	0.08	0.22	-0.11	0.43
oxford	0.01	0.00	0.07	0.09	0.01	0.00	0.08	0.21	-0.04	0.06
second	-0.02	0.00	-0.03	0.02	-0.03	0.02	0.01	0.00	-0.04	0.05
view	0.19	0.32	0.00	0.00	0.04	0.04	-0.05	0.07	0.08	0.24
practice	-0.04	0.01	-0.04	0.03	0.07	0.10	-0.04	0.04	-0.05	0.09
john	0.15	0.21	0.13	0.32	0.11	0.28	-0.01	0.00	-0.00	0.00
material	-0.20	0.35	-0.03	0.01	0.09	0.18	-0.04	0.06	-0.05	0.10
ancient	-0.28	0.70	-0.09	0.15	-0.03	0.02	-0.01	0.00	0.02	0.02
result	-0.24	0.54	0.01	0.00	0.03	0.02	-0.01	0.00	0.06	0.12
analysis	-0.38	1.33	-0.06	0.07	0.01	0.00	-0.01	0.00	0.04	0.06
rome	-0.14	0.19	0.08	0.11	-0.06	0.08	-0.05	0.06	0.00	0.00
ages	-0.02	0.00	-0.03	0.02	0.03	0.02	0.07	0.13	-0.09	0.28
context	-0.10	0.09	-0.02	0.00	0.02	0.01	0.04	0.05	-0.01	0.01
lead	-0.15	0.20	0.03	0.01	0.02	0.01	-0.07	0.13	0.03	0.04
hand	0.06	0.03	-0.11	0.21	0.04	0.03	-0.05	0.06	-0.02	0.01
account	0.12	0.12	0.04	0.03	0.06	0.08	-0.00	0.00	0.06	0.11
cultural	-0.10	0.10	0.13	0.30	0.07	0.12	0.05	0.07	0.03	0.03
accord	-0.05	0.02	-0.00	0.00	0.06	0.07	-0.02	0.01	0.03	0.03
often	0.05	0.02	0.03	0.01	0.00	0.00	-0.04	0.04	-0.01	0.00
individual	-0.41	1.46	-0.09	0.15	0.06	0.07	0.04	0.05	0.01	0.00
line	0.31	0.81	-0.03	0.01	-0.05	0.05	0.15	0.63	-0.05	0.07
role	-0.00	0.00	0.08	0.10	-0.01	0.00	0.02	0.01	0.04	0.05
western	-0.08	0.05	0.01	0.00	0.11	0.24	0.02	0.01	0.06	0.12
narrative	0.01	0.00	0.29	1.43	0.22	1.01	-0.02	0.01	0.02	0.02
community	-0.06	0.03	0.24	0.98	-0.00	0.00	0.05	0.08	-0.01	0.00

identity	-0.04	0.01	0.40	2.63	0.25	1.29	0.03	0.02	0.10	0.30
research	-0.23	0.45	-0.02	0.01	0.07	0.11	0.07	0.12	0.08	0.22
jews	-0.76	4.72	-0.28	1.27	-0.14	0.37	-0.16	0.70	-0.33	3.62
record	0.10	0.08	0.05	0.04	-0.11	0.23	-0.02	0.01	0.10	0.34
war	-0.12	0.12	-0.04	0.02	-0.07	0.09	-0.04	0.05	0.16	0.81
region	-0.35	1.01	-0.05	0.04	-0.10	0.18	0.02	0.01	-0.12	0.48
still	0.09	0.06	-0.06	0.05	-0.01	0.00	-0.06	0.11	-0.00	0.00
rule	0.15	0.18	-0.13	0.27	0.04	0.03	-0.09	0.19	0.01	0.00
consider	-0.05	0.02	-0.02	0.01	0.05	0.04	0.00	0.00	0.05	0.08
local	-0.28	0.61	-0.06	0.06	0.03	0.01	0.07	0.11	0.01	0.00
death	-0.04	0.02	-0.02	0.01	0.04	0.03	-0.05	0.07	-0.06	0.11
reference	0.06	0.03	-0.00	0.00	-0.01	0.00	0.04	0.03	-0.05	0.08
west	0.03	0.01	0.12	0.24	-0.20	0.77	0.01	0.00	0.02	0.02
population	-0.49	1.91	-0.18	0.51	-0.22	0.89	0.06	0.09	-0.06	0.12
slave	-0.00	0.00	-0.13	0.25	-0.14	0.38	-0.08	0.14	0.29	2.57
york	0.19	0.28	0.04	0.02	-0.07	0.08	0.05	0.08	-0.01	0.00
literature	0.26	0.53	-0.10	0.17	-0.03	0.01	0.08	0.18	-0.04	0.04
settlement	-0.13	0.13	0.44	2.95	-0.46	3.94	0.02	0.01	-0.09	0.24
similar	-0.06	0.03	-0.01	0.00	0.03	0.02	-0.11	0.33	-0.00	0.00
question	0.11	0.09	-0.00	0.00	0.02	0.00	0.04	0.05	-0.03	0.02
right	-0.02	0.00	-0.10	0.16	0.01	0.00	-0.11	0.31	0.02	0.01
story	0.06	0.03	0.09	0.12	0.11	0.24	0.06	0.08	-0.13	0.53
son	0.10	0.07	0.06	0.05	-0.11	0.21	0.02	0.01	0.02	0.01
refer	-0.02	0.00	0.00	0.00	0.05	0.05	-0.09	0.18	0.09	0.25
bishop	-0.04	0.01	-0.27	1.11	0.02	0.01	0.22	1.15	0.04	0.04
read	0.16	0.20	0.02	0.00	-0.05	0.04	0.02	0.01	-0.04	0.05
family	0.15	0.17	-0.10	0.15	-0.07	0.08	0.14	0.47	-0.08	0.21
saint	0.02	0.00	-0.06	0.06	0.20	0.69	-0.17	0.70	-0.05	0.07
represent	-0.02	0.00	-0.01	0.00	0.02	0.01	-0.04	0.05	-0.01	0.01
body	-0.14	0.14	0.06	0.05	0.22	0.85	-0.10	0.25	0.03	0.03
journal	-0.14	0.15	0.17	0.44	0.07	0.08	-0.04	0.03	0.05	0.08
version	-0.02	0.00	0.01	0.00	0.07	0.08	0.04	0.04	0.06	0.11

type	0.04	0.01	-0.10	0.16	-0.05	0.05	0.08	0.15	0.12	0.38
day	-0.09	0.06	-0.09	0.13	-0.06	0.06	0.02	0.01	-0.04	0.04
nature	0.09	0.06	0.05	0.04	0.05	0.05	-0.10	0.23	-0.03	0.03
royal	-0.21	0.31	-0.17	0.40	-0.16	0.47	0.02	0.01	-0.16	0.69
therefore	-0.06	0.03	-0.07	0.07	0.06	0.07	-0.05	0.06	0.04	0.04
central	-0.29	0.60	0.01	0.00	-0.06	0.05	0.06	0.07	0.01	0.00
small	-0.11	0.08	0.01	0.00	-0.08	0.11	-0.06	0.09	-0.05	0.06
letter	0.05	0.02	0.08	0.09	-0.04	0.03	-0.06	0.08	0.13	0.47
common	-0.01	0.00	-0.04	0.02	0.04	0.03	0.08	0.16	0.02	0.01
european	-0.21	0.33	-0.04	0.03	0.05	0.04	0.09	0.19	0.01	0.00
identify	-0.09	0.06	0.00	0.00	0.00	0.00	0.03	0.02	-0.02	0.01
christ	-0.08	0.04	0.16	0.35	0.11	0.22	-0.23	1.24	-0.15	0.64
live	-0.03	0.01	0.07	0.06	-0.04	0.03	0.06	0.07	-0.06	0.09
set	-0.04	0.01	0.07	0.07	0.04	0.03	-0.05	0.05	0.01	0.00
several	-0.10	0.07	-0.07	0.06	-0.04	0.02	-0.06	0.07	-0.01	0.00
influence	0.01	0.00	0.06	0.05	0.09	0.15	0.03	0.02	-0.00	0.00
east	-0.13	0.11	-0.05	0.03	0.01	0.00	0.05	0.05	-0.00	0.00
archaeological	-0.41	1.15	0.02	0.00	-0.13	0.28	0.06	0.08	0.08	0.17
origin	-0.07	0.04	-0.02	0.00	0.08	0.10	0.07	0.11	-0.03	0.02
value	-0.32	0.72	-0.06	0.05	0.10	0.15	0.02	0.01	-0.05	0.08
understand	0.00	0.00	0.14	0.28	0.05	0.05	-0.02	0.01	-0.04	0.05
leave	0.02	0.00	-0.03	0.01	0.02	0.01	-0.11	0.25	0.03	0.03
translation	0.17	0.20	0.04	0.03	-0.02	0.01	-0.02	0.01	-0.00	0.00
less	0.15	0.15	0.03	0.01	-0.10	0.15	-0.01	0.00	-0.05	0.06
possible	-0.03	0.01	-0.07	0.07	-0.05	0.05	-0.02	0.01	-0.00	0.00
general	0.09	0.06	-0.12	0.19	-0.05	0.04	-0.03	0.03	0.03	0.03
especially	0.03	0.00	-0.05	0.03	0.02	0.01	-0.00	0.00	0.02	0.01
claim	0.12	0.10	0.11	0.15	0.12	0.24	0.06	0.09	-0.01	0.00
article	-0.22	0.34	0.00	0.00	0.08	0.11	-0.05	0.06	0.03	0.03
idea	0.05	0.01	0.12	0.18	0.15	0.34	0.06	0.07	-0.01	0.00
indicate	0.02	0.00	-0.12	0.19	-0.05	0.04	-0.15	0.51	0.02	0.01
event	-0.08	0.05	0.01	0.00	0.07	0.07	0.04	0.03	0.03	0.02

play	0.27	0.48	0.19	0.47	-0.28	1.21	0.06	0.08	-0.01	0.00
poem	0.52	1.81	0.16	0.34	-0.27	1.12	0.00	0.00	-0.04	0.03
support	-0.09	0.05	-0.05	0.03	-0.02	0.00	0.03	0.01	0.04	0.04
regard	-0.00	0.00	0.07	0.07	0.02	0.01	0.00	0.00	0.13	0.41
pagan	-0.03	0.00	0.19	0.47	-0.12	0.23	-0.18	0.65	0.00	0.00
probably	0.06	0.02	-0.13	0.23	-0.12	0.22	-0.09	0.17	0.11	0.30
town	-0.01	0.00	0.45	2.67	-0.39	2.36	-0.01	0.00	-0.06	0.09
non	-0.08	0.04	-0.08	0.08	0.07	0.07	-0.08	0.12	-0.05	0.05
hold	0.12	0.09	-0.07	0.06	-0.04	0.02	-0.01	0.00	-0.01	0.00
relate	-0.11	0.07	-0.00	0.00	0.11	0.19	-0.05	0.05	0.01	0.00
studies	0.09	0.05	0.09	0.11	0.02	0.01	0.06	0.06	-0.05	0.06
need	0.06	0.03	-0.01	0.00	0.02	0.01	-0.04	0.03	-0.01	0.00
perhaps	0.22	0.31	-0.05	0.03	-0.02	0.00	-0.10	0.20	-0.04	0.04
court	0.21	0.29	-0.12	0.17	-0.05	0.04	0.16	0.54	0.02	0.01
least	0.08	0.04	-0.06	0.05	-0.05	0.04	-0.03	0.02	-0.04	0.03
chapter	0.29	0.54	-0.29	1.05	-0.06	0.05	0.49	4.99	-0.02	0.01
south	-0.07	0.03	-0.05	0.04	-0.06	0.06	0.04	0.03	0.19	0.87
last	-0.04	0.01	0.00	0.00	0.03	0.02	0.01	0.00	-0.00	0.00
argue	0.17	0.17	0.15	0.27	0.09	0.12	0.05	0.04	0.00	0.00
turn	0.07	0.03	0.05	0.03	0.06	0.05	-0.01	0.00	-0.02	0.01
scholar	0.13	0.10	0.07	0.06	0.03	0.01	0.07	0.09	0.02	0.01
emperor	-0.20	0.26	0.07	0.05	-0.02	0.01	-0.06	0.07	0.15	0.58
particular	0.10	0.06	0.09	0.10	0.08	0.11	-0.00	0.00	0.00	0.00
contemporary	0.05	0.01	0.04	0.02	0.08	0.09	0.10	0.20	0.06	0.08
cross	0.04	0.01	-0.06	0.04	0.22	0.73	-0.10	0.22	-0.14	0.46
chronicle	-0.09	0.05	0.01	0.00	0.18	0.51	-0.16	0.49	0.05	0.06
subject	0.15	0.14	-0.02	0.01	-0.03	0.01	0.02	0.01	0.08	0.16
knowledge	0.07	0.03	0.00	0.00	0.04	0.02	0.13	0.34	-0.04	0.04
kingdom	-0.01	0.00	0.06	0.05	-0.05	0.04	-0.18	0.65	-0.04	0.04
william	0.23	0.34	0.19	0.47	0.29	1.27	0.10	0.22	0.05	0.07
structure	-0.15	0.13	-0.04	0.02	-0.03	0.01	0.00	0.00	0.15	0.55
literary	0.22	0.30	-0.08	0.08	-0.07	0.08	0.13	0.36	-0.07	0.12

bring	0.08	0.04	0.01	0.00	-0.06	0.05	-0.02	0.01	0.01	0.00
model	-0.18	0.19	0.06	0.05	0.12	0.22	0.05	0.04	-0.16	0.64
element	-0.04	0.01	0.01	0.00	0.11	0.17	-0.01	0.00	0.13	0.43
relationship	0.01	0.00	0.13	0.22	0.03	0.02	0.04	0.03	-0.01	0.00
concern	0.14	0.12	-0.07	0.05	-0.03	0.01	0.01	0.00	0.01	0.00
act	-0.05	0.02	0.05	0.03	0.11	0.18	-0.12	0.27	-0.08	0.14
northern	-0.13	0.11	-0.03	0.01	0.04	0.03	0.20	0.74	0.07	0.10
establish	0.02	0.00	0.06	0.04	-0.05	0.04	0.02	0.01	-0.01	0.00
contain	-0.06	0.02	-0.07	0.05	0.07	0.08	-0.09	0.15	-0.05	0.05
authority	0.02	0.00	0.00	0.00	0.04	0.03	0.03	0.02	0.11	0.27
create	-0.07	0.03	0.09	0.09	0.12	0.21	0.01	0.00	0.10	0.24
original	0.06	0.02	0.02	0.00	-0.01	0.00	-0.04	0.03	0.06	0.07
far	0.08	0.04	-0.00	0.00	0.00	0.00	-0.01	0.00	0.06	0.08
religion	-0.02	0.00	0.24	0.66	0.18	0.44	-0.03	0.02	-0.03	0.03
continue	-0.02	0.00	0.09	0.09	0.01	0.00	-0.02	0.01	0.01	0.00
various	-0.01	0.00	-0.02	0.00	0.03	0.02	-0.07	0.10	-0.04	0.04
sense	0.20	0.23	0.05	0.03	0.09	0.11	-0.05	0.05	-0.05	0.06
iii	0.22	0.29	-0.34	1.34	-0.06	0.05	-0.08	0.13	-0.13	0.39
system	-0.07	0.03	0.06	0.04	0.16	0.36	-0.04	0.03	0.18	0.77
jewish	-0.66	2.56	-0.09	0.09	-0.02	0.01	-0.13	0.33	-0.08	0.14
norman	0.17	0.17	0.32	1.17	-0.03	0.02	0.19	0.65	-0.02	0.01
publish	-0.20	0.22	-0.06	0.04	-0.11	0.17	0.08	0.11	0.07	0.11
process	-0.17	0.17	0.02	0.01	0.03	0.01	0.00	0.00	0.06	0.07
report	-0.08	0.04	0.03	0.01	0.09	0.12	-0.08	0.11	-0.11	0.30
battle	0.26	0.39	-0.03	0.01	0.25	0.88	-0.24	1.04	0.14	0.41
discuss	0.08	0.04	-0.05	0.03	0.00	0.00	-0.03	0.02	-0.03	0.02
force	0.16	0.15	-0.02	0.01	0.05	0.03	-0.14	0.36	0.08	0.15
likely	-0.12	0.09	0.09	0.09	-0.01	0.00	0.01	0.00	0.01	0.00
clear	0.05	0.02	0.08	0.07	-0.01	0.00	-0.02	0.00	0.01	0.00
interpretation	0.15	0.13	0.03	0.01	0.01	0.00	-0.15	0.41	0.14	0.44
section	0.07	0.03	0.00	0.00	0.18	0.46	-0.02	0.00	-0.03	0.02
already	-0.05	0.01	-0.07	0.06	-0.04	0.03	0.01	0.00	-0.01	0.00

level	0.14	0.11	-0.16	0.29	-0.05	0.03	-0.22	0.93	-0.04	0.04
low	-0.03	0.00	-0.10	0.11	-0.08	0.09	-0.13	0.29	-0.03	0.01
development	0.02	0.00	-0.02	0.01	0.06	0.06	-0.01	0.00	-0.01	0.00
trade	-0.15	0.12	0.11	0.14	-0.19	0.51	0.01	0.00	0.22	1.04
datum	-0.54	1.65	-0.22	0.52	-0.05	0.03	0.03	0.02	-0.06	0.08
approach	-0.10	0.05	0.05	0.03	0.04	0.03	0.09	0.14	-0.03	0.01
german	0.06	0.02	-0.15	0.24	0.05	0.03	0.14	0.37	0.21	0.94
greek	0.07	0.02	-0.02	0.01	0.00	0.00	0.06	0.07	-0.18	0.74
military	-0.17	0.17	0.01	0.00	0.25	0.80	-0.04	0.03	0.02	0.01
indeed	0.13	0.10	-0.02	0.00	-0.04	0.02	-0.06	0.07	-0.05	0.06
eastern	-0.28	0.42	-0.06	0.05	-0.02	0.00	0.10	0.18	-0.03	0.02
think	0.14	0.10	0.08	0.07	0.05	0.03	0.02	0.01	-0.00	0.00
historian	0.00	0.00	-0.07	0.06	0.03	0.01	0.12	0.25	0.13	0.37
issue	0.06	0.02	-0.03	0.01	-0.08	0.09	0.10	0.19	0.02	0.01
reason	0.12	0.07	0.05	0.03	0.08	0.07	0.00	0.00	0.06	0.07
other	0.11	0.07	0.07	0.05	0.03	0.01	-0.04	0.02	-0.05	0.06
byzantine	-0.29	0.46	-0.17	0.31	0.01	0.00	-0.18	0.58	-0.22	1.02
certain	0.05	0.01	-0.08	0.07	-0.00	0.00	-0.16	0.42	0.06	0.07
national	-0.07	0.03	0.10	0.10	0.11	0.15	0.07	0.09	0.21	0.90
legal	-0.33	0.59	-0.15	0.24	0.05	0.04	0.12	0.25	0.22	1.01
interest	0.09	0.04	0.00	0.00	-0.09	0.11	0.01	0.00	-0.01	0.00
draw	0.11	0.06	-0.07	0.06	-0.02	0.01	0.01	0.00	-0.00	0.00
serve	0.04	0.01	0.07	0.06	0.11	0.14	0.04	0.02	0.06	0.08
archaeology	-0.26	0.37	-0.11	0.13	-0.08	0.09	0.09	0.15	-0.02	0.01
information	-0.15	0.13	-0.10	0.11	-0.11	0.16	0.02	0.00	0.09	0.15
position	-0.12	0.08	0.01	0.00	-0.03	0.01	-0.03	0.02	0.00	0.00
explain	0.04	0.01	-0.05	0.02	0.04	0.02	-0.06	0.06	-0.04	0.04
produce	0.14	0.10	-0.03	0.01	-0.08	0.08	-0.01	0.00	-0.08	0.13
british	0.22	0.25	0.10	0.11	-0.10	0.14	0.09	0.15	-0.04	0.04
focus	-0.10	0.05	0.11	0.12	0.07	0.07	0.07	0.08	0.02	0.01
und	-0.14	0.10	-0.16	0.26	0.01	0.00	0.09	0.15	0.09	0.15
imperial	-0.04	0.01	0.07	0.06	-0.04	0.02	0.01	0.00	0.13	0.33

child	0.21	0.23	0.05	0.03	-0.24	0.75	-0.19	0.59	0.01	0.00
christians	-0.22	0.26	0.24	0.59	-0.03	0.01	-0.13	0.26	-0.04	0.04
close	-0.02	0.00	-0.06	0.04	-0.01	0.00	0.02	0.01	0.01	0.00
antiquity	-0.30	0.47	-0.03	0.01	0.05	0.03	0.06	0.06	0.04	0.03
edition	0.31	0.49	-0.17	0.30	-0.06	0.05	0.16	0.41	-0.04	0.03
barbarian	0.12	0.07	-0.12	0.15	0.16	0.31	0.34	1.89	-0.16	0.50
sample	-0.90	4.17	-0.25	0.67	-0.04	0.02	-0.07	0.09	-0.32	2.02
associate	-0.02	0.00	0.01	0.00	0.07	0.05	0.04	0.03	-0.01	0.00
discussion	0.22	0.24	-0.07	0.06	-0.05	0.03	0.02	0.01	0.02	0.01
status	-0.09	0.04	0.05	0.02	0.03	0.01	0.04	0.03	0.01	0.00
building	-0.28	0.40	0.03	0.01	-0.24	0.71	-0.02	0.01	0.40	3.15
offer	0.15	0.12	0.12	0.16	0.01	0.00	0.10	0.16	-0.04	0.04
house	0.03	0.01	0.04	0.02	-0.18	0.39	-0.05	0.03	-0.06	0.06
speak	0.15	0.12	0.03	0.01	-0.09	0.09	-0.05	0.04	0.05	0.05
fall	0.04	0.01	0.04	0.02	0.01	0.00	-0.01	0.00	0.01	0.00
attempt	0.15	0.11	0.05	0.03	0.00	0.00	-0.10	0.15	0.01	0.00
main	-0.27	0.37	-0.01	0.00	-0.02	0.01	0.03	0.01	-0.04	0.02
christianity	-0.22	0.24	0.12	0.14	0.07	0.06	-0.07	0.08	0.14	0.39
italy	-0.22	0.24	0.01	0.00	-0.11	0.14	-0.03	0.02	0.03	0.02
problem	0.11	0.06	-0.08	0.07	-0.02	0.00	-0.01	0.00	0.01	0.00
mark	0.05	0.01	0.07	0.05	0.17	0.36	0.00	0.00	-0.01	0.00
henry	0.28	0.40	0.01	0.00	0.36	1.54	-0.03	0.01	0.02	0.01
wife	0.66	2.17	-0.43	1.82	-0.38	1.73	-0.47	3.61	-0.09	0.15
particularly	0.05	0.01	0.09	0.08	-0.09	0.10	-0.10	0.15	-0.03	0.01
relation	0.05	0.01	0.02	0.00	0.03	0.01	-0.09	0.13	0.09	0.16
father	0.21	0.22	0.45	2.00	-0.35	1.48	0.09	0.12	-0.08	0.14
description	-0.02	0.00	0.06	0.04	-0.02	0.00	-0.10	0.17	0.02	0.01
animal	-0.09	0.04	0.05	0.02	0.10	0.13	0.04	0.02	0.11	0.25
von	-0.22	0.23	-0.15	0.23	0.03	0.01	0.05	0.04	0.18	0.62
holy	-0.16	0.13	0.04	0.01	0.28	0.91	-0.08	0.11	-0.17	0.53
twelfth	0.34	0.56	0.08	0.07	-0.01	0.00	0.13	0.26	-0.21	0.88
activity	-0.25	0.31	-0.03	0.01	0.00	0.00	-0.11	0.19	0.07	0.08

cause	-0.01	0.00	-0.02	0.00	0.03	0.01	-0.15	0.37	0.09	0.17
little	0.20	0.20	0.00	0.00	-0.07	0.05	-0.07	0.08	-0.09	0.14
control	-0.09	0.04	-0.01	0.00	-0.10	0.11	-0.03	0.01	-0.11	0.24
review	0.19	0.18	-0.12	0.15	-0.05	0.03	0.15	0.37	0.06	0.06
allow	-0.04	0.01	-0.01	0.00	-0.03	0.01	0.02	0.01	-0.02	0.01
paul	-0.04	0.01	0.10	0.11	0.19	0.44	-0.02	0.00	-0.24	1.05
theory	0.08	0.03	-0.06	0.04	0.15	0.25	0.05	0.04	-0.06	0.08
list	0.09	0.04	-0.13	0.17	-0.08	0.07	0.07	0.08	-0.04	0.03
table	-0.26	0.32	-0.09	0.08	-0.08	0.07	0.06	0.06	-0.10	0.19
reflect	-0.00	0.00	-0.02	0.00	-0.02	0.00	0.03	0.02	-0.00	0.00
link	-0.08	0.03	-0.01	0.00	0.17	0.32	0.08	0.10	0.03	0.01
difference	-0.13	0.08	-0.04	0.01	0.11	0.14	-0.08	0.09	-0.10	0.18
recent	0.08	0.03	-0.03	0.01	0.07	0.05	0.05	0.04	-0.10	0.17
experience	-0.04	0.01	0.06	0.04	-0.05	0.02	0.12	0.21	0.14	0.36
third	-0.09	0.04	-0.05	0.03	-0.06	0.04	0.01	0.00	-0.01	0.00
introduction	0.06	0.02	-0.01	0.00	0.06	0.05	0.22	0.73	-0.04	0.03
castle	-0.03	0.01	0.50	2.40	-0.07	0.05	-0.02	0.01	0.54	5.40
past	-0.12	0.07	0.03	0.01	0.05	0.03	0.09	0.13	0.11	0.24
feature	0.06	0.02	-0.12	0.13	0.02	0.01	-0.04	0.02	0.04	0.04
character	0.06	0.02	0.08	0.05	0.13	0.20	-0.00	0.00	-0.05	0.05
classical	0.25	0.28	-0.19	0.33	-0.05	0.02	0.27	1.13	0.01	0.00
detail	0.03	0.00	-0.02	0.00	-0.02	0.00	-0.01	0.00	0.12	0.25
reveal	-0.08	0.03	-0.00	0.00	-0.10	0.12	-0.03	0.01	-0.06	0.06
presence	-0.14	0.10	0.02	0.00	-0.12	0.15	-0.09	0.12	0.01	0.00
ruler	-0.11	0.05	0.17	0.28	0.17	0.34	-0.09	0.12	0.05	0.05
compare	-0.01	0.00	-0.20	0.38	0.02	0.01	0.30	1.34	0.00	0.00
conquest	-0.02	0.00	-0.00	0.00	0.08	0.07	0.04	0.02	-0.05	0.04
islamic	-0.10	0.05	-0.13	0.15	0.14	0.23	0.34	1.76	-0.05	0.05
army	0.01	0.00	0.04	0.02	0.39	1.70	-0.20	0.59	0.04	0.02
concept	-0.06	0.02	-0.07	0.04	0.14	0.21	0.10	0.15	0.08	0.12
female	0.14	0.08	-0.06	0.03	0.06	0.03	-0.20	0.58	0.02	0.01
course	0.26	0.32	0.01	0.00	0.03	0.01	-0.01	0.00	-0.03	0.02

look	0.21	0.19	0.02	0.01	-0.11	0.14	-0.15	0.33	0.06	0.07
mongol	-0.22	0.21	0.18	0.30	-0.33	1.22	-0.01	0.00	0.38	2.64
poet	0.45	0.93	0.22	0.46	-0.27	0.81	-0.00	0.00	-0.06	0.06
clearly	0.12	0.06	0.00	0.00	-0.02	0.00	-0.05	0.03	0.03	0.02
stand	0.13	0.08	-0.01	0.00	-0.05	0.03	-0.11	0.19	0.02	0.01
collection	0.14	0.09	-0.11	0.12	-0.07	0.05	-0.00	0.00	-0.06	0.06
daughter	0.22	0.21	0.91	7.55	-0.73	5.85	0.22	0.68	-0.16	0.48
public	0.07	0.02	-0.09	0.08	-0.13	0.18	0.04	0.02	0.03	0.02
edit	-0.34	0.52	0.05	0.02	-0.10	0.11	0.08	0.10	-0.22	0.85
page	0.00	0.00	-0.06	0.03	0.00	0.00	-0.04	0.02	0.10	0.18
light	-0.10	0.04	0.07	0.05	0.13	0.18	-0.09	0.11	0.11	0.20
burial	-0.64	1.83	-0.24	0.51	0.05	0.02	0.08	0.10	-0.11	0.23
kind	0.24	0.27	0.01	0.00	0.12	0.15	-0.07	0.07	-0.02	0.00
function	0.07	0.02	0.05	0.02	-0.05	0.03	0.07	0.06	0.09	0.13
thing	0.15	0.11	-0.00	0.00	0.09	0.08	-0.10	0.13	-0.12	0.24
build	-0.27	0.33	0.02	0.00	-0.09	0.09	-0.04	0.02	0.18	0.57
southern	-0.11	0.05	0.06	0.04	-0.11	0.12	0.01	0.00	0.11	0.22
whole	0.12	0.06	-0.08	0.06	0.01	0.00	-0.06	0.05	-0.04	0.03
copy	0.00	0.00	-0.24	0.53	-0.12	0.14	0.14	0.27	-0.19	0.60
muslim	-0.25	0.27	0.33	0.97	-0.11	0.13	-0.01	0.00	0.27	1.23
significant	-0.22	0.21	-0.06	0.03	0.02	0.00	-0.04	0.03	-0.06	0.06
contrast	0.13	0.07	-0.00	0.00	0.04	0.02	0.10	0.14	-0.05	0.05
object	-0.05	0.01	0.07	0.04	0.10	0.10	-0.10	0.13	0.07	0.09
receive	-0.14	0.08	-0.06	0.04	0.05	0.03	-0.02	0.01	-0.10	0.17
together	-0.06	0.01	-0.03	0.01	0.00	0.00	-0.00	0.00	-0.00	0.00
develop	0.02	0.00	0.06	0.03	0.06	0.04	-0.01	0.00	0.02	0.01
irish	0.30	0.40	0.00	0.00	0.20	0.41	0.33	1.56	0.22	0.82
economic	-0.10	0.04	0.09	0.08	-0.15	0.22	0.03	0.01	-0.03	0.02
open	-0.09	0.03	-0.01	0.00	0.02	0.00	-0.05	0.04	0.07	0.09
believe	0.09	0.04	0.15	0.19	-0.01	0.00	-0.05	0.04	-0.04	0.03
faith	-0.16	0.11	0.15	0.19	0.12	0.15	-0.04	0.02	0.00	0.00
instance	0.16	0.11	0.09	0.08	0.29	0.90	-0.11	0.17	-0.02	0.00

half	-0.10	0.04	-0.16	0.22	-0.07	0.05	0.00	0.00	0.01	0.00
writing	0.11	0.06	-0.19	0.30	-0.04	0.02	-0.09	0.11	-0.03	0.01
tell	0.16	0.10	-0.01	0.00	-0.09	0.09	-0.01	0.00	-0.07	0.08
space	-0.15	0.10	0.08	0.06	-0.01	0.00	0.09	0.12	0.23	0.93
specific	-0.14	0.09	0.00	0.00	0.02	0.00	0.04	0.02	0.01	0.00
lake	0.34	0.51	0.48	1.97	1.07	11.83	-0.42	2.50	-0.22	0.80
britain	0.05	0.01	0.45	1.73	0.06	0.04	0.02	0.00	-0.15	0.38
demonstrate	-0.07	0.02	0.13	0.14	-0.05	0.02	0.03	0.01	-0.06	0.06
almost	0.13	0.07	-0.11	0.10	-0.02	0.00	-0.02	0.00	-0.03	0.02
increase	-0.13	0.07	0.02	0.00	0.22	0.50	-0.13	0.24	-0.09	0.15
robert	0.01	0.00	-0.10	0.08	-0.07	0.05	-0.14	0.26	-0.19	0.59
head	-0.02	0.00	-0.07	0.04	0.02	0.00	-0.14	0.26	-0.02	0.00
side	0.01	0.00	-0.01	0.00	0.05	0.02	-0.03	0.01	0.04	0.03
popular	-0.06	0.01	-0.05	0.03	-0.11	0.12	0.06	0.06	-0.16	0.45
matter	0.22	0.20	-0.04	0.01	0.07	0.05	0.04	0.03	-0.00	0.00
return	0.09	0.04	0.06	0.03	0.01	0.00	-0.01	0.00	0.01	0.00
reader	0.26	0.30	0.03	0.01	-0.05	0.03	0.18	0.47	-0.14	0.32
occur	0.11	0.05	-0.00	0.00	-0.04	0.02	-0.08	0.10	0.02	0.01
never	0.22	0.20	0.09	0.07	-0.08	0.06	-0.01	0.00	0.08	0.10
passage	0.20	0.16	-0.01	0.00	0.12	0.15	-0.01	0.00	-0.03	0.02
help	0.05	0.01	-0.02	0.00	0.08	0.07	-0.03	0.01	-0.00	0.00
add	0.12	0.06	-0.05	0.02	-0.03	0.01	0.09	0.12	-0.03	0.01
wall	-0.16	0.10	0.27	0.63	-0.32	1.01	-0.04	0.02	0.06	0.06
exist	0.05	0.01	0.01	0.00	0.08	0.06	0.02	0.00	0.04	0.02
member	0.10	0.05	0.00	0.00	0.09	0.08	0.28	1.05	-0.05	0.04
addition	0.03	0.00	0.08	0.05	-0.02	0.00	-0.05	0.04	-0.04	0.03
island	-0.16	0.11	0.42	1.44	-0.16	0.26	-0.02	0.00	-0.01	0.00
bear	0.14	0.08	0.05	0.02	0.02	0.00	-0.05	0.03	0.02	0.01
back	0.02	0.00	-0.02	0.00	0.00	0.00	-0.07	0.06	0.03	0.01
pattern	-0.10	0.04	0.01	0.00	-0.08	0.06	-0.09	0.11	0.12	0.22
series	0.07	0.02	-0.04	0.02	-0.08	0.07	0.04	0.02	0.01	0.00
ireland	0.17	0.12	0.07	0.04	0.23	0.52	0.29	1.14	-0.07	0.07

grant	-0.21	0.18	-0.04	0.01	-0.20	0.39	0.19	0.49	-0.24	0.97
peter	-0.05	0.01	0.06	0.03	0.15	0.21	-0.04	0.02	-0.11	0.18
face	0.12	0.06	-0.08	0.06	-0.15	0.23	-0.23	0.67	0.06	0.05
carry	-0.13	0.07	-0.12	0.12	0.02	0.00	-0.04	0.02	-0.01	0.00
muslims	-0.24	0.24	0.51	2.14	-0.43	1.77	0.07	0.07	0.06	0.06
library	0.12	0.05	-0.11	0.10	-0.10	0.10	0.16	0.31	-0.08	0.10
person	0.07	0.02	-0.09	0.07	0.12	0.13	-0.04	0.02	0.07	0.08
poetry	0.62	1.55	-0.31	0.80	-0.23	0.52	0.03	0.02	0.03	0.01
yet	0.11	0.05	-0.03	0.01	0.06	0.04	0.02	0.00	0.01	0.00
connection	-0.12	0.05	0.06	0.03	0.08	0.06	0.03	0.01	-0.04	0.03
natural	0.06	0.01	0.20	0.31	0.04	0.02	-0.06	0.04	-0.01	0.00
slavic	-0.11	0.05	0.27	0.59	-0.20	0.38	0.08	0.08	-0.06	0.06
arabic	0.25	0.25	-0.35	0.98	-0.15	0.23	0.39	1.98	-0.10	0.16
self	0.08	0.02	0.22	0.38	0.04	0.01	0.00	0.00	-0.05	0.04
method	-0.13	0.07	0.02	0.00	0.11	0.12	0.03	0.01	0.19	0.53
single	0.07	0.02	0.03	0.01	0.02	0.00	-0.00	0.00	0.03	0.02
water	-0.07	0.02	-0.31	0.77	-0.08	0.06	-0.32	1.30	-0.15	0.34
lack	0.02	0.00	-0.08	0.05	-0.05	0.02	-0.11	0.14	0.05	0.04
style	0.28	0.30	-0.20	0.31	0.02	0.00	0.14	0.23	0.13	0.25
mary	-0.37	0.54	-0.01	0.00	0.13	0.16	-0.09	0.11	-0.22	0.74
cite	0.35	0.48	-0.18	0.26	-0.11	0.12	0.08	0.07	0.05	0.04
thomas	0.16	0.10	0.01	0.00	0.10	0.10	0.20	0.51	-0.02	0.01
instead	0.05	0.01	0.11	0.10	0.16	0.24	-0.00	0.00	-0.03	0.02
production	-0.22	0.19	0.10	0.07	-0.25	0.58	0.08	0.08	0.05	0.04
short	0.12	0.05	-0.05	0.02	-0.05	0.02	0.09	0.11	-0.09	0.13
sea	-0.21	0.17	0.07	0.04	-0.08	0.05	0.03	0.01	-0.05	0.04
david	0.15	0.09	0.21	0.35	0.02	0.00	-0.12	0.19	-0.03	0.01
true	0.14	0.08	-0.06	0.03	-0.03	0.01	-0.04	0.02	-0.06	0.05
territory	-0.42	0.68	-0.01	0.00	-0.01	0.00	0.01	0.00	0.08	0.10
lord	-0.04	0.01	-0.08	0.05	-0.03	0.01	0.01	0.00	-0.21	0.66
access	-0.40	0.60	0.10	0.07	0.05	0.02	-0.01	0.00	-0.01	0.00
major	0.11	0.04	-0.04	0.01	-0.10	0.09	-0.04	0.02	0.12	0.23

master	0.16	0.09	-0.26	0.50	-0.06	0.03	0.23	0.64	0.28	1.16
ethnic	0.06	0.01	0.24	0.44	0.48	2.10	0.04	0.02	-0.04	0.02
richard	0.32	0.39	0.01	0.00	0.36	1.21	0.15	0.29	-0.03	0.01
viking	-0.14	0.08	0.25	0.48	-0.24	0.54	-0.04	0.02	-0.06	0.05
paper	0.03	0.00	-0.10	0.07	-0.16	0.22	0.07	0.05	-0.11	0.18
aspect	0.06	0.02	-0.04	0.01	0.01	0.00	0.01	0.00	0.12	0.22
involve	-0.01	0.00	0.04	0.01	-0.08	0.05	0.12	0.17	0.04	0.02
africa	0.09	0.03	0.08	0.04	-0.02	0.01	-0.02	0.00	0.17	0.44
define	0.02	0.00	0.06	0.02	0.01	0.00	0.02	0.01	0.05	0.04
shape	-0.16	0.10	0.04	0.01	-0.05	0.02	0.00	0.00	0.02	0.01
black	0.04	0.01	0.28	0.60	-0.29	0.75	-0.09	0.10	-0.10	0.14
representation	-0.13	0.06	-0.15	0.17	0.03	0.01	-0.18	0.40	-0.02	0.01
germanic	0.15	0.08	0.04	0.01	0.33	0.97	0.07	0.06	-0.08	0.10
direct	0.05	0.01	0.01	0.00	-0.03	0.01	0.10	0.11	-0.03	0.01
argument	0.19	0.14	-0.03	0.00	0.03	0.01	0.13	0.22	-0.08	0.09
post	-0.28	0.29	-0.06	0.03	-0.03	0.01	-0.09	0.10	-0.08	0.09
survive	0.19	0.13	0.05	0.02	-0.21	0.39	0.05	0.03	-0.06	0.06
gregory	-0.26	0.25	-0.12	0.11	0.14	0.19	-0.18	0.38	-0.22	0.71
seek	0.15	0.08	0.07	0.03	0.10	0.09	0.01	0.00	-0.06	0.05
put	0.29	0.30	-0.06	0.02	-0.09	0.08	-0.00	0.00	-0.02	0.01
country	-0.05	0.01	-0.00	0.00	-0.05	0.02	0.08	0.09	0.07	0.07
saga	0.00	0.00	0.13	0.12	0.17	0.25	0.21	0.52	-0.26	0.98
action	-0.02	0.00	-0.00	0.00	0.07	0.05	-0.04	0.02	-0.07	0.07
always	0.13	0.07	0.00	0.00	0.07	0.04	-0.03	0.01	-0.02	0.01
effect	-0.02	0.00	0.02	0.00	0.00	0.00	-0.00	0.00	0.05	0.04
tale	-0.26	0.25	0.16	0.19	-0.30	0.77	0.05	0.03	-0.18	0.48
river	-0.11	0.04	-0.11	0.08	-0.10	0.09	-0.08	0.07	0.20	0.56
due	-0.31	0.35	-0.02	0.00	0.03	0.01	-0.07	0.07	0.06	0.06
young	0.08	0.02	-0.01	0.00	-0.05	0.02	-0.15	0.28	-0.06	0.05
american	0.16	0.09	0.27	0.51	-0.18	0.27	0.03	0.01	-0.04	0.02
move	-0.05	0.01	0.00	0.00	0.02	0.00	0.09	0.08	0.03	0.01
construction	-0.04	0.01	0.39	1.10	-0.07	0.05	0.07	0.06	0.03	0.02

learn	0.22	0.17	0.05	0.02	-0.16	0.22	0.03	0.01	-0.07	0.07
available	-0.17	0.11	-0.20	0.29	0.04	0.02	0.11	0.15	-0.03	0.02

TABLE 7.28 – Résultats pour l'ensemble des facteurs

7.5.2 La LDA




FIGURE 7.24 – Test itératif de la cohérence selon le nombre de clusters k choisi




FIGURE 7.25 – Courbe de convergence du modèle LDA à 14 topics